PROJETO 2 · CIÊNCIA DE DADOS · UNIFOR

Previsão da nota de Matemática do ENEM 2023

Acompanhamento: dados, features e resultados preliminares

EQUIPE

João Igor Vidal de Andrade · Raquel Albuquerque Quirino · Amanda Lira · Sofya Oliveira

Alvo: NU_NOTA_MT

EQUIPE

Divisão das atividades

Integrante	Contribuições no projeto
João Igor Vidal de Andrade	Exploração complementar dos dados e treinamento preliminar. Responsável pelos modelos baseline pela média e Ridge.
Raquel Albuquerque Quirino	Análise exploratória, criação dos documentos, dos slides e do artigo. Organização das tarefas da equipe.
Amanda Lira	Análise exploratória, limpeza e higienização da base, análise de outliers e demais etapas de preparação.
Sofya Oliveira	Engenharia de features e análise da relação das features com o alvo, para orientar as escolhas do grupo.

O PROBLEMA

Alvo, tarefa e fonte dos dados

> Quanto o perfil socioeconômico, escolar e demográfico dos participantes permite estimar a nota de Matemática do ENEM 2023?

Item	Definição da equipe
Alvo	NU_NOTA_MT: nota de Matemática e suas Tecnologias (escala de 0 a 1000)
Tarefa	Regressão supervisionada: o alvo é um valor numérico contínuo, não uma classe
Entradas (X)	Perfil demográfico, trajetória escolar e questionário socioeconômico, todos conhecidos antes da prova
Fonte	Inep: Microdados do ENEM 2023, base nacional completa (3.933.955 registros e 76 colunas)
Repositório	github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

BASE DE DADOS

Diagnóstico da base completa e triagem do alvo

Indicador	Quantidade
Registros na base bruta	3.933.955
Sem nota de Matemática (31,56%)	1.241.528
Com nota observada, elegíveis (68,44%)	2.692.427
Treineiros na base bruta	620.067
Treineiros elegíveis (mantidos)	516.920
Treineiros sem nota (fora da regressão)	103.147

Decisões

- Sem NU_NOTA_MT: entra no diagnóstico, não no treino nem na avaliação. Nota ausente não é imputada nem vira zero.
- Toda a população elegível é usada, sem amostra por conveniência.
- Treineiros mantidos: IN_TREINEIRO é conhecido na inscrição.

PROTOCOLO DE AVALIAÇÃO

Partição 80/20 e validação cruzada

Conjunto	Registros	Proporção	Uso
Desenvolvimento	2.153.941	80%	Exploração, comparação de alternativas e validação cruzada
Teste	538.486	20%	Reservado para a avaliação final; não usado nesta etapa
Total	2.692.427	100%	Sem sobreposição de IDs (verificado)

Partição

random_state=42; IDs salvos em dados/splits/ e nunca usados como entrada.

Validação

KFold(n_splits=3, shuffle=True, random_state=42), mesmas dobras em todas as comparações.

Métricas

RMSE (principal), MAE e R^2, na escala original, com média ± desvio entre dobras.

DISTRIBUIÇÃO DO ALVO

NU_NOTA_MT no desenvolvimento (n = 2.153.941)

Medida	Pontos
Média	533,83
Desvio padrão	131,63
Mínimo	0,0
1º quartil	431,20
Mediana	523,50
3º quartil	630,10
Máximo	958,6
Menor nota acima de zero	319,8

Cauda longa à direita (média acima da mediana). O desvio padrão de 131,6 é o RMSE do baseline pela média.

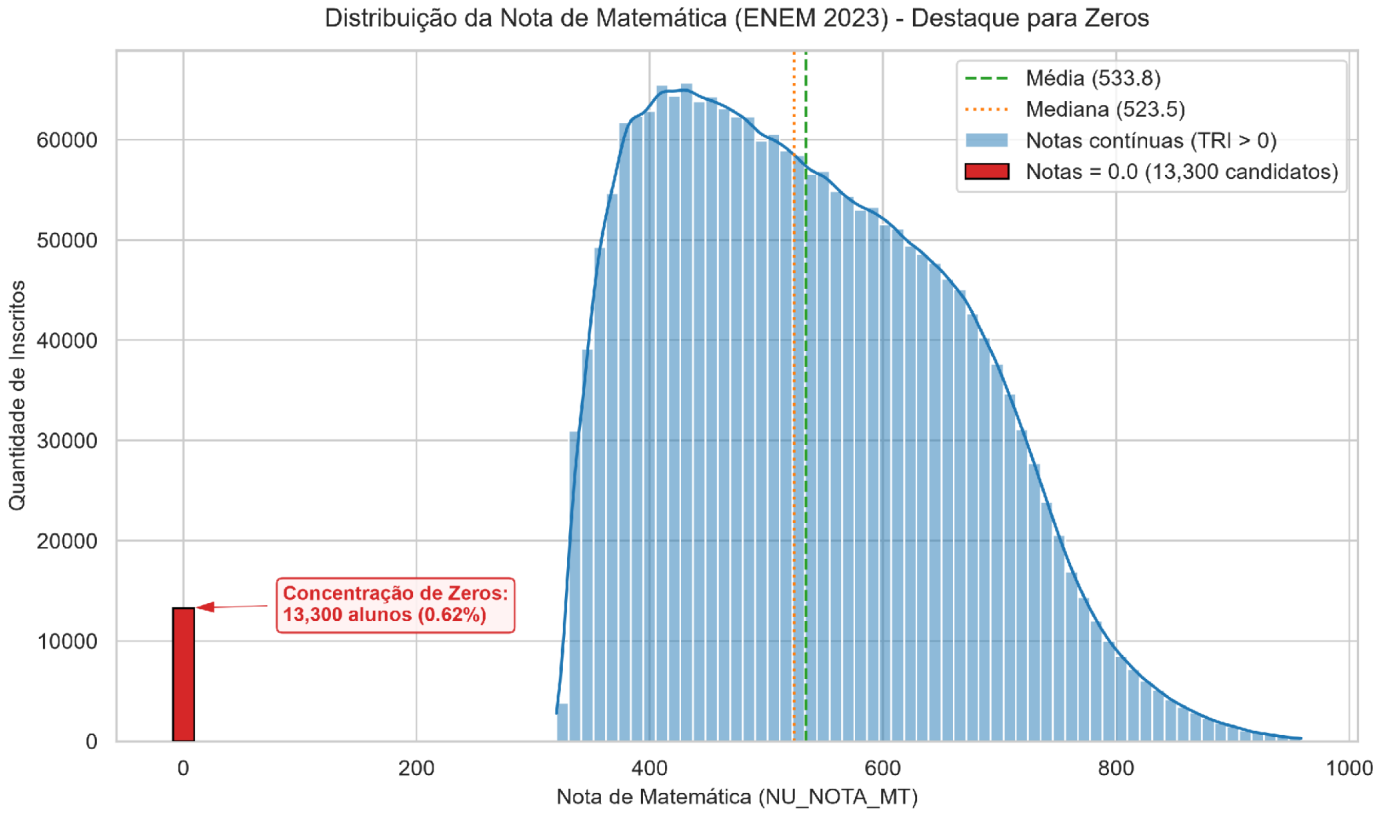
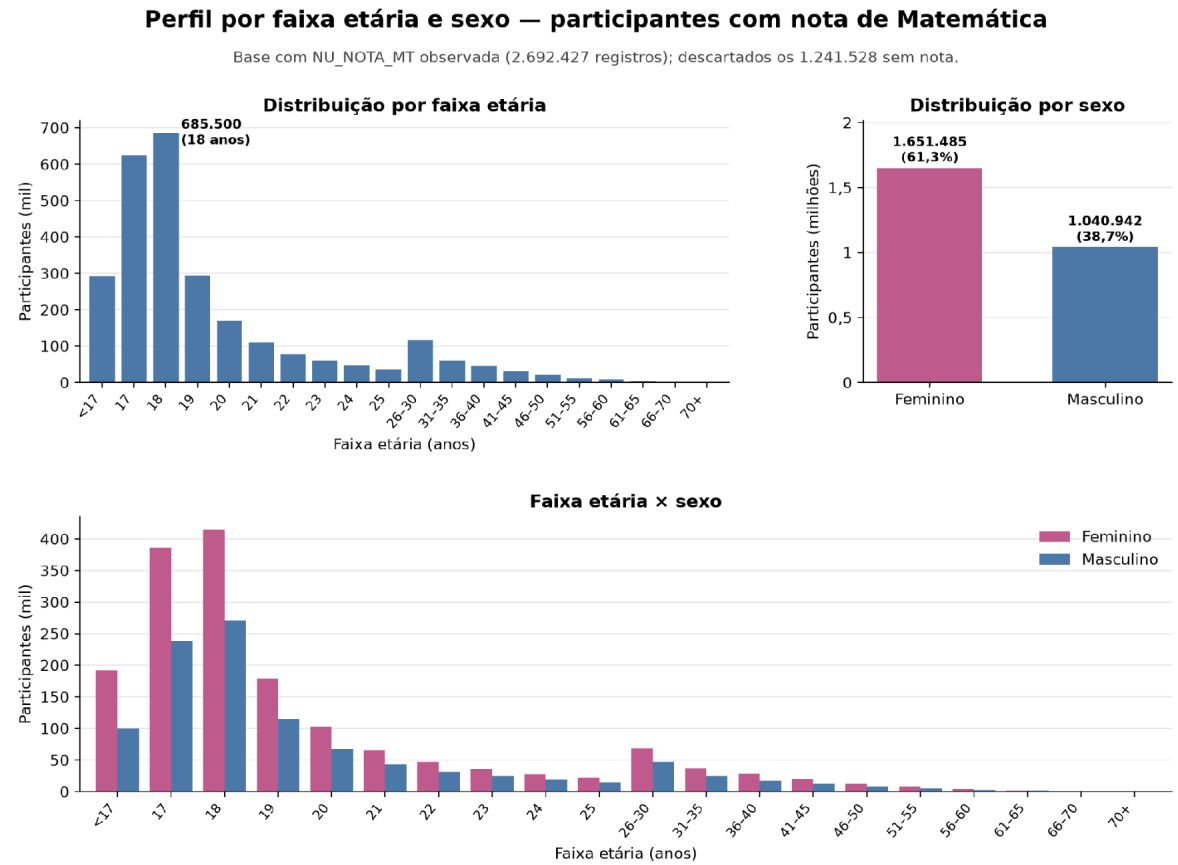


Figura 1 · Distribuição de NU_NOTA_MT, notas zero em destaque · Fonte: Inep, ENEM 2023

PERFIL DE QUEM TEM NOTA

Faixa etária e sexo



61,3%

são mulheres (1.651.485); homens são 38,7% (1.040.942)

59,5%

têm de 17 a 19 anos; a faixa de 18 anos é a maior (685.500)

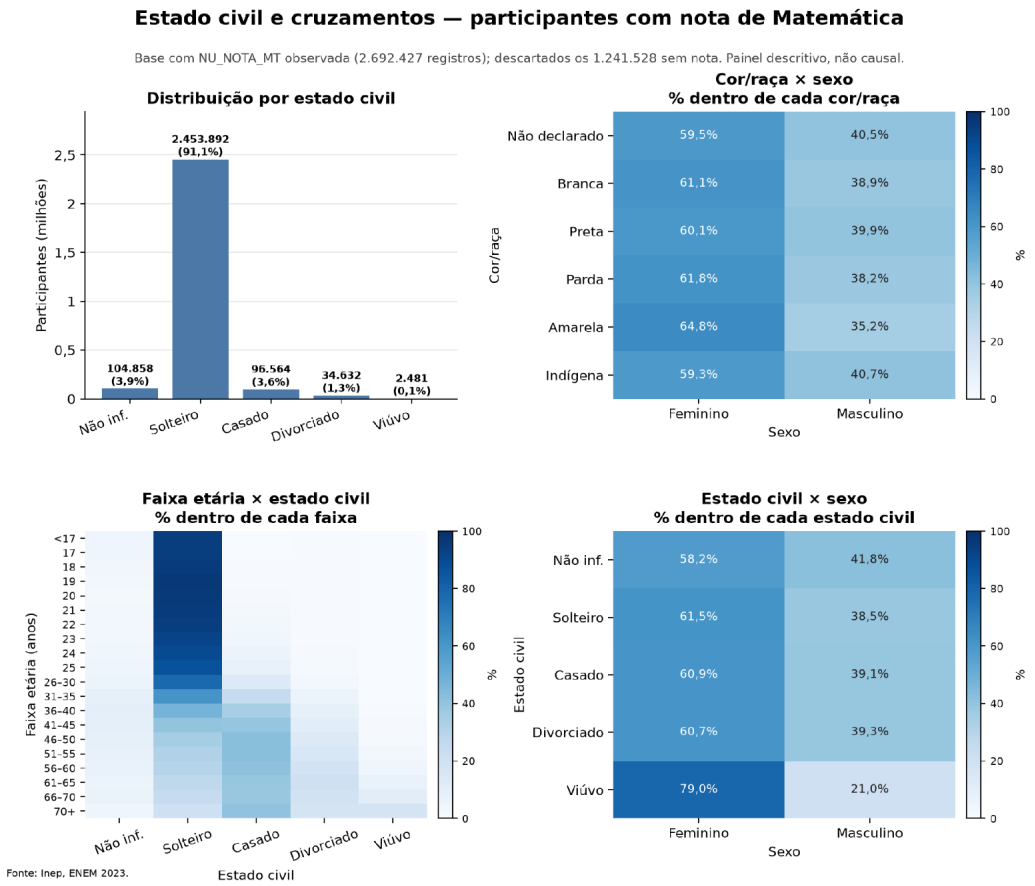
76,7%

têm até 20 anos; homens só são maioria acima dos 65

Figura 2 · 2.692.427 participantes com nota (exclui 1.241.528 sem nota) · Leitura descritiva, não causal · Fonte: Inep, ENEM 2023

PERFIL DE QUEM TEM NOTA

Estado civil e cruzamentos



91,1%

são solteiros (2.453.892); 3,9% não informaram, 3,6% são casados ou moram com companheiro(a)

59,3% a 64,8%

é a parcela feminina por cor/raça (indígenas a amarelos)

79,0%

dos viúvos são mulheres, em um grupo de apenas 2.481 participantes

Figura 3 · 2.692.427 participantes com nota · Leitura descritiva, não causal · Fonte: Inep, ENEM 2023

DISTRIBUIÇÃO DO ALVO

Notas zero e valores extremos

Indicador	Valor
Notas zero no desenvolvimento	13.300 (0,617%)
Notas zero entre todos os elegíveis	16.638
1º quartil (Q1): 25% têm até essa nota	431,20
3º quartil (Q3): 75% têm até essa nota	630,10
IQR = Q3 − Q1	198,90
Limite inferior = Q1 − 1,5 × IQR	132,85
Limite superior = Q3 + 1,5 × IQR	928,45
Notas abaixo do limite inferior	13.300, todas zero
Notas acima do limite superior	1.533
Notas fora da escala de 0 a 1000	0

Decisões

- Nota zero é resultado observado e válido, diferente de nota ausente: todas mantidas.
- O critério 1,5 × IQR é só um sinalizador exploratório: nenhuma nota é removida.
- Próximo passo: comparar o treino com e sem zeros no mesmo modelo, mantendo os zeros na validação e no teste.

INVENTÁRIO DOS DADOS

Das 76 colunas do arquivo às 138 colunas do modelo

76
colunas em MICRODADOS_ENEM_2023.csv

→

46
candidatas, escolhidas pelo dicionário do ENEM 2023

→

33
features mantidas: 8 de perfil e escola + 25 do questionário

→

138
colunas numéricas depois da codificação

Fora de X por vazamento: notas, presença, respostas, gabaritos, códigos de prova e ano.

13 candidatas deixadas fora da 1ª configuração, além de TP_LINGUA.

INVENTÁRIO · COLUNAS REMOVIDAS

Grupo	Colunas	Motivo
Notas de outras áreas	NU_NOTA_CN, NU_NOTA_CH, NU_NOTA_LC	Produzidas pela correção da prova
Redação	NU_NOTA_REDACAO, NU_NOTA_COMP1 a COMP5	Produzidas pela correção
Presença e situação da redação	TP_PRESENCA_*, TP_STATUS_REDACAO	Servem só ao diagnóstico da disponibilidade das notas
Respostas e gabaritos	TX_RESPOSTAS_*, TX_GABARITO_*	Derivam da prova realizada
Códigos de prova	CO_PROVA_*	Sem justificativa de pertinência para o problema
Ano	NU_ANO	Constante nesta edição
Identificador	NU_INSCRICAO	Só controla registros e partições

A função verificar_sem_vazamento (src/config.py) interrompe a execução se alguma coluna proibida aparecer entre as preditoras. A nota de Matemática compõe apenas o alvo y.

INVENTÁRIO · COLUNAS MANTIDAS

As 33 features usadas em X

Colunas	Tema	O que descreve
TP_FAIXA_ETARIA, TP_SEXO, TP_ESTADO_CIVIL, TP_COR_RACA, TP_ST_CONCLUSAO, TP_ESCOLA, TP_ENSINO, IN_TREINEIRO	Perfil e trajetória escolar (8)	Idade, sexo, estado civil, cor ou raça, conclusão do ensino médio, tipo de escola e de ensino, treineiro
Q001, Q002	Escolaridade dos responsáveis	De A (nunca estudou) a G (pós-graduação); H = não sei (9,34% em Q001 e 2,91% em Q002)
Q003, Q004	Ocupação dos responsáveis	Grupos A a E, sem distância numérica; F = não sei (11,94% em Q003 e 8,66% em Q004)
Q005, Q006	Moradores e renda	Número de moradores e faixa de renda familiar (A a Q)
Q007 a Q009	Domicílio	Empregada doméstica, banheiros e quartos
Q010 a Q021	Bens do domicílio	Carro, moto, eletrodomésticos, TV, DVD e TV por assinatura
Q022 a Q025	Telefonia e acesso digital	Celular, telefone fixo, computador e internet

“Não sei” em 4 colunas (Q001 a Q004): 21,88% do desenvolvimento têm ao menos um · Fonte: Inep, ENEM 2023

INVENTÁRIO · COLUNAS MANTIDAS

Questionário socioeconômico: Q001 a Q025

Var.	O que pergunta
Q001	Escolaridade do pai (A a G; H não sei)
Q002	Escolaridade da mãe (A a G; H não sei)
Q003	Ocupação do pai (grupos 1 a 5; F não sei)
Q004	Ocupação da mãe (grupos 1 a 5; F não sei)
Q005	Moradores na residência (1 a 20)
Q006	Renda mensal da família (faixas A a Q)
Q007	Empregado(a) doméstico(a), dias/semana
Q008	Banheiros (contagem)
Q009	Quartos para dormir (contagem)
Q010	Carros (contagem)
Q011	Motocicletas (contagem)
Q012	Geladeiras (contagem)
Q013	Freezers (contagem)

Var.	O que pergunta
Q014	Máquinas de lavar roupa (contagem)
Q015	Máquinas de secar roupa (contagem)
Q016	Fornos micro-ondas (contagem)
Q017	Máquinas de lavar louça (contagem)
Q018	Aspirador de pó (sim/não)
Q019	Televisões em cores (contagem)
Q020	Aparelho de DVD (sim/não)
Q021	TV por assinatura (sim/não)
Q022	Telefones celulares (contagem)
Q023	Telefone fixo (sim/não)
Q024	Computadores (contagem)
Q025	Acesso à internet (sim/não)

Contagens: A = não; B a E = 1, 2, 3 ou 4 ou mais · Fonte: dicionário de microdados do ENEM 2023 (Inep), texto resumido

INVENTÁRIO · COLUNAS RETIRADAS

Fora da 1ª configuração: campos da escola

Coluna(s)	Ausentes (elegíveis)	Motivo
CO_MUNICIPIO_ESC, NO_MUNICIPIO_ESC, CO_UF_ESC, SG_UF_ESC	73,10%	Baixa cobertura, muitas categorias e redundância entre código, nome e sigla. O município da escola não equivale à residência.
TP_DEPENDENCIA_ADM_ESC, TP_LOCALIZACAO_ESC	73,10%	Baixa cobertura. Candidatas a experimento posterior, com tratamento explícito das ausências.
TP_SIT_FUNC_ESC	73,10%	Baixa cobertura; descreve a situação da escola, informação indireta sobre a preparação individual.

⚠ 73,10% de ausências entre os participantes com nota (75,64% na base completa). A ausência não é tratada como aleatória nem imputada sem justificativa.

Decisão de modelagem: as colunas podem voltar em experimentos próprios, sem consultar o teste · Fonte: Inep, ENEM 2023

INVENTÁRIO · COLUNAS RETIRADAS

Fora da 1ª configuração: perfil e local de prova

Coluna(s)	Ausentes	Motivo
TP_NACIONALIDADE	sem ausência real	Decisão de escopo: a grande maioria é brasileira, então se espera pouca diferenciação. Pode ser revista.
TP_ANO_CONCLUIU	sem ausência real	Sobreposição parcial com TP_ST_CONCLUSAO e codificação especial (0 = não informado; 17 = antes de 2007).
CO_MUNICIPIO_PROVA, NO_MUNICIPIO_PROVA	sem ausência real	Local de aplicação não equivale à residência; código e nome redundantes; muitas categorias.
CO_UF_PROVA, SG_UF_PROVA	sem ausência real	UF de aplicação não equivale à residência; código e sigla redundantes. Será estudada em experimento próprio.
TP_LINGUA	—	Opção por inglês ou espanhol; ficou fora de X por decisão anterior.

Ao todo: 46 candidatas − 33 mantidas = 13 fora da 1ª configuração (Tabela 6 da documentação) · Fonte: Inep, ENEM 2023

PREPARAÇÃO DOS DADOS

Ausências, redundâncias e categorias raras

Ponto	O que encontramos	Decisão
TP_ENSINO	61,66% de ausências entre os elegíveis (65,96% na base completa)	Mantida; a ausência ganha indicador próprio e o efeito de mantê-la será comparado
“Não sei”, “não informado”	Respostas explícitas (ex.: H em Q001 e Q002)	Ficam separadas de ausência real
IN_TREINEIRO × TP_ST_CONCLUSAO	Associação perfeita (V de Cramér = 1,00): todo treineiro tem TP_ST_CONCLUSAO = 3 (está cursando e conclui o ensino médio depois de 2023), e ninguém com outro código é treineiro	Ambas mantidas por ora; verificar se usar as duas acrescenta algo
Categorias raras (abaixo de 1,5%)	Q006 faixas L a P; TP_COR_RACA 0 e 5; TP_ESTADO_CIVIL 3 e 4	Q006 vira ponto médio; as demais viram one-hot e são mantidas
Demais features	Sem ausências reais	Nenhum tratamento extra

Fonte: resultados/tabelas/categorias_raras.csv · Inep, ENEM 2023

PREPARAÇÃO DOS DADOS

Regras de codificação (determinísticas, pelo dicionário)

Tipo	Colunas	Tratamento
Nominais	TP_FAIXA_ETARIA, TP_SEXO, TP_ESTADO_CIVIL, TP_COR_RACA, TP_ST_CONCLUSAO, TP_ESCOLA, TP_ENSINO, Q003, Q004	One-hot com categorias fixas; a 1ª categoria é a referência
Escolaridade	Q001, Q002	A a G viram 0 a 6; H (não sei) gera o indicador DESCONHECE
Renda	Q006	Ponto médio da faixa em salários mínimos; Q usa o piso 20
Moradores	Q005	Número de moradores, com indicador de fora do domínio
Contagens	Q008 a Q017, Q019, Q022, Q024	A a E viram 0 a 4 (E = “4 ou mais”)
Binárias	Q018, Q020, Q021, Q023, Q025	Não ou sim, em 0 e 1
Empregada	Q007	A a D viram níveis ordinais de 0 a 3
Treineiro	IN_TREINEIRO	Mantida em 0 e 1

Indicadores __AUSENTE e __OUTRO quando se aplica · Resultado: **138 colunas numéricas** · Imputação pela mediana e padronização esparsa ficam no Pipeline.

Implementado em src/higienizacao.py a partir do notebook 03_limpeza_dados · Fonte: dicionário do ENEM 2023

PREPARAÇÃO DOS DADOS · EXEMPLO

Como o “não sei” vira o indicador DESCONHECE

Q001: “Até que série seu pai estudou?” A a G viram níveis de 0 a 6. O “não sei” (H) não cabe nessa escala, então ganha uma coluna própria de 0 e 1.

Aluno	Respondeu	Nível (0 a 6)	DESCONHECE
Ana	F: faculdade	5	0
Bruno	E: ensino médio	4	0
Carla	H: não sei	—	1

Por que assim

- Como 0, diria que o pai nunca estudou; como 7, mais que pós-graduação. Os dois seriam falsos.
- Ninguém é removido: 220.341 participantes (10,23%) com H em Q001 ou Q002 continuam nos dados.
- Remover ou imputar ainda será testado.

Exemplo ilustrativo · Mesma regra para Q002 (mãe) · Fonte: dicionário do ENEM 2023 (Inep)

ENGENHARIA DE FEATURES

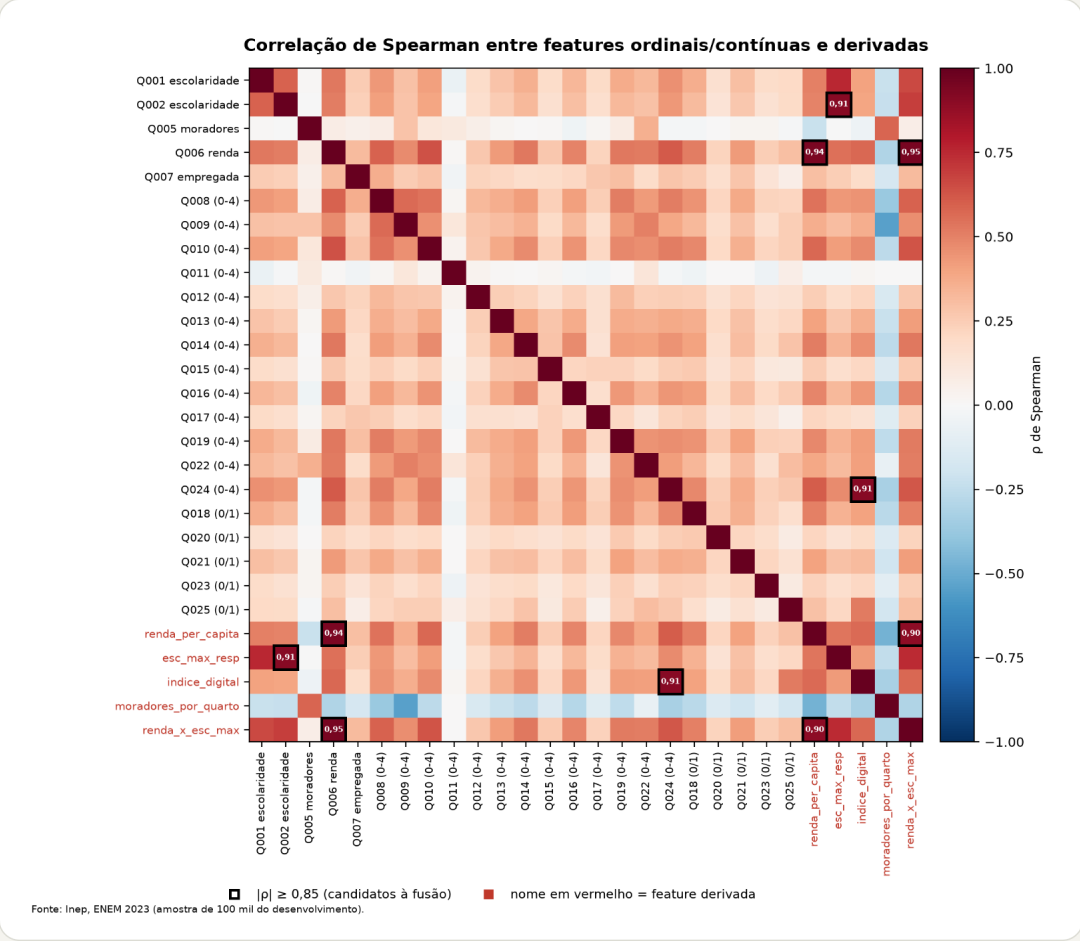
Cinco features derivadas, cada uma com uma hipótese

Feature	Fórmula	Hipótese e cuidado
Renda per capita	Q006_RENDA_SM_ESTIMADA / Q005_MORADORES	Renda por morador descreve melhor a condição material. Denominador inválido vira ausente.
Escolaridade máxima dos responsáveis	máximo de Q001 e Q002 (níveis)	O maior nível do domicílio resume o capital educacional. Se só um é conhecido, o outro é ignorado.
Índice de acesso digital	computador (Q024) e internet (Q025)	Computador e internet favorecem o estudo. Resposta ausente conta como “não tem”.
Moradores por quarto	Q005_MORADORES / Q009_CONTAGEM_ESTIMADA	Domicílio adensado dificulta o estudo. Quartos igual a 0 ou ausente vira ausente.
Renda × escolaridade	renda × escolaridade máxima	Os dois fatores se reforçam; árvores já aprendem a interação, modelos lineares não.

Calculadas sem aprender nada dos dados (notebook 02_analise_features), portanto sem vazamento

REDUNDÂNCIA ENTRE FEATURES

Correlação de Spearman entre 28 features



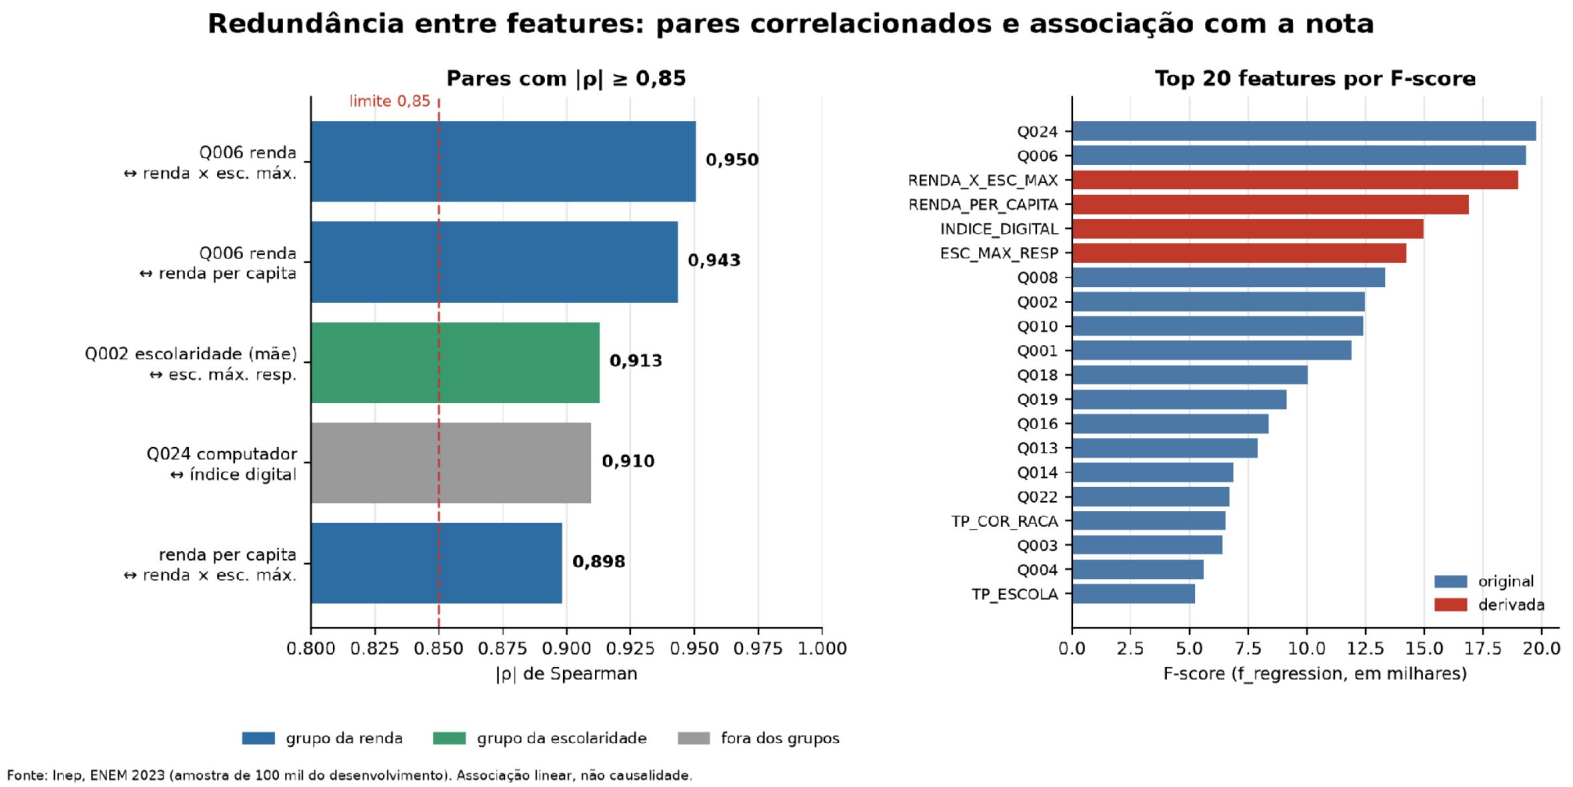
Pares com |ρ| ≥ 0,85 são candidatos à fusão. Amostra de 100 mil do desenvolvimento; dummies ficam de fora.

Par	ρ
Renda (Q006) × renda × escolaridade	0,950
Renda (Q006) × renda per capita	0,943
Escolaridade da mãe (Q002) × escolaridade máxima	0,913
Computador (Q024) × índice digital	0,910
Renda per capita × renda × escolaridade	0,898

Figura 4 · Contorno preto: |ρ| ≥ 0,85; nomes em vermelho: derivadas · Fonte: Inep, ENEM 2023

REDUNDÂNCIA ENTRE FEATURES

Grupos sugeridos e associação com a nota



O FeatureAgglomeration (limiar 0,15 = 1 − 0,85) sugeriu dois grupos: **renda** e **escolaridade**.

Computador × índice digital passa do limite, mas não formou grupo.

4 das 5 derivadas estão entre as 6 features mais associadas à nota, mas não trazem informação independente.

Figura 5 · F-score entre 38 features (33 originais + 5 derivadas) · Associação linear, não causalidade · Fonte: Inep, ENEM 2023

REDUNDÂNCIA ENTRE FEATURES

Features fundidas no experimento D

Resultante	Colunas de origem	|ρ| entre elas	Situação
FUSAO_RENDA	Q006, RENDA_PER_CAPITA, RENDA_X_ESC_MAX	0,898 a 0,950	Fundida
FUSAO_ESCOLARIDADE	Q002, ESC_MAX_RESP	0,913	Fundida
sem fusão	Q024 e INDICE_DIGITAL	0,910	Não formou grupo

Método

Cada grupo vira a média das colunas padronizadas (z-score), ajustada só no treino de cada dobra. Saem 5 colunas, entram 2 (143 para 140).

Resultado

No Ridge, a fusão piorou o RMSE em cerca de 0,11 ponto frente a B. O uso dela nos próximos modelos ainda será decidido.

ENGENHARIA DE FEATURES

Comparação das representações com o Ridge

Representação	RMSE	MAE	R^2
A. Originais (138 colunas)	110,647 ± 0,175	86,601 ± 0,057	0,2935
B. A + 5 derivadas (143)	110,447 ± 0,179	86,383 ± 0,057	0,2960
C. B + SelectKBest (k = 50)	111,284 ± 0,190	87,083 ± 0,049	0,2853
D. B com grupos fundidos (140)	110,553 ± 0,172	86,503 ± 0,050	0,2947

Derivadas (B × A)

RMSE caiu cerca de 0,2 ponto (0,18%), nas três dobras. Ganho pequeno: as derivadas são parcialmente redundantes.

Seleção (C)

Reduzir para 50 colunas piorou o erro, cerca de 0,6 ponto acima das originais.

Fusão (D × B)

0,11 ponto pior que B e 0,09 melhor que A, com 3 colunas a menos.

Ridge(alpha=1), KFold(3, shuffle=True, random_state=42), média ± desvio · Em verde: menor RMSE · Teste não usado

PREPARAÇÃO DOS DADOS

Respostas “não sei” sobre os responsáveis

Resposta “não sei”	Registros	% do dev.	Nota média: “não sei” × demais
Q001 = H (escolaridade do pai)	201.083	9,34%	496,8 × 537,6
Q002 = H (escolaridade da mãe)	62.572	2,91%	483,3 × 535,3
Q001 ou Q002 = H	220.341	10,23%	496,7 × 538,1
Q001 e Q002 = H	43.314	2,01%	477,9 × 535,0
Q003 = F (ocupação do pai)	257.093	11,94%	502,2 × 538,1
Q004 = F (ocupação da mãe)	186.453	8,66%	515,9 × 535,5
Q003 ou Q004 = F	370.624	17,21%	512,0 × 538,4
Qualquer “não sei” em Q001 a Q004	471.359	21,88%	508,6 × 540,9

Decisão atual: manter com o indicador DESCONHECE. Remover ou imputar ainda está em aberto; a comparação vai treinar com e sem esses registros e validar sempre no mesmo conjunto.

RESULTADOS PRELIMINARES

Visão geral dos experimentos

Experimento	Features	RMSE	MAE	R^2
Baseline (média)	Nenhuma (ignora X)	131,634 ± 0,158	107,582 ± 0,058	0,0000
Ridge A	138 colunas originais	110,647 ± 0,175	86,601 ± 0,057	0,2935
Ridge B	138 + 5 derivadas (143)	110,447 ± 0,179	86,383 ± 0,057	0,2960
Ridge C	143 reduzidas a 50 (SelectKBest)	111,284 ± 0,190	87,083 ± 0,049	0,2853
Ridge D	5 trocadas por 2 fundidas (140)	110,553 ± 0,172	86,503 ± 0,050	0,2947

RMSE e MAE

Erro típico em pontos da nota; menor é melhor. O RMSE pune mais os erros grandes e é a métrica principal.

R^2

Quanto da variação da nota o modelo explica: 0 é igual ao baseline, 1 seria perfeito.

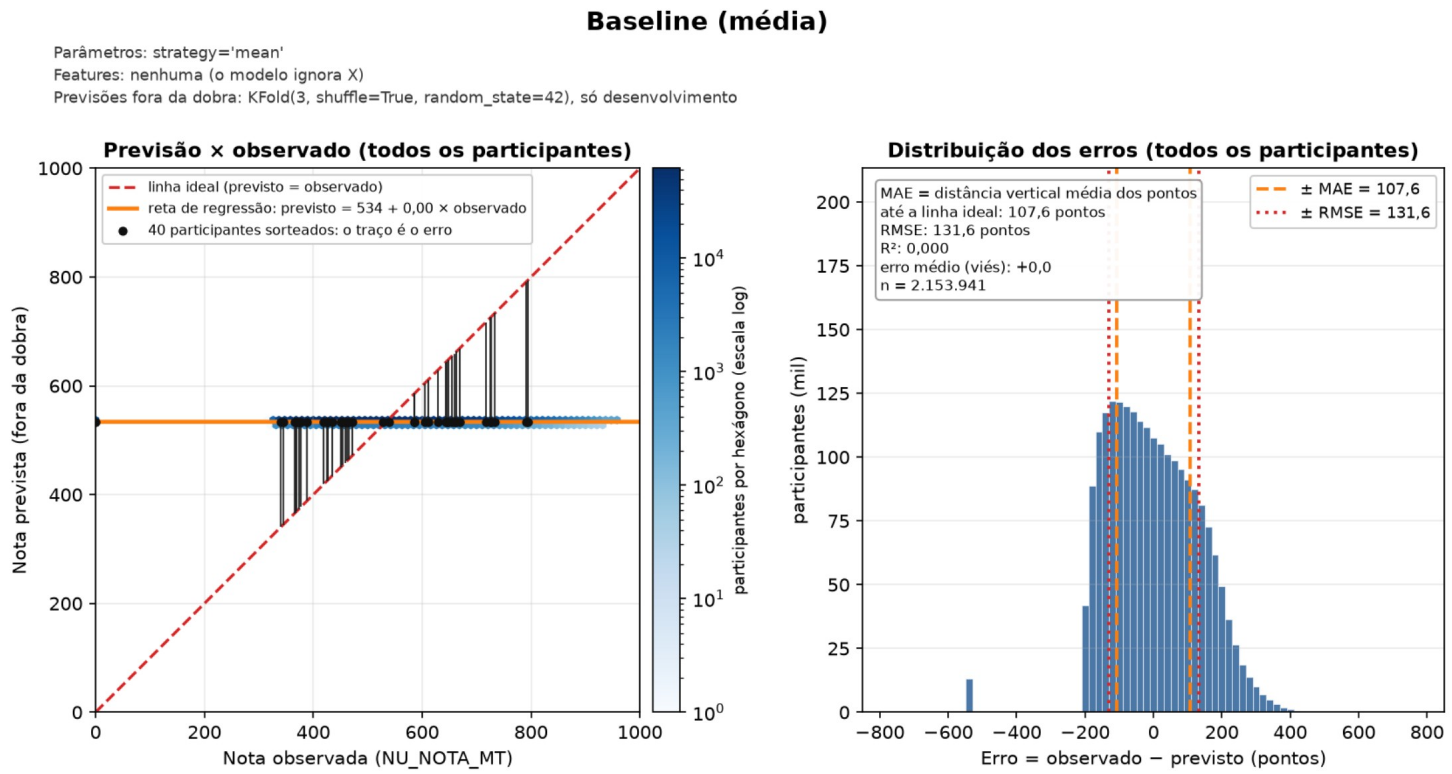
± desvio

Variação entre as 3 dobras. Diferenças menores que isso valem pouco.

Ridge com alpha=1, solver='lsqr' · CV de 3 dobras no desenvolvimento · Em verde: menor RMSE · Fonte: resultados/experimentos.csv

RESULTADOS PRELIMINARES · BASELINE

Baseline pela média: a referência a superar



`DummyRegressor(strategy='mean')`

Métrica	Valor
RMSE	131,634 ± 0,158
MAE	107,582 ± 0,058
R^2	0 (por construção)

Prevê 534 pontos para todos. As 13.300 notas zero têm erro de cerca de −534.

Figura 6 · Igual em A, B e D (não usa features) · 2.153.941 participantes, previsões fora da dobra · Fonte: Inep, ENEM 2023

RESULTADOS PRELIMINARES · RIDGE

Pipeline e resultado em cada conjunto de features

Conjunto	Pipeline, por dobra	RMSE	MAE	R^2
A (138)	Imputação pela mediana → padronização esparsa → Ridge	110,647 ± 0,175	86,601 ± 0,057	0,2935
B (143)	Derivadas calculadas antes → imputação → padronização → Ridge	110,447 ± 0,179	86,383 ± 0,057	0,2960
D (140)	Derivadas → imputação → fusão (5 viram 2) → padronização → Ridge	110,553 ± 0,172	86,503 ± 0,050	0,2947

Parâmetros

Ridge(alpha=1,0; solver='lsqr'); StandardScaler(with_mean=False). Todo passo aprendido é reajustado no treino de cada dobra.

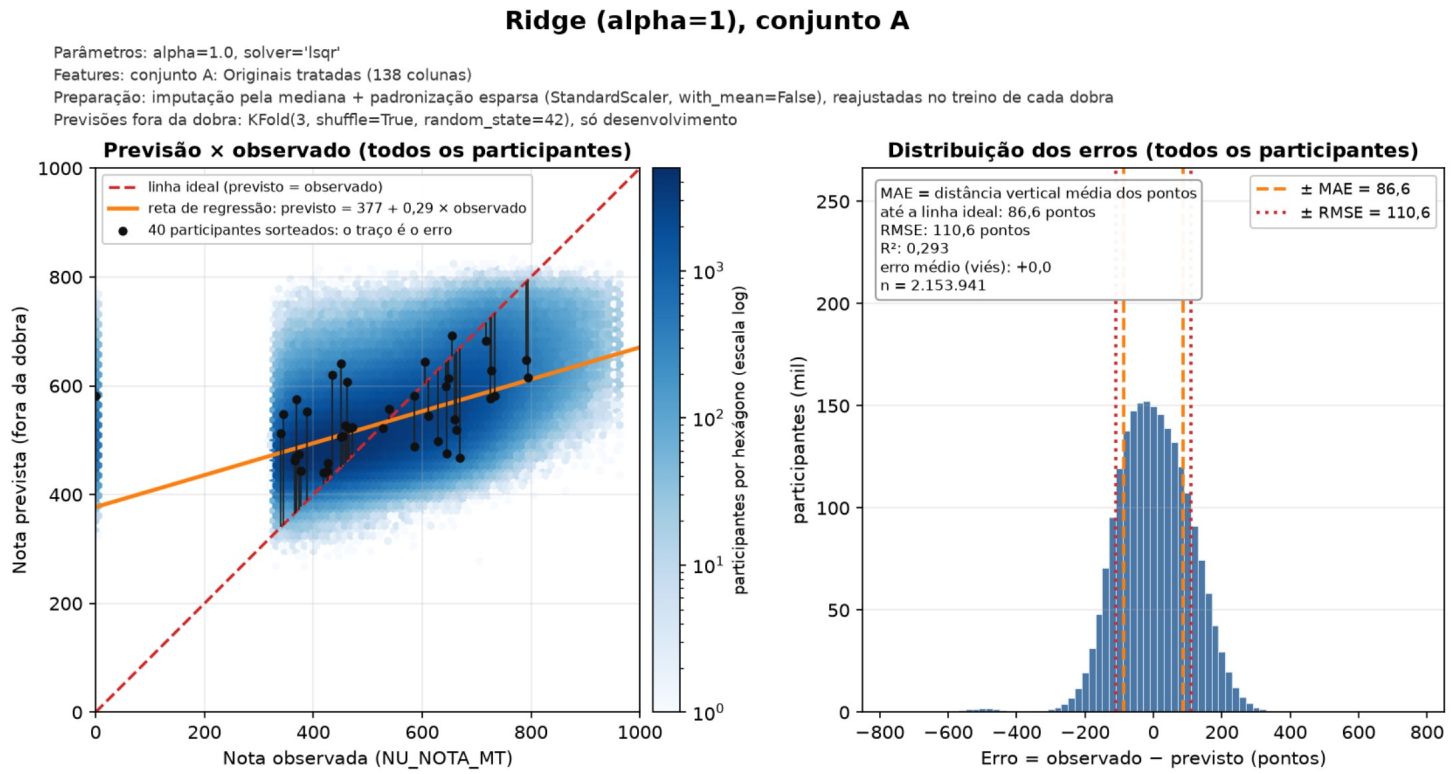
Tempo e memória

Leitura em blocos de 100 mil linhas, matriz esparsa de 32 bits em 16 GB. Ajuste das 3 dobras: 4,1 s (A), 6,1 s (B), 6,3 s (D).

Em verde: menor RMSE · Fonte: resultados/tabelas/modelos_por_conjunto.csv · Inep, ENEM 2023

RESULTADOS PRELIMINARES · RIDGE

Ridge no conjunto A (138 colunas originais)



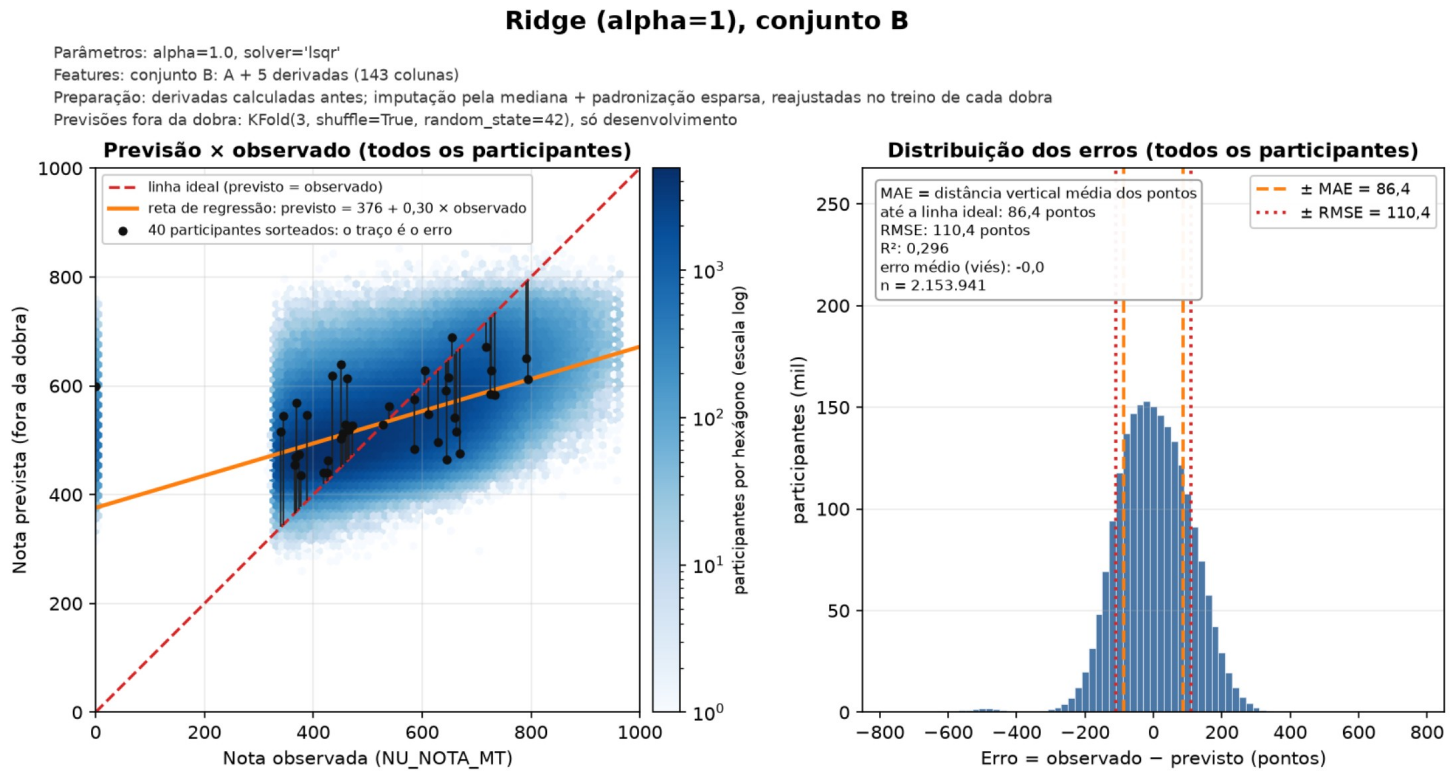
Métrica	Valor
RMSE	110,647
MAE	86,601
R^2	0,2935
Inclinação	0,29

Previsões de 264 a 831 pontos (a maioria entre 405 e 728), enquanto a nota observada vai de 0 a 959.

Figura 7 · alpha=1,0, solver='lsqr' · 2.153.941 participantes, previsões fora da dobra · Fonte: Inep, ENEM 2023

RESULTADOS PRELIMINARES · RIDGE

Ridge no conjunto B (A + 5 derivadas, 143)



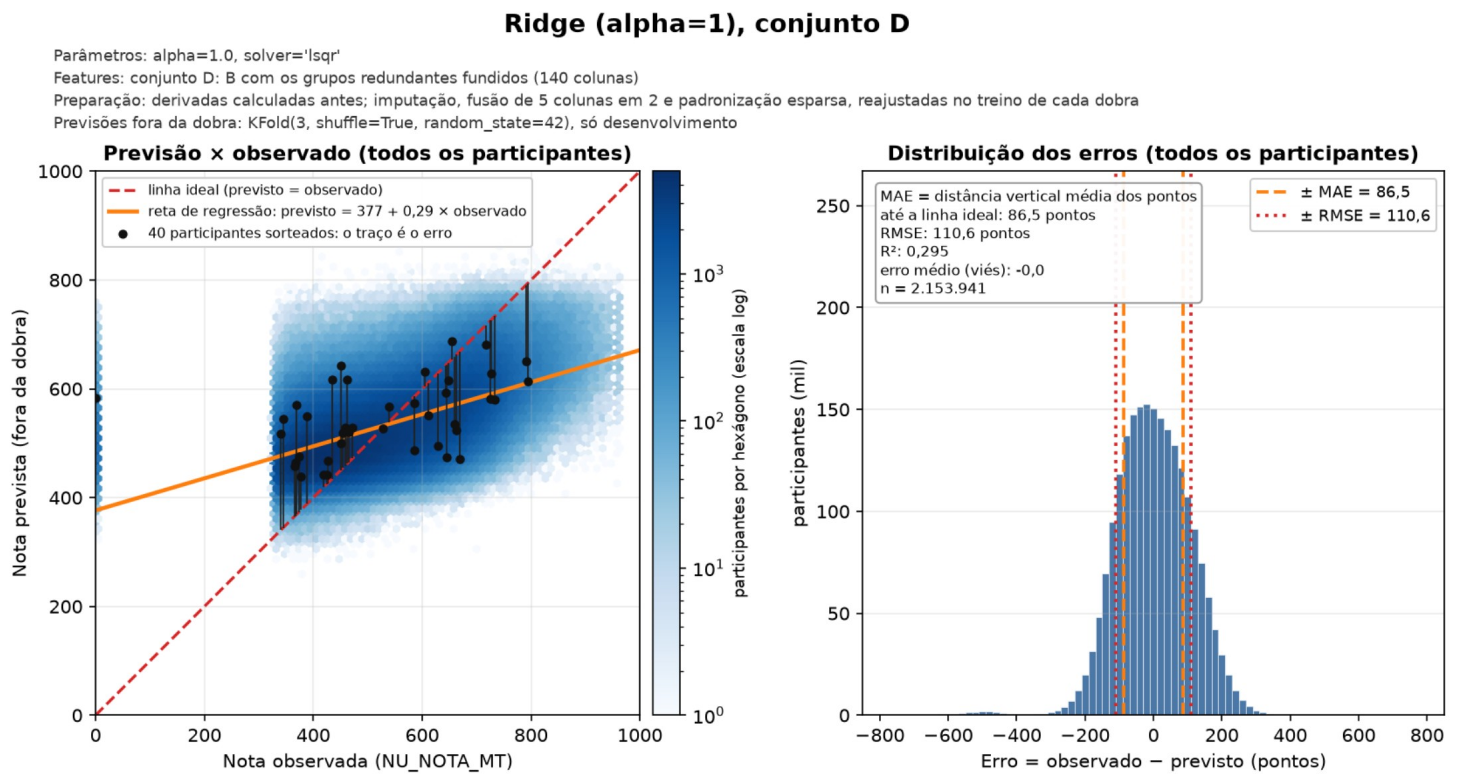
Métrica	Valor
RMSE	110,447
MAE	86,383
R^2	0,2960
Inclinação	0,30

Melhor resultado até agora. Previsões de 257 a 875 pontos.

Figura 8 · alpha=1,0, solver='lsqr' · 2.153.941 participantes, previsões fora da dobra · Fonte: Inep, ENEM 2023

RESULTADOS PRELIMINARES · RIDGE

Ridge no conjunto D (B com grupos fundidos, 140)



Métrica	Valor
RMSE	110,553
MAE	86,503
R^2	0,2947
Inclinação	0,29

Fica entre A e B, com 3 colunas a menos que B. Previsões de 263 a 871 pontos.

Figura 9 · alpha=1,0, solver='lsqr' · 2.153.941 participantes, previsões fora da dobra · Fonte: Inep, ENEM 2023

RESULTADOS PRELIMINARES · RIDGE

Varredura exploratória de alpha

alpha	A: RMSE · R²	B: RMSE · R²	D: RMSE · R²
0,001	110,647 · 0,2935	110,447 · 0,2960	110,553 · 0,2947
0,01	110,647 · 0,2935	110,447 · 0,2960	110,553 · 0,2947
1	110,647 · 0,2935	110,447 · 0,2960	110,553 · 0,2947
100	110,647 · 0,2935	110,447 · 0,2960	110,553 · 0,2947
10.000	110,651 · 0,2934	110,458 · 0,2959	110,557 · 0,2946
1.000.000	111,882 · 0,2776	111,522 · 0,2822	111,711 · 0,2798
10.000.000	118,385 · 0,1912	116,982 · 0,2102	117,850 · 0,1985

Leitura

- De 0,001 a 100 o RMSE não muda em nenhum conjunto.
- Com 10.000 sobe no máximo 0,011 ponto.
- A partir de 1 milhão o modelo fica rígido demais e subajusta.
- A ordem B, D, A se mantém em todos os alphas.

Exploratória, não é a busca oficial de hiperparâmetros · Desvio entre dobras 0,158 a 0,179 · Fonte: resultados/tabelas/ridge_alpha_cv.csv

LEITURA INICIAL DOS RESULTADOS

O perfil explica só uma parte da nota

−16%
RMSE de 131,6 (baseline) para 110,4 (Ridge B)

0,30
R^2 máximo: nenhuma variação passou desse valor

≈ 0,3
inclinação: previsões achatadas em direção à média

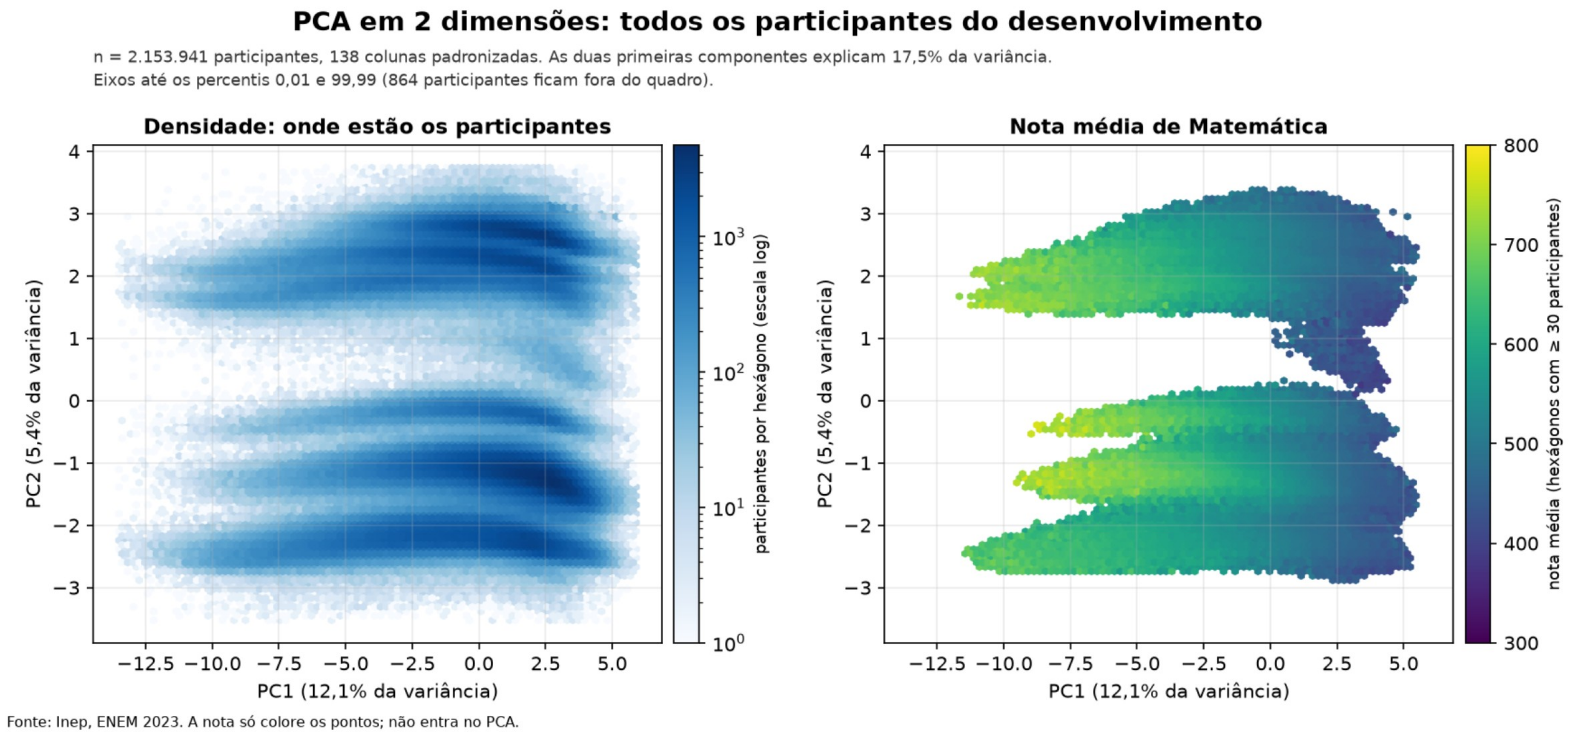
515
pontos previstos, em média, para as notas zero

Erro médio (viés) praticamente zero nos três conjuntos. São valores de validação cruzada: o Ridge ainda não é o modelo final, e os demais regressores ainda não foram treinados.

CV de 3 dobras no desenvolvimento · Teste não usado · Fonte: Inep, ENEM 2023

REDUÇÃO DE DIMENSIONALIDADE · PCA EXPLORATÓRIO

Todos os participantes em 2 dimensões



PC1 · 12,1%

Renda e bens da residência. Correlação de −0,457 com a nota.

PC2 · 5,4%

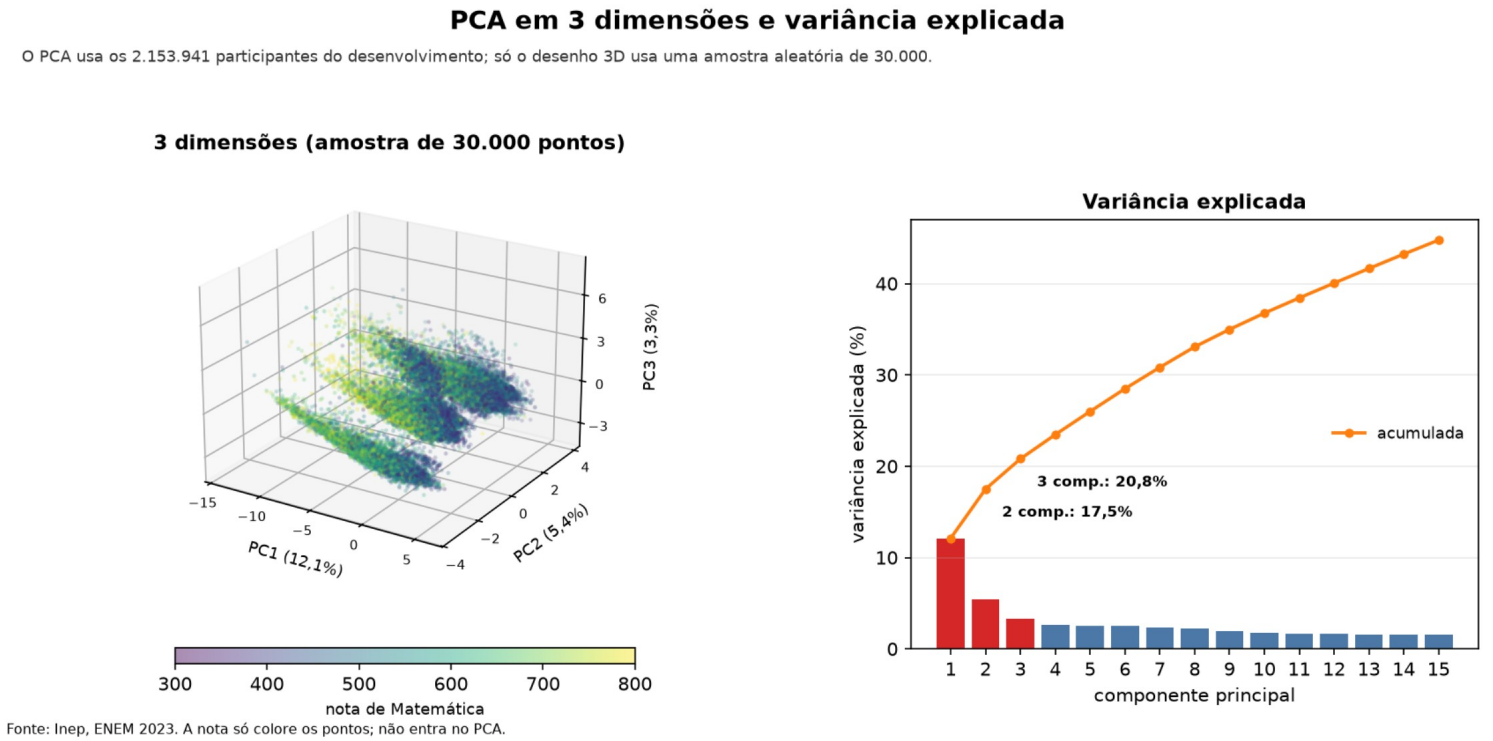
Conclusão do ensino médio, tipo de escola e de ensino. Correlação de −0,013.

As faixas horizontais vêm de variáveis categóricas, não de grupos de desempenho.

Figura 10 · 2.153.941 participantes, 138 colunas (72 com variação) padronizadas; a nota só colore · Fonte: Inep, ENEM 2023

REDUÇÃO DE DIMENSIONALIDADE · PCA EXPLORATÓRIO

3 dimensões e variância explicada



Componentes	Variância
2	17,5%
3	20,8%
19	50%
41	80%
50	90%

Os dados não se comprimem bem em 2 ou 3 dimensões: servem para visualizar, não substituem as features.

Figura 11 · Desenho com amostra de 30.000; variância com todos os participantes · PC3 = 3,3% · Fonte: Inep, ENEM 2023

PRÓXIMOS PASSOS

Próximos experimentos

Experimento	O que será feito
Regressão linear sem regularização	LinearRegression em A, B e D; entra na avaliação final (Raquel)
Demais regressores	Árvore (Raquel); KNN e SVR (Amanda); bagging e pasting (Sofya); Random Forest, Gradient Boosting e Stacking (João Igor)
Busca de hiperparâmetros	Três melhores regressores, ao menos 10 configurações cada, CV de 3 dobras
PCA na validação cruzada	PCA dentro do Pipeline; com e sem PCA em ao menos dois regressores
Balanceamento	Ponderação ou subamostragem por faixa de nota, definida no treino de cada dobra
Análise dos erros	Resíduos e erros por faixa de nota e por grupo (estado, renda ou escola)
Curva de aprendizado	Modelo final com 10%, 25%, 50%, 75% e 100% do treino de cada dobra
Codificação das categorias	One-hot atual × números discretos nas variáveis nominais
Avaliação final	Baseline, linear sem regularização e solução final no teste

Aprofundamento: ao menos duas hipóteses além do mínimo · Todos os modelos nos conjuntos A, B e D

PRÓXIMOS PASSOS

Dúvidas que vamos investigar

Dúvida	Contexto ou plano
Remover, manter com DESCONHECE ou imputar o “não sei”?	Hoje mantido; treinar com e sem, validar no mesmo conjunto
Filtrar todos os “não sei” (Q001 a Q004) muda o desempenho do modelo?	Seriam 471.359 registros (21,88% do desenvolvimento); comparar o mesmo modelo com e sem eles, nas mesmas dobras
As notas zero atrapalham o treino?	Treino com e sem zeros; zeros mantidos na validação
B ou D como base dos próximos modelos?	B tem o menor erro; D tem menos colunas
Derivadas e fusão seguem úteis em árvores?	Árvores já aprendem interações
Colunas deixadas de fora melhoram o erro?	UF da prova, dependência e localização da escola, ano de conclusão
A seleção melhora com outro método ou k maior?	Com SelectKBest e k = 50 o erro piorou
Códigos de escola e município influenciam?	Com e sem, como categorias; médias só no treino de cada dobra