Previsão da nota de Matemática do ENEM 2023 a partir do perfil dos participantes: comparação de preparação e modelagem

João Igor Vidal de Andrade, Raquel Albuquerque Quirino, Amanda Lira e Sofya Oliveira
Ciência de Dados, Projeto 2 (Unidade II: Aprendizado de Máquina) — Universidade de Fortaleza (Unifor)
Alvo: NU_NOTA_MT (Matemática e suas Tecnologias) — Repositório: github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

***Resumo*—** Este trabalho estima a nota de Matemática do ENEM 2023 por regressão, usando só o perfil socioeconômico, escolar e demográfico informado na inscrição. Foram usados os 2.692.427 participantes com nota observada, divididos em 80% para desenvolvimento e 20% para teste (semente 42), com validação cruzada de três dobras no desenvolvimento e todo o preparo dentro de um Pipeline. Comparamos o baseline pela média, a regressão linear, árvore, KNN, SVR, bagging, pasting, Random Forest, Gradient Boosting e stacking, além de PCA, seleção de atributos, balanceamento por ponderação, busca de hiperparâmetros e testes de hipóteses sobre a situação escolar, a UF e os blocos de informação. O Gradient Boosting foi o melhor regressor: RMSE de 105,86 $\pm$ 0,17 na validação cruzada e 105,81 no teste, contra 131,70 do baseline e 108,86 da regressão linear (R^2 de teste 0,354). O perfil explica cerca de um terço da variação da nota: PCA e seleção pioraram o erro, o balanceamento trocou o erro das notas altas pelo das notas médias, e a curva de aprendizado indica que o limite é a informação, não o volume de dados.

***Palavras-chave*—** regressão, ENEM 2023, validação cruzada, Gradient Boosting, prevenção de vazamento, curva de aprendizado.

***Abstract*—** We predict the 2023 ENEM mathematics score from socioeconomic, school and demographic profile, using 2.692.427 participants with an observed score. With an 80/20 split, three-fold cross-validation on the development set and every transformation inside a Pipeline, Gradient Boosting was the best regressor (test RMSE 105,81 against 131,70 for the mean baseline; test R^2 0,354). PCA and feature selection did not help, weighting trades high-score error for middle-score error, and the learning curve suggests the limit is information rather than data volume or model complexity.

***Keywords*—** regression, ENEM 2023, cross-validation, Gradient Boosting, leakage prevention.

I. INTRODUÇÃO

O Exame Nacional do Ensino Médio (ENEM) é a principal porta de entrada para a educação superior brasileira, e suas notas costumam ser associadas ao contexto socioeconômico dos participantes [1]. Este trabalho investiga **quanto o perfil socioeconômico, escolar e demográfico informado na inscrição permite estimar a nota de Matemática e suas Tecnologias** do ENEM 2023 e **quais escolhas de preparação e de modelagem fazem diferença** . O objetivo não é maximizar a acurácia, e sim comparar alternativas sob um protocolo livre de vazamento e explicar os resultados e os limites das previsões. As associações entre perfil e nota não indicam causa nem a capacidade individual dos participantes. Código, experimentos e resultados adicionais estão no repositório do projeto.

II. METODOLOGIA

A. Dados, participantes elegíveis e protocolo

Os dados são os microdados do ENEM 2023 do Inep, com 3.933.955 registros e 76 colunas [1]. São elegíveis os 2.692.427 participantes com nota de Matemática observada (68,44% da base). A nota ausente não é imputada nem convertida em zero; a nota zero é um resultado observado (13.300 casos no desenvolvimento, 0,62%) e permanece no treino e na validação. Treineiros foram mantidos e nenhuma amostra por conveniência foi usada. A divisão é aleatória: 80% para desenvolvimento (2.153.941 participantes) e 20% para teste (538.486), com *random_state* = 42, e os identificadores ficam em dados/splits. Modelos, features e hiperparâmetros são escolhidos só no desenvolvimento, por validação cruzada *KFold* (3, *shuffle* , 42), com as mesmas dobras em todas as comparações. A métrica principal é o RMSE; MAE e R^2 são complementares, sempre na escala original, com média e desvio entre as dobras. Notas de outras provas, presença, respostas, gabarito e código da prova ficam fora das entradas, por vazamento.

B. Features e preparação

As entradas são o questionário socioeconômico (Q001 a Q025), sexo, estado civil, cor/raça, língua estrangeira, nacionalidade, tipo e localização da escola, UF da prova e quatro colunas de trajetória escolar (faixa etária, situação de conclusão, ano de conclusão e treineiro). As letras do questionário viram números pelo dicionário do Inep. "Não sei" em Q001 a Q004 é ausência de informação, e não nível de escolaridade ou ocupação: recebe a mediana e um indicador próprio (quem não sabe tira 40 a 50 pontos a menos). Ausência de escola vira "sem informação" (referência da codificação 0/1) e a UF entra em 26 colunas 0/1 (referência SP). Criamos três features com hipóteses: **pessoas por quarto** (aglomeração reduz condições de estudo; denominador mínimo 1), **celulares por morador** (acesso digital per capita) e **renda menos escolaridade** dos responsáveis (renda e estudo na escala 0 a 1). Quatro colunas de trajetória tinham $|\rho|$ de Spearman [2] acima de 0,7; foram testadas fundidas numa só (*FUSAO_1* , média de z-scores), com média e desvio **aprendidos só no treino de cada dobra** dentro do Pipeline, ou mantidas separadas. A representação final tem 74 colunas e nenhum nulo.

C. Modelos, PCA, seleção, balanceamento e busca

Além do baseline (*DummyRegressor* pela média), treinamos regressão linear sem e com regularização (Ridge [3]), árvore de decisão, KNN, SVR linear, bagging e pasting [4], Random Forest [5], Gradient Boosting [6] e stacking [7], todos com o scikit-learn [8], em configuração inicial registrada antes das buscas. O PCA [9] foi aplicado após a padronização, dentro do Pipeline, com 5 a 25 componentes e meta de 80% da variância, em regressão linear e Gradient Boosting. A seleção de atributos usa *SelectKBest* com o teste F de *f_regression* (dentro do Pipeline, com k de 30%, 50% e 70% das colunas). O balanceamento é por **ponderação** : o treino da dobra é agrupado em faixas de 50 pontos (a nota zero à parte) e

cada linha recebe peso n^(−α), com α = 0,5 ou 1,0, calculado só com o treino; a validação mantém a distribuição original. A busca de hiperparâmetros foi uma *RandomizedSearchCV* [10] com 10 configurações e as mesmas 3 dobras, nos três melhores regressores distintos.

D. Curva de aprendizado e métodos novos

A curva de aprendizado da solução final usa, em cada dobra, 10%, 25%, 50%, 75% e 100% do treino (subconjuntos aleatórios progressivos, semente 42), reajustando todo o Pipeline com os hiperparâmetros fixos e medindo o RMSE de treino e de validação. Como hipóteses além do mínimo testamos: (i) fundir ou separar a trajetória escolar; (ii) incluir a UF; (iii) retirar um bloco de informação por vez; (iv) retirar as notas zero do treino; e (v) distâncias a grupos do K-means como features. Dois métodos merecem explicação. O *HistGradientBoostingRegressor* agrupa cada coluna em até 255 faixas e cresce árvores em sequência, cada uma corrigindo o erro da anterior, parando sozinho quando uma parcela interna do treino deixa de melhorar [6], [11]. O *stacking* treina um modelo final sobre previsões fora da dobra dos modelos de base [7]. A importância por permutação mede quanto o RMSE sobe ao embaralhar uma coluna da validação [12].

III. RESULTADOS

A. Distribuição da nota e comparação inicial dos modelos

A nota tem média 533,8, mediana 523,5 e desvio padrão 131,6; as notas zero são 0,62% do desenvolvimento e formam um pico isolado (Fig. 1). Prever sempre a média (baseline) erra 131,63 pontos de RMSE, o próprio desvio padrão. Na validação cruzada inicial (dataset de 30 colunas, Tabela I), o Gradient Boosting teve RMSE de 107,77 ± 0,23, contra 111,15 da regressão linear, e o stacking empatou com ele (107,76) a um custo cinco vezes maior; KNN (111,58) e SVR linear (111,15) não ganharam da regressão linear (Fig. 2). Dos sete modelos que passaram pela busca de hiperparâmetros, o bagging foi o que mais ganhou (−0,93) e o Gradient Boosting o que menos (−0,09, dentro do desvio de 0,18).

B. PCA

Para atingir 80% da variância explicada são necessários 18 de 30 componentes: os dados quase não se comprimem (Fig. 3). Dentro do Pipeline, o PCA piorou os dois regressores testados em todos os cortes: com 25 componentes, o RMSE do Gradient Boosting foi de 107,77 (sem PCA) para 110,17, e com 5 componentes para 113,21; na regressão linear, de 111,15 para 111,66 (25) e 114,43 (5). Nenhum corte ficou dentro de um desvio do modelo sem PCA. Como justificativa do número de componentes, 18 preservariam 80% da variância, mas a decisão final foi não usar PCA.

C. Hipóteses de preparação, seleção e balanceamento

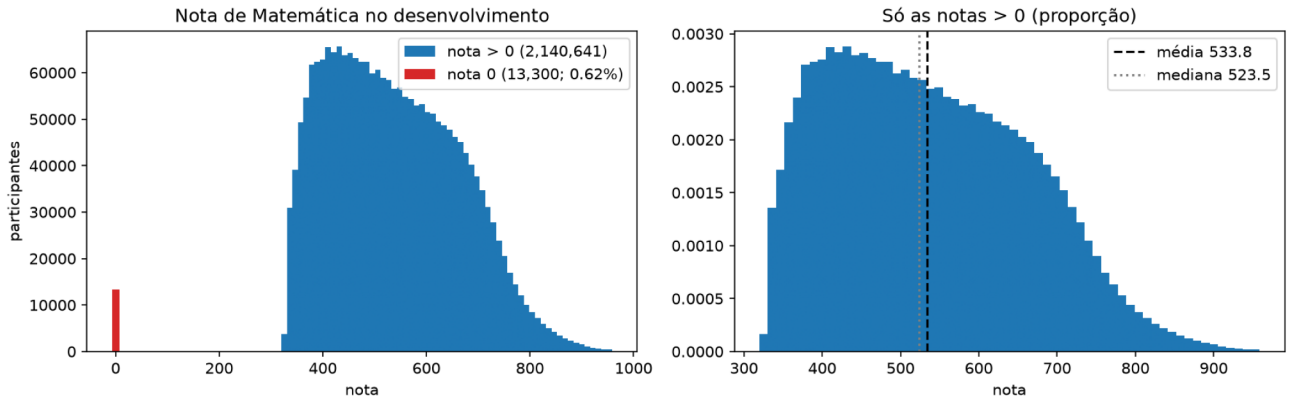
A fusão das quatro colunas de trajetória, refeita só com o treino de cada dobra (RMSE 107,05; Tabela II), perdeu informação: mantê-las separadas deu 106,73 (−0,33), e acrescentar a UF da prova deu 106,03 (−0,70), ambas maiores que o desvio entre dobras (0,19). As três features criadas não tiveram efeito (+0,01). A seleção com SelectKBest piorou em todos os cortes (+1,04 com k = 51 e +4,58 com k = 22), então mantivemos as 74 colunas. A ponderação por faixa de nota piorou o RMSE geral (+2,12 e +17,43), mas reduziu o erro das notas altas: acima de 800 o RMSE caiu de 184,9 para 155,4 (α = 0,5) e 131,7 (α = 1,0) (Fig. 4), à custa das faixas do meio (de 66,8 para 80,6 na faixa de 500 a 600). Retirar um bloco de informação por vez piorou o erro em todos os casos; o bloco de perfil e trajetória pesa mais (+4,42), seguido de bens (+1,33), renda (+0,87) e UF (+0,70) (Fig. 5).

D. Solução final e curva de aprendizado

A solução final é o Gradient Boosting com os hiperparâmetros da busca, sobre 74 colunas (trajetória separada e UF), sem seleção, PCA nem pesos. Na validação cruzada teve RMSE de 105,86 ± 0,17 e R^2 de 0,353, contra 108,87 da regressão linear e 131,63 do baseline. Na curva de aprendizado (Fig. 6), de 10% a 100% do treino da dobra, o RMSE de treino sobe de 102,6 para 104,8 e o de validação cai de 106,7 para 105,9; a diferença encolhe de 4,1 para 1,1 ponto, e de 75% para 100% a validação melhora só 0,07 ponto, menos que o desvio entre dobras (0,2).

E. Teste final

O teste foi aberto uma única vez, com a solução fixada, nos 538.486 participantes reservados (Tabela III). A solução final teve RMSE de 105,81, MAE de 82,00 e R^2 de 0,354, contra 131,70 do baseline e 108,86 da regressão linear sem regularização: 19,7% menos erro que o baseline e 2,8% menos que a regressão linear. O resultado de teste coincide com o da validação (105,81 contra 105,86),



Fonte: Inep, Microdados do ENEM 2023; desenvolvimento (2,153,941 participantes).

Fig. 1. Distribuição da nota de Matemática no desenvolvimento, com as notas zero em vermelho. Fonte: Inep, ENEM 2023; desenvolvimento (2.153.941 participantes).

TABELA I
CONFIGURAÇÃO INICIAL DE TODOS OS MODELOS (VALIDAÇÃO CRUZADA, DATASET DE 30 COLUNAS)

Modelo	RMSE (± desvio)	MAE	R^2	Tempo/dobra (s)
Stacking	107,76 ± 0,23	83,80	0,330	629,8
Gradient Boosting	107,77 ± 0,23	83,83	0,330	132,7
Random Forest	109,42 ± 0,20	85,49	0,309	103,4
Pasting	110,01 ± 0,21	86,00	0,302	19,8
Bagging	110,01 ± 0,21	85,99	0,302	24,1
Árvore de decisão	110,55 ± 0,19	86,38	0,295	3,0
Regressão linear	111,15 ± 0,18	86,96	0,287	0,7
Ridge	111,15 ± 0,18	86,96	0,287	0,3
SVR linear	111,15 ± 0,18	86,96	0,287	1,9
KNN	111,58 ± 0,18	87,18	0,282	476,3
Baseline	131,63 ± 0,16	107,58	0,000	0,1

Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

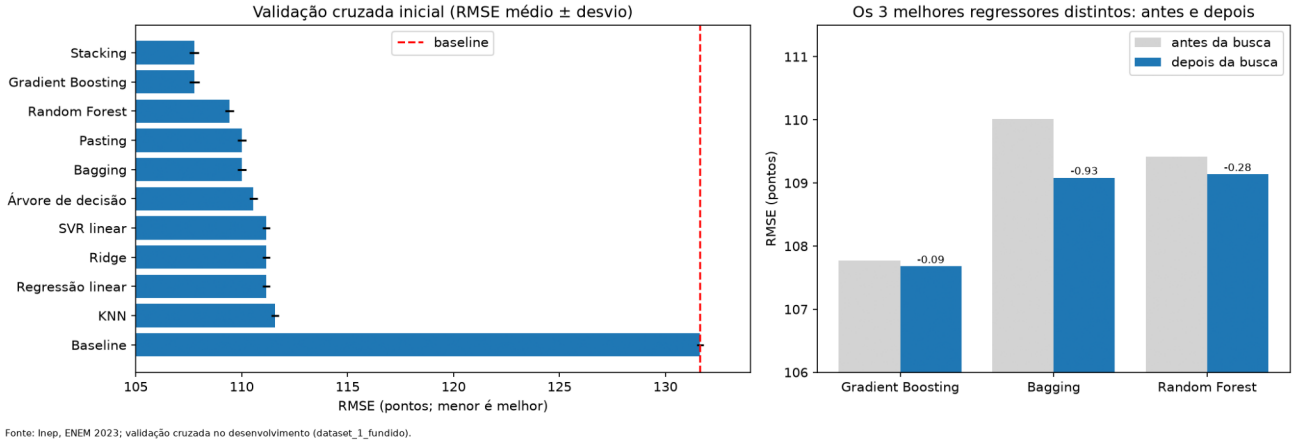


Fig. 2. Validação cruzada inicial de todos os regressores contra o baseline (esquerda) e os três melhores regressores distintos antes e depois da busca (direita). Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento, dataset_1_fundido.

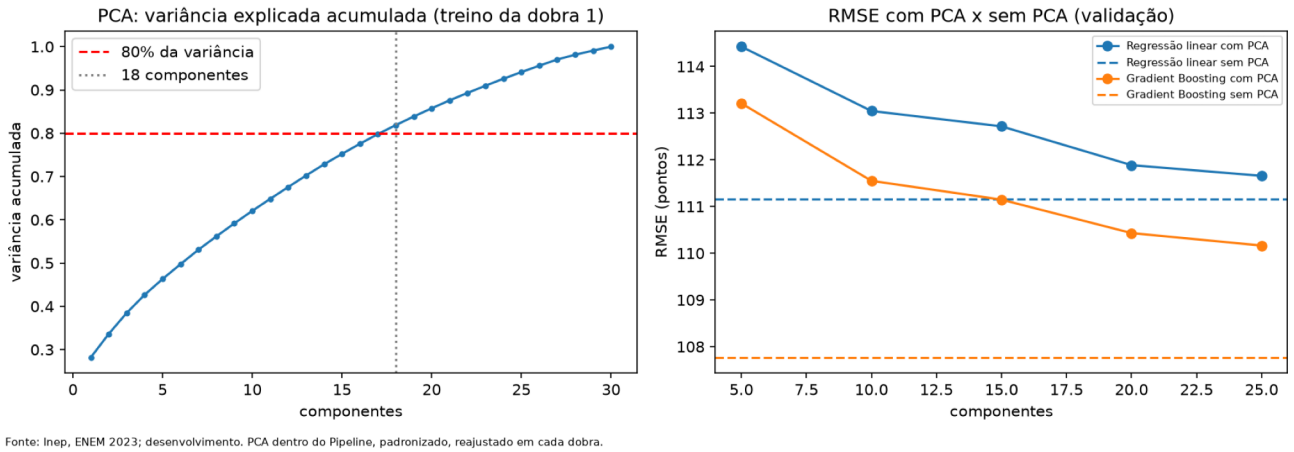


Fig. 3. Variância explicada acumulada do PCA (esquerda; 18 componentes chegam a 80%) e RMSE com e sem PCA em dois regressores (direita). Fonte: Inep, ENEM 2023; desenvolvimento. PCA padronizado e reajustado em cada dobra.

diferença menor que o desvio entre dobras.

Os resíduos têm média 0,1 e desvio 105,8, e a média do resíduo fica perto de zero em toda a faixa prevista. As previsões ficam concentradas entre cerca de 350 e 850, enquanto as notas reais vão de 0 a 1000 (regressão à média, Fig. 7); as notas zero formam uma faixa isolada de resíduos entre −370 e −770. O erro é mínimo perto da média (RMSE 67 na faixa de 500 a 600) e cresce nas pontas com viés de sinal oposto: +171 pontos acima de 800 (11.243 participantes) e −510 nos zeros (3.338) (Fig. 8). Por grupo, o viés médio é menor que 1 ponto; o RMSE vai de 97,3 (renda até 1 salário, 187.962 participantes) a 113,3 (renda de 6 a 10 salários, 34.469) e de 97,9 (região Norte, 57.603) a 111,0 (Sul, 58.227), com R^2 dentro de cada faixa de renda entre 0,17 e 0,21: o erro maior nos grupos de renda alta acompanha uma nota mais dispersa, não um modelo pior

TABELA II
HIPÓTESES TESTADAS (GRADIENT BOOSTING INICIAL, VALIDAÇÃO CRUZADA)

Experimento	**RMSE (± desvio)**	**Δ RMSE**
1a. Fusão da situação escolar, só treino	107,051 ± 0,192	
1b. 4 colunas separadas	106,726 ± 0,189	-0,325
2. 1b + UF da prova	106,025 ± 0,188	-0,701
3. Sem as 3 features criadas	106,038 ± 0,167	+0,013
4a. SelectKBest, k = 51	107,069 ± 0,199	+1,044
4b. SelectKBest, k = 22	110,607 ± 0,191	+4,582
5a. Pesos por faixa, α = 0,5	108,140 ± 0,188	+2,115
5b. Pesos por faixa, α = 1,0	123,459 ± 0,149	+17,434
6a. Sem perfil e trajetória	110,445 ± 0,189	+4,420
6b. Sem bens e domicílio	107,356 ± 0,174	+1,331
6c. Sem renda	106,893 ± 0,194	+0,868
6d. Sem UF	106,726 ± 0,189	+0,701

Fonte: Inep, ENEM 2023; desenvolvimento. Δ em relação à referência indicada (1a para 1b; 1b para 2; 2 para as demais).

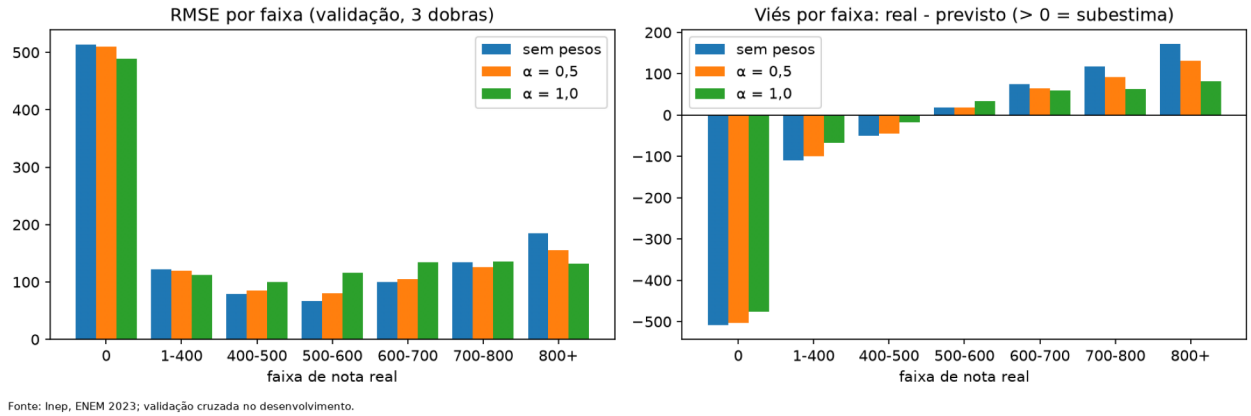


Fig. 4. RMSE e viés por faixa de nota real, sem pesos e com pesos α = 0,5 e α = 1,0. Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

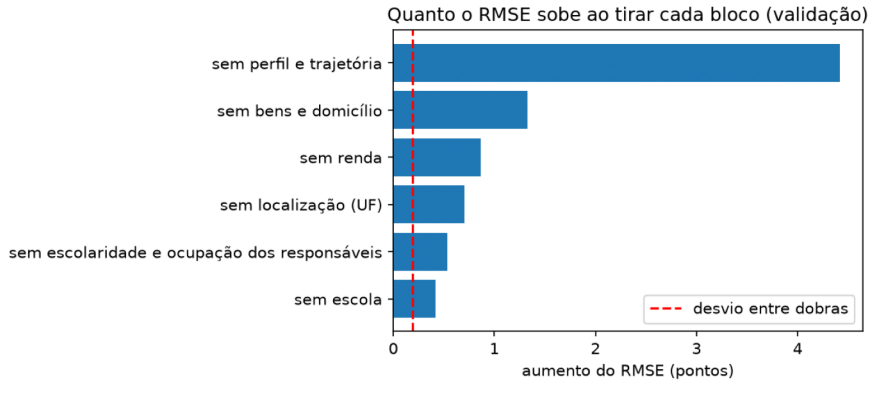


Fig. 5. Quanto o RMSE sobe ao retirar cada bloco de informação (linha vermelha: desvio entre dobras). Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

para eles.

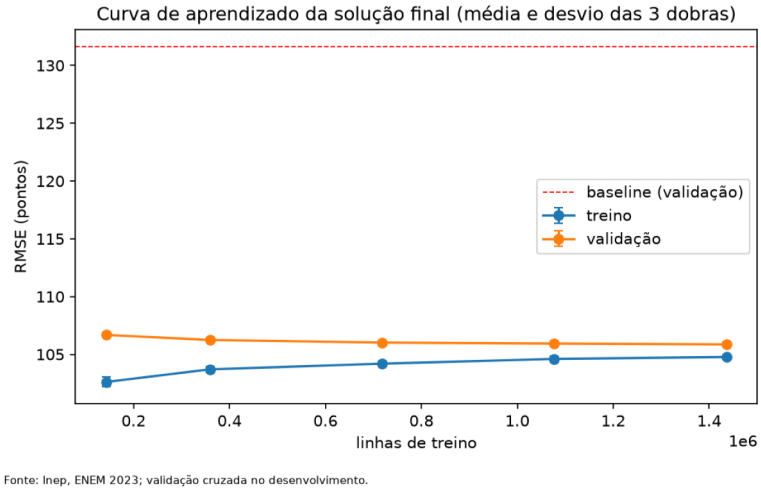


Fig. 6. Curva de aprendizado da solução final: RMSE de treino e de validação (média e desvio das três dobras). Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

TABELA III
VALIDAÇÃO CRUZADA (MÉDIA ± DESVIO) E TESTE DO BASELINE, DA REGRESSÃO LINEAR SEM REGULARIZAÇÃO E DA SOLUÇÃO FINAL

Modelo	CV RMSE	CV MAE	CV R^2	CV s/dobra	Teste RMSE	Teste MAE	Teste R^2	Ajuste (s)
Baseline (média)	131,63 ± 0,16	107,58 ± 0,06	0,000	0	131,70	107,64	0,000	0
Regressão linear	108,87 ± 0,16	84,86 ± 0,04	0,316	3	108,86	84,89	0,317	4
Solução final	**105,86 ± 0,17**	**82,02 ± 0,05**	**0,353**	**91**	**105,81**	**82,00**	**0,354**	**165**

Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento e teste (538.486 participantes).

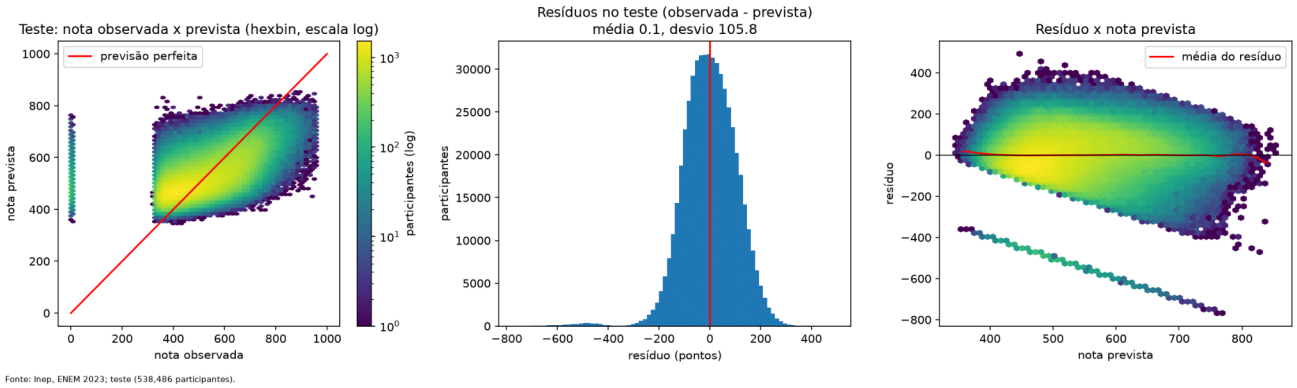


Fig. 7. Teste: nota observada contra prevista (a reta vermelha é a previsão perfeita), histograma dos resíduos e resíduo contra nota prevista. Fonte: Inep, ENEM 2023; teste (538.486 participantes); dispersão agregada em células hexagonais.

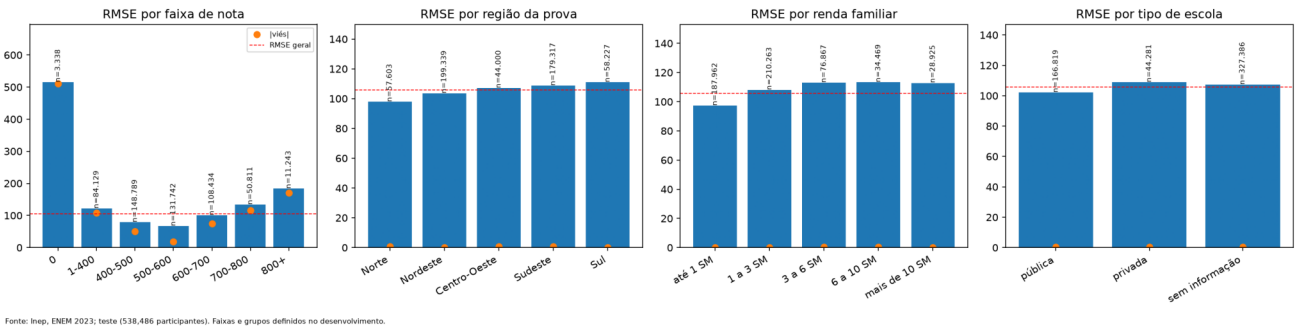


Fig. 8. Teste: RMSE por faixa de nota, região da prova, faixa de renda e tipo de escola, com o tamanho de cada grupo. Fonte: Inep, ENEM 2023; teste; faixas e grupos definidos no desenvolvimento.

IV. DISCUSSÃO

Limite de informação. Famílias muito diferentes (linear, árvores, KNN, bagging e boosting) terminam num intervalo estreito de RMSE (106 a 112), e as árvores só ganham de três a quatro pontos da regressão linear. A curva de aprendizado mostra treino e validação separados por apenas 1,1 ponto e sem ganho relevante com mais dados, o

que não indica sobreajuste forte. Erros altos e próximos podem ser subajuste, mas também falta de informação; aqui, a convergência de modelos tão distintos e o ganho mínimo do Gradient Boosting com 500 árvores sobre o inicial ($-0{,}16$) sugerem que a variação restante vem do que o perfil não captura (esforço de estudo, qualidade do ensino, circunstâncias do dia da prova), e não da falta de capacidade do modelo. Isso é uma interpretação, não um resultado medido.

Desempenho e complexidade. O ganho de 3 pontos de RMSE do Gradient Boosting sobre a regressão linear custa cerca de 30 vezes mais tempo por dobra (91 s contra 3 s). O stacking não ganhou do Gradient Boosting e custou cinco vezes mais. A seleção de atributos e o PCA reduzem colunas, mas pioram o erro em 1 a 5 pontos; a solução mais simples que preservou o erro foi manter todas as colunas e deixar o modelo de árvores escolher. As três features criadas, calculadas a partir de colunas já presentes, não acrescentaram informação a esse modelo.

Erros nas pontas e grupos. O modelo regride à média: superestima as notas baixas e subestima as altas. A ponderação mostra um compromisso explícito entre o erro das pontas e o das faixas do meio, onde está quase toda a população; a escolha depende do objetivo (identificar notas altas ou minimizar o erro médio). O viés médio por grupo é próximo de zero, mas as associações (renda, escola, idade) não indicam causa nem a capacidade de uma pessoa, e com erro médio de cerca de 82 pontos o modelo não serve para decisões individuais.

Limitações. A divisão avalia novos participantes da mesma edição, não escolas ou municípios inéditos; UF e escola não são residência. Os hiperparâmetros foram buscados no dataset de 30 colunas e reaproveitados na representação final; stacking e KNN não passaram pela busca por custo. Cor/raça e estado civil entram como números em escada, o que as árvores toleram e a regressão linear não; o município (cerca de 1.750 categorias) não foi usado e exigiria codificação supervisionada dentro do Pipeline. Usamos uma única semente, de modo que o desvio entre dobras não mede a variação entre sementes. Um vazamento pequeno nos datasets iniciais (média e desvio da fusão com todas as linhas) foi medido em 0,003 ponto de RMSE e corrigido no Pipeline final.

V. CONCLUSÃO

O perfil socioeconômico, escolar e demográfico permite estimar a nota de Matemática do ENEM 2023 apenas de forma aproximada: a solução final erra 105,81 pontos de RMSE no teste e explica 0,354 da variação, contra 131,70 do baseline. O que mais ajudou foi usar um modelo de árvores, manter a trajetória escolar sem fusão e incluir a UF; PCA, seleção de atributos, features combinadas, retirada dos zeros e K-means não ajudaram, e a ponderação troca erro das notas altas por erro das médias. A concordância entre validação e teste, e a curva de aprendizado, indicam que o limite é a informação disponível. Como próximos passos, o município com codificação supervisionada dentro do Pipeline e a busca de hiperparâmetros na representação final.

REFERÊNCIAS

[1] Inep, "Microdados do ENEM 2023 e dicionário de variáveis," Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, Brasília, DF, 2024. [Online]. Disponível: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem

[2] C. Spearman, "The proof and measurement of association between two things," *Am. J. Psychol.* , vol. 15, no. 1, pp. 72–101, 1904.

[3] A. E. Hoerl and R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems," *Technometrics* , vol. 12, no. 1, pp. 55–67, 1970.

[4] L. Breiman, "Bagging predictors," *Mach. Learn.* , vol. 24, no. 2, pp. 123–140, 1996.

[5] L. Breiman, "Random forests," *Mach. Learn.* , vol. 45, no. 1, pp. 5–32, 2001.

[6] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Ann. Statist.* , vol. 29, no. 5, pp. 1189–1232, 2001.

[7] D. H. Wolpert, "Stacked generalization," *Neural Netw.* , vol. 5, no. 2, pp. 241–259, 1992.

[8] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.* , vol. 12, pp. 2825–2830, 2011.

[9] I. T. Jolliffe, *Principal Component Analysis* , 2nd ed. New York, NY, USA: Springer, 2002.

[10] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *J. Mach. Learn. Res.* , vol. 13, pp. 281–305, 2012.

[11] G. Ke et al., "LightGBM: A highly efficient gradient boosting decision tree," in *Proc. Adv. Neural Inf. Process. Syst. (NIPS)* , 2017, pp. 3146–3154.

[12] scikit-learn developers, "User guide: Cross-validation, pipelines, model evaluation and ensembles." [Online]. Disponível: https://scikit-learn.org/stable/user_guide.html