PREVISÃO DA NOTA DE MATEMÁTICA DO ENEM 2023 A PARTIR DO PERFIL DOS PARTICIPANTES: COMPARAÇÃO DE PREPARAÇÃO E MODELAGEM

João Igor Vidal de Andrade · Raquel Albuquerque Quirino · Amanda Lira Andrade Botelho · Sofya Emilly Oliveira

Universidade de Fortaleza (UNIFOR) · Curso de Ciência da Computação · Fortaleza, CE

joaoigorandrade.dev@gmail.com · raquelacontato@gmail.com · amandalirabotelho@gmail.com · sofyaoliveira@edu.unifor.br

Repositório: https://github.com/Alyra004/ciencia-de-dados-unifor-projeto-2 | Alvo: NU_NOTA_MT

RESUMO – Investiga-se quanto o perfil socioeconômico, escolar e demográfico informado na inscrição permite estimar a nota de Matemática do ENEM 2023. Dos 3.933.955 registros nacionais, 2.692.427 apresentavam nota observada, divididos em desenvolvimento (80%) e teste (20%). Foram comparadas famílias de regressão, engenharia e seleção de atributos, análise de componentes principais (PCA), ponderação por faixas de nota e ajuste de hiperparâmetros, usando validação cruzada de três dobras e transformações ajustadas apenas nos dados de treino. O HistGradientBoostingRegressor com 74 entradas obteve RMSE de 105,86 ± 0,17 na validação e 105,81 no teste, contra 131,70 do baseline, com R^2 de teste de 0,354. PCA, seleção de atributos e atributos compostos não reduziram o erro; a ponderação melhorou previsões extremas à custa do desempenho global. A curva de aprendizado e os erros por grupo indicam que o perfil explica apenas parte da variação, sem permitir inferências causais ou decisões individuais.

Palavras-chave: ENEM 2023; regressão; Gradient Boosting; validação cruzada; análise de erros.

1 INTRODUÇÃO

O Exame Nacional do Ensino Médio (ENEM) é utilizado no acesso ao ensino superior brasileiro e reúne dados sobre trajetória escolar e condições socioeconômicas de seus participantes. Essas informações oferecem uma oportunidade para estudar associações estatísticas com o desempenho, mas não substituem medidas de aprendizagem, do contexto pedagógico ou das condições específicas de realização da prova (INEP, 2024).

A pergunta central deste trabalho é: até que ponto as informações disponíveis antes da prova permitem estimar a nota de Matemática e suas Tecnologias? O objetivo é comparar decisões de preparação, representações de atributos e modelos de regressão sob um protocolo

reproduzível e sem vazamento de informação, interpretando ganhos, ausência de melhorias, padrões de erro e limitações. A investigação não busca prever com precisão a nota individual nem estabelecer relações de causalidade.

2 METODOLOGIA

2.1 Dados e protocolo experimental

Foram utilizados os microdados nacionais do ENEM 2023 disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP, 2024), com 3.933.955 registros e 76 colunas. Permaneceram os 2.692.427 participantes (68,44%) com NU_NOTA_MT observada, inclusive treineiros e 13.300 notas iguais a zero no desenvolvimento. Notas ausentes não foram convertidas em zero nem imputadas. O desenvolvimento contou com 2.153.941 registros (80%) e o teste reservado com 538.486 (20%), em divisão aleatória de semente 42.

No desenvolvimento, utilizou-se KFold de três dobras embaralhadas, com semente 42 e particionamento idêntico em todas as comparações. Imputação, padronização, fusão, seleção, PCA e ponderação, quando aplicáveis, foram ajustados exclusivamente no treino de cada dobra, em Pipeline, antes de calcular RMSE, MAE e R^2 na validação. O conjunto de teste permaneceu isolado até a escolha da solução final. Notas de outras áreas, presença, códigos de prova, respostas e gabaritos foram excluídos das entradas por risco de vazamento.

2.2 Preparação e representação dos atributos

As entradas incluíram o questionário Q001–Q025, perfil demográfico, trajetória escolar, informações disponíveis da escola e UF de realização da prova. Os códigos ordenados do questionário foram mapeados segundo o dicionário do INEP; respostas “não sei” em Q001–Q004 receberam tratamento de ausência com indicadores específicos. Informações escolares faltantes foram representadas como categoria “sem informação”; a UF foi codificada em 26 indicadores binários, com São Paulo como referência. Três atributos compostos foram testados: pessoas por quarto, celulares por morador e diferença normalizada entre renda e escolaridade familiar.

As quatro colunas de trajetória escolar apresentaram correlação de Spearman elevada ($|\rho| > 0,7$), o que motivou comparar a fusão padronizada FUSAO_1 com sua manutenção separada (SPEARMAN, 1904). A representação final preservou as quatro colunas, incorporou a UF e totalizou 74 entradas. A preparação utilizou os grupos disponíveis, sem exigir informações escolares ausentes da maior parte dos participantes.

2.3 Modelos, redução, ponderação e ajuste

O baseline foi o DummyRegressor que prevê a média do treino. Foram comparadas regressões linear e Ridge (HOERL; KENNARD, 1970), árvore de decisão, KNN, SVR linear, bagging e pasting, Random Forest, Gradient Boosting e stacking, utilizando scikit-learn (SCIKIT-LEARN DEVELOPERS, [s. d.]; BREIMAN, 1996; BREIMAN, 2001; FRIEDMAN, 2001; WOLPERT, 1992; PEDREGOSA et al., 2011). No stacking, previsões fora das dobras alimentam um regressor combinador; o boosting agrega árvores sequencialmente para corrigir erros anteriores. Também foi avaliada a importância por permutação das entradas.

O PCA foi executado sobre atributos padronizados, de 5 a 25 componentes, em regressão linear e Gradient Boosting, sempre reajustado dentro da dobra (JOLLIFFE, 2002). A seleção utilizou SelectKBest (f_regression), preservando 30%, 50% ou 70% das colunas. Para o balanceamento da regressão, as notas do treino foram agrupadas em intervalos de 50 pontos, com zero separado, e as observações receberam peso proporcional a n^(−α), para α = 0,5 ou 1,0; a validação manteve a distribuição original. A busca de hiperparâmetros usou RandomizedSearchCV, 10 configurações e as mesmas três dobras nos três melhores regressores distintos (BERGSTRA; BENGIO, 2012).

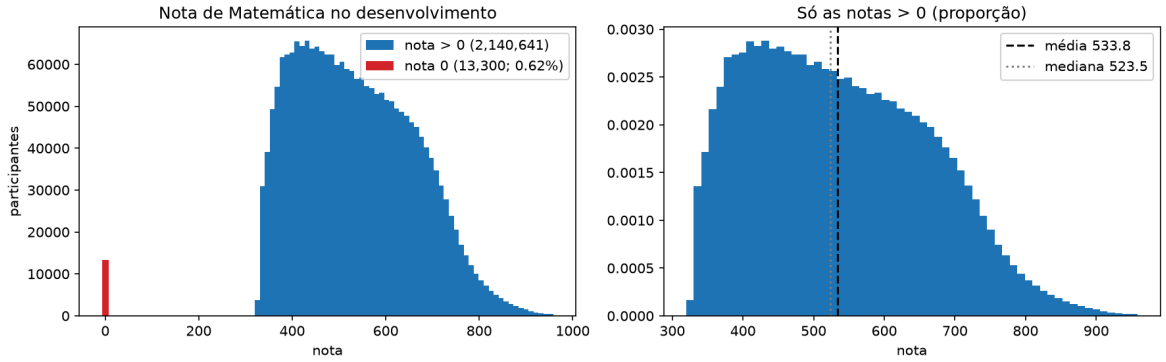
A curva de aprendizado do modelo final comparou 10%, 25%, 50%, 75% e 100% das linhas de treino de cada dobra, com subconjuntos progressivos, semente 42, validação fixa e todo o Pipeline reajustado a cada ponto. Investigaram-se ainda fusão de trajetórias, localização, ablação de blocos de atributos, remoção de zeros no treino e distâncias a agrupamentos de K-means. O repositório contém notebooks 01–07, partições, parâmetros, 82 registros de experimentos e previsões finais.

3 RESULTADOS

3.1 Distribuição da nota e comparação inicial

A nota observada teve média 533,8, mediana 523,5 e desvio padrão 131,6; a distribuição é assimétrica e inclui um pico isolado de notas zero (0,62% do desenvolvimento). O baseline obteve RMSE de 131,63 na validação. No conjunto inicial de 30 colunas, Gradient Boosting (107,77 ± 0,23) e stacking (107,76 ± 0,23) tiveram os menores erros; porém, o stacking exigiu aproximadamente cinco vezes mais tempo. Regressão linear, SVR linear e KNN tiveram RMSE acima de 111. As buscas posteriores trouxeram ganhos modestos ao Gradient Boosting (cerca de 0,09 ponto) e mais expressivos ao bagging (0,93 ponto).

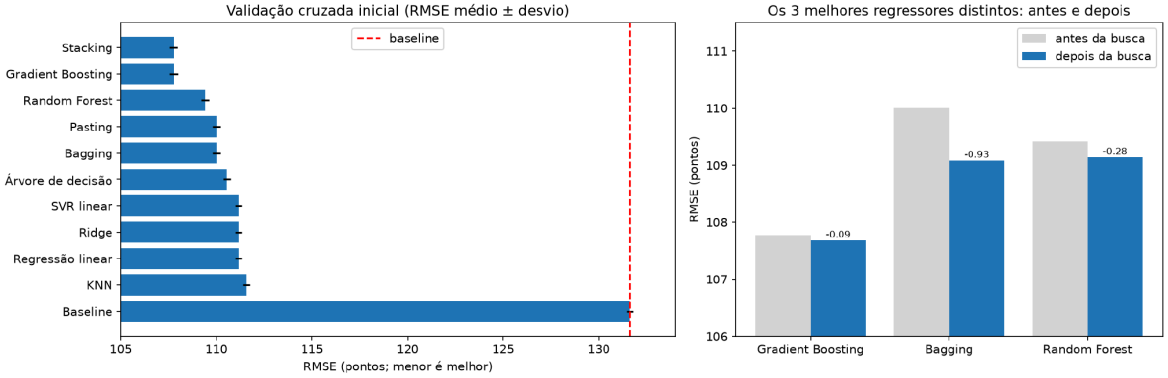
Figura 1 – Distribuição das notas de Matemática no desenvolvimento, incluindo notas zero.



Fonte: Inep, Microdados do ENEM 2023; desenvolvimento (2,153,941 participantes).

Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Desenvolvimento: n = 2.153.941.

Figura 2 – Comparação inicial dos modelos e dos três regressores distintos antes e depois da busca.



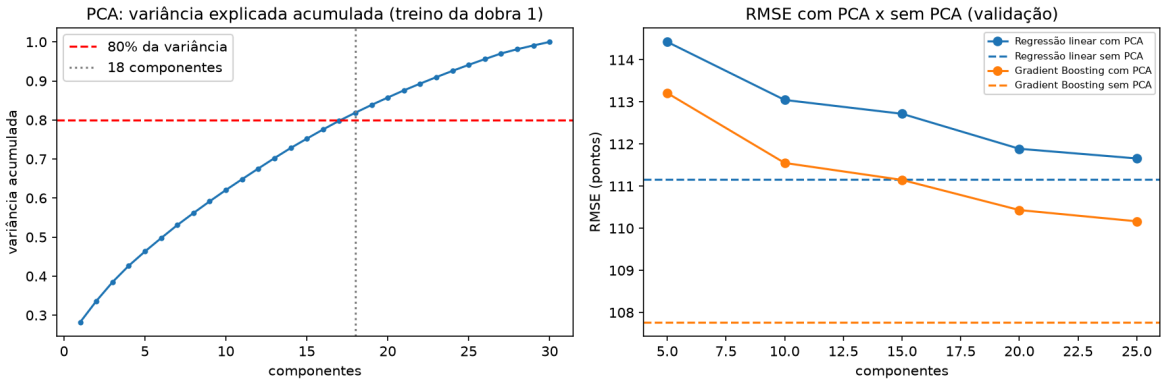
Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento (dataset_1_fundido).

Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Validação cruzada em três dobras; dataset inicial de 30 colunas.

3.2 PCA, representação e hipóteses de preparação

Para atingir 80% da variância explicada, seriam necessários 18 dos 30 componentes iniciais; portanto, a redução foi limitada. O PCA piorou os dois regressores avaliados: com 25 componentes, o RMSE do Gradient Boosting passou de 107,77 para 110,17 e o da regressão linear passou de 111,15 para 111,66. A seleção de 51 entradas aumentou o RMSE em 1,04 ponto, e a de 22 em 4,58 pontos. Consequentemente, nenhum desses métodos foi adotado.

Figura 3 – Variância acumulada do PCA e comparação do RMSE com e sem redução.

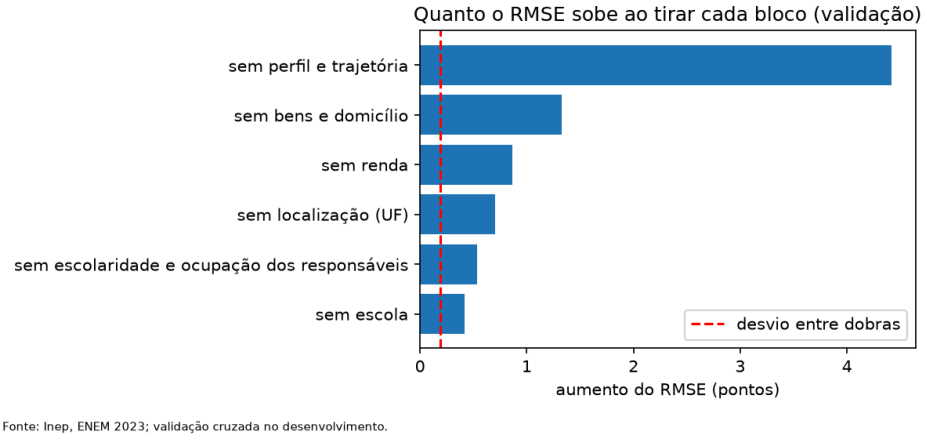


Fonte: Inep, ENEM 2023; desenvolvimento. PCA dentro do Pipeline, padronizado, reajustado em cada dobra.

Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Desenvolvimento; ajuste do PCA em cada dobra.

Entre os oito conjuntos de atributos salvos, o melhor foi o de 45 colunas (RMSE 107,05). Manter separadas as variáveis de trajetória escolar reduziu o erro de 107,05 para 106,73; acrescentar UF reduziu-o para 106,03. Retirar as três features compostas alterou o erro em apenas +0,01 ponto. Na ablação de blocos, retirar perfil e trajetória provocou a maior piora (+4,42), seguido de bens (+1,33), renda (+0,87) e localização (+0,70). A renda familiar (Q006; $\rho = 0{,}457$) e o número de computadores no domicílio (Q024; $\rho = 0{,}409$) foram as entradas isoladas com maior correlação com a nota.

Figura 4 – Aumento do RMSE quando blocos de atributos são retirados do modelo.

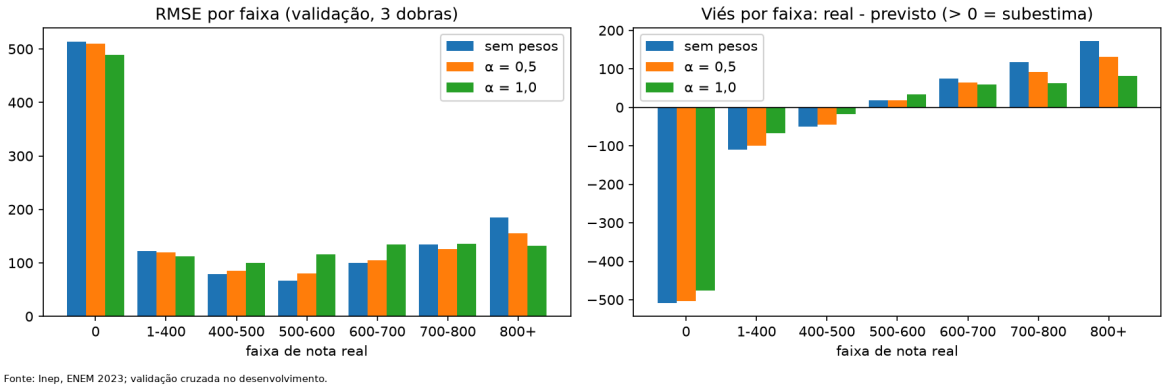


Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Validação cruzada no desenvolvimento.

3.3 Balanceamento e solução final

O balanceamento mostrou um compromisso entre extremos e centro: para notas acima de 800, o RMSE caiu de 184,9 para 155,4 ($\alpha = 0{,}5$) e 131,7 ($\alpha = 1{,}0$), mas o RMSE global piorou em 2,12 e 17,43 pontos, respectivamente. A opção sem pesos foi mantida porque minimiza o erro no conjunto original. A retirada experimental das notas zero apenas do treino não trouxe ganho consistente.

Figura 5 – RMSE e viés por faixa de nota, com e sem ponderação.



Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Validação cruzada no desenvolvimento; faixas de nota fixadas antes do teste.

A solução final adotou HistGradientBoostingRegressor com hiperparâmetros da busca e 74 entradas, sem PCA, seleção ou pesos (taxa de aprendizado de aproximadamente 0,067, até 500 iterações, 89 folhas, mínimo de 137 observações por folha e regularização L2 de 0,24). Na validação cruzada, obteve RMSE de 105,86 ± 0,17; no teste isolado, RMSE de 105,81, MAE de 82,00 e R^2 de 0,354, com redução de 19,7% no RMSE frente ao baseline e 2,8% frente à regressão linear.

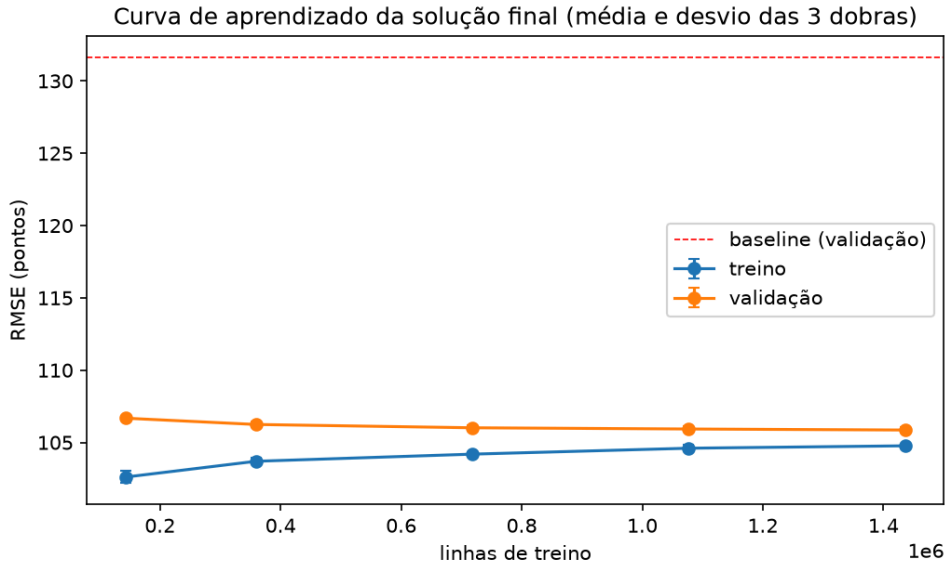
Tabela 1 – Métricas e tempo na validação cruzada e no teste final

Modelo	Avaliação	RMSE	MAE	R^2	Tempo (s)
Baseline	CV (por dobra)	131,63 ± 0,16	107,58 ± 0,06	0,000	0,2
Baseline	Teste	131,70	107,64	0,000	0
Linear sem regularização	CV (por dobra)	108,87 ± 0,16	84,86 ± 0,04	0,316 ± 0,001	2,8
Linear sem regularização	Teste	108,86	84,89	0,317	4
Gradient Boosting final	CV (por dobra)	105,86 ± 0,17	82,02 ± 0,05	0,353 ± 0,001	91
Gradient Boosting final	Teste	105,81	82,00	0,354	165

Fonte: elaboração própria, com base nos experimentos da equipe e nos microdados do ENEM 2023 (INEP, 2024).

A curva de aprendizado mostra RMSE de treino próximo de 104,8 e de validação próximo de 105,9 com o conjunto completo; a diferença é de aproximadamente 1,1 ponto. De 75% para 100% do treino, o ganho na validação foi de somente 0,07 ponto, inferior à variabilidade entre dobras. Não houve evidência de sobreajuste acentuado no modelo selecionado.

Figura 6 – Curva de aprendizado do modelo final, com média e desvio entre dobras.



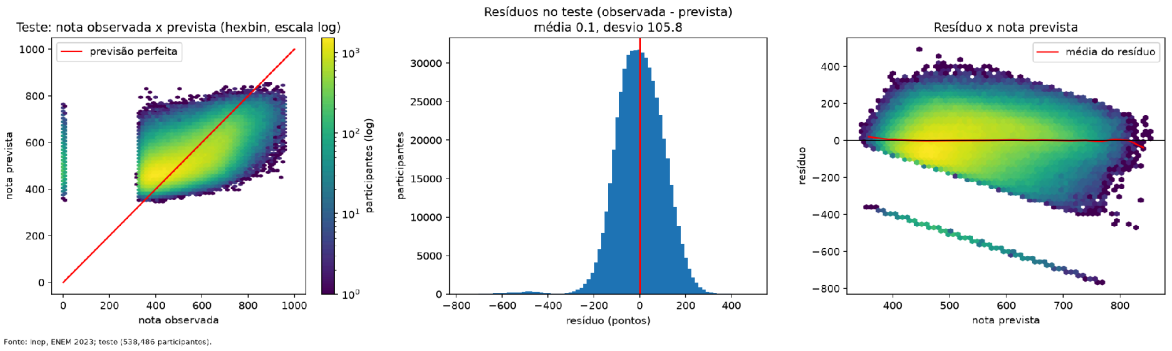
Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Validação cruzada; proporções de 10%, 25%, 50%, 75% e 100% do treino de cada dobra.

3.4 Previsões, resíduos e diferenças entre grupos

As previsões do teste se concentraram aproximadamente entre 350 e 850, ainda que as notas reais variassem de 0 a 1.000. Os resíduos (observado menos previsto) tiveram média próxima de 0,1 ponto, mas exibiram regressão à média: superestimação das notas baixas e subestimação das altas. Entre participantes com nota acima de 800 (n = 11.243), o viés médio foi de +171 pontos; entre os de nota zero (n = 3.338), de aproximadamente −510 pontos. O RMSE foi menor na faixa de 500 a 600 (cerca de 67 pontos).

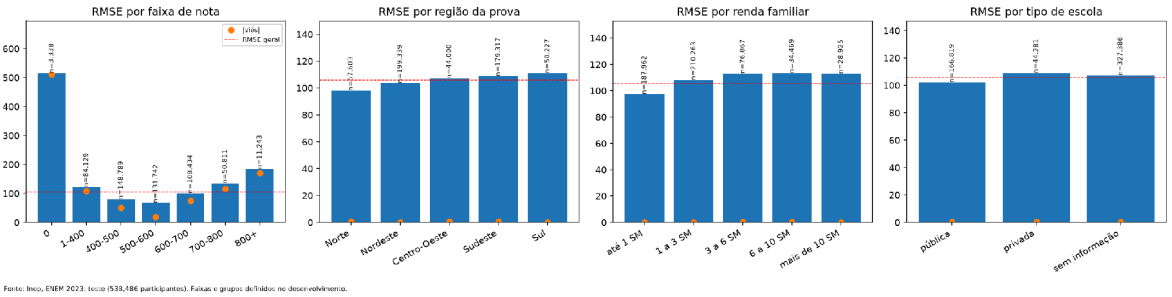
Figura 7 – Nota observada versus prevista e diagnósticos de resíduos no teste final.



Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Teste: n = 538.486; dispersão por agregação em células hexagonais.

Os erros também variaram entre grupos. A renda de até um salário mínimo apresentou RMSE de 97,3 (187.962 participantes) e a de seis a dez salários, 113,3 (34.469). Por região da prova, o Norte apresentou RMSE de 97,9 (57.603) e o Sul, 111,0 (58.227). Essas diferenças devem ser interpretadas com as distribuições das notas e os tamanhos dos grupos; não medem causalidade nem, isoladamente, tratamento desigual pelo algoritmo.

Figura 8 – RMSE do teste por nota real, região, renda e tipo de escola, com tamanhos dos grupos.



Fonte: elaboração própria, a partir dos microdados do ENEM 2023 (INEP, 2024). Teste: n = 538.486; grupos e faixas definidos no desenvolvimento.

3.5 Verificações complementares e controle de vazamento

Uma implementação independente, avaliada no mesmo conjunto reservado após a definição da solução principal, obteve RMSE de 107,53 com Ridge e codificação one-hot; a solução principal manteve o menor erro (105,81). Em diagnóstico estritamente separado da solução, inserir notas de outras provas como entradas reduziu o RMSE de 107,05 para 74,43 e elevou o

R^2 de 0,339 para 0,680 na validação. Esse ganho ilustra o potencial de informação indisponível na inscrição, mas essas variáveis são proibidas como entradas para a tarefa. Testes posteriores à abertura do conjunto de teste, como município com target encoding (ganho de até 0,30 na validação), foram documentados e não alteraram a solução selecionada.

4 DISCUSSÃO

Os experimentos indicam que a representação dos dados e a escolha da família de modelo produziram melhorias reais, porém limitadas. O Gradient Boosting reduziu o RMSE em aproximadamente três pontos em relação à regressão linear, mas exigiu cerca de 30 vezes mais tempo por dobra (91 s contra 3 s). O stacking, apesar de complexo, praticamente empatou com o boosting inicial e demandou mais processamento. PCA e seleção reduziram o número de colunas, mas sacrificaram a precisão; as combinações de variáveis pouco acrescentaram à capacidade de uma árvore de aprender interações.

A convergência da curva de treino e validação, a proximidade do erro final de teste ao da validação e as melhorias marginais com mais exemplos sugerem que ampliar o volume de dados ou a complexidade do modelo não resolveria, por si só, os erros remanescentes. Isso não prova subajuste nem ausência completa de sobreajuste: variáveis relevantes como qualidade do ensino, tempo de estudo e circunstâncias da prova não constam do questionário. O R^2 de 0,354 representa a fração de variação explicada nessa avaliação, não a proporção de pontos de cada nota que pode ser prevista.

A divisão aleatória estima generalização a outros participantes da edição de 2023, não a novos anos, escolas ou municípios nunca observados. A UF da prova não equivale necessariamente à residência. Algumas variáveis nominais foram codificadas numericamente na comparação inicial, o que pode desfavorecer modelos lineares: na validação cruzada complementar, one-hot reduziu o RMSE linear de 108,87 para 107,89. Também deve ser considerada a escolha entre muitas configurações com as mesmas dobras. Um vazamento pequeno da fusão padronizada nos datasets históricos foi identificado e corrigido na solução final; o efeito estimado foi de 0,003 ponto no RMSE. Todos esses limites aconselham restringir a interpretação ao objetivo exploratório do estudo.

5 CONCLUSÃO

O perfil declarado na inscrição permite estimar tendências de desempenho em Matemática do ENEM 2023, mas não prever com precisão a nota de cada participante. A solução escolhida, Gradient Boosting com 74 entradas, apresentou RMSE de 105,81, MAE de 82,00 e R^2 de 0,354 no teste, superando o baseline e a regressão linear. As melhorias mais úteis foram a

modelagem por árvores, a manutenção da trajetória escolar em colunas separadas e a inclusão da UF; PCA, seleção, features compostas e agrupamentos não trouxeram ganhos, enquanto a ponderação redistribuiu os erros entre faixas de notas. Como desdobramentos, recomendam-se avaliações em outras edições do ENEM, tratamento mais sistemático das variáveis nominais e eventual incorporação de indicadores externos disponíveis antes da prova. As associações identificadas não permitem conclusões causais ou decisões individuais.

REFERÊNCIAS

BERGSTRA, James; BENGIO, Yoshua. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, v. 13, p. 281–305, 2012.

BREIMAN, Leo. Bagging predictors. *Machine Learning*, v. 24, n. 2, p. 123–140, 1996.

BREIMAN, Leo. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.

FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.

HOERL, Arthur E.; KENNARD, Robert W. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, v. 12, n. 1, p. 55–67, 1970.

INEP – INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. *Microdados do ENEM 2023 e dicionário de variáveis*. Brasília, DF: INEP, 2024. Disponível em: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem. Acesso em: 11 nov. 2026.

JOLLIFFE, Ian T. *Principal component analysis*. 2. ed. New York: Springer, 2002.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

SCIKIT-LEARN DEVELOPERS. *User guide: cross-validation, pipelines, model evaluation and ensembles*. [S. l.]: scikit-learn, [s. d.]. Disponível em: https://scikit-learn.org/stable/user_guide.html. Acesso em: 11 nov. 2026.

SPEARMAN, Charles. The proof and measurement of association between two things. *American Journal of Psychology*, v. 15, n. 1, p. 72–101, 1904.

WOLPERT, David H. Stacked generalization. *Neural Networks*, v. 5, n. 2, p. 241–259, 1992.