Previsão da nota de Matemática do ENEM 2023 pelo perfil dos participantes

Quanto o perfil explica a nota, e o que mudou o erro dos modelos

João Igor Vidal de Andrade · Raquel Albuquerque Quirino · Amanda Lira · Sofya Oliveira

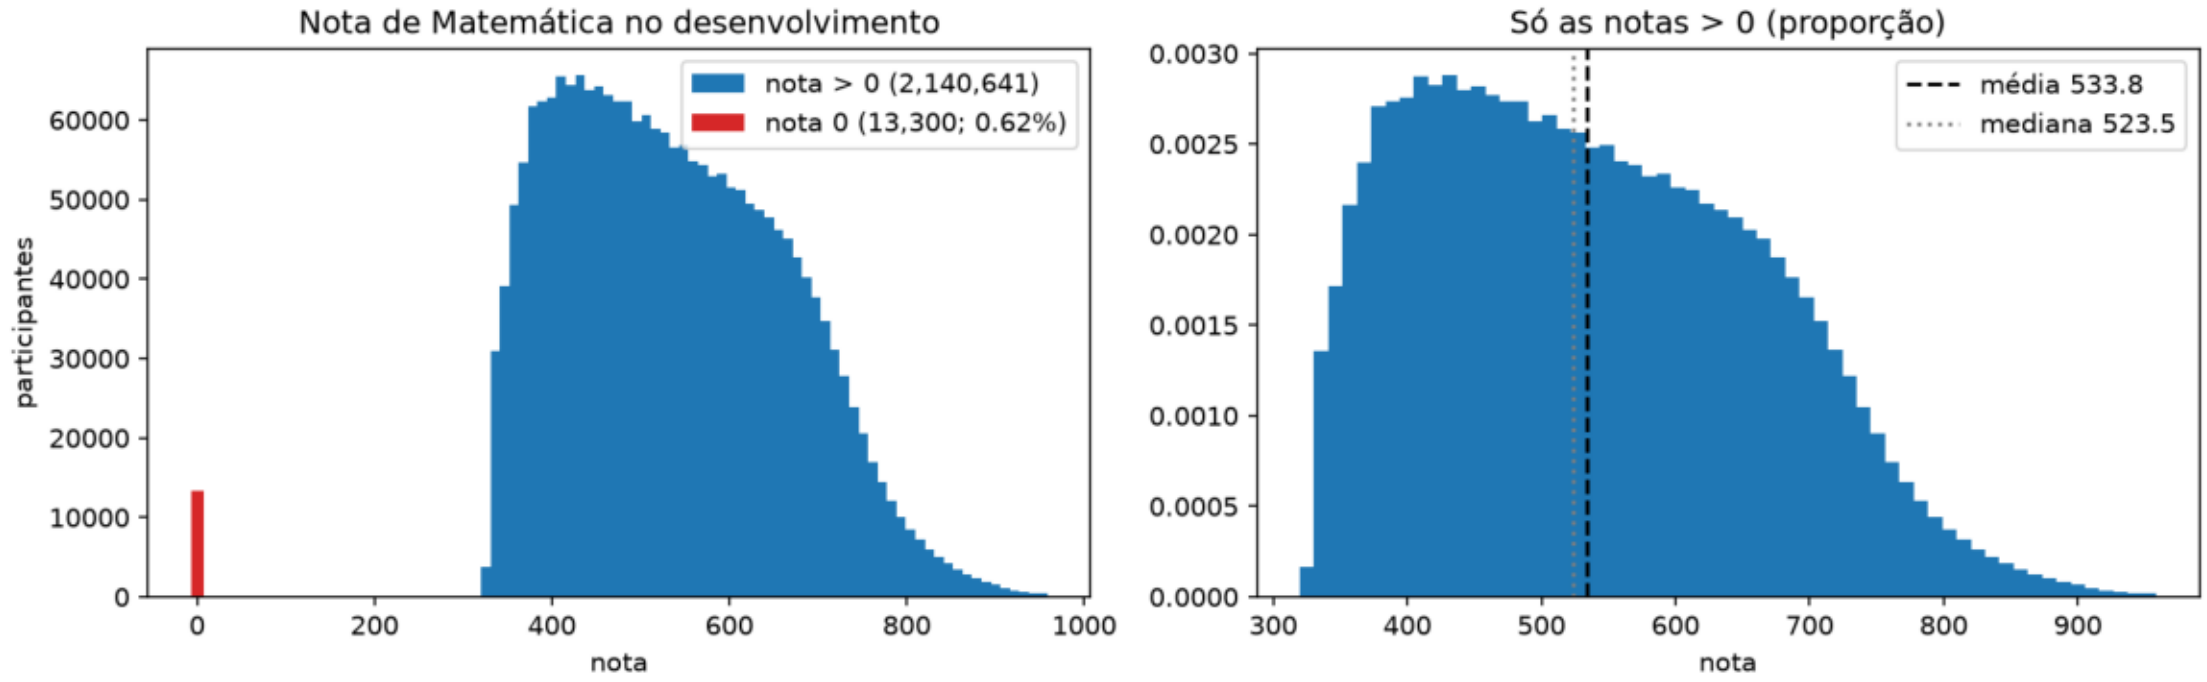
Ciência de Dados, Projeto 2 (Unidade II: Aprendizado de Máquina) · Unifor

github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

O problema e a base

- Pergunta: quanto o perfil socioeconômico, escolar e demográfico estima a nota de Matemática (NU_NOTA_MT, de 0 a 1000)?
- Base nacional completa do Inep: 3.933.955 participantes; 2.692.427 com nota observada (usados).
- 80% para desenvolvimento (2.153.941) e 20% para teste (538.486), semente 42. O teste só foi aberto no fim.
- Nota ausente não vira zero; nota zero (0,62%) é resultado observado e fica nos dados.
- Objetivo: comparar escolhas de preparação e de modelagem e explicar os limites, não maximizar o R^2.

A nota: distribuição e as notas zero



Fonte: Inep, Microdados do ENEM 2023; desenvolvimento (2,153,941 participantes).

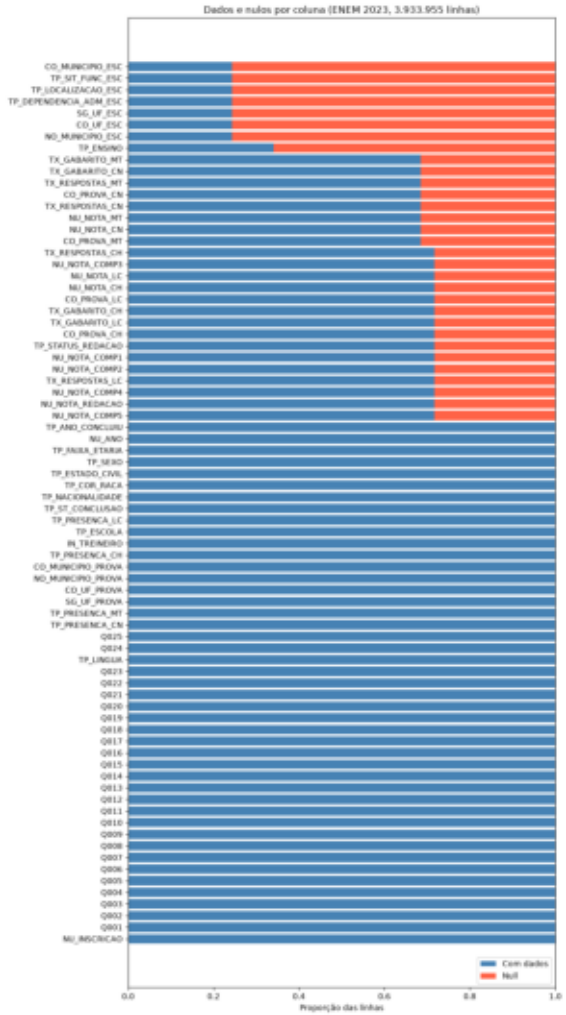
Desenvolvimento: 2.153.941 participantes. Zeros em vermelho: 13.300 (0,62%).

Zeros: resultado observado e válido (0,62%); ficam no treino e na validação.

Protocolo de avaliação e vazamento

- Validação cruzada de 3 dobras só no desenvolvimento, sempre as mesmas dobras (KFold, semente 42).
- Tudo que se aprende dos dados fica dentro de um Pipeline e é refeito só no treino de cada dobra.
- Métrica principal: RMSE (MAE e R^2 complementares), com média e desvio entre as dobras.
- Fora das entradas: notas de outras provas, presença, respostas, gabarito, código da prova.
- Vazamento encontrado e corrigido: a fusão da situação escolar usava média e desvio de todas as linhas. Agora é refeita no treino de cada dobra (efeito medido: 0,003 ponto).

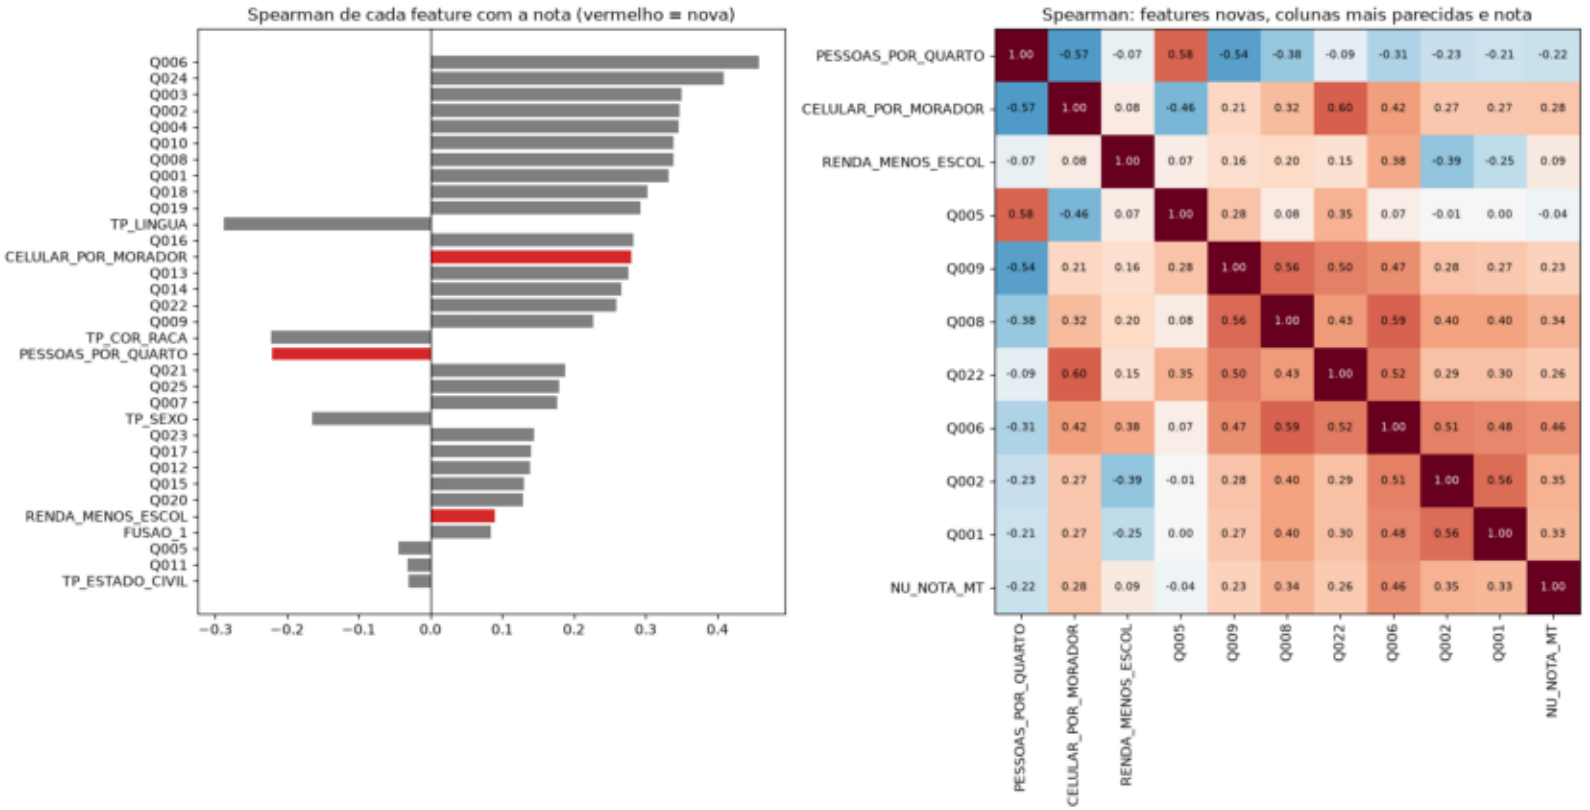
Preparação: o que está faltando e o que significa



Proporção de dados e de valores ausentes por coluna na base bruta.

- Escola: 73% de vazio entre quem tem nota. É quem já concluiu o ensino médio: vira "sem informação", não mediana.
- "Não sei" em Q001 a Q004 não é nível de escolaridade: vira ausente + indicador (quem não sabe tira 40 a 50 pontos a menos).
- Questionário em letras vira número pelo dicionário do Inep; sexo em 0/1.

Features criadas, com hipótese



Spearman de cada feature criada com a nota, com as colunas parecidas e matriz resumida.

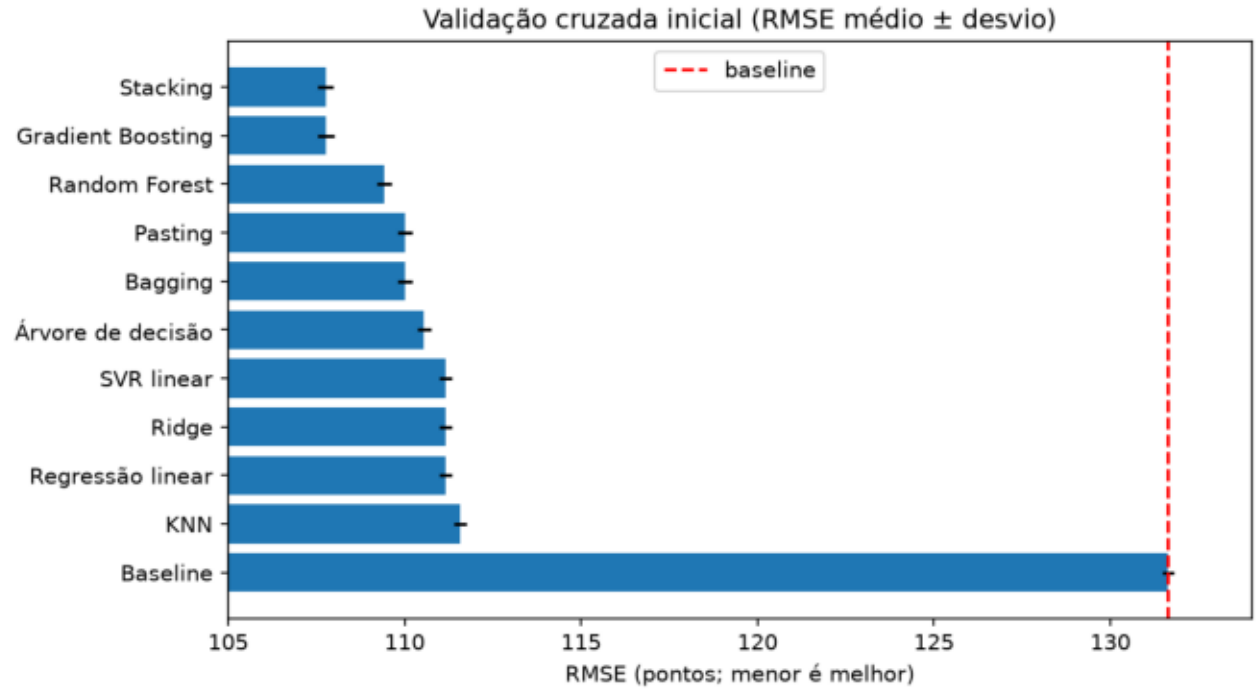
- PESSOAS_POR_QUARTO (−0,22): casa lotada, menos espaço para estudar.
- CELULAR_POR_MORADOR (+0,28): mais acesso próprio a conteúdo.
- RENDA_MENOS_ESCOL (+0,09): renda alta ou baixa para o nível de estudo da família.
- Todas com |Spearman| < 0,7 entre si e com as originais.

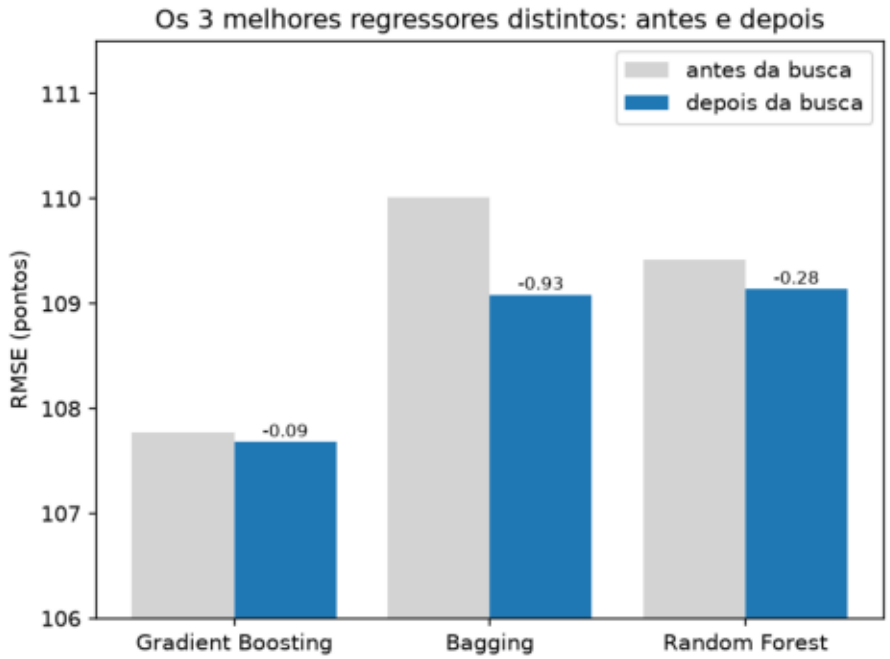
21 conjuntos de entrada avaliados

Grupo	Quantos	O que varia
Datasets salvos	8	Fusão da situação; escola; NAO_SEI e nacionalidade; 3 features criadas (30 a 45 colunas)
Variações no notebook 04	13	Fusão sem vazamento ou 4 colunas separadas; UF; sem features criadas; 3 cortes de seleção; 6 blocos retirados
Total com validação cruzada	21	Gradient Boosting em todos; regressão linear e bagging nos 8 datasets
Diagnósticos à parte	4	UF e idade desdobrada (não entram nos notebooks)

Melhor dataset salvo: dataset_3_escola_features (45 colunas): RMSE 107,05, 0,7 ponto melhor que o dataset 1. Mais colunas ajudam pouco.

Modelos: configuração inicial e busca de hiperparâmetros





Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento (dataset_1_fundido).

Validação cruzada, dataset de 30 colunas. Baseline 131,63 · regressão linear 111,15 · Gradient Boosting 107,77.

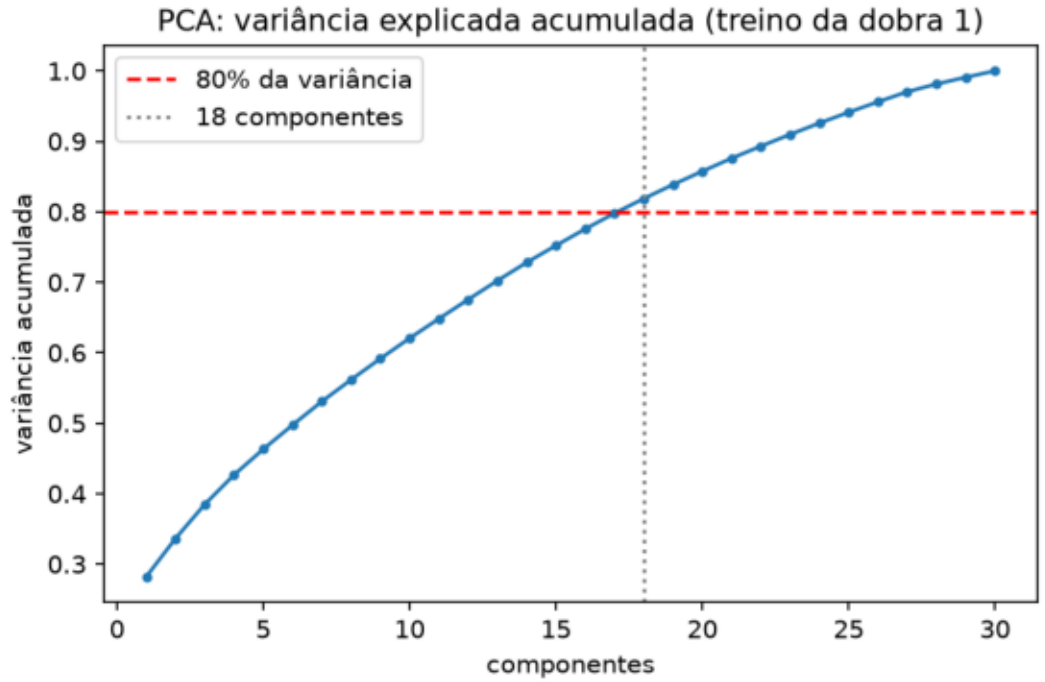
Gradient Boosting é o melhor; a busca só ajudou de fato o bagging.

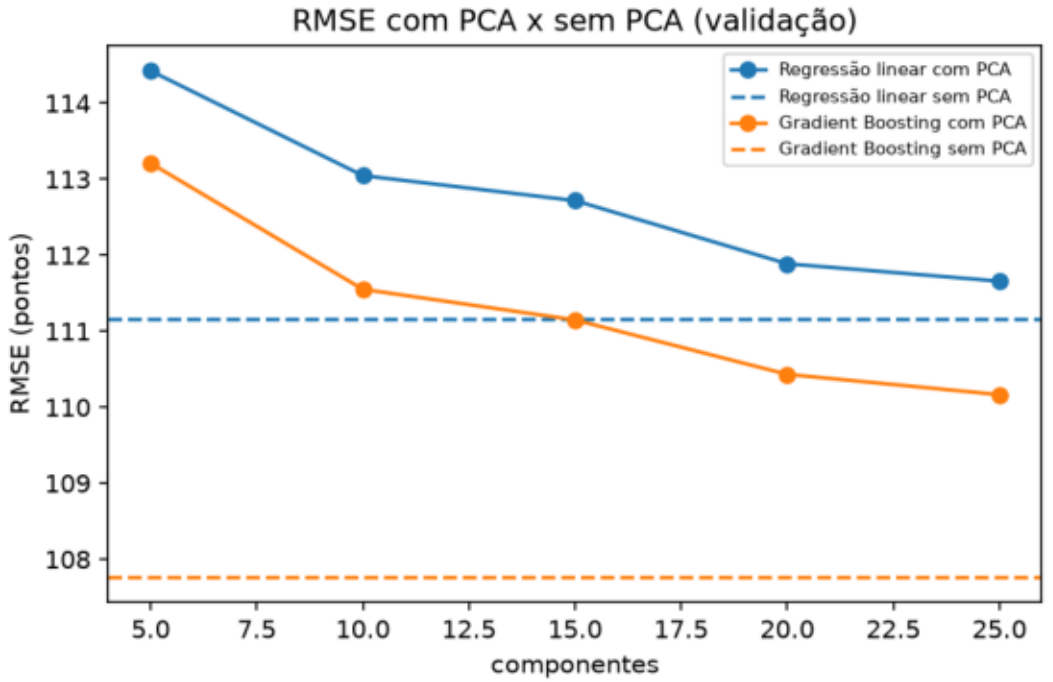
Resultados da configuração inicial

Modelo	RMSE (± desvio)	R^2	Tempo/dobra (s)
Gradient Boosting	**107,77 ± 0,23**	**0,330**	**133**
Stacking	107,76 ± 0,23	0,330	630
Random Forest	109,42 ± 0,20	0,309	103
Bagging / Pasting	110,01 ± 0,21	0,302	24 / 20
Árvore de decisão	110,55 ± 0,19	0,295	3
Regressão linear = Ridge = SVR linear	111,15 ± 0,18	0,287	0,3 a 2
KNN	111,58 ± 0,18	0,282	476
Baseline (média)	131,63 ± 0,16	0,000	0,06

Busca (RandomizedSearchCV, 10 configurações): bagging −0,93, Random Forest −0,28, Gradient Boosting −0,09 (dentro do desvio). Stacking empata e custa 5 vezes mais.

PCA: não ajudou





Fonte: Inep, ENEM 2023; desenvolvimento. PCA dentro do Pipeline, padronizado, reajustado em cada dobra.

18 de 30 componentes chegam a 80% da variância; nenhum corte supera o modelo sem PCA.

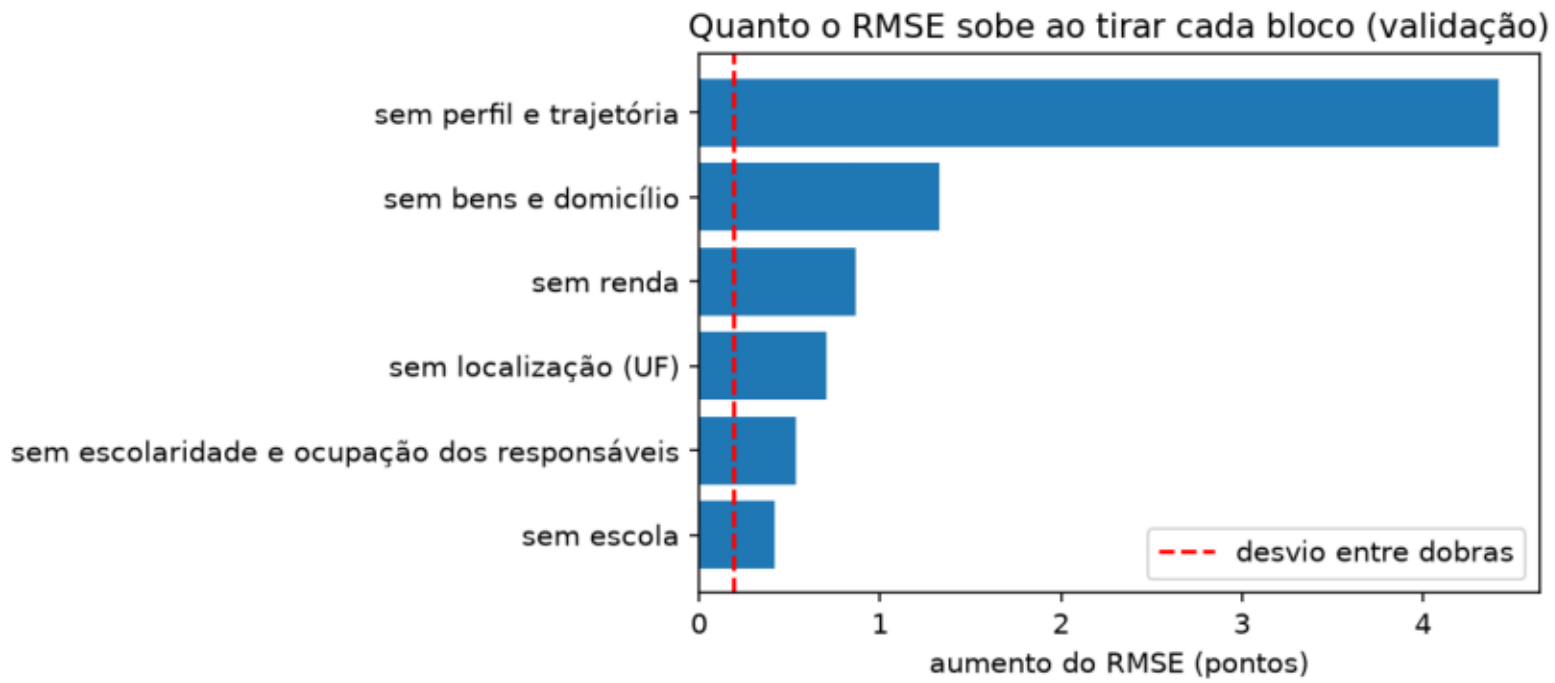
Os dados quase não se comprimem: com PCA o erro piora (GB 107,8 para 110,2 com 25 componen

Hipóteses de preparação (Gradient Boosting, validação cruzada)

Experimento	RMSE (± desvio)	Δ RMSE	Leitura
Fusão da situação escolar (só treino)	107,05 ± 0,19		referência
4 colunas de situação separadas	**106,73 ± 0,19**	**−0,33**	**melhora**
+ UF da prova (26 colunas)	**106,03 ± 0,19**	**−0,70**	**melhora**
Sem as 3 features criadas	106,04 ± 0,17	+0,01	sem diferença
SelectKBest, k = 51	107,07 ± 0,20	+1,04	piora
SelectKBest, k = 22	110,61 ± 0,19	+4,58	piora

Diferença só vale se passar do desvio entre dobras. Também sem efeito: tirar as notas zero do treino e K-means como feature.

Quanto vale cada bloco de informação

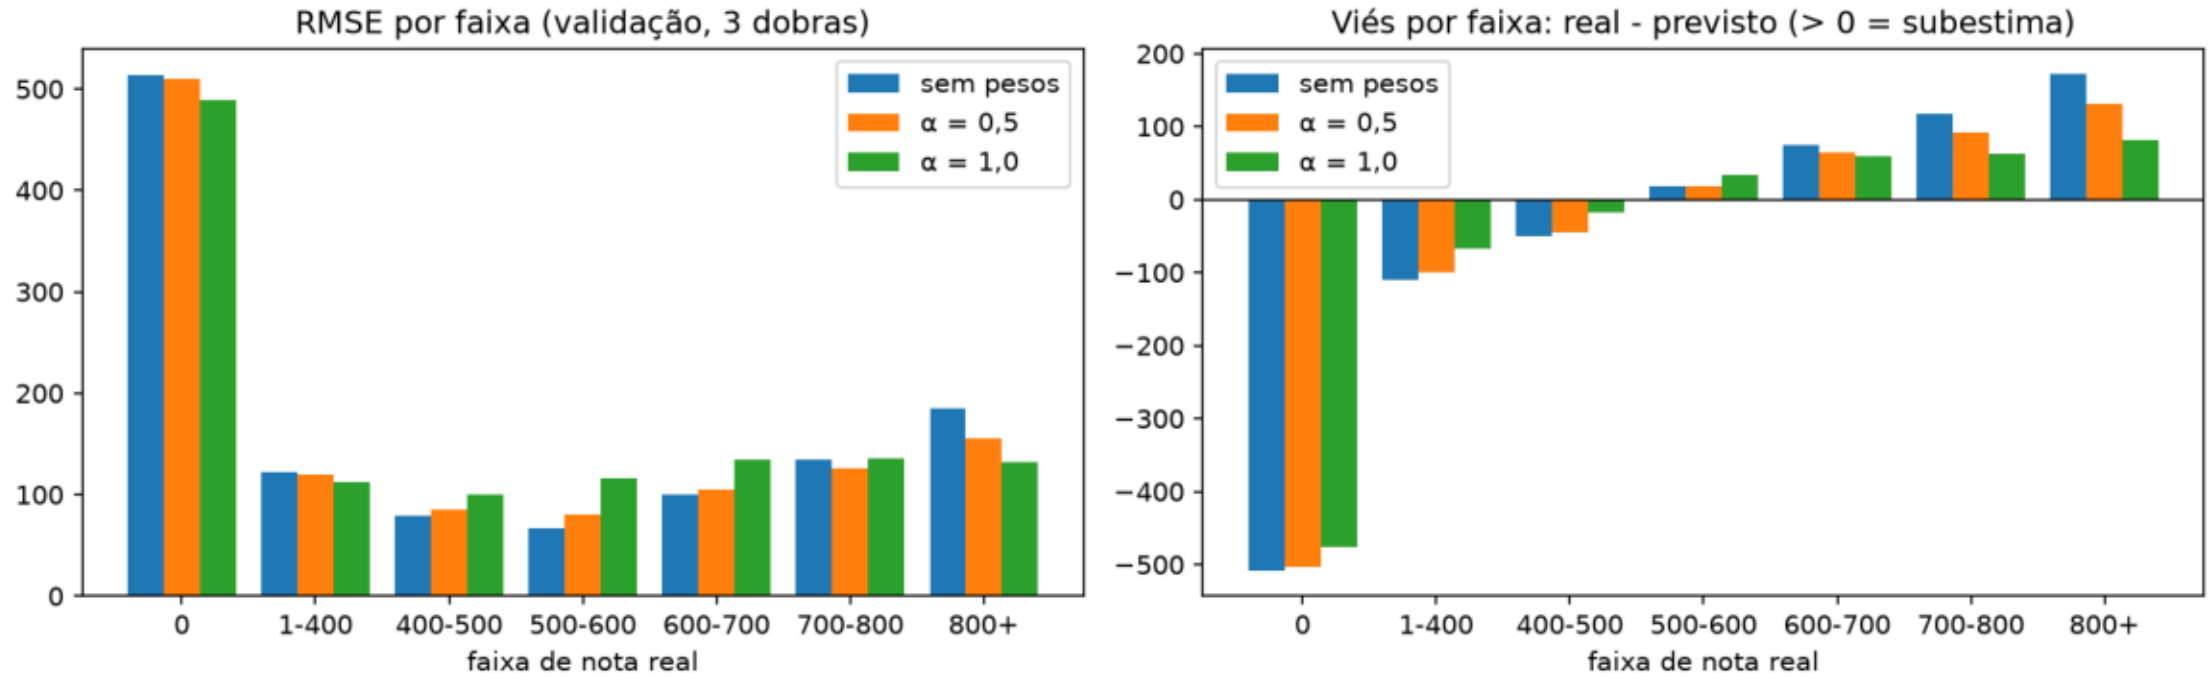


Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

RMSE sobe ao tirar um bloco por vez (linha vermelha: desvio entre dobras).

- Perfil e trajetória (sexo, idade, situação de conclusão, cor/raça, língua): +4,4.
- Bens e domicílio: +1,3. Renda: +0,9. UF: +0,7. Escolaridade e ocupação dos pais: +0,5. Escola: +0,4.
- Todos pioram o erro quando saem; os blocos se sobrepõem.

Balanceamento por ponderação de faixas



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Pesos n^(−α) por faixa de 50 pontos, calculados só no treino de cada dobra.

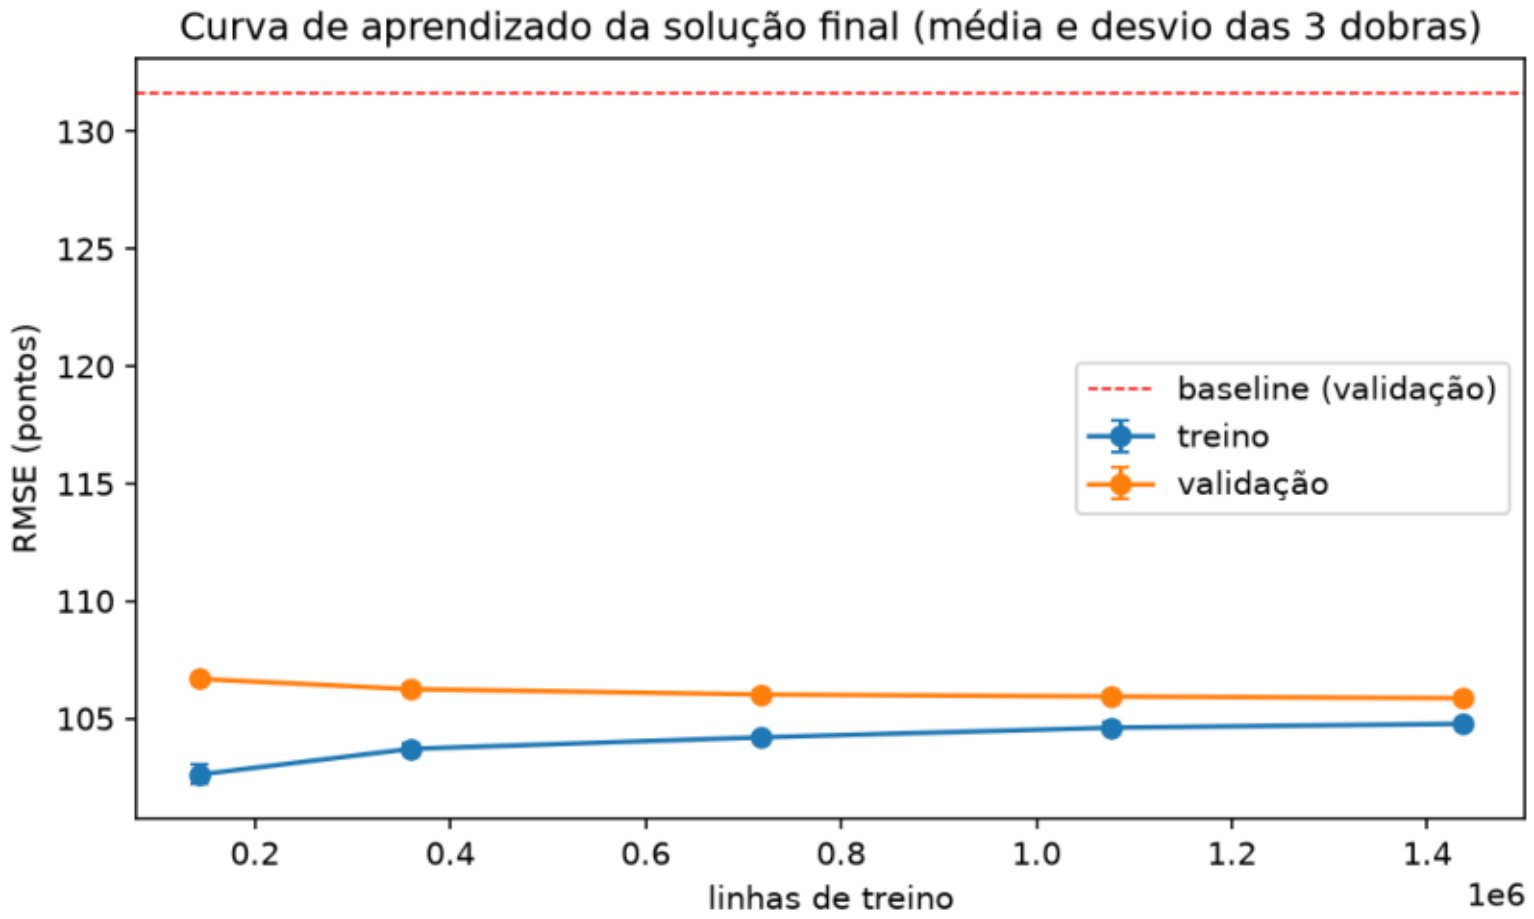
Peso nas faixas raras: as notas altas melhoram e as notas do meio pioram.

Balanceamento: o que ganhamos e o que perdemos

- Notas acima de 800: RMSE cai de 184,9 para 155,4 (α = 0,5) e 131,7 (α = 1,0); o viés cai de 172 para 81.
- Faixa de 500 a 600 (quase todos): RMSE sobe de 66,8 para 80,6 e 115,6.
- RMSE geral piora (+2,1 e +17,4): não adotado.
- É um compromisso de objetivo: identificar notas altas pede α = 0,5; erro médio pede nenhum peso.

Peso nas pontas troca erro das notas altas por erro das notas médias.

Solução final e curva de aprendizado



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Treino e validação (média e desvio das 3 dobras) com 10%, 25%, 50%, 75% e 100% do treino da dobra.

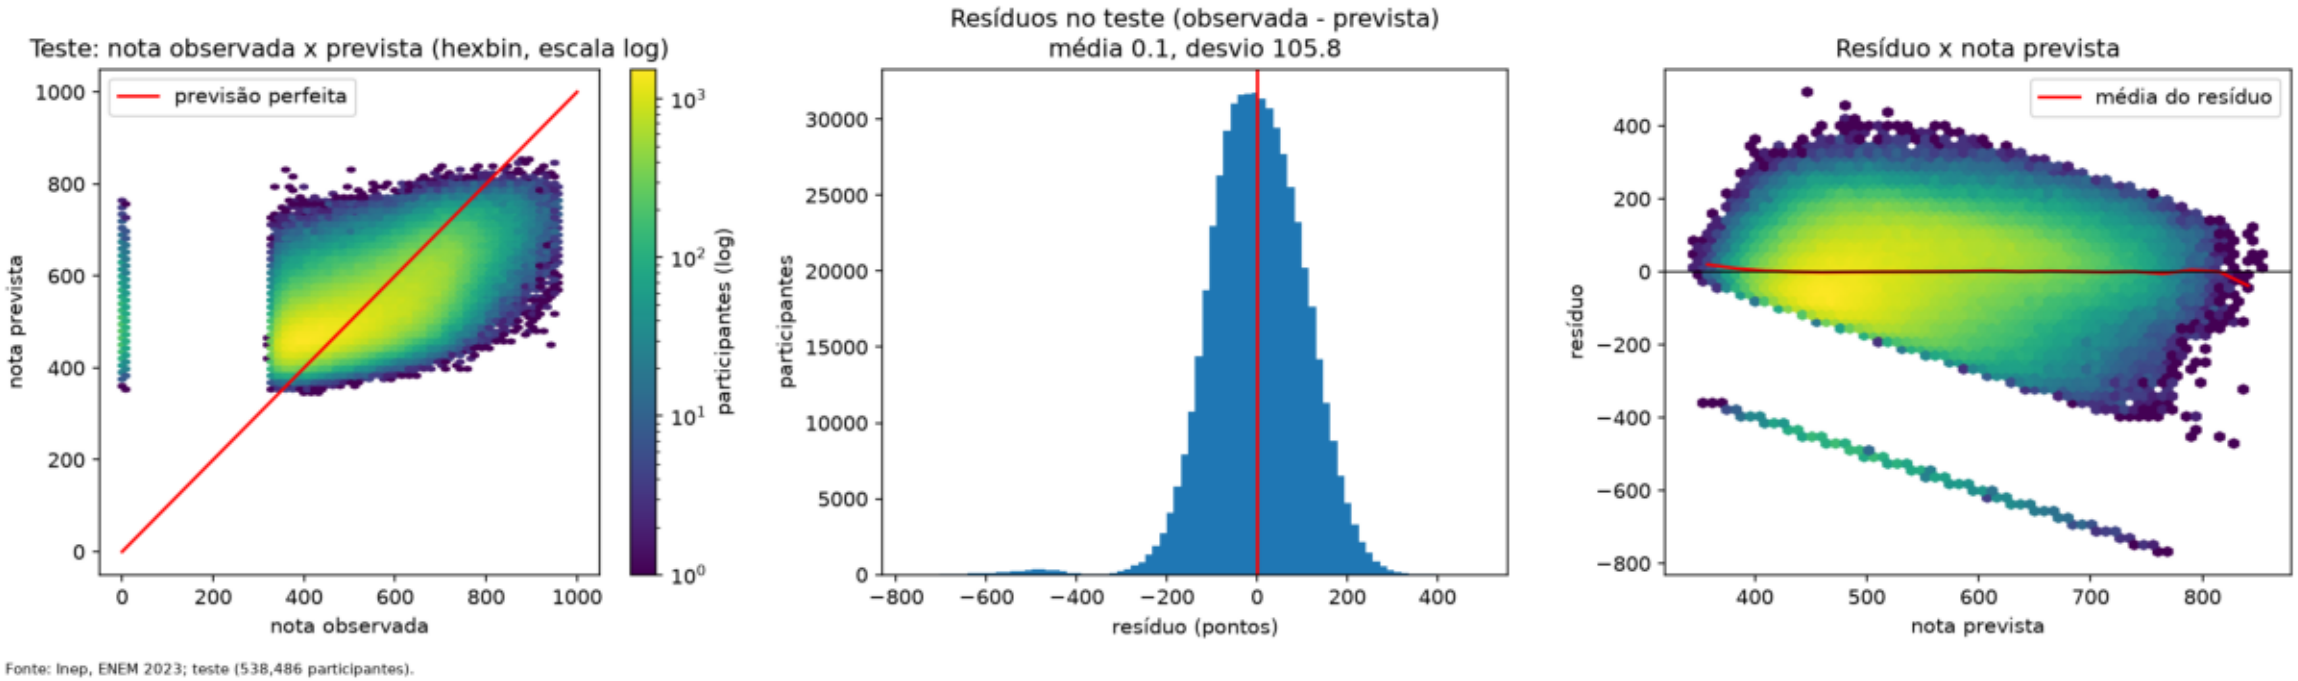
- Gradient Boosting com os hiperparâmetros da busca, 74 colunas, sem seleção, PCA nem pesos.
- Validação cruzada: RMSE 105,86 ± 0,17.
- Treino e validação separados por só 1,1 ponto; de 75% para 100%, ganho de 0,07.
- Sem sobreajuste forte; mais dados não resolveriam.

Teste final: aberto uma única vez

Modelo	CV RMSE (± desvio)	Teste RMSE	Teste MAE	Teste R^2
Baseline (média)	131,63 ± 0,16	131,70	107,64	0,000
Regressão linear sem regularização	108,87 ± 0,16	108,86	84,89	0,317
Solução final (Gradient Boosting)	**105,86 ± 0,17**	**105,81**	**82,00**	**0,354**

538.486 participantes. 19,7% menos erro que o baseline e 2,8% menos que a regressão linear. Teste e validação concordam (105,81 contra 105,86).

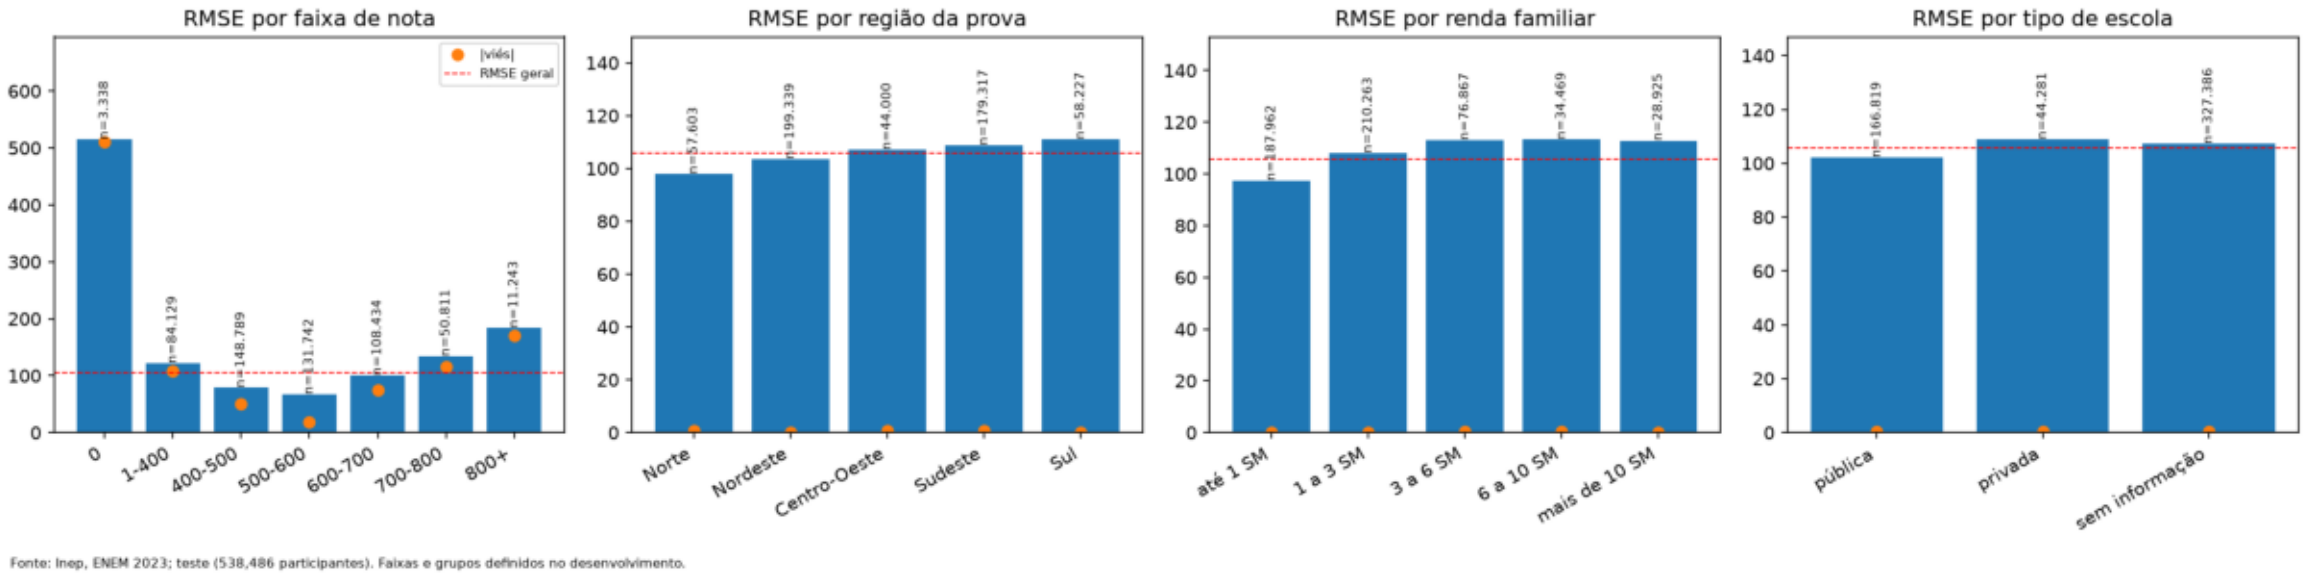
Teste: observada contra prevista e resíduos



538.486 participantes; dispersão agregada em células hexagonais; reta vermelha = previsão perfeita.

Regressão à média: previsões entre 350 e 850; os zeros viram resíduos de −370 a −770.

Erros por faixa de nota e por grupo



Fonte: Inep, ENEM 2023; teste (538,486 participantes). Faixas e grupos definidos no desenvolvimento.

RMSE no teste com o tamanho de cada grupo (n); laranja: |viés|.

Viés médio por grupo menor que 1 ponto; o erro cresce nas pontas da nota.

Conclusões e limites

- O perfil estima só a tendência: erro de 105,8 pontos e R^2 de 0,354 no teste. O limite é a informação, não o algoritmo.
- Ajudaram: modelo de árvores (−3,4), UF (−0,7), situação escolar sem fusão (−0,33), escola (−0,4). Não ajudaram: PCA, seleção, features criadas, sem zeros, K-means.
- Viés médio por grupo menor que 1 ponto; o erro maior está nas pontas (zeros: −510; acima de 800: +171).
- Limites: mesma edição (não vale para escolas ou municípios inéditos); UF e escola não são residência; uma só semente; associação não é causa.
- Próximo passo: município com codificação supervisionada dentro do Pipeline e busca na representação final.