CIÊNCIA DE DADOS · PROJETO 2 · UNIFOR

Quanto o perfil do participante explica a nota de Matemática no ENEM 2023?

Regressão com 2,7 milhões de participantes, sem vazamento

João Igor Vidal de Andrade · Raquel Albuquerque Quirino
Amanda Lira · Sofya Oliveira

Universidade de Fortaleza (UNIFOR) · Unidade II: Aprendizado de Máquina
github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

O PROBLEMA

A pergunta

Só com o que a pessoa informa na inscrição (renda, família, bens, escola, idade, UF), quanto dá para prever a nota de Matemática?

3.933.955

inscritos na base nacional do Inep (76 colunas)

2.692.427

com nota de Matemática observada (68,4%): o nosso universo

0 a 1000

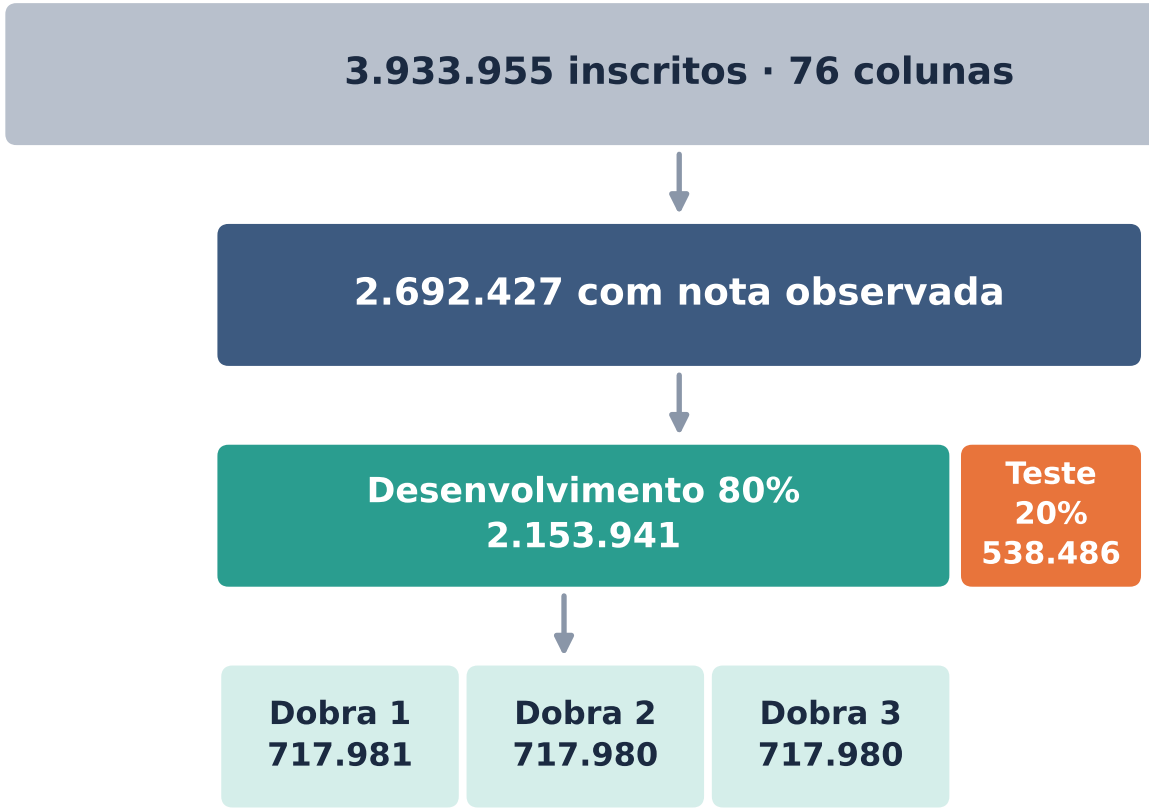
escala do alvo NU_NOTA_MT; média 533,8 e desvio 131,6

Objetivo: comparar escolhas de preparação e de modelagem sob um protocolo sem vazamento, e explicar os limites. Não é maximizar o R^2 nem prever a nota de uma pessoa: associação não é causa.

DADOS

Do Inep às dobras de validação

Cada participante fica numa única parte; o teste é sorteado no início e só é aberto no fim.



−1.241.528 sem nota de Matemática (faltaram ou foram eliminados). Nota ausente não vira zero.

A nota zero (0,62%) é resultado observado: fica no treino e na validação.

train_test_split com random_state = 42; ids salvos em dados/splits. Teste trancado até a solução final.

KFold(3, shuffle, 42) só no desenvolvimento: as mesmas dobras em todas as comparações.

PROTOCOLO

Validação cruzada sem vazamento

Tudo que se aprende dos dados é refeito só com o treino de cada rodada, dentro de um Pipeline.

	Dobra 1	Dobra 2	Dobra 3
Rodada 1	**validação**	treino	treino
Rodada 2	treino	**validação**	treino
Rodada 3	treino	treino	**validação**

Teste (538.486): fechado até o fim

Treino da rodada (≈1,44 milhão)

↓

Pipeline.fit: fusão da situação, padronização, seleção, PCA, pesos

↓

Modelo treinado

↓

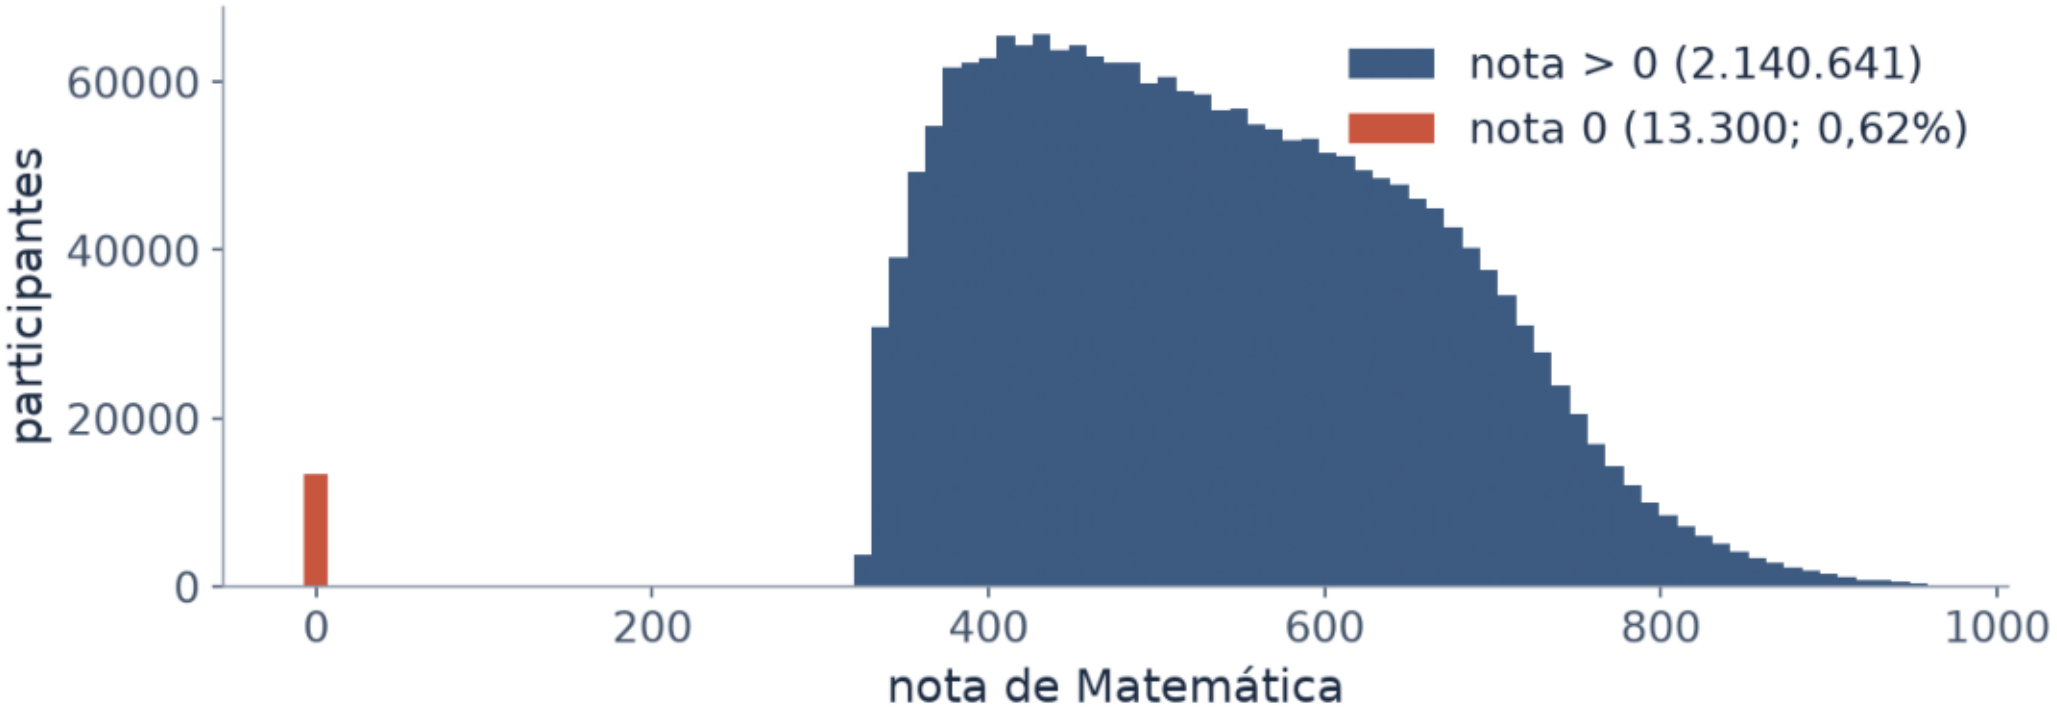
Prevê a validação (≈718 mil): RMSE, MAE e R^2

Resultado: média ± desvio das 3 rodadas. Só é melhora se a diferença passa do desvio entre dobras (≈0,2 ponto).

DADOS

A nota de Matemática

Distribuição assimétrica, com um pico isolado de notas zero (0,62%): o modelo precisa lidar com as duas pontas.

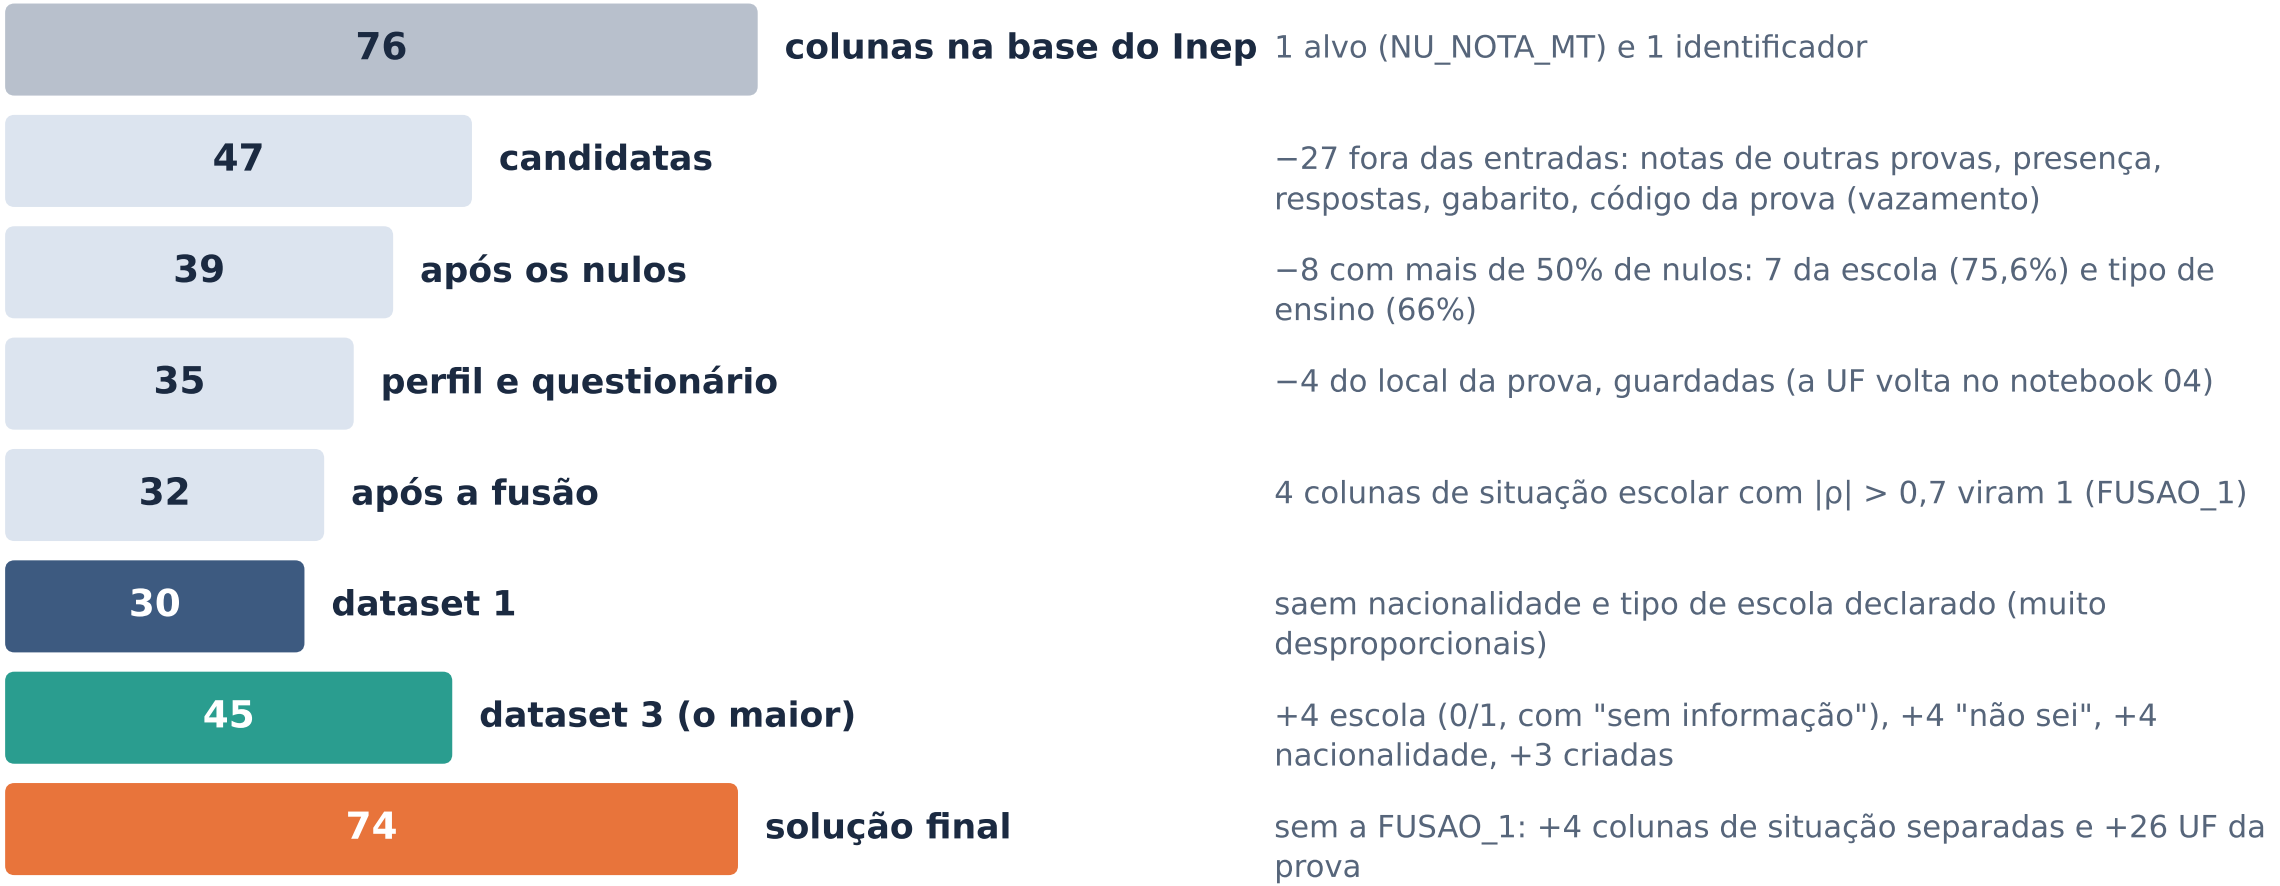


Fonte: Inep, ENEM 2023.

FEATURES

Como escolhemos as colunas

De 76 colunas da base a 74 na solução final: cada corte e cada volta tem um motivo.



FEATURES

Decisões de preparação

Seguimos o dicionário do Inep: vazio, "não sei" e "não informado" são coisas diferentes.

Escola vazia (73%)

Não é erro: é quem já concluiu o ensino médio. Vira a categoria "sem informação" nas colunas 0/1. Apagar essas linhas deixaria só 724.385 pessoas.

"Não sei" em Q001 a Q004

Não é um nível de escolaridade. Vira ausente + um indicador próprio: quem não sabe tira de 40 a 50 pontos a menos.

Letras do questionário

A, B, C... viram 0, 1, 2... na ordem do dicionário: renda e escolaridade são escadas ordenadas; bens contam de 0 a 4.

Situação escolar redundante

Faixa etária, ano de conclusão, situação e treineiro têm $|\rho|$ de até 0,885. Testamos fundidas (FUSAO_1) e separadas: separadas ganharam (−0,33).

FEATURES

Três features criadas, cada uma com uma hipótese

A primeira versão repetia as colunas de origem (|ρ| de 0,89 a 0,94) e foi descartada; ficaram as que não passam de 0,7.

PESSOAS_POR_QUARTO

pessoas ÷ quartos (mínimo 1)

−0,22

Spearman com a nota

Hipótese: Casa mais lotada, menos espaço para estudar.

CELULAR_POR_MORADOR

celulares ÷ pessoas

+0,28

Spearman com a nota

Hipótese: Mais acesso próprio a conteúdo e aulas online.

RENDA_MENOS_ESCOL

renda (0 a 1) − escolaridade dos pais (0 a 1)

+0,09

Spearman com a nota

Hipótese: Renda alta ou baixa para o estudo da família traz informação extra.

Resultado: retirar as três não muda o erro (+0,01, dentro do desvio). Elas vêm de colunas que o modelo já tem.

DATASETS

Os 8 datasets e a representação final

Cada dataset acrescenta um bloco ao anterior; o número é o RMSE do Gradient Boosting inicial (menor é melhor).

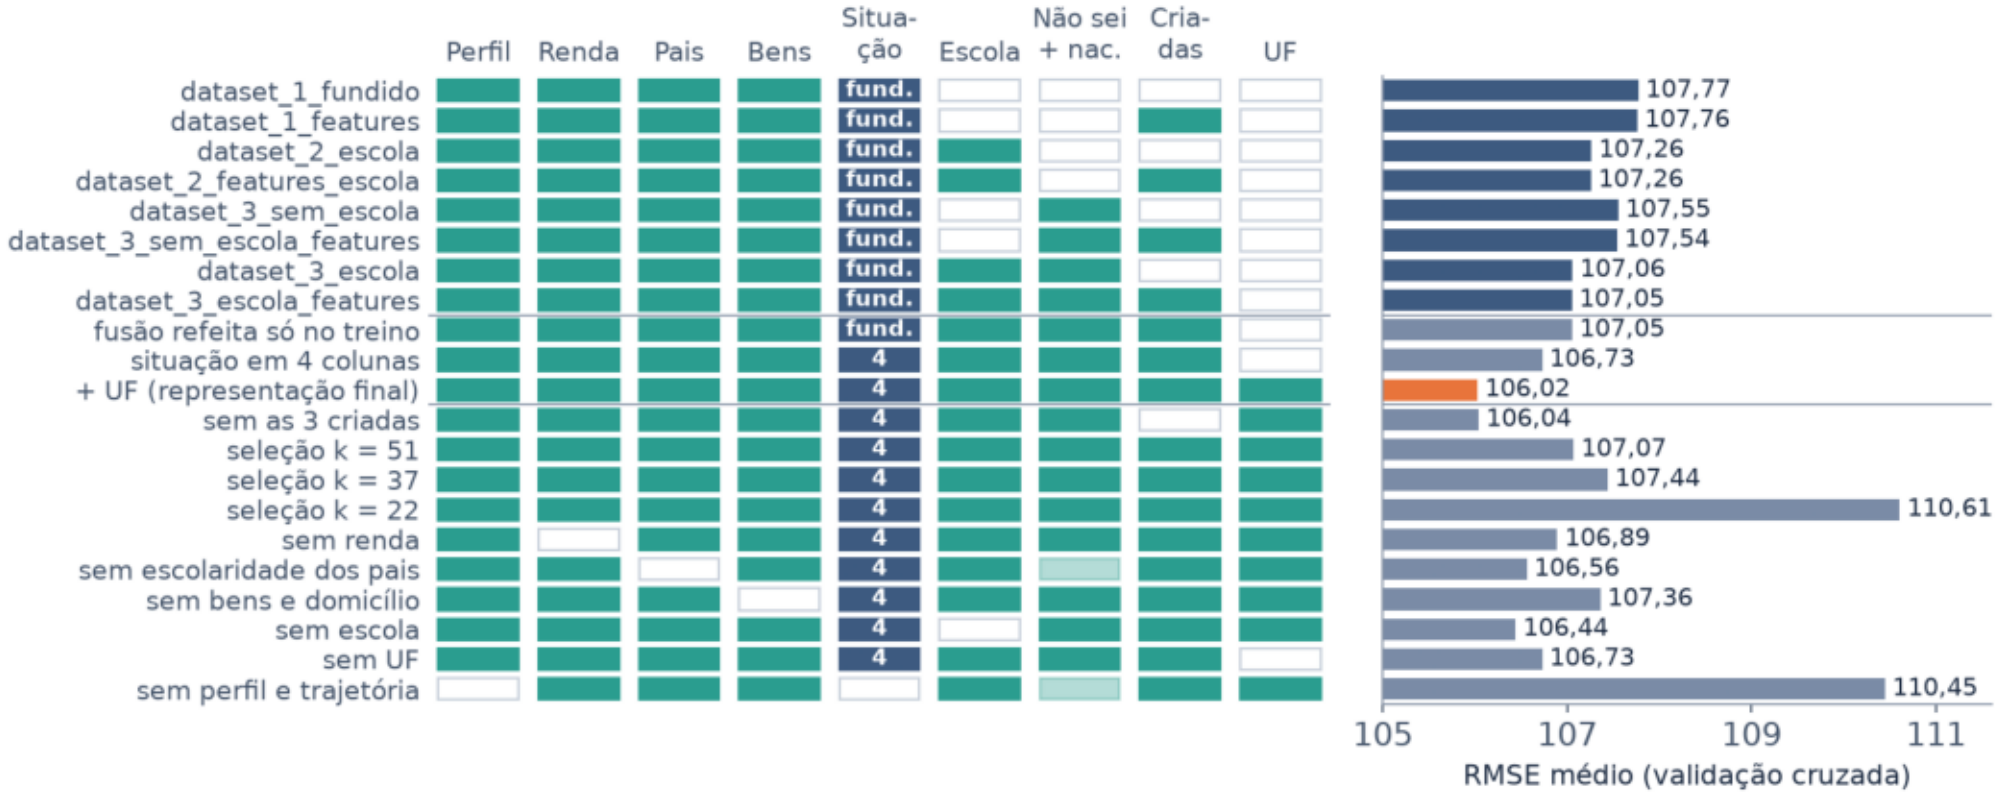


Mais colunas ajudam pouco: do menor (30) ao maior (45) o ganho é de 0,72 ponto. A escola dá o ganho mais consistente.

DATASETS

As 21 combinações testadas

Verde = bloco presente. A UF deu o maior ganho; tirar perfil ou selecionar poucas colunas piorou.

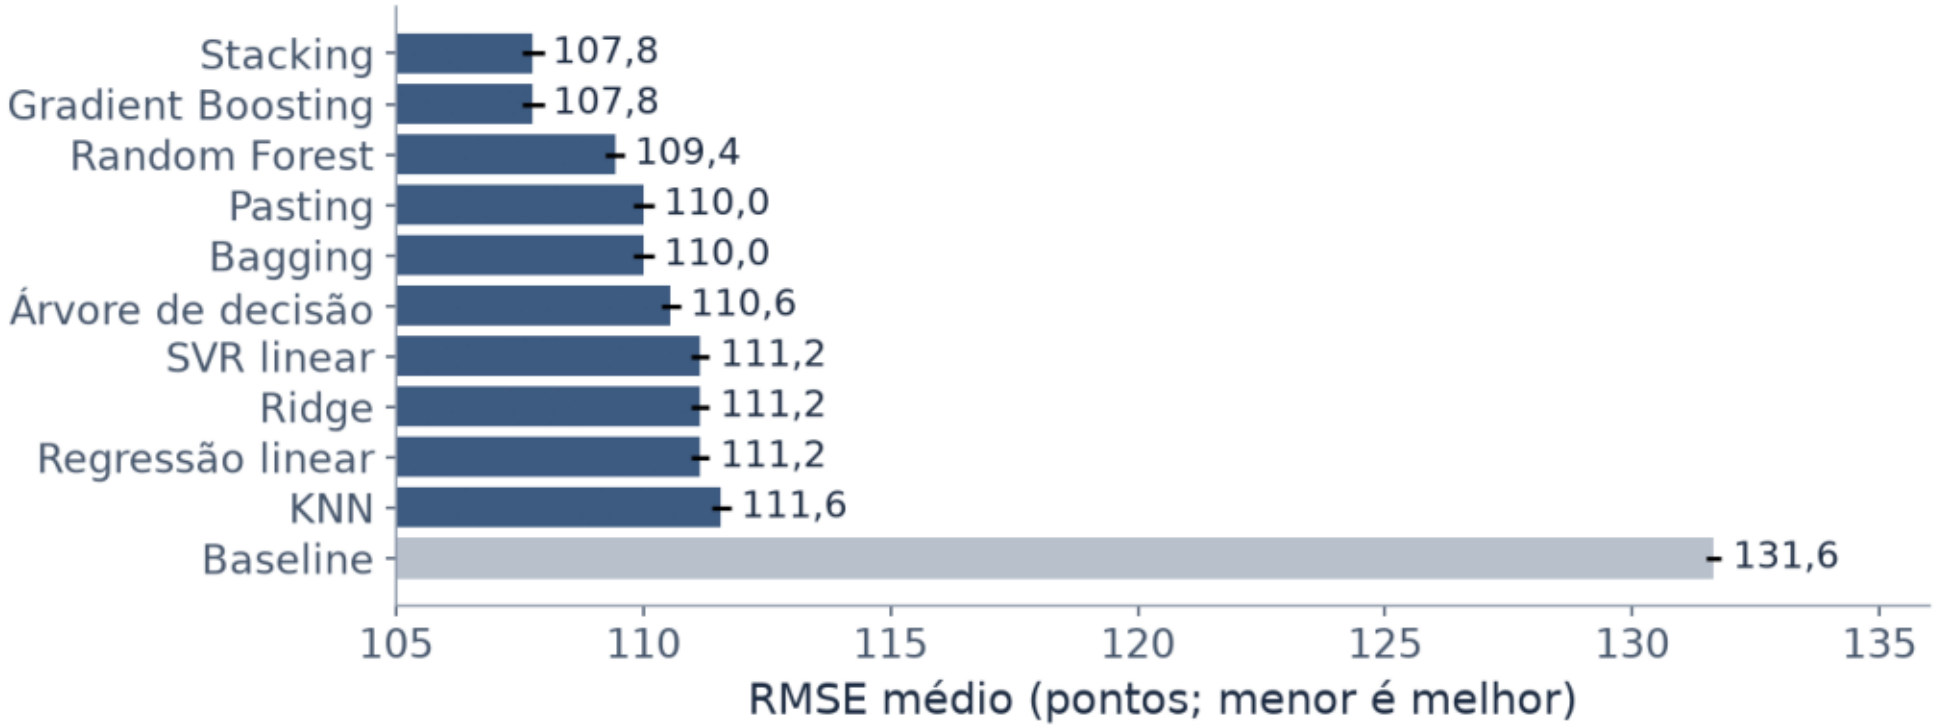


Gradient Boosting inicial, 3 dobras. Verde claro: bloco retirado em parte. Seleção: SelectKBest dentro do Pipeline.

MODELOS

Dez regressores na configuração inicial

As árvores com boosting ficam na frente; KNN e SVR linear não superam a regressão linear. Stacking empata e custa 5 vezes mais.

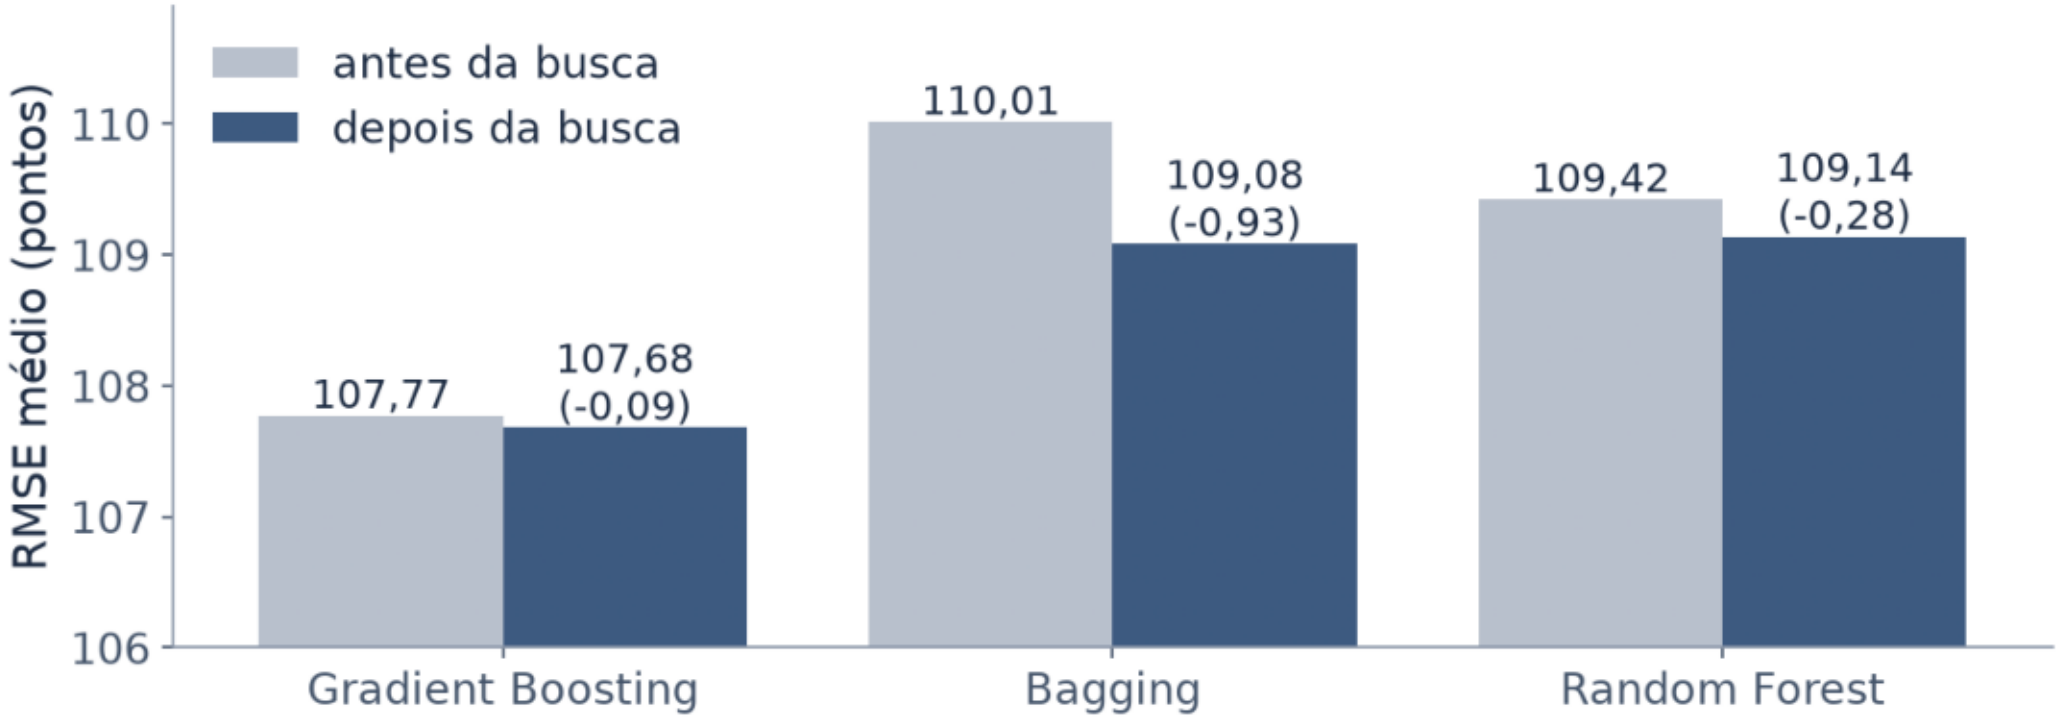


Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento (dataset_1_fundido). Barra de erro: desvio entre dobras.

MODELOS

Busca de hiperparâmetros

RandomizedSearchCV, 10 configurações, mesmas dobras: só o bagging ganhou de fato (−0,93); no Gradient Boosting, −0,09.

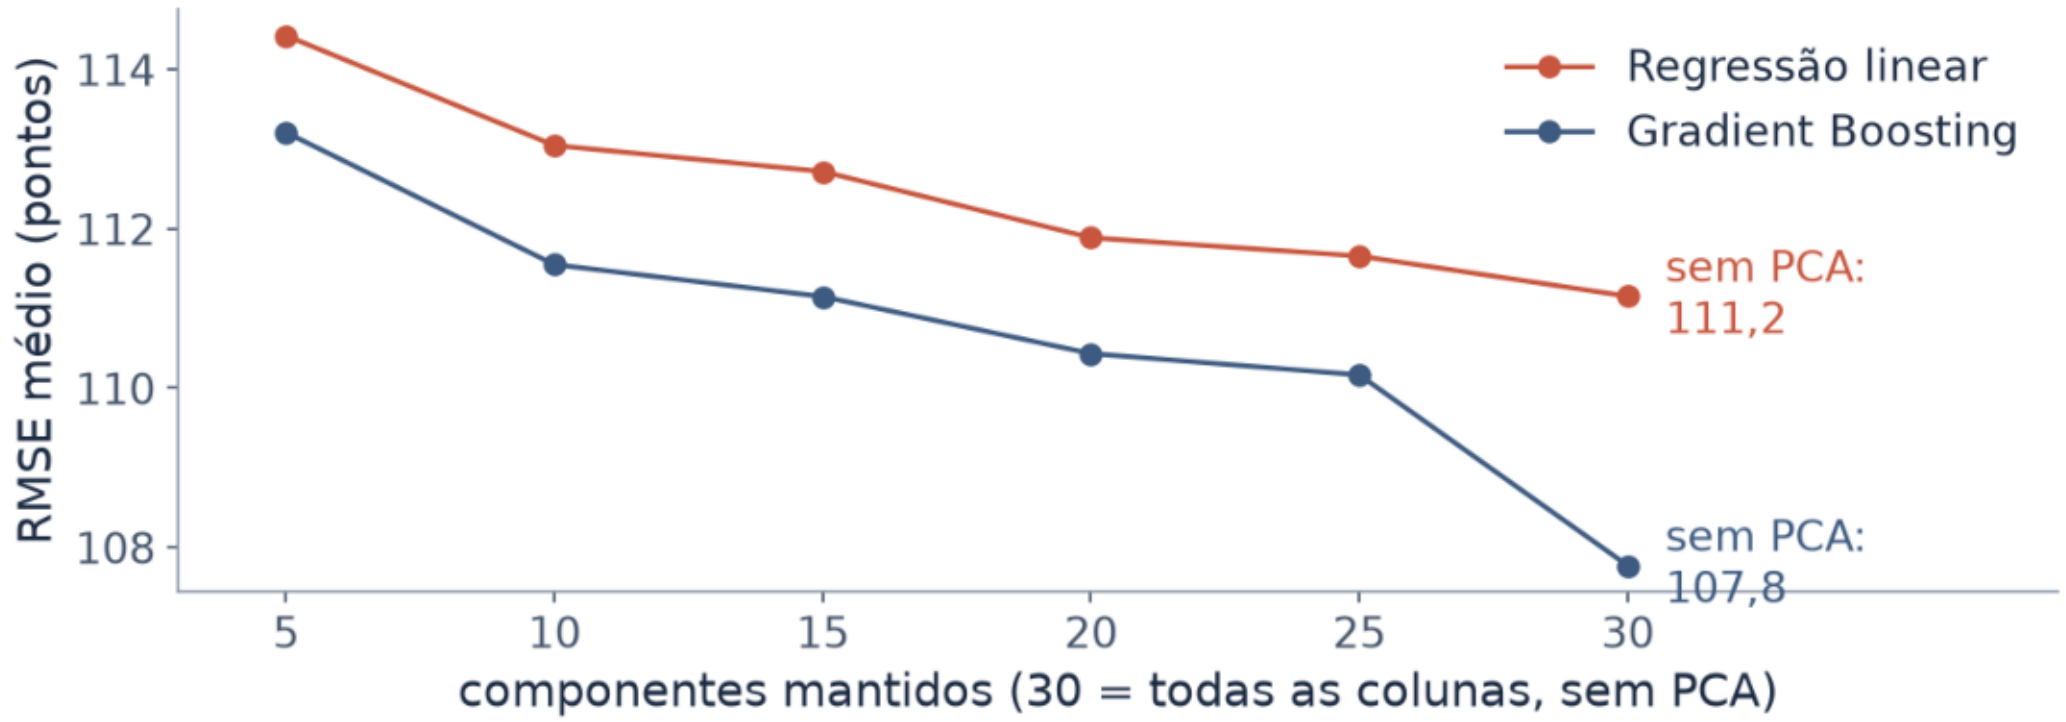


Fonte: Inep, ENEM 2023; RandomizedSearchCV, 10 configurações, validação cruzada no desenvolvimento.

HIPÓTESES

PCA: os dados quase não se comprimem

São precisos 18 de 30 componentes para 80% da variância, e com PCA o erro piora em todos os cortes.

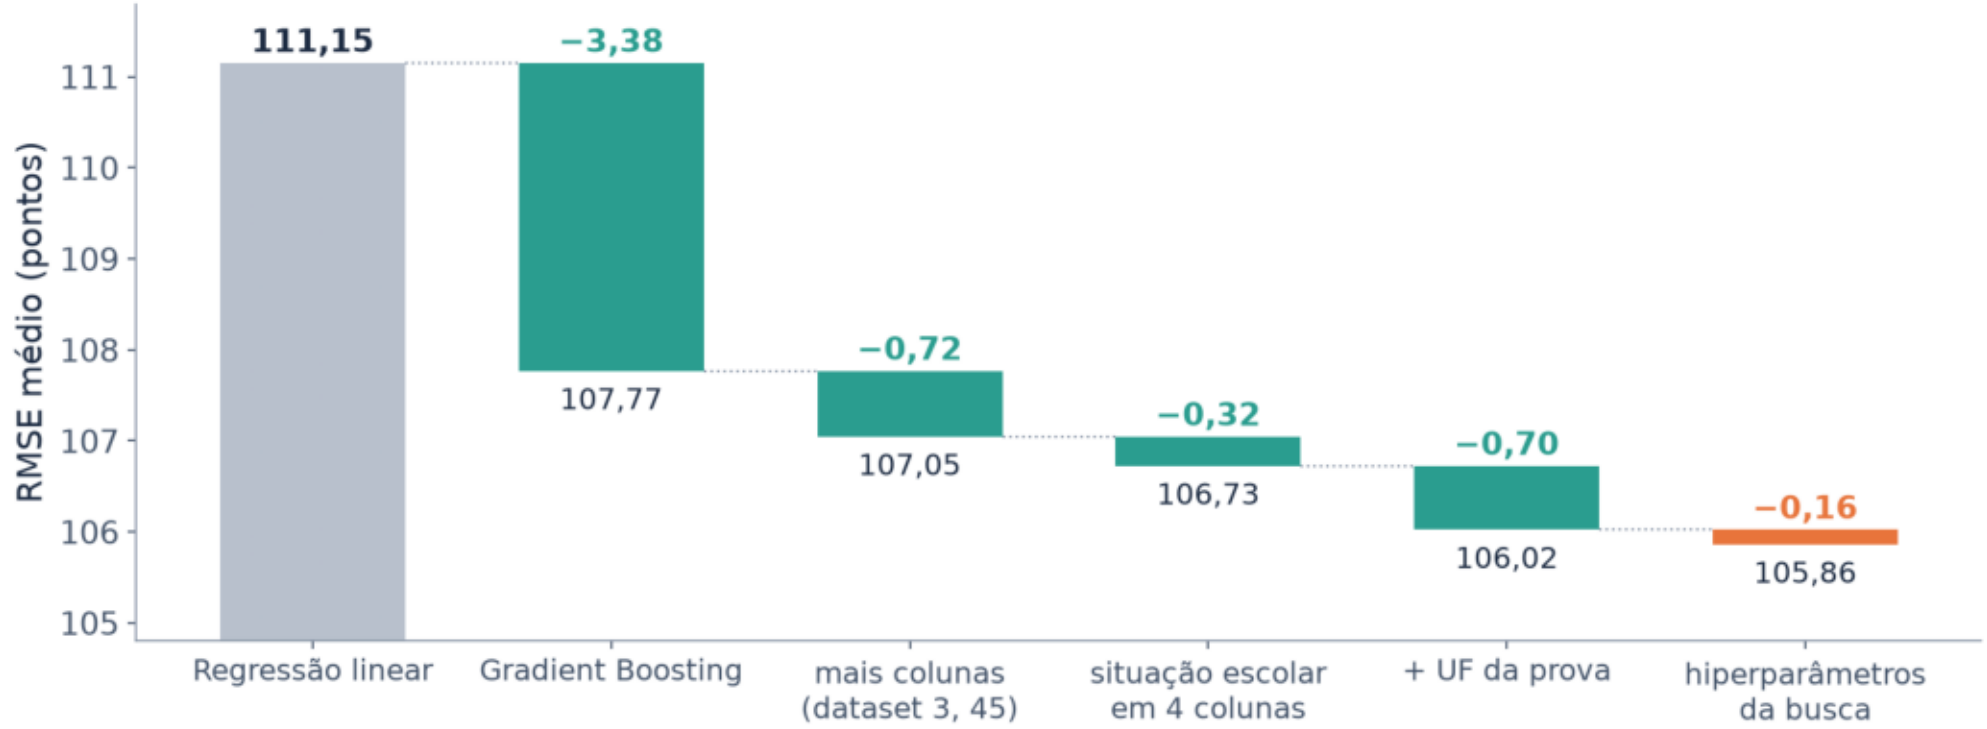


Fonte: Inep, ENEM 2023; PCA dentro do Pipeline, validação cruzada no desenvolvimento.

HIPÓTESES

O que reduziu o erro, passo a passo

Da regressão linear à solução final: o modelo de árvores pesa mais que tudo; UF e situação separada vêm depois.



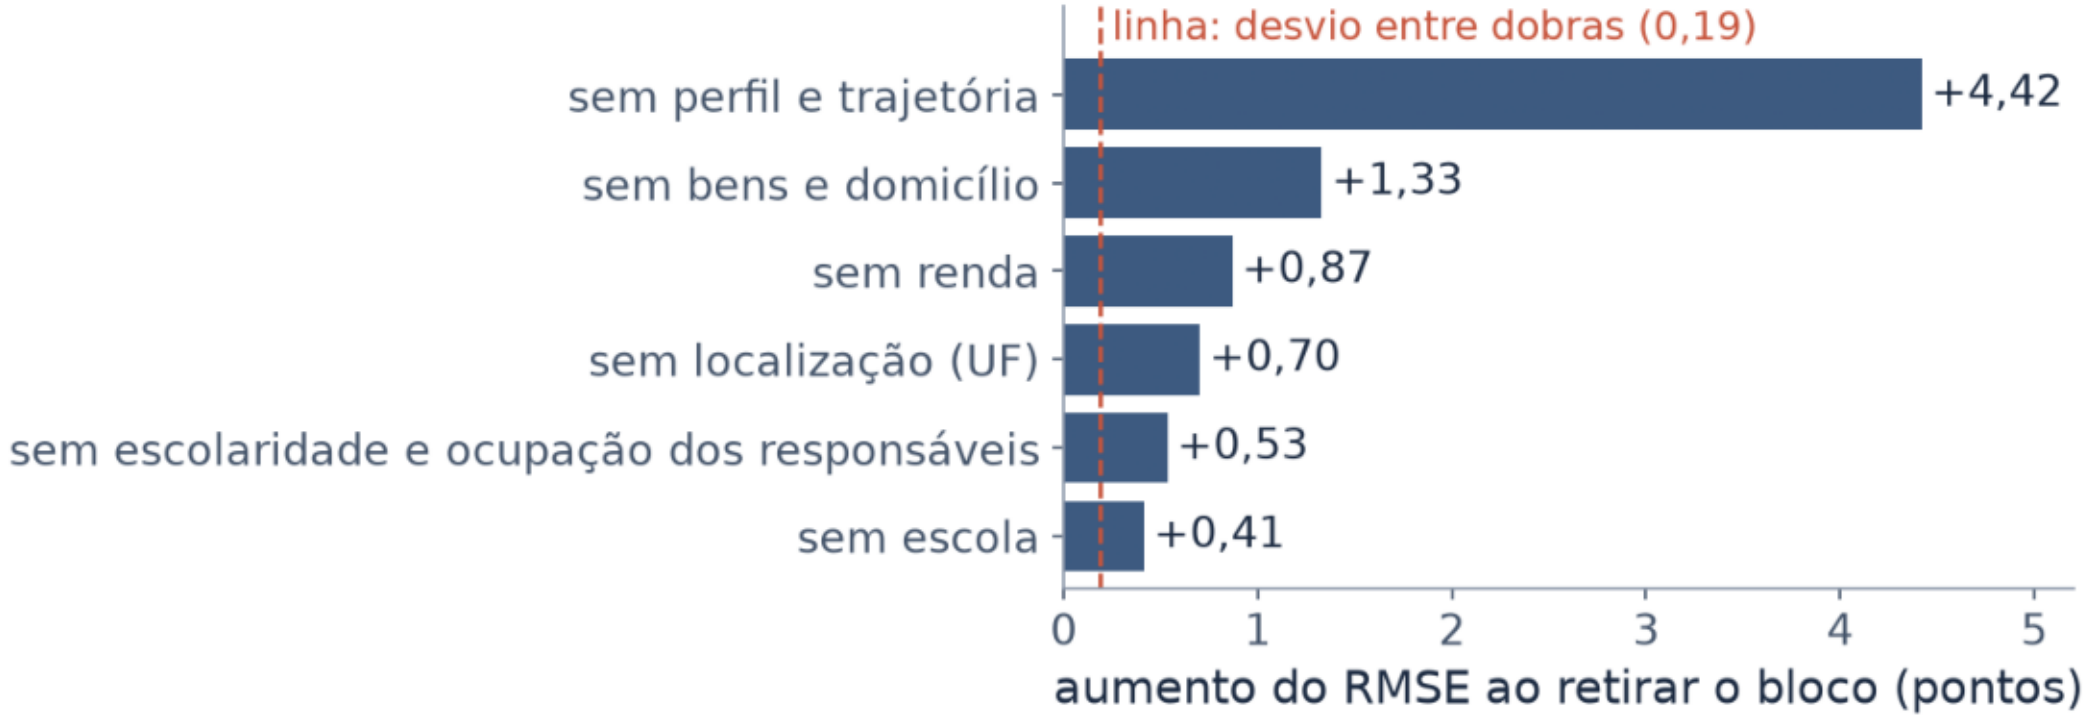
Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento (mesmas 3 dobras). Baseline pela média: 131,63.

Sem efeito ou piora: features criadas (+0,01), seleção de colunas (+1,0 a +4,6), pesos por faixa (+2,1), PCA, retirar os zeros, K-means.

HIPÓTESES

Quanto vale cada bloco de informação

Retiramos um bloco por vez da representação final: perfil e trajetória é o que mais faz falta.

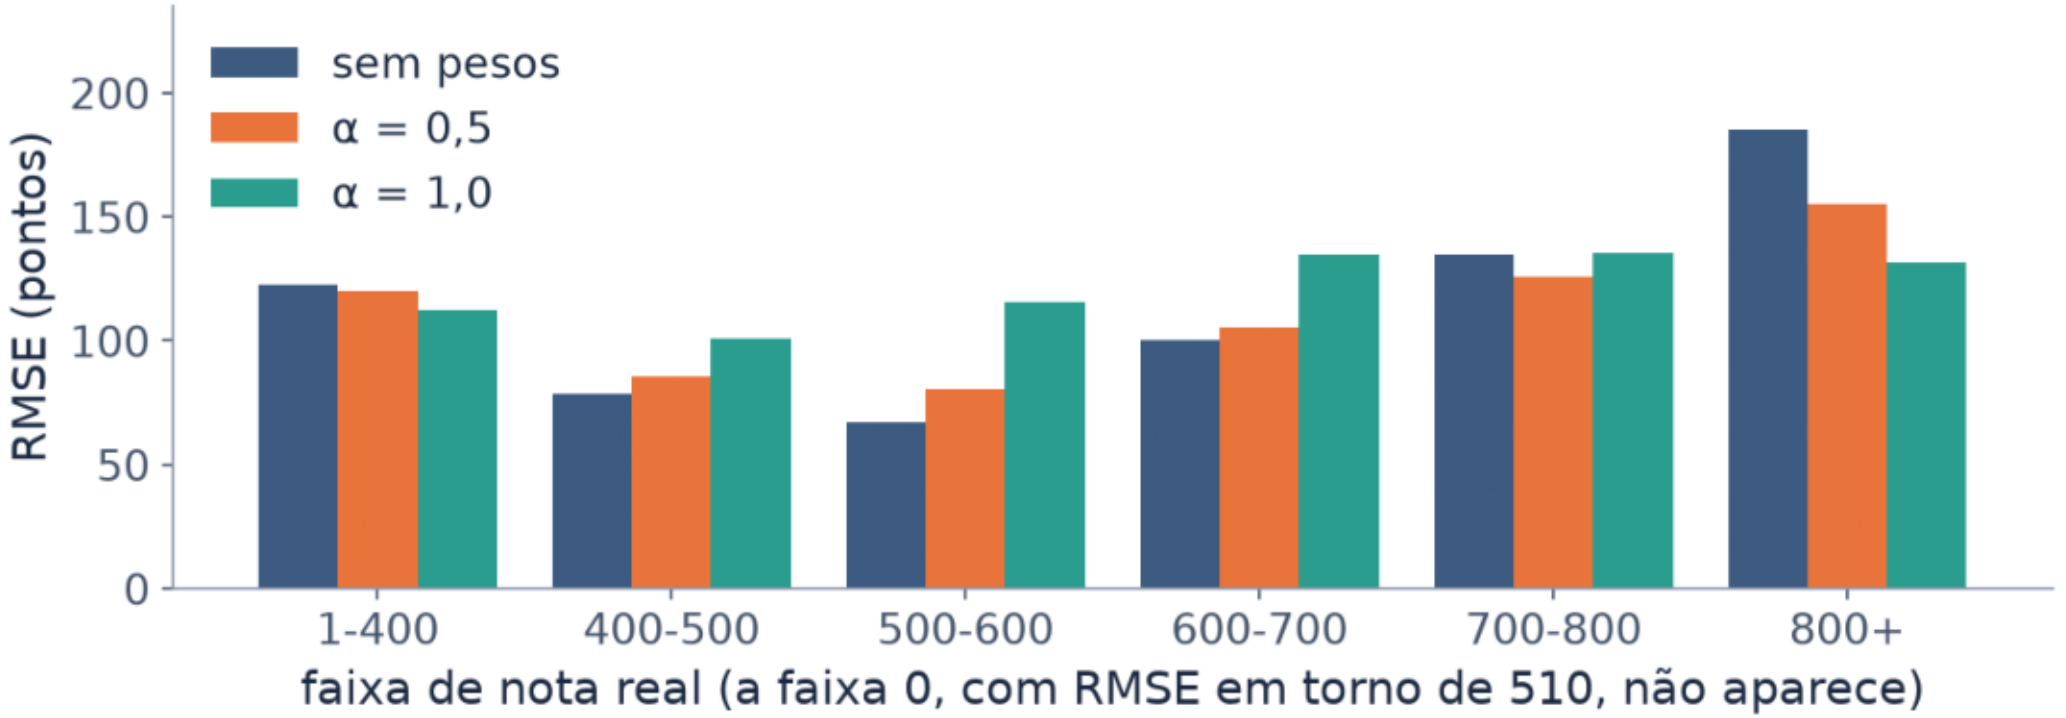


Fonte: Inep, ENEM 2023; Gradient Boosting, validação cruzada; um bloco retirado por vez.

HIPÓTESES

Balanceamento por pesos nas faixas de nota

Acima de 800 o erro cai de 185 para 155, mas o erro geral sobe 2,1 pontos: troca as pontas pelo meio. Não adotado.



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento; pesos n^(−α) por faixa de 50 pontos, calculados só no treino.

SOLUÇÃO FINAL

A solução final

Gradient Boosting com os hiperparâmetros da busca, sobre 74 colunas, sem seleção, PCA nem pesos.



105,86

RMSE na validação cruzada (± 0,17)

105,81

RMSE no teste, aberto uma única vez

0,354

R^2 no teste: o perfil explica cerca de um terço

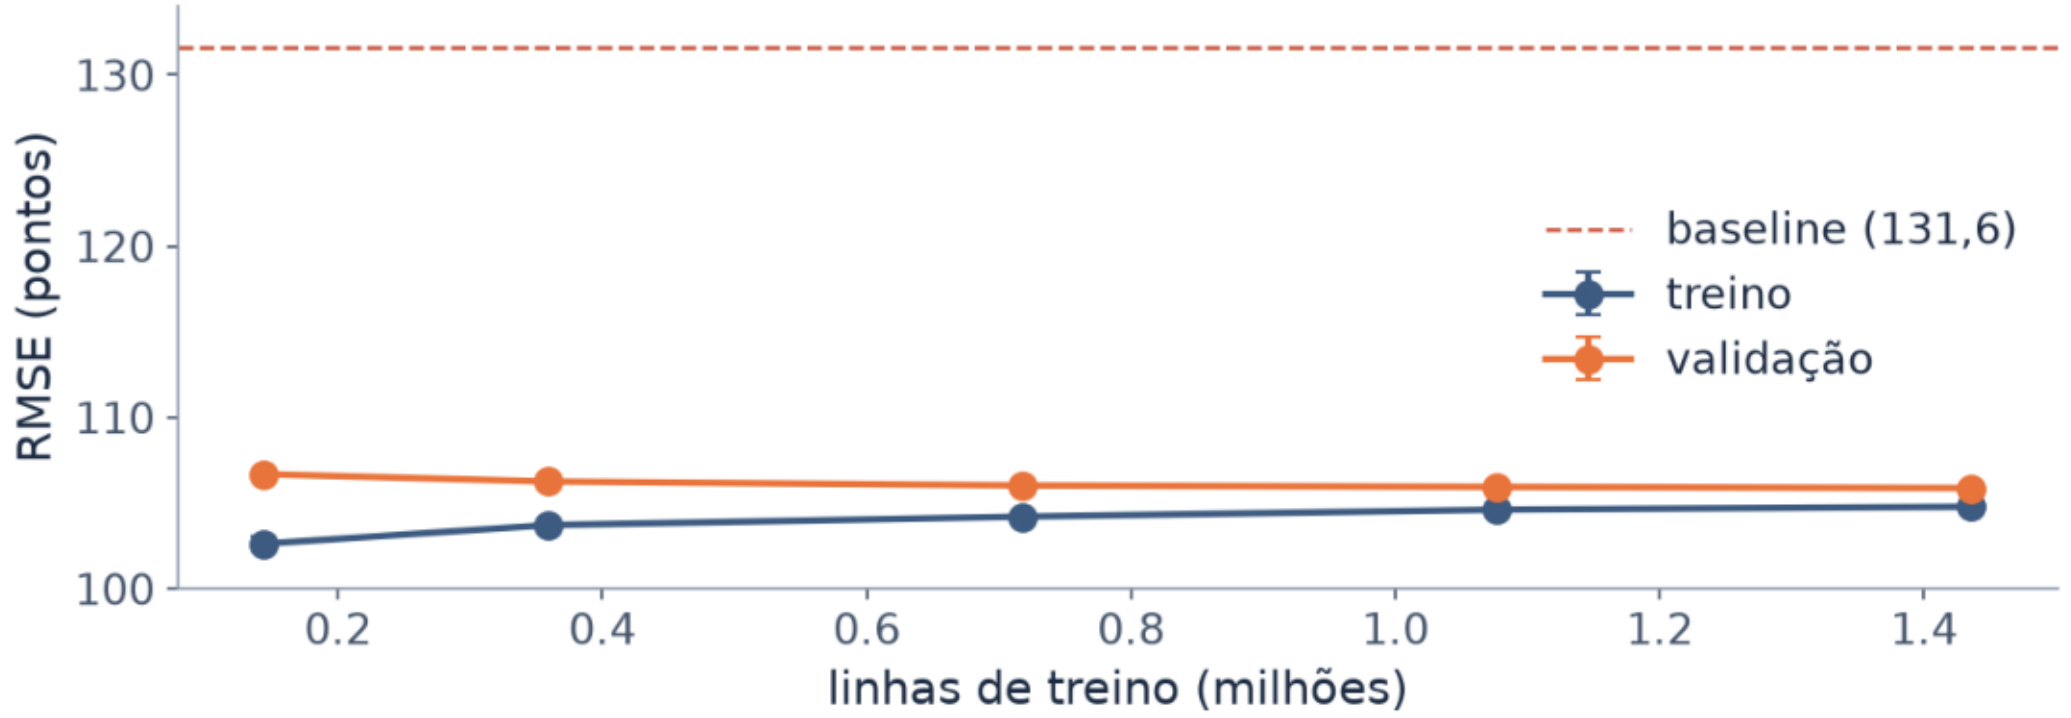
−19,7%

de erro contra o baseline pela média (131,70)

SOLUÇÃO FINAL

Curva de aprendizado

Treino e validação ficam a 1,1 ponto; de 75% para 100% do treino a validação melhora só 0,07. Falta informação, não dados.

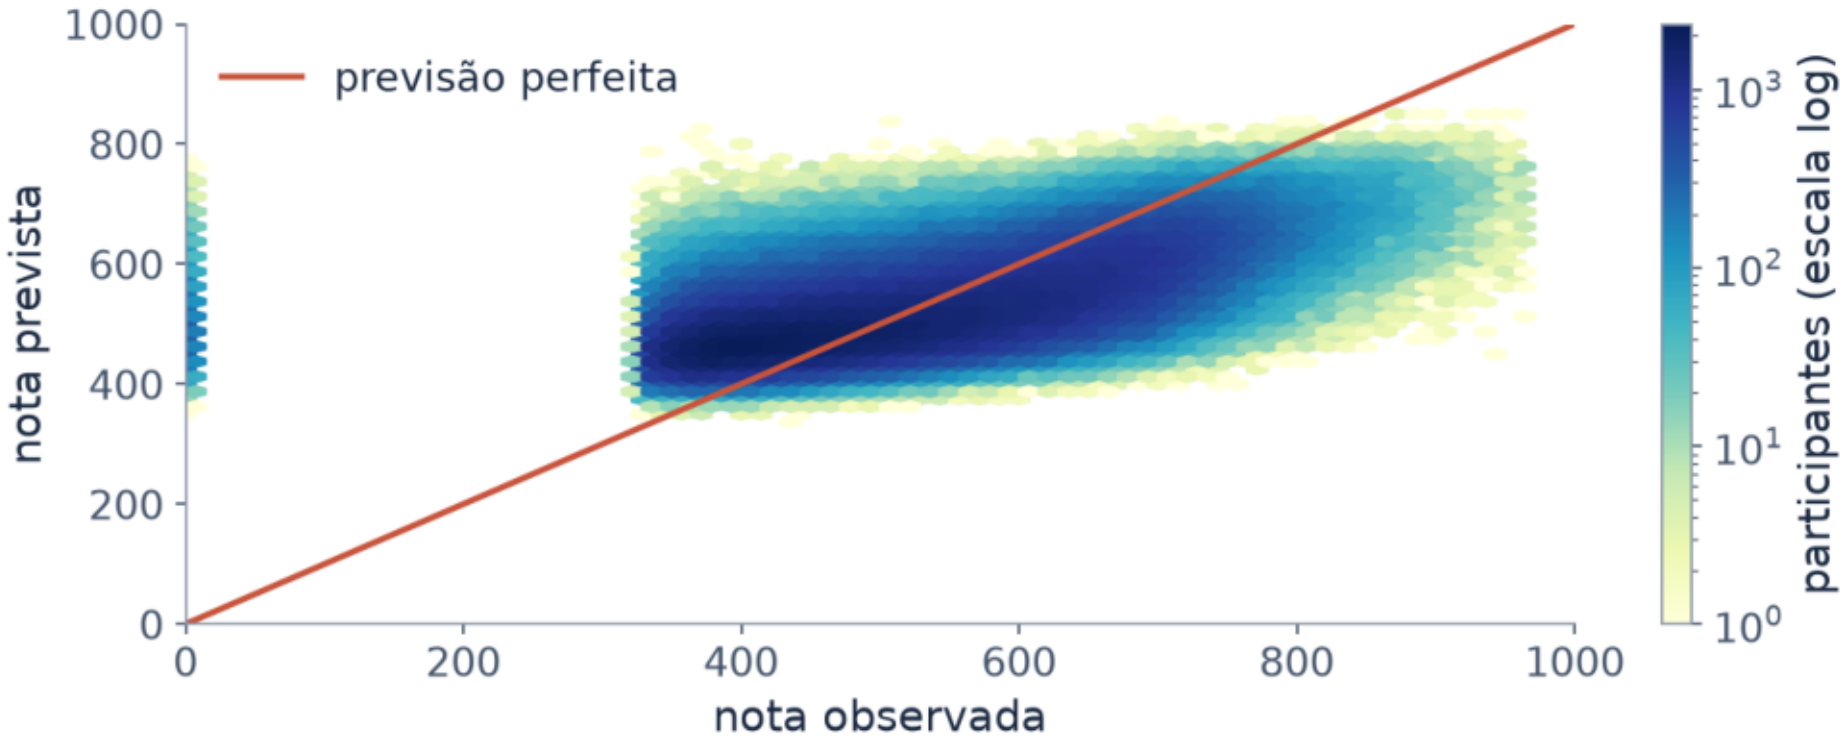


Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento; média e desvio das 3 dobras.

TESTE

Teste: nota observada contra prevista

Regressão à média: as previsões ficam entre 350 e 850. Os zeros viram uma faixa de resíduos de −370 a −770.

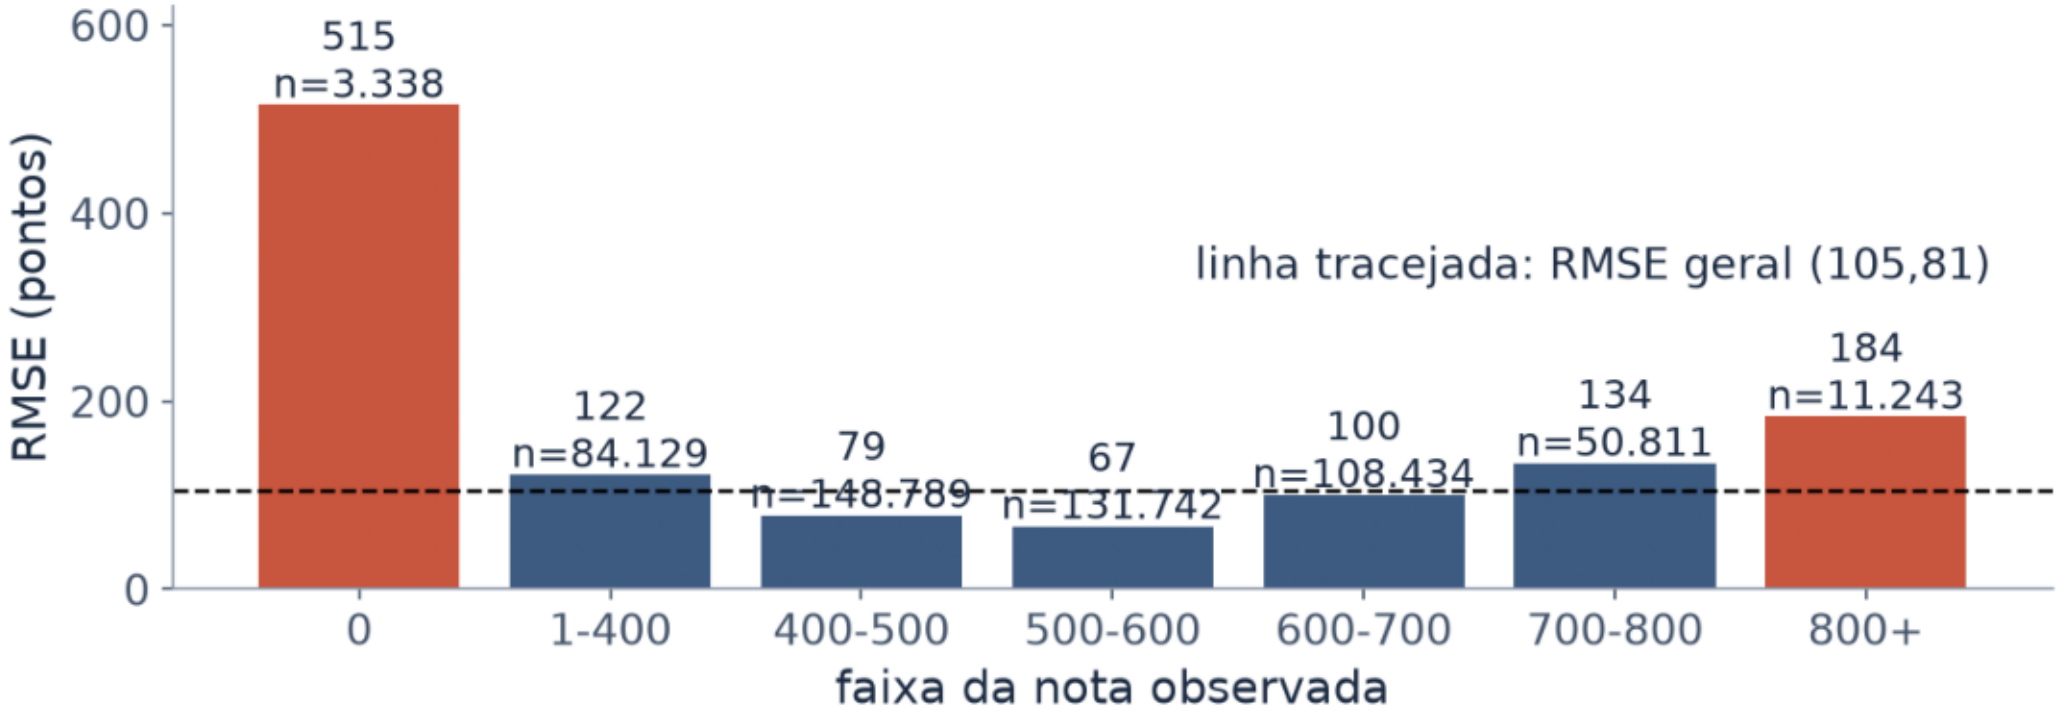


Fonte: Inep, ENEM 2023; teste; dispersão agregada em células hexagonais.

TESTE

Onde o modelo erra mais

O erro é mínimo perto da média (67 na faixa 500–600) e cresce nas pontas: 515 nos zeros e 184 acima de 800.

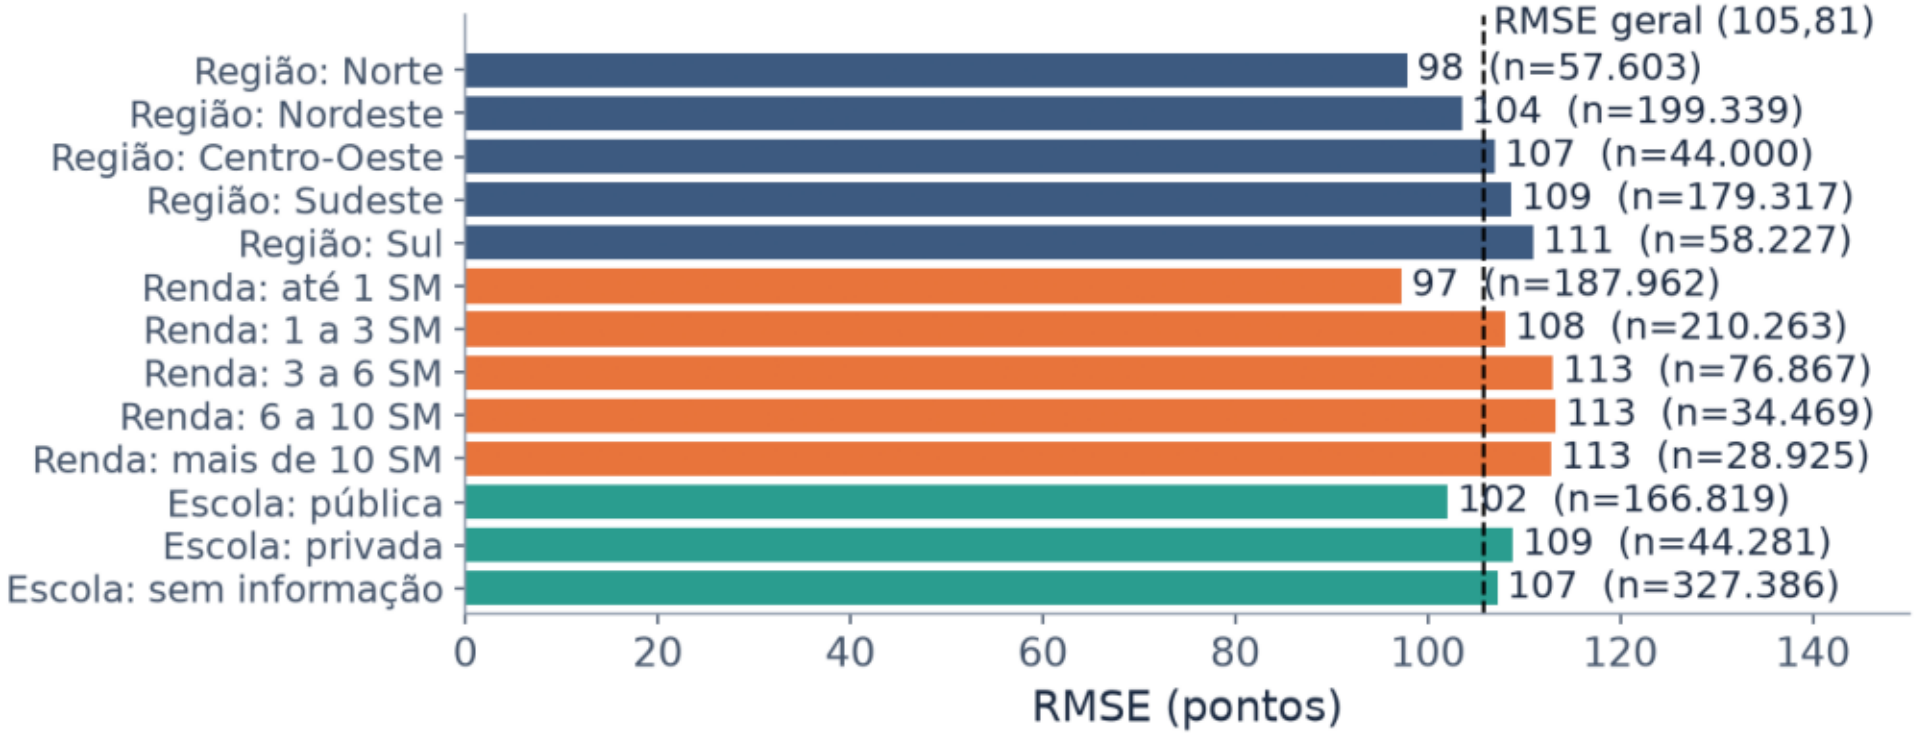


Fonte: Inep, ENEM 2023; teste (538.486 participantes); faixas definidas no desenvolvimento.

TESTE

Erros por região, renda e escola

O viés médio fica abaixo de 1 ponto nesses grupos e o RMSE varia de 97 a 113: o modelo não erra muito mais para um grupo.



Fonte: Inep, ENEM 2023; teste (538.486 participantes); n = participantes do grupo.

VERIFICAÇÕES

Replicação independente (dataset 5)

Outra IA recebeu só o enunciado e o CSV, sem nada do nosso trabalho, e treinou no mesmo teste.

O que ela fez

45 colunas, one-hot em todas as categóricas, modelos leves com configuração fixa e sem validação cruzada. Depois reproduzimos a preparação dela nas nossas dobras para comparar em pé de igualdade.

105,81
a nossa solução, no teste

107,53
o melhor dela (Ridge com one-hot), no teste

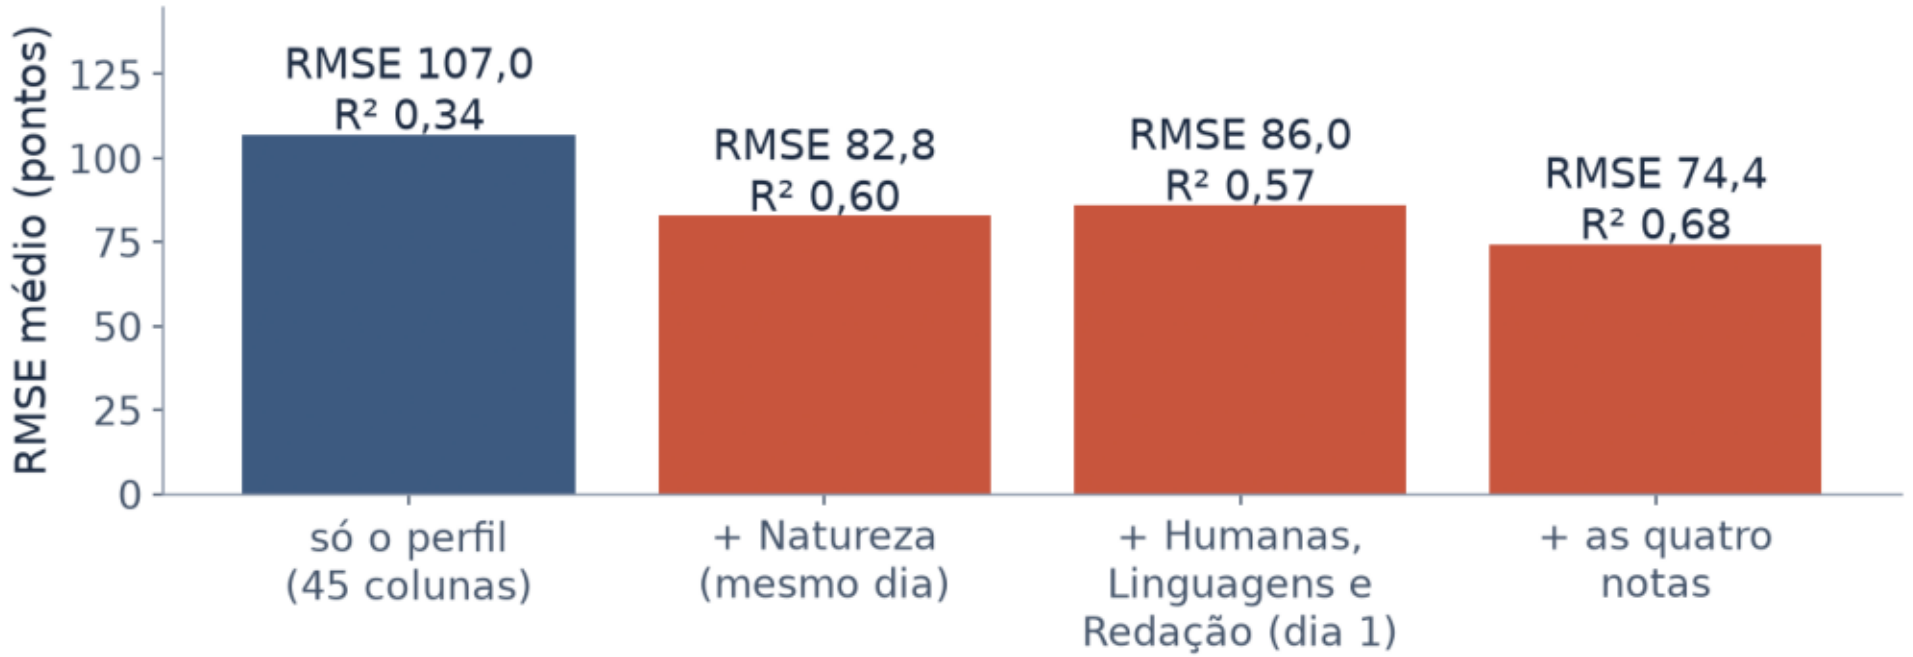
107,51
a preparação dela nas nossas 3 dobras

Mesmo patamar por outro caminho: o resultado não depende de uma escolha de preparação específica. O ganho dela, nos modelos lineares, vem do one-hot.

VERIFICAÇÕES

Diagnóstico com as notas de outras áreas

Proibidas como entrada, usadas só para medir o vazamento: com elas o R² vai de 0,34 para 0,68. O limite vem da informação.



Fonte: Inep, ENEM 2023; dataset 6, só validação cruzada no desenvolvimento; fora da solução.

Dataset 6: só validação cruzada no desenvolvimento; o teste não foi aberto e nada disto entra na solução.

VERIFICAÇÕES

Extensões depois do teste

Testadas só por validação cruzada: como o teste já tinha sido aberto, nenhuma muda a solução final.

One-hot nos modelos lineares

−0,98

108,87 → 107,89; ainda 2 pontos atrás do boosting

Município com target encoding

−0,30

106,03 → 105,73 nas 3 dobras; não adotado

Quatro sementes do modelo final

0,009

de 105,862 a 105,871: a semente não pesa

Busca nas 74 colunas finais

0,005

105,859 contra 105,864: a busca já estava no limite

Dataset 5 nas nossas dobras

107,51

igual ao teste da outra IA (107,53)

V de Cramér entre categóricas

0,707

só situação × tipo de escola passa de 0,7

PERGUNTAS

As perguntas que fizemos e o que respondemos

As 8 primeiras vêm do enunciado. Verde ajudou, laranja ajudou pouco, cinza não, vazio não testado.

●	**1 Quais blocos de informação contribuem mais?**	Perfil e trajetória (+4,4), bens (+1,3) e renda (+0,9)
●	**2 O tratamento das categorias faz diferença?**	Situação separada −0,33; não sei −0,2; one-hot linear −0,98
●	**3 As interações ajudam?**	Não: as 3 features criadas mudam o erro em +0,01
●	**4 A localização acrescenta informação?**	UF −0,70 (ajudou); município −0,30 (depois do teste)
○	**5 Dados externos melhoram o contexto?**	Não testado
●	**6 Existem perfis semelhantes?**	K-means como feature: sem diferença (107,79 contra 107,77)
●	**7 Dá para reduzir o erro nas pontas?**	Pesos: acima de 800, 185 para 155, mas +2,1 no geral
●	**8 Uma solução mais simples mantém o erro?**	Não: seleção +1,0 a +4,6; PCA piora; linear perde 3,0
●	**9 Alguém sem contexto faria melhor?**	Não: 107,5 contra 105,8 (dataset 5)
●	**10 O limite é a informação ou o modelo?**	A informação: R^2 de 0,34 a 0,68 com outras notas

CONCLUSÃO

O que aprendemos

O perfil estima a tendência de um grupo, não a nota de uma pessoa.

O limite é a informação

Erro de 105,8 pontos e R^2 de 0,354 no teste. Modelos muito diferentes param no mesmo patamar, e mais dados quase não ajudam.

O que ajudou

Modelo de árvores (−3,4), UF da prova (−0,7), situação escolar separada (−0,3), informação de escola (−0,4).

O que não ajudou

PCA, seleção de colunas, features criadas, tirar os zeros, K-means; os pesos trocam o erro das pontas pelo do meio.

Limites: mesma edição (não vale para escolas ou municípios inéditos); UF e escola não são residência; associação não é causa. Próximo passo: o município com codificação supervisionada (ganho de 0,3 na validação cruzada).