Previsão da nota de Matemática do ENEM 2023 pelo perfil dos participantes

Quanto o perfil explica a nota, e o que mudou o erro dos modelos

João Igor Vidal de Andrade · Raquel Albuquerque Quirino · Amanda Lira · Sofya Oliveira

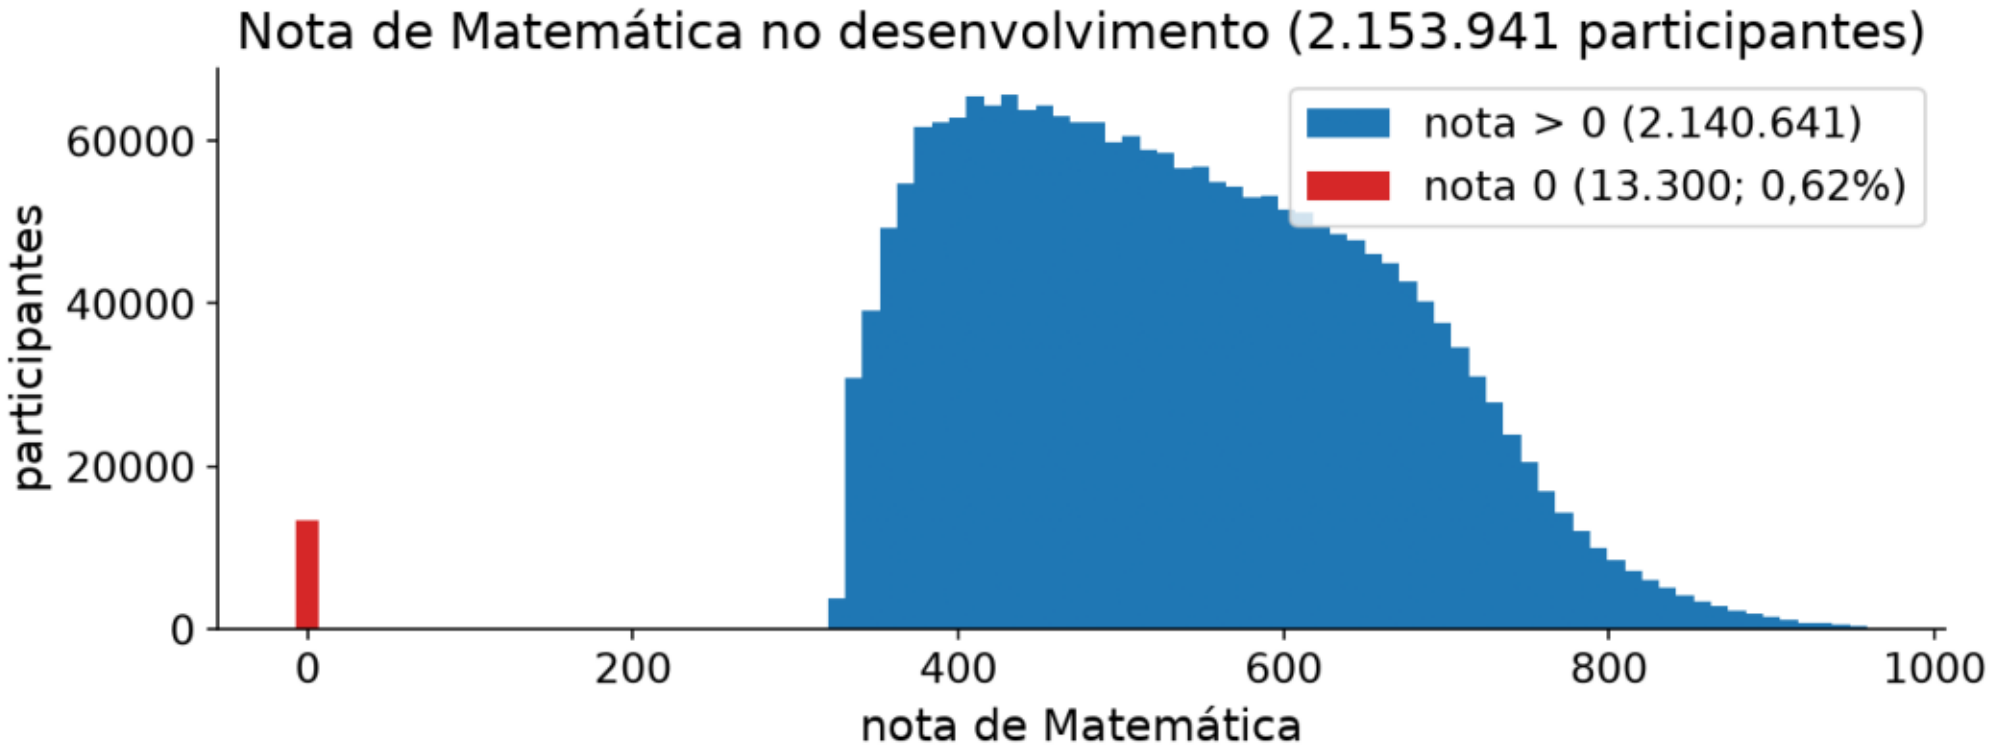
Ciência de Dados, Projeto 2 (Unidade II: Aprendizado de Máquina) · Unifor

github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

O problema e a base

- Pergunta: quanto o perfil socioeconômico, escolar e demográfico estima a nota de Matemática (NU_NOTA_MT, de 0 a 1000)?
- Base nacional completa do Inep: 3.933.955 participantes; 2.692.427 com nota observada (usados).
- 80% para desenvolvimento (2.153.941) e 20% para teste (538.486), semente 42. O teste só foi aberto no fim.
- Nota ausente não vira zero; nota zero (0,62%) é resultado observado e fica nos dados.
- Objetivo: comparar escolhas de preparação e de modelagem e explicar os limites, não maximizar o R^2.

A nota: distribuição e as notas zero



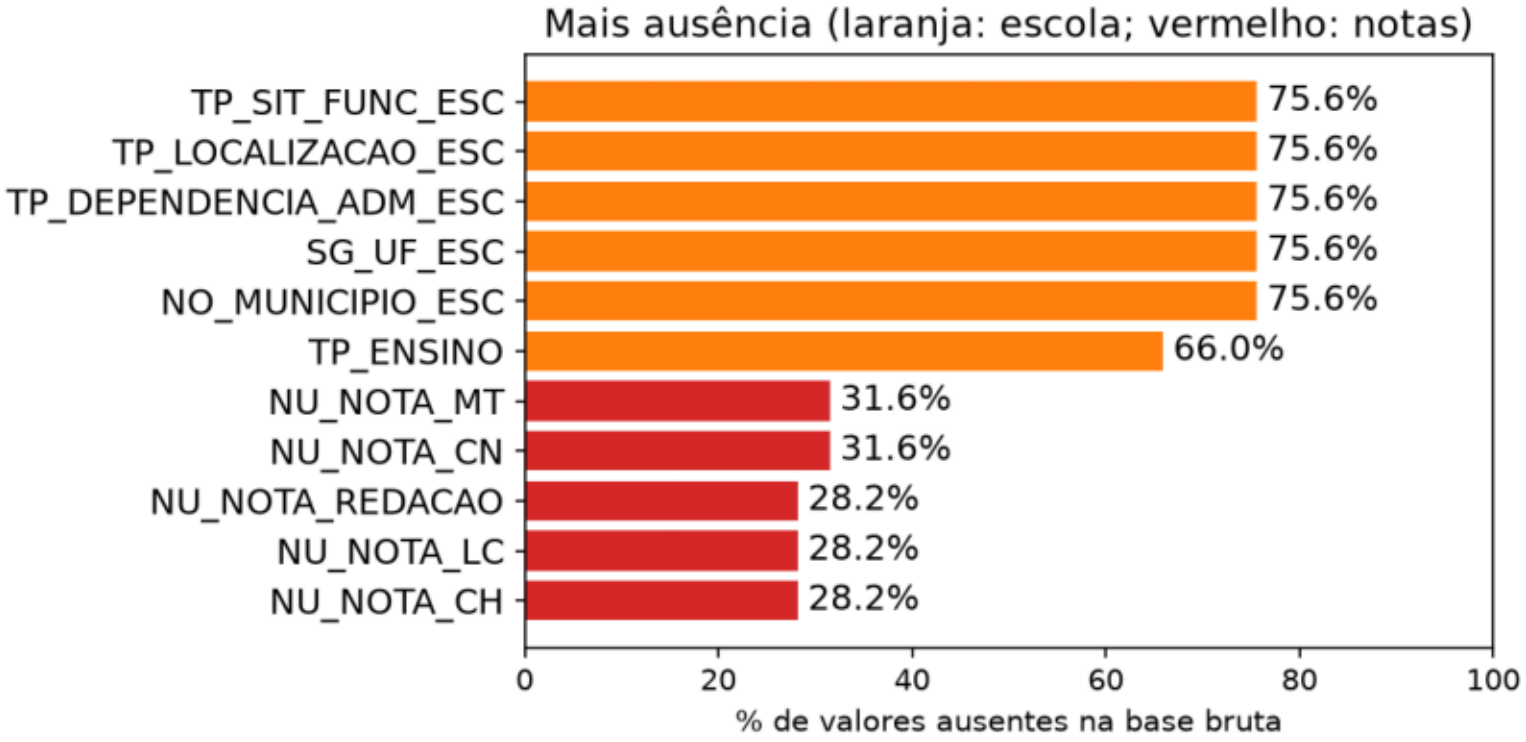
Fonte: Inep, ENEM 2023.

Zeros: resultado observado e válido (0,62%); ficam no treino e na validação.

Protocolo de avaliação e vazamento

- Validação cruzada de 3 dobras só no desenvolvimento, sempre as mesmas dobras (KFold, semente 42).
- Tudo que se aprende dos dados fica dentro de um Pipeline e é refeito só no treino de cada dobra.
- Métrica principal: RMSE (MAE e R^2 complementares), com média e desvio entre as dobras.
- Fora das entradas: notas de outras provas, presença, respostas, gabarito, código da prova.
- Vazamento encontrado e corrigido: a fusão da situação escolar usava média e desvio de todas as linhas. Agora é refeita no treino de cada dobra (efeito medido: 0,003 ponto).

Preparação: o que está faltando e o que significa

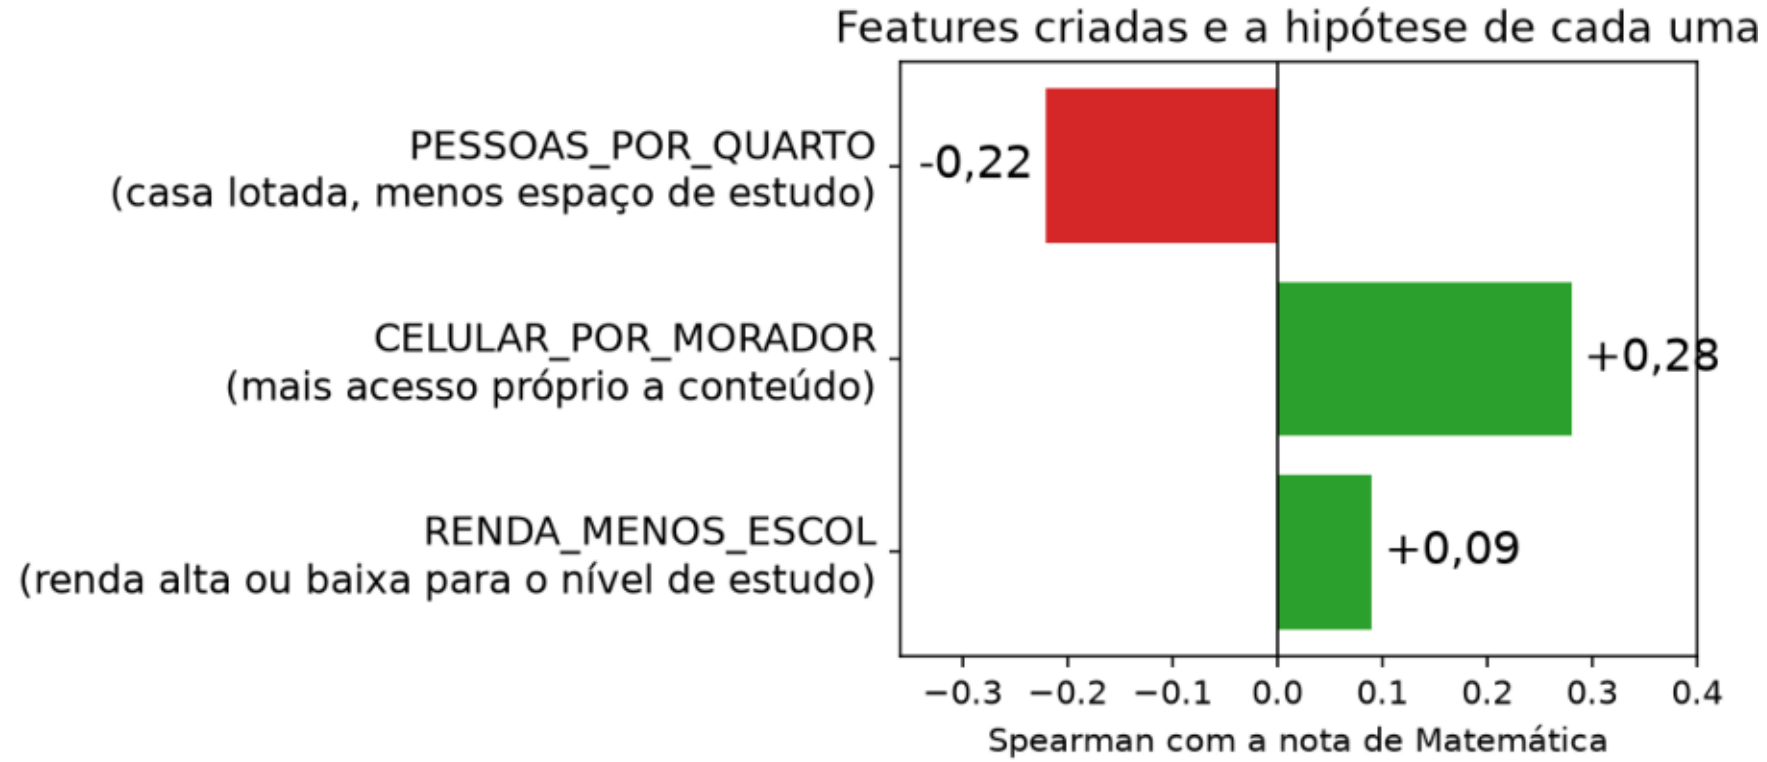


Fonte: Inep, ENEM 2023. 3.933.955 registros.

Valores ausentes na base bruta (3.933.955 registros).

- Escola: 73% de vazio entre quem tem nota. É quem já concluiu o ensino médio: vira "sem informação", não mediana.
- "Não sei" em Q001 a Q004 não é nível de escolaridade: vira ausente + indicador (quem não sabe tira 40 a 50 pontos a menos).
- Questionário em letras vira número pelo dicionário do Inep; sexo em 0/1.

Features criadas, com hipótese



Fonte: Inep, ENEM 2023. Desenvolvimento; todas com |Spearman| < 0,7 entre si e com as colunas originais.

Spearman de cada feature criada com a nota de Matemática (desenvolvimento).

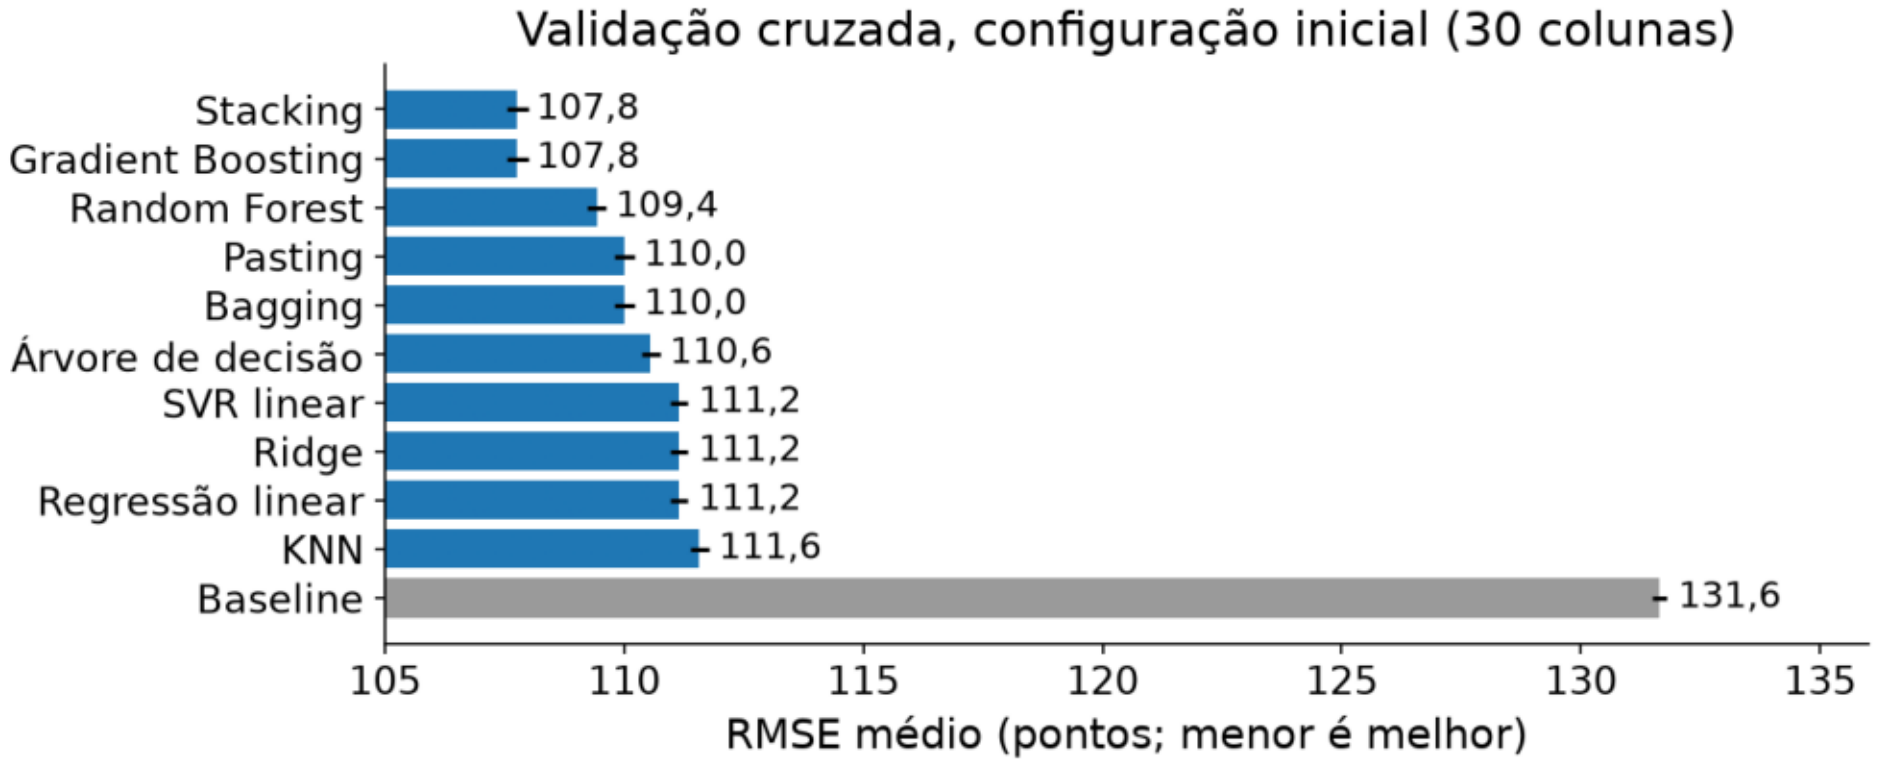
Cada feature tem uma hipótese e nenhuma repete as originais (|Spearman| < 0,7).

21 conjuntos de entrada avaliados

Grupo	Quantos	O que varia
Datasets salvos	8	Fusão da situação; escola; NAO_SEI e nacionalidade; 3 features criadas (30 a 45 colunas)
Variações no notebook 04	13	Fusão sem vazamento ou 4 colunas separadas; UF; sem features criadas; 3 cortes de seleção; 6 blocos retirados
Total com validação cruzada	21	Gradient Boosting em todos; regressão linear e bagging nos 8 datasets
Diagnósticos à parte	4	UF e idade desdobrada (não entram nos notebooks)

Melhor dataset salvo: dataset_3_escola_features (45 colunas): RMSE 107,05, 0,7 ponto melhor que o dataset 1. Mais colunas ajudam pouco.

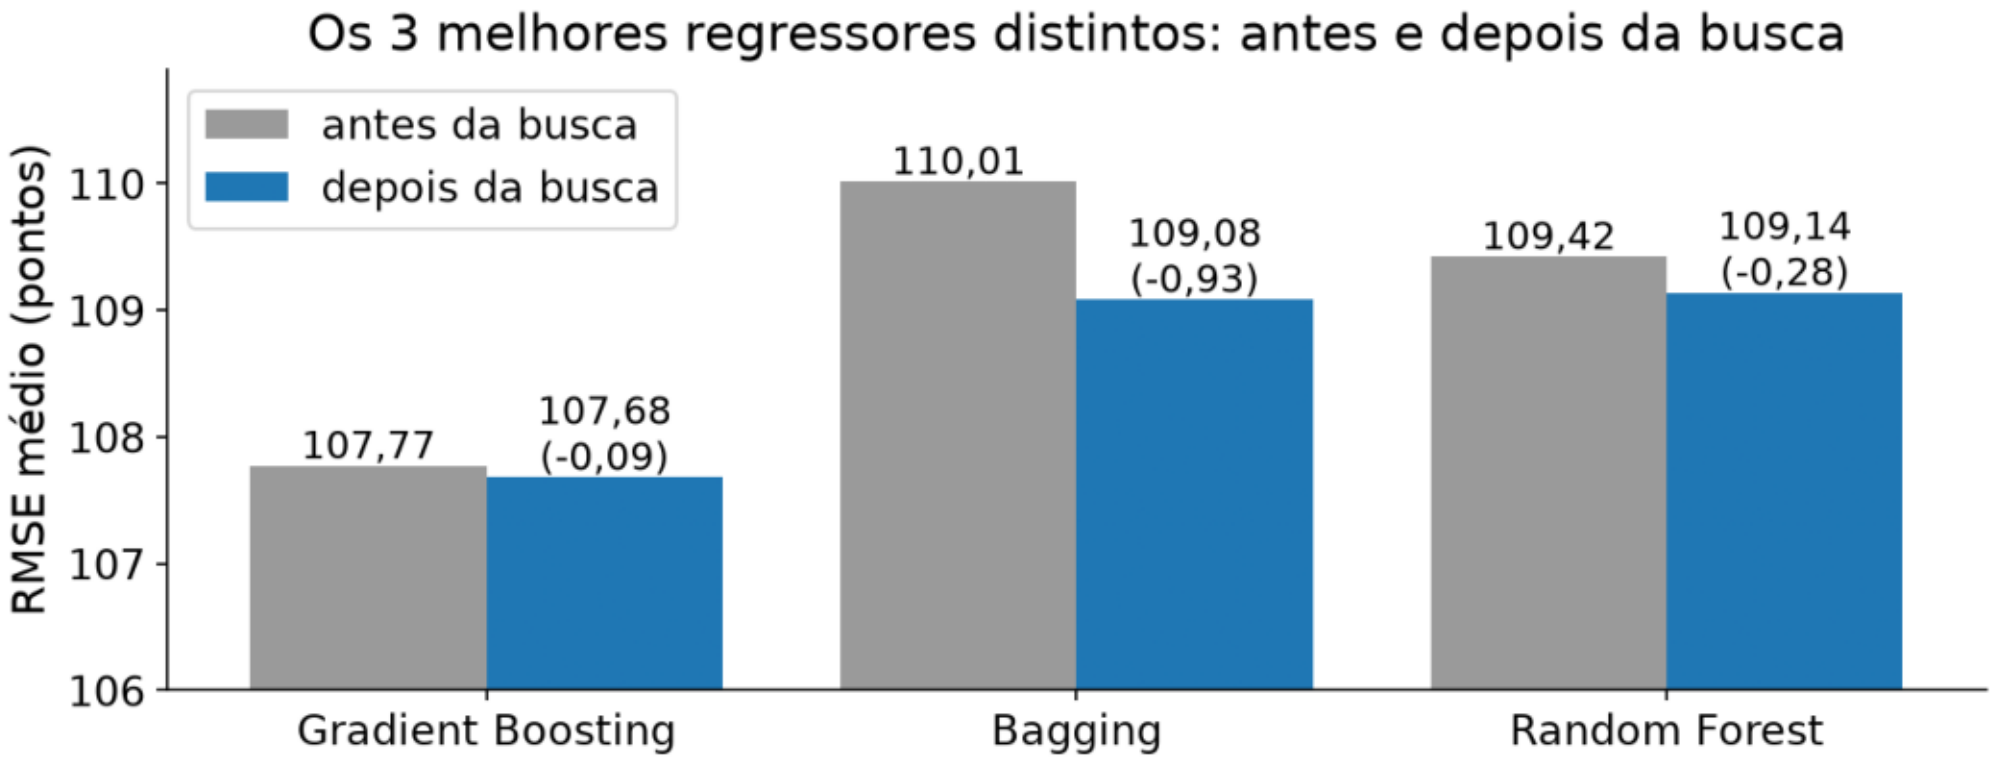
Modelos em configuração inicial



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento (dataset_1_fundido). Barra de erro: desvio entre dobras.

Gradient Boosting é o melhor; stacking empata e custa 5 vezes mais.

Busca de hiperparâmetros



Fonte: Inep, ENEM 2023; RandomizedSearchCV, 10 configurações, validação cruzada no desenvolvimento.

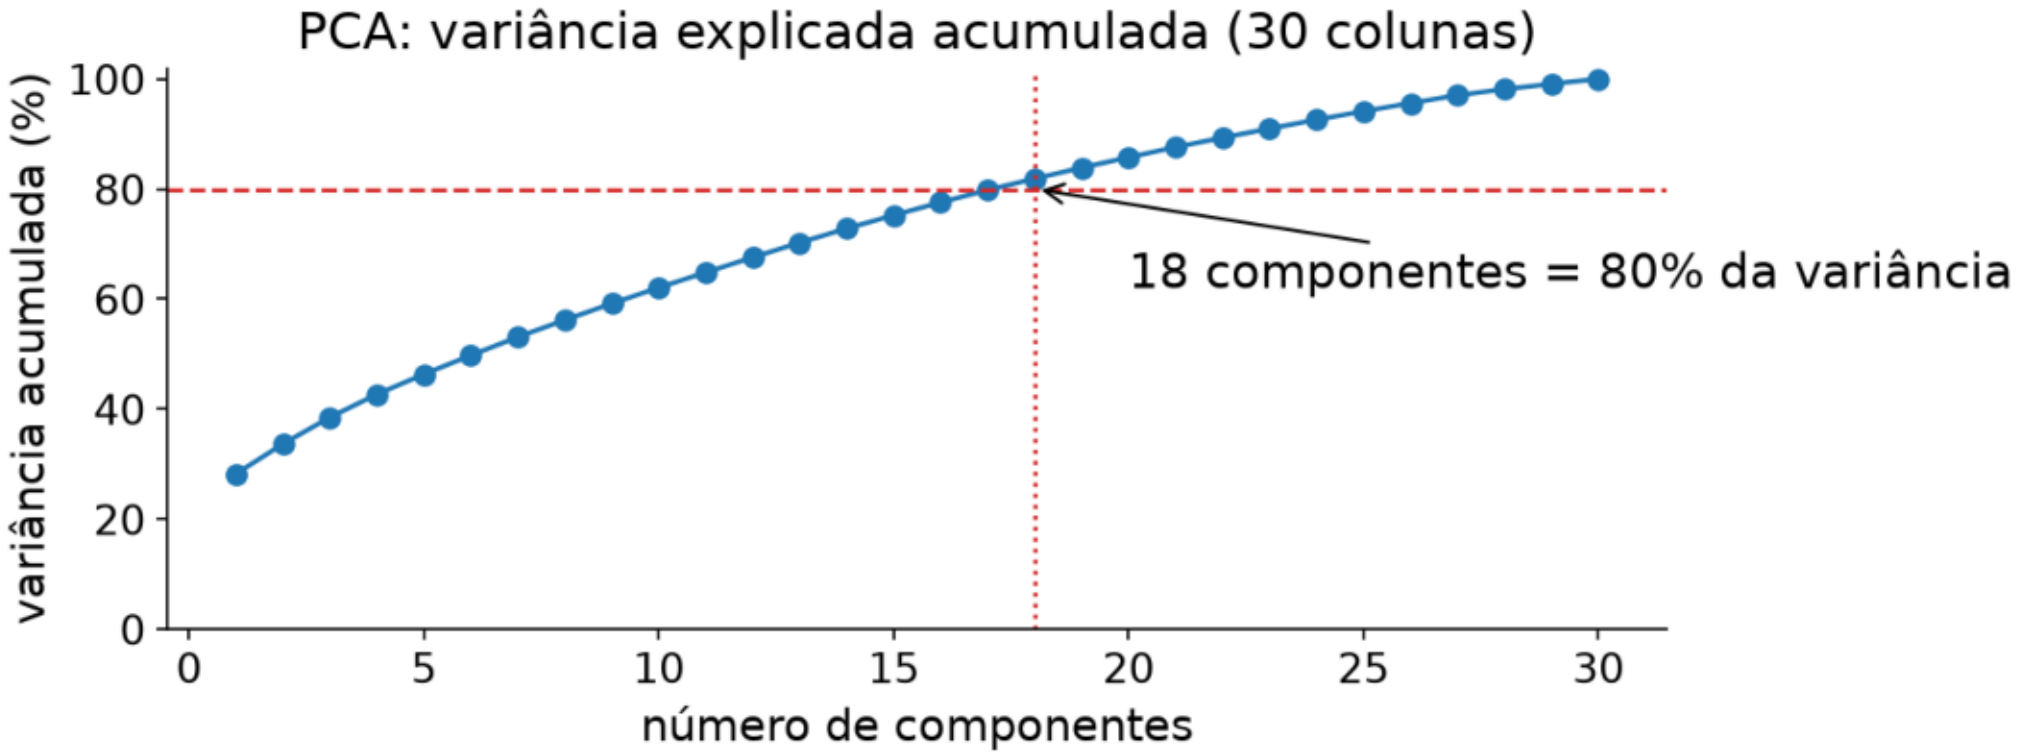
A busca só ajudou o bagging (−0,93); no boosting, −0,09, dentro do desvio.

Resultados da configuração inicial

Modelo	RMSE (± desvio)	R^2	Tempo/dobra (s)
Gradient Boosting	**107,77 ± 0,23**	**0,330**	**133**
Stacking	107,76 ± 0,23	0,330	630
Random Forest	109,42 ± 0,20	0,309	103
Bagging / Pasting	110,01 ± 0,21	0,302	24 / 20
Árvore de decisão	110,55 ± 0,19	0,295	3
Regressão linear = Ridge = SVR linear	111,15 ± 0,18	0,287	0,3 a 2
KNN	111,58 ± 0,18	0,282	476
Baseline (média)	131,63 ± 0,16	0,000	0,06

Busca (RandomizedSearchCV, 10 configurações): bagging −0,93, Random Forest −0,28, Gradient Boosting −0,09 (dentro do desvio). Stacking empata e custa 5 vezes mais.

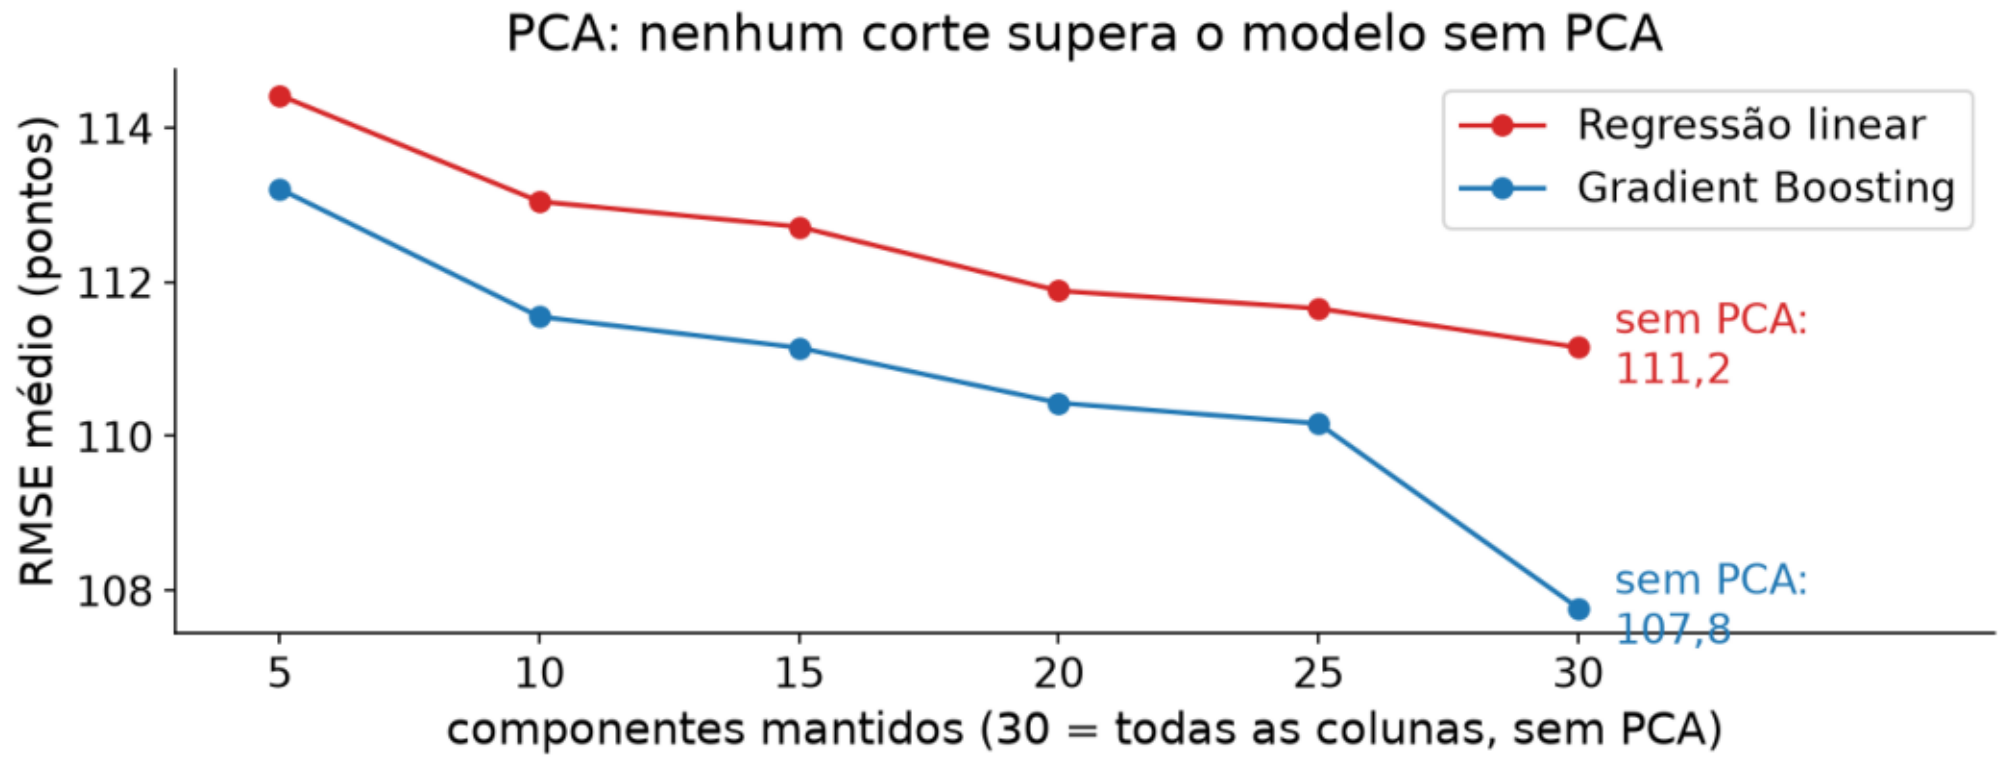
PCA: os dados quase não se comprimem



Fonte: Inep, ENEM 2023; desenvolvimento, colunas padronizadas.

18 de 30 componentes só para chegar a 80% da variância.

PCA: não ajudou



Fonte: Inep, ENEM 2023; PCA dentro do Pipeline, validação cruzada no desenvolvimento.

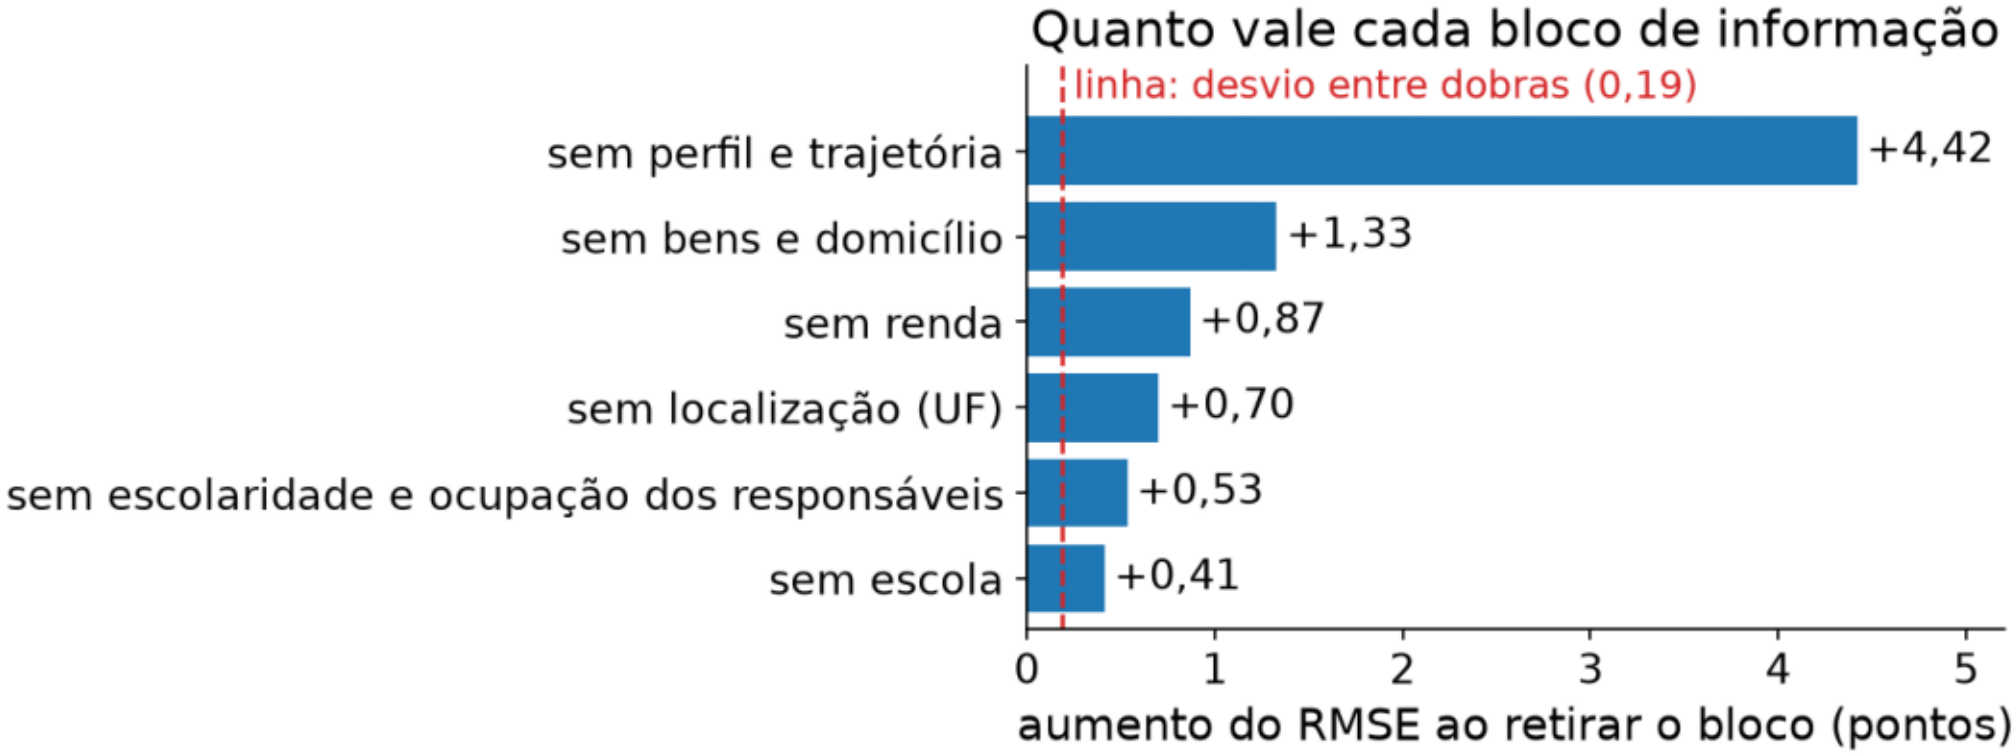
Com PCA o erro piora em todos os cortes (107,8 para 110,2 no boosting).

Hipóteses de preparação (Gradient Boosting, validação cruzada)

Experimento	RMSE (± desvio)	Δ RMSE	Leitura
Fusão da situação escolar (só treino)	107,05 ± 0,19		referência
4 colunas de situação separadas	**106,73 ± 0,19**	**−0,33**	**melhora**
+ UF da prova (26 colunas)	**106,03 ± 0,19**	**−0,70**	**melhora**
Sem as 3 features criadas	106,04 ± 0,17	+0,01	sem diferença
SelectKBest, k = 51	107,07 ± 0,20	+1,04	piora
SelectKBest, k = 22	110,61 ± 0,19	+4,58	piora

Diferença só vale se passar do desvio entre dobras. Também sem efeito: tirar as notas zero do treino e K-means como feature.

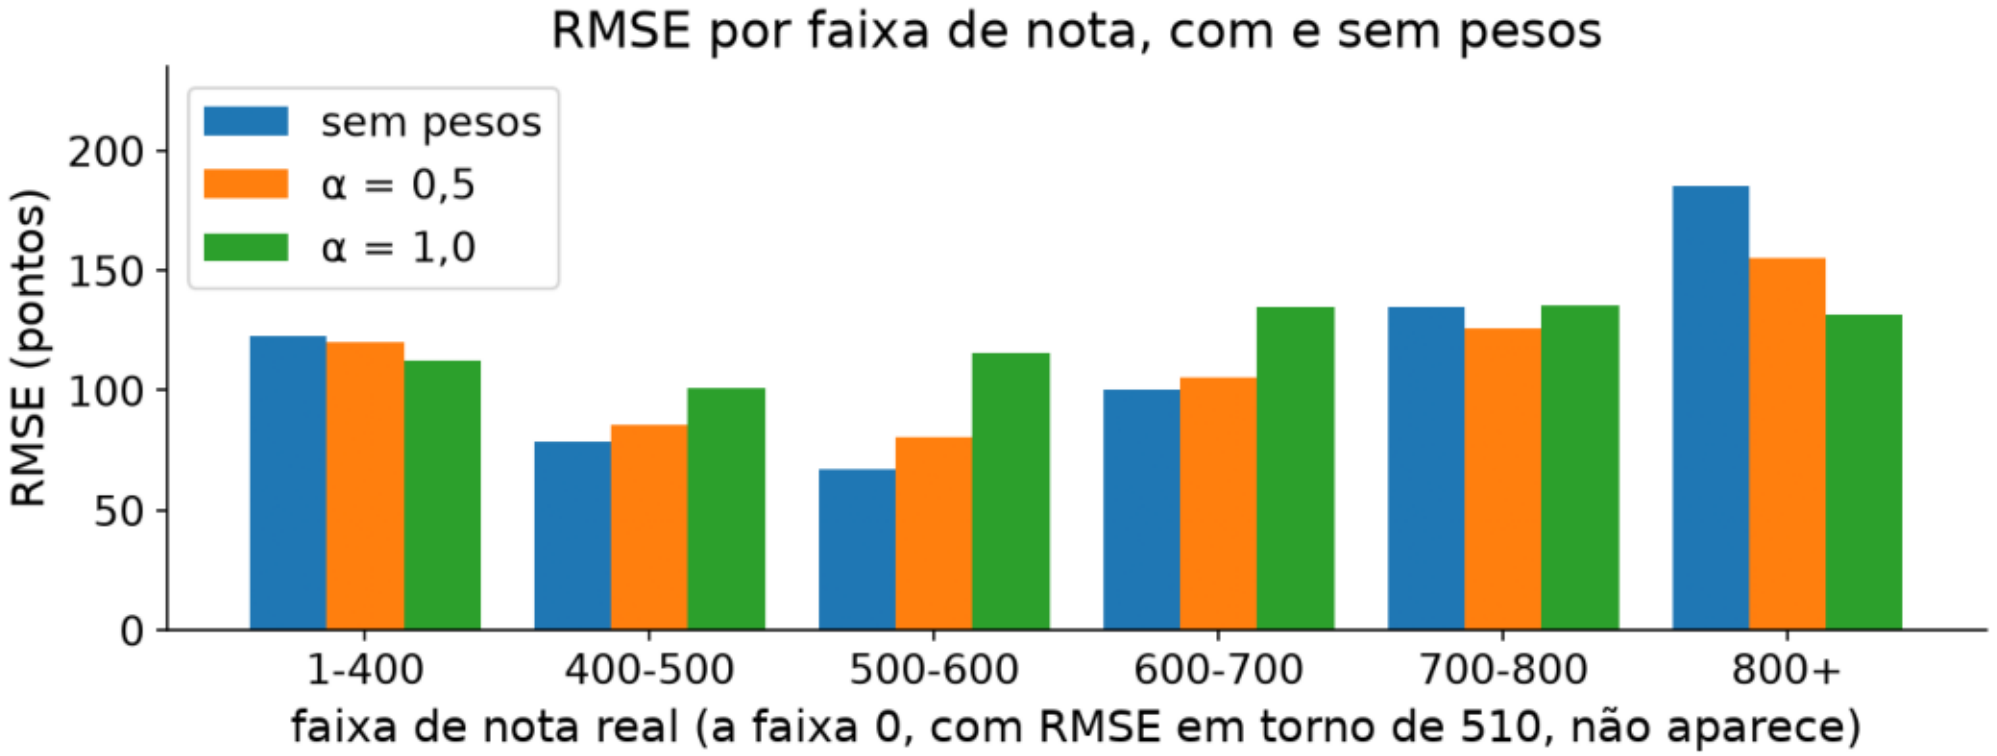
Quanto vale cada bloco de informação



Fonte: Inep, ENEM 2023; Gradient Boosting, validação cruzada; um bloco retirado por vez.

O bloco que mais pesa: perfil e trajetória (sexo, idade, situação, cor/raça, língua).

Balanceamento por ponderação de faixas



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento; pesos n^(−α) por faixa de 50 pontos, calculados só no treino.

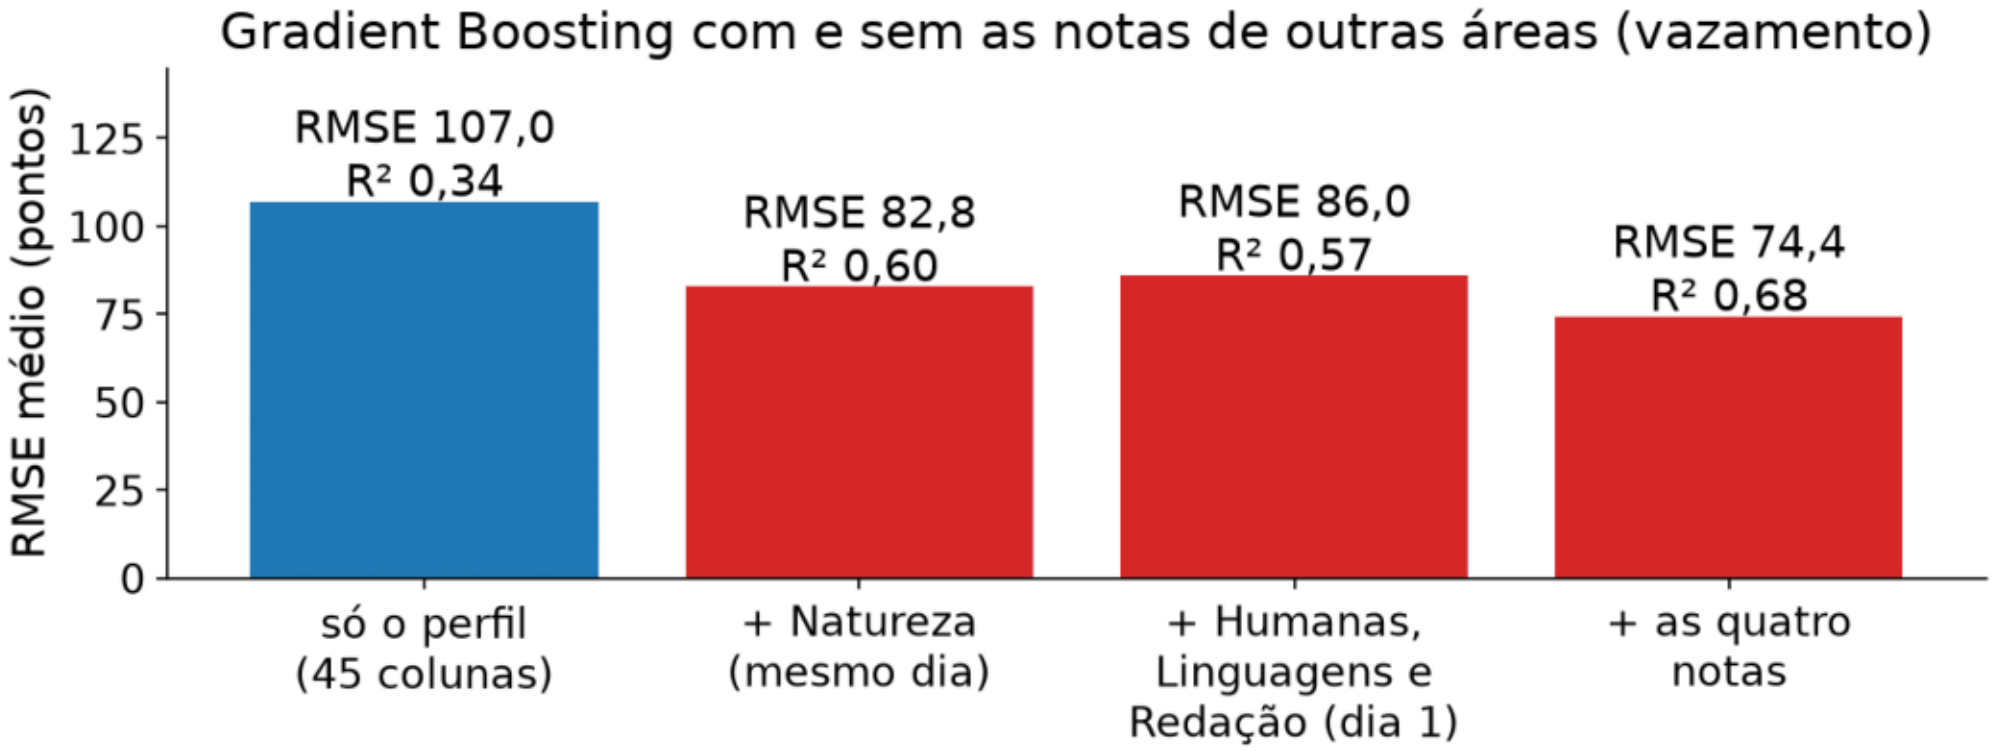
Acima de 800 o RMSE cai de 185 a 155, mas o geral piora (+2,1): não adotado.

Replicação independente: solução de outra IA (dataset 5)

Modelo	RMSE no teste	MAE	R²
Nossa solução final (Gradient Boosting)	**105,81**	**82,00**	**0,354**
Ridge com one-hot de tudo (outra IA)	107,53	83,63	0,333
SVR linear (outra IA)	107,89	83,30	0,329
Gradient Boosting leve, 50 árvores (outra IA)	108,07	84,46	0,327
Random Forest, 30 árvores (outra IA)	108,13	84,32	0,326
Nossa regressão linear sem regularização	108,86	84,89	0,317

Mesmo teste (ids idênticos), sem validação cruzada do lado dela. O ganho dela está nos modelos lineares: one-hot + regularização, 1,3 ponto melhor que a nossa regressão linear. Nada foi escolhido a partir dela.

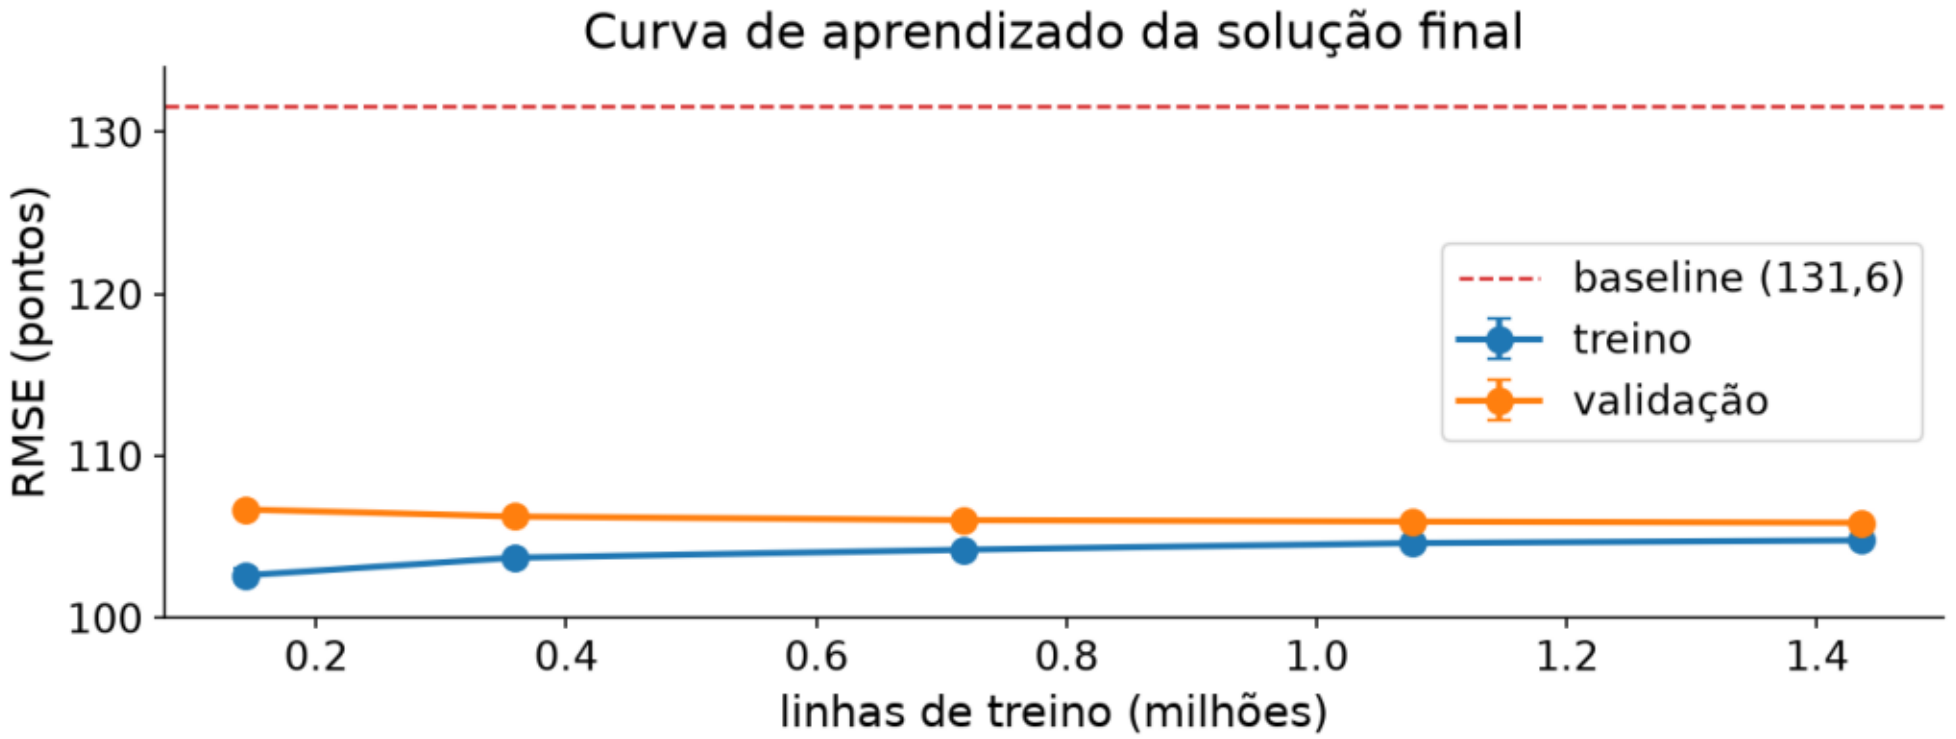
Diagnóstico: notas de outras áreas (fora da solução)



Fonte: Inep, ENEM 2023; dataset 6, só validação cruzada no desenvolvimento; fora da solução.

Proibido como entrada: só mede o vazamento. O R² vai de 0,34 para 0,68.

Solução final e curva de aprendizado



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento; média e desvio das 3 dobras.

Gradient Boosting com os hiperparâmetros da busca, 74 colunas, sem seleção, PCA nem pesos. Validação cruzada: RMSE 105,86 ± 0,17.

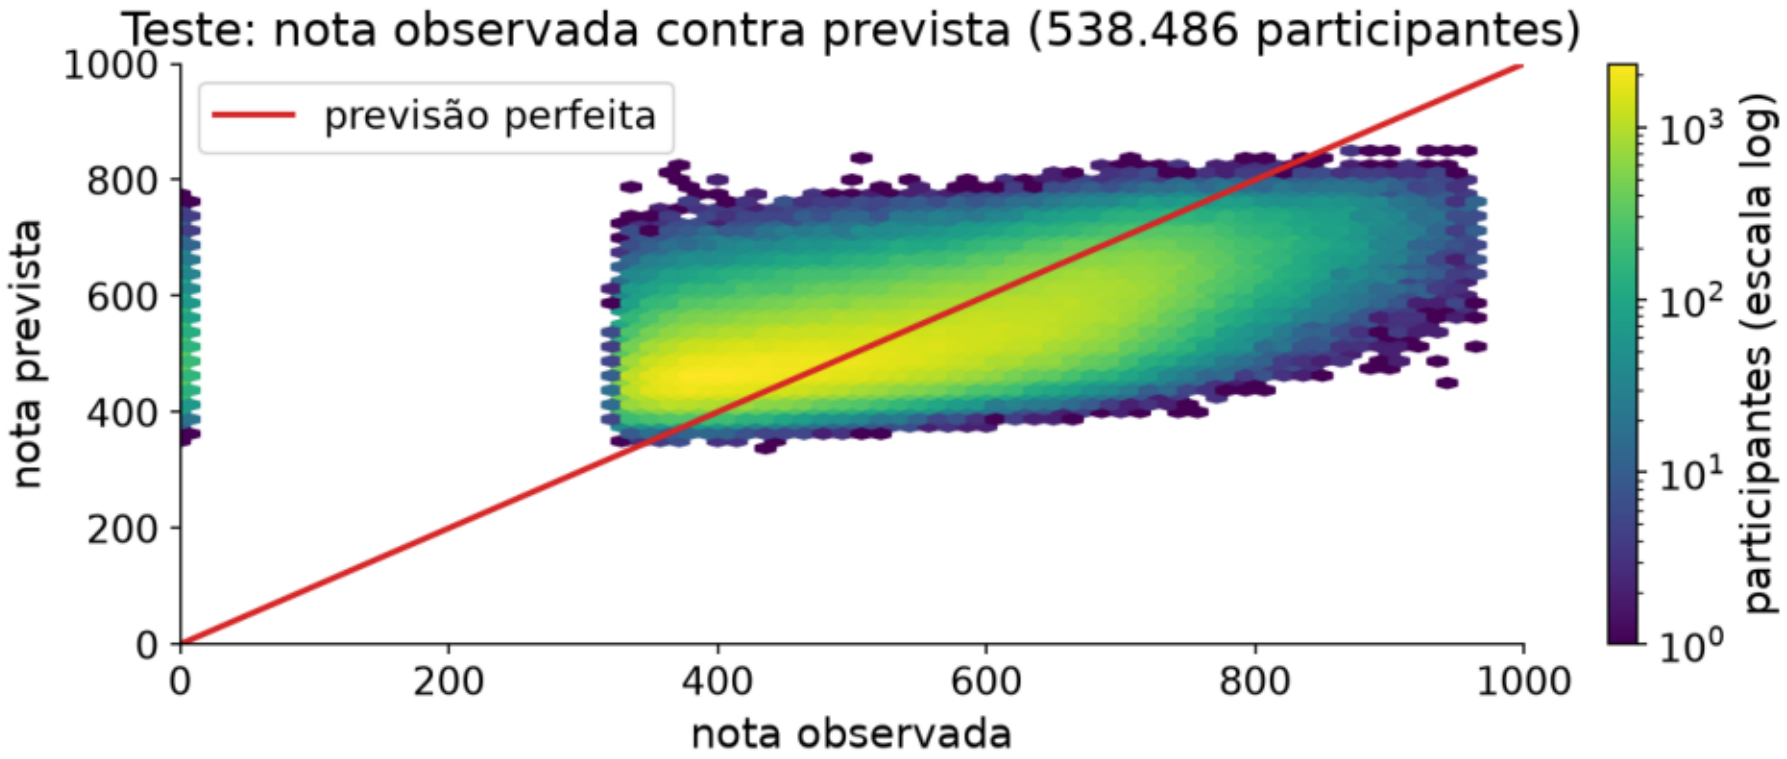
Treino e validação a 1,1 ponto; de 75% a 100% do treino, ganho de só 0,07.

Teste final: aberto uma única vez

Modelo	CV RMSE (± desvio)	Teste RMSE	Teste MAE	Teste R^2
Baseline (média)	131,63 ± 0,16	131,70	107,64	0,000
Regressão linear sem regularização	108,87 ± 0,16	108,86	84,89	0,317
Solução final (Gradient Boosting)	**105,86 ± 0,17**	**105,81**	**82,00**	**0,354**

538.486 participantes. 19,7% menos erro que o baseline e 2,8% menos que a regressão linear. Teste e validação concordam (105,81 contra 105,86).

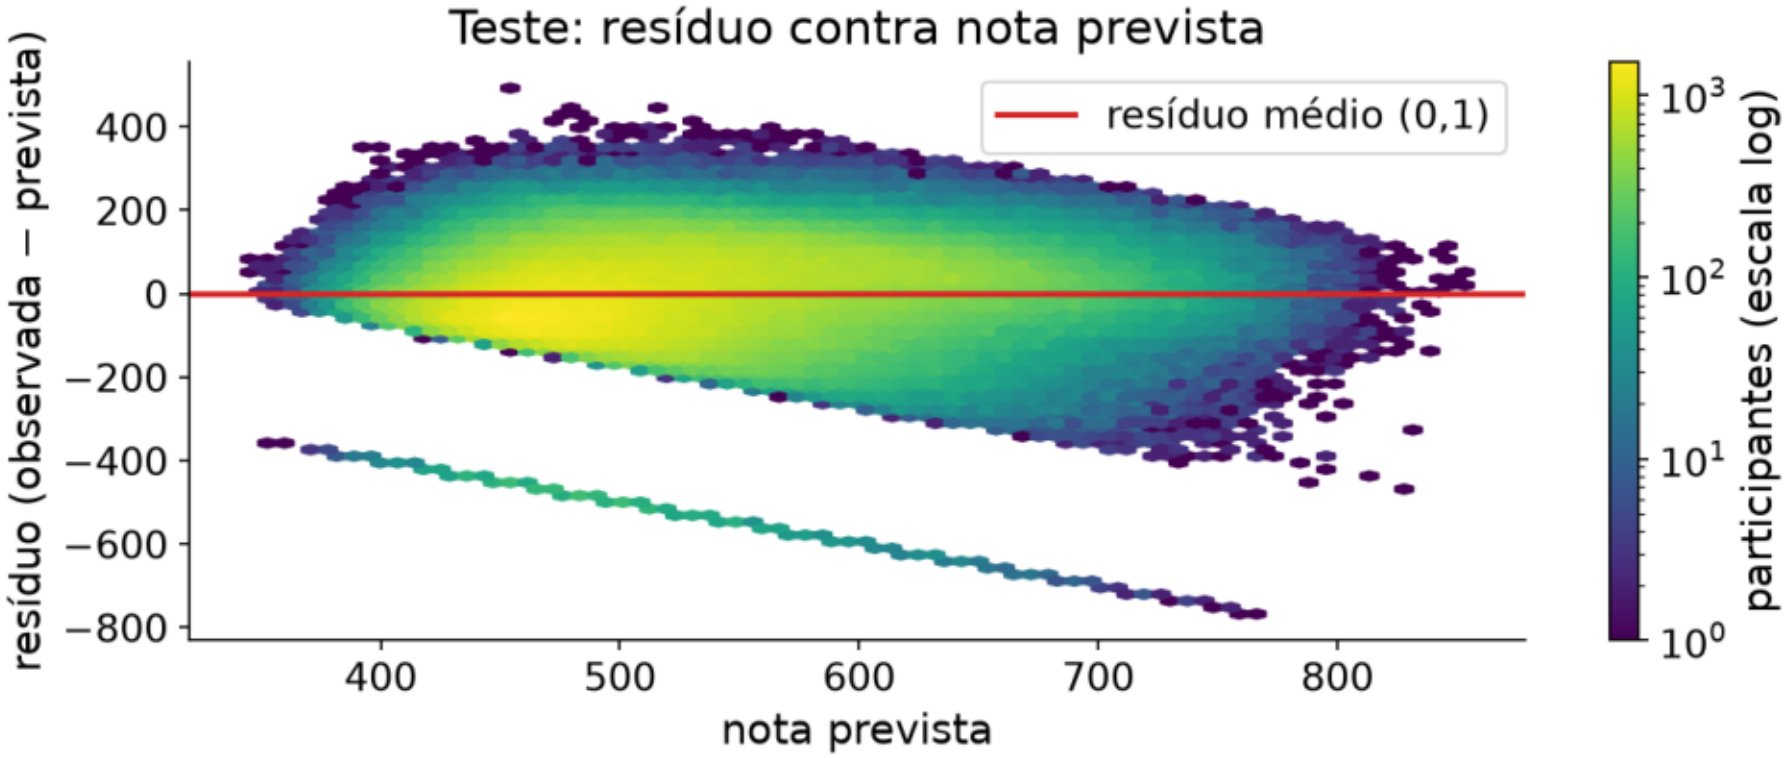
Teste: nota observada contra prevista



Fonte: Inep, ENEM 2023; teste; dispersão agregada em células hexagonais.

Regressão à média: as previsões ficam entre 350 e 850, para notas de 0 a 1000.

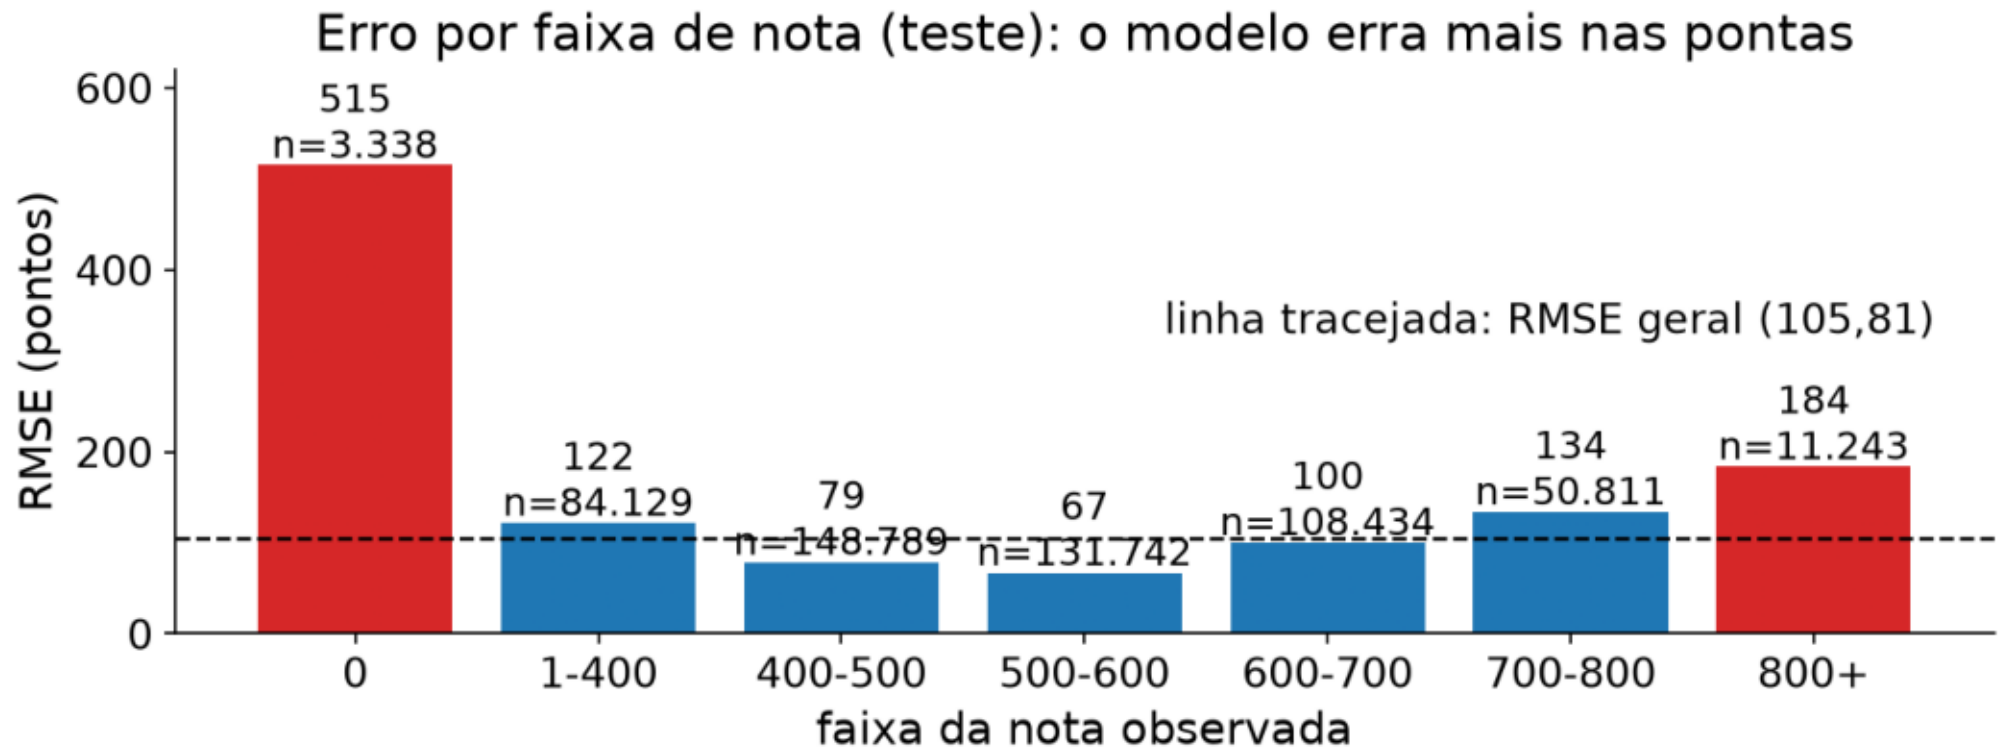
Teste: resíduos



Fonte: Inep, ENEM 2023; teste; a faixa de pontos inclinada, abaixo de −370, são as notas zero.

Resíduo médio ≈ 0; os zeros viram resíduos de −370 a −770 (faixa inclinada).

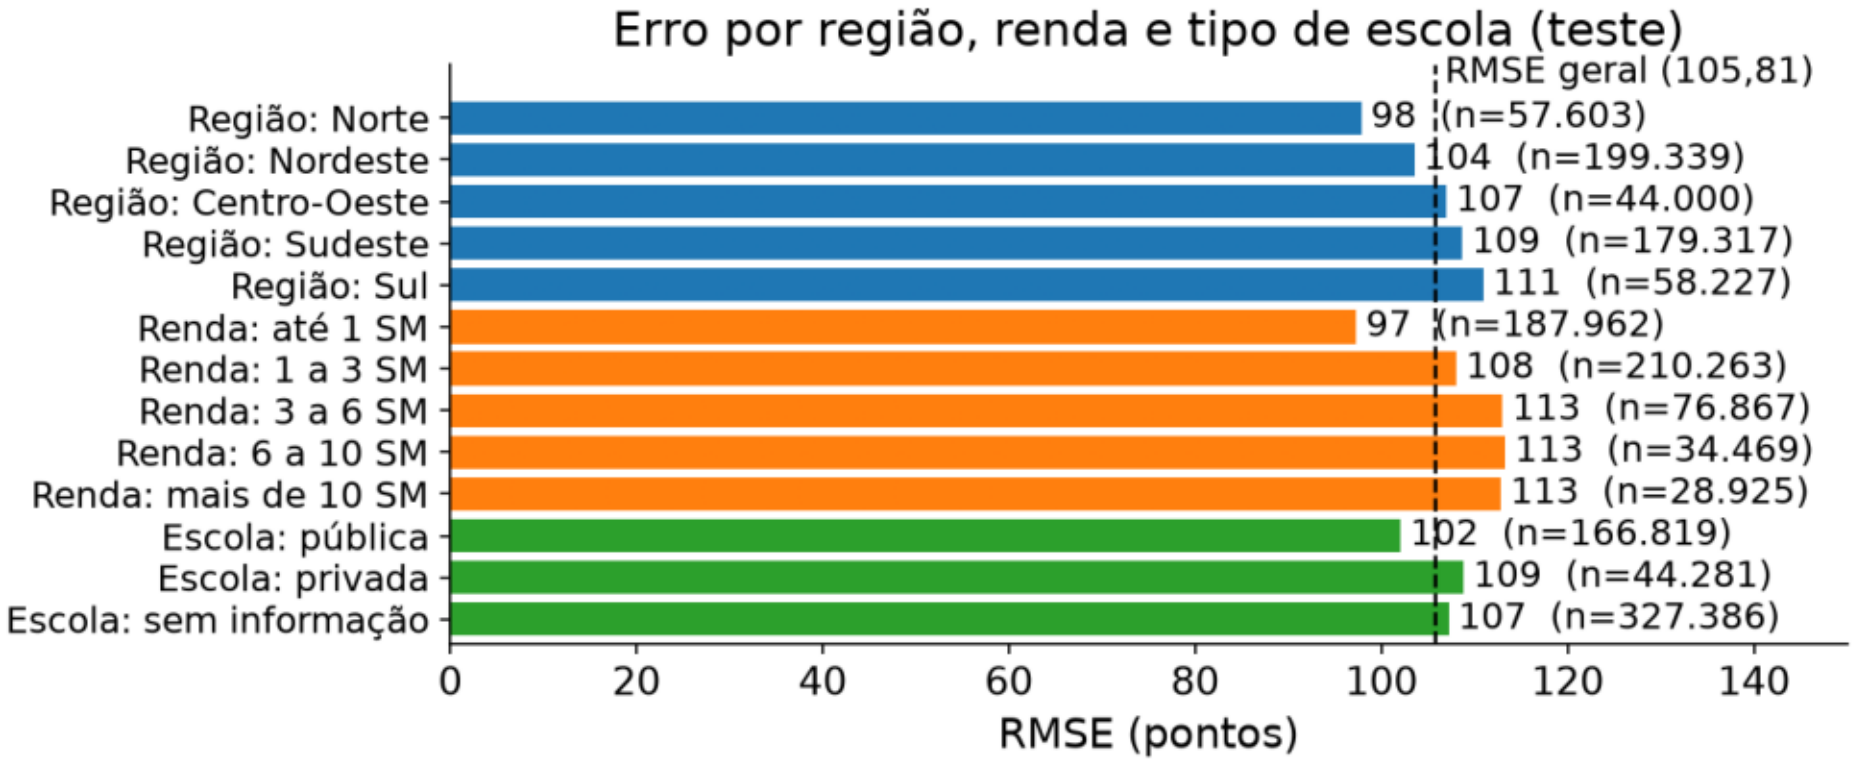
Erro por faixa de nota



Fonte: Inep, ENEM 2023; teste (538.486 participantes); faixas definidas no desenvolvimento.

O erro cresce nas pontas: notas zero (515) e acima de 800 (184).

Erro por região, renda e tipo de escola



Fonte: Inep, ENEM 2023; teste (538.486 participantes); n = participantes do grupo.

Viés < 1 ponto por região, renda e escola; RMSE de 97 a 113 entre grupos.

Extensões depois do teste (só validação cruzada)

Hipótese	Resultado (RMSE)	Leitura
One-hot em todas as categóricas, modelos lineares	108,87 para 107,89	ganha 1 ponto; ainda 2 atrás do boosting
Município com target encoding	**106,03 para 105,73**	**ganha 0,3; não adotado (teste já aberto)**
Quatro sementes do modelo final	105,862 a 105,871	variação de 0,009
Busca de hiperparâmetros nas 74 colunas	105,859 contra 105,864	mesmo erro: a busca já estava no limite
Dataset 5 (outra IA) por validação cruzada	Ridge 107,51	bate com o teste dela (107,53)

O teste já tinha sido aberto, então nada disto muda a solução final. Detalhes no Apêndice G da documentação.

Conclusões e limites

- O perfil estima só a tendência: erro de 105,8 pontos e R^2 de 0,354 no teste. O limite é a informação, não o algoritmo.
- Ajudaram: modelo de árvores (−3,4), UF (−0,7), situação escolar sem fusão (−0,33), escola (−0,4). Não ajudaram: PCA, seleção, features criadas, sem zeros, K-means.
- Viés médio menor que 1 ponto por região, renda, escola e sexo (por UF, até 2,5); o erro maior está nas pontas (zeros: −510; acima de 800: +171).
- Limites: mesma edição (não vale para escolas ou municípios inéditos); UF e escola não são residência; associação não é causa.
- Próximo passo: o município com codificação supervisionada (ganho de 0,3 na validação cruzada) e a busca em stacking e KNN. Quatro sementes variaram só 0,009.