Previsão da nota de Matemática do ENEM

Ciência de Dados · Projeto 2

Amanda Lira; João Igor; Raquel Albuquerque; Sofya Emilly

repositório: https://github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

3.933.955 inscritos na base nacional do Inep

2.692.427 participantes com nota de Matemática observada

Só com o perfil da inscrição, quanto dá para prever a nota?

A resposta está no perfil do participante.

Pergunta de pesquisa

O que o perfil explica da nota?

Estimar a nota a partir do perfil da inscrição.

Comparar modelos e escolhas de preparação.

Interpretar o que o perfil explica da nota.

Evitar vazamento de dados na validação.

Origem dos dados e divisão

Base do Inep

3.933.955

inscritos

Após filtro

2.692.427

participantes com nota
de Matemática observada

Divisão dos dados

80%	20%
2.153.941 registros	538.486 participantes

Validação cruzada com 3 dobras

Protocolo de validação

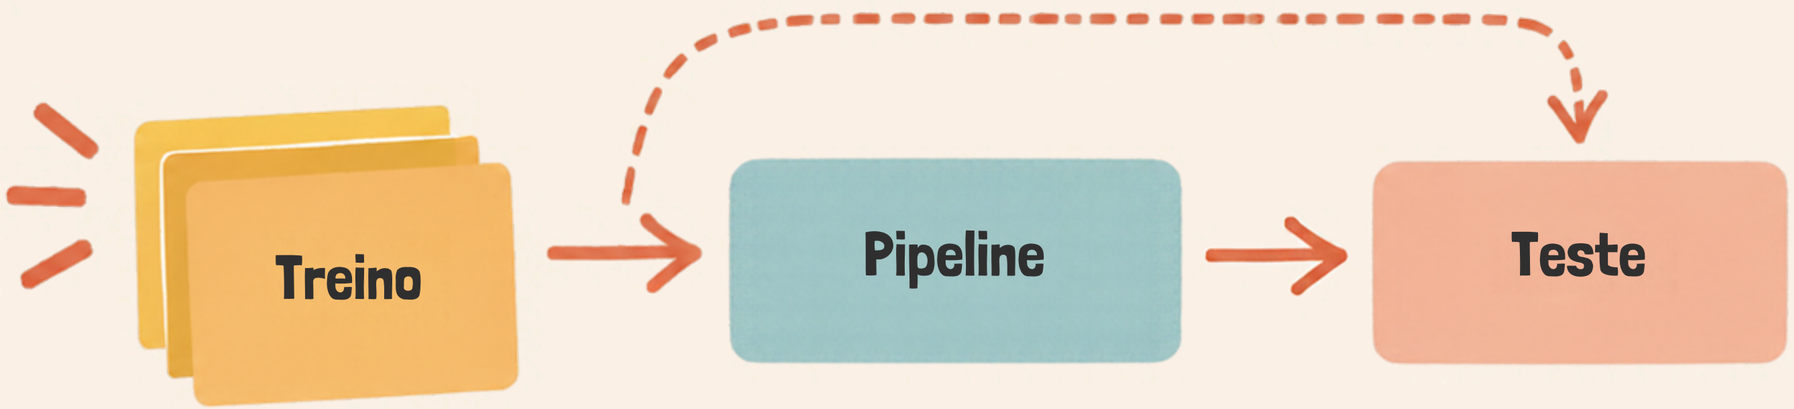

A base de treino alimenta o pipeline
e o teste permanece separado até a avaliação.

A nota de Matemática em perspectiva

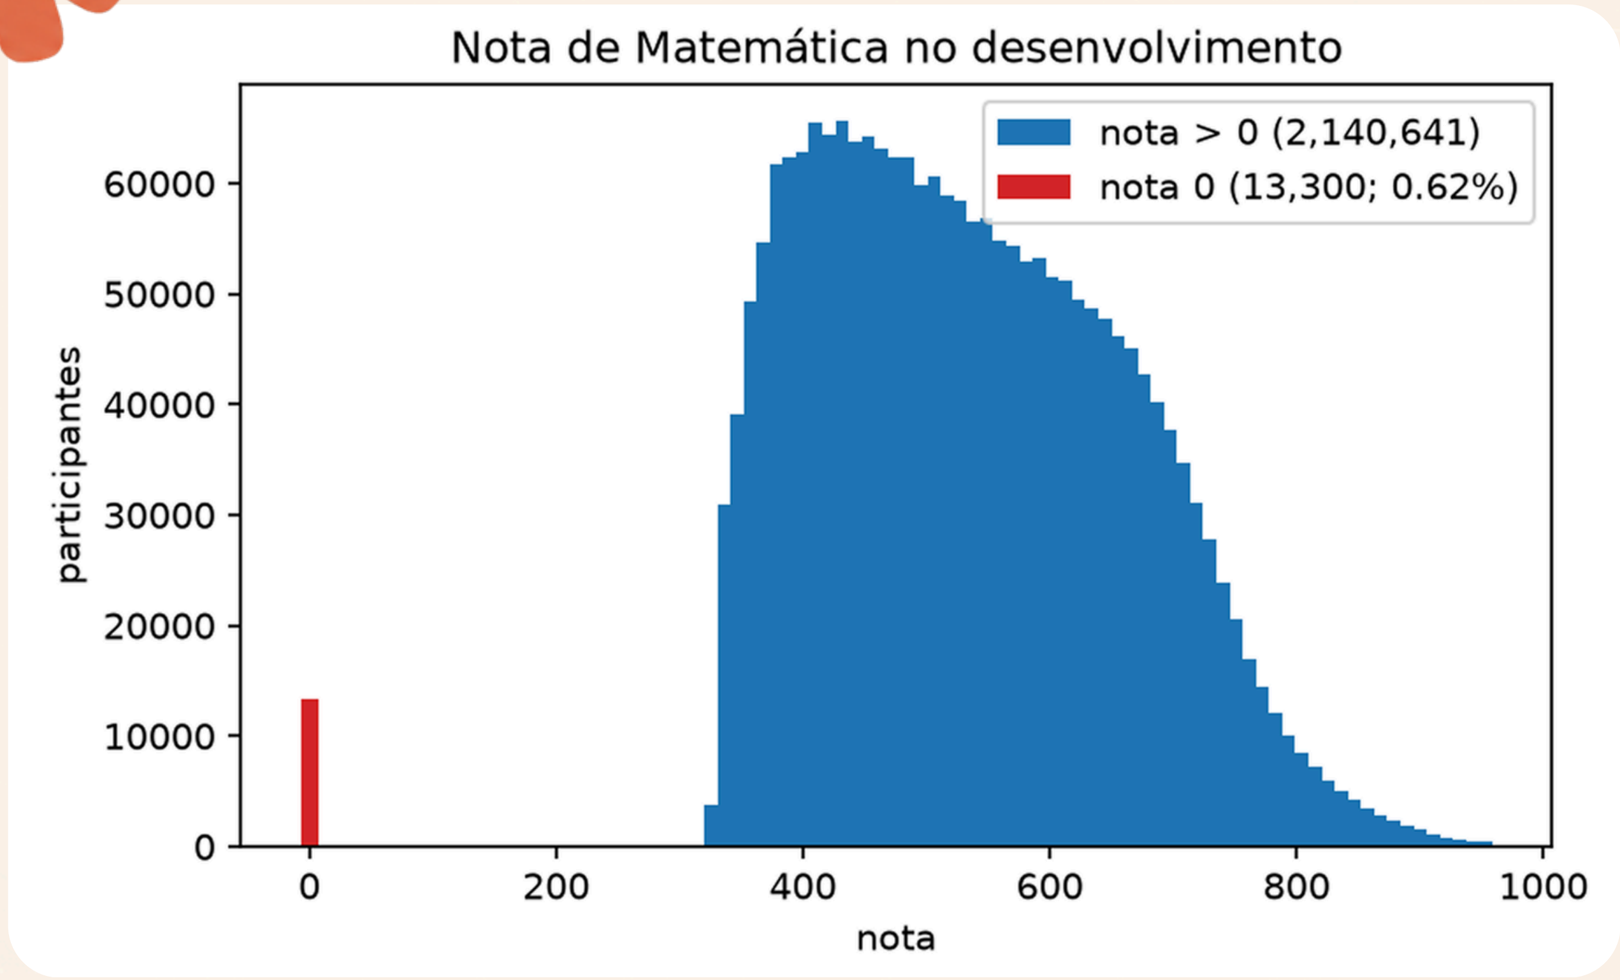

Média

533,8

Desvio padrão

131,6

Preparação dos dados

76 colunas na base original

76

74 colunas na solução final

74

"Não sei" virou ausente + indicador

Escola vazia tratada como "sem informação"

Sem vazamento: dados de outras áreas removidos.

Quais informações entraram nos datasets?

Perfil e trajetória escolar

Renda, bens e domicílio

UF e município da prova

Escola e situação escolar

Três features criadas e suas hipóteses

Descartamos combinações redundantes (|ρ| > 0,7) e testamos 3 interações inéditas calculadas linha a linha

ρ = **–0,22**

Pessoas por quarto

Fórmula: Q005 / Q009 (mín. 1)

Hipótese: Casa mais lotada oferece menos espaço individual para estudo.

ρ = **+0,28**

Celular por morador

Fórmula: Q022 / Q005

Hipótese: Maior disponibilidade individual facilita acesso a conteúdo e aulas online.

ρ = **+0,09**

Renda menos estudo

Fórmula: Renda [0-1] - Escol. [0-1]

Hipótese: Descompasso entre capital econômico e estudo familiar traz sinal extra.

Resultado experimental: +0,01 ponto no RMSE ao retirar as 3

Sem diferença clara (dentro do desvio de 0,19): modelos baseados em árvores já capturam essas interações sozinhos.

Dos 8 datasets salvos às 21 combinações testadas

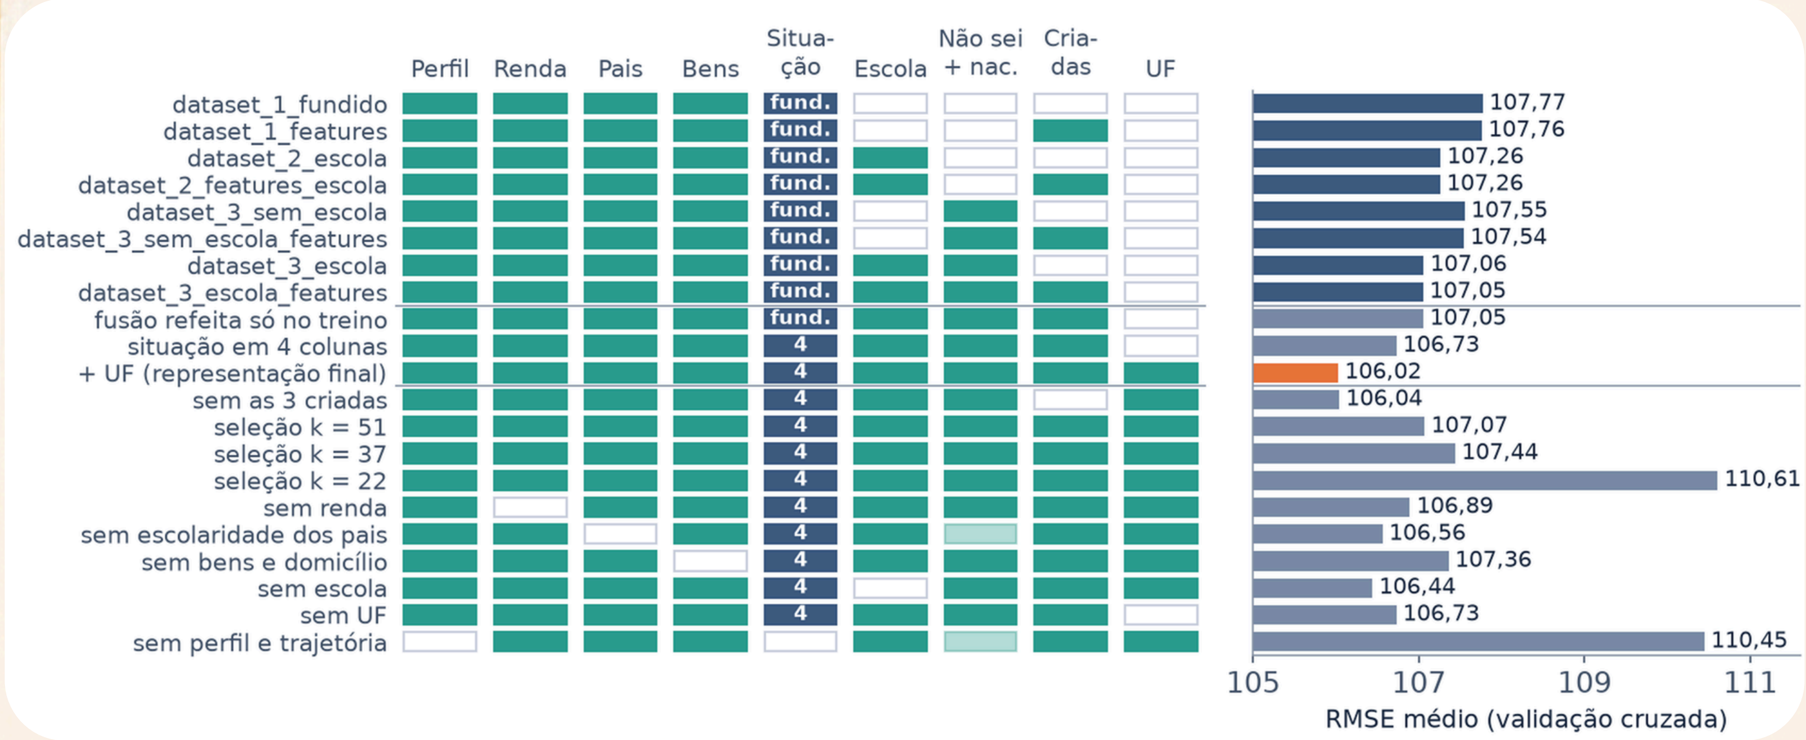

8 Datasets (30 a 45 col.)

RMSE cai de 107,77 para 107,05. Escola dá o ganho mais consistente (-0,50).

Solução Final (74 col.)

Situação em 4 col. (-0,33) + 26 UFs (-0,70) reduzem RMSE para 106,03.

SelectKBest piora

Cortar para 51, 37 ou 22 colunas piorou o erro em +1,04 a +4,58 pts.

Famílias de modelos testadas

Modelos lineares

Regressão linear

Ridge

Métodos de vizinhança

KNN

SVR linear

Ensembles

Árvore de decisão

Random Forest

Bagging

Pasting

Gradient Boosting

Stacking

Árvores e boosting superam regressão linear e baseline pela média.

Comparação dos modelos

As árvores com boosting ficam na frente; KNN e SVR linear não superam a regressão linear. Stacking empata e custa cinco vezes mais.

- Gradient Boosting e Stacking ficam em primeiro, com RMSE médio de 107,8.
- Random Forest registra 109,4; Bagging e Pasting ficam em 110,0.
- Regressão linear, Ridge e SVR linear marcam 111,2; KNN, 111,6.
- O baseline pela média chega a 131,6; menor RMSE é melhor.

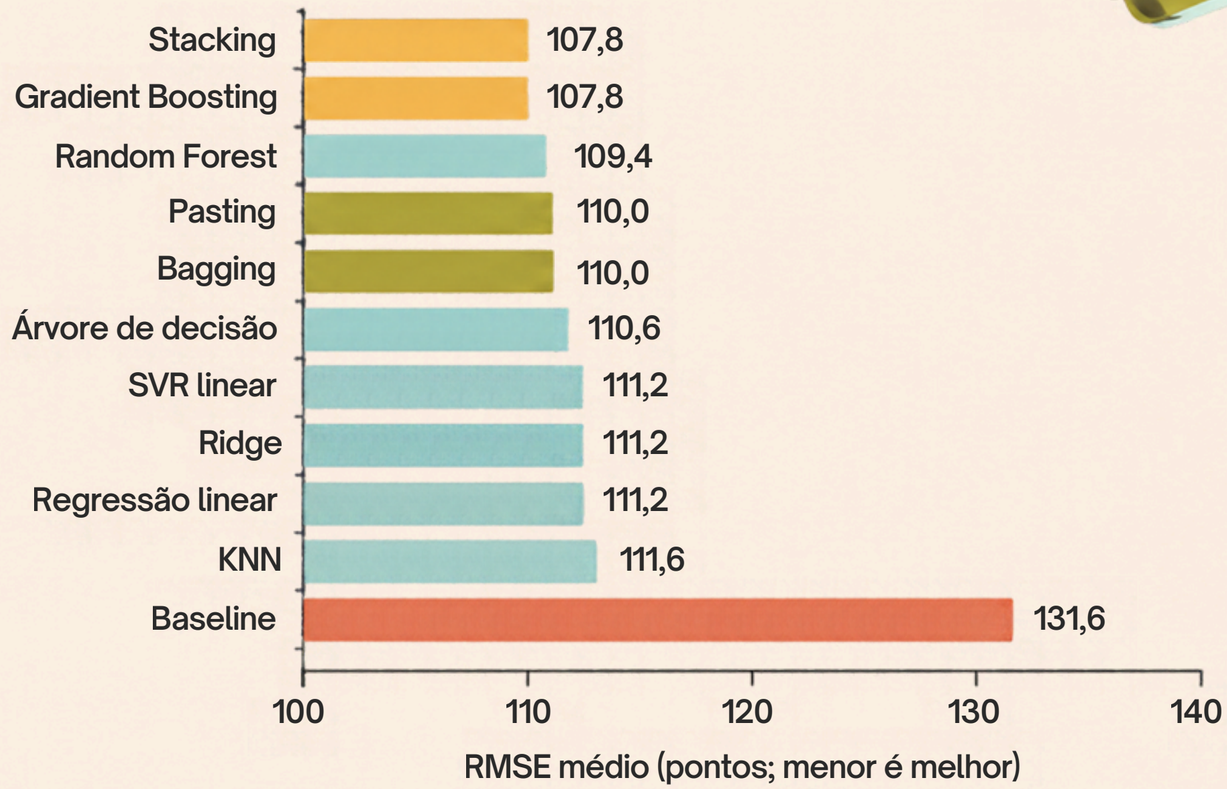

Busca de hiperparâmetros

Ambos reajustados exclusivamente no treino de cada dobra dentro do Pipeline

Busca: RandomizedSearchCV (10 config.)

Bagging: 110,01 -> 109,08 (−0,93) | RF: −0,28 | Boosting: −0,09 (dentro do desvio)

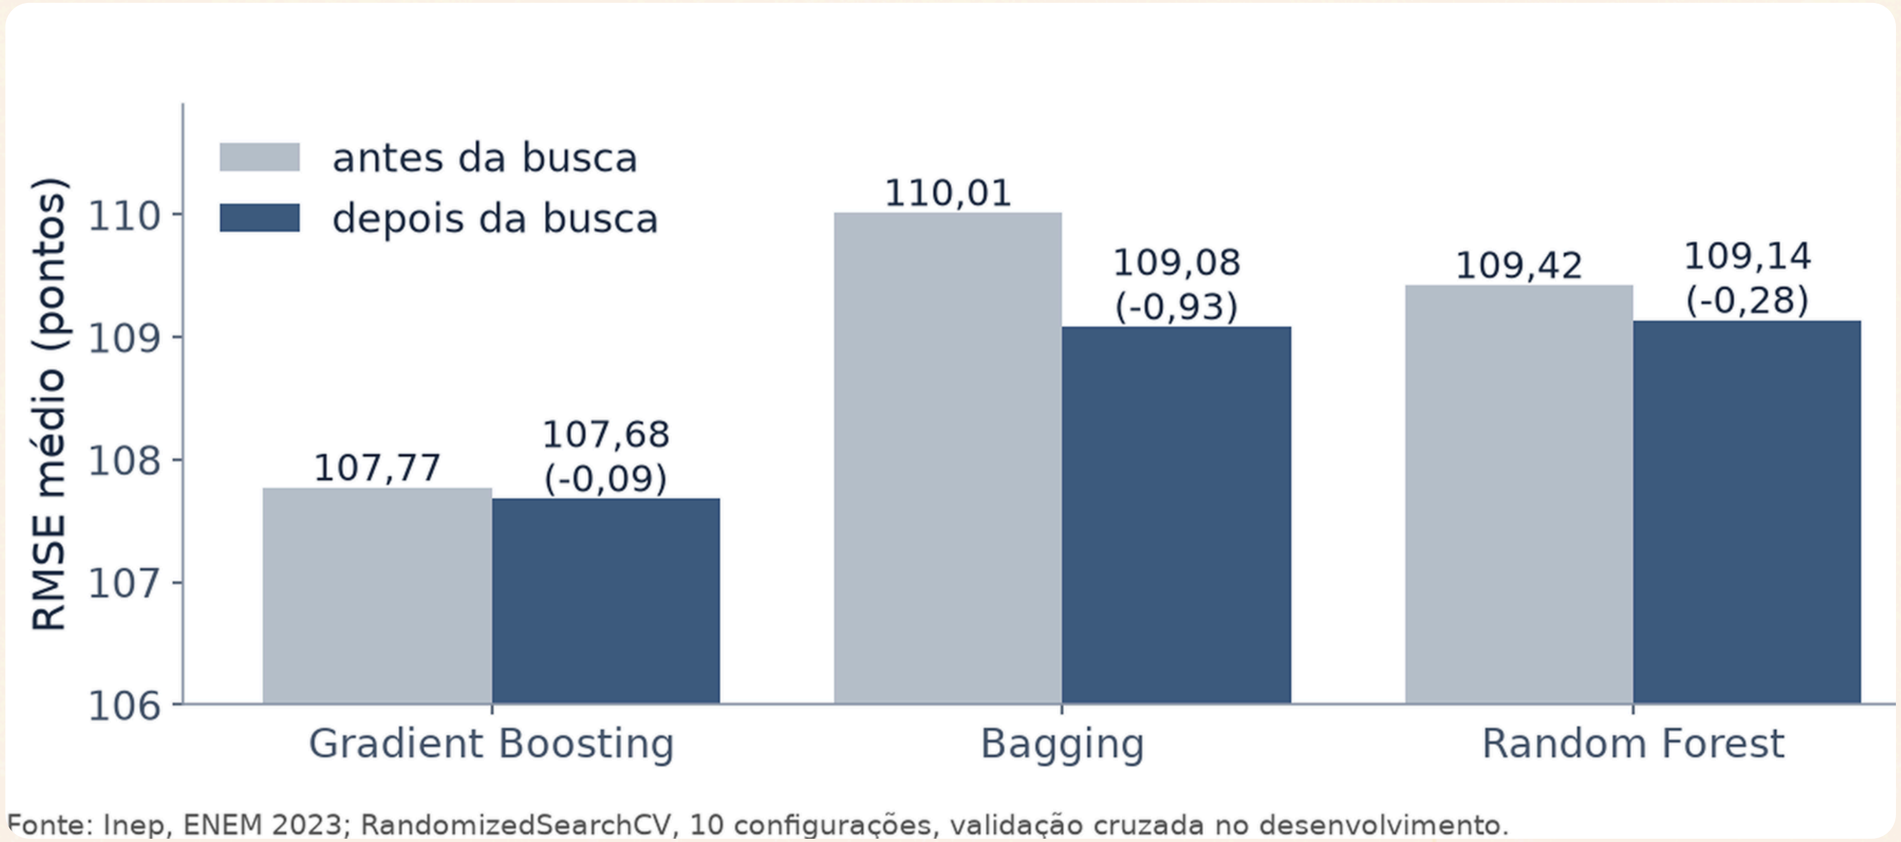

Fonte: Inep, ENEM 2023; RandomizedSearchCV, 10 configurações, validação cruzada no desenvolvimento.

Redução por PCA

Reajustado exclusivamente no treino de cada dobra dentro do Pipeline

PCA: 18 de 30 comp. para 80% da variância

Dados pouco redundantes; com PCA o RMSE piora em todos os cortes (107,77 -> 110,17).

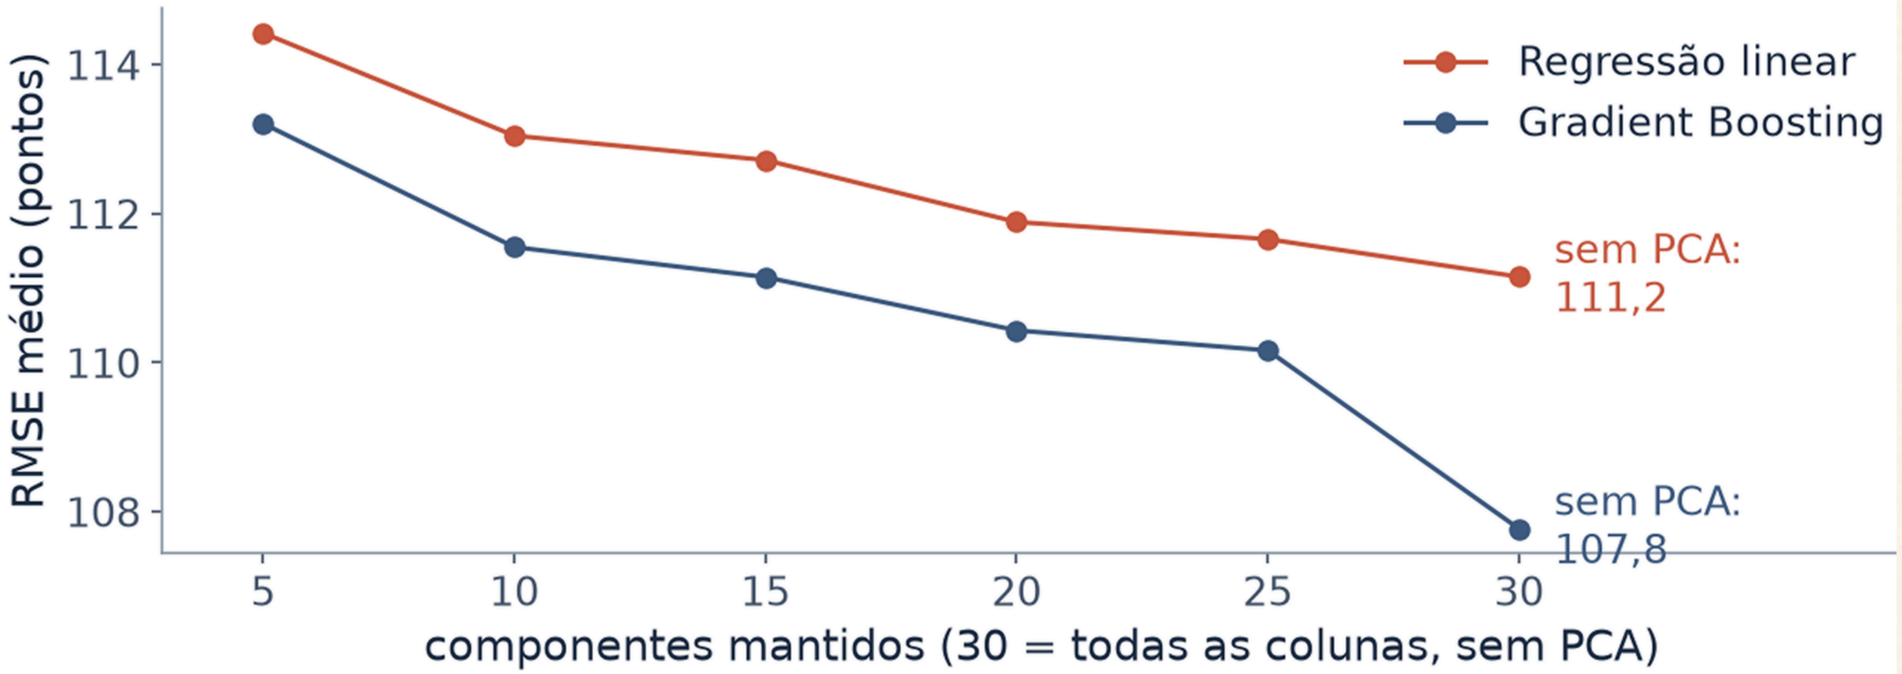

Fonte: Inep, ENEM 2023; PCA dentro do Pipeline, validação cruzada no desenvolvimento.

Hipóteses e ablações

Reduções sucessivas de RMSE

Gradient Boosting	→	Mais colunas	→	Situação escolar separada	→	UF da prova	→	Busca de hiperparâmetros
-3,38		-0,72		-0,32		-0,70		-0,16

PCA piorou o erro, mesmo com muitos componentes.

O maior ganho veio da inclusão da UF da prova.

Quanto vale cada bloco de informação?

Aumento do RMSE na validação cruzada ao retirar um bloco por vez das 74 colunas finais

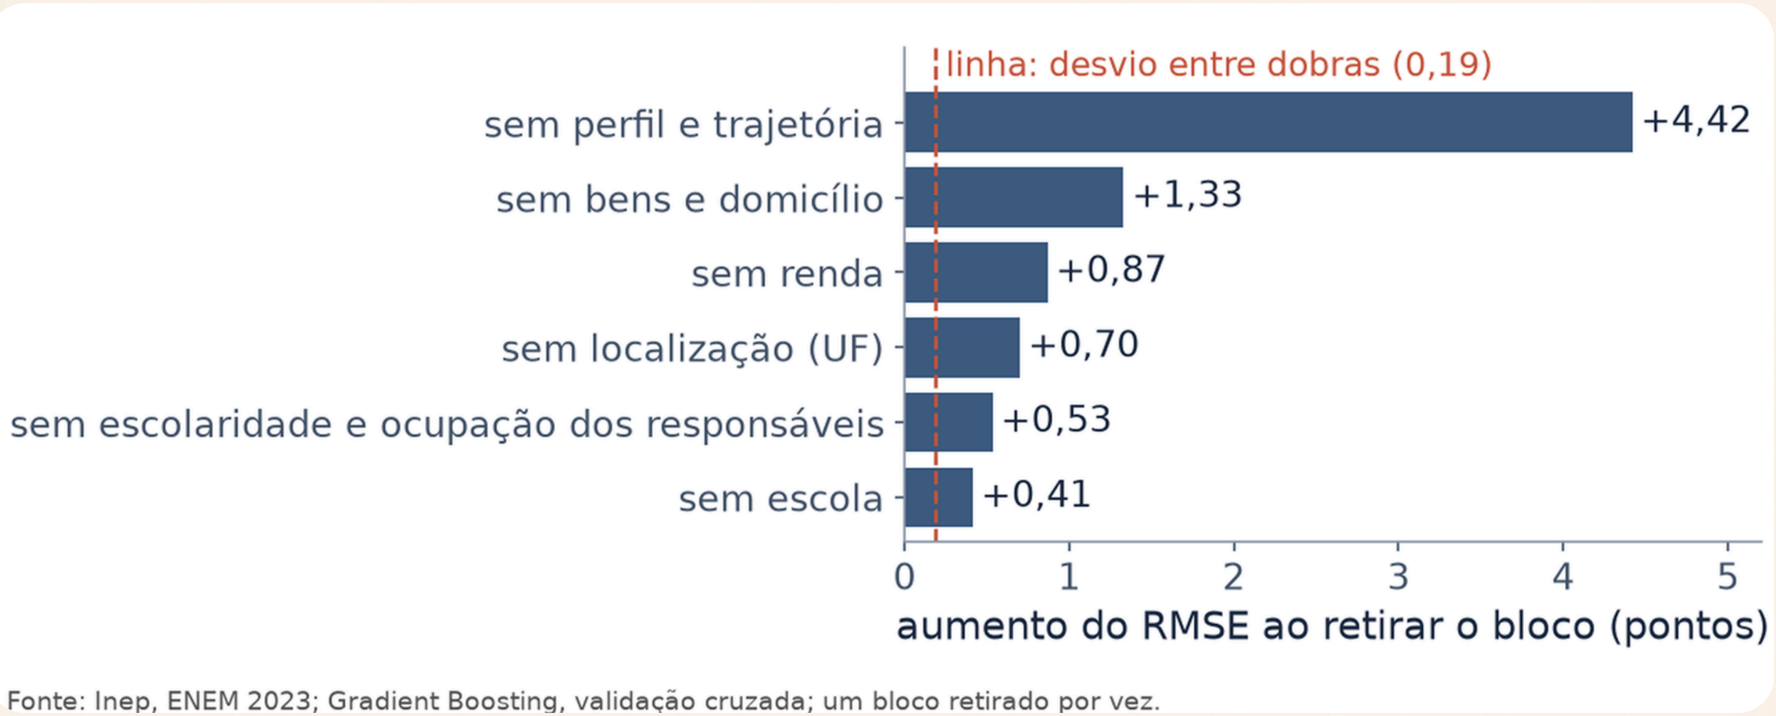

Fonte: Inep, ENEM 2023; Gradient Boosting, validação cruzada; um bloco retirado por vez.

+4,42 pontos
Sem Perfil e Trajetória

Idade, situação de conclusão, sexo e língua formam o bloco mais decisivo.

+1,33 e +0,87
Bens e Renda

Condição material vem logo atrás. Todos os 6 blocos superam o desvio (0,19).

Balanceamento por pesos nas faixas de nota

Pesos n^(-α) por faixa de 50 pontos no treino da dobra: reduz o erro nas pontas, mas sacrifica o meio

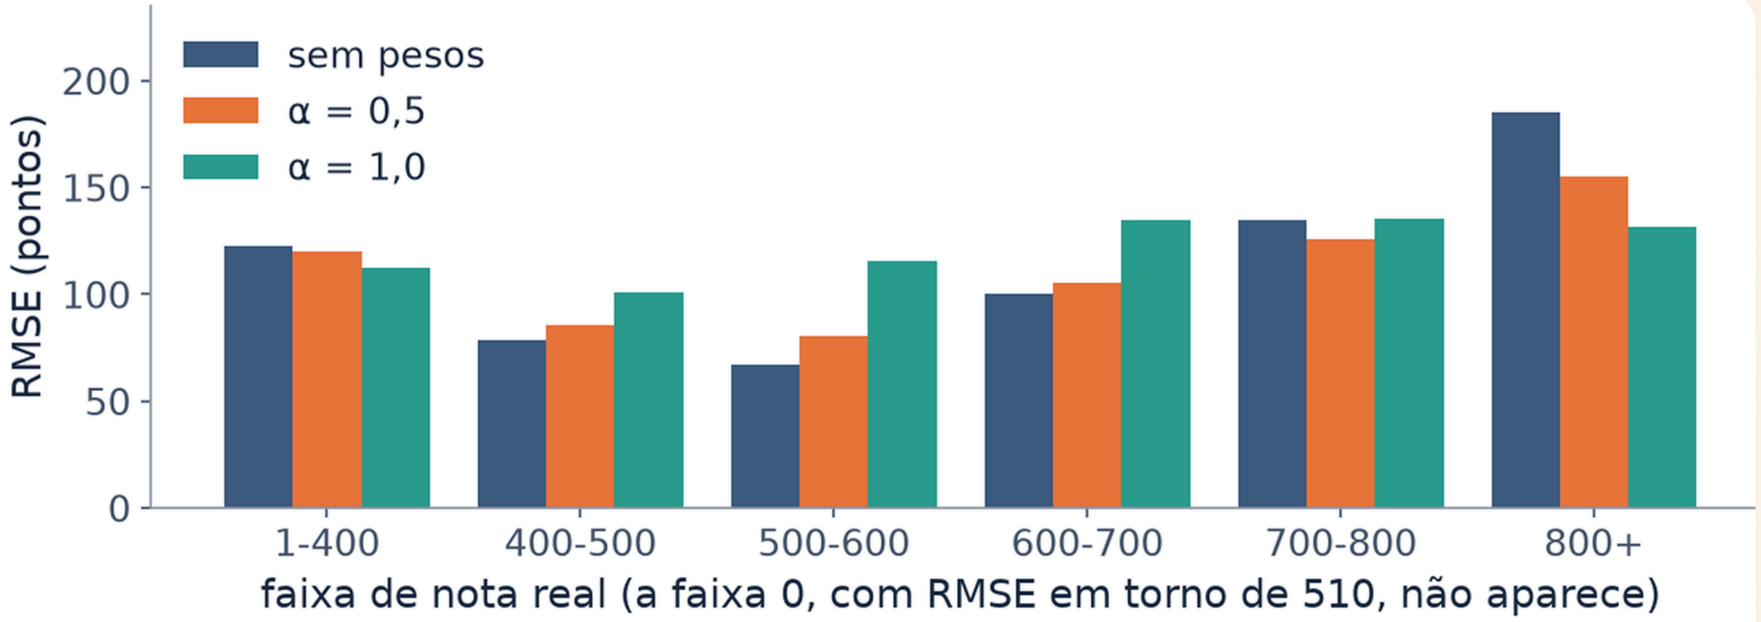

Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento; pesos n^(−α) por faixa de 50 pontos, calculados só no treino.

184,9 -> 155,4
Notas 800+ (α=0,5)

A ponderação cumpre o papel de reduzir a subestimação nas notas altas.

+2,12 pontos
Piora no RMSE Geral

O erro na faixa central (500–600) sobe de 66,8 para 80,6. Solução mantida sem pesos.

Solução final

HistGradientBoosting

74 colunas · sem seleção, PCA ou pesos

RMSE de validação cruzada	RMSE de teste	R^2 de teste
105,86 ± 0,17	**105,81**	**0,354**

Redução de **19,7%** contra o baseline (131,70) e 2,8% contra a Regressão Linear no teste (108,86) | MAE: 82,0

Curva de aprendizado: subajuste, sobreajuste ou falta de informação?

Subconjuntos progressivos de 10%, 25%, 50%, 75% e 100% do treino da dobra (até 1,44 milhão de linhas)

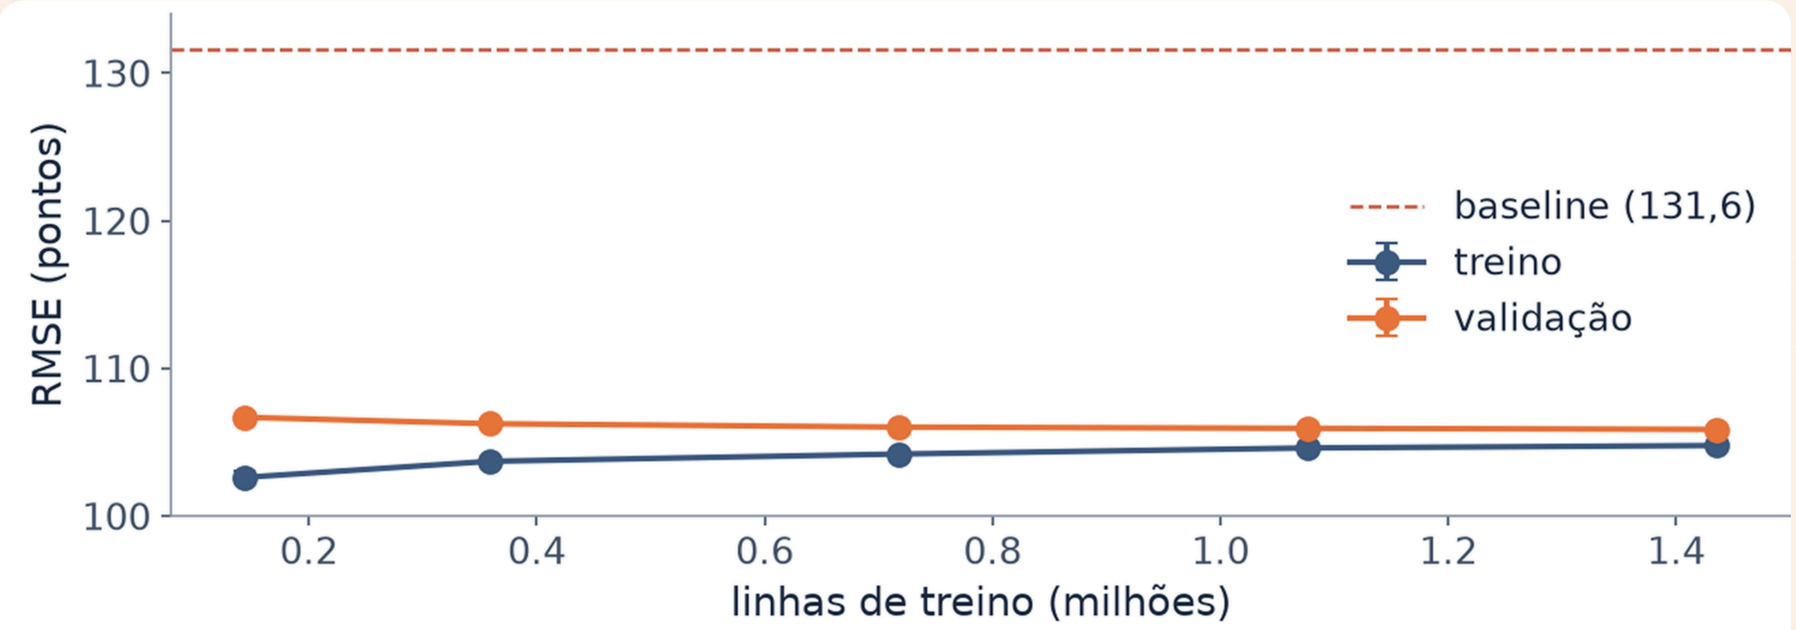

Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento; média e desvio das 3 dobras.

1,09 ponto
Treino vs. Validação

Treino (104,77) e validação (105,86) terminam juntos: sem sobreajuste forte.

–0,07 ponto
De 75% a 100% do treino

Mais linhas quase não ajudam: o limite vem da falta de informação sobre estudo e ensino.

O que o teste revela sobre as previsões?

Regressão à média

As previsões ficam entre 350 e 850, mesmo quando a nota observada é extrema.

RMSE de teste geral

105,81

184

Erro maior nas notas acima de 800.

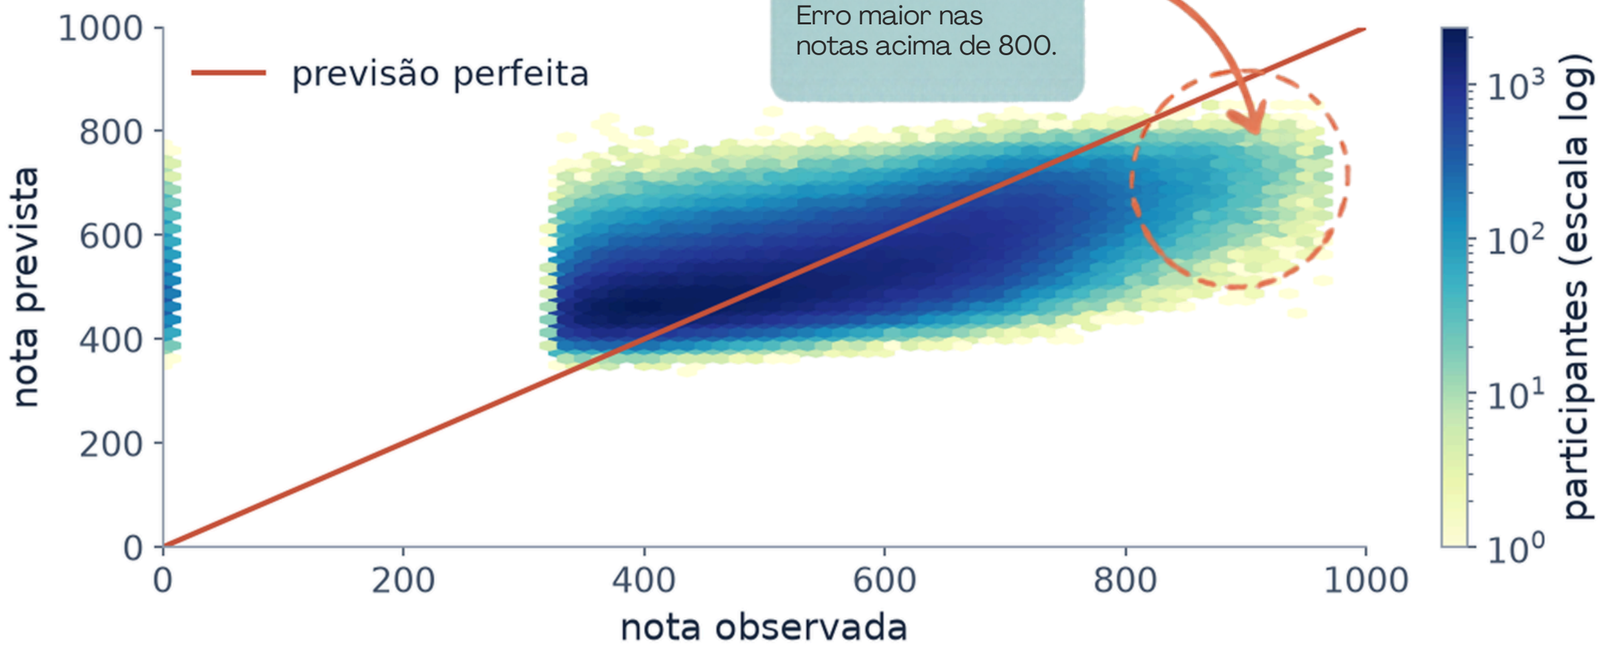

Fonte: Inep, ENEM 2023; teste; dispersão agregada em células hexagonais.

Onde o modelo erra mais

O erro é mínimo perto da média e cresce nas pontas: 515 nos zeros e 184 acima de 800.

515

Para notas zero, o RMSE sobe a 515 pontos, com 3.338 participantes.

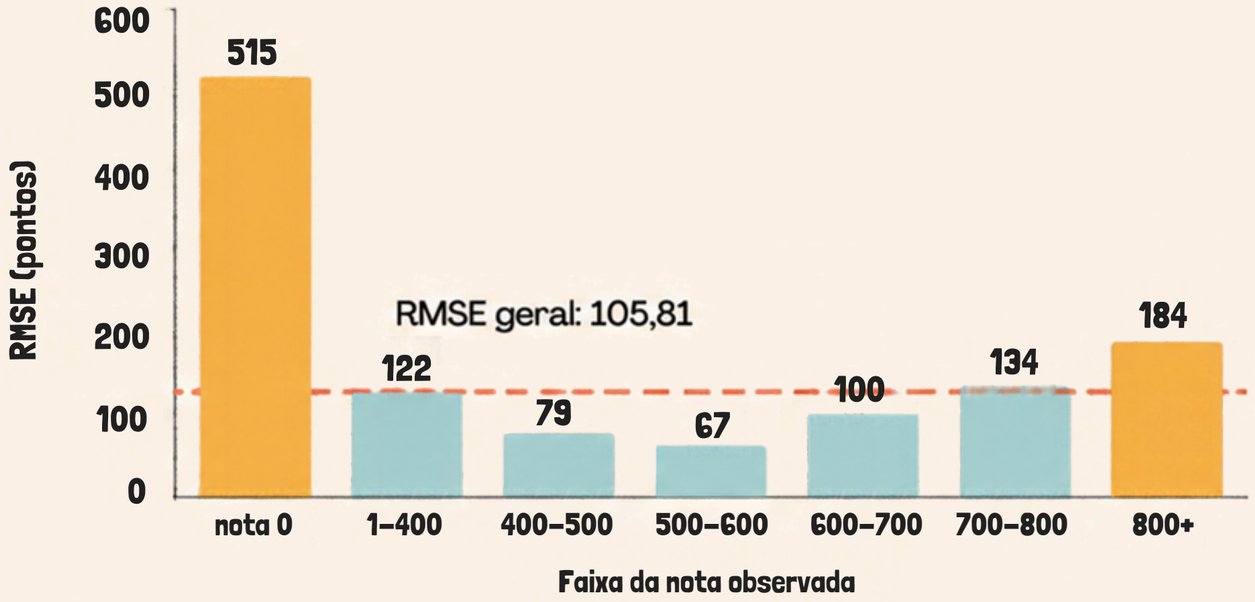

184

Acima de 800, o RMSE é 184 pontos, com 11.243 participantes.

- Na faixa 500–600, o RMSE é 67 pontos, o menor entre as faixas mostradas.
- Para notas zero, o RMSE sobe a 515 pontos, com 3.338 participantes.
- Acima de 800, o RMSE é 184 pontos, com 11.243 participantes.

Teste: 538.486 participantes; faixas definidas no desenvolvimento.

Erros por região, renda e escola

O viés médio fica abaixo de 1 ponto nesses grupos e o RMSE varia de 97 a 113.

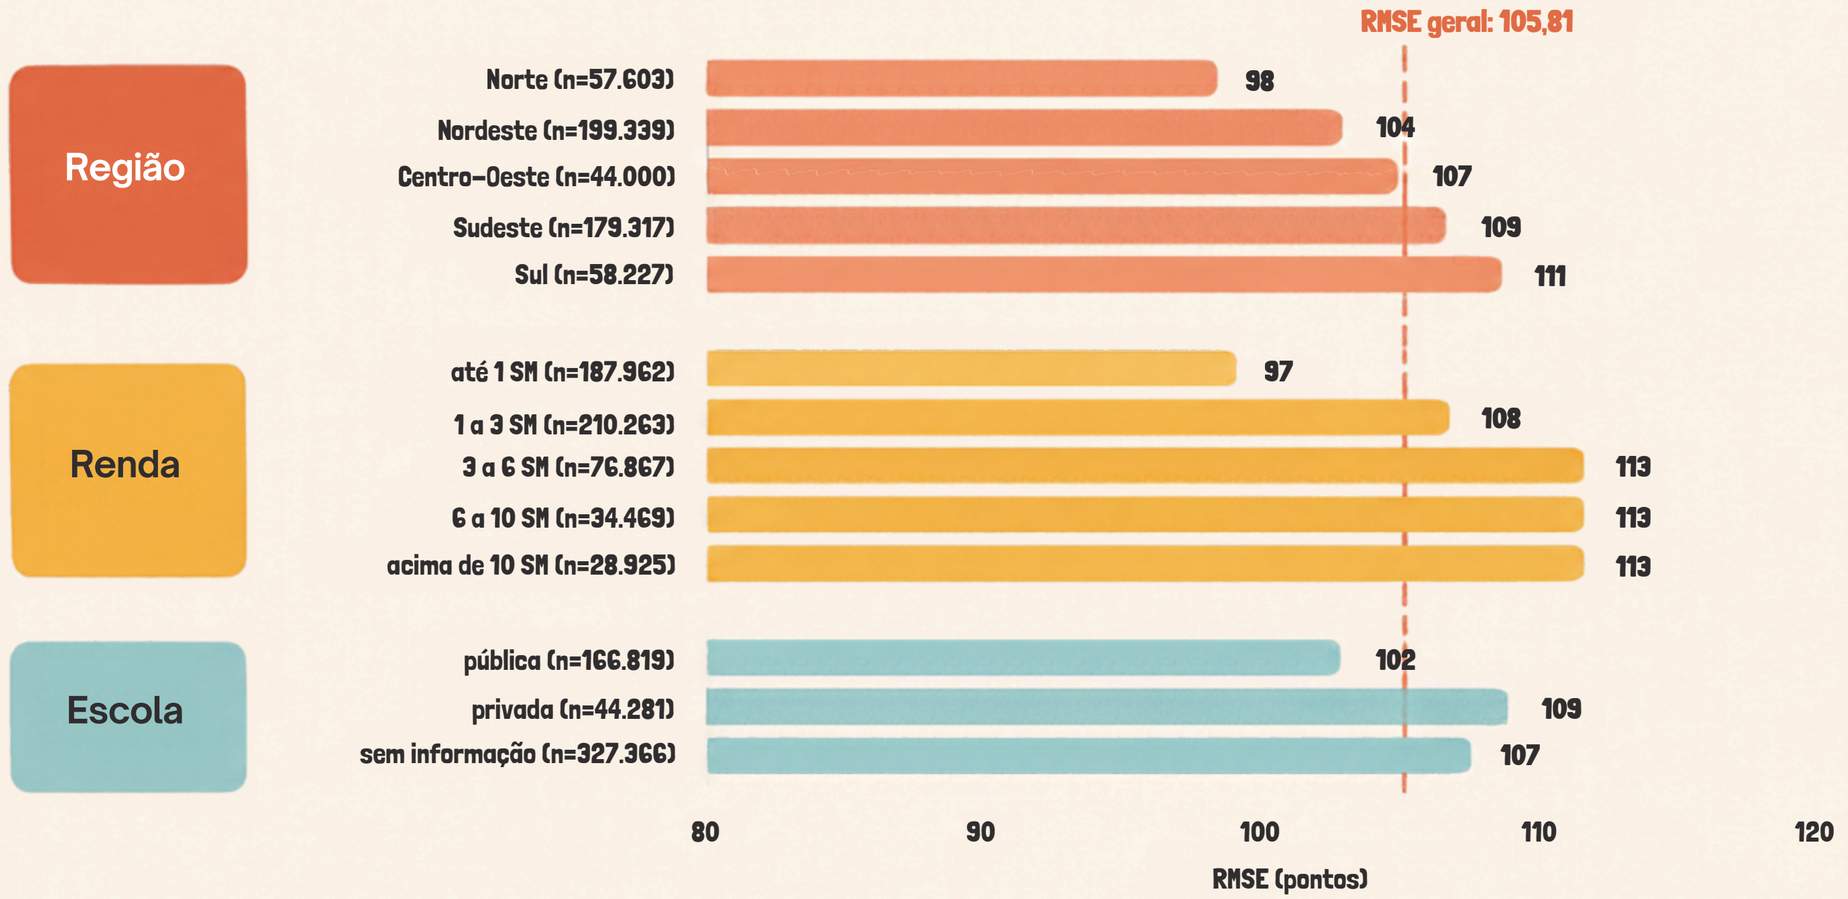

- O RMSE observado nos grupos varia de 97 a 113 pontos.
- A referência do RMSE geral no teste é 105,81.
- Os valores de viés médio permanecem abaixo de 1 ponto nos grupos avaliados.

Verificações independentes

Replicação independente: RMSE de teste 107,53, sem superar a solução do grupo (105,81).

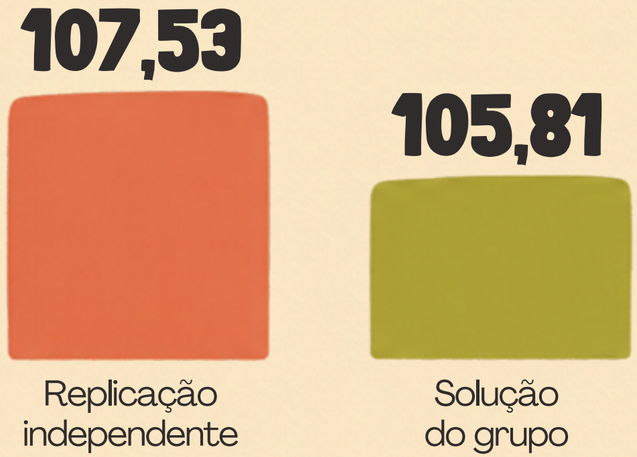

Notas de outras áreas elevam o R^2 de 0,34 para 0,68; o limite é a informação disponível.

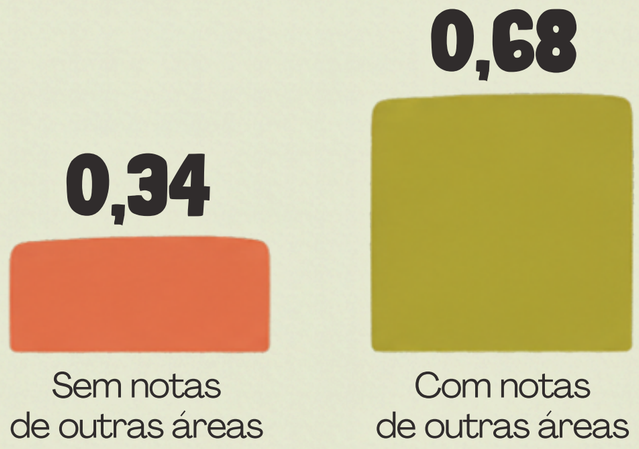

Extensões pós-teste e perguntas respondidas

Avaliadas apenas por validação cruzada: como o teste já havia sido aberto, nenhuma altera a solução oficial

-0,98 ponto
One-Hot nos Lineares

Reduziu o RMSE linear de 108,87 para 107,89, mas seguiu 2 pontos atrás do Boosting (105,86).

-0,30 ponto
Município da Prova

Target Encoding no Pipeline baixou o RMSE de 106,03 para 105,73. Melhor próximo passo.

Síntese das demais perguntas do edital (sem ganho no RMSE):

- Retirar notas zero do treino: -0,06 pt (sem diferença clara; zeros só são identificáveis com a nota de Natureza).
- Perfis por K-means (k=2) como feature: +0,02 pt (sem efeito) | V de Cramér: só Situação x Tipo de Escola passa de 0,7 (0,707).

Conclusão

O perfil estima a tendência de um grupo, não a nota individual.

RMSE final:

105,8

R^2:

0,354

Associação não é causalidade.