Previsão da nota de Matemática do ENEM 2023 pelo perfil dos participantes

Quanto o perfil explica a nota, e o que mudou o erro dos modelos

João Igor Vidal de Andrade · Raquel Albuquerque Quirino · Amanda Lira · Sofya Oliveira

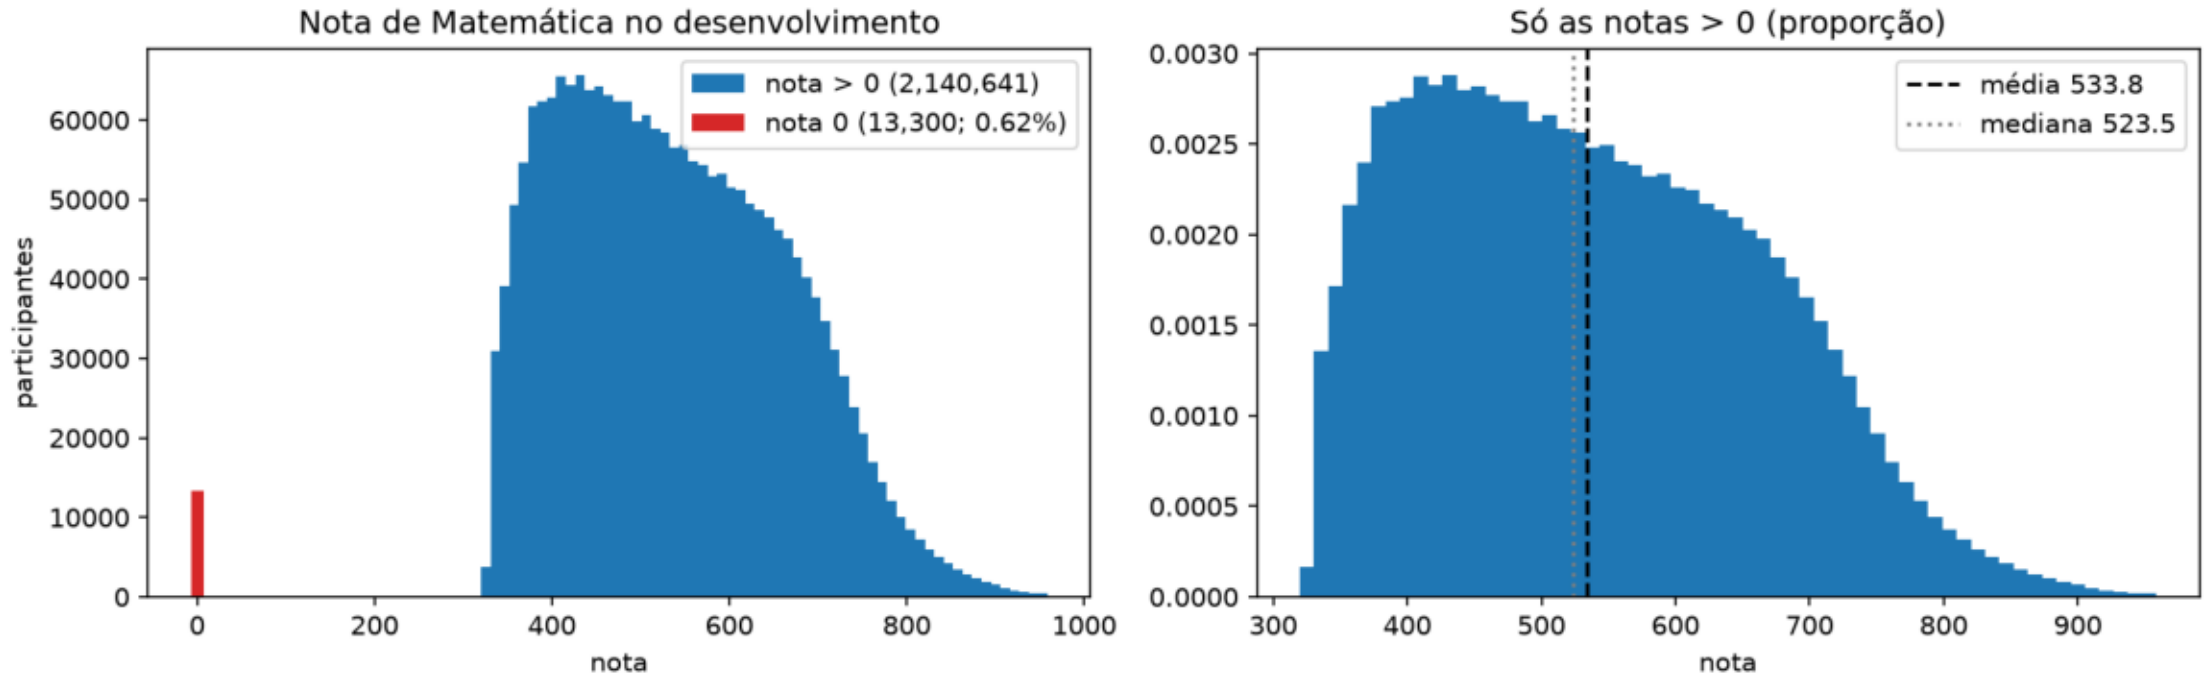
Ciência de Dados, Projeto 2 (Unidade II: Aprendizado de Máquina) · Unifor

github.com/Alyra004/ciencia-de-dados-unifor-projeto-2

O problema e a base

- Pergunta: quanto o perfil socioeconômico, escolar e demográfico estima a nota de Matemática (NU_NOTA_MT, de 0 a 1000)?
- Base nacional completa do Inep: 3.933.955 participantes; 2.692.427 com nota observada (usados).
- 80% para desenvolvimento (2.153.941) e 20% para teste (538.486), semente 42. O teste só foi aberto no fim.
- Nota ausente não vira zero; nota zero (0,62%) é resultado observado e fica nos dados.
- Objetivo: comparar escolhas de preparação e de modelagem e explicar os limites, não maximizar o R^2.

A nota: distribuição e as notas zero



Fonte: Inep, Microdados do ENEM 2023; desenvolvimento (2,153,941 participantes).

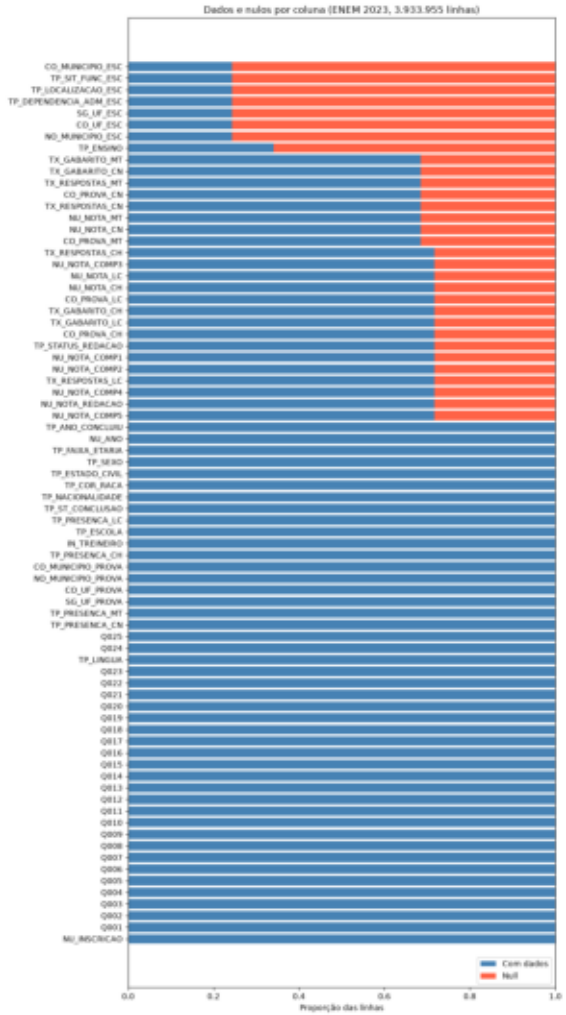
Desenvolvimento: 2.153.941 participantes. Zeros em vermelho: 13.300 (0,62%).

Zeros: resultado observado e válido (0,62%); ficam no treino e na validação.

Protocolo de avaliação e vazamento

- Validação cruzada de 3 dobras só no desenvolvimento, sempre as mesmas dobras (KFold, semente 42).
- Tudo que se aprende dos dados fica dentro de um Pipeline e é refeito só no treino de cada dobra.
- Métrica principal: RMSE (MAE e R^2 complementares), com média e desvio entre as dobras.
- Fora das entradas: notas de outras provas, presença, respostas, gabarito, código da prova.
- Vazamento encontrado e corrigido: a fusão da situação escolar usava média e desvio de todas as linhas. Agora é refeita no treino de cada dobra (efeito medido: 0,003 ponto).

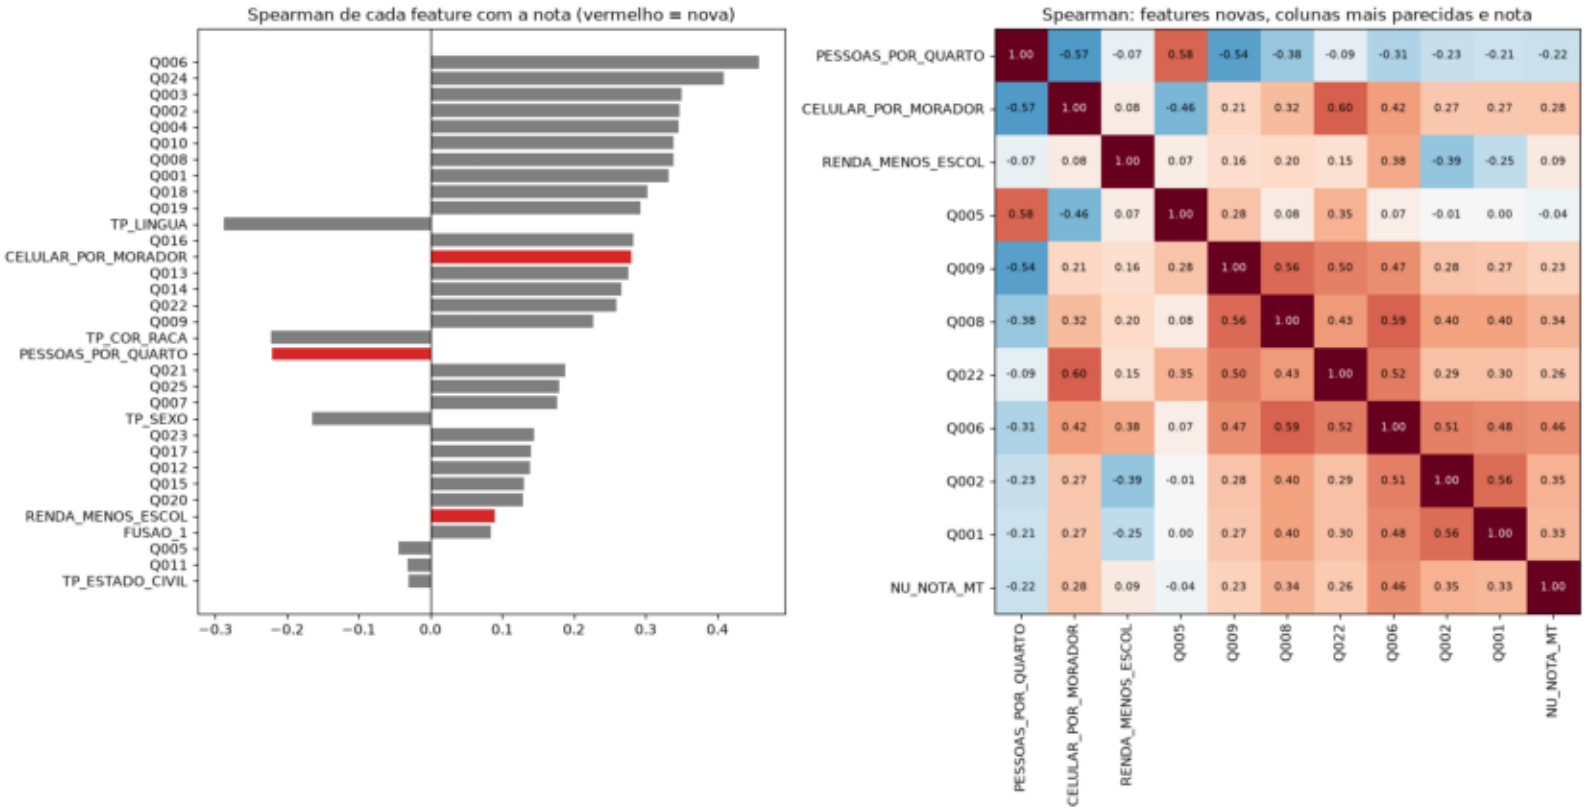
Preparação: o que está faltando e o que significa



Proporção de dados e de valores ausentes por coluna na base bruta.

- Escola: 73% de vazio entre quem tem nota. É quem já concluiu o ensino médio: vira "sem informação", não mediana.
- "Não sei" em Q001 a Q004 não é nível de escolaridade: vira ausente + indicador (quem não sabe tira 40 a 50 pontos a menos).
- Questionário em letras vira número pelo dicionário do Inep; sexo em 0/1.

Features criadas, com hipótese



Spearman de cada feature criada com a nota, com as colunas parecidas e matriz resumida.

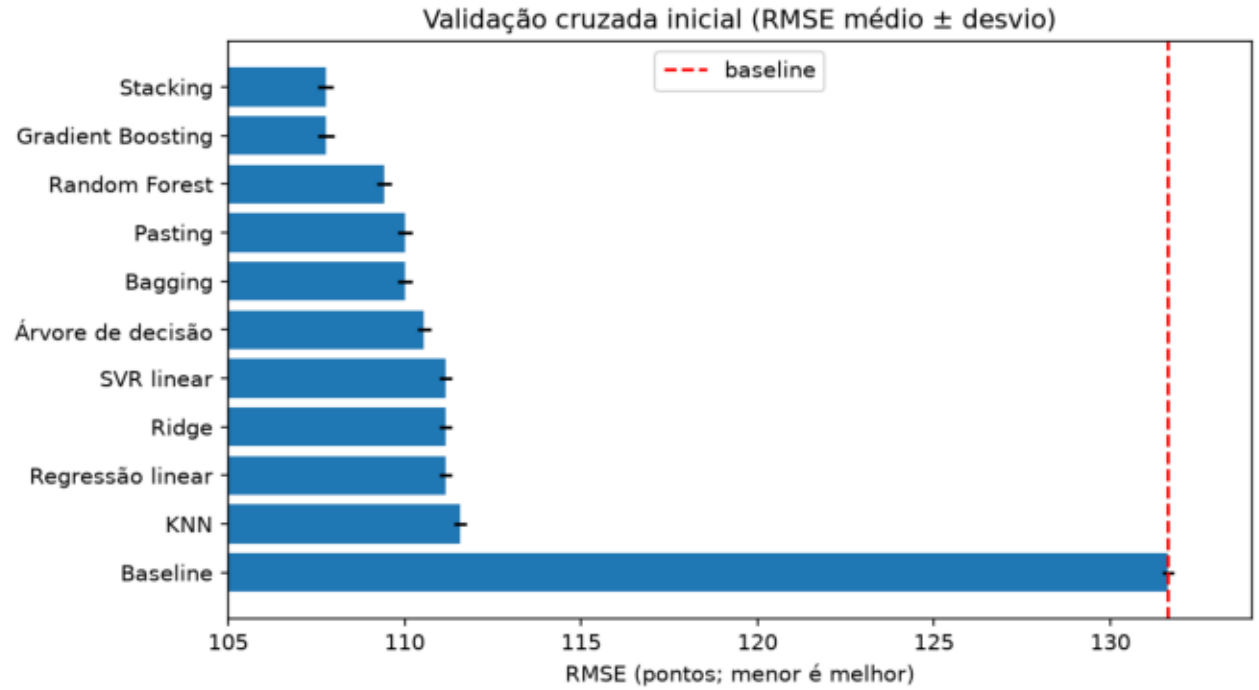
- PESSOAS_POR_QUARTO (−0,22): casa lotada, menos espaço para estudar.
- CELULAR_POR_MORADOR (+0,28): mais acesso próprio a conteúdo.
- RENDA_MENOS_ESCOL (+0,09): renda alta ou baixa para o nível de estudo da família.
- Todas com |Spearman| < 0,7 entre si e com as originais.

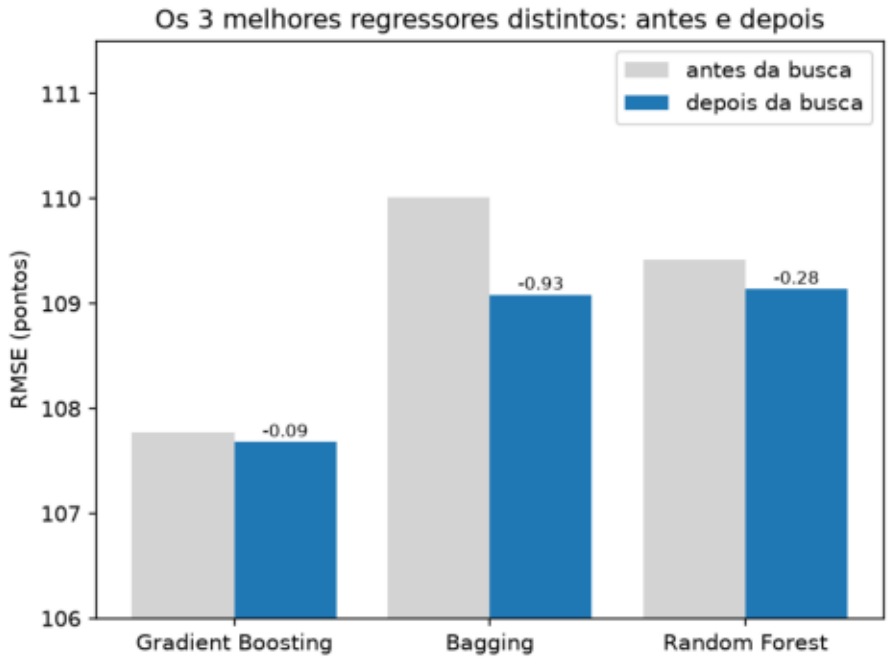
21 conjuntos de entrada avaliados

Grupo	Quantos	O que varia
Datasets salvos	8	Fusão da situação; escola; NAO_SEI e nacionalidade; 3 features criadas (30 a 45 colunas)
Variações no notebook 04	13	Fusão sem vazamento ou 4 colunas separadas; UF; sem features criadas; 3 cortes de seleção; 6 blocos retirados
Total com validação cruzada	21	Gradient Boosting em todos; regressão linear e bagging nos 8 datasets
Diagnósticos à parte	4	UF e idade desdobrada (não entram nos notebooks)

Melhor dataset salvo: dataset_3_escola_features (45 colunas): RMSE 107,05, 0,7 ponto melhor que o dataset 1. Mais colunas ajudam pouco.

Modelos: configuração inicial e busca de hiperparâmetros





Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento (dataset_1_fundido).

Validação cruzada, dataset de 30 colunas. Baseline 131,63 · regressão linear 111,15 · Gradient Boosting 107,77.

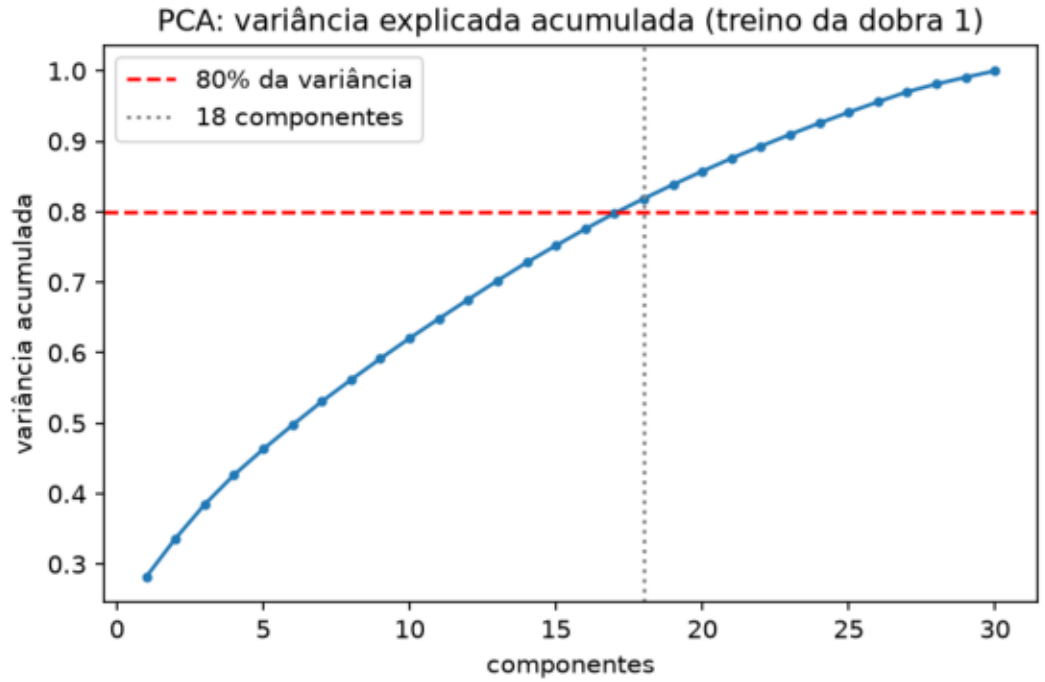
Gradient Boosting é o melhor; a busca só ajudou de fato o bagging.

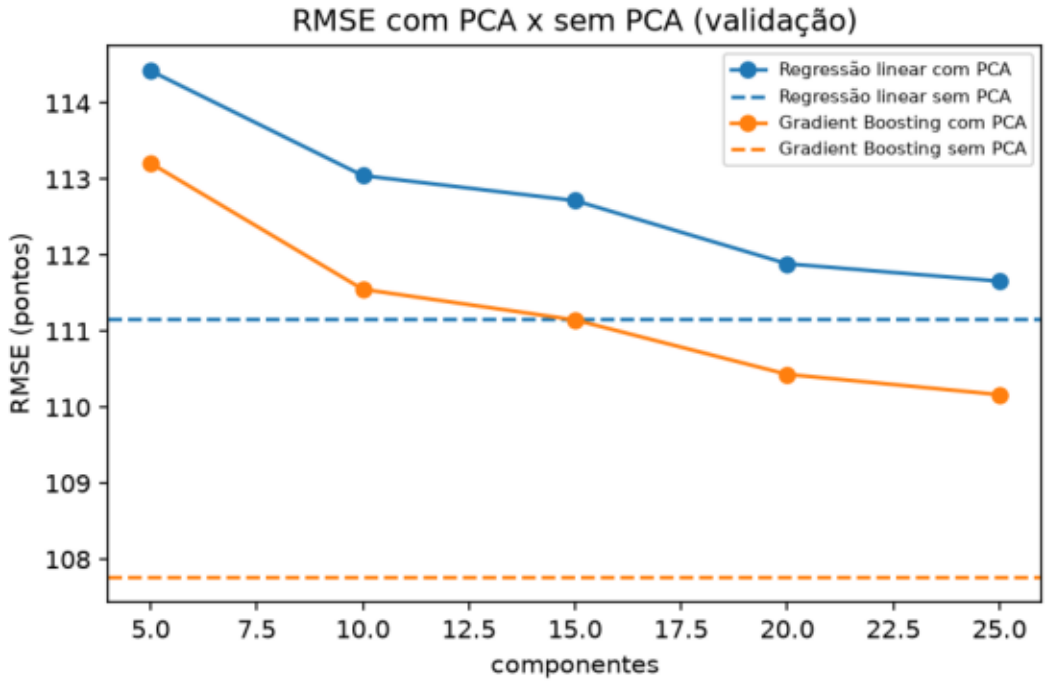
Resultados da configuração inicial

Modelo	RMSE (± desvio)	R^2	Tempo/dobra (s)
Gradient Boosting	**107,77 ± 0,23**	**0,330**	**133**
Stacking	107,76 ± 0,23	0,330	630
Random Forest	109,42 ± 0,20	0,309	103
Bagging / Pasting	110,01 ± 0,21	0,302	24 / 20
Árvore de decisão	110,55 ± 0,19	0,295	3
Regressão linear = Ridge = SVR linear	111,15 ± 0,18	0,287	0,3 a 2
KNN	111,58 ± 0,18	0,282	476
Baseline (média)	131,63 ± 0,16	0,000	0,06

Busca (RandomizedSearchCV, 10 configurações): bagging −0,93, Random Forest −0,28, Gradient Boosting −0,09 (dentro do desvio). Stacking empata e custa 5 vezes mais.

PCA: não ajudou





Fonte: Inep, ENEM 2023; desenvolvimento. PCA dentro do Pipeline, padronizado, reajustado em cada dobra.

18 de 30 componentes chegam a 80% da variância; nenhum corte supera o modelo sem PCA.

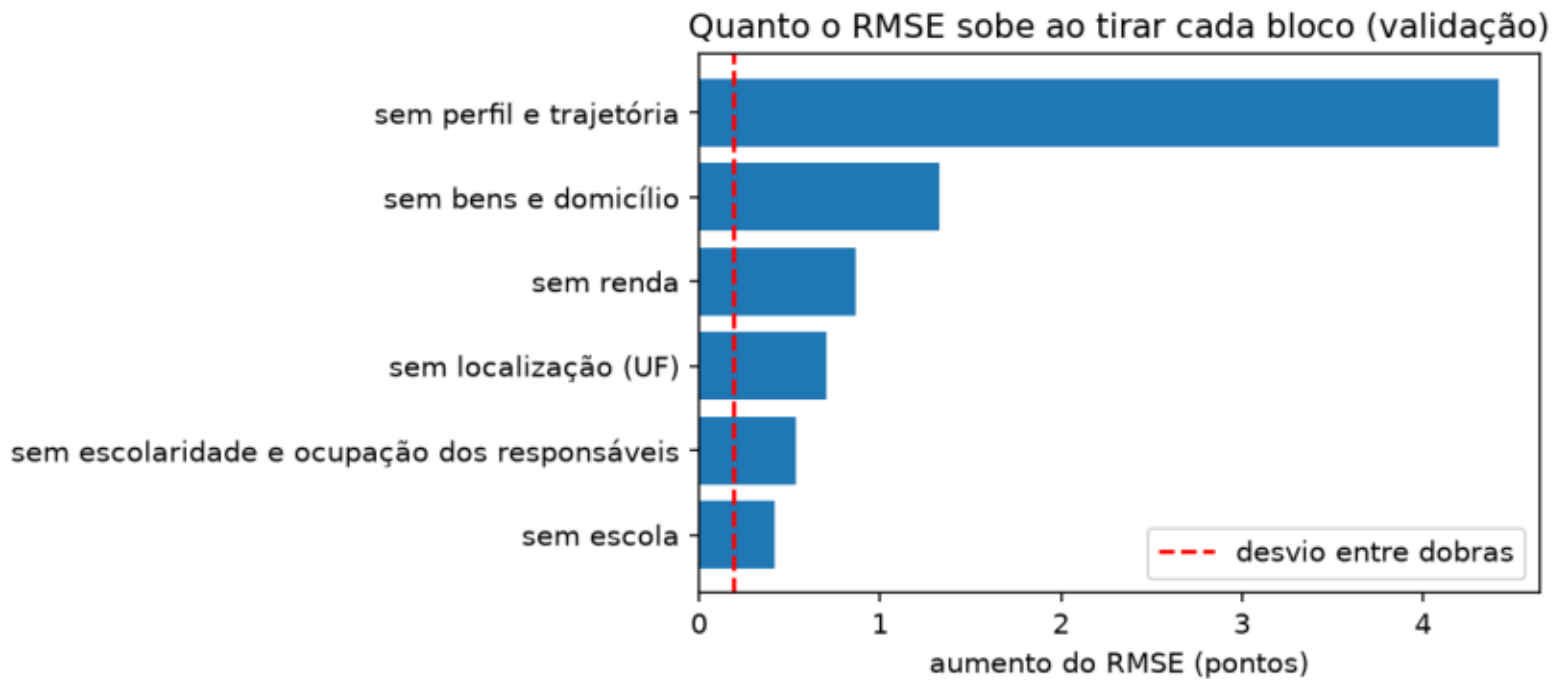
Os dados quase não se comprimem: com PCA o erro piora (GB 107,8 para 110,2 com 25 componen

Hipóteses de preparação (Gradient Boosting, validação cruzada)

Experimento	RMSE (± desvio)	Δ RMSE	Leitura
Fusão da situação escolar (só treino)	107,05 ± 0,19		referência
4 colunas de situação separadas	**106,73 ± 0,19**	**−0,33**	**melhora**
+ UF da prova (26 colunas)	**106,03 ± 0,19**	**−0,70**	**melhora**
Sem as 3 features criadas	106,04 ± 0,17	+0,01	sem diferença
SelectKBest, k = 51	107,07 ± 0,20	+1,04	piora
SelectKBest, k = 22	110,61 ± 0,19	+4,58	piora

Diferença só vale se passar do desvio entre dobras. Também sem efeito: tirar as notas zero do treino e K-means como feature.

Quanto vale cada bloco de informação

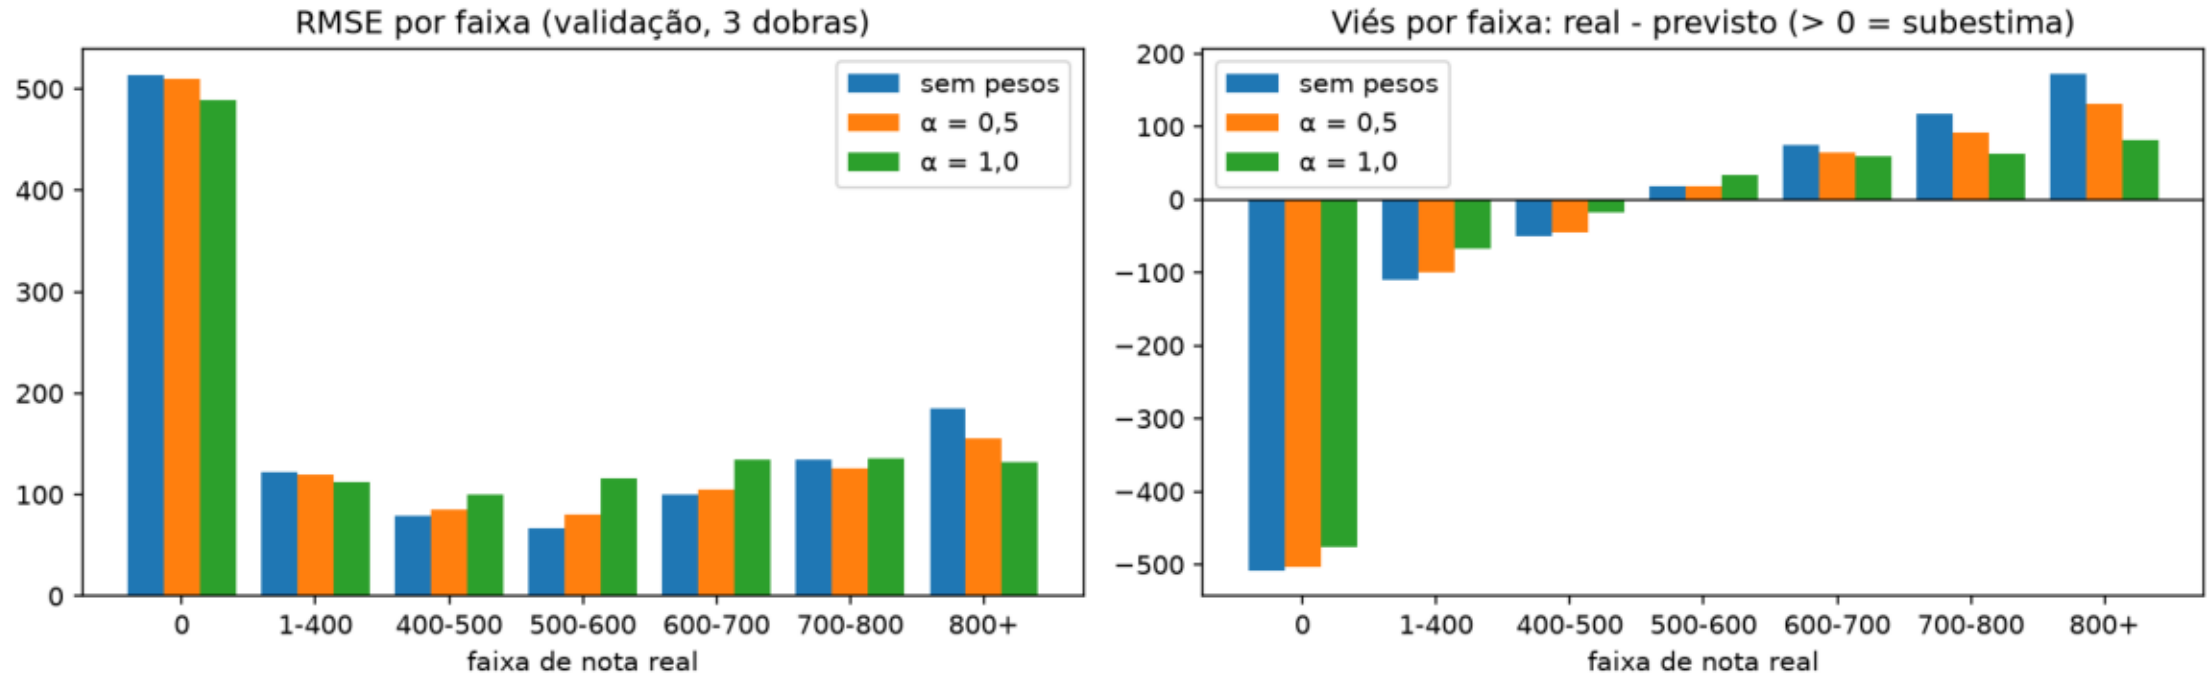


Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

RMSE sobe ao tirar um bloco por vez (linha vermelha: desvio entre dobras).

- Perfil e trajetória (sexo, idade, situação de conclusão, cor/raça, língua): +4,4.
- Bens e domicílio: +1,3. Renda: +0,9. UF: +0,7. Escolaridade e ocupação dos pais: +0,5. Escola: +0,4.
- Todos pioram o erro quando saem; os blocos se sobrepõem.

Balanceamento por ponderação de faixas



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Pesos n^(−α) por faixa de 50 pontos, calculados só no treino de cada dobra.

Peso nas faixas raras: as notas altas melhoram e as notas do meio pioram.

Balanceamento: o que ganhamos e o que perdemos

- Notas acima de 800: RMSE cai de 184,9 para 155,4 (α = 0,5) e 131,7 (α = 1,0); o viés cai de 172 para 81.
- Faixa de 500 a 600 (quase todos): RMSE sobe de 66,8 para 80,6 e 115,6.
- RMSE geral piora (+2,1 e +17,4): não adotado.
- É um compromisso de objetivo: identificar notas altas pede α = 0,5; erro médio pede nenhum peso.

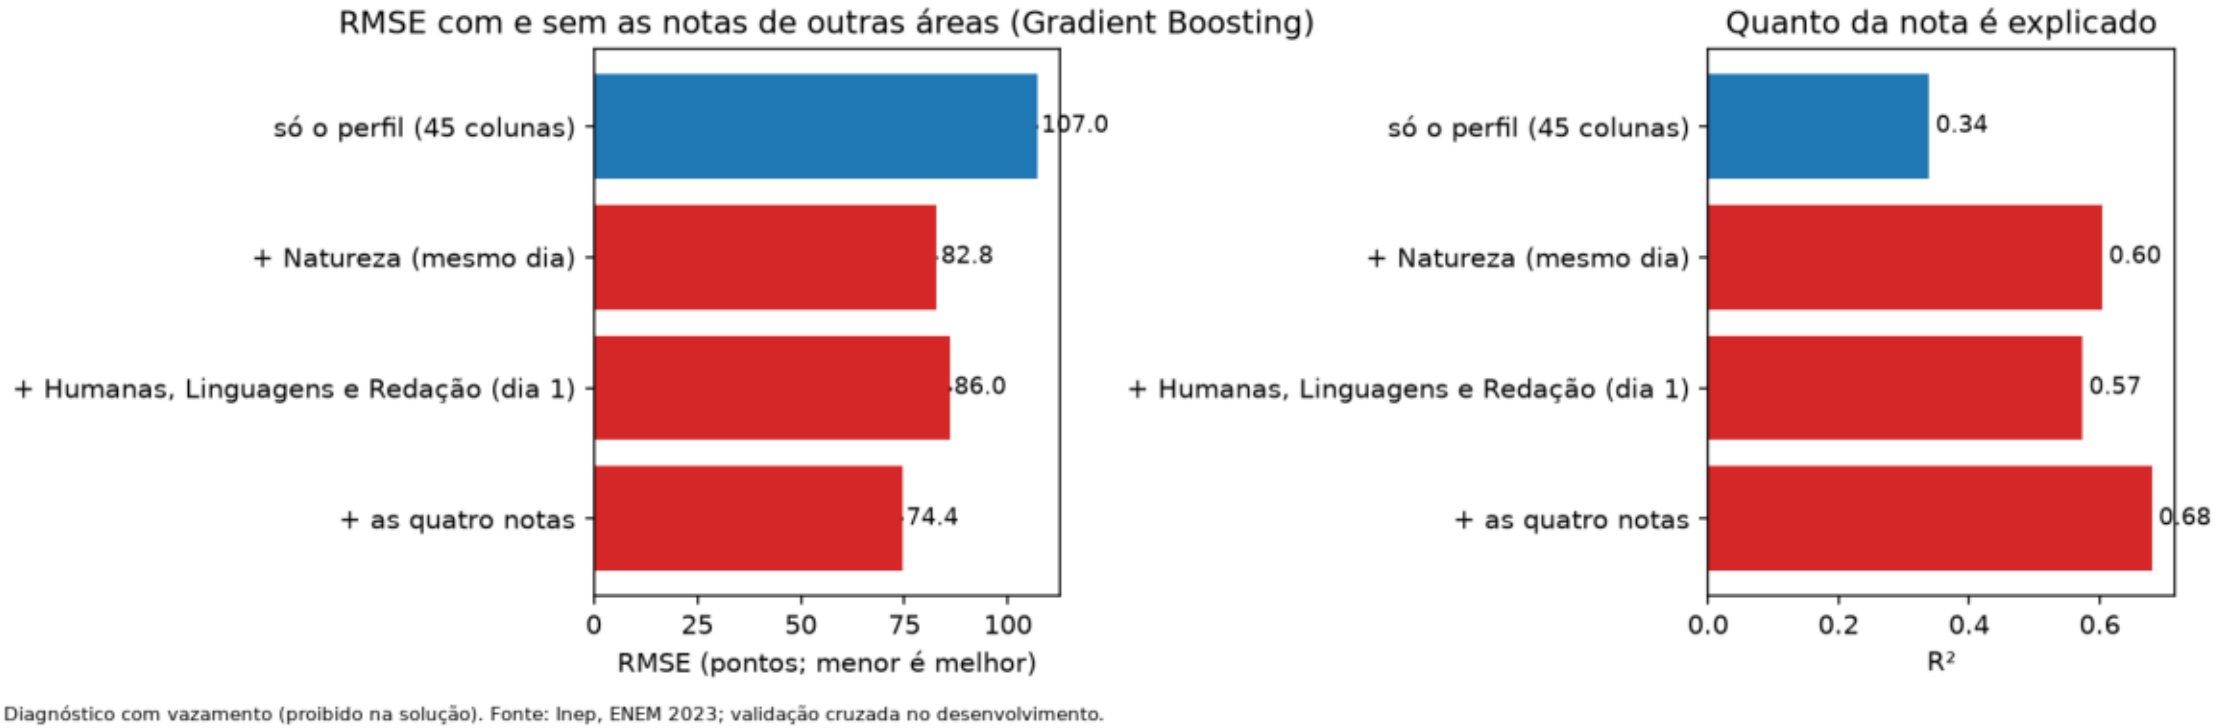
Peso nas pontas troca erro das notas altas por erro das notas médias.

Replicação independente: solução de outra IA (dataset 5)

Modelo	RMSE no teste	MAE	R^2
Nossa solução final (Gradient Boosting)	**105,81**	**82,00**	**0,354**
Ridge com one-hot de tudo (outra IA)	107,53	83,63	0,333
SVR linear (outra IA)	107,89	83,30	0,329
Gradient Boosting leve, 50 árvores (outra IA)	108,07	84,46	0,327
Random Forest, 30 árvores (outra IA)	108,13	84,32	0,326
Nossa regressão linear sem regularização	108,86	84,89	0,317

Mesmo teste (ids idênticos), sem validação cruzada do lado dela. O ganho dela está nos modelos lineares: one-hot + regularização, 1,3 ponto melhor que a nossa regressão linear. Nada foi escolhido a partir dela.

Diagnóstico: notas de outras áreas (fora da solução)

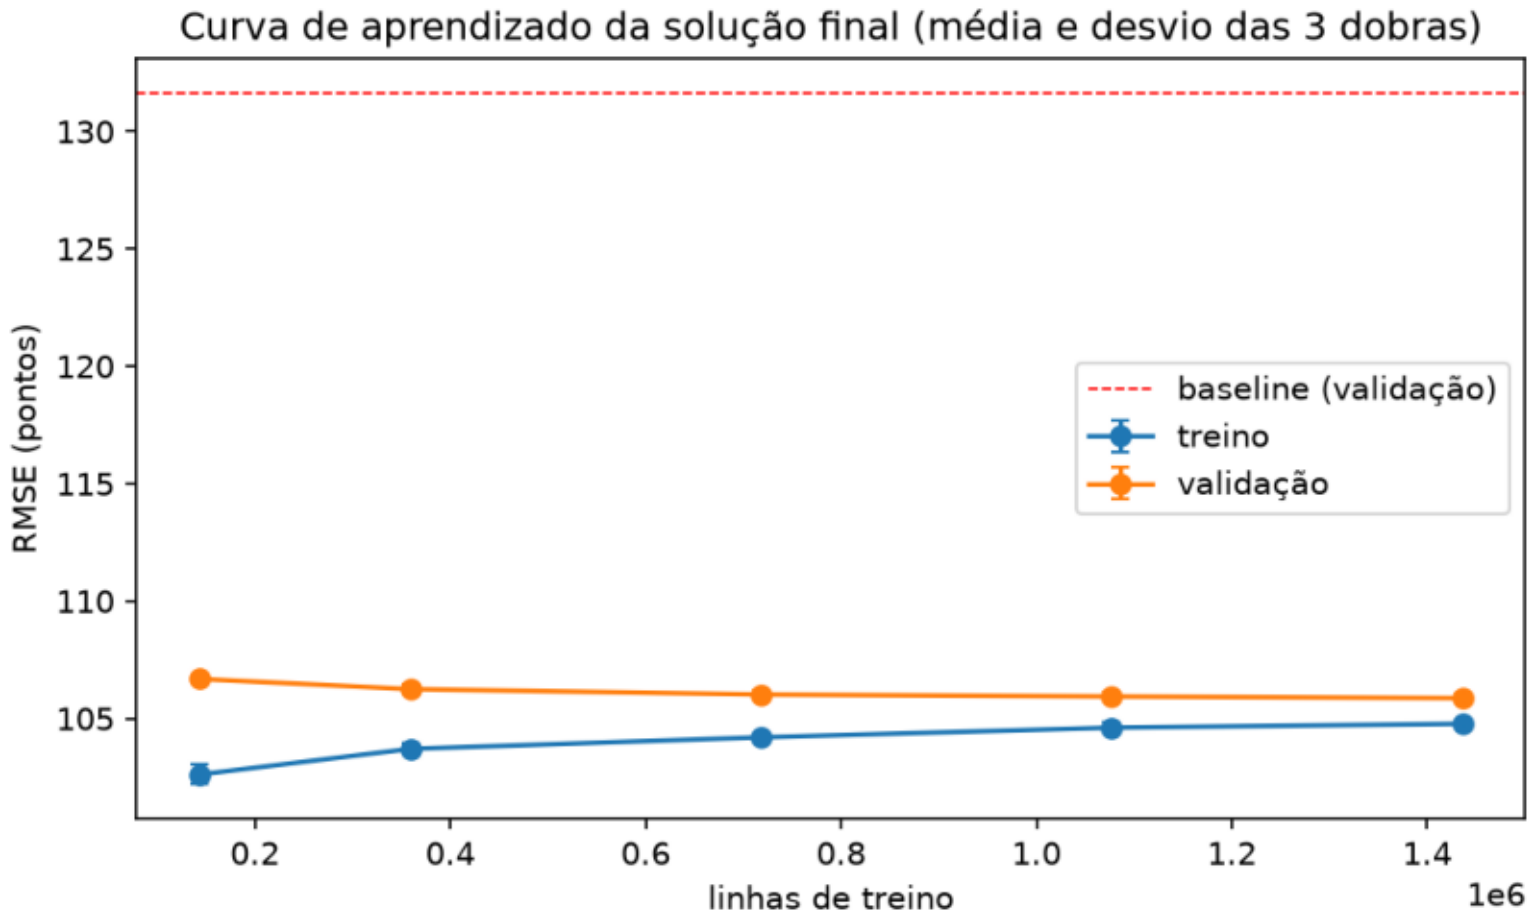


Diagnóstico com vazamento (proibido na solução). Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Dataset 6, só validação cruzada no desenvolvimento; o teste não foi aberto.

Proibido como entrada: só mede o vazamento. R² de 0,34 para 0,68.

Solução final e curva de aprendizado



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Treino e validação (média e desvio das 3 dobras) com 10%, 25%, 50%, 75% e 100% do treino da dobra.

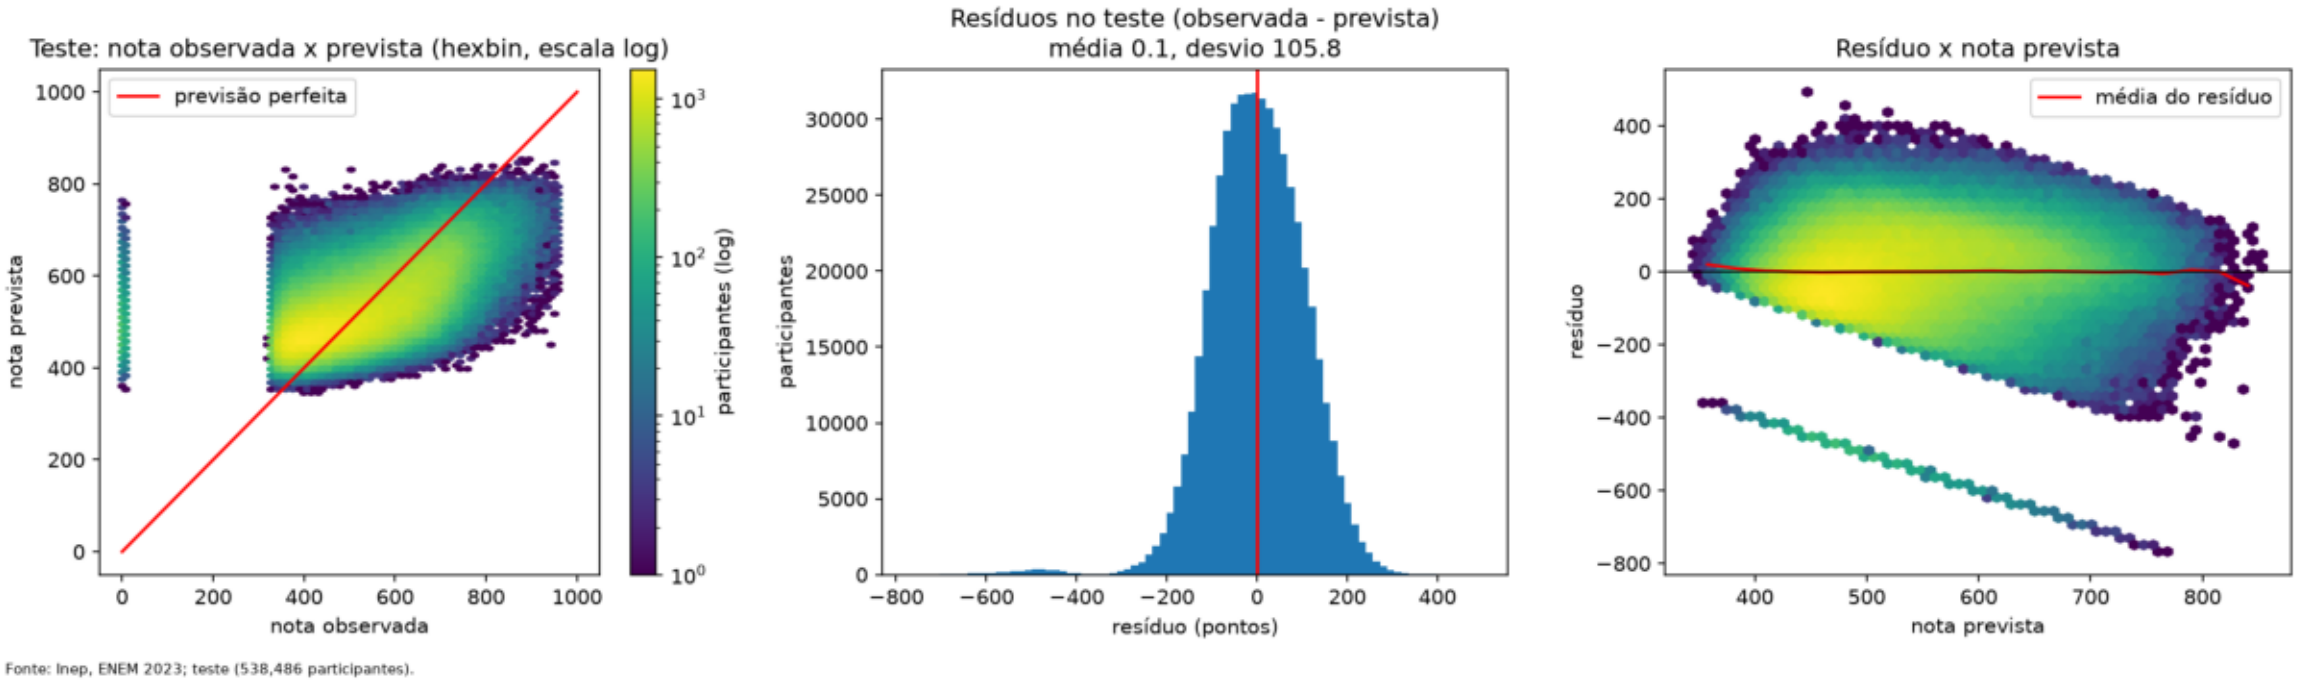
- Gradient Boosting com os hiperparâmetros da busca, 74 colunas, sem seleção, PCA nem pesos.
- Validação cruzada: RMSE 105,86 ± 0,17.
- Treino e validação separados por só 1,1 ponto; de 75% para 100%, ganho de 0,07.
- Sem sobreajuste forte; mais dados não resolveriam.

Teste final: aberto uma única vez

Modelo	CV RMSE (± desvio)	Teste RMSE	Teste MAE	Teste R^2
Baseline (média)	131,63 ± 0,16	131,70	107,64	0,000
Regressão linear sem regularização	108,87 ± 0,16	108,86	84,89	0,317
Solução final (Gradient Boosting)	**105,86 ± 0,17**	**105,81**	**82,00**	**0,354**

538.486 participantes. 19,7% menos erro que o baseline e 2,8% menos que a regressão linear. Teste e validação concordam (105,81 contra 105,86).

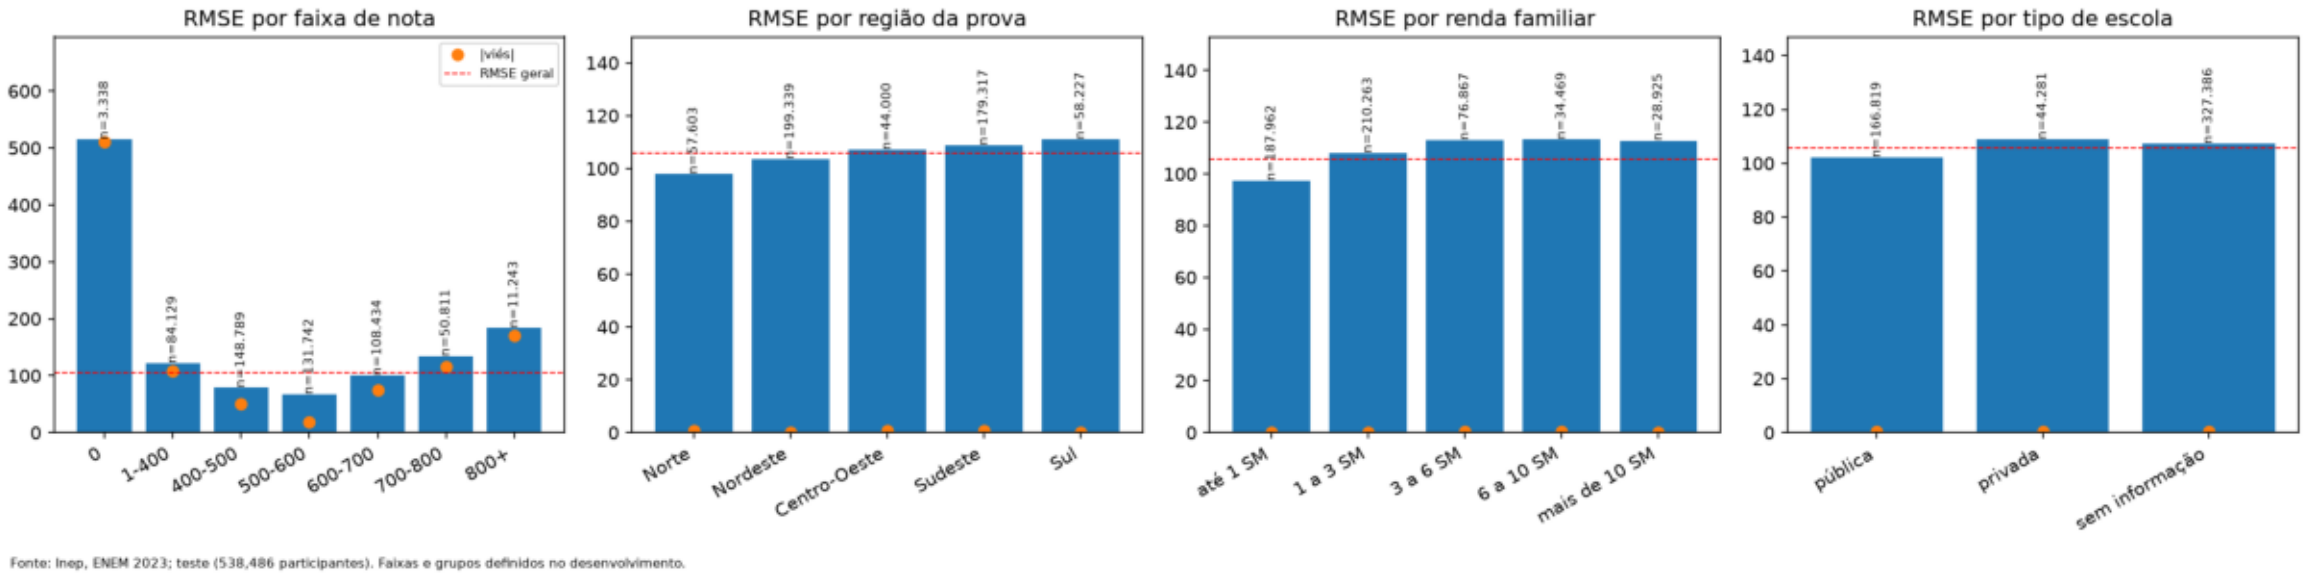
Teste: observada contra prevista e resíduos



538.486 participantes; dispersão agregada em células hexagonais; reta vermelha = previsão perfeita.

Regressão à média: previsões entre 350 e 850; os zeros viram resíduos de −370 a −770.

Erros por faixa de nota e por grupo



Fonte: Inep, ENEM 2023; teste (538,486 participantes). Faixas e grupos definidos no desenvolvimento.

RMSE no teste com o tamanho de cada grupo (n); laranja: |viés|.

Viés médio por grupo menor que 1 ponto; o erro cresce nas pontas da nota.

Conclusões e limites

- O perfil estima só a tendência: erro de 105,8 pontos e R^2 de 0,354 no teste. O limite é a informação, não o algoritmo.
- Ajudaram: modelo de árvores (−3,4), UF (−0,7), situação escolar sem fusão (−0,33), escola (−0,4). Não ajudaram: PCA, seleção, features criadas, sem zeros, K-means.
- Viés médio por grupo menor que 1 ponto; o erro maior está nas pontas (zeros: −510; acima de 800: +171).
- Limites: mesma edição (não vale para escolas ou municípios inéditos); UF e escola não são residência; uma só semente; associação não é causa.
- Próximo passo: município com codificação supervisionada dentro do Pipeline e busca na representação final.