Projeto 2

Aprendizado de Máquina com Dados do ENEM

Requisitos, entregas e avaliação da disciplina de Ciência de Dados

VÍNCULO CURRICULAR Unidade II - Aprendizado de Máquina	**FONTE DE DADOS** Inep / ENEM 2023 - base nacional completa
TAREFA Regressão de notas a partir do perfil dos participantes	**PRAZOS** Consultar o AVA, seção Avaliações

Desafio central. Investigar quanto o perfil socioeconômico, escolar e demográfico permite estimar uma nota do ENEM. Comparar escolhas de preparação e modelagem e explicar os resultados e os limites das previsões.

Sumário

Clique em um item para navegar pelo documento.

1. Contextualização e vínculo com a Unidade II

2. Objetivos do projeto

3. Temas e base de dados

4. Requisitos técnicos comuns

5. Organização do repositório e dos dados

6. Análise exploratória e modelagem

7. Acompanhamento obrigatório

8. Entregas

9. Critérios de avaliação

10. Artigo do projeto

11. Pitch presencial

12. Fontes e materiais de apoio

Apêndice A. Interpretação das variáveis

1. Contextualização e vínculo com a Unidade II

Cada equipe desenvolverá modelos de regressão para estimar uma nota do Exame Nacional do Ensino Médio (ENEM) 2023 a partir do perfil dos participantes e do questionário socioeconômico. Na regressão, o alvo é um valor numérico; as features são as variáveis de entrada usadas para estimá-lo. O trabalho reúne preparação dos dados, engenharia e seleção de features, comparação de modelos, redução de dimensionalidade e busca de hiperparâmetros.

A investigação deverá ser reproduzível e apresentar hipóteses, comparações e análise dos erros. Ganhos pequenos, ausência de melhoria e resultados contrários às expectativas também deverão ser discutidos. A avaliação considerará a qualidade do trabalho, sem ranking de equipes ou exigência de um R^2 mínimo.

Competências mobilizadas

- Interpretar o problema, as variáveis e os limites dos dados.
- Preparar e transformar os dados sem vazamento de informação.
- Comparar modelos com um protocolo de avaliação consistente.
- Comunicar métodos e resultados no acompanhamento, no artigo e no pitch final.

2. Objetivos do projeto

O objetivo é avaliar o potencial e os limites de estimar notas a partir do perfil dos participantes. Para isso, cada equipe deverá:

- Caracterizar as variáveis, a distribuição do alvo e os problemas de preparação.
- Criar e selecionar features e avaliar uma representação por PCA.
- Testar os modelos estudados em sala e ajustar os três melhores por busca de hiperparâmetros.
- Investigar uma estratégia de balanceamento da distribuição das notas.
- Analisar erros, subajuste e sobreajuste, justificar decisões e registrar experimentos reproduzíveis.

3. Temas e base de dados

Todas as equipes utilizarão o arquivo nacional completo do ENEM 2023. Cada equipe receberá um dos alvos abaixo; a distribuição será informada em sala de aula. Um alvo poderá ser atribuído a mais de uma equipe.

Tema	Variável alvo	O que estimar
Matemática	NU_NOTA_MT	Nota de Matemática e suas Tecnologias.
Ciências da Natureza	NU_NOTA_CN	Nota de Ciências da Natureza e suas Tecnologias.
Ciências Humanas	NU_NOTA_CH	Nota de Ciências Humanas e suas Tecnologias.
Linguagens	NU_NOTA_LC	Nota de Linguagens, Códigos e suas Tecnologias.
Redação	NU_NOTA_REDACAO	Nota total da redação.

Base completa e unidade de observação

Cada linha representa um participante do ENEM 2023. O arquivo MICRODADOS_ENEM_2023.csv contém 3.933.955 registros e deverá ser utilizado integralmente como fonte. Contabilizar todos os registros no diagnóstico; para a regressão, utilizar todos os participantes com nota observada no alvo atribuído, sem exigir as notas das outras áreas. Manter treineiros e diferentes faixas etárias. Não substituir a base por uma amostra por conveniência computacional.

Registros sem a nota alvo entram no diagnóstico, mas não no treinamento e na avaliação supervisionados. Nota ausente não poderá ser imputada nem convertida em zero. Informar a quantidade inicial, as exclusões justificadas e o total utilizado. Os subconjuntos das curvas de aprendizado e da visualização opcional por t-SNE têm finalidade diagnóstica; não substituem a base utilizada na comparação principal e no ajuste final.

Redação. Os microdados não incluem o texto nem a imagem das redações dos participantes. O espelho divulgado pelo Inep é de consulta individual. A equipe desse tema estimará a nota pelas informações tabulares de perfil, sem precisar processar textos ou imagens. A fonte está na Seção 12.

Notas zero

Nota zero é um resultado observado e difere de nota ausente. A equipe poderá investigar sua influência, sem obrigação de excluir esses registros. Se testar o treinamento sem zeros, deverá compará-lo com o treinamento que os inclui, usando o mesmo modelo e mantendo os mesmos participantes, inclusive os zeros, na validação e no teste. A exclusão experimental ocorrerá somente no treino de cada dobra; registrar sua justificativa e seus efeitos gerais e por faixa de nota.

Não é necessário conhecer a nota do participante para aplicar um modelo treinado sem zeros: ele continuará prevendo a nota de todos os participantes. Já uma avaliação restrita às notas positivas descreve outra população e não comprova melhoria na tarefa original. Presença e situação da redação podem apoiar esse diagnóstico, mas não serão features nem regras para selecionar participantes na previsão. Não excluir registros porque o modelo errou muito neles.

Features candidatas

O arquivo principal tem 76 colunas, incluindo entradas candidatas, identificadores, resultados e informações que não poderão entrar nos modelos. A tabela apresenta os grupos candidatos; consultar o dicionário de 2023 para a relação completa, os códigos e as ausências. A equipe deverá registrar quais colunas usou, criou e removeu, com justificativas.

Grupo	Exemplos de informações e colunas	Cuidados
Perfil demográfico	Faixa etária (TP_FAIXA_ETARIA), sexo, cor ou raça, estado civil e nacionalidade.	Interpretar categorias e não informação pelo dicionário.
Situação escolar	Conclusão do ensino médio, ano de conclusão, tipo de escola e ensino; IN_TREINEIRO.	Códigos não são medidas contínuas; verificar ausências.
Contexto da escola	Dependência administrativa, localização urbana ou rural e situação de funcionamento.	Verificar a cobertura; o arquivo não fornece identificador da escola.

Grupo	Exemplos de informações e colunas	Cuidados
Localização	UF e município da escola e de realização da prova; por exemplo CO_MUNICIPIO_PROVA.	Usar códigos como categorias; nomes e códigos podem ser redundantes.
Língua estrangeira	Opção por inglês ou espanhol (TP_LINGUA).	Representa a opção do participante, não sua proficiência.
Questionário socioeconômico	Q001 a Q025: escolaridade e ocupação dos responsáveis, moradores, renda, bens e acesso digital.	Distinguir categorias, ordinais e contagens; ver o Apêndice A.

Entradas dos modelos e prevenção de vazamento

Vazamento de informação ocorre quando a preparação ou o modelo utiliza informações que deveriam permanecer indisponíveis na previsão ou na avaliação. Para esta tarefa, as entradas devem descrever o perfil e o contexto do participante, respeitando estas regras:

- Excluir de X todas as notas do ENEM, inclusive as de outras áreas, as competências da redação, respostas, gabaritos e demais informações produzidas pela correção. A nota atribuída à equipe compõe apenas o alvo y.
- Não usar presença (TP_PRESENCA_*) nem situação da redação (TP_STATUS_REDACAO) como features. Esses campos servem somente ao diagnóstico da disponibilidade das notas e à interpretação dos resultados.
- Usar NU_INSCRICAO apenas para controlar registros e partições. NU_ANO é constante nesta edição e não acrescenta informação para distinguir participantes.
- Outros campos, como códigos de prova, não são automaticamente preditores adequados por não conterem notas. Sua inclusão deverá ser justificada pelo significado no dicionário, pela pertinência ao problema e pela disponibilidade no contexto da estimativa.

Dados externos

É permitido integrar dados de qualquer fonte confiável, desde que a fonte seja citada e os indicadores se refiram ao mesmo ano de referência, 2023, e à área geográfica correspondente. Por exemplo, um indicador municipal deve ser associado ao código do município que ele descreve. Município de prova e município da escola não devem ser interpretados como residência.

Registrar a fonte, o ano, a chave de junção, a cobertura e as perdas de correspondência. A integração deve preservar uma linha por participante e respeitar as regras de prevenção de vazamento, inclusive para estatísticas calculadas a partir de notas.

4. Requisitos técnicos comuns

Dimensão	Mínimo obrigatório	Evidência esperada
Preparação e exploração	Analisar tipos, ausências, categorias, duplicatas e distribuição da nota no desenvolvimento.	Regras de tratamento e gráficos que orientem a modelagem.
Modelos	Baseline pela média e todos os regressores indicados na Seção 6.	Comparação inicial pela mesma validação cruzada.

Dimensão	Mínimo obrigatório	Evidência esperada
Engenharia e seleção	Criar ao menos três features e testar um método de seleção.	Justificativa e comparação com a representação inicial.
Redução	Testar PCA em pelo menos dois regressores e justificar o número de componentes.	Variância explicada e comparação com os modelos sem PCA.
Balanceamento	Testar uma estratégia de reamostragem ou ponderação adequada à regressão.	Efeitos nas métricas gerais e nos erros por faixa de nota.
Hiperparâmetros	Aplicar GridSearchCV ou RandomizedSearchCV aos três melhores regressores iniciais, com pelo menos dez configurações válidas por modelo e validação cruzada de três dobras.	Espaço de busca, critério de seleção e resultados.
Avaliação	Reportar RMSE, MAE e R^2; analisar resíduos, faixas de nota e um grupo de perfil ou localização.	Tabelas e gráficos com tamanhos dos grupos e interpretação dos erros.
Diagnóstico do ajuste	Produzir a curva de aprendizado do modelo final e discutir subajuste e sobreajuste.	RMSE de treino e validação para cinco tamanhos de treino.
Reprodutibilidade	Registrar código, dependências, sementes, partições e experimentos.	Execução documentada no GitHub e resultados associados ao código.

Qualquer modelo ou método utilizado que não tenha sido apresentado em sala deverá ser explicado brevemente: como funciona, por que foi escolhido e quais decisões ou parâmetros afetam sua aplicação. Incluir a referência correspondente.

Protocolo de avaliação

Desenvolvimento é o conjunto usado para explorar os dados, comparar alternativas e escolher a solução. Teste é o conjunto reservado à avaliação final. Seguir esta sequência:

1. Separar aleatoriamente os participantes com nota alvo observada: 80% para desenvolvimento e 20% para teste, com random_state=42. A semente fixa permite reproduzir a divisão. Guardar os identificadores de cada conjunto; eles não serão entradas do modelo.
2. Nos 80% de desenvolvimento, usar validação cruzada de três dobras: dividir os registros em três partes e, em cada rodada, treinar em duas e validar na terceira. Usar KFold(n_splits=3, shuffle=True, random_state=42) e manter as mesmas dobras nas comparações. Não criar outra parcela fixa de validação.
3. Comparar as configurações iniciais pelo RMSE médio nas três dobras. Escolher os três melhores regressores distintos, sem contar o baseline, para GridSearchCV ou RandomizedSearchCV, com pelo menos dez configurações válidas por regressor. Não selecionar três configurações do mesmo regressor como se fossem três modelos.
4. Escolher a solução apenas pelos resultados do desenvolvimento. Reajustar suas transformações e seu regressor nos 80% completos; a busca pode fazer esse reajuste automaticamente com refit=True. Ajustar também o baseline e a regressão linear sem regularização nesse conjunto.
5. Avaliar no teste reservado o baseline, a regressão linear sem regularização e a solução final, nos mesmos participantes. Não usar o teste para escolher features, técnicas, hiperparâmetros ou o tamanho do treino. Produzir seus gráficos somente após fixar a solução; não retomar a seleção com base nesses resultados.

Pipeline e prevenção de vazamento entre as dobras

O módulo sklearn.pipeline.Pipeline automatiza uma sequência de preparação e modelagem, como imputação, codificação, padronização, seleção, PCA e regressor. Passar o pipeline completo à validação cruzada e às buscas faz com que essas etapas sejam ajustadas novamente apenas na parte de treino de cada dobra e depois aplicadas à validação. Ajustar uma transformação em todo o desenvolvimento antes da validação cruzada produz vazamento, mesmo que o regressor esteja em um pipeline.

Aplicar a mesma regra a estatísticas por categoria, codificação supervisionada, clusterização e outras transformações aprendidas com os dados. A reamostragem altera linhas e exige uma implementação compatível, restrita ao treino de cada dobra; não é uma transformação comum que se aplique também à validação. Se houver parada antecipada, usar uma parcela interna do treino da dobra, preservando sua validação para avaliação. Nunca usar o teste nessa decisão.

Usar RMSE como métrica principal, MAE e R^2 como complementares e registrar tempos. RMSE e MAE expressam o erro em pontos da nota; valores menores são melhores. R^2 indica a qualidade do ajuste relativamente à variabilidade das notas e pode ser negativo. Calcular tudo na escala original, mesmo se o alvo for transformado no ajuste. Informar média e desvio padrão entre as dobras; o resultado de teste é separado dessa média.

Usar a semente 42 também nas operações aleatórias que aceitem random_state e registrar as configurações. Comparar alternativas nas mesmas dobras e registrar resultados sem melhoria. A divisão principal avalia novos participantes da mesma edição; ela não demonstra generalização para escolas ou municípios inéditos.

Os estimadores tradicionais do scikit-learn adotados no projeto utilizam CPU. Planejar memória, representações e paralelismo de acordo com o volume; registrar tempos e limites encontrados. A reamostragem de treinamento e as subamostras internas de bagging e pasting são experimentos ou mecanismos dos algoritmos e não substituem a base nacional por um recorte de conveniência.

5. Organização do repositório e dos dados

O repositório GitHub deverá separar os dados originais, o código, os experimentos e os resultados. A estrutura abaixo pode ser adaptada, mantendo os itens indicados.

```
projeto-2/
  README.md
  requirements.txt
  dados/
    raw/              # dados originais ou instruções de obtenção
    processed/        # dados preparados
    splits/           # identificadores das partições
  notebooks/          # exploração e experimentos
  src/                # preparação e treinamento
  resultados/
    experimentos.csv
    previsoes_teste.csv
    figuras/
  docs/
    acompanhamento.pdf
    artigo.pdf
    pitch.pdf
  .gitignore
```

- No README, apresentar o alvo, as fontes, as features utilizadas, o ambiente e a ordem de execução. Documentar como obter arquivos grandes sem depender de caminhos pessoais.
- Preservar os dados originais. Gerar transformações por código e registrar as colunas criadas, selecionadas e removidas. Salvar a divisão desenvolvimento/teste e as dobras em dados/splits/. Arquivos grandes podem ser obtidos pelas instruções, sem serem enviados ao GitHub.
- Em experimentos.csv, registrar hipótese, features, preparação, modelo, parâmetros, conjunto avaliado, métricas por dobra, média, desvio padrão, tempo e conclusão. Distinguir a validação cruzada no desenvolvimento do teste final.
- Em previsoes_teste.csv, guardar o identificador de controle, a nota observada e as previsões dos modelos avaliados no teste.

6. Análise exploratória e modelagem

Preparação e engenharia de features

Explorar o desenvolvimento para entender ausências, códigos, categorias e distribuição das notas; manter o teste reservado. Diferenciar desconhecimento, não informação e ausência; distinguir nota zero de nota não observada. Justificar a codificação de escolaridade, ocupação, renda e bens domésticos com base no dicionário.

Criar pelo menos três features com hipóteses claras. Exemplos incluem recursos por morador, combinações de escolaridade dos responsáveis e indicadores de acesso digital. Faixas de renda e contagens limitadas exigem que aproximações e denominadores inválidos sejam explicitados. Comparar as features originais, as novas features e o resultado da seleção de atributos.

Regressores obrigatórios

O baseline é uma referência simples para interpretar o erro: usar DummyRegressor(strategy='mean'), que aprende a média do alvo no treino e prevê esse mesmo valor para todos, sem usar as features. Se a média for 550, todas as previsões serão 550. Recalcular essa média no treino de cada dobra e, para o teste final, nos 80% de desenvolvimento; nunca usar a média do teste.

Além do baseline, treinar todos os modelos ou famílias abaixo. Na regressão linear, testar as duas versões; nas demais famílias, basta uma implementação, podendo investigar variantes. Registrar as configurações iniciais antes das buscas. Todos os modelos serão regressores.

Modelo ou família	O que testar
Regressão linear	Sem regularização e com regularização, como Ridge ou Lasso.
SVM	SVR com kernel linear, RBF, polinomial ou outro pertinente. A escolha do kernel deverá ser justificada; LinearSVR também é permitido.
Árvore de decisão	DecisionTreeRegressor.
KNN	KNeighborsRegressor.
Bagging	Combinação de modelos treinados em amostras com reposição, por exemplo BaggingRegressor com bootstrap=True.
Pasting	Combinação de modelos treinados sem reposição dentro de cada subamostra, por exemplo BaggingRegressor com bootstrap=False e uma fração max_samples menor que 1.
Random Forest	RandomForestRegressor, comparado também ao bagging.
Boosting	Ao menos um: AdaBoostRegressor, GradientBoostingRegressor, HistGradientBoostingRegressor, XGBoost, LightGBM ou CatBoost. Não é obrigatório usar todos.
Stacking	Combinação de pelo menos dois regressores diferentes e um modelo final. Treinar o combinador com previsões fora da dobra: cada previsão deve vir de um modelo de base que não treinou naquele participante.

Exemplo de pasting. Com bootstrap=False e max_samples=0.7, cada estimador recebe 70% das linhas disponíveis no treino, sem repetir uma linha dentro dessa subamostra. Os subconjuntos de estimadores diferentes podem compartilhar participantes. Com max_samples=1.0, todos recebem todas as linhas, o que não cria diversidade pela seleção dos exemplos.

Outras implementações dessas famílias poderão ser utilizadas, respeitando a exigência de explicação dos métodos não vistos em sala. Para stacking, o pré-processamento dos modelos de base também deve ser ajustado dentro de cada dobra. Redes neurais ficam fora do escopo.

Redução de dimensionalidade

Aplicar PCA após o tratamento e a codificação das features, justificando a padronização e o bloco de atributos utilizado. Escolher e justificar o número de componentes; sugere-se preservar ao menos 80% da variância explicada no treino. É permitido usar IncrementalPCA para processar todas as linhas de treino em lotes. Ajustar a redução novamente dentro de cada dobra da validação cruzada.

Comparar a representação com PCA e a representação sem redução em pelo menos dois regressores. Os componentes podem substituir as features ou ser acrescentados a elas; indicar a escolha e avaliar seus efeitos. Acrescentá-los às features originais cria atributos, mas não reduz a dimensão final. Opcionalmente, utilizar t-SNE com dois componentes para visualização, com uma subamostra documentada do desenvolvimento. Essa visualização não substitui o experimento com PCA.

Balanceamento na regressão

Verificar se faixas de nota pouco frequentes concentram erros. Testar pelo menos uma estratégia adequada à regressão: undersampling, reduzindo exemplos de faixas frequentes; oversampling, repetindo exemplos de faixas raras; ou ponderação, atribuindo pesos maiores às faixas de interesse em um regressor compatível. As faixas orientam o treino; o alvo continua sendo a nota numérica original, e não uma classe.

Definir limites de faixas e pesos a partir do treino de cada dobra, sem usar suas notas de validação. Reamostrar apenas as linhas de treino, preservando os alvos numéricos associados; manter a distribuição original na validação e no teste. Não aplicar diretamente técnicas de classificação, como SMOTE clássico, ao alvo contínuo. Comparar o mesmo regressor com e sem a estratégia e discutir efeitos gerais e por faixa, inclusive pioras.

Busca e análise dos resultados

Aplicar as buscas aos três melhores regressores da comparação inicial, conforme o protocolo da Seção 4. Justificar hiperparâmetros e intervalos; apresentar RMSE, MAE e R^2 médios e seus desvios padrão nas três dobras, além do tempo de execução. Comparar antes e depois da busca. A solução final poderá ser a configuração mais precisa ou uma alternativa mais simples com desempenho semelhante, desde que essa escolha seja sustentada pela validação cruzada.

Apresentar gráficos da distribuição do alvo, dos problemas de preparação e das relações relevantes com features. Analisar resíduos (nota observada menos nota prevista), erros por faixa de nota e por pelo menos um grupo, como estado, renda ou tipo de escola, informando o número de participantes. Usar o desenvolvimento durante a investigação; os gráficos de teste serão produzidos após fixar a solução final.

Curva de aprendizado e diagnóstico do ajuste

Produzir obrigatoriamente a curva de aprendizado do modelo final com sua configuração já escolhida. O eixo horizontal mostra a quantidade de exemplos de treino, e o vertical, o RMSE de treino e de validação. Usar 10%, 25%, 50%, 75% e 100% das linhas disponíveis para treinamento em cada uma das três dobras. Esses percentuais se referem ao treino da dobra, não à base nacional nem ao teste. Curvas de outros modelos são opcionais.

Manter a validação de cada dobra fixa e selecionar subconjuntos aleatórios e progressivos de seu treino, com semente 42. Para cada tamanho, reajustar todo o pipeline, mantendo a configuração do regressor; executar também a estratégia de treinamento escolhida, se houver. Mostrar a média e o desvio padrão do RMSE nas três dobras. A função sklearn.model_selection.learning_curve pode automatizar esse diagnóstico. Não usar o teste nem ajustar novamente os hiperparâmetros a cada ponto.

Discutir subajuste (underfitting) e sobreajuste (overfitting) nos resultados: erro de treino baixo e erro de validação maior podem indicar sobreajuste; erros altos e próximos podem indicar subajuste, mas também falta de informação nas features ou variabilidade não explicada pelos dados. Relacionar esses indícios às curvas, aos modelos e à complexidade. Não concluir que existe subajuste apenas porque o R^2 é baixo, nem supor que mais dados ou um modelo mais complexo sempre resolverão o problema.

Possibilidades de aprofundamento

Escolher hipóteses que ajudem a explicar os resultados. O critério de aprofundamento valoriza comparações bem justificadas, inclusive sem ganho preditivo. Para a pontuação integral, investigar pelo menos duas hipóteses além do mínimo. Algumas perguntas possíveis são:

- Quais blocos de informação contribuem mais? Retirar, um de cada vez, renda, escolaridade, bens ou localização e medir a mudança no erro.
- O tratamento das categorias faz diferença? Comparar codificações ou formas de representar desconhecimento, categorias raras e ausência de informação.
- As interações ajudam? Combinar renda e moradores, acesso digital e escolaridade, ou outros atributos com uma justificativa ligada ao contexto.
- A localização acrescenta informação? Comparar modelos com e sem município ou estado; investigar um modelo nacional e modelos regionais com avaliação nos mesmos participantes.
- Dados externos melhoram a descrição do contexto? Integrar indicadores confiáveis de 2023 e medir sua contribuição em relação ao modelo sem esses indicadores.
- Existem perfis semelhantes? Ajustar uma clusterização no treino e testar distâncias aos grupos como features, interpretando os perfis encontrados.
- Os erros nas notas extremas podem ser reduzidos? Investigar transformações do alvo ou funções de perda e avaliar o efeito nas demais faixas.
- É possível manter o desempenho com uma solução mais simples? Reduzir features, componentes ou complexidade do regressor e comparar erro, tempo e, quando possível, memória. Preservar as métricas com menor custo também representa melhoria; considerar a variação entre dobras ao interpretar diferenças pequenas.

Executar o PCA, a seleção ou a curva obrigatória não caracteriza, por si só, aprofundamento: é necessário investigar uma hipótese adicional. Alterar apenas a semente ou ampliar uma busca sem uma hipótese também não basta. Associações entre perfil e nota devem ser interpretadas sem atribuir causalidade ou determinar a capacidade individual dos participantes.

7. Acompanhamento obrigatório

Realizar uma apresentação breve do andamento do projeto, com participação de todos. Utilizar slides com explicações e gráficos; mostrar somente código não atende à entrega. A apresentação deverá conter:

- Descrição rápida da base completa, dos registros com nota observada e do alvo da equipe.
- Features utilizadas e principais decisões de tratamento ou criação de atributos.
- Resultados preliminares do baseline pela média e de pelo menos um regressor na validação cruzada do desenvolvimento, com gráficos e uma interpretação inicial.
- Próximos experimentos e dúvidas que a equipe pretende investigar.

Disponibilizar os slides em PDF e o código no GitHub. Não avaliar o teste nessa etapa. O professor poderá solicitar explicações sobre as decisões e a participação de cada integrante.

Prazo. Consultar o AVA, seção Avaliações.

8. Entregas

Entrega	Formato e conteúdo
Acompanhamento	Apresentação do andamento, com slides, descrição dos dados e features e resultados preliminares com gráficos, conforme a Seção 7.
Repositório GitHub	Código, dependências, README, partições, registro de experimentos, previsões e gráficos. Incluir instruções para obtenção dos dados e reprodução dos resultados.
Artigo do projeto	PDF de até dez páginas no padrão ABNT, incluindo figuras, tabelas e referências, conforme a Seção 10.
Pitch presencial	Apresentação final de 10 a 15 minutos, com participação de todos e slides em PDF, conforme a Seção 11.

O repositório deverá estar acessível ao professor e conter o artigo e os slides do acompanhamento e do pitch. As datas de entrega serão disponibilizadas no AVA, seção Avaliações.

9. Critérios de avaliação

A nota totaliza 10,0 pontos: 2,0 para acompanhamento, 5,0 para a solução técnica, incluindo o repositório e o artigo, e 3,0 para o pitch. O desempenho preditivo será analisado no contexto dos experimentos, sem pontuação por ranking ou por atingir uma métrica predeterminada.

Pilar	Critério	Pontos	Total do pilar
Acompanhamento	Apresentação dos dados, features e resultados preliminares	1,50	2,00
	Engajamento e proatividade	0,25	
	Colaboração e participação	0,25	
Solução técnica e artigo	Preparação e análise exploratória	0,60	5,00
	Protocolo de avaliação e prevenção de vazamento	0,60	

Pilar	Critério	Pontos	Total do pilar
	Engenharia, seleção, PCA e balanceamento	0,80	
	Modelos obrigatórios e busca nos três melhores	0,80	
	Análise dos erros, curva de aprendizado e diagnóstico do ajuste	0,60	
	Artigo, referências, organização e reprodutibilidade	0,80	
	Aprofundamento além do mínimo	0,80	
Pitch	Clareza, tempo e participação equilibrada	1,00	3,00
	Domínio dos métodos, resultados e limitações	1,00	
	Gráficos e evidências que sustentem as conclusões	1,00	
TOTAL	Soma dos critérios		10,00

Como a pontuação será atribuída

Aplicar os níveis abaixo à pontuação máxima de cada critério. Por exemplo, atendimento parcial em um critério de 0,80 ponto corresponde a 0,40 ponto. No aprofundamento, avaliar até duas hipóteses adicionais, cada uma com máximo de 0,40 ponto, usando os mesmos níveis. Duas hipóteses completas totalizam 0,80 ponto; tentativas extras não aumentam esse limite.

Atendimento	Percentual	Descrição
Completo	100%	Cumpre o critério com execução correta, justificativa, evidências e interpretação consistentes.
Majoritário	75%	Cumpre a maior parte, com pequenas lacunas nas justificativas, evidências ou análise.
Parcial	50%	Cumpre parte do critério, com lacunas relevantes na execução ou na análise.
Incipiente	25%	Apresenta tentativa identificável, mas com falhas importantes ou evidências insuficientes.
Ausente	0%	Não entrega, não demonstra ou não atende ao critério.

Um experimento sem melhoria pode receber pontuação integral se a hipótese, a execução e a conclusão forem consistentes. A avaliação não exige superar o baseline ou obter R^2 predeterminado. A participação individual será observada nas apresentações e no histórico do trabalho.

Situações que resultam em nota zero

- Acompanhamento: a não entrega ou a não realização da apresentação resulta em zero nesse pilar para a equipe. O integrante que não comparecer ou não participar recebe zero individual nesse pilar.
- Solução técnica e artigo: a não entrega do artigo resulta em zero nos 5,0 pontos desse pilar para a equipe, mesmo que o repositório tenha sido entregue.
- Pitch: o integrante que não comparecer ou não participar recebe zero individual nos 3,0 pontos desse pilar. Se a equipe não realizar a apresentação, todos recebem zero nesse pilar.

10. Artigo do projeto

Escrever um artigo de até dez páginas, incluindo identificação, figuras, tabelas e referências. O artigo deverá apresentar uma síntese da investigação e remeter ao repositório para detalhes de implementação e resultados adicionais. Usar a seguinte organização:

- Título, equipe e links: identificar os autores, o alvo e o repositório GitHub na primeira página.
- Resumo: apresentar o problema, a abordagem, os principais resultados e a conclusão.
- Introdução e contextualização: explicar o problema, sua relevância e o objetivo da investigação.
- Metodologia: descrever dados, participantes elegíveis, features, preparação, modelos, PCA, balanceamento, buscas, curva de aprendizado e protocolo de avaliação. Explicar brevemente métodos não vistos em sala.
- Resultados: apresentar comparações, métricas e gráficos dos experimentos mais informativos, incluindo o teste final.
- Discussão: interpretar os ganhos ou sua ausência, os erros, os indícios de subajuste e sobreajuste e as limitações das features e dos dados. Relacionar desempenho e complexidade.
- Conclusão: responder ao objetivo e indicar o que a investigação permitiu aprender.
- Referências: listar todas as fontes externas utilizadas e citadas no texto.

Figuras e tabela obrigatórias

As evidências abaixo deverão aparecer no artigo. É permitido reunir gráficos em painéis para respeitar as dez páginas, mantendo títulos, eixos, legendas e fontes legíveis. Identificar se o resultado vem do desenvolvimento ou do teste e explicar o que cada figura demonstra.

- Distribuição da nota alvo no desenvolvimento, identificando as notas zero quando existirem.
- Comparação dos modelos com o baseline, mostrando a validação cruzada inicial e os resultados dos três regressores antes e depois da busca.
- Variância explicada acumulada do PCA, com o número de componentes escolhido e a justificativa.
- Curva de aprendizado do modelo final, com RMSE de treino e validação e variação entre as dobras, conforme a Seção 6.
- Notas observadas versus previstas pelo modelo final no teste, com linha de referência da previsão perfeita, e gráfico dos resíduos que permita identificar padrões nos erros.
- Erros do modelo final no teste por faixa de nota e por pelo menos um grupo de perfil ou localização, informando os tamanhos dos grupos.
- Tabela comparativa de RMSE, MAE, R^2 e tempo de execução. Separar os resultados de validação cruzada (média e desvio padrão) dos resultados de teste do baseline, da regressão linear sem regularização e da solução final.

Definir faixas e grupos durante o desenvolvimento e mantê-los na avaliação final. Gráficos de dispersão muito densos podem usar agregação em células ou uma amostra visual documentada; todas as métricas e análises por grupo deverão considerar os registros elegíveis do conjunto avaliado.

Apresentação e referências

Seguir o padrão ABNT para artigos científicos, citações e referências, com apoio do guia de normalização da biblioteca. Todas as fontes externas utilizadas, incluindo dados, artigos, documentação, métodos, códigos

adaptados e figuras, deverão ser citadas no ponto de uso e incluídas nas referências. Identificar a fonte dos dados nos gráficos e tabelas produzidos pela equipe.

Usar seções claras, linguagem objetiva e figuras legíveis. O texto deverá explicar as decisões e relacionar cada conclusão aos resultados apresentados, sem reproduzir saídas de código sem interpretação.

11. Pitch presencial

Apresentar a investigação em 10 a 15 minutos, com participação equilibrada de todos os integrantes. Selecionar as decisões e os experimentos mais informativos, incluindo resultados sem melhoria. A apresentação deverá explicar:

- O problema, a nota alvo, a base utilizada e as features escolhidas.
- As principais decisões de preparação, engenharia de features e avaliação.
- As comparações entre modelos, o PCA, o balanceamento e a busca de hiperparâmetros.
- Os resultados finais, a curva de aprendizado, o diagnóstico de subajuste e sobreajuste, os erros e as limitações.

Utilizar slides legíveis, com gráficos e tabelas. A apresentação deverá se concentrar na explicação do trabalho; não será aceita a exibição apenas de código. Todos deverão demonstrar domínio das decisões e responder às perguntas. Disponibilizar os slides em docs/pitch.pdf no repositório.

Prazo. Consultar o AVA, seção Avaliações.

12. Fontes e materiais de apoio

Dados e escrita científica

- Inep — Microdados do ENEM e documentação — baixar a edição de 2023 e seu dicionário
- Inep — Espelhos de redação do ENEM 2023 — consulta individual
- IBGE SIDRA — indicadores para integração opcional
- Biblioteca da Unifor — Trabalhos acadêmicos e normalização

Documentação de modelagem

- scikit-learn — Guia de preparação modelagem e avaliação
- scikit-learn — bagging pasting boosting Random Forest e stacking
- scikit-learn — PCA
- scikit-learn — IncrementalPCA para processamento em lotes
- scikit-learn — SVR e kernels
- scikit-learn — Pipeline
- scikit-learn — DummyRegressor para o baseline
- scikit-learn — curvas de aprendizado e diagnóstico do ajuste
- scikit-learn — t-SNE para visualização
- scikit-learn — busca de hiperparâmetros e validação cruzada

Opções adicionais de boosting

- XGBoost — XGBRegressor
- LightGBM — LGBMRegressor
- CatBoost — CatBoostRegressor

Apêndice A. Interpretação das variáveis

Consultar o dicionário do ENEM 2023 para interpretar códigos e alternativas. Os exemplos abaixo destacam cuidados úteis à preparação.

Grupo	Significado	Cuidados
Q001 e Q002	Escolaridade dos responsáveis.	Tratar desconhecimento separadamente dos níveis de escolaridade.
Q003 e Q004	Ocupação dos responsáveis.	Não assumir distâncias numéricas entre categorias de ocupação.
Q005 e Q006	Moradores e faixa de renda familiar.	Explicitar aproximações para renda e verificar denominadores.
Q007 a Q025	Serviço doméstico, bens e recursos do domicílio.	Distinguir contagens limitadas, categorias e respostas binárias.
Campos escolares	Tipo de escola e de ensino, dependência, localização e município, quando disponíveis.	Investigar ausências e informar a cobertura de cada campo.
Campos geográficos	UF e município de prova e município da escola.	Usar os códigos como categorias e respeitar o significado territorial de cada campo.

Caso sejam usadas médias de notas por categoria ou outras codificações supervisionadas, as linhas de treino devem receber valores calculados sem seu próprio alvo, por divisões internas ou método equivalente. A validação recebe estatísticas calculadas apenas no treino da dobra, com tratamento para grupos não vistos. Calcular médias com toda a base antes da divisão produz vazamento de informação.