PROJETO 2 · CIÊNCIA DE DADOS · UNIFOR

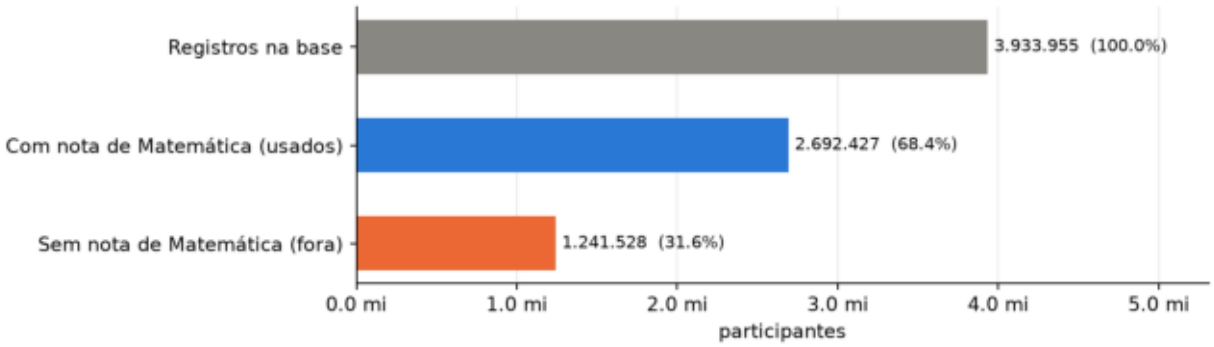
Previsão da nota de Matemática do ENEM 2023

Relatório de andamento: preparação dos dados e análise de correlação

Gerado em 08/11/2026 · branch do-zero · todos os números vêm da base real do Inep, calculados a partir do CSV.

Em uma frase

Partimos de 3.933.955 participantes do ENEM 2023, ficamos com os 2.692.427 que têm nota de Matemática, descartamos colunas que vazariam a resposta ou que quase não têm dados e medimos quais características (renda, escolaridade, bens da casa) andam junto com a nota. Ainda não treinamos nenhum modelo.



Principais números

- 3,933,955 registros e 76 colunas na base bruta, 2,692,427 (68,44% têm nota de Matemática e entram no estudo; 1,241,528 (31,56%) não têm nota (faltaram ou foram eliminados) e ficam de fora.
- 16,638 notas zero (0,62% dos usados). Zero é uma nota observada e válida, então é mantido.
- 47 colunas candidatas a feature; 8 removidas por terem mais de 50% de null; ficaram 39.
- Relação mais forte com a nota (Spearman): Q006 (+0,458), Q024 (+0,409) e Q003 (+0,377).
- Achamos e corrigimos um problema no tratamento do "não sei" do questionário (página 8).
- Falta: dividir em desenvolvimento e teste (80/20) antes de decidir qualquer coisa a mais com base na nota.

VISÃO GERAL

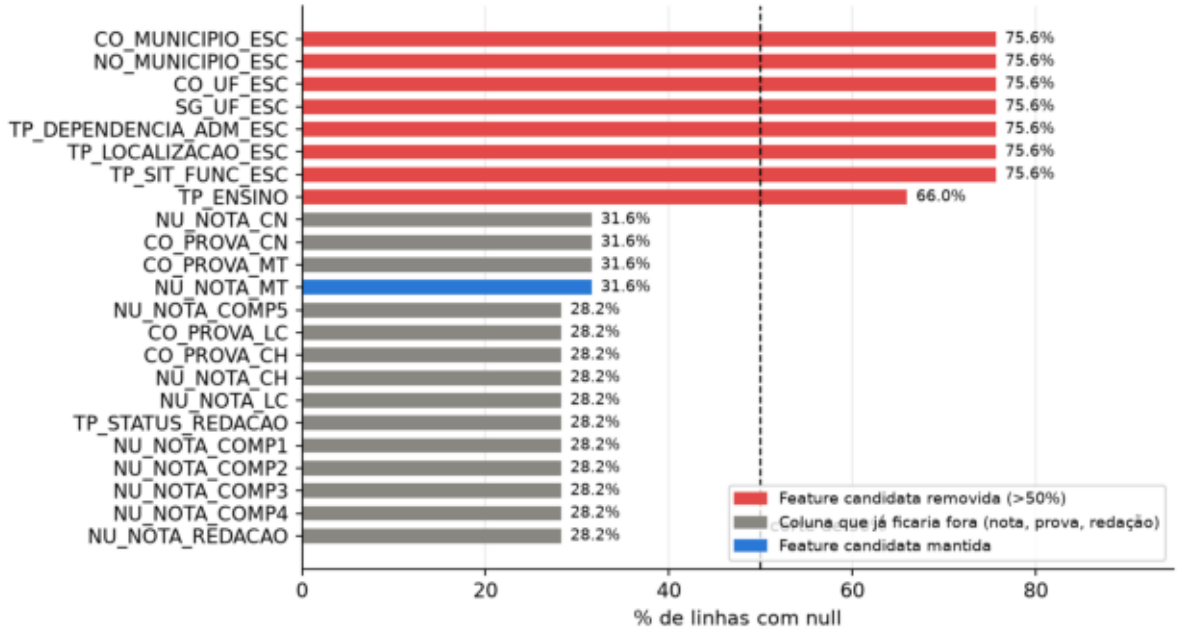
Onde estamos no roteiro

#	Etapa	Situação	Resultado
1	Carregar a base bruta	Feito	3.933.955 linhas, 76 colunas
2	Triagem: nulos, nota ausente, duplicatas	Feito	1.241.528 sem nota (diagnóstico explicado); 0 duplicatas
3	Classificar as 76 colunas pelo dicionário do Inep	Feito	1 alvo, 1 identificador, 27 fora de X, 47 candidatas
4	Remover candidatas com mais de 50% de null	Feito	8 removidas, 39 mantidas
5	Filtrar linhas sem nota e tirar NU_INSCRICAO	Feito	2.692.427 linhas. IDs guardados à parte
6	Remover linhas com null nas features	Feito (sem efeito)	0 linhas tinham null nas 39 features
7	Spearman com a nota e entre as colunas	Feito, corrigido	Correção do "não sei" (pág. 8)
8	Fundir colunas redundantes (|ρ| > 0,7)	Feito, a validar	1 grupo de 4 colunas (FUSAO_1)
9	Dividir em desenvolvimento e teste (80/20)	Pendente	random_state=42. Refazer 7 e 8 só no desenvolvimento
10	Codificação final, baseline e modelos	Pendente	Depois da divisão

Como ler este relatório
Cada página tem a mesma estrutura: o que fizemos, o que aparece nos dados, a decisão tomada e uma caixa azul com uma sugestão do que dizer na apresentação. As páginas 12 e 13 trazem um roteiro de fala, um glossário e links para estudar.

Etapa 1: o que falta em cada coluna

O que fizemos: para cada coluna, calculamos a proporção de linhas com null (valor vazio, que o pandas chama de NaN). O gráfico mostra as colunas com mais de 20% de null.



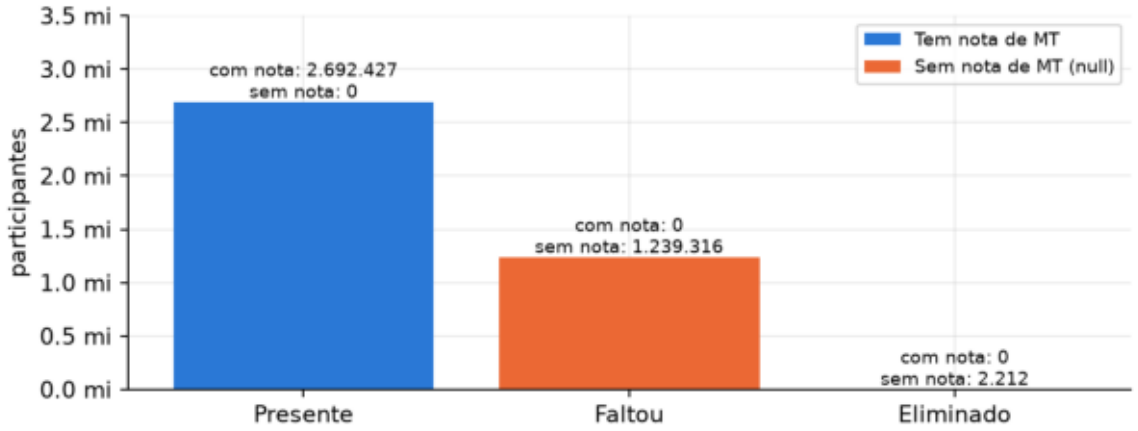
- Colunas da escola (7 delas): 75,6% de null. Vêm juntas: ou há escola informada ou não há nenhuma.
- TP_ENSINO: 66,0% de null. Só é preenchida para quem concluiu ou está concluindo o ensino médio.
- Colunas de nota e prova: 31,6% (Matemática) e 28,2% (redação) de null. Vazio porque a pessoa faltou ou foi eliminada, não por erro.

Decisão: removemos as 8 candidatas com mais de 50% de null (as 7 da escola e TP_ENSINO). Atenção: nelas o null tem significado ("sem escola informada", "não se aplica"). Ao remover perdemos essa informação. Depois podemos testar, como hipótese, um indicador "tem escola informada? (0/1)".

O que dizer na apresentação
"Antes de modelar, medimos o que falta em cada coluna. As colunas com mais da metade vazia têm pouco a ensinar e saíram. O vazio delas tem significado, então vale testar mais tarde se um indicador de 'tem escola' ajuda."

Etapa 2: por que a nota de Matemática está vazia

A nota de Matemática é o nosso alvo (y), Ela é null em 1,241,528 linhas (31,56%),



- Faltaram à prova de Matemática: 1.239.316. Foram eliminados: 2.212. Nenhum desses tem nota.
- Estiveram presentes: 2.692.427. Todos têm nota. Não existe presente sem nota.
- Ou seja: o null da nota não é erro de dado, é "não fez a prova".
- Duplicatas de NU_INSCRICAO: 0.
- Notas zero: 16,638 (0,62% dos que têm nota), Quem tirou zero fez a prova, então o zero é um resultado,

Decisões: (1) nota ausente não vira zero e não é imputada; essas linhas saem do estudo. (2) A presença serve só para diagnóstico e não entra como feature, porque seria vazamento de informação. (3) As notas zero ficam.

O que dizer na apresentação
"Nulo não é zero. 1,24 milhão de pessoas não têm nota porque faltaram ou foram eliminadas. Elas saem. Quem tirou zero fez a prova e fica."

Etapa 3: o que cada coluna é e o que fazemos com ela

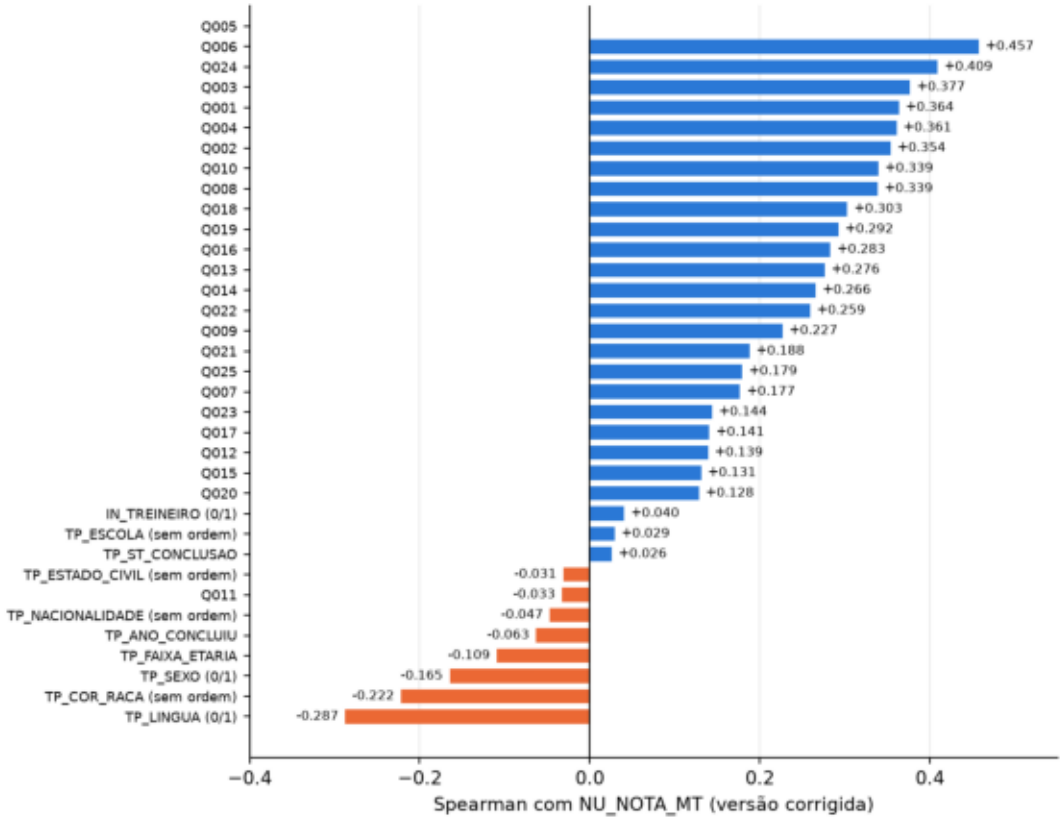
Grupo	Colunas	Decisão e motivo
Alvo (1)	NU_NOTA_MT	É o y que queremos prever.
Identificador (1)	NU_INSCRICAO	Serve só para controlar registros e a divisão em desenvolvimento e teste. Guardado à parte e removido de X.
Fora de X (27)	NU_ANO; NU_NOTA_CN, CH, LC; 5 competências e a nota da redação; TX_RESPOSTAS_* e TX_GABARITO_* (8); TP_PRESENCA_* (4); CO_PROVA_* (4); TP_STATUS_REDACAO	Vazamento: são notas, respostas, gabaritos ou informações produzidas pela correção. NU_ANO é sempre 2023, não distingue ninguém.
Candidatas removidas (8)	CO_MUNICIPIO_ESC, NO_MUNICIPIO_ESC, CO_UF_ESC, SG_UF_ESC, TP_DEPENDENCIA_ADM_ESC, TP_LOCALIZACAO_ESC, TP_SIT_FUNC_ESC, TP_ENSINO	Mais de 50% de null (75,6% e 66,0%).
Perfil (5)	TP_FAIXA_ETARIA, TP_SEXO, TP_ESTADO_CIVIL, TP_COR_RACA, TP_NACIONALIDADE	Mantidas. Os códigos são categorias, não medidas contínuas.
Situação escolar (4)	TP_ST_CONCLUSAO, TP_ANO_CONCLUIU, TP_ESCOLA, IN_TREINEIRO	Mantidas. TP_ANO_CONCLUIU tem 62,4% de código 0 ("não informado").
Local da prova e língua (5)	CO_MUNICIPIO_PROVA, NO_MUNICIPIO_PROVA, CO_UF_PROVA, SG_UF_PROVA, TP_LINGUA	Mantidas por ora. Decisão pendente (pág. 11): nome e código dizem a mesma coisa, e o município tem milhares de valores.
Questionário (25)	Q001 a Q025	Mantidas. Escolaridade e renda têm ordem; bens são contagens; ocupação (Q003, Q004) são grupos sem distância numérica.

O que dizer na apresentação

"Das 76 colunas, só 39 descrevem o perfil de quem faz a prova. O resto é nota, gabarito ou correção, e usar isso para prever a nota seria trapaça. O que sobrou vem do perfil do participante e do questionário socioeconômico."

Etapa 4: quais características andam com a nota

O Spearman troca cada valor pela posição dele na fila (1º, 2º, 3º...) e mede se duas colunas sobem juntas. Vai de -1 a +1: perto de 0 quase não há relação; positivo, as duas sobem juntas; negativo, uma sobe quando a outra desce. Mostra relação, não causa.

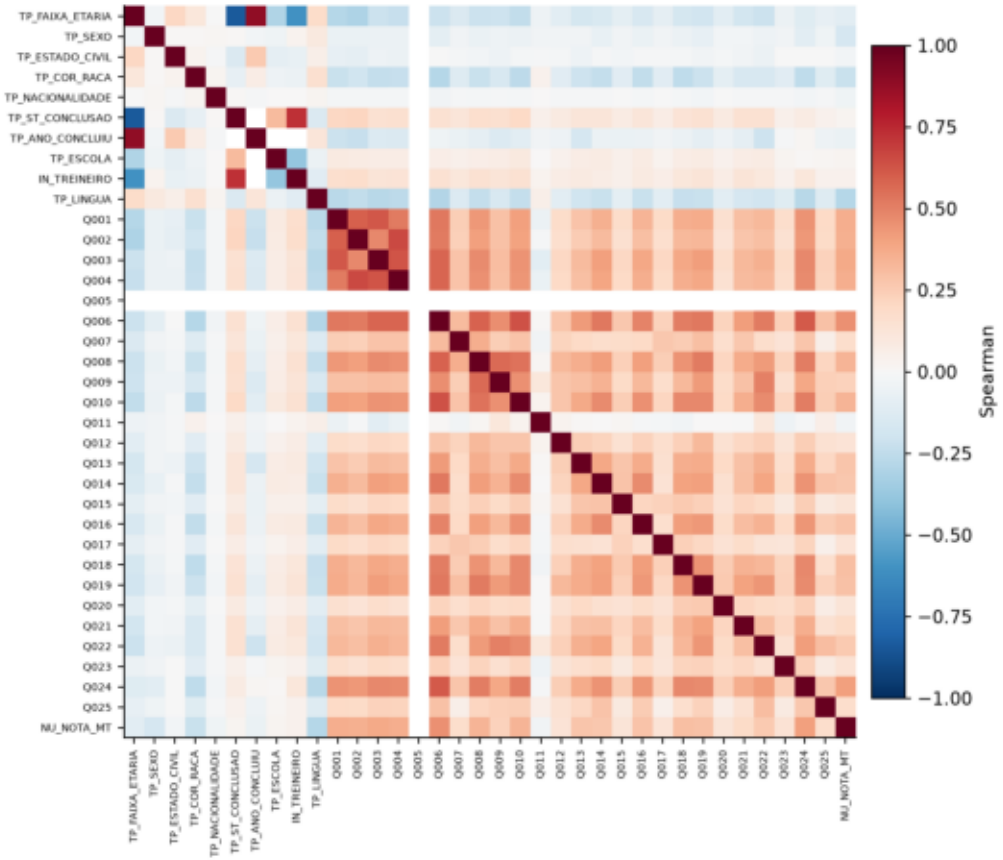


- Mais fortes: Q006 (+0,458), Q024 (+0,409), Q003 (+0,377), Q001 (+0,363), Q004 (+0,361), Q002 (+0,354). Renda, computador, carro e banheiros, ou seja, o nível socioeconômico da casa.
- Escolaridade e ocupação dos responsáveis (Q001 a Q004) ficam entre +0,354 e +0,377.
- TP_LINGUA (-0,287): quem escolheu espanhol (1) tem nota menor em média. TP_SEXO (-0,165, F=1). Associação, não explicação.
- Idade (TP_FAIXA_ETARIA, -0,109): fraca e negativa.
- Colunas marcadas "sem ordem" (cor, estado civil, nacionalidade, tipo de escola) têm código só como rótulo. O Spearman delas não deve ser interpretado.

O que dizer na apresentação
"As relações mais fortes com a nota de Matemática são renda e bens da casa. Nenhuma passa de 0,5, então o perfil sozinho explica parte da nota, não tudo. Isso já indica que o R^2 do modelo não deve ser alto."

Etapa 5: quais colunas são parecidas entre si

Cada quadradinho é a correlação de Spearman entre duas colunas. Vermelho: relação positiva. Azul: relação negativa. Branco: perto de zero. A diagonal é sempre vermelha, porque cada coluna é igual a si mesma.



Fixamos o corte em |Spearman| > 0,7 (valor usual entre 0,7 e 0,9). Saíram 3 pares, todos na situação escolar:

- TP_FAIXA_ETARIA × TP_ANO_CONCLUIU: +0,885
- TP_FAIXA_ETARIA × TP_ST_CONCLUSAO: -0,842
- TP_ST_CONCLUSAO × IN_TREINEIRO: +0,728

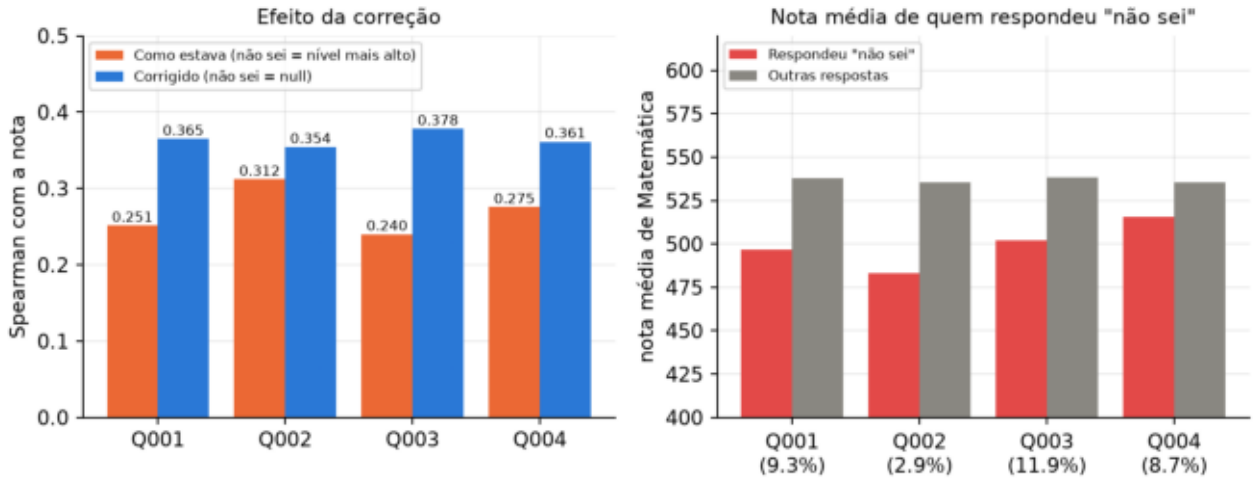
O questionário (Q001 a Q025) não tem nenhum par acima de 0,7: não há bens ou respostas quase iguais entre si.

O que dizer na apresentação
"Procuramos colunas que dizem quase a mesma coisa. Só a situação escolar tem isso: idade, ano de conclusão, situação do ensino médio e treineiro contam a mesma história, que é há quanto tempo a pessoa saiu da escola."

Atenção: um problema que corrigimos

O que aconteceu: no notebook, a célula que converte as letras do questionário em números (A=0, B=1…) usava o teste dtype == object. No pandas 3, texto tem dtype "str", então o teste deu falso e as letras ficaram como estavam. A saída df_num.dtypes.value_counts() já mostrava "str 25".

Consequência: o rank() ordenou as letras em ordem alfabética, o que dá a mesma ordem de A=0, B=1… Isso está certo. Mas "não sei" (H em Q001 e Q002; F em Q003 e Q004) não foi tratado: continuou sendo o nível mais alto da escala, acima de "pós-graduação". A troca por null (== 7) comparava texto com número e não fez nada.



- Q001: 9,3% responderam "não sei" e tiveram nota média de 496,7 contra 537,7 dos demais. Spearman: +0,251 → +0,365.
- Q002: 2,9% · Spearman +0,312 → +0,354. Q003: 11,9% · +0,240 → +0,378. Q004: 8,7% · +0,275 → +0,361.
- Os pares acima de 0,7 e a fusão não mudaram: são os mesmos nos dois cálculos.

Correção para colar na célula de preparação

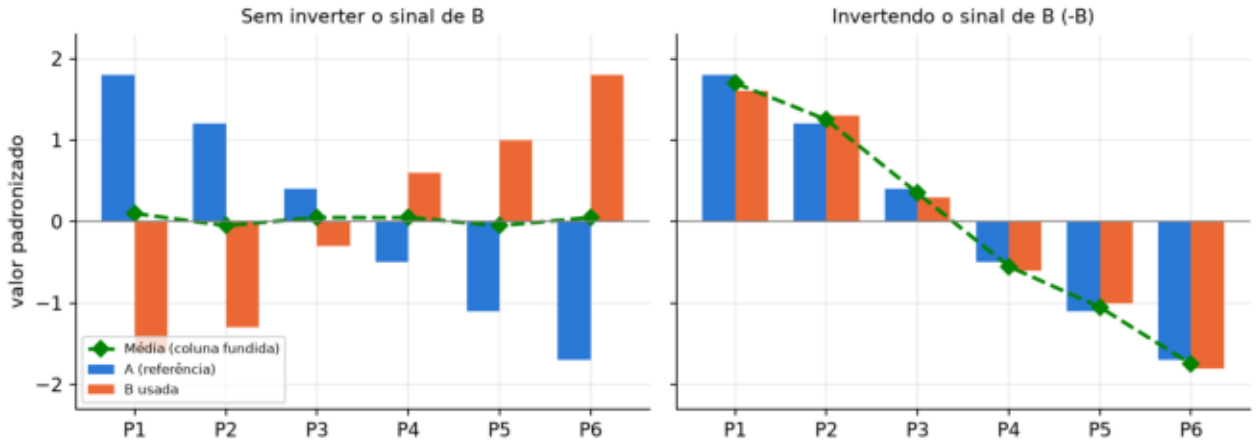
```
mapa = {chr(65 + i): i for i in range(17)}
for c in df_num.columns:
    if c.startswith("Q") and pd.api.types.is_string_dtype(df_num[c]):
        df_num[c] = df_num[c].map(mapa)
# depois, "não sei" vira NaN (agora a comparação com 7 e 5 funciona)
```

Etapa 6: fundir colunas parecidas

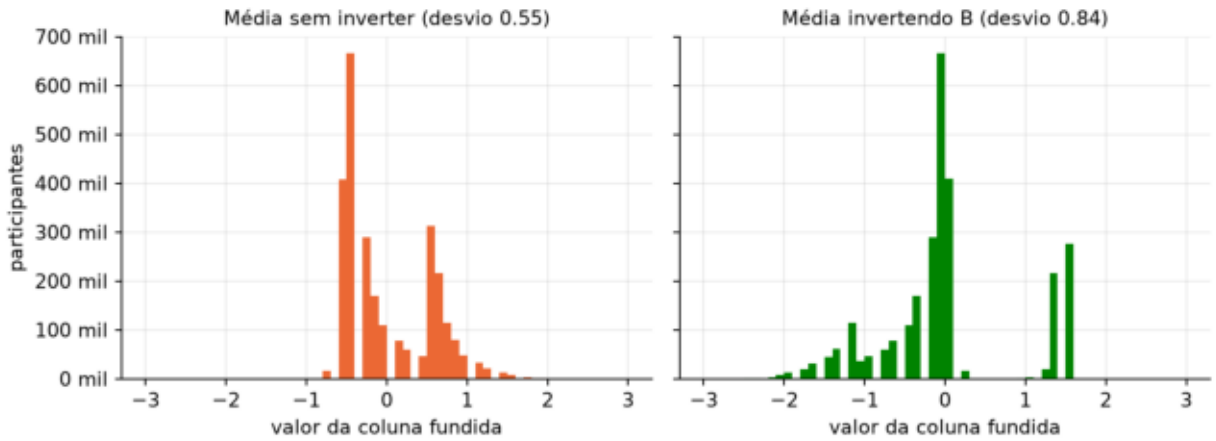
Fundir é trocar um grupo de colunas parecidas por uma coluna nova: a média das colunas depois de padronizadas (z-score), para nenhuma pesar mais só por ter escala maior. Um grupo é um conjunto de colunas ligadas por pares com |Spearman| > 0,7.

O cuidado com o sinal: se duas colunas têm correlação negativa, uma sobe quando a outra desce, e a média dos valores se cancela. Por isso invertemos o sinal das colunas que têm correlação negativa com a coluna de referência do grupo antes de fazer a média.

Exemplo ilustrativo (números inventados, só para entender a ideia):



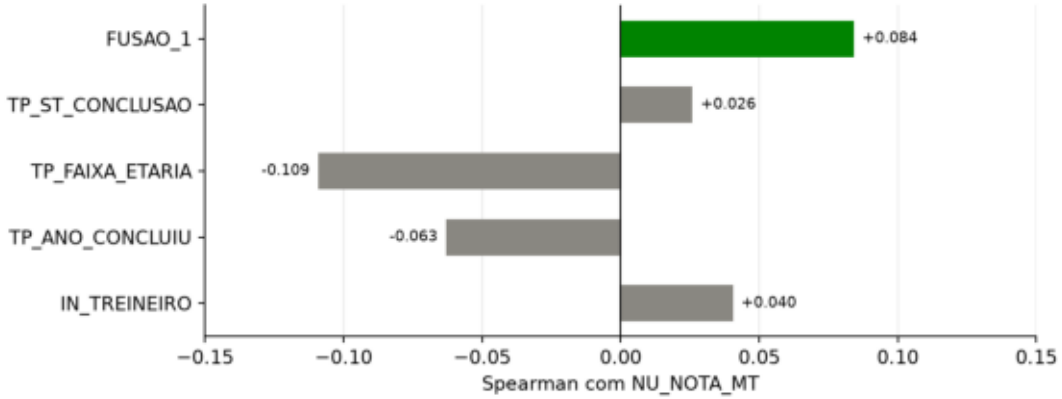
Com os dados reais: IN_TREINEIRO e TP_FAIXA_ETARIA têm Spearman -0,605, O desvio padrão da média é 0,55 sem inverter e 0,84 invertendo, Quanto maior o desvio, mais a coluna fundida diferencia os participantes,



O que dizer na apresentação
"Se duas colunas andam em sentidos opostos e a gente só tira a média, elas se anulam. Invertendo o sinal de uma delas, a coluna fundida preserva a informação."

Resultado da fusão: o que fundiu, o que saiu e por quê

Item	Detalhe
Coluna nova	FUSAO_1 = média padronizada de IN_TREINEIRO, TP_ANO_CONCLUIU, TP_FAIXA_ETARIA, TP_ST_CONCLUSAO
Motivo	TP_FAIXA_ETARIA × TP_ANO_CONCLUIU: +0,885; TP_FAIXA_ETARIA × TP_ST_CONCLUSAO: -0,842; TP_ST_CONCLUSAO × IN_TREINEIRO: +0,728. Os três pares acima de 0,7 ligam as quatro colunas.
Sinal invertido	TP_ANO_CONCLUIU, TP_FAIXA_ETARIA (correlação negativa com a referência IN_TREINEIRO).
Colunas que saíram	IN_TREINEIRO, TP_ANO_CONCLUIU, TP_FAIXA_ETARIA, TP_ST_CONCLUSAO (substituídas pela coluna nova).
Ficaram como estavam	31 colunas do questionário e do perfil, mais o alvo. Motivos: não têm par acima de 0,7, ou o par é com coluna sem ordem numérica.
Antes → depois	36 colunas → 33 colunas



Leitura honesta:

- A coluna fundida tem Spearman +0,084 com a nota. A melhor coluna sozinha do grupo, TP_FAIXA_ETARIA, tem -0,109. Em valor absoluto, a fusão ficou abaixo da melhor coluna: perdeu um pouco de sinal.
- Isso não prova que a fusão é ruim: o Spearman só vê relação em linha, e um modelo pode usar as colunas separadas de outro jeito. A resposta vem de comparar o modelo com e sem a fusão.
- TP_ANO_CONCLUIU tem 62,4% de código 0 ("não informado"), tratado como null. Nessas linhas a média usa só as outras três colunas.
- A média e o desvio da padronização foram calculados com todas as linhas. No pipeline final, devem ser calculados só no treino.

Pendências, decisões em aberto e próximos passos

Antes de seguir

- Dividir em desenvolvimento (80%) e teste (20%) com random_state=42, e guardar os IDs de cada parte. Todo número deste relatório usa as 2.692.427 linhas juntas. Para decidir features, refazer Spearman, pares e fusão só no desenvolvimento.
- Corrigir a célula de conversão das letras no notebook (página 8).

Decisões em aberto

- Localização: o df_modelo ainda tem CO_MUNICIPIO_PROVA, NO_MUNICIPIO_PROVA, CO_UF_PROVA e SG_UF_PROVA. Proposta: ficar só com SG_UF_PROVA e testar o município depois, como hipótese. O Spearman de CO_UF_PROVA (+0,187) é artefato da numeração dos códigos, sem significado.
- "Não sei" em Q001 a Q004 (2,9% a 11,9%): manter como categoria própria (indicador), imputar ou remover. Quem respondeu "não sei" tem nota média menor.
- TP_ANO_CONCLUIU: 62,4% são "não informado". Tratar com indicador, em vez de descartar.
- Fusão: manter FUSAO_1 ou as quatro colunas separadas. Testar nos modelos.
- Codificação: one-hot para as categorias sem ordem e níveis para escolaridade e renda. Q003 e Q004 (ocupação) são grupos sem distância numérica.

Próximos passos do projeto

- Baseline (média) e regressão linear sem regularização, com KFold(3, shuffle=True, random_state=42) e Pipeline.
- Ridge, árvore, KNN, LinearSVR, Bagging, Pasting, Random Forest, boosting e Stacking.
- PCA dentro do Pipeline, balanceamento por faixa de nota, busca de hiperparâmetros nos 3 melhores e curva de aprendizado.
- Teste final uma única vez, análise de erros e duas hipóteses de aprofundamento (por exemplo, com e sem a fusão).

Roteiro de fala e glossário

Roteiro (cerca de 3 minutos)

- Problema: prever a nota de Matemática do ENEM 2023 a partir do perfil do participante, sem usar nenhuma nota ou resposta da prova.
- Dados: 3.933.955 registros; 2.692.427 têm nota e entram. O resto faltou ou foi eliminado, e a nota dessas pessoas não é zero, é inexistente.
- Limpeza: tiramos 27 colunas por serem resultado da prova, 8 por terem mais de 50% de null e o identificador. Sobraram 39 colunas de perfil e questionário.
- Correlação: renda, computador e bens da casa são o que mais anda com a nota, mas nada passa de 0,5. O perfil explica só parte.
- Redundância: só a situação escolar tem colunas muito parecidas. Fundimos as quatro numa só, invertendo o sinal das que andam ao contrário.
- Erro que achamos: o "não sei" estava tratado como nível mais alto de escolaridade. Corrigimos e as correlações do questionário subiram.
- Próximo passo: dividir 80/20, refazer isso só no desenvolvimento e começar os modelos.

Glossário

Termo	Significado
null / NaN	Valor vazio. No pandas aparece como NaN. Não é o mesmo que zero.
Feature (X) e alvo (y)	Feature é a coluna de entrada do modelo. Alvo é o que queremos prever: NU_NOTA_MT.
Vazamento de dados	Usar no modelo uma informação que não existiria na hora da previsão (por exemplo, a nota de outra prova).
Spearman	Correlação por posições. De -1 a +1. Mede se duas colunas sobem juntas, em ordem.
Redundância	Duas colunas dizendo quase a mesma coisa (|Spearman| alto).
z-score	Valor menos a média, dividido pelo desvio padrão. Põe colunas diferentes na mesma escala.
Fusão	Trocar um grupo de colunas parecidas por uma coluna só (aqui, a média padronizada).
Treineiro	Quem faz a prova só para treinar, sem ter concluído nem estar concluindo o ensino médio em 2023.
Desenvolvimento e teste	80% dos dados para explorar e escolher; 20% guardados para a avaliação final.

LINKS

Vídeos e materiais para estudar

Aviso sobre os vídeos
Um PDF não toca vídeo dentro dele; o clique abre o navegador. Os vídeos de Spearman abaixo vieram de uma busca no YouTube: os títulos são os que aparecem na busca, e eu não assisti a eles, então não sei a duração nem a qualidade. Veja os primeiros minutos antes de indicar. Para os outros temas não consegui endereços confirmados, então deixei links que abrem a busca do YouTube com o termo certo.

Vídeos sobre correlação de Spearman (clicáveis)

Em português

- Análise Exploratória de Dados: Correlação de Pearson e Spearman (com Python)
- Testes de Correlação (Pearson e Spearman), com Excel e R
- Inferência Estatística, Aula 18: Teste não paramétrico de Spearman

Em inglês e espanhol

- Spearman Correlation Explained in 3 Minutes
- Spearman Rank Correlation Explained: Nonparametric Statistics Made Easy
- Correlación de rangos de Spearman (explicado de forma sencilla)

Spearman em Python

- Calculate Spearman Rank Correlation in Python
- Python: Spearman Correlation (value and test)
- How to Measure Correlation Between Two DataFrame Columns in Pandas
- Las correlaciones de Pearson, Spearman y Kendall en Python

Outros temas: buscas no YouTube (clicáveis)

- Data leakage (vazamento de dados) em machine learning
- Valores nulos (NaN) no pandas: dropna e fillna
- Multicolinearidade e variáveis muito correlacionadas
- Pipeline e validação cruzada no scikit-learn
- Padronização (z-score) e StandardScaler

Artigos em português que apareceram na pesquisa

- DataCamp: correlação de Spearman
- DataCamp: multicolinearidade
- Hashtag Treinamentos: NaN e Null no Python
- LabEx: Pipelines e estimadores compostos (scikit-learn)

Documentação oficial

- Inep: microdados do ENEM
- pandas: dados ausentes
- scikit-learn: Pipeline
- scikit-learn: validação cruzada
- SciPy: spearmanr