Previsão da nota de Matemática do ENEM 2023: relatório detalhado dos modelos

Nov 11, 2026 · @João Igor Andrade

1. Resumo executivo

O perfil socioeconômico, escolar e demográfico estima a nota de Matemática do ENEM 2023 só de forma aproximada: a solução final (Gradient Boosting) erra em média **105,8 pontos (RMSE) no teste** e explica **35,4%** da variação da nota (R^2 0,354), contra 131,7 e 0 do baseline que prevê a média. O limite vem da informação disponível, não do algoritmo.

	Baseline (média)	Regressão linear (sem regularização)	Solução final
RMSE, validação cruzada (média ± desvio)	131,63 ± 0,16	108,87 ± 0,16	105,86 ± 0,17
RMSE, teste (538.486 participantes)	**131,70**	**108,86**	**105,81**
MAE, teste	107,64	84,89	82,00
R^2, teste	0,000	0,317	0,354

Abordagem. 2.692.427 participantes com nota observada, 80% para desenvolvimento e 20% para teste (semente 42); validação cruzada de 3 dobras só no desenvolvimento; tudo que é aprendido dos dados dentro de um Pipeline. Dez regressores comparados, em **21 conjuntos de entrada** (8 datasets salvos e 13 variações de representação), com PCA, seleção de atributos, balanceamento, busca de hiperparâmetros e seis hipóteses de aprofundamento. Mais dois conjuntos ficam fora da conta: a solução independente de outra IA (dataset 5; melhor modelo 107,53 no teste, sem superar a nossa) e um diagnóstico com as notas de outras áreas (dataset 6, proibido na solução: o R^2 sobe de 0,34 para 0,68).

Qual modelo, com qual conjunto de entrada. A solução oficial é o Gradient Boosting com hiperparâmetros buscados, nas 74 colunas finais (não é um dos 8 datasets salvos: é a representação montada no notebook 04). O quadro resume o melhor de cada grupo.

Grupo	Modelo	Conjunto de entrada	RMSE, validação cruzada	RMSE, teste
Solução final (oficial)	**Gradient Boosting, com busca**	**74 colunas: 44 do `dataset_3_escola_features` sem a `FUSAO_1`, 4 de situação separadas e 26 dummies de UF**	**105,86**	**105,81**
Melhor dos 8 datasets salvos	Gradient Boosting, configuração inicial	`dataset_3_escola_features` (45 colunas, com escola e features criadas)	107,05	não aberto

Grupo	Modelo	Conjunto de entrada	RMSE, validação cruzada	RMSE, teste
Melhor da outra IA (dataset 5)	Ridge com one-hot	45 colunas, one-hot de todas as categóricas	107,51	107,53
Menor erro medido, não adotado	Gradient Boosting	as 74 colunas + município com target encoding	105,73	não aberto
Diagnóstico com vazamento, fora da solução	Gradient Boosting	perfil + notas de outras áreas (dataset 6)	74,43	não aberto

O município ficou de fora da solução porque só foi testado depois de o teste ser aberto (Apêndice G.3); o dataset 6 é proibido pelo enunciado e só mede o vazamento.

Principais resultados.

- O Gradient Boosting é o melhor regressor em todas as comparações. Ganha 3,4 pontos da regressão linear; stacking empata com ele e custa 5 vezes mais; KNN e SVR linear não ganham da regressão linear.
- O que mais melhorou o erro, em ordem: modelos de árvores (−3,4), UF da prova (−0,70), situação escolar separada em vez de fundida (−0,33), informação de escola (−0,4 a −0,5). Todos pequenos.
- Não ajudaram: PCA (piora, 18 de 30 componentes para 80% da variância), seleção de atributos (piora), as 3 features criadas (sem efeito), tirar as notas zero do treino (sem efeito), K-means como feature (sem efeito) e a busca de hiperparâmetros no melhor modelo (−0,16, dentro do desvio).
- Balanceamento por ponderação de faixas: reduz o erro nas notas acima de 800 (RMSE de 184,9 para 155,4) mas piora o erro geral (+2,1) e o das faixas do meio; não adotado.
- O bloco que mais pesa é perfil e trajetória (sexo, idade, situação de conclusão, cor/raça, língua): tirá-lo sobe o RMSE em 4,4. Depois vêm bens (+1,3), renda (+0,9) e UF (+0,7).
- Teste e validação concordam (105,81 contra 105,86). A curva de aprendizado mostra treino e validação separados por 1,1 ponto, quase sem ganho de 75% para 100% do treino: mais dados ou um modelo mais complexo não resolveriam.
- Um vazamento pequeno (média e desvio da `FUSAO_1` com todas as linhas) foi corrigido dentro do Pipeline; o efeito era de 0,003 ponto.
- Extensões depois do teste (notebook 06, só validação cruzada; não mudam a solução final, Apêndice G): one-hot em todas as categóricas melhora os modelos lineares em cerca de 1 ponto (108,87 para 107,89); o município com target encoding melhora 0,30 ponto (106,03 para 105,73); quatro sementes variam 0,009; a busca nas 74 colunas finais dá o mesmo erro (105,859 contra 105,864); o dataset 5 por validação cruzada (Ridge, 107,51) confirma o teste da outra IA.

Conclusão. Com o perfil é possível dizer a tendência de um grupo, não a nota de uma pessoa: pessoas com o mesmo perfil tiram notas muito diferentes, e o que mais pesa (esforço de estudo, qualidade do ensino, circunstâncias do dia) não está no questionário. As associações não indicam causa.

Perguntas que investigamos e o que respondemos. Cada teste do trabalho nasceu de uma pergunta. As oito primeiras são as perguntas de aprofundamento propostas no enunciado; as demais surgiram dos resultados. A coluna da direita diz onde está o experimento (ids do `experimentos.csv`) e a seção do relatório. Diferenças de RMSE só contam como melhora ou piora quando passam do desvio entre dobras (cerca de 0,2 ponto).

Pergunta	O que testamos	Resposta (RMSE médio, validação cruzada)	Onde
1. Quais blocos de informação contribuem mais?	Retirar um bloco por vez da representação final	Perfil e trajetória: +4,42; bens: +1,33; renda: +0,87; UF: +0,70; escolaridade e ocupação dos pais: +0,53; escola: +0,41. Todos pioram ao sair.	`S6_*`, seção 9
2. O tratamento das categorias faz diferença?	"Não sei" como ausente mais indicador; situação escolar fundida ou separada; one-hot nos modelos lineares	Situação separada: −0,33 (107,05 para 106,73). "Não sei" com indicador: cerca de −0,2. One-hot em todas as categóricas nos modelos lineares: −0,98 (108,87 para 107,89). Sim, mas pouco no boosting.	`S1a`, `S1b`, `H_dataset_*`, `E1_*`, Ap. G.1
3. As interações ajudam?	Três features criadas: pessoas por quarto, celulares por morador e renda menos escolaridade	Retirar as três muda o erro em +0,01. Não: o modelo de árvores já capta o que elas combinam.	`S3_*`, seção 5
4. A localização acrescenta informação?	UF da prova em 26 colunas; município com target encoding (depois do teste)	UF: −0,70 (106,73 para 106,03). Município: −0,30 (106,03 para 105,73), não adotado. Sim, pouco. Modelos regionais não foram testados.	`S2_com_uf`, `E3_*`, Ap. G.3
5. Dados externos melhoram o contexto?	Não testado: nenhum indicador externo foi integrado	Sem resposta. Fica como próximo passo.	—
6. Existem perfis semelhantes?	K-means ajustado no treino, com a distância aos grupos como feature	107,79 contra 107,77: sem diferença. As distâncias aos grupos não ajudaram.	`H_kmeans_*`, seção 10
7. Os erros nas notas extremas podem ser reduzidos?	Ponderar as faixas de nota por n^(−α); retirar as notas zero do treino	Acima de 800, o RMSE cai de 185 para 155 (α = 0,5), mas o erro geral sobe 2,1. Sem os zeros no treino: sem diferença. Transformar o alvo ou a função de perda não foi testado.	`S5_*`, `H_semzeros_*`, seção 12

Pergunta	O que testamos	Resposta (RMSE médio, validação cruzada)	Onde
8. Dá para manter o desempenho com uma solução mais simples?	Selecionar colunas (k = 22, 37, 51), PCA e regressão linear no lugar do boosting	Seleção: +1,04 (k = 51) a +4,58 (k = 22). PCA: piora em todos os cortes. Regressão linear: +3,0 de erro, mas cerca de 30 vezes mais rápida (3 s contra 91 s por dobra). Não sem perder erro.	`S4_*`, `H_pca_*`, `F_*`, seções 10, 11 e 13
9. Outra pessoa, sem contexto, chegaria a algo melhor?	Replicação independente (dataset 5), avaliada no mesmo teste e nas nossas dobras	107,53 no teste e 107,51 na validação cruzada, contra 105,81 e 105,86 da nossa solução. Não.	`E6_*`, seção 8.4, Ap. G.6
10. O limite vem da informação ou do modelo?	Curva de aprendizado; notas de outras áreas como diagnóstico (dataset 6, fora da solução)	Treino e validação ficam a 1,1 ponto e mais dados quase não ajudam; com as notas de outras áreas o R^2 vai de 0,34 para 0,68. O limite é a informação.	`F_*`, curva, seções 13 e 8.5 e Ap. D

2. Problema, alvo e dados

Estimamos a nota de Matemática (`NU_NOTA_MT`, escala de 0 a 1000) de 2.692.427 participantes do ENEM 2023 usando só o perfil informado na inscrição: socioeconômico, escolar e demográfico. A pergunta é quanto desse perfil explica a nota e quais escolhas de preparação e de modelagem fazem diferença; não é obter o maior R^2 possível.

Fonte. Inep, Microdados do ENEM 2023 e dicionário de variáveis. Tarefa: regressão supervisionada (o alvo é um número contínuo, não uma classe).

Indicador	Quantidade
Registros na base bruta (76 colunas)	3.933.955
Sem nota de Matemática (31,56%; fora da regressão)	1.241.528
Com nota de Matemática observada (elegíveis, 68,44%)	**2.692.427**
Desenvolvimento (80%)	2.153.941
Teste (20%, reservado)	538.486
Dobras da validação cruzada (3)	717.981 / 717.980 / 717.980
Notas zero no desenvolvimento	13.300 (0,62%)
Nota no desenvolvimento: média, mediana, desvio padrão	533,83 · 523,50 · 131,63

Decisões sobre a nota.

- Nota ausente (faltou ou foi eliminado) **não é imputada nem vira zero**: essas pessoas saem da regressão.

- Nota **zero** é um resultado observado e válido: fica no treino e na validação. O notebook de treino sem zeros mostrou que tirá-la do treino não muda o erro de forma mensurável (seção 9).
- Treineiros e todas as faixas etárias foram mantidos. Nenhuma amostra por conveniência: todas as linhas elegíveis entram. Amostras só aparecem em gráficos de dispersão e no t-SNE, e são sempre documentadas.
- O desvio padrão da nota no desenvolvimento (131,63) é o RMSE do baseline que prevê a média, e é a régua de todos os modelos.

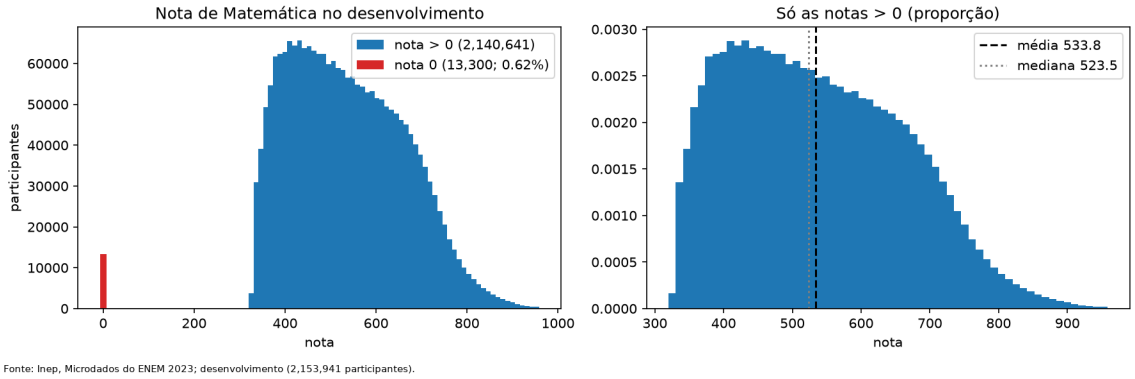


Figura 1. Distribuição da nota de Matemática no desenvolvimento (2.153.941 participantes); as 13.300 notas zero (0,62%) em vermelho. Fonte: Inep, ENEM 2023.

O que fica fora das entradas (vazamento). Notas de outras áreas e da redação, `TP_PRESENCA_*`, `TP_STATUS_REDACAO`, `TX_RESPOSTAS_*`, `TX_GABARITO_*`, `CO_PROVA_*`, `NU_ANO` e o identificador `NU_INSCRICAO`. Com essas colunas o R^2 passaria de 0,7, mas elas descrevem a própria prova, não o perfil, e o enunciado as proíbe.

3. Protocolo de avaliação e prevenção de vazamento

Todas as escolhas (features, técnicas, hiperparâmetros, tamanho do treino) saíram da validação cruzada no desenvolvimento; o teste foi aberto uma única vez, no fim, com a solução fixada.

Elemento	Como foi feito
Partição	`train_test_split(ids_elegiveis, test_size=0.2, random_state=42)`: 80% desenvolvimento, 20% teste. Ids em `dados/splits/`.
Validação cruzada	`KFold(n_splits=3, shuffle=True, random_state=42)` só no desenvolvimento, nas mesmas dobras em todas as comparações (`dobras_cv.csv`). Não há outra parcela de validação.
Baseline	`DummyRegressor(strategy="mean")`; média recalculada no treino de cada dobra e, no teste, nos 80% de desenvolvimento.
Métricas	RMSE (principal), MAE e R^2, sempre na escala original da nota; média e desvio padrão entre as dobras; tempo por dobra.

Elemento	Como foi feito
Pipeline	Tudo que é aprendido dos dados (fusão da situação escolar, padronização, seleção de atributos, PCA, pesos por faixa) é reajustado só no treino de cada dobra.
Semente	42 em tudo que aceita `random_state`.
Regra de leitura	Só chamamos de melhora ou piora se a diferença do RMSE médio passa do desvio entre dobras da referência; senão é "sem diferença clara".

Os identificadores do teste foram conferidos só quanto à distribuição da nota (média 533,84 e desvio 131,70 no teste, contra 533,83 e 131,63 no desenvolvimento). Nada mais do teste foi usado antes do fim. O script `src/particao.py` recria as partições e confere que os arquivos salvos são iguais aos gerados com a semente 42.

Vazamento que existia e foi corrigido. Nos datasets 1 a 3 (notebook 01), a média e o desvio da `FUSAO_1` e as medianas de `Q001` a `Q004` (usadas no "não sei") foram calculados com todas as linhas, inclusive as do teste. No notebook 04:

- A `FUSAO_1` é refeita dentro do Pipeline (classe `FusaoSituacao`), com média e desvio só do treino de cada dobra, a partir das 4 colunas originais. A receita reproduz a coluna salva com erro máximo de 5e-6.
- As medianas são números inteiros e foram conferidas: a mediana do desenvolvimento é igual à de todas as linhas (Q001 = 4, Q002 = 4, Q003 = 2, Q004 = 1).
- O efeito foi desprezível: a fusão refeita só com o treino dá RMSE 107,051 contra 107,048 com a versão que vazava.

Nenhuma codificação supervisionada por categoria (como target encoding de município) foi usada, então essa fonte de vazamento não existe no pipeline.

4. Exploração e preparação dos dados

A preparação seguiu o dicionário do Inep: diferenciar desconhecimento, não informação e ausência, e não assumir distância numérica entre categorias sem ordem. Os gráficos desta etapa estão no notebook `01-exploracao-filtro` e entram abaixo.

4.1 Valores ausentes. As colunas da escola têm 75,6% de ausentes na base completa (73,1% entre quem tem nota). O vazio tem significado: é quem já concluiu o ensino médio e não está numa escola no cadastro. `TP_ENSINO` tem 66,0% de ausentes. As colunas de nota e de prova têm 31,6% ou 28,2% de ausentes porque a pessoa faltou ou foi eliminada. Por isso o vazio da escola vira a categoria "sem informação" (referência da codificação 0/1), sem imputar mediana e sem remover linhas (remover deixaria só 724.385 participantes).

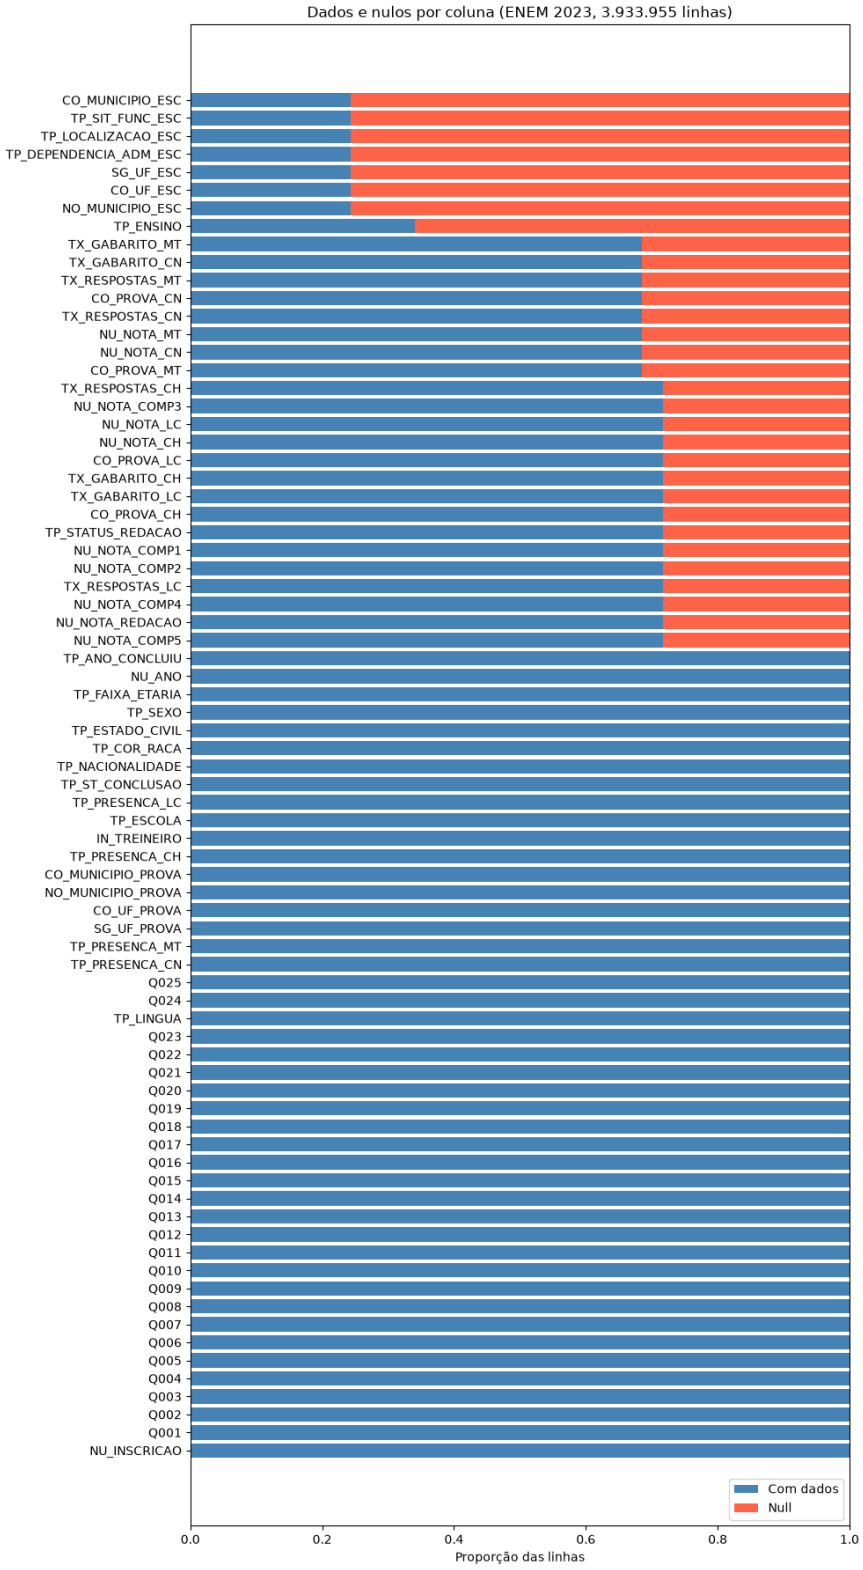


Figura 2. Proporção de dados e de valores ausentes em cada coluna da base bruta. Fonte: Inep, ENEM 2023.

4.2 Codificação.

- Questionário `Q001` a `Q025`: letras viram números (A=0, B=1, C=2…), mantendo a ordem do dicionário (escolaridade e renda são escadas ordenadas; contagens de bens vão de 0 a 4).
- Sexo em 0/1. Cor/raça, estado civil, nacionalidade, tipo e localização da escola são categorias sem ordem: nos datasets 2 e 3 entram em colunas 0/1.
- "Não sei" em `Q001` a `Q004` (escolaridade e ocupação do pai e da mãe) não é um nível da escala: vira ausente, é preenchido com a mediana de quem respondeu e, no dataset 3, ganha indicador próprio. Quem não sabe tira 40 a 50 pontos a menos, informação que o preenchimento por mediana apagaria.
- `TP_ANO_CONCLUIU = 0` (não informado) vira ausente na fusão da situação escolar.

4.3 Sexo e língua (descrição). Antes de qualquer tratamento foi descrito quem faz mais o ENEM e quem tira notas maiores, com as 2.692.427 linhas e sem tomar decisão de modelo a partir disso. Quem escolheu inglês tem média 74,5 pontos maior que quem escolheu espanhol (efeito de 0,60 desvio padrão).

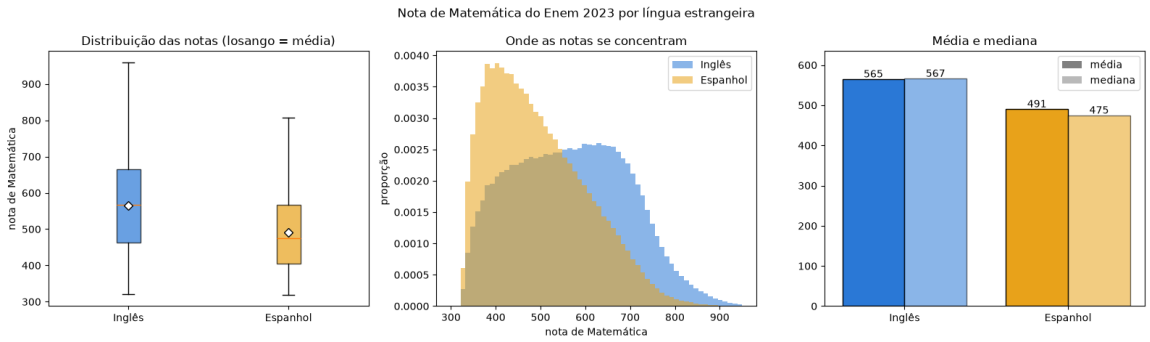


Figura 3. Nota de Matemática por língua estrangeira (inglês × espanhol), 2.692.427 participantes, descrição sem decisão de modelo. Fonte: Inep, ENEM 2023.

4.4 Correlação de Spearman e redundância. O Spearman (correlação de ranking) mede a relação de cada coluna com a nota e quais colunas se repetem. Limite de redundância: $|\rho| > 0{,}7$. Colunas nominais não entram na fusão, porque o código numérico não tem ordem. Quatro colunas da situação escolar (`IN_TREINEIRO`, `TP_ANO_CONCLUIU`, `TP_FAIXA_ETARIA`, `TP_ST_CONCLUSAO`; pares de 0,885, −0,842 e 0,728) foram fundidas na `FUSAO_1`: média dos z-scores, com sinal invertido em `TP_ANO_CONCLUIU` e `TP_FAIXA_ETARIA`. No notebook 04 essa fusão é comparada com manter as quatro colunas separadas (seção 9).

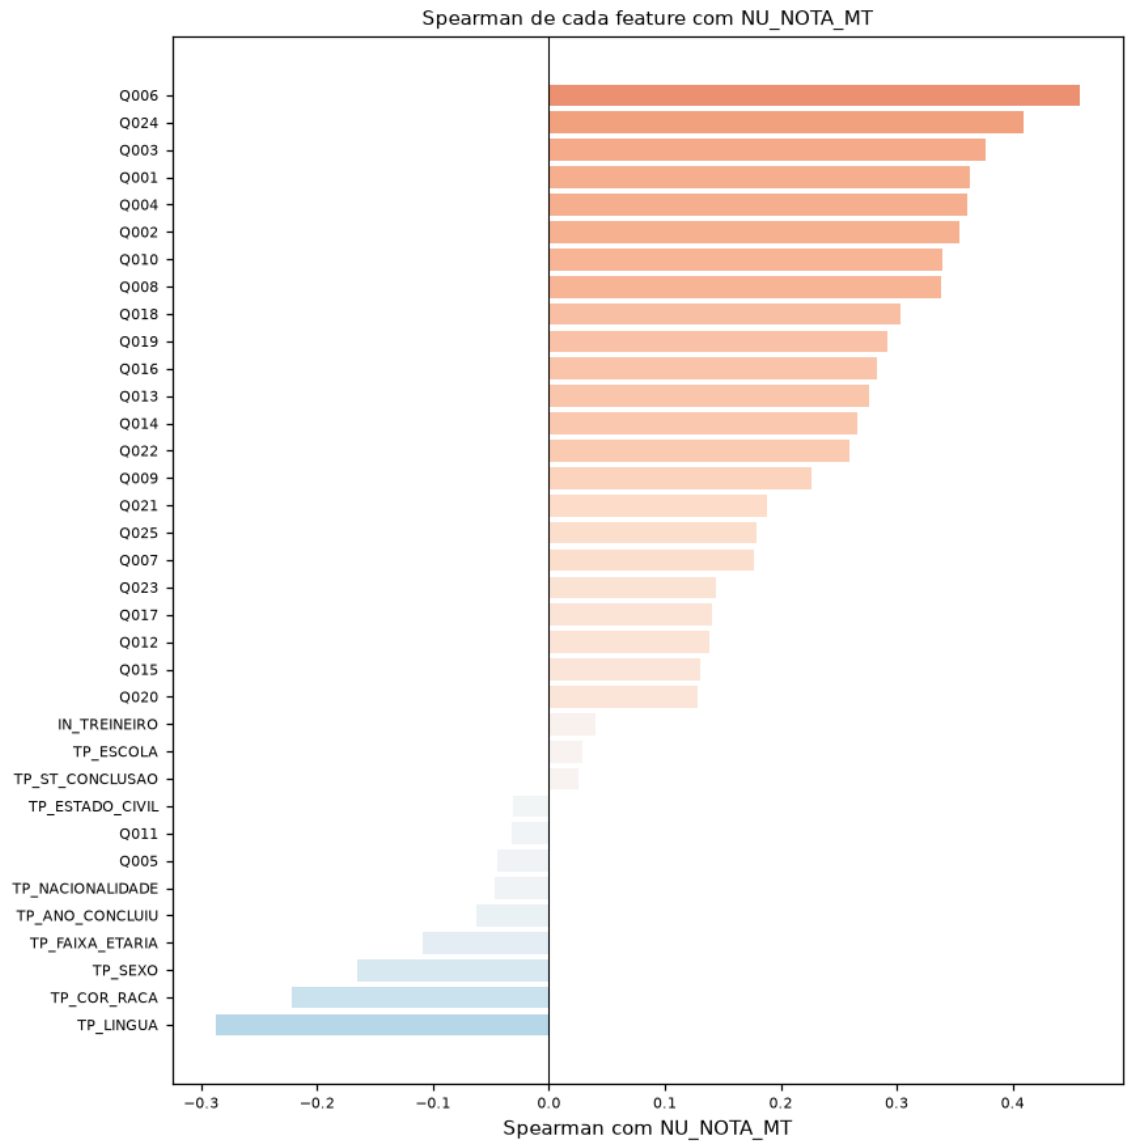


Figura 4. Spearman de cada feature com a nota, antes da fusão das colunas redundantes. Fonte: Inep, ENEM 2023.

Tabela da Figura 4: Spearman de cada coluna com a nota, antes da fusão (35 colunas, da maior para a menor correlação). Calculado nos 2.692.427 participantes com nota, no notebook 01, antes da partição 80/20; essa correlação não escolheu modelo nem hiperparâmetro (a seleção de atributos do notebook 04 usa só o treino de cada dobra). ρ positivo: quanto mais da coluna, maior a nota. As descrições seguem o dicionário do Inep.

Coluna	O que é	ρ com a nota
`Q006`	renda familiar mensal	+0,457
`Q024`	computadores	+0,409

Coluna	O que é	ρ com a nota
`Q003`	ocupação do pai ou responsável	+0,377
`Q001`	escolaridade do pai ou responsável	+0,364
`Q004`	ocupação da mãe ou responsável	+0,361
`Q002`	escolaridade da mãe ou responsável	+0,354
`Q010`	carros	+0,339
`Q008`	banheiros	+0,339
`Q018`	aspirador de pó	+0,303
`Q019`	televisores	+0,292
`Q016`	micro-ondas	+0,283
`Q013`	freezers	+0,276
`Q014`	máquina de lavar roupa	+0,266
`Q022`	celulares	+0,259
`Q009`	quartos para dormir	+0,227
`Q021`	TV por assinatura	+0,188
`Q025`	acesso à internet	+0,179
`Q007`	empregado doméstico	+0,177
`Q023`	telefone fixo	+0,144
`Q017`	máquina de lavar louça	+0,141
`Q012`	geladeiras	+0,139
`Q015`	máquina de secar roupa	+0,131
`Q020`	aparelho de DVD	+0,128
`IN_TREINEIRO`	treineiro (0/1)	+0,040
`TP_ESCOLA`	tipo de escola (declarado)	+0,029
`TP_ST_CONCLUSAO`	situação de conclusão do ensino médio	+0,026
`TP_ESTADO_CIVIL`	estado civil	−0,031
`Q011`	motocicletas	−0,033
`Q005`	pessoas na residência	−0,045
`TP_NACIONALIDADE`	nacionalidade	−0,047
`TP_ANO_CONCLUIU`	ano de conclusão do ensino médio	−0,063
`TP_FAIXA_ETARIA`	faixa etária	−0,109

Coluna	O que é	ρ com a nota
`TP_SEXO`	sexo	−0,165
`TP_COR_RACA`	cor/raça	−0,222
`TP_LINGUA`	língua estrangeira (inglês ou espanhol)	−0,287

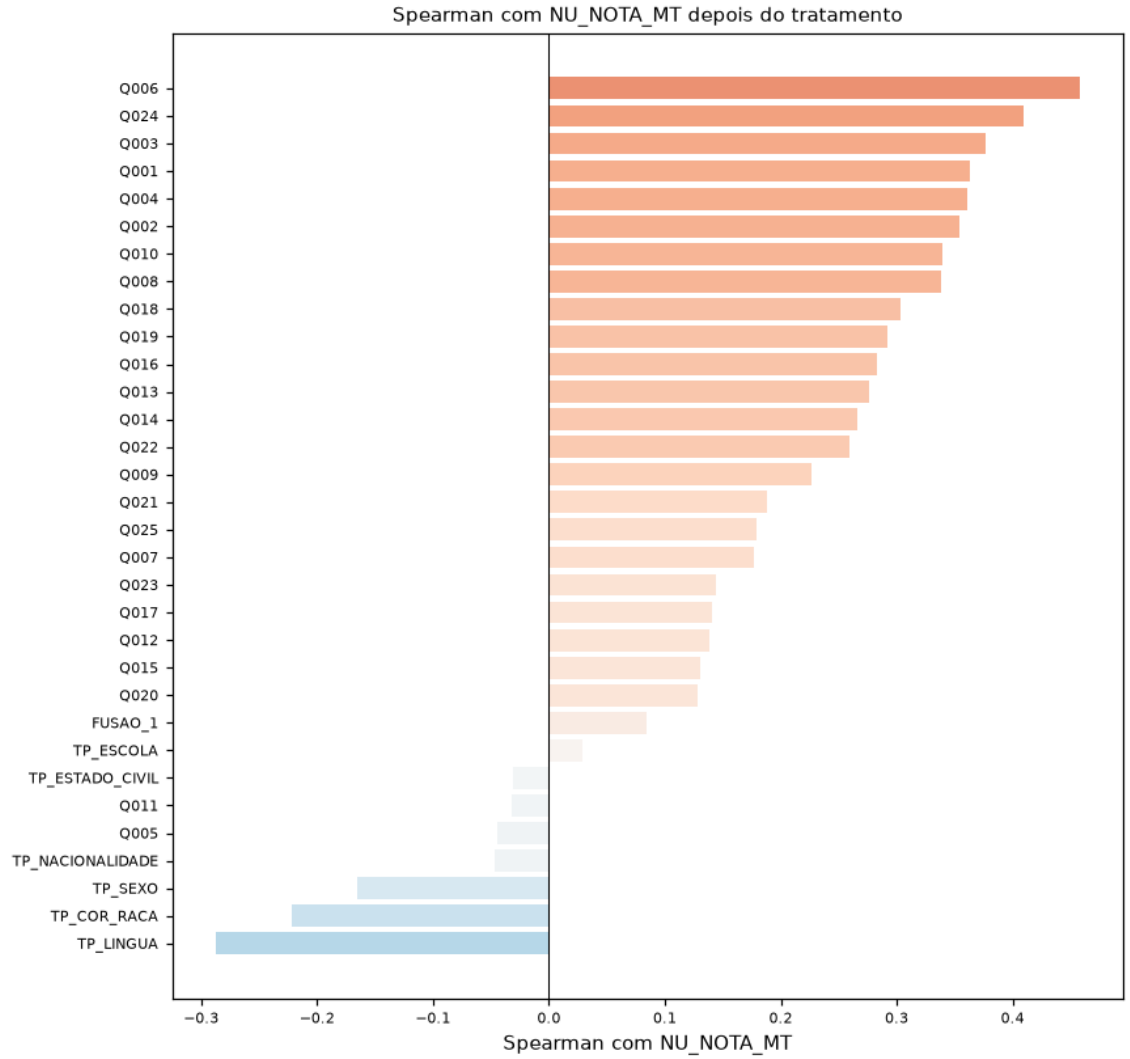


Figura 5. Spearman de cada feature com a nota, depois da fusão (dataset 1). Fonte: Inep, ENEM 2023.

Tabela da Figura 5: Spearman de cada coluna com a nota, depois da fusão (32 colunas). As quatro colunas de situação escolar (`IN_TREINEIRO`, `TP_ANO_CONCLUIU`, `TP_FAIXA_ETARIA`, `TP_ST_CONCLUSAO`) viram `FUSAO_1`. Estes valores são anteriores ao tratamento do "não sei" em Q001 a Q004 (seção 5); depois dele, veja a tabela da Figura 10.

Coluna	O que é	ρ com a nota
`Q006`	renda familiar mensal	+0,457

Coluna	O que é	ρ com a nota
Q024	computadores	+0,409
Q003	ocupação do pai ou responsável	+0,377
Q001	escolaridade do pai ou responsável	+0,364
Q004	ocupação da mãe ou responsável	+0,361
Q002	escolaridade da mãe ou responsável	+0,354
Q010	carros	+0,339
Q008	banheiros	+0,339
Q018	aspirador de pó	+0,303
Q019	televisores	+0,292
Q016	micro-ondas	+0,283
Q013	freezers	+0,276
Q014	máquina de lavar roupa	+0,266
Q022	celulares	+0,259
Q009	quartos para dormir	+0,227
Q021	TV por assinatura	+0,188
Q025	acesso à internet	+0,179
Q007	empregado doméstico	+0,177
Q023	telefone fixo	+0,144
Q017	máquina de lavar louça	+0,141
Q012	geladeiras	+0,139
Q015	máquina de secar roupa	+0,131
Q020	aparelho de DVD	+0,128
FUSAO_1	fusão das 4 colunas de situação escolar	+0,084
TP_ESCOLA	tipo de escola (declarado)	+0,029
TP_ESTADO_CIVIL	estado civil	−0,031
Q011	motocicletas	−0,033
Q005	pessoas na residência	−0,045
TP_NACIONALIDADE	nacionalidade	−0,047
TP_SEXO	sexo	−0,165
TP_COR_RACA	cor/raça	−0,222

Coluna	O que é	ρ com a nota
`TP_LINGUA`	língua estrangeira (inglês ou espanhol)	−0,287

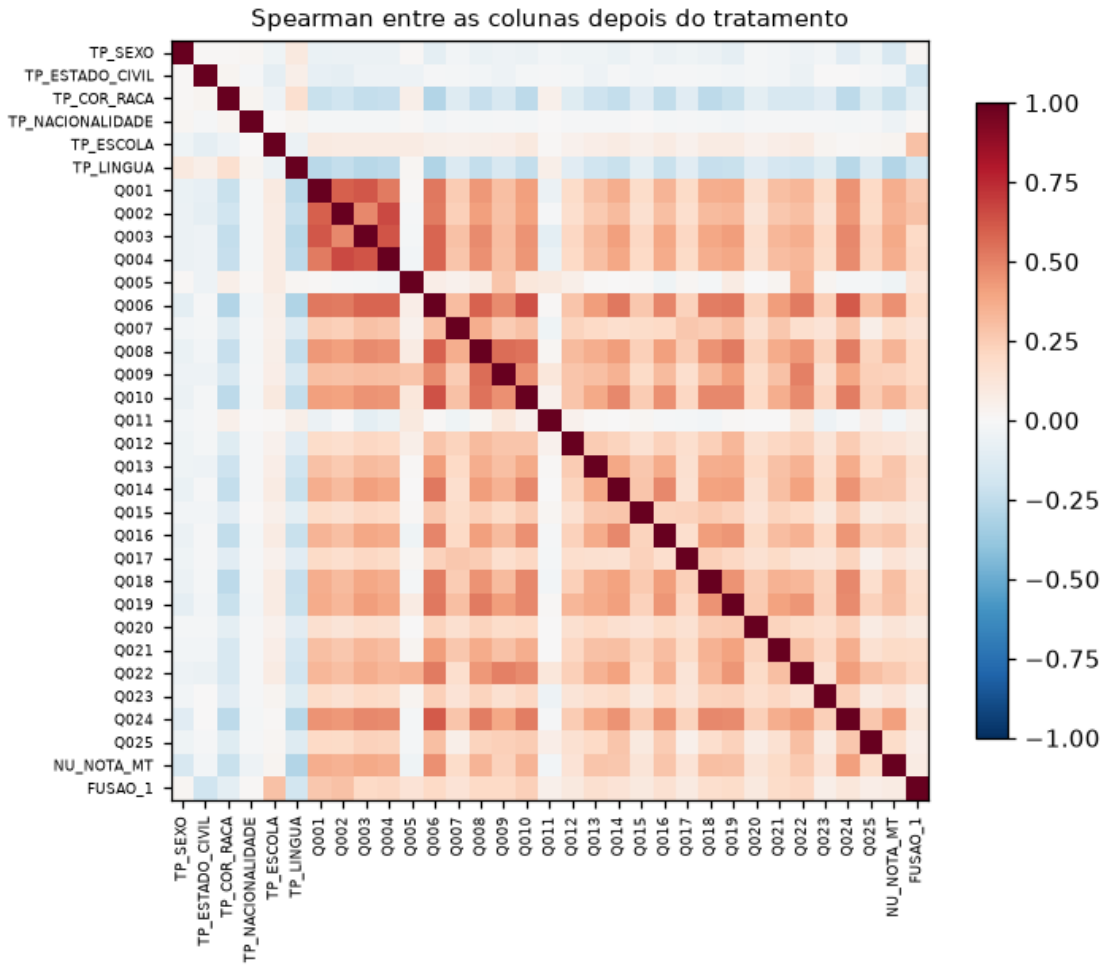


Figura 6. Matriz de Spearman entre as colunas depois da fusão: nenhum par passa de 0,7. Fonte: Inep, ENEM 2023.

Tabela da Figura 6: pares de colunas com |ρ| ≥ 0,50 depois da fusão (22 pares, valores arredondados em 2 casas, como na matriz da figura). O limite de redundância é 0,70, e nenhum par o atinge; o maior é `Q002` × `Q004` (0,66).

Coluna 1	Coluna 2	ρ
`Q002`	`Q004`	+0,66
`Q006`	`Q010`	+0,64
`Q003`	`Q004`	+0,63

Coluna 1	Coluna 2	ρ
Q001	Q003	+0,62
Q006	Q024	+0,61
Q001	Q002	+0,60
Q006	Q008	+0,59
Q003	Q006	+0,58
Q004	Q006	+0,58
Q008	Q009	+0,56
Q008	Q010	+0,54
Q001	Q006	+0,53
Q006	Q014	+0,53
Q006	Q019	+0,53
Q001	Q004	+0,52
Q002	Q006	+0,52
Q006	Q022	+0,52
Q008	Q019	+0,52
Q006	Q018	+0,51
Q008	Q024	+0,51
Q010	Q024	+0,51
Q009	Q022	+0,50

4.5 Colunas que saíram de vários datasets. TP_NACIONALIDADE (97,8% são brasileiros) e TP_ESCOLA (61% "não respondeu") saíram da primeira versão do dataset 1 por serem desproporcionais, e voltaram nos datasets 2 e 3 em colunas 0/1. As quatro colunas DEP_* (dependência administrativa da escola) foram retiradas por redundância: ESCOLA_PRIVADA × DEP_PRIVADA tem ρ = 0,88 e DEP_ESTADUAL × LOC_URBANA tem 0,73.

5. Datasets e features criadas

Foram montados oito datasets, todos com as mesmas 2.692.427 linhas, na ordem de ids_elegiveis.csv, sem nenhum valor nulo e com o alvo na última coluna. Os cinco primeiros crescem por camadas; o dataset 3 devolve as colunas que tinham saído por serem desproporcionais.

Dataset	Features	Composição
dataset_1_fundido	30	Perfil (sexo, estado civil, cor/raça, língua), Q001 a Q025 e FUSAO_1

Dataset	Features	Composição
`dataset_1_features`	33	Dataset 1 + 3 features criadas
`dataset_2_escola`	34	Dataset 1 + 4 colunas de escola (0/1): `ESCOLA_PUBLICA`, `ESCOLA_PRIVADA`, `LOC_URBANA`, `LOC_RURAL`
`dataset_2_features_escola`	37	Dataset 2 + 3 features criadas
`dataset_3_sem_escola`	38	Dataset 1 + 4 colunas `NAO_SEI` + 4 colunas de nacionalidade
`dataset_3_sem_escola_features`	41	Dataset 3 sem escola + 3 features criadas
`dataset_3_escola`	42	Dataset 2 + `NAO_SEI` + nacionalidade
`dataset_3_escola_features`	45	Dataset 2 + features + `NAO_SEI` + nacionalidade (o maior)

5.1 As 3 features criadas e suas hipóteses. A primeira versão (renda per capita, escolaridade máxima dos responsáveis e acesso digital) tinha Spearman de 0,89 a 0,94 com as colunas de origem, ou seja, repetia informação, e foi descartada. Entre 29 candidatas, ficaram as que não passam de $|\rho| = 0{,}7$ com nenhuma coluna nem entre si.

Feature	Hipótese	Spearman com a nota
`PESSOAS_POR_QUARTO` (pessoas ÷ quartos, mínimo 1 quarto)	Casa mais lotada, menos espaço para estudar	−0,221
`CELULAR_POR_MORADOR` (celulares ÷ pessoas)	Mais celulares por pessoa, mais acesso próprio a conteúdo e aulas online	+0,280
`RENDA_MENOS_ESCOL` (renda 0 a 1 − escolaridade máxima 0 a 1)	Renda alta (ou baixa) para o nível de estudo da família carrega informação extra	+0,090

Cuidados com aproximações: a renda é uma faixa (a escala 0 a 1 usa a posição da faixa, não um valor em reais), as contagens de bens vão só de 0 a 4 e o denominador de quartos tem mínimo 1, para não dividir por zero. Todas são calculadas linha a linha com colunas da própria linha, então não vazam informação do teste.

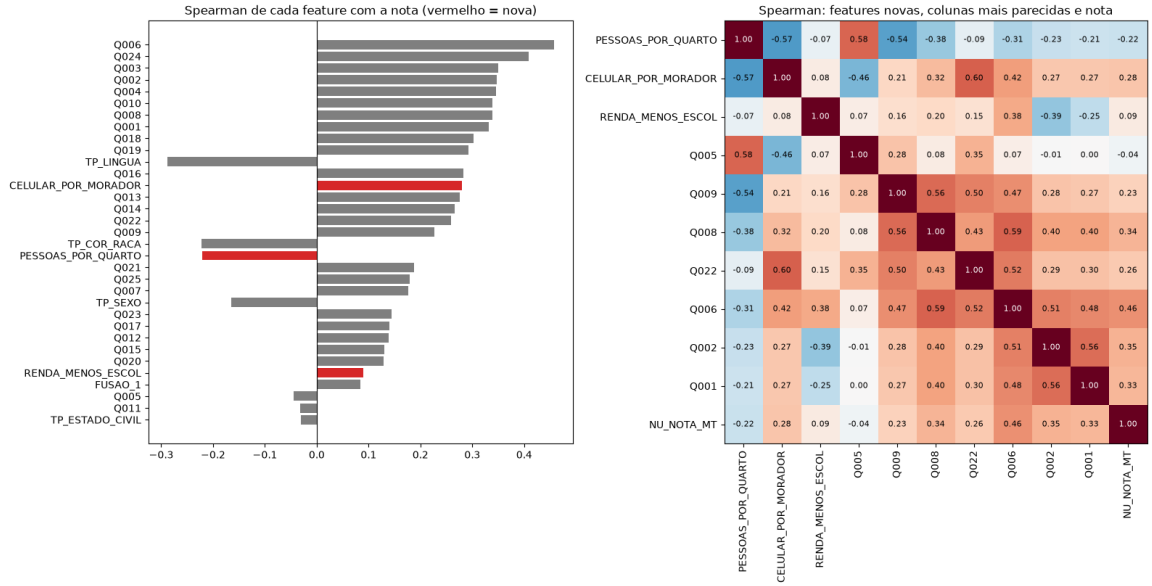


Figura 7. As três features criadas: Spearman com a nota, com as colunas mais parecidas e matriz resumida. Fonte: Inep, ENEM 2023.

Tabela da Figura 7: as três features criadas. ρ com a nota e as três colunas mais parecidas com cada uma (limite de redundância 0,70; a maior, 0,60, está longe dele).

Feature criada	O que é	ρ com a nota	Colunas mais parecidas (ρ)
`PESSOAS_POR_QUARTO`	pessoas na casa por quarto (`Q005` / `Q009`)	−0,221	`Q005` +0,58; `Q009` −0,54; `Q008` −0,38
`CELULAR_POR_MORADOR`	celulares por morador (`Q022` / `Q005`)	+0,280	`Q022` +0,60; `Q005` −0,46; `Q006` +0,42
`RENDA_MENOS_ESCOL`	renda menos escolaridade	+0,090	`Q002` −0,39; `Q006` +0,38; `Q001` −0,25

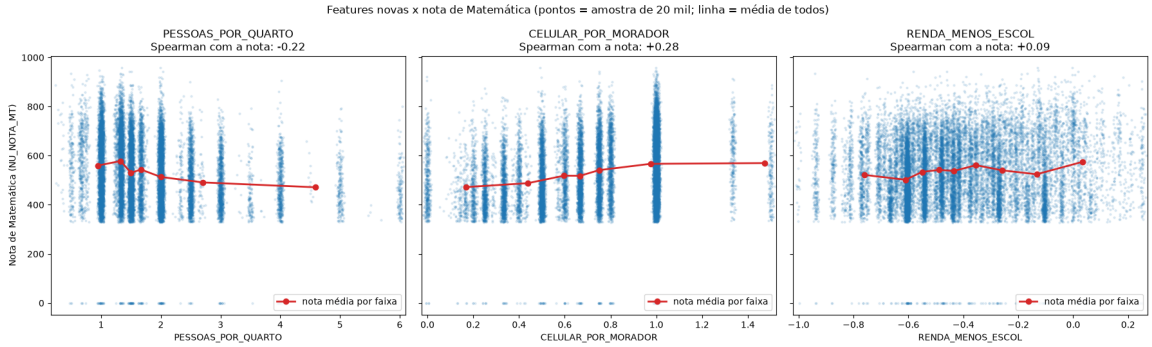


Figura 8. Features criadas contra a nota de Matemática (pontos: amostra de 20 mil; linha vermelha: nota média por faixa, com todas as linhas). Fonte: Inep, ENEM 2023.

5.2 Escola (dataset 2). O vazio nas colunas da escola (73%) é “sem informação” e fica como referência (todas as colunas de escola em 0). Spearman com a nota: `ESCOLA_PUBLICA` −0,150, `ESCOLA_PRIVADA` +0,217, `LOC_URBANA` +0,068, `LOC_RURAL` −0,028. Nenhum par passa de 0,7 depois de tirar as `DEP_*`.

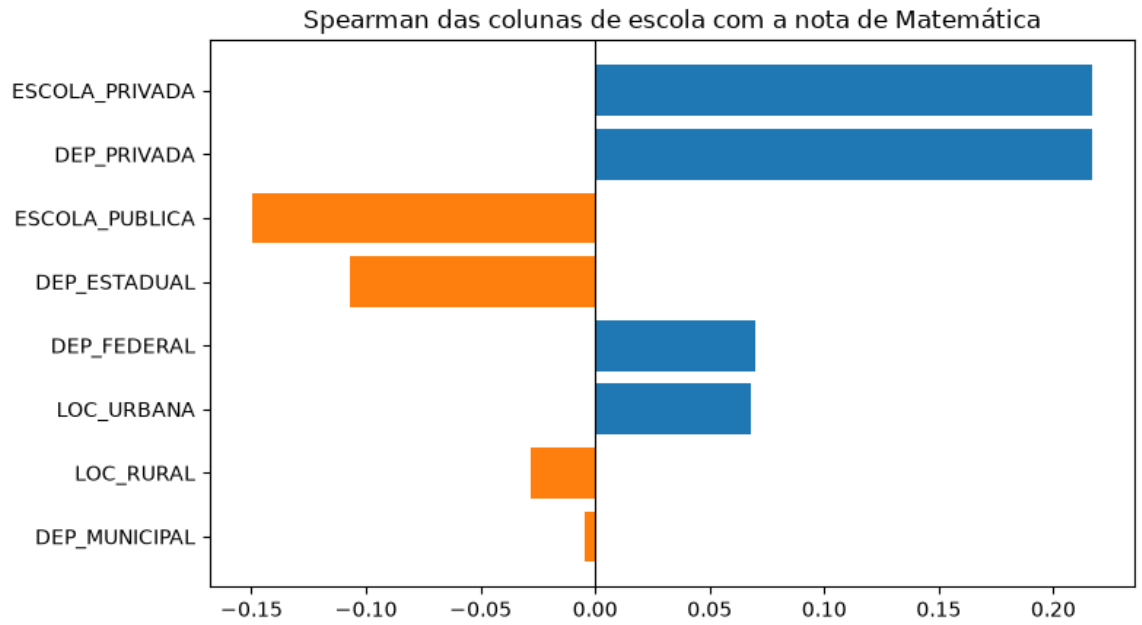


Figura 9. Spearman das oito colunas de escola com a nota, antes de retirar as `DEP_*`. Fonte: Inep, ENEM 2023.

Tabela da Figura 9: as colunas de escola. ρ com a nota e a coluna mais parecida com cada uma (redundante quando |ρ| > 0,70).

Coluna	O que é	ρ com a nota	Mais parecida com outra coluna	Situação
`ESCOLA_PRIVADA`	escola privada (0/1)	+0,217	`DEP_PRIVADA` (0,880)	redundante
`DEP_PRIVADA`	escola privada, pela dependência (0/1)	+0,217	`ESCOLA_PRIVADA` (0,880)	redundante
`ESCOLA_PUBLICA`	escola pública (0/1)	−0,150	`DEP_ESTADUAL` (0,677)	ok
`DEP_ESTADUAL`	escola estadual (0/1)	−0,107	`LOC_URBANA` (0,727)	redundante
`DEP_FEDERAL`	escola federal (0/1)	+0,070	`ESCOLA_PUBLICA` (0,193)	ok
`LOC_URBANA`	escola em zona urbana (0/1)	+0,068	`DEP_ESTADUAL` (0,727)	redundante
`LOC_RURAL`	escola em zona rural (0/1)	−0,028	`DEP_FEDERAL` (0,152)	ok

Coluna	O que é	ρ com a nota	Mais parecida com outra coluna	Situação
`DEP_MUNICIPAL`	escola municipal (0/1)	−0,005	`LOC_URBANA` (0,069)	ok

5.3 Não sei e nacionalidade (dataset 3).

Coluna	O que é	Pessoas	Nota média de quem marcou	Nota média de quem respondeu
`Q001_NAO_SEI`	não sabe a escolaridade do pai	9,3%	497	538
`Q002_NAO_SEI`	não sabe a escolaridade da mãe	2,9%	483	535
`Q003_NAO_SEI`	não sabe a ocupação do pai	11,9%	502	538
`Q004_NAO_SEI`	não sabe a ocupação da mãe	8,7%	516	536
`NAC_*` (4 colunas)	nacionalidade em 0/1 (referência: brasileiro, 97,8%)	0,05% a 1,8%	478 a 575	535 (brasileiros)

Nenhum par do dataset 3 passa de 0,7 de Spearman.

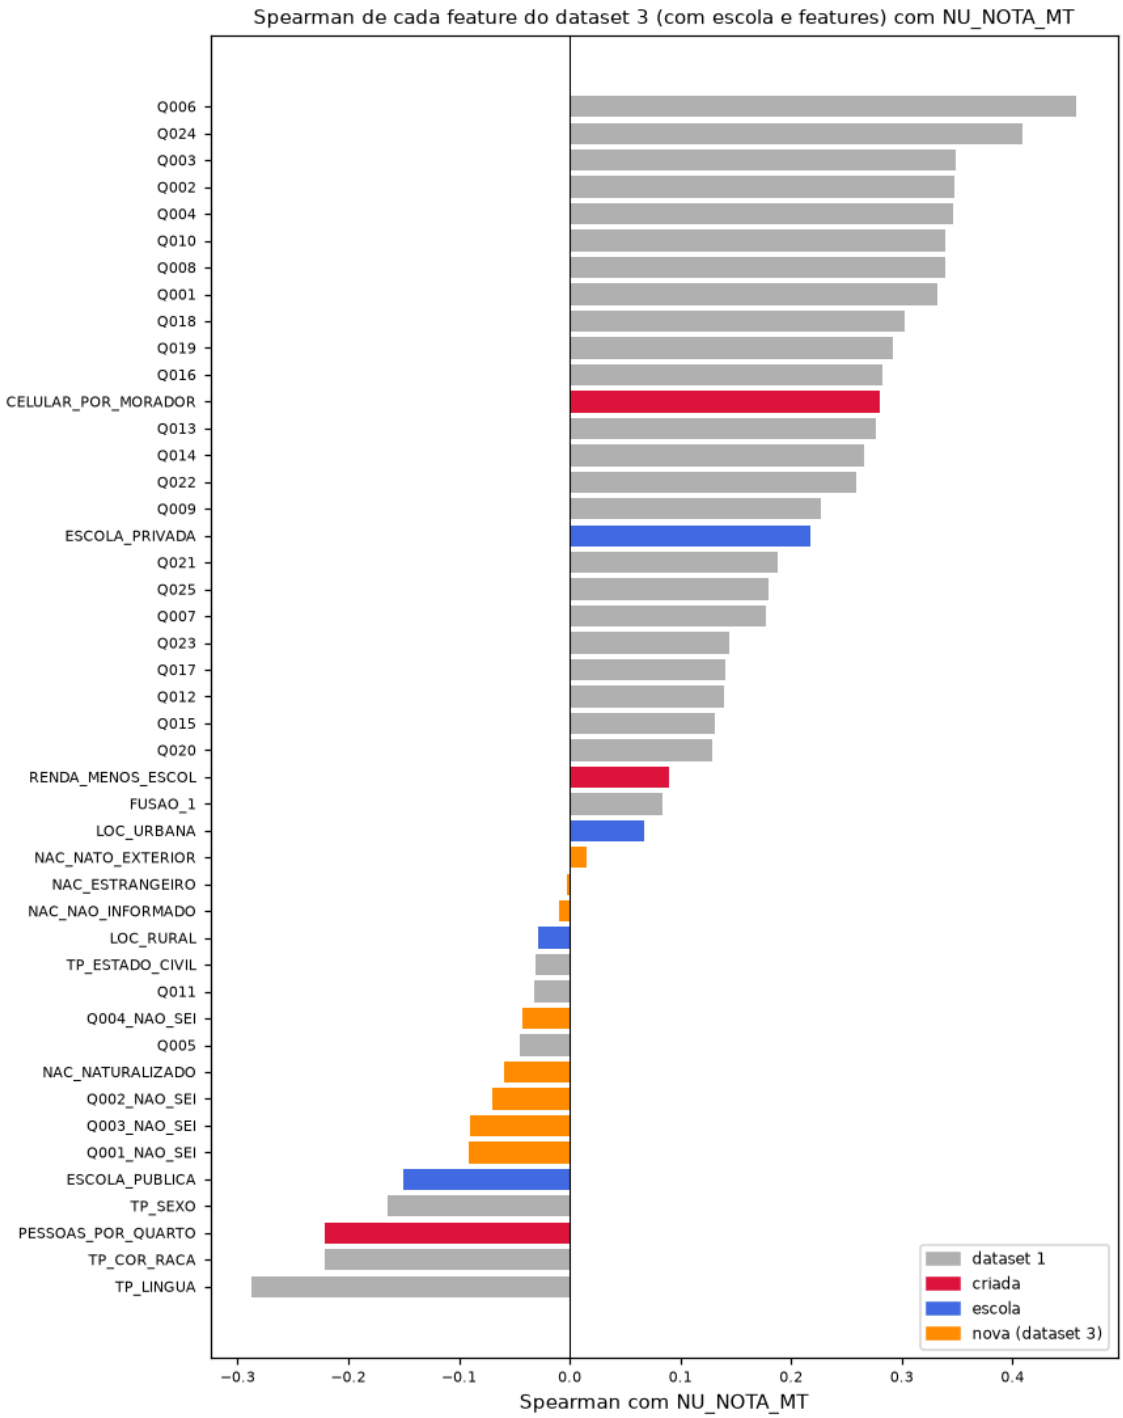


Figura 10. Dataset 3 (maior tabela): Spearman de cada feature com a nota; em destaque as colunas `NAO_SEI` e de nacionalidade. Fonte: Inep, ENEM 2023.

Tabela da Figura 10: Spearman de todas as colunas do dataset 3 com a nota (45 colunas, depois do tratamento do “não sei”). O gráfico mostra só as 30 colunas originais; esta tabela traz também as criadas, as de escola e os indicadores de “não sei” e de nacionalidade.

Coluna	O que é	ρ com a nota
`Q006`	renda familiar mensal	+0,457
`Q024`	computadores	+0,409
`Q003`	ocupação do pai ou responsável	+0,349
`Q002`	escolaridade da mãe ou responsável	+0,347
`Q004`	ocupação da mãe ou responsável	+0,346
`Q010`	carros	+0,339
`Q008`	banheiros	+0,339
`Q001`	escolaridade do pai ou responsável	+0,332
`Q018`	aspirador de pó	+0,303
`Q019`	televisores	+0,292
`Q016`	micro-ondas	+0,283
`CELULAR_POR_MORADOR`	criada: celulares por morador (Q022 / Q005)	+0,280
`Q013`	freezers	+0,276
`Q014`	máquina de lavar roupa	+0,266
`Q022`	celulares	+0,259
`Q009`	quartos para dormir	+0,227
`ESCOLA_PRIVADA`	escola privada (0/1)	+0,217
`Q021`	TV por assinatura	+0,188
`Q025`	acesso à internet	+0,179
`Q007`	empregado doméstico	+0,177
`Q023`	telefone fixo	+0,144
`Q017`	máquina de lavar louça	+0,141
`Q012`	geladeiras	+0,139
`Q015`	máquina de secar roupa	+0,131
`Q020`	aparelho de DVD	+0,128
`RENDA_MENOS_ESCOL`	criada: renda menos escolaridade	+0,090
`FUSAO_1`	fusão das 4 colunas de situação escolar	+0,084
`LOC_URBANA`	escola em zona urbana (0/1)	+0,068
`NAC_NATO_EXTERIOR`	brasileiro nato no exterior (0/1)	+0,015
`NAC_ESTRANGEIRO`	estrangeiro (0/1)	−0,003

Coluna	O que é	ρ com a nota
NAC_NAO_INFORMADO	nacionalidade não informada (0/1)	−0,010
LOC_RURAL	escola em zona rural (0/1)	−0,028
TP_ESTADO_CIVIL	estado civil	−0,031
Q011	motocicletas	−0,033
Q004_NAO_SEI	indicador: não sabe a ocupação da mãe	−0,043
Q005	pessoas na residência	−0,045
NAC_NATURALIZADO	brasileiro naturalizado (0/1)	−0,059
Q002_NAO_SEI	indicador: não sabe a escolaridade da mãe	−0,070
Q003_NAO_SEI	indicador: não sabe a ocupação do pai	−0,089
Q001_NAO_SEI	indicador: não sabe a escolaridade do pai	−0,091
ESCOLA_PUBLICA	escola pública (0/1)	−0,150
TP_SEXO	sexo	−0,165
PESSOAS_POR_QUARTO	criada: pessoas por quarto (Q005 / Q009)	−0,221
TP_COR_RACA	cor/raça	−0,222
TP_LINGUA	língua estrangeira (inglês ou espanhol)	−0,287

6. Modelos em configuração inicial

Todos os regressores obrigatórios foram medidos no `dataset_1_fundido` (30 features), nas mesmas 3 dobras, com a configuração inicial registrada antes de qualquer busca. Modelos que usam distância ou pesos (regressão linear, KNN, SVR) têm um `StandardScaler` dentro do Pipeline, ajustado só no treino de cada dobra.

Modelo	RMSE (média ± desvio)	MAE	R^2	Tempo por dobra (s)	Menos erro que o baseline
Stacking	107,763 ± 0,226	83,804	0,330	630	18,1%
Gradient Boosting	107,770 ± 0,226	83,825	0,330	133	18,1%
Random Forest	109,422 ± 0,195	85,494	0,309	103	16,9%
Pasting	110,012 ± 0,208	85,996	0,302	20	16,4%
Bagging	110,014 ± 0,207	85,991	0,302	24	16,4%
Árvore de decisão	110,551 ± 0,190	86,381	0,295	3,0	16,0%
Ridge (alpha = 1)	111,153 ± 0,178	86,960	0,287	0,3	15,6%
Regressão linear	111,153 ± 0,178	86,960	0,287	0,7	15,6%

Modelo	RMSE (média ± desvio)	MAE	R^2	Tempo por dobra (s)	Menos erro que o baseline
SVR linear (LinearSVR)	111,153 ± 0,178	86,961	0,287	1,9	15,6%
KNN (50 vizinhos)	111,575 ± 0,184	87,180	0,282	476	15,2%
Baseline (média)	131,634 ± 0,158	107,582	0,000	0,06	0,0%

Configurações iniciais. Árvore com `max_depth=10` e `min_samples_leaf=50`; KNN com 50 vizinhos e `algorithm='brute'`; LinearSVR com `C=1` e `epsilon=0` (o SVR com kernel RBF custa o quadrado do tamanho da base e foi descartado após medição em amostras de 2.000 a 8.000 pessoas); bagging com 20 árvores e `bootstrap=True`; pasting com 20 árvores, `bootstrap=False` e `max_samples=0,5`; Random Forest com 100 árvores, `max_depth=12`, `min_samples_leaf=50` e `max_features=0,5`; Gradient Boosting (`HistGradientBoostingRegressor`) com `learning_rate=0,1`, até 300 árvores de 31 folhas e parada antecipada com 10% do treino da dobra; stacking com Ridge, árvore e Gradient Boosting como base e Ridge como modelo final, com previsões fora da dobra.

6.1 Baseline. Prever sempre a média (533,8) erra, em média, o próprio desvio padrão (RMSE 131,634) e tem R^2 zero. É a régua: qualquer modelo útil precisa ter RMSE menor e R^2 maior que zero.

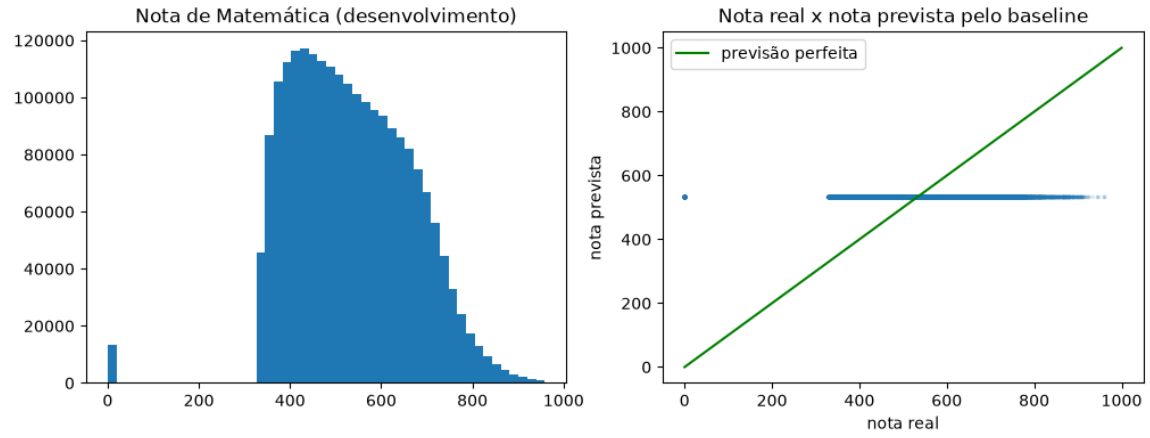


Figura 11. Baseline: distribuição da nota (esquerda) e nota real × nota prevista (direita): prever a média dá uma reta horizontal. Fonte: Inep, ENEM 2023; desenvolvimento.

6.2 Regressão linear. A nota é uma soma ponderada das features. Pesos em pontos de nota por desvio padrão: renda (`Q006`) +27,2, computadores (`Q024`) +14,8 e escolaridade da mãe (`Q002`) +10,2 são os maiores positivos; língua (espanhol), sexo (feminino) e `FUSAO_1` são os maiores negativos. É associação nos dados, não causa. A reta do modelo tem inclinação de cerca de 0,29: ele puxa as previsões para a média, subestimando notas altas e superestimando as baixas; os zeros são previstos em cerca de 519 pontos. Ridge e regressão linear dão o mesmo resultado: com 2 milhões de linhas e colunas pouco redundantes, a regularização quase não pesa.

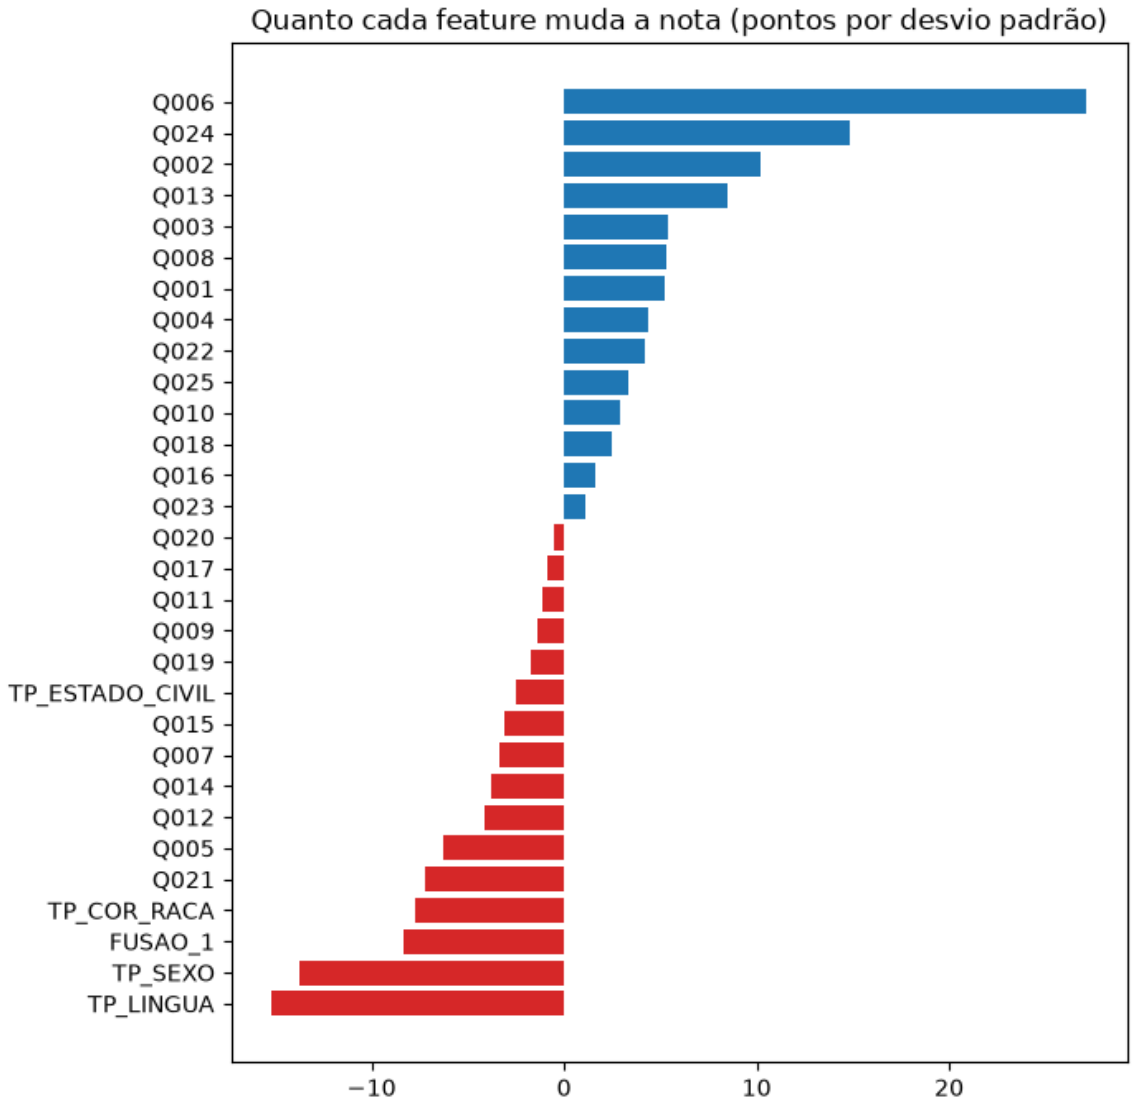


Figura 12. Regressão linear: peso de cada feature (pontos de nota por desvio padrão). Fonte: Inep, ENEM 2023; desenvolvimento.

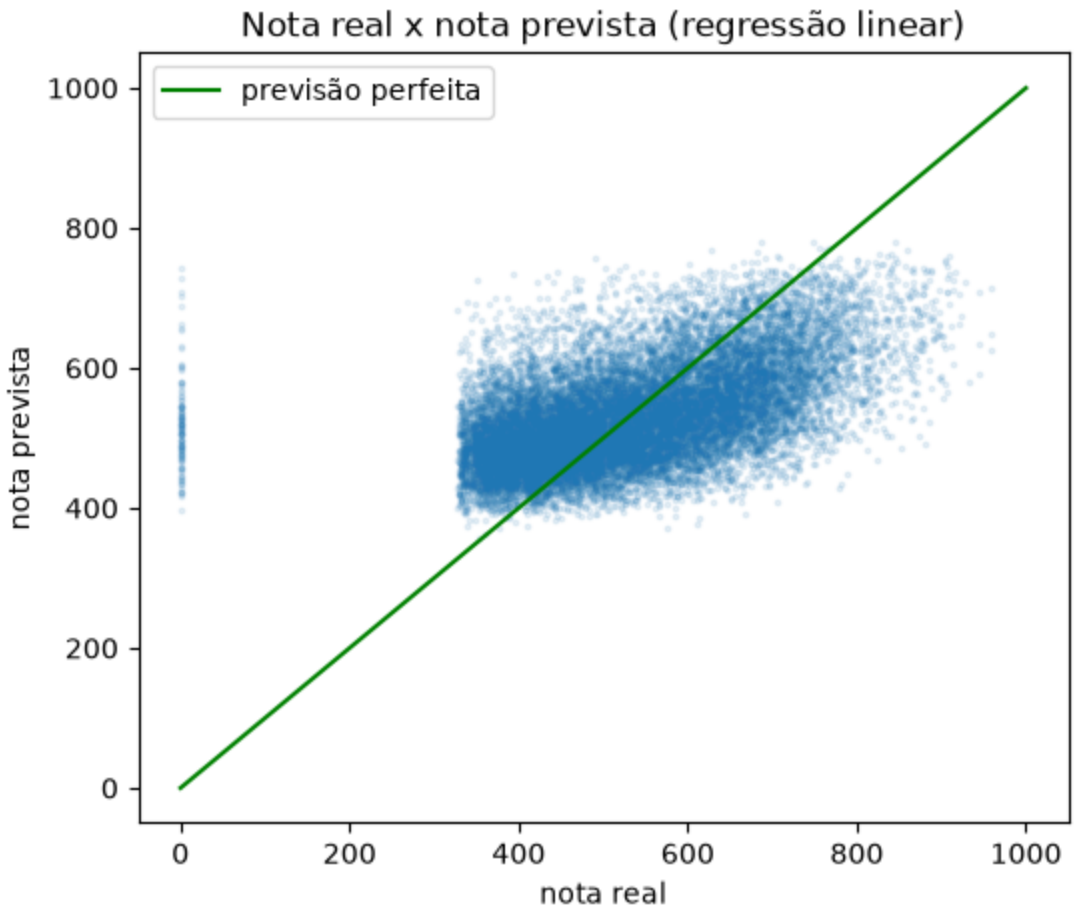


Figura 13. Regressão linear: nota real × nota prevista (previsões fora da dobra); a inclinação de cerca de 0,29 mostra o achatamento para a média. Fonte: Inep, ENEM 2023; desenvolvimento.

6.3 Árvore de decisão. A primeira pergunta (`Q006` ≤ 4) separa 1,49 milhão de pessoas (nota média 499) de 662 mil (612). Em profundidade 10, treino e validação têm R^2 parecidos (0,301 e 0,295); a partir de 15 níveis o treino continua subindo (0,328 e 0,345) e a validação cai (0,291 e 0,280): é o início do sobreajuste. `Q006` concentra 62% da importância, seguida de `Q024` (11,8%), `TP_LINGUA` (7,8%), `FUSAO_1` (4,8%) e `TP_SEXO` (3,7%).

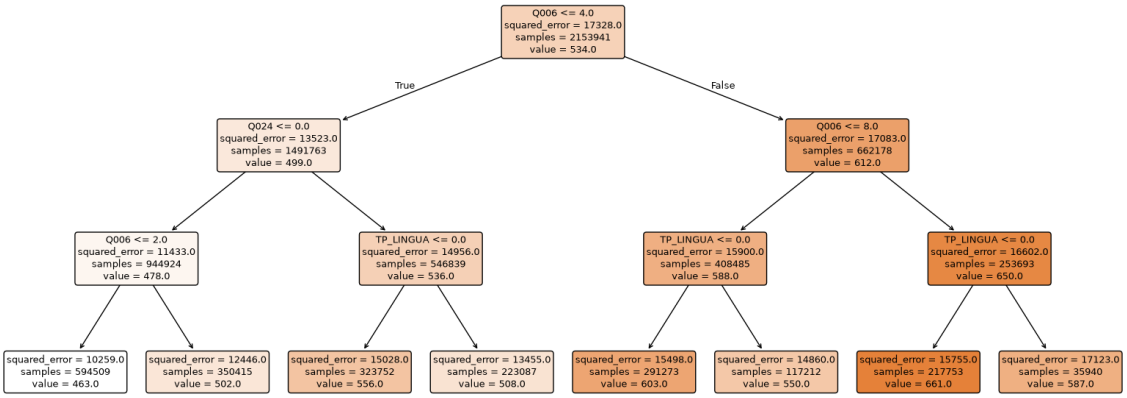


Figura 14. Árvore pequena (3 níveis) para ilustrar como o modelo divide as pessoas. Fonte: Inep, ENEM 2023; desenvolvimento.

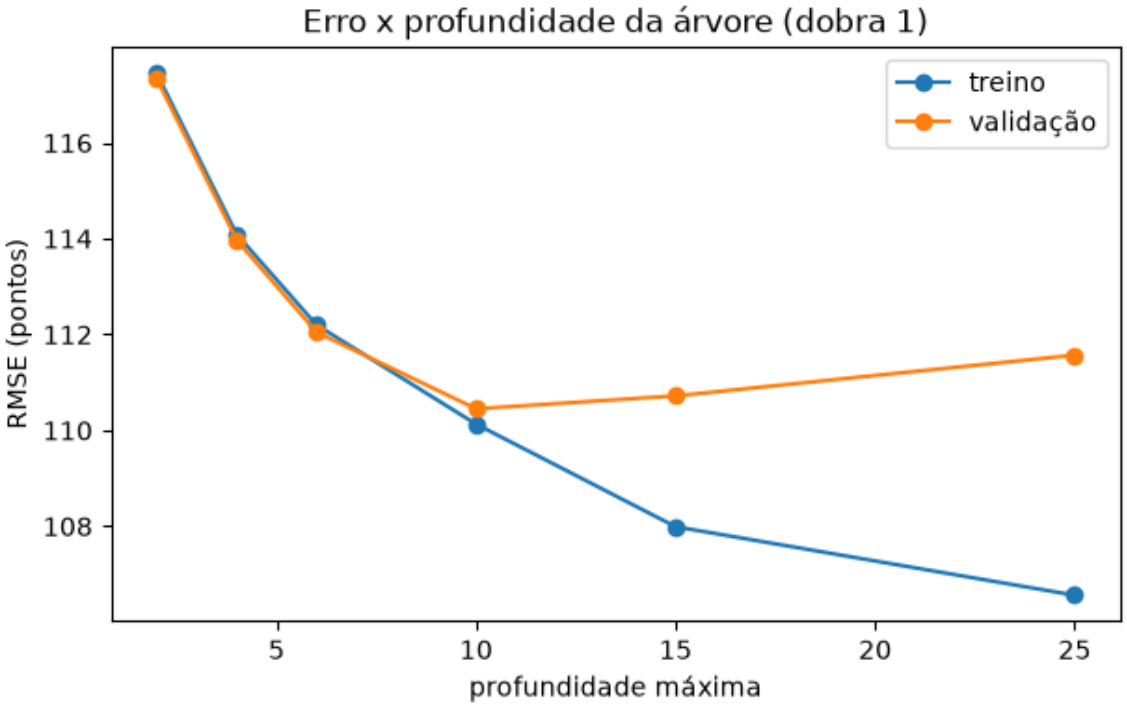


Figura 15. Erro contra profundidade da árvore (dobra 1): o treino continua caindo e a validação volta a subir a partir de 10 níveis, início do sobreajuste. Fonte: Inep, ENEM 2023; desenvolvimento.

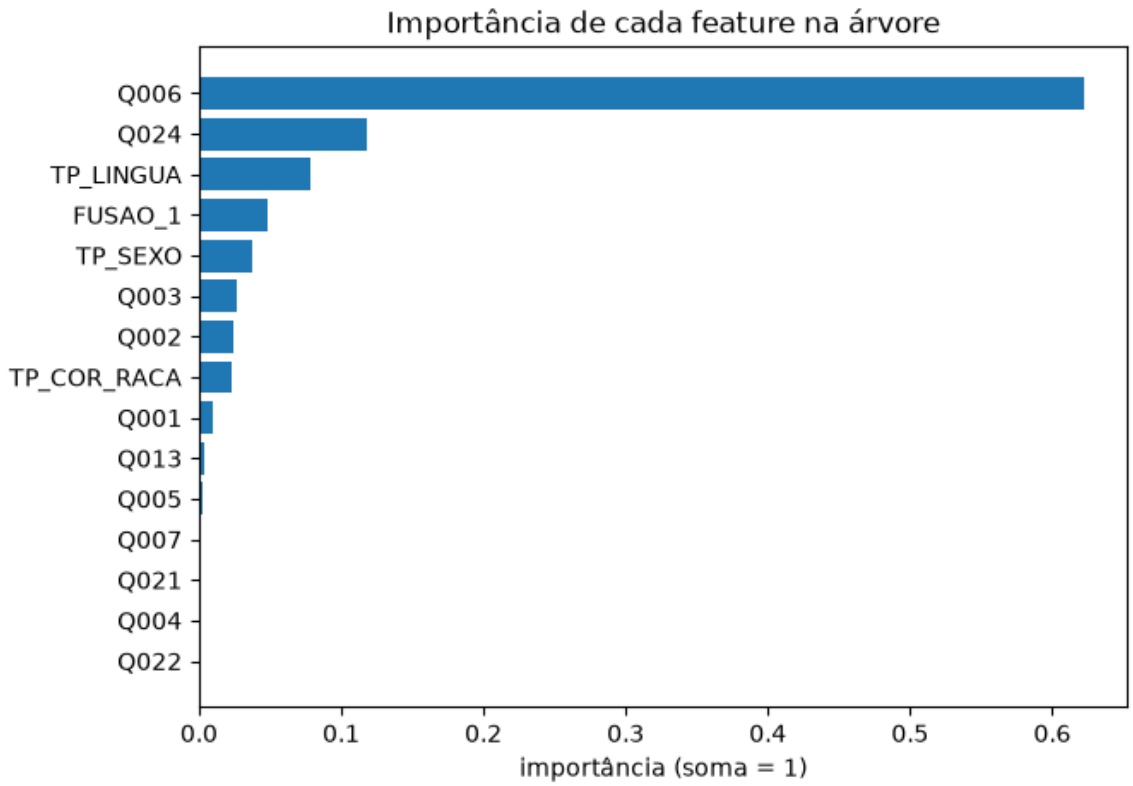


Figura 16. Importância de cada feature na árvore (soma = 1). Fonte: Inep, ENEM 2023; desenvolvimento.

6.4 KNN. Para cada pessoa acha as 50 mais parecidas e prevê a média da nota delas. É o mais lento (cerca de 476 s por dobra: cada previsão compara com cerca de 1,4 milhão de pessoas) e ficou pior que a regressão linear.

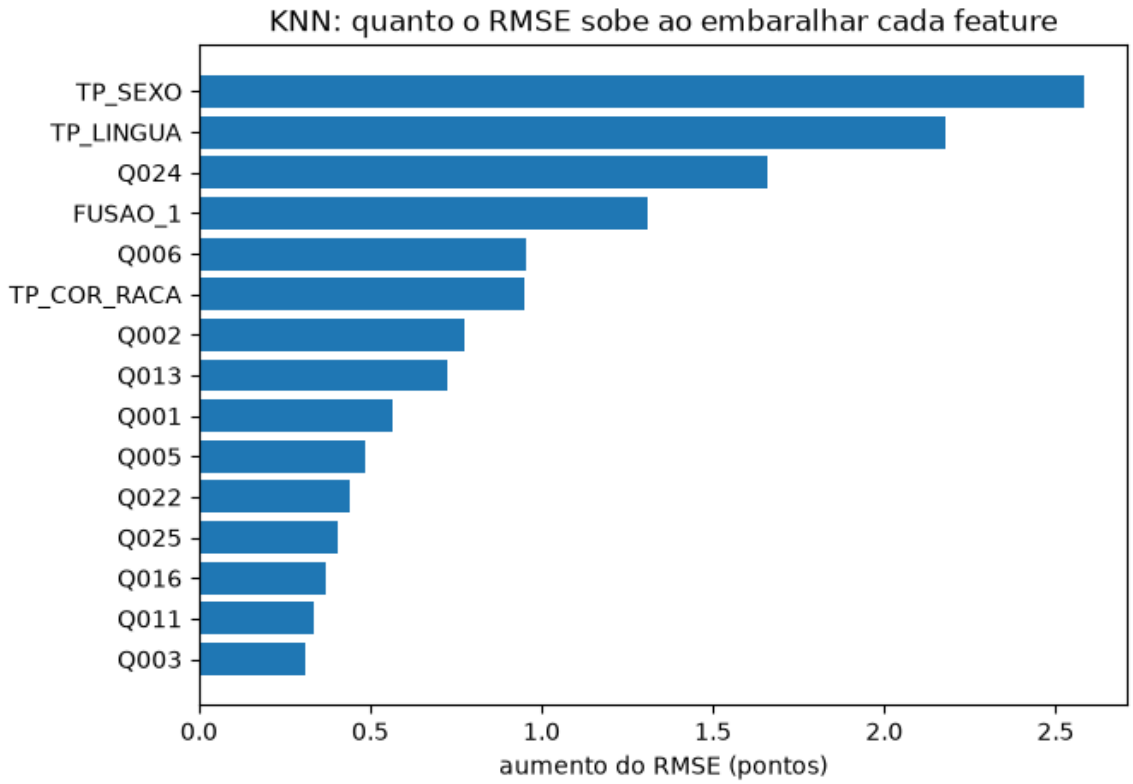


Figura 17. KNN: importância por permutação (quanto o RMSE sobe ao embaralhar a feature), em 3.000 pessoas da validação da dobra 1. Fonte: Inep, ENEM 2023; desenvolvimento.

6.5 SVR linear. Mesmo resultado da regressão linear (111,153). O SVR com kernel compara todos os pares de pessoas e é inviável para 1,4 milhão de linhas; o `LinearSVR` é permitido pelo enunciado.

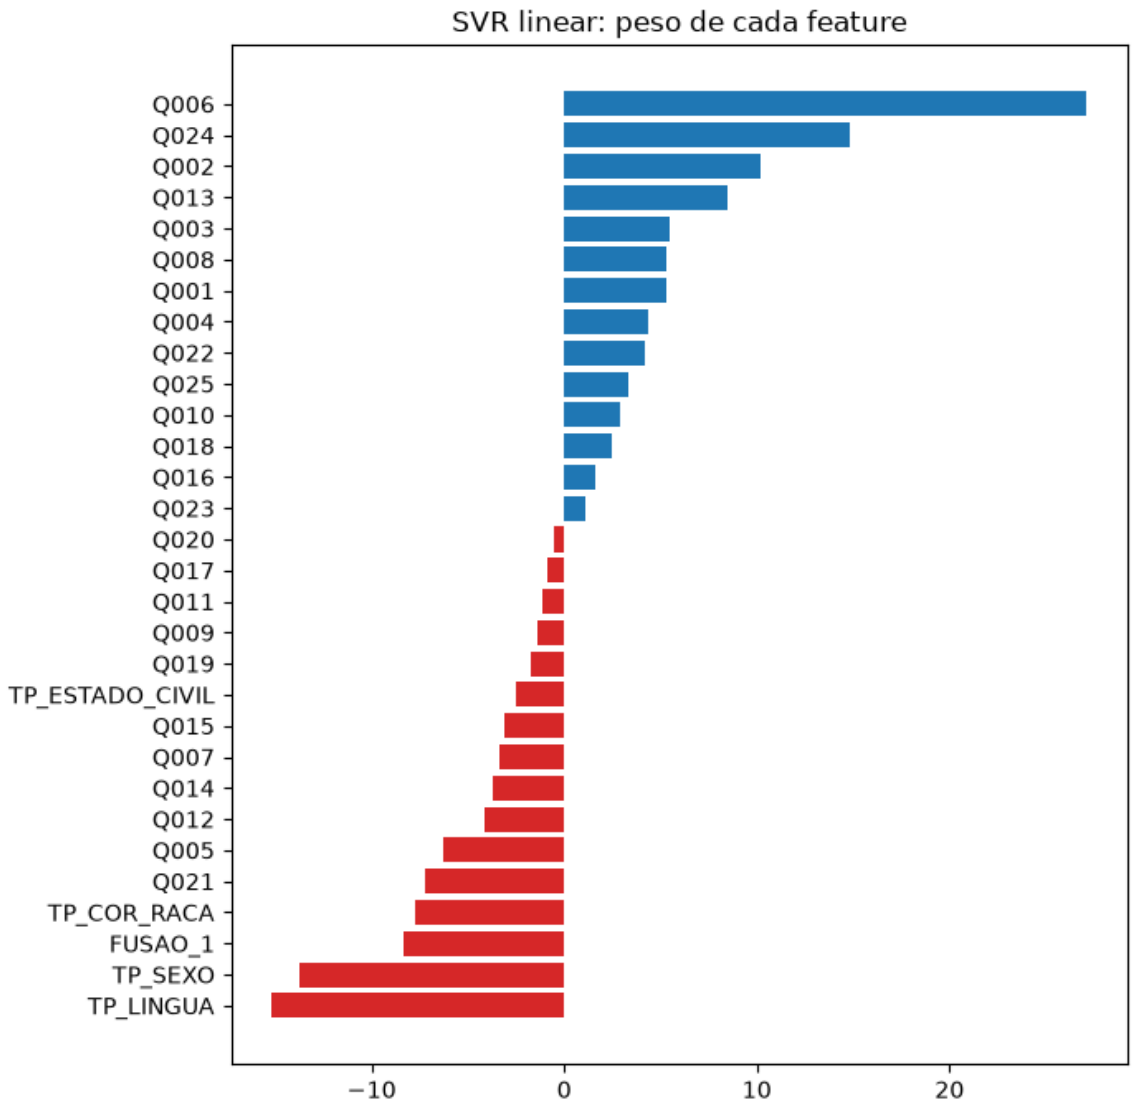


Figura 18. SVR linear: peso de cada feature. Fonte: Inep, ENEM 2023; desenvolvimento.

6.6 Bagging e pasting. Bagging: 20 árvores, cada uma numa amostra sorteada com reposição. Pasting: o mesmo sem reposição, com metade do treino em cada árvore. Ficaram praticamente iguais (110,014 e 110,012).

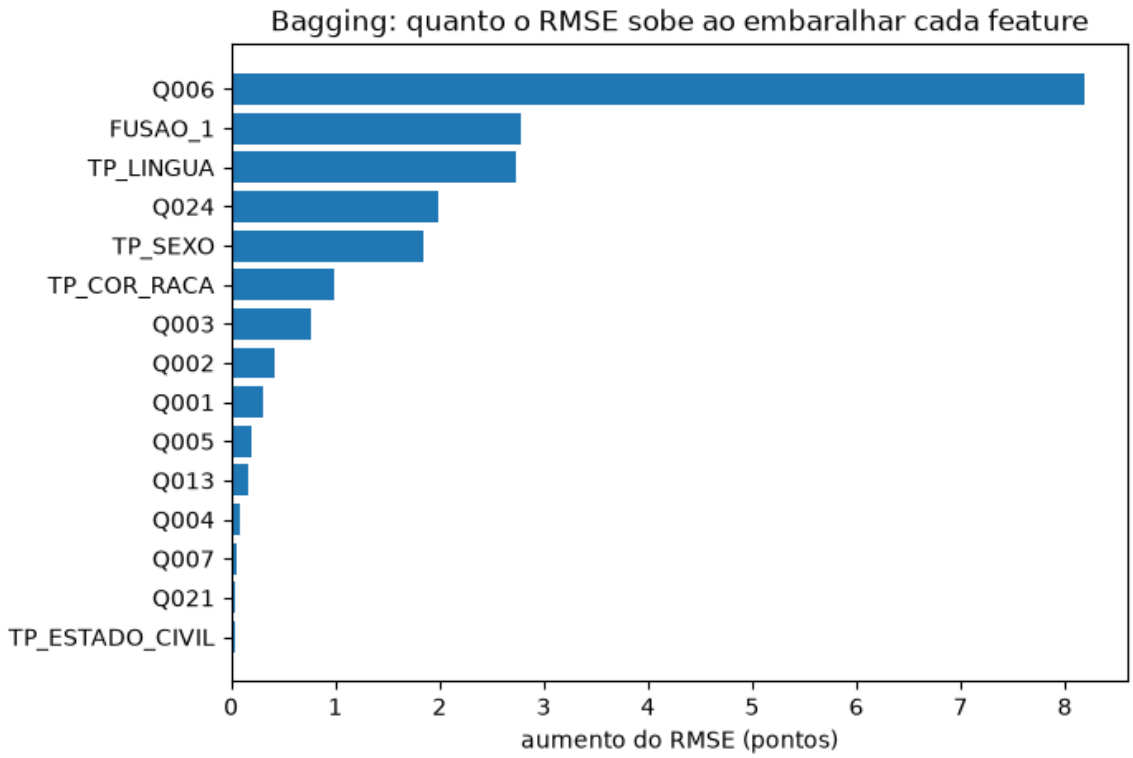


Figura 19. Bagging: importância por permutação na dobra 1. Fonte: Inep, ENEM 2023; desenvolvimento.

6.7 Random Forest e Gradient Boosting. A Random Forest é um bagging em que cada divisão só considera uma parte sorteada das features (RMSE 109,422). No boosting as árvores são treinadas em sequência, cada uma corrigindo o erro das anteriores; é o melhor modelo (RMSE 107,770, R^2 0,330). A importância por permutação (quanto o RMSE sobe ao embaralhar a coluna) coloca `Q006` (+6,0 pontos), `FUSAO_1` (+4,0), `TP_SEXO` e `TP_LINGUA` (+2,1) e `Q024` (+1,8) no topo.

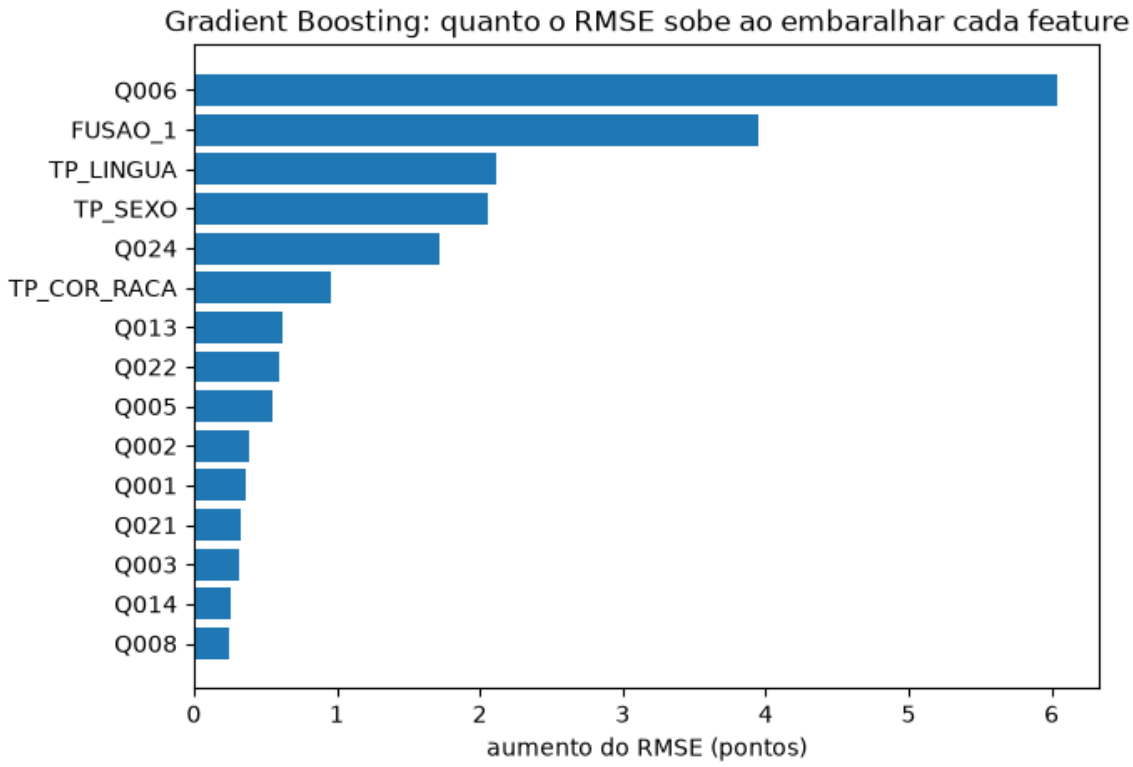


Figura 20. Gradient Boosting (configuração inicial): quanto o RMSE sobe ao embaralhar cada feature. Fonte: Inep, ENEM 2023; desenvolvimento.

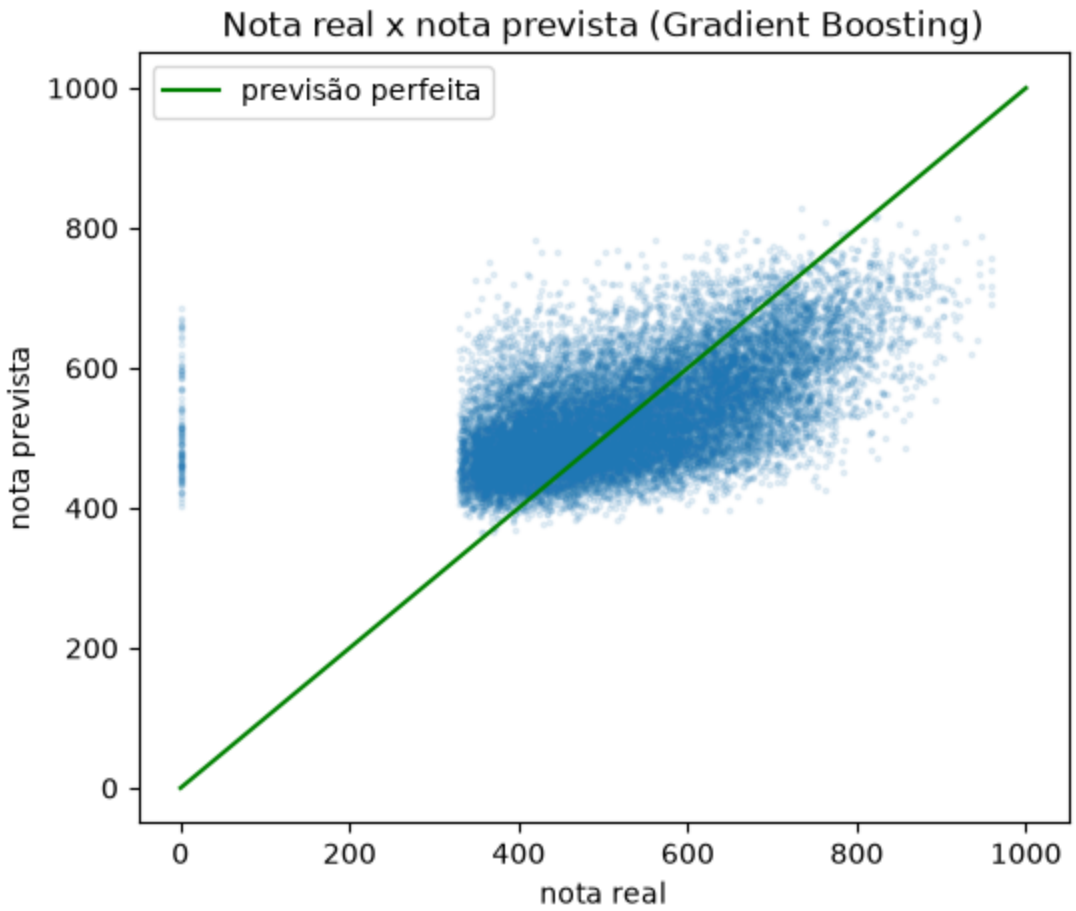


Figura 21. Gradient Boosting: nota real × nota prevista (20 mil pessoas da validação; as notas zero formam a coluna à esquerda). Fonte: Inep, ENEM 2023; desenvolvimento.

6.8 Stacking. Empata com o Gradient Boosting (diferença de 0,007, muito menor que o desvio de 0,226) e custa cerca de 5 vezes mais tempo: não se justifica.

6.9 Leitura geral. Famílias muito diferentes (linear, árvore, KNN) caem no mesmo patamar de 110 a 112 de RMSE, e árvores só ganham 3 a 4 pontos. Se o problema fosse fortemente não linear, os modelos flexíveis ganhariam muito mais: o limite está nas features, não no algoritmo. Os 3 melhores regressores distintos (sem contar o baseline) são stacking, Gradient Boosting e Random Forest; como o stacking custa 5 vezes mais e não ganha, a busca de hiperparâmetros foi feita no Gradient Boosting, no bagging e na Random Forest (os três melhores sem o stacking, por família).

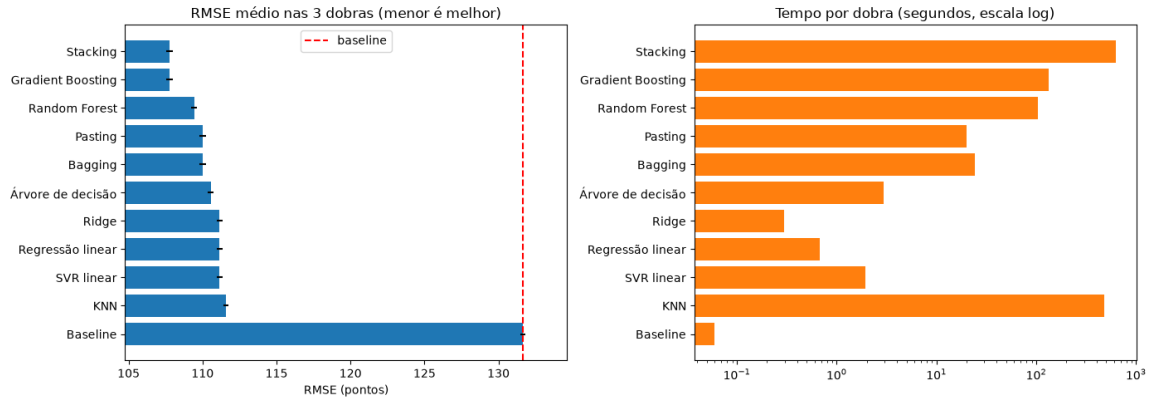


Figura 22. RMSE médio de cada modelo com o desvio entre as dobras (esquerda) e tempo por dobra em escala logarítmica (direita). Fonte: Inep, ENEM 2023; dataset_1_fundido, validação cruzada.

7. Busca de hiperparâmetros

O otimizador foi o `RandomizedSearchCV` do scikit-learn (um dos dois que o enunciado cita): sorteia 10 configurações dentro de faixas definidas pela equipe, mede cada uma nas mesmas 3 dobras pelo RMSE médio, escolhe a de menor RMSE e a reajusta nos 80% do desenvolvimento (Bergstra e Bengio, 2012: a busca aleatória cobre melhor espaços de muitas dimensões que uma grade). Semente 42; o teste não entra. KNN e stacking ficaram sem busca pelo custo (mais de 3 e mais de 2 horas). O Optuna não foi usado: não está instalado no ambiente.

A busca foi feita no `dataset_1_fundido` e cobriu sete modelos; os 3 melhores regressores distintos, sem o stacking, são Gradient Boosting, bagging e Random Forest.

Modelo	RMSE inicial	RMSE depois da busca	Ganho	R^2 depois	Tempo da busca
Bagging	110,014	109,083 ± 0,154	0,931	0,313	17,8 min
Pasting	110,012	109,146 ± 0,158	0,866	0,312	12,0 min
Random Forest	109,422	109,138 ± 0,159	0,284	0,313	19,7 min
Árvore de decisão	110,551	110,337 ± 0,148	0,214	0,297	4,7 min
Gradient Boosting	107,770	107,680 ± 0,178	0,090	0,331	54,2 min
Ridge	111,153	111,153 ± 0,145	0,000	0,287	0,6 min
SVR linear	111,153	111,153 ± 0,145	0,000	0,287	2,0 min

O RMSE depois da busca é um pouco otimista, porque é o melhor entre 10 sorteados. O maior ganho foi no bagging e no pasting (cerca de 0,9, acima do desvio de 0,15); Random Forest e árvore ganharam 0,2 a 0,3. No Gradient Boosting o ganho (0,09) fica dentro do desvio (0,178): a busca praticamente não melhorou o melhor modelo. Ridge e SVR linear não mudam, porque todas as configurações sorteadas dão o mesmo resultado.

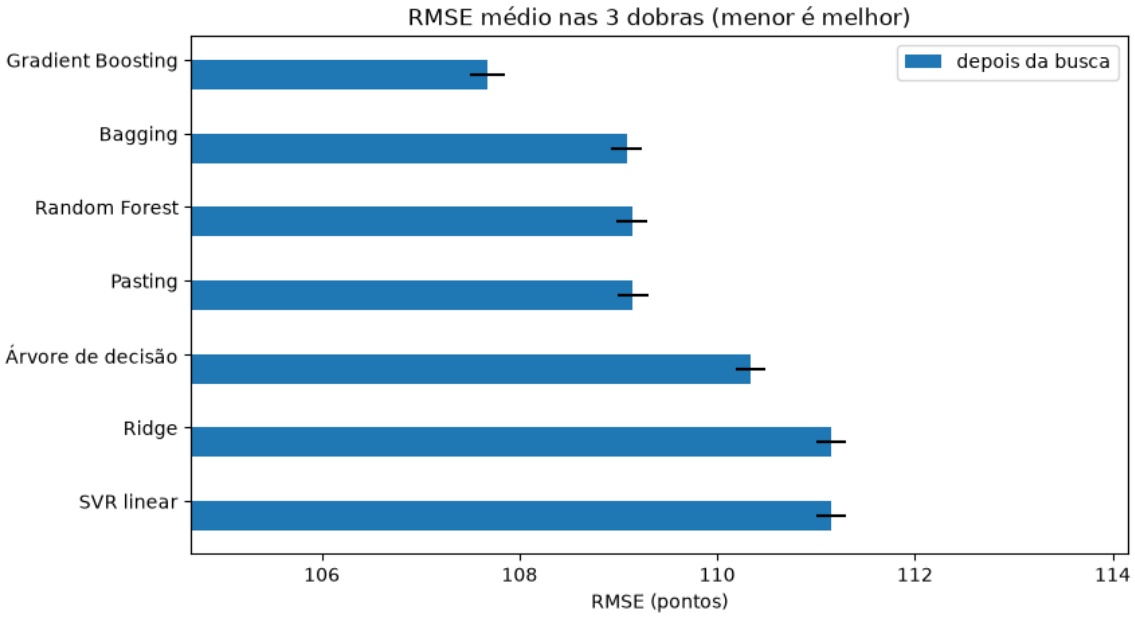


Figura 23. RMSE de cada modelo depois da busca de hiperparâmetros (dataset_1_fundido, validação cruzada). Fonte: Inep, ENEM 2023.

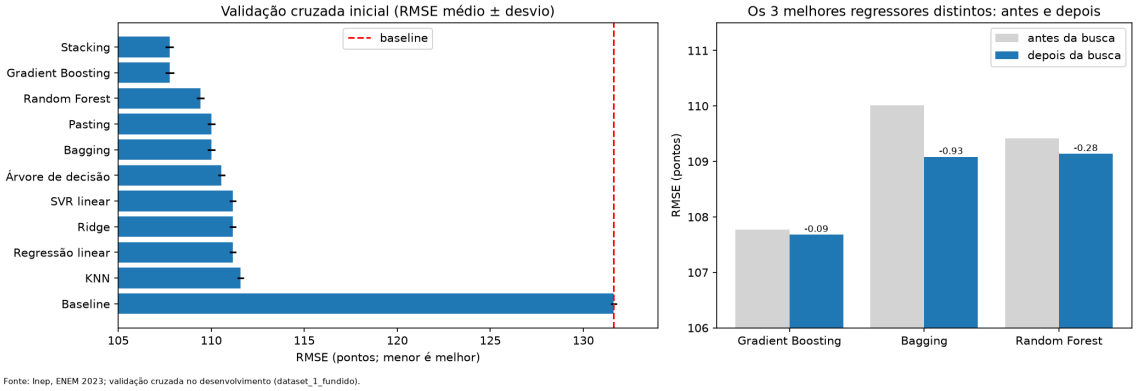


Figura 24. Comparação inicial de todos os regressores com o baseline (esquerda) e os três melhores regressores distintos antes e depois da busca (direita). Fonte: Inep, ENEM 2023; dataset_1_fundido, validação cruzada.

Melhores hiperparâmetros.

- Gradient Boosting: `learning_rate` 0,067; até 500 árvores; 89 folhas; `min_samples_leaf` 137; `l2_regularization` 0,244; parada antecipada com 10% do treino.
- Bagging: 24 árvores, `max_samples` 0,7, `max_features` 0,8, árvore base com `max_depth` 15 e `min_samples_leaf` 34.
- Random Forest: 50 árvores, `max_depth` 15, `max_features` 0,3, `min_samples_leaf` 30.
- Pasting: 24 árvores, `max_samples` 0,3 (mesmos demais valores do bagging).

- Árvore: `max_depth` 25, `max_features` 0,8, `min_samples_leaf` 298. Ridge: `alpha` 461,9. SVR linear: `C` 0,029, `epsilon` 0,78.

Espaços de busca (10 configurações cada, mesmas 3 dobras): Ridge `alpha` loguniform de 1e-3 a 1e5; árvore `max_depth` 5 a 30, `min_samples_leaf` 5 a 299, `max_features` None, 0,8 ou 0,5; SVR linear `C` loguniform de 1e-2 a 10, `epsilon` de 0 a 5; bagging `n_estimators` 10 a 40, `max_samples` 0,5, 0,7 ou 1,0, `max_features` 0,6, 0,8 ou 1,0, árvore base `max_depth` 6 a 15 e `min_samples_leaf` 20 a 199; pasting igual com `max_samples` 0,2, 0,3, 0,5 ou 0,7; Random Forest `n_estimators` 50 ou 100, `max_depth` 8 a 15, `min_samples_leaf` 10 a 199, `max_features` 0,3, 0,5 ou 0,7; Gradient Boosting `learning_rate` loguniform de 0,02 a 0,3, `max_iter` 200, 300 ou 500, `max_leaf_nodes` 15 a 99, `min_samples_leaf` 50 a 499, `l2_regularization` loguniform de 1e-3 a 10.

Limite desta busca. Foi feita antes da correção do vazamento e do desdobramento da situação escolar, no dataset 1 com 30 colunas. Na solução final (seção 13) os mesmos hiperparâmetros foram reaproveitados; refazer a busca na representação final custaria mais de uma hora e não muda a conclusão, já que o ganho da busca no Gradient Boosting ficou dentro do desvio.

8. Variações de dataset e comparação

Foram avaliados **21 conjuntos de entrada** com validação cruzada: **8 datasets salvos** em `dados/processed/` (notebooks 01 e 02) e **13 variações de representação** montadas no notebook 04 a partir da mesma base (tratamento da situação escolar, UF, sem as features criadas, três cortes de seleção e seis blocos retirados). Além deles, 4 testes de diagnóstico à parte (A a D, seção 8.2) não entram nos notebooks, e dois conjuntos ficam fora da conta: o dataset 5 (solução independente de outra IA, seção 8.4) e o dataset 6 (diagnóstico com as notas de outras áreas, seção 8.5).

8.1 Os 8 datasets salvos (nenhum é filtrado por linhas: todos têm as 2.692.427 linhas). RMSE médio nas 3 dobras, menor é melhor:

Dataset	Features	Regressão linear	Gradient Boosting (inicial)	Bagging otimizado
`dataset_1_fundido`	30	111,153	107,770	109,083
`dataset_1_features`	33	111,146	107,759	109,170
`dataset_2_escola`	34	110,747	107,261	108,720
`dataset_2_features_escola`	37	110,742	107,255	108,684
`dataset_3_sem_escola`	38	110,752	107,551	109,089
`dataset_3_sem_escola_features`	41	110,744	107,540	109,081
`dataset_3_escola`	42	110,384	107,056	108,597
`dataset_3_escola_features`	45	110,378	107,048	108,615

- O melhor dataset salvo é o `dataset_3_escola_features` (45 features): Gradient Boosting 107,048, 0,72 ponto melhor que o dataset 1.

- A escola dá o ganho mais consistente (cerca de 0,5 ponto no Gradient Boosting e 0,4 na regressão linear); `NAO_SEI` e nacionalidade dão 0,2 a 0,4.
- As 3 features criadas quase não mudam o resultado (cerca de 0,01 ponto), como era de se esperar de colunas calculadas a partir das que já existem.
- Do dataset 1 ao melhor dataset são 0,8 ponto na regressão linear e 0,7 no Gradient Boosting: mais colunas ajudam pouco.

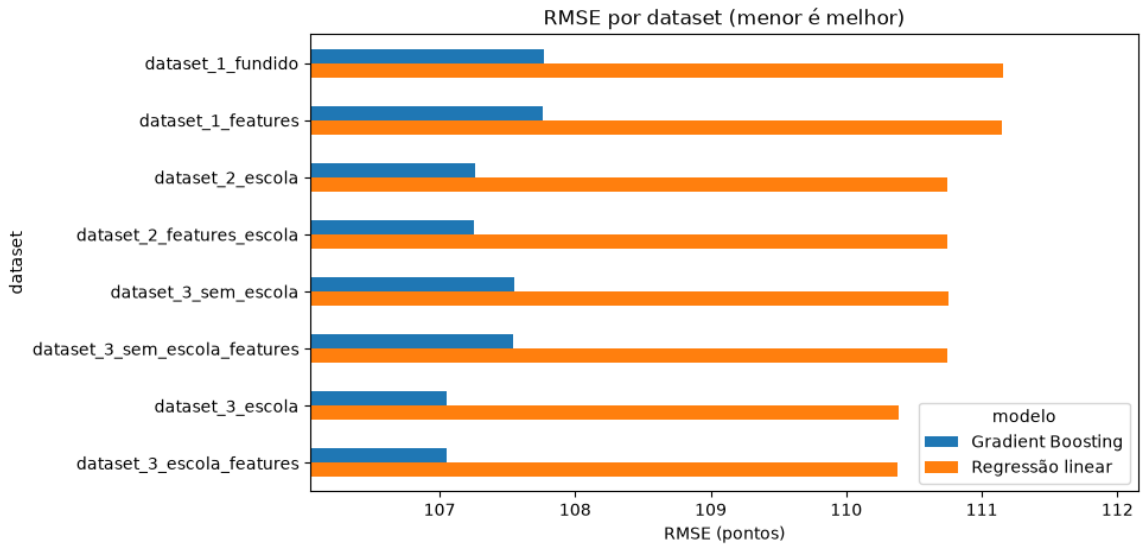


Figura 25. RMSE por dataset salvo (menor é melhor): regressão linear e Gradient Boosting. Fonte: Inep, ENEM 2023; validação cruzada.

8.2 Teste de diagnóstico à parte (Gradient Boosting leve, 150 árvores, dataset 1 como base): a UF da prova (27 colunas 0/1) e as colunas que a `FUSAO_1` havia juntado ajudam, e os efeitos se somam.

Conjunto	Colunas	RMSE (± desvio)	R^2	Ganho
A. Dataset 1	30	107,977 ± 0,185	0,327	
B. A + UF da prova (one-hot)	57	107,334 ± 0,169	0,335	0,64
C. A + idade, situação, ano e treineiro separados	34	107,505 ± 0,152	0,333	0,47
D. A + B + C	61	106,830 ± 0,139	0,341	1,15

Esse diagnóstico motivou as hipóteses das seções 9.1 e 9.2, agora medidas dentro do Pipeline, com o dataset 3 como base.

8.3 As 13 variações do notebook 04. Base: as 44 colunas do `dataset_3_escola_features` sem a `FUSAO_1`, mais as 4 colunas originais da situação escolar (48) e, quando indicado, 26 colunas de UF. Gradient Boosting inicial, mesmas dobras.

Variação	Colunas	RMSE (± desvio)	Em relação à referência
1a. Fusão da situação refeita só com o treino	48	107,051 ± 0,192	referência da seção 9.1
1b. 4 colunas de situação separadas	48	106,726 ± 0,189	−0,325: melhora
2. 1b + UF da prova	74	106,025 ± 0,188	−0,701 sobre 1b: melhora
3. Sem as 3 features criadas	71	106,038 ± 0,167	+0,013 sobre a variação 2: sem diferença
4a/4b/4c. Seleção k = 22 / 37 / 51 colunas	74 de entrada	110,607 / 107,436 / 107,069	piora (+4,58 / +1,41 / +1,04)
6a. Sem renda	72	106,893 ± 0,194	+0,868
6b. Sem escolaridade e ocupação dos responsáveis	66	106,559 ± 0,168	+0,534
6c. Sem bens e domicílio	52	107,356 ± 0,174	+1,331
6d. Sem escola	70	106,439 ± 0,185	+0,414
6e. Sem localização (UF)	48	106,726 ± 0,189	+0,701
6f. Sem perfil e trajetória	62	110,445 ± 0,189	+4,420

A conclusão de cada linha está nas seções 9, 11 e 12.

8.4 Dataset 5: a solução independente de outra IA. Pedimos a outra IA um treino "só com o enunciado e o CSV", sem nenhum contexto do nosso trabalho (pasta `treino_projeto2/`, script `treino_enem.py`). O teste dela é **o mesmo nosso**: os 538.486 identificadores são idênticos aos de `dados/splits/teste_ids.csv`. O dataset 5 é a definição de entradas dela, não um arquivo:

- **45 colunas de entrada:** 41 categóricas originais (16 de perfil, trajetória, escola e UF, mais `Q001` a `Q025`) e 4 derivadas (`QTD_QUESTIONARIO_PREENCHIDO`, `QTD_PERFIL_PREENCHIDO`, `RESPONSAVEIS_ESCOLARIDADE_IGUAL` e `UF_ESCOLA_PROVA_IGUAL`). Inclui colunas que nós tiramos (`TP_ENSINO`, `SG_UF_ESC`, `TP_DEPENDENCIA_ADM_ESC`, `TP_SIT_FUNC_ESC`) e não usa as nossas features criadas.
- **Codificação:** one-hot de **todas** as categóricas, inclusive as escadas do questionário, com a ausência como categoria própria e categorias com menos de 50 pessoas agrupadas; as contagens passam por mediana e padronização. O Gradient Boosting dela usa codificação ordinal. Tudo dentro de Pipelines.
- **Protocolo dela:** mesma partição 80/20 com semente 42; **sem validação cruzada, busca de hiperparâmetros, PCA, seleção ou balanceamento**, com configurações fixas e leves (Gradient Boosting com 50 árvores e 15 folhas, bagging e pasting com 5 árvores) e avaliação direto no teste. O próprio README dela diz que não substitui as etapas obrigatórias.

Resultado no teste (RMSE em pontos), junto com as nossas referências:

Modelo	RMSE no teste	MAE	R^2	Ajuste (s)
Nossa solução final (Gradient Boosting, 74 colunas)	**105,81**	**82,00**	**0,354**	165
Dataset 5: Ridge	107,53	83,63	0,333	55
Dataset 5: SVR linear	107,89	83,30	0,329	60
Dataset 5: Gradient Boosting (50 árvores)	108,07	84,46	0,327	15
Dataset 5: Random Forest (30 árvores)	108,13	84,32	0,326	4.904
Nossa regressão linear sem regularização	108,86	84,89	0,317	4
Dataset 5: pasting, bagging, regressão linear	109,62 a 109,70	84,05 a 85,80	0,306 a 0,307	82 a 302
Dataset 5: árvore de decisão	110,02	85,65	0,302	685
Dataset 5: AdaBoost	114,09	90,04	0,250	177
Baseline (média)	131,70	107,64	0,000	0

Leitura. Nenhum modelo do dataset 5 supera a nossa solução final: o melhor dele (Ridge, 107,53) fica 1,7 ponto atrás. O ganho dela aparece nos modelos lineares: o Ridge com one-hot de tudo erra 1,33 ponto a menos que a nossa regressão linear, o que confirma a limitação que já tínhamos anotado (cor/raça, estado civil e as escadas do questionário como números prejudicam a regressão linear). Sua regressão linear sem regularização (109,70) fica pior que a nossa (108,86): o ganho vem do one-hot somado à regularização. O Gradient Boosting dela é bem mais leve que o nosso (50 contra até 500 árvores) e termina 2,3 pontos atrás. **Cuidados:** a comparação é só de teste (não há validação cruzada do lado dela), então nada pode ser escolhido a partir dela sem refazer a validação cruzada no desenvolvimento. Esse cuidado foi atendido depois: reproduzimos a preparação dela e a avaliamos por validação cruzada nas nossas dobras (notebook 06, Apêndice G.6): o Ridge fez 107,51, igual ao teste dela (107,53), e a nossa solução fica 1,6 ponto melhor. Onde ficou o material: a pasta original (treino_projeto2, 365 MB) foi apagada depois de arquivar o essencial em resultados/dataset5_replicacao_independente: o script treino_enem.py (que define o dataset 5), as métricas de teste, o diagnóstico e o README dela. Não foram guardados o ambiente virtual, os modelos joblib, os ids (idênticos aos nossos) e as previsões de teste (61 MB); as métricas por modelo estão na tabela acima.

8.5 Dataset 6: diagnóstico com as notas de outras áreas (fora da solução). As notas de outras matérias influenciam a nota de Matemática? Sim, e muito, mas usar essas notas é o vazamento que o enunciado proíbe (elas descrevem a própria prova, não o perfil), então o dataset 6 existe só para medir o tamanho do efeito (notebook `05-diagnostico-notas-outras-areas`). Ele é o `dataset_3_escola_features` (45 colunas) mais as notas de Ciências da Natureza (mesmo dia da prova de Matemática), Ciências Humanas, Linguagens e Redação (as três do primeiro dia): 53 colunas, sem nulos (a nota ausente vira 0 e ganha uma coluna indicadora). Foi avaliado só por validação cruzada no desenvolvimento; o teste não foi aberto, e o dataset não entra na solução final nem em nenhuma tabela de teste.

Correlação de Pearson de cada nota com a de Matemática (desenvolvimento): Natureza 0,71, Humanas 0,63, Linguagens 0,62 e Redação 0,50. Entre os participantes com nota de Matemática, só 0,5% não têm as notas do primeiro dia e todos têm a de Natureza.

Entrada	Colunas	Gradient Boosting: RMSE (± desvio)	R^2	Regressão linear: RMSE	R^2
Só o perfil	45	107,05 ± 0,20	0,339	110,38	0,297
+ Natureza (mesmo dia)	47	82,83 ± 0,06	0,604	86,05	0,573
+ Humanas, Linguagens e Redação (dia 1)	51	85,96 ± 0,23	0,574	89,69	0,536
+ as quatro notas	53	**74,43 ± 0,03**	**0,680**	79,63	0,634

Leitura. Com as quatro notas o RMSE cai de 107,0 para 74,4 e o R^2 sobe de 0,34 para 0,68: a nota de outra área sozinha (Natureza) já tira 24 pontos do erro. Isso confirma que o limite de R^2 de cerca de 0,35 dos outros experimentos vem da informação disponível sobre o perfil, e não do modelo. Mesmo com o vazamento o R^2 chega a 0,68, não a 1: cerca de um terço da variação da nota de Matemática não é explicada nem por outras provas feitas pela mesma pessoa. A regressão linear também ganha muito (110,4 para 79,6), mas fica 5 pontos atrás do Gradient Boosting.

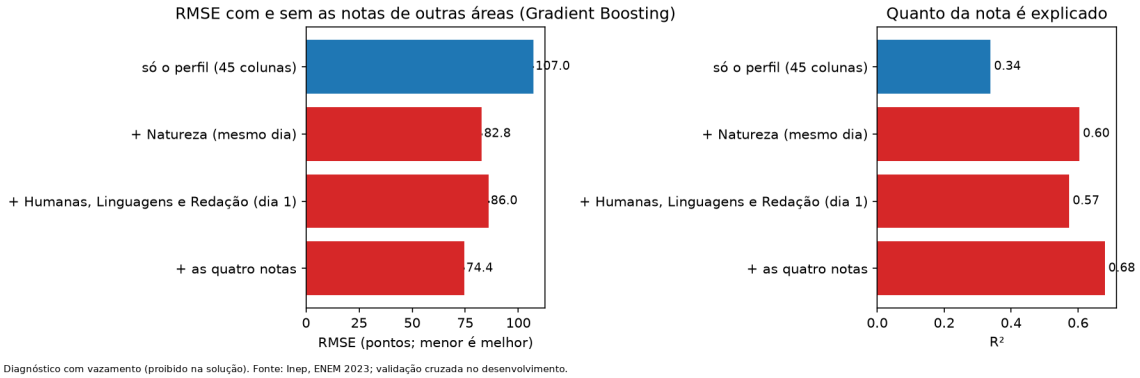


Figura 25b. Diagnóstico com vazamento (dataset 6, fora da solução): RMSE e R^2 do Gradient Boosting só com o perfil e com as notas de outras áreas. Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

8.5.1 Spearman do dataset 6 (só desenvolvimento). As quatro notas de outras áreas são as colunas mais associadas à nota de Matemática, acima de qualquer coluna do perfil: Humanas 0,656, Linguagens 0,643, Natureza 0,643 e Redação 0,527, contra 0,457 da renda (`Q006`) e 0,409 dos computadores (`Q024`). Quatro pares passam do limite de redundância ($|\rho| > 0{,}7$): Humanas × Linguagens (0,788) e as três colunas `AUSENTE_CH`, `AUSENTE_LC` e `AUSENTE_REDACAO`, que são **idênticas** ($\rho = 1{,}000$: quem não fez o primeiro dia não fez nenhuma das três). Entre as próprias notas: Natureza × Humanas 0,66, Natureza × Linguagens 0,64 e Redação de 0,46 a 0,52 com as outras. `AUSENTE_CN` é constante (ninguém no desenvolvimento deixou de fazer Natureza), então o Spearman dela é indefinido e ela fica fora dos gráficos. A correlação de Pearson da Natureza (0,71) é maior que a de Spearman (0,64); uma explicação provável, não testada, é que quem zerou Matemática também zerou Natureza (8.5.2), e esses pontos em (0, 0) pesam mais no Pearson.

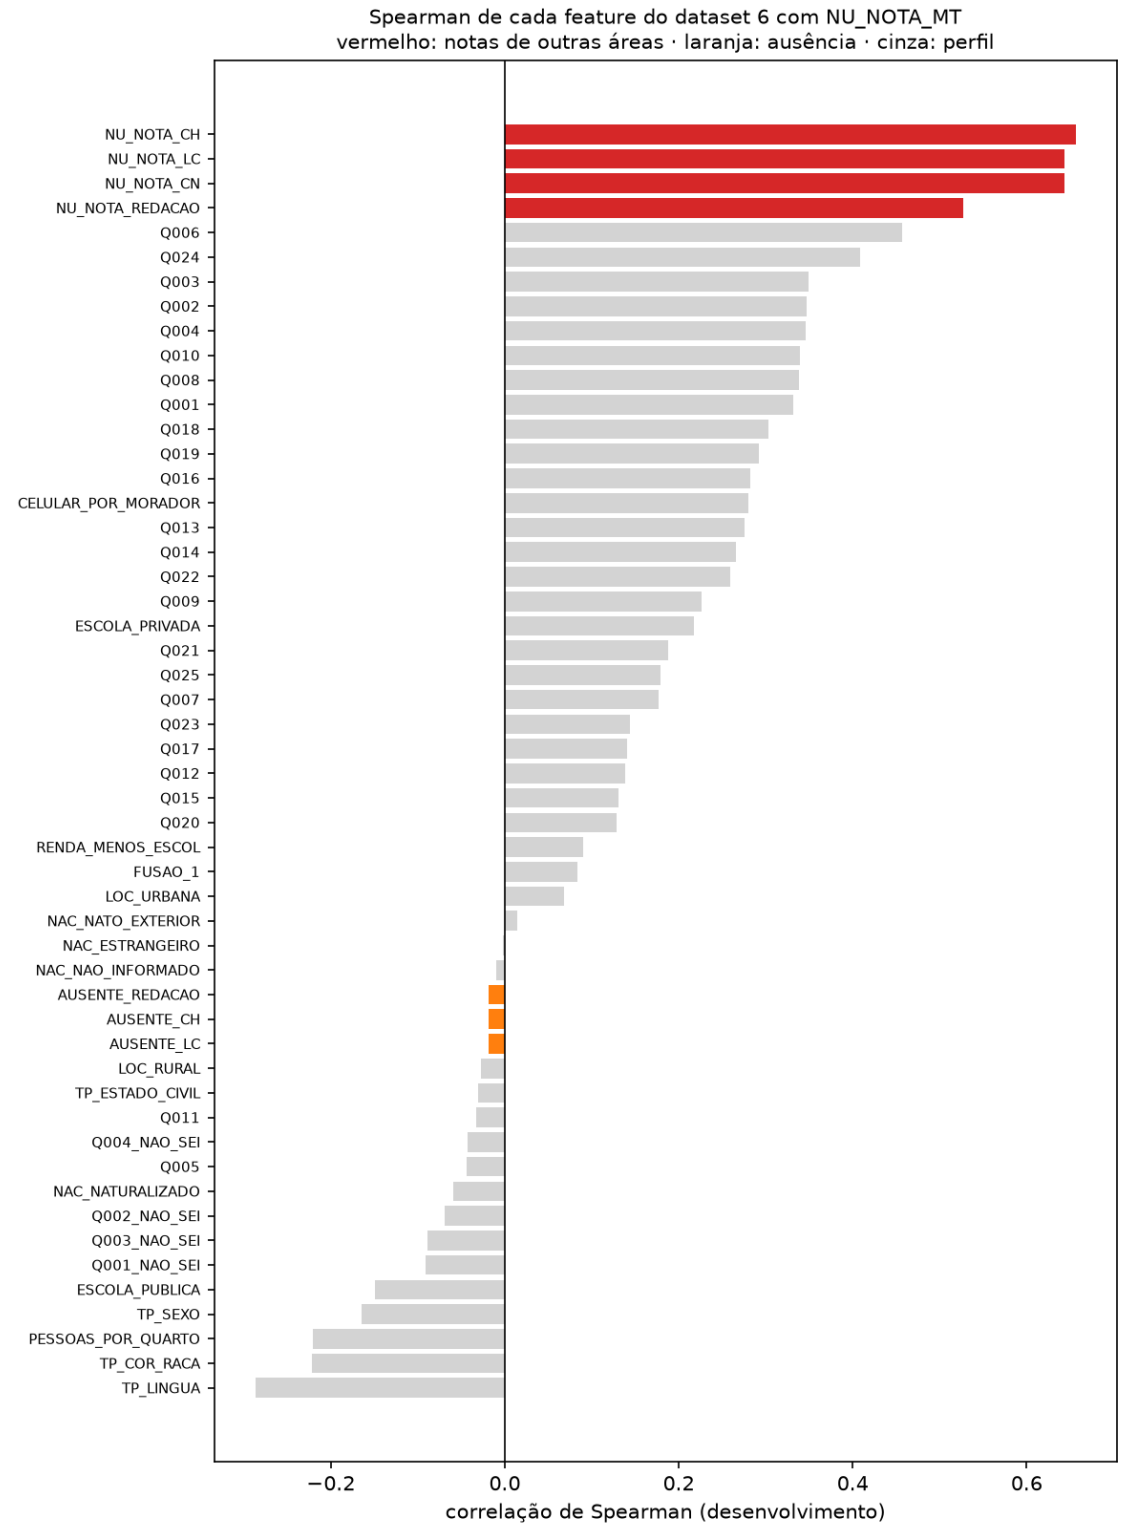


Figura 25c. Spearman de cada feature do dataset 6 com a nota de Matemática (vermelho: notas de outras áreas; laranja: indicadoras de ausência; cinza: perfil). Fonte: Inep, ENEM 2023; desenvolvimento. Diagnóstico com vazamento.

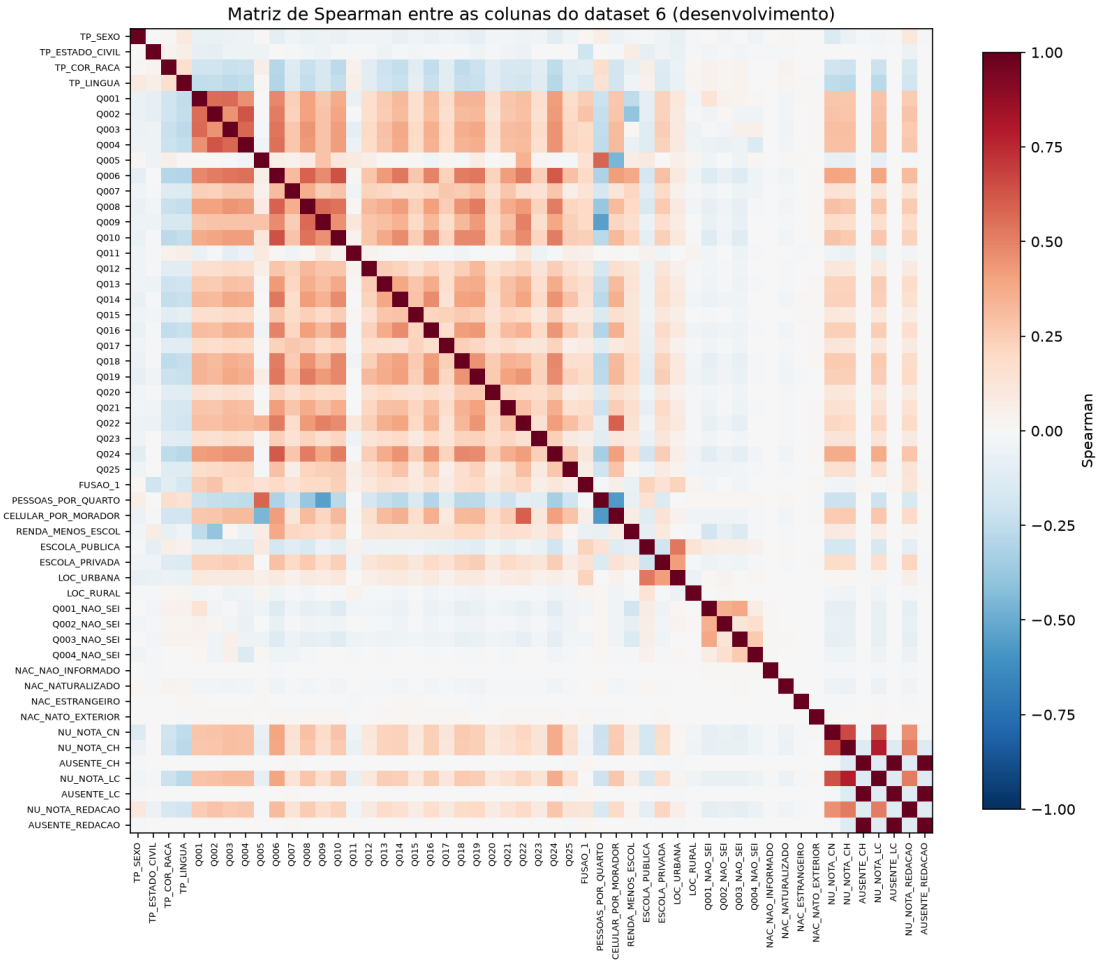


Figura 25d. Matriz de Spearman entre as colunas do dataset 6: as notas formam um bloco entre si e as três indicadoras de ausência aparecem como um bloco de correlação 1. Fonte: Inep, ENEM 2023; desenvolvimento.

8.5.2 Dataset 6 sem as notas zero no treino. As 13.300 pessoas com nota 0 em Matemática (0,62%) respondem por 13,7% do erro ao quadrado da regressão linear só com o perfil. Com as notas de outras áreas, o modelo consegue **reconhecê-las**: **98,3% de quem zerou Matemática também tem nota 0 em Natureza** (a prova do mesmo dia), 17,3% zeraram a Redação e 2,1% não têm as notas do primeiro dia. As notas zero saíram **só do treino de cada dobra**; a validação manteve todos, inclusive os zeros (regra do enunciado).

Entrada	Modelo	Zeros no treino	RMSE geral (± desvio)	RMSE de quem não zerou	RMSE dos zeros	R^2
Só o perfil	Gradient Boosting	sim	107,05 ± 0,20	99,41	515,1	0,339
Só o perfil	Gradient Boosting	não	107,12 ± 0,20	99,36	519,1	0,338

Entrada	Modelo	Zeros no treino	RMSE geral (± desvio)	RMSE de quem não zerou	RMSE dos zeros	R^2
Só o perfil	Regressão linear	sim	110,38 ± 0,19	102,82	521,2	0,297
Só o perfil	Regressão linear	não	110,43 ± 0,20	102,76	524,8	0,296
+ as quatro notas	Gradient Boosting	sim	**74,43 ± 0,03**	74,46	**69,0**	**0,680**
+ as quatro notas	Gradient Boosting	não	82,81 ± 0,14	74,30	471,3	0,604
+ as quatro notas	Regressão linear	sim	79,63 ± 0,06	78,33	198,8	0,634
+ as quatro notas	Regressão linear	não	80,51 ± 0,04	77,70	279,1	0,626

Leitura. Com só o perfil, tirar os zeros do treino não muda nada (107,12 contra 107,05, dentro do desvio), como já tínhamos visto no notebook 02 sem zeros. Com as notas de outras áreas acontece o contrário: **tirar os zeros do treino piora muito** o erro geral (82,81 contra 74,43 no Gradient Boosting), porque o modelo nunca viu um zero e passa a prever cerca de 470 para eles (RMSE de 471 nos zeros, contra 69 quando eles estão no treino). Para quem não zerou a diferença é pequena (74,30 sem zeros contra 74,46 com, diferença de 0,16). Ou seja, as notas zero deixam de ser ruído quando se conhece a nota de Natureza: elas são um grupo identificável (provavelmente quem teve a prova do dia anulada ou foi eliminado; isso não foi verificado nos dados), e retirá-las do treino joga fora essa informação. Com só o perfil elas continuam imprevisíveis, o que explica o RMSE de cerca de 515 nelas.

9. Hipóteses e aprofundamento

Seis hipóteses além do mínimo, todas com o mesmo modelo (Gradient Boosting de configuração inicial), as mesmas dobras e a regra de leitura da seção 3. As tabelas completas por dobra estão em `resultados/experimentos.csv`.

9.1 Situação escolar: fundir ou separar. *Hipótese:* fundir as 4 colunas redundantes (`IN_TREINEIRO`, `TP_ANO_CONCLUIU`, `TP_FAIXA_ETARIA`, `TP_ST_CONCLUSAO`) numa só joga fora informação. *Resultado:* a fusão refeita só com o treino dá RMSE 107,051 ± 0,192; as 4 colunas separadas dão 106,726 ± 0,189 (−0,325, maior que o desvio: melhora). Escolhemos as 4 separadas. *Leitura:* a fusão, que existia para eliminar redundância por Spearman, custava informação; modelos de árvores não sofrem com colunas parecidas, e manter separado também resolve o vazamento da média e do desvio da fusão.

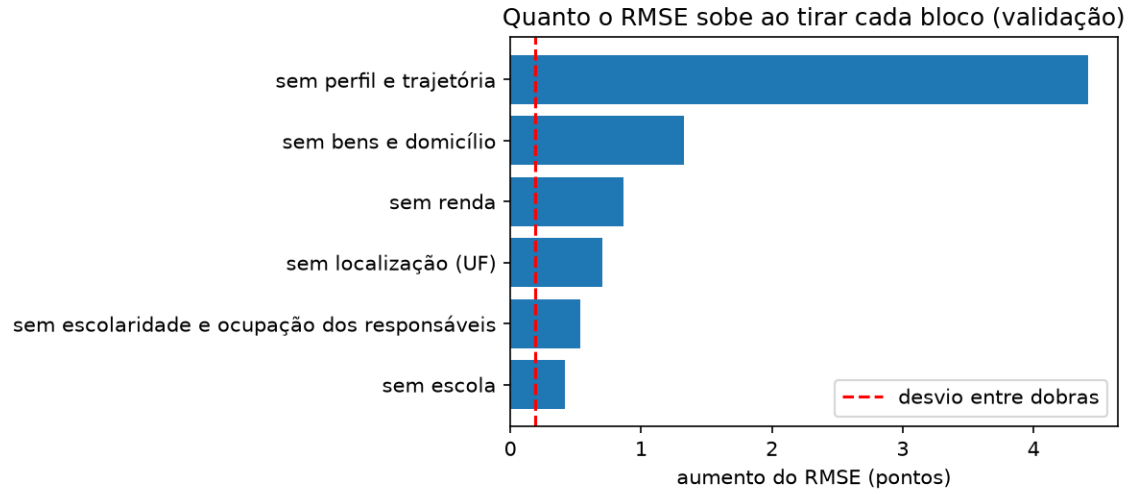
9.2 Localização: UF da prova. *Hipótese:* o estado acrescenta contexto (rede de ensino, desigualdade regional) que o perfil não tem. A UF entra em 26 colunas 0/1 (referência SP, a mais frequente); é a UF onde a pessoa fez a prova, não onde mora. *Resultado:* 106,025 ± 0,188, −0,701 sobre 106,726 (melhora). Adotada. Município não foi testado: teria de entrar com target encoding dentro do Pipeline, e fica como próximo passo.

9.3 As 3 features criadas ajudam? *Hipótese:* `PESSOAS_POR_QUARTO`, `CELULAR_POR_MORADOR` e `RENDA_MENOS_ESCOL` acrescentam sinal que as colunas originais não têm. *Resultado:* sem elas, 106,038 ± 0,167; com elas, 106,025: diferença de 0,013, sem diferença clara. *Leitura:* eram combinações de colunas que o Gradient Boosting já consegue formar sozinho. Mantidas na solução por não piorarem e por documentarem a engenharia pedida, mas não são responsáveis por ganho algum.

9.4 Quanto vale cada bloco de informação. *Hipótese:* cada bloco contribui. Retiramos um bloco por vez da representação de 74 colunas (RMSE de referência 106,025) e medimos quanto o erro sobe. Toda retirada piorou mais que o desvio (0,188):

Bloco retirado	Colunas que saem	RMSE	Aumento
Perfil e trajetória (sexo, estado civil, cor/raça, língua, nacionalidade, idade, situação de conclusão, ano, treineiro)	12	110,445	+4,420
Bens e domicílio (`Q005`, `Q007` a `Q025`, pessoas por quarto, celular por morador)	22	107,356	+1,331
Renda (`Q006`, renda menos escolaridade)	2	106,893	+0,868
Localização (UF)	26	106,726	+0,701
Escolaridade e ocupação dos responsáveis (`Q001` a `Q004` e `NAO_SEI`)	8	106,559	+0,534
Escola (pública, privada, urbana, rural)	4	106,439	+0,414

Leitura: o perfil e a trajetória pesam mais que todos os blocos socioeconômicos (a idade e a situação de conclusão carregam a maior parte, algo que não separamos: o bloco mistura as duas coisas); bens e renda vêm em seguida. Os blocos são parcialmente redundantes entre si (renda, bens e escolaridade andam juntos), então o aumento de cada um subestima o valor de tê-lo sozinho.



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Figura 26. Quanto o RMSE sobe ao tirar cada bloco de informação (linha vermelha: desvio entre dobras). Fonte: Inep, ENEM 2023; validação cruzada.

9.5 Notas zero fora do treino. *Hipótese:* tirar as 13.300 notas zero do treino reduz o erro nas outras faixas. A classe `SemZerosNoTreino` descarta as pessoas com nota 0 só nas duas dobras de treino; a validação mantém todos. *Resultado (dataset 1, hiperparâmetros da busca):*

Modelo	RMSE com zeros	RMSE sem zeros	Diferença	Desvio entre dobras	Veredito
Regressão linear	111,153	111,202	−0,049	0,178	sem diferença clara
Ridge	111,153	111,202	−0,049	0,178	sem diferença clara
Árvore de decisão	110,337	110,331	+0,006	0,181	sem diferença clara
Gradient Boosting	107,680	107,737	−0,057	0,218	sem diferença clara

Por faixa de nota (regressão linear), o erro dos zeros e das notas baixas sobe um pouco sem eles (de 522,6 para 526,0 nos zeros) e o erro das notas altas cai um pouco (de 210,4 para 207,7 acima de 800). Os zeros são previstos em cerca de 519 pontos nos dois casos. Eles são 0,62% das pessoas e geram 13,7% do erro ao quadrado da regressão linear; o RMSE entre quem não zerou é 103,6, uma média que descreve outra população e não comprova melhoria.

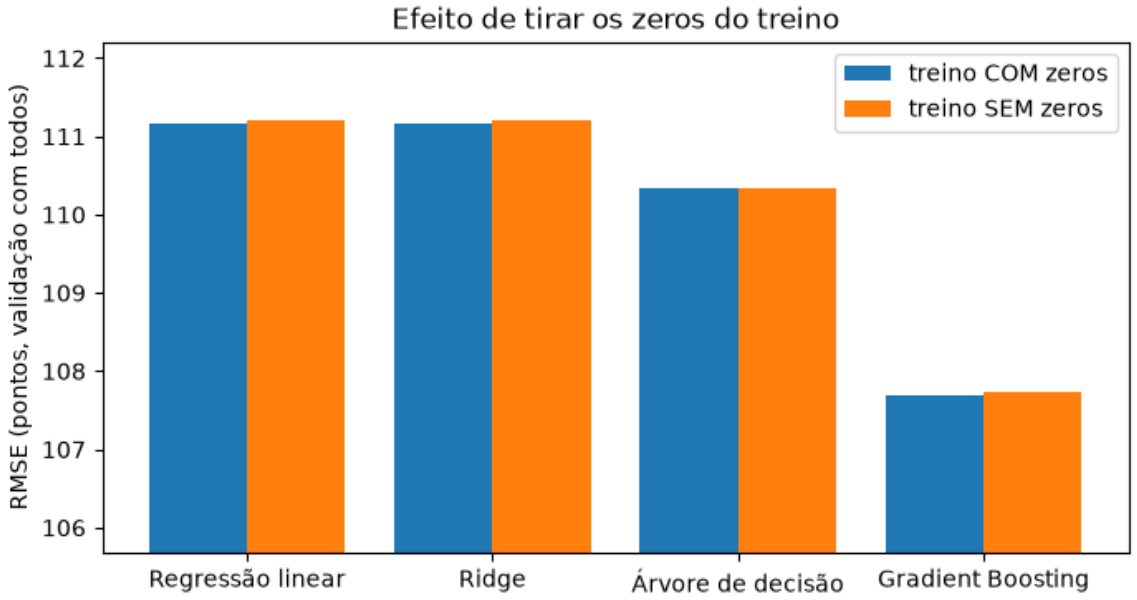


Figura 27. RMSE de cada modelo treinando com e sem as notas zero (validação com todos os participantes). Fonte: Inep, ENEM 2023; validação cruzada.

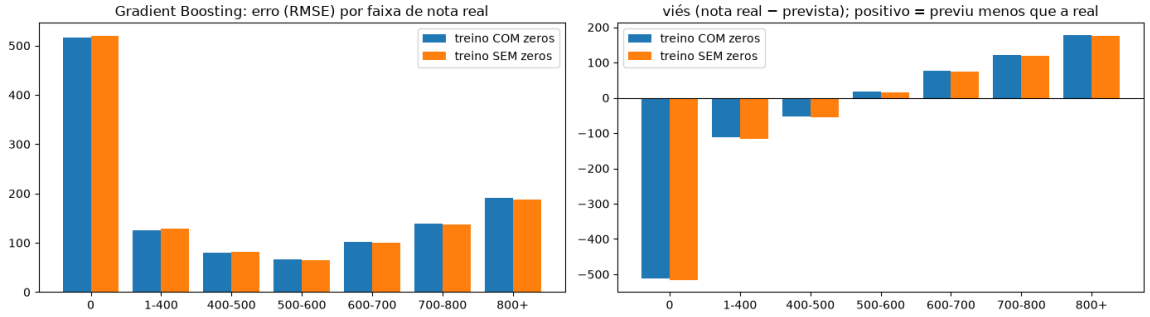


Figura 28. Gradient Boosting: RMSE e viés por faixa de nota real, com e sem zeros no treino. Fonte: Inep, ENEM 2023; validação cruzada.

9.6 Perfis semelhantes: K-means. *Hipótese:* grupos de perfil (clusters) acrescentam informação como features. O `MiniBatchKMeans` foi rodado para k de 2 a 10 nos 2,15 milhões de pessoas padronizadas. A silhueta é maior com k = 2 (0,207) e cai para menos de 0,11 de k = 3 em diante: as pessoas formam um contínuo, não ilhas. Os dois grupos separam o perfil de maior renda e escolaridade (705.499 pessoas, nota média 607,5, `Q006` médio 7,6) do de menor (1.448.442 pessoas, nota média 497,9, `Q006` médio 2,0), mas a nota varia muito dentro de cada grupo (desvios de 116 e 131). Dar o grupo ao modelo (distâncias aos centros, com o K-means reajustado só no treino de cada dobra) não ajuda: Gradient Boosting 107,770 sem e 107,789 com as distâncias (+0,019, dentro do desvio de 0,226).

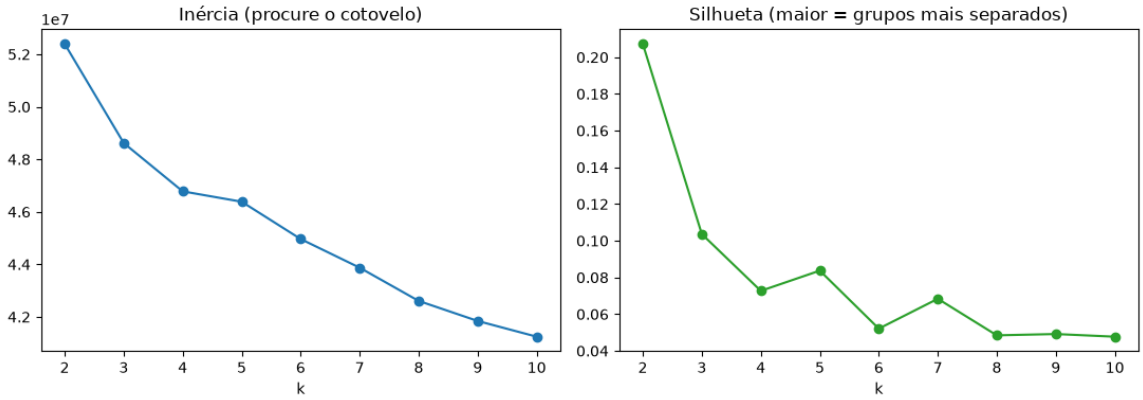


Figura 29. K-means (k de 2 a 10): inércia e silhueta. Fonte: Inep, ENEM 2023; desenvolvimento.

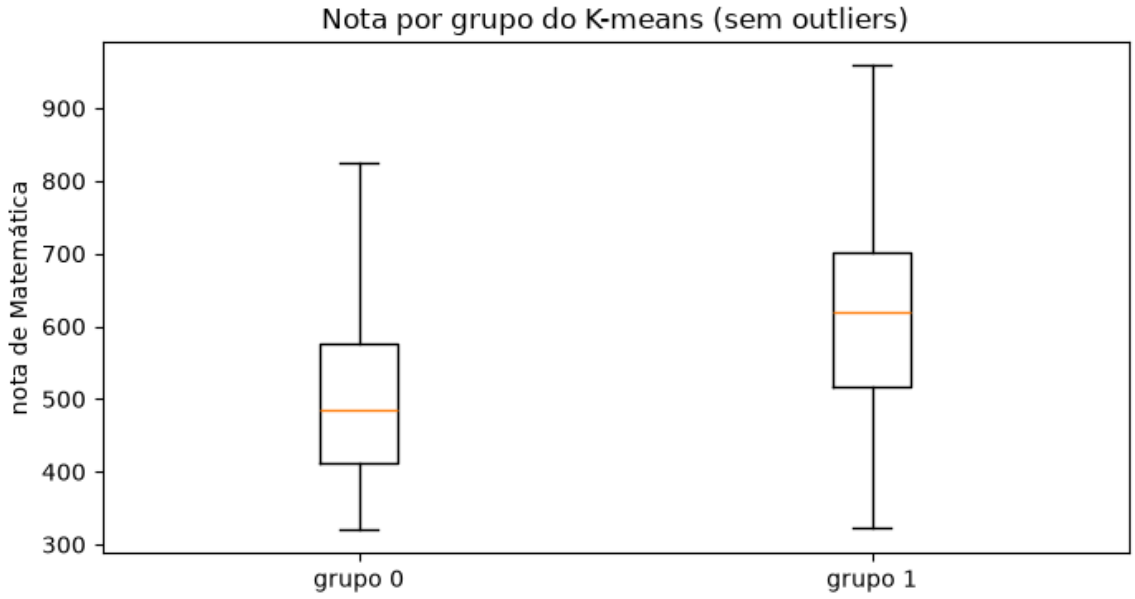


Figura 30. Nota por grupo do K-means (k = 2), sem outliers. Fonte: Inep, ENEM 2023; desenvolvimento.

10. PCA, t-SNE e K-means

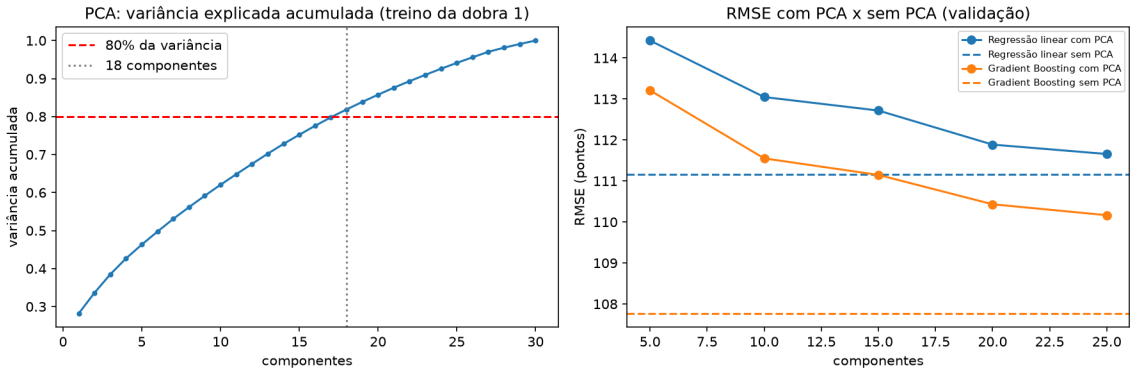
O PCA (análise de componentes principais) gira as colunas padronizadas em novos eixos ordenados por quanta variação carregam. Foi aplicado depois do tratamento e da codificação, com `StandardScaler` antes (o PCA é sensível à escala), dentro do Pipeline, reajustado só no treino de cada dobra, em dois regressores (regressão linear e Gradient Boosting), no `dataset_1_fundido` (30 colunas).

10.1 Variância explicada. Com todo o desenvolvimento padronizado, são necessários 7 componentes para 50% da variância, **18 para 80%**, 23 para 90% e 26 para 95% (de 30). Os dados quase não se comprimem: as colunas carregam informações independentes, o que combina com nenhum par passar de 0,7 de Spearman. O primeiro componente (renda e bens da casa) tem correlação de 0,463 com a nota; o segundo, −0,152.

10.2 PCA dentro do Pipeline. Testados k = 5, 10, 15, 20 e 25 componentes e o modelo sem PCA, nas mesmas dobras.

Componentes	Regressão linear: RMSE	Regressão linear: R^2	Gradient Boosting: RMSE	Gradient Boosting: R^2
sem PCA	111,153	0,287	107,770	0,330
25	111,658	0,280	110,165	0,300
20	111,887	0,278	110,432	0,296
15	112,718	0,267	111,148	0,287
10	113,047	0,262	111,551	0,282
5	114,425	0,244	113,210	0,260

Resultado. O PCA piora os dois regressores, e o RMSE cresce à medida que se cortam componentes. Nenhum k testado fica dentro de 1 desvio do modelo sem PCA (desvio de 0,18 a 0,23). A regressão linear só se aproximaria do resultado sem PCA com todos os componentes (o PCA completo é só uma rotação); o Gradient Boosting perde mais, porque o PCA mistura as colunas e dificulta as divisões das árvores. **Justificativa do número de componentes:** para 80% da variância seriam 18, mas nenhum corte melhora o erro; a melhor escolha para o modelo final é não usar PCA, e esse resultado sem ganho é legítimo e vai para o artigo.



Fonte: Inep, ENEM 2023; desenvolvimento. PCA dentro do Pipeline, padronizado, reajustado em cada dobra.

Figura 31. Esquerda: variância explicada acumulada do PCA; 18 componentes (de 30) chegam a 80%. Direita: RMSE com e sem PCA na regressão linear e no Gradient Boosting. Fonte: Inep, ENEM 2023; desenvolvimento.

10.3 t-SNE (diagnóstico). O t-SNE desenha as pessoas em 2 dimensões mantendo perto as parecidas e não entra em nenhum modelo (não sabe transformar pessoas novas). Foi usada uma amostra de 15 mil pessoas do desenvolvimento, o que o enunciado aceita por ser diagnóstico. Distâncias grandes entre grupos não devem ser lidas ao pé da letra: o t-SNE preserva vizinhanças, não distâncias. O desenho mostra pouca estrutura além de um gradiente renda × nota.

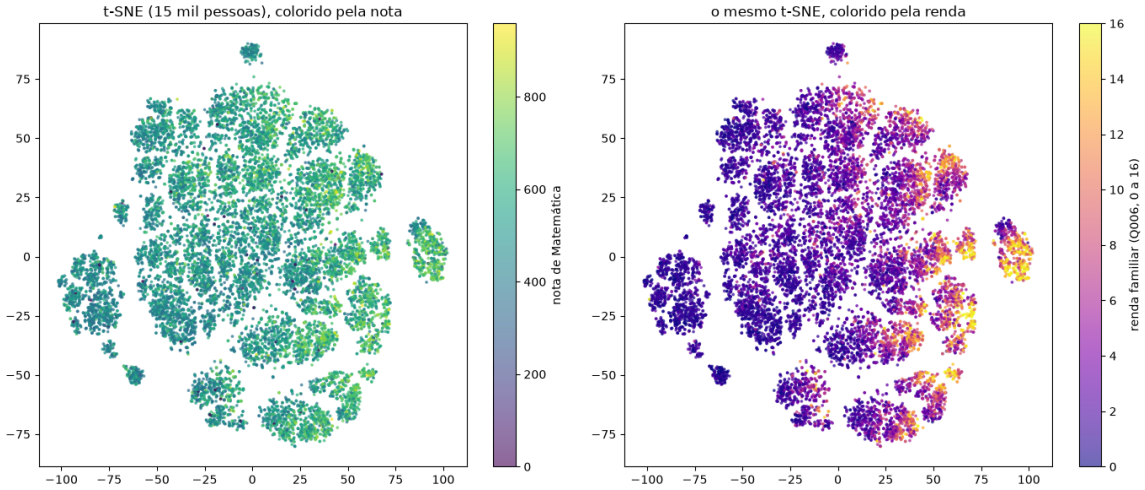


Figura 32. t-SNE de 15 mil pessoas do desenvolvimento, coloridas pela nota (esquerda) e pela renda familiar `Q006` (direita). Fonte: Inep, ENEM 2023.

10.4 K-means. Resultados na seção 9.6: dois grupos de perfil, sem ganho como feature.

11. Seleção de atributos

Método. `SelectKBest(f_regression, k)`: dá a cada coluna uma nota (teste F da correlação linear com a nota) e fica com as `k` maiores. Roda **dentro do Pipeline**, então as notas são recalculadas só com o treino de cada dobra. É rápido nos 2 milhões de linhas, mas mede só relação linear individual; por isso o notebook também calcula a importância por permutação do modelo final.

Hipótese (solução mais simples). Dá para manter o RMSE com menos colunas e menos tempo. Testamos `k` = 30%, 50% e 70% das 74 colunas (22, 37 e 51), no Gradient Boosting e na regressão linear. Regra de escolha, decidida antes de ver os resultados: o menor `k` cujo RMSE médio fica dentro de 1 desvio entre dobras do RMSE com todas as colunas; se nenhum, usamos todas.

Colunas	Gradient Boosting: RMSE	Aumento	Regressão linear: RMSE	Aumento
Todas (74)	106,025		108,868	
k = 51	107,069	+1,044	110,198	+1,329
k = 37	107,436	+1,412	110,526	+1,657
k = 22	110,607	+4,582	112,251	+3,382

Resultado. Cortar colunas piora os dois modelos, em todos os `k`, e a perda cresce quando o corte aumenta. Nenhum `k` ficou dentro do limite (106,025 + 0,188), então a regra manteve **todas as colunas**. Explicação provável (não testada): o teste F mede só a relação linear de cada coluna isolada, e o Gradient Boosting aproveita colunas com pouco sinal individual, como as UF, e combinações entre colunas. O método de seleção foi testado, comparado com a representação completa e não adotado, e esse é o resultado a reportar.

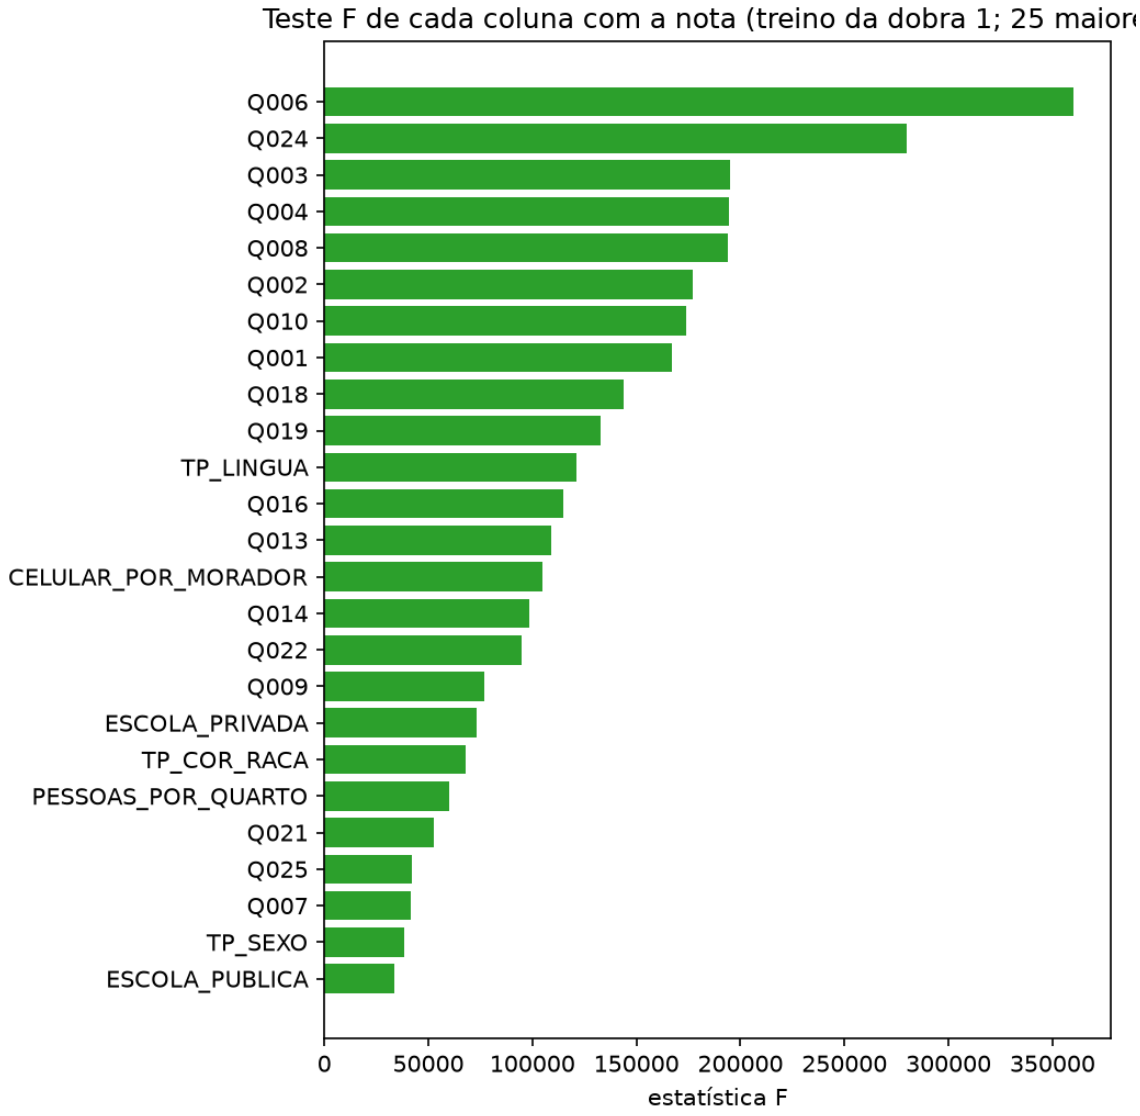


Figura 33. Teste F de cada coluna com a nota (treino da dobra 1; 25 maiores). Fonte: Inep, ENEM 2023; desenvolvimento.

A comparação pedida entre **features originais, novas features e seleção** fica assim: sem as 3 features criadas 106,038; com elas 106,025; com seleção (k = 51) 107,069.

12. Balanceamento por ponderação de faixas

Problema. As notas muito baixas e muito altas são raras e o modelo erra mais nelas: ele puxa tudo para o meio (regressão à média). O enunciado pede testar ao menos uma estratégia adequada à regressão, definida só com o treino de cada dobra, preservando a distribuição original na validação.

Estratégia: ponderação. O treino da dobra é agrupado em **faixas de 50 pontos** (a nota 0 numa faixa própria) e cada linha recebe peso `(pessoas na faixa)^(−α)`, normalizado para média 1, via `sample_weight` do Gradient Boosting. Os pesos usam só as notas do treino da dobra; o alvo continua sendo a nota numérica, não uma classe; nada de SMOTE. α = 0,5 dá um peso moderado (raiz do inverso da frequência); α = 1,0 equilibra todas as faixas (inverso da frequência). Regra de adoção, decidida antes: só adotar se o RMSE médio geral ficar menor que o do mesmo modelo sem pesos.

Efeito geral (validação, 3 dobras).

Peso	RMSE	MAE	R^2	Em relação a sem pesos
Sem pesos	106,025 ± 0,188	82,196	0,351	referência
α = 0,5	108,140 ± 0,188	82,820	0,325	+2,115: piora
α = 1,0	123,459 ± 0,149	94,826	0,120	+17,434: piora

Efeito por faixa de nota (RMSE e viés = nota real − prevista; positivo = o modelo subestima; média das 3 dobras):

Faixa	Pessoas por dobra	RMSE sem pesos	RMSE α = 0,5	RMSE α = 1,0	Viés sem pesos	Viés α = 0,5	Viés α = 1,0
0	4.433	513,8	510,4	489,5	−509,1	−503,3	−475,4
1 a 400	111.778	122,6	120,1	112,2	−109,2	−99,9	−67,7
400 a 500	198.921	78,8	85,3	100,6	−50,2	−44,6	−18,1
500 a 600	175.776	66,8	80,6	115,6	18,3	17,7	33,0
600 a 700	144.449	100,3	105,5	134,7	74,6	63,7	58,9
700 a 800	67.509	134,9	125,7	135,2	116,7	91,9	62,3
800 ou mais	15.114	184,9	155,4	131,7	172,4	131,8	81,1

Leitura. A ponderação faz o que promete nas pontas: nas notas acima de 800 o RMSE cai de 184,9 para 155,4 (α = 0,5) e 131,7 (α = 1,0), e o viés encolhe de 172 para 81. O preço é o erro das faixas do meio, onde estão quase todos: a faixa de 500 a 600 vai de 66,8 para 80,6 e 115,6. Como a maior parte das pessoas está no meio, o RMSE geral piora, e a regra de adoção rejeitou os dois pesos. A escolha entre eles é uma decisão de objetivo, não técnica: se o interesse for identificar as notas altas, α = 0,5 dá um compromisso melhor que α = 1,0; se for o erro médio, nenhum peso. Nenhuma das duas corrige o viés dos zeros (previstos em cerca de 500 pontos a mais), que não têm como ser previstos pelo perfil.

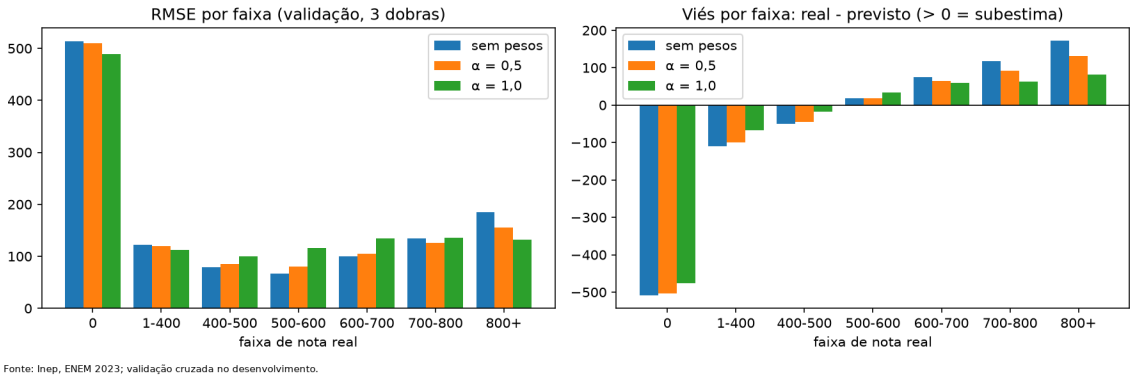


Figura 34. RMSE e viés por faixa de nota (validação, 3 dobras) sem pesos e com pesos α = 0,5 e α = 1,0. Fonte: Inep, ENEM 2023; validação cruzada.

13. Solução final, validação cruzada e curva de aprendizado

A solução final é o **Gradient Boosting** (`HistGradientBoostingRegressor`) com os hiperparâmetros da busca (seção 7: `learning_rate` 0,067, até 500 árvores, 89 folhas, `min_samples_leaf` 137, `l2_regularization` 0,244, parada antecipada com 10% do treino da dobra), sobre a representação que ganhou nas seções 9, 11 e 12:

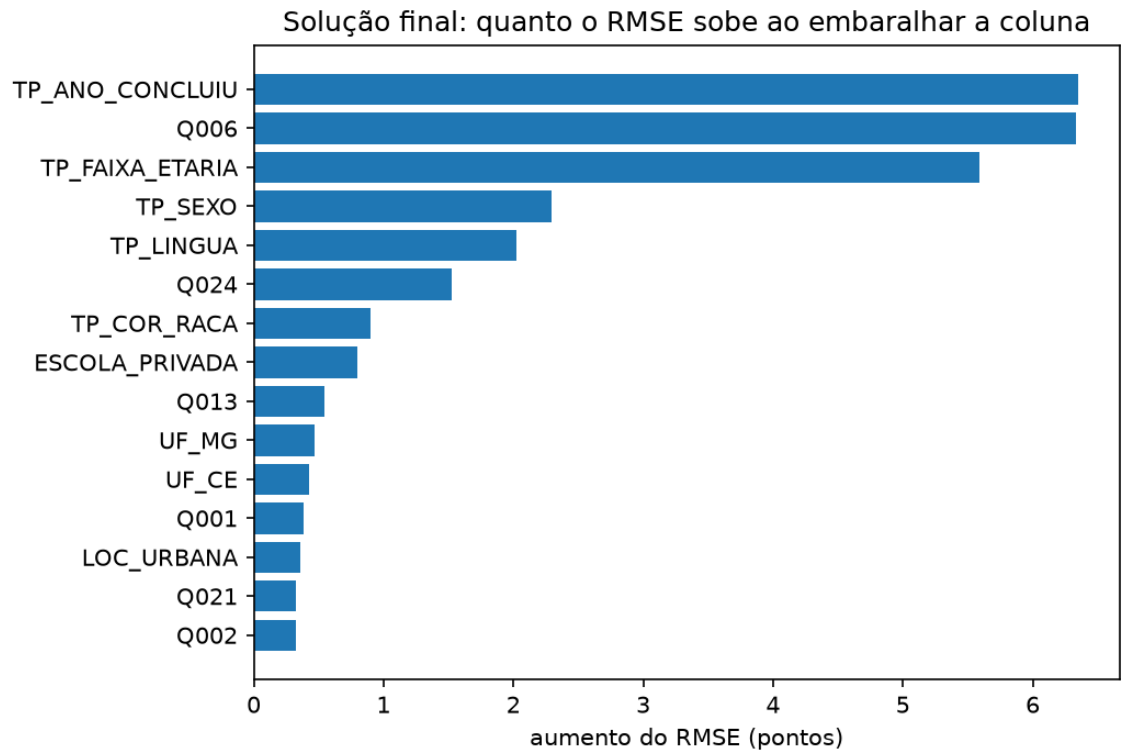
- **74 colunas, nenhum nulo:** as 44 colunas do dataset 3 (escola, `NAO_SEI`, nacionalidade, 3 features criadas) sem a `FUSAO_1`, mais as **4 colunas de situação escolar separadas** e **26 colunas de UF da prova**.
- Sem fusão, sem seleção de atributos, sem PCA, sem pesos por faixa (cada um foi testado e não adotado).
- Escolhida **só pela validação cruzada**: 105,864 ± 0,169, contra 106,025 ± 0,188 do mesmo modelo com a configuração inicial (−0,161, dentro do desvio de 0,188: a busca quase não ajuda).

13.1 Validação cruzada na representação final (média ± desvio nas 3 dobras):

Modelo	RMSE	MAE	R^2	Tempo por dobra (s)
Baseline (média)	131,63 ± 0,16	107,58 ± 0,06	0,000	0,2
Regressão linear (sem regularização)	108,87 ± 0,16	84,86 ± 0,04	0,316 ± 0,001	2,8
Gradient Boosting, configuração inicial	106,03 ± 0,19	82,20	0,351	40
Solução final (hiperparâmetros da busca)	**105,86 ± 0,17**	**82,02 ± 0,05**	**0,353 ± 0,001**	91

RMSE da solução final por dobra: 105,80; 105,74; 106,06. A regressão linear também melhorou com a nova representação (111,15 no dataset 1 para 108,87), o que mostra que o ganho da UF e da situação escolar desdobrada não é só do Gradient Boosting.

13.2 Importância das colunas (importância por permutação: quanto o RMSE sobe ao embaralhar a coluna na validação da dobra 1, 5 mil pessoas, 3 repetições): `TP_ANO_CONCLUIU` +6,35 pontos, `Q006` (renda) +6,33, `TP_FAIXA_ETARIA` +5,59, `TP_SEXO` +2,29, `TP_LINGUA` +2,02, `Q024` (computadores) +1,53, `TP_COR_RACA` +0,90 e `ESCOLA_PRIVADA` +0,80. As três maiores são idade, ano de conclusão e renda; é associação, não causa.



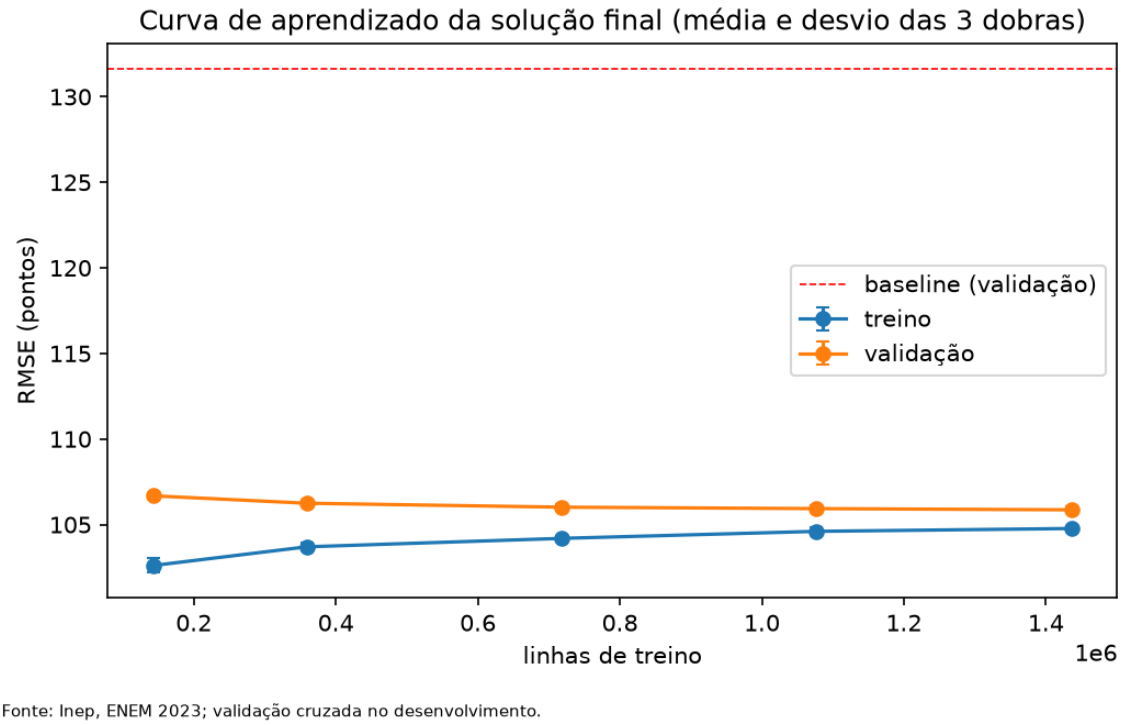
Fonte: Inep, ENEM 2023; validação da dobra 1.

Figura 35. Solução final: quanto o RMSE sobe ao embaralhar cada coluna (validação da dobra 1). Fonte: Inep, ENEM 2023; desenvolvimento.

13.3 Curva de aprendizado (obrigatória). Em cada uma das 3 dobras, a validação fica fixa e o treino da dobra é embaralhado com a semente 42; usamos os primeiros 10%, 25%, 50%, 75% e 100% das linhas (subconjuntos progressivos, de 143.596 a 1.435.961 linhas). Para cada tamanho todo o Pipeline é reajustado, com os hiperparâmetros fixos; o RMSE de treino é medido no próprio subconjunto e o de validação na validação da dobra. O teste não entra.

Treino (% da dobra)	Linhas (média)	RMSE treino	RMSE validação	Diferença (val. − treino)
10%	143.596	102,61 ± 0,42	106,68 ± 0,17	4,07
25%	358.990	103,70 ± 0,22	106,25 ± 0,19	2,55

Treino (% da dobra)	Linhas (média)	RMSE treino	RMSE validação	Diferença (val. − treino)
50%	717.980	104,19 ± 0,13	106,02 ± 0,19	1,82
75%	1.076.971	104,60 ± 0,21	105,93 ± 0,18	1,33
100%	1.435.961	104,77 ± 0,10	105,86 ± 0,21	1,09



Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Figura 36. Curva de aprendizado da solução final: RMSE de treino e de validação (média e desvio das 3 dobras) com 10%, 25%, 50%, 75% e 100% do treino da dobra; linha vermelha: baseline. Fonte: Inep, ENEM 2023; validação cruzada no desenvolvimento.

Diagnóstico. As duas curvas se aproximam e ficam altas: o erro de treino sobe de 102,6 para 104,8 (com pouco dado o modelo decora um pouco mais) e o de validação cai de 106,7 para 105,9, terminando separados por só 1,1 ponto. Isso **não indica sobreajuste forte**, que apareceria como erro de treino bem menor que o de validação. De 75% para 100% do treino a validação melhora só 0,07 ponto, menos que o desvio entre dobras (0,2): dobrar o volume de dados não resolveria. Erros altos e próximos podem ser subajuste, mas também falta de informação nas features; aqui há indícios de que é informação: modelos muito diferentes (linear, árvores, KNN, bagging, boosting) terminam todos entre 106 e 112, e um Gradient Boosting com muito mais capacidade (500 árvores, 89 folhas) pouco ganha sobre o inicial (−0,16). O erro restante é em grande parte variância que o perfil não explica, como o esforço de estudo, a qualidade do ensino e as circunstâncias do dia da prova.

14. Teste final

O teste foi aberto **uma única vez**, com a solução fixada. No desenvolvimento completo (2.153.941 pessoas) foram ajustados o baseline, a regressão linear sem regularização e a solução final; os três foram

avaliados nos mesmos 538.486 participantes. Faixas de nota e grupos foram definidos no desenvolvimento (seção 12 e abaixo) e mantidos. Nada do teste voltou para a escolha de features, técnicas ou hiperparâmetros.

14.1 Métricas. Validação cruzada (média ± desvio nas 3 dobras) separada do teste:

Modelo	CV RMSE	CV MAE	CV R^2	Teste RMSE	Teste MAE	Teste R^2	Ajuste no teste (s)
Baseline (média)	131,63 ± 0,16	107,58 ± 0,06	0,000	131,70	107,64	0,000	0
Regressão linear (sem regularização)	108,87 ± 0,16	84,86 ± 0,04	0,316	108,86	84,89	0,317	4
Solução final (Gradient Boosting)	**105,86 ± 0,17**	**82,02 ± 0,05**	**0,353**	**105,81**	**82,00**	**0,354**	165

O teste confirma a validação: o RMSE da solução final é 105,81 no teste e 105,86 na validação, diferença de 0,05, bem menor que o desvio entre dobras (0,17). Não há sinal de que a escolha da solução tenha sido ajustada demais à validação. A solução final erra **19,7% menos que o baseline** (105,81 contra 131,70) e 2,8% menos que a regressão linear (3,05 pontos). Em média ela erra cerca de 82 pontos por participante.

14.2 Resíduos (nota observada − prevista). A média dos resíduos é 0,1 e o desvio, 105,8 (praticamente o RMSE). Contra a nota prevista, a média do resíduo fica perto de zero em toda a faixa prevista, sem tendência, mas a dispersão é grande e as previsões ficam concentradas entre cerca de 350 e 850, enquanto as notas reais vão de 0 a 1000: é a regressão à média, que aparece como o "leque" do gráfico. As notas zero formam uma faixa diagonal isolada, com resíduos de −370 a −770, e uma pequena corcova perto de −500 no histograma; fora elas, o histograma é aproximadamente simétrico.

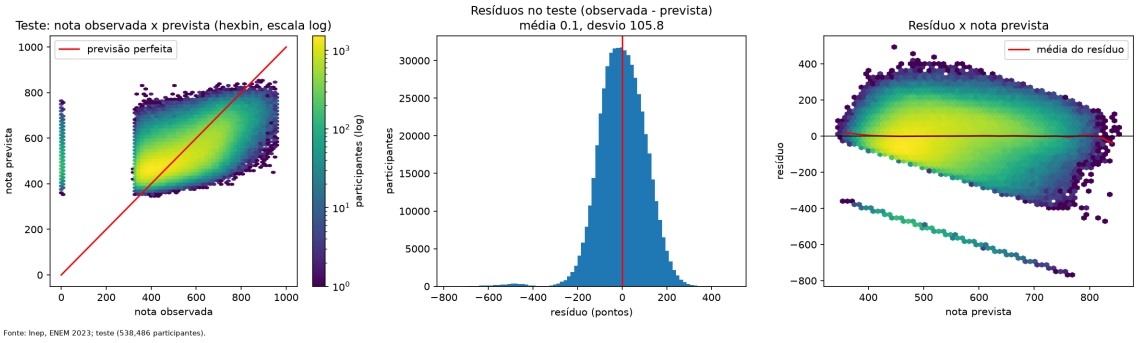


Figura 37. Teste (538.486 participantes): nota observada × prevista pela solução final em células hexagonais (a reta vermelha é a previsão perfeita), histograma dos resíduos e resíduo × nota prevista. Fonte: Inep, ENEM 2023; teste.

14.3 Erro por faixa de nota (tamanhos dos grupos no teste):

Faixa	Participantes	Nota média	RMSE	MAE	Viés (real − previsto)
0	3.338	0,0	515,0	510,4	−510,4
1 a 400	84.129	369,2	121,8	108,6	−108,5
400 a 500	148.789	449,5	78,8	60,8	−49,8
500 a 600	131.742	548,7	67,1	54,8	+18,6
600 a 700	108.434	647,5	100,3	84,6	+74,2
700 a 800	50.811	738,8	133,9	117,3	+115,5
800 ou mais	11.243	844,1	183,7	171,0	+171,0

O erro é mínimo perto da média (faixa 500 a 600: 67) e cresce nas pontas, com viés de sinal oposto: o modelo superestima as notas baixas e subestima as altas. As notas zero (0,62%) são previstas em cerca de 510 pontos acima do real e não têm como ser identificadas pelo perfil: eliminar ou faltar parte da prova não aparece no questionário socioeconômico.

14.4 Erro por grupo de perfil e de localização (grupos definidos no desenvolvimento):

Grupo	Participantes	Nota média	RMSE	MAE	Viés
Região Norte	57.603	487,9	97,9	75,2	−0,6
Região Nordeste	199.339	511,6	103,5	80,8	0,0
Região Centro-Oeste	44.000	533,5	107,0	82,8	−0,7
Região Sudeste	179.317	565,9	108,7	84,5	+0,6
Região Sul	58.227	557,2	111,0	84,5	−0,1
Renda até 1 salário mínimo	187.962	472,9	97,3	74,8	−0,1
Renda de 1 a 3 salários	210.263	530,8	108,1	84,9	+0,1
Renda de 3 a 6 salários	76.867	594,9	113,1	88,7	+0,6
Renda de 6 a 10 salários	34.469	634,3	113,3	87,3	+0,3
Renda acima de 10 salários	28.925	669,8	112,9	84,3	−0,2
Escola pública	166.819	503,7	102,1	79,7	−0,3
Escola privada	44.281	630,9	108,9	85,9	+0,3
Escola sem informação	327.386	536,1	107,3	82,7	+0,2
Feminino	330.626	516,9	101,2	78,3	0,0
Masculino	207.860	560,9	112,8	87,9	+0,2

Salário mínimo de 2023: R$ 1.320. Por UF, o RMSE vai de 95,3 (AP) a 116,2 (SC); a tabela completa das 27 UF está em `resultados/tabelas/teste_erros_por_grupo.csv`.

Leitura: o viés médio de cada grupo de região, renda, escola e sexo é quase zero (menos de 1 ponto; por UF chega a 2,5, no Apêndice D.2), então o modelo não favorece nem prejudica sistematicamente nenhum grupo em média. O RMSE varia mais do que o viés: de 97 a 102 no Norte, na renda até 1 salário

e na escola pública, a 111 a 113 no Sul, na renda acima de 3 salários e no sexo masculino. O R^2 dentro de cada faixa de renda é parecido (0,17 a 0,21), então o RMSE maior nos grupos de renda alta acompanha uma nota mais dispersa dentro do grupo, não um modelo pior para eles. Os grupos têm tamanhos muito diferentes (de 2.992 no Acre a 330.626 mulheres); a leitura vale para o grupo, não para a pessoa.

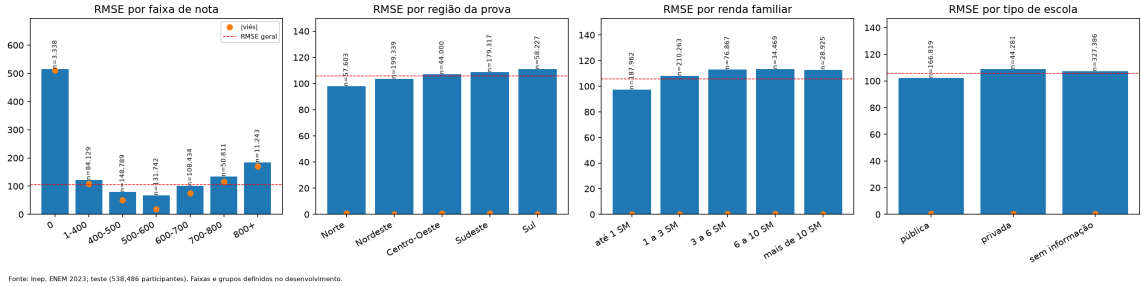


Figura 38. Teste: RMSE por faixa de nota, região da prova, faixa de renda e tipo de escola, com o tamanho de cada grupo (n); laranja: valor absoluto do viés; linha vermelha: RMSE geral. Fonte: Inep, ENEM 2023; teste.

15. Discussão, limitações e o que não funcionou

15.1 Por que o R^2 fica em torno de 0,35.

- As features descrevem o perfil (renda, escolaridade dos pais, bens, escola, UF, idade). O que mais pesa na nota de Matemática (horas de estudo, base escolar, qualidade do ensino, circunstâncias do dia da prova) não está nos dados. Pessoas com o mesmo perfil tiram notas muito diferentes.
- Famílias de modelos muito diferentes (linear, árvore, KNN, bagging, boosting) terminam num intervalo estreito (106 a 112 de RMSE) e as árvores só ganham 3 a 4 pontos sobre a regressão linear. A curva de aprendizado mostra treino e validação separados por só 1,1 ponto e quase sem ganho de 75% para 100% do treino. Tudo aponta para um limite de informação, não de algoritmo nem de volume de dados.
- A base de 2023 não traz o código da escola (só município e UF), então não dá para usar a nota média da escola, que seria um dos melhores preditores. As colunas da escola existem para cerca de 27% dos participantes.
- Usar as notas de outras áreas elevaria o R^2 de 0,34 para 0,68 (dataset 6, seção 8.5; presença e respostas não foram testadas), mas é vazamento e o enunciado proíbe. Prever pelo perfil é o objetivo.
- O erro maior nas pontas é regressão à média: o modelo não enxerga o que separa uma nota 800 de uma 600 com o mesmo perfil, e os zeros (quem faltou parte da prova ou foi eliminado) não têm relação com o questionário.

15.2 O que funcionou e o que não funcionou (RMSE de validação; negativo = melhora):

Alavanca	Efeito no RMSE	Avaliação
Modelos de árvores (Gradient Boosting) contra regressão linear	−3,4 (dataset 1)	Funcionou, maior ganho
UF da prova	−0,70	Funcionou, pequeno
Situação escolar separada em vez de fundida	−0,33	Funcionou, pequeno
Informação de escola	−0,4 a −0,5	Funcionou, pequeno
`NAO_SEI` e nacionalidade	−0,2 a −0,4	Pequeno
Busca de hiperparâmetros	−0,93 no bagging; −0,09 a −0,16 no Gradient Boosting	Ajudou só nos modelos de bagging
3 features criadas	+0,01	Sem efeito prático
Stacking contra Gradient Boosting	−0,007	Não vale o custo (5 vezes mais tempo)
Treino sem as notas zero	−0,06 a +0,01	Sem efeito mensurável
K-means como feature	+0,02	Sem efeito
Seleção de atributos (`SelectKBest`)	+1,0 a +4,6	Piora
PCA (Gradient Boosting, 5 a 25 componentes)	+2,4 a +5,4	Piora
Balanceamento por ponderação	+2,1 ($\alpha = 0,5$) e +17,4 ($\alpha = 1,0$)	Piora o geral; melhora as notas acima de 800
KNN e SVR linear	+0,4 e 0,0 contra a regressão linear	Lentos e sem ganho

15.3 Limitações e riscos.

- **Associação não é causa.** Renda, idade ou escola privada estão associadas à nota; não determinam a capacidade de uma pessoa, e o modelo não serve para decidir sobre indivíduos (erro médio de 82 pontos).
- **A divisão avalia novos participantes da mesma edição**, não escolas ou municípios inéditos. A UF é a da prova e a escola é a do cadastro; nenhuma delas é residência.
- **Hiperparâmetros buscados no dataset 1** (30 colunas, antes da correção da fusão) e reaproveitados na representação final. O RMSE de uma busca é otimista (o melhor entre 10).
- **Colunas nominais** (cor/raça, estado civil) entram como números em escada; árvores toleram, a regressão linear não. Não testamos one-hot nelas.
- **Spearman não mede redundância entre colunas sem ordem**; faltou V de Cramér para esses pares.

- **Município** (cerca de 1.750 categorias) não entrou na solução final; era o maior sinal ainda não explorado. Testado depois no notebook 06 (Apêndice G.3), com target encoding dentro do Pipeline, melhorou 0,30 ponto na validação cruzada (0,13 sobre a solução final) e não foi adotado, porque o teste já havia sido aberto.
- **Uma só semente** (42) em tudo; o desvio entre dobras mede a variação por dobra, não por semente.
- Os arquivos `resultados/tabelas/busca_<modelo>.csv` são gravados com o mesmo nome pelo notebook otimizado e pelo notebook sem zeros; rodar um depois do outro sobrescreve o anterior.
- Os notebooks 02 e 03 usam o dataset 1 (com a fusão calculada em todas as linhas, efeito medido em 0,003 ponto de RMSE); só o notebook 04 está sem esse vazamento.

16. Reprodutibilidade, arquivos e mapa para o artigo e o pitch

Ambiente. Python 3.14.8, pandas 3.1.0, numpy 2.5.4, scipy 1.18.1, scikit-learn 1.9.1, matplotlib 3.11.2, em um computador com 10 núcleos e 16 GB; os estimadores usados rodam em CPU. Semente 42 em tudo que aceita `random_state`. Versões fixadas em `requirements.txt`.

Ordem de execução (notebooks, a partir da pasta `notebooks/`):

1. Obter `MICRODADOS_ENEM_2023.csv` no Inep e colocar em `dados/raw/DADOS/`.
2. `01-exploracao-filtro`: triagem, filtro dos participantes com nota, codificação, features criadas e os 8 datasets em `dados/processed/`.
3. `python src/particao.py` (opcional): confere que `dados/splits/` é igual à partição gerada com a semente 42.
4. `02-treino-modelos`: todos os regressores em configuração inicial e a comparação dos 8 datasets.
5. `02-treino-modelos-optimized`: `RandomizedSearchCV` (10 configurações).
6. `02-treino-modelos-sem-zeros-optimized`: treino sem as notas zero.
7. `03-reducao-dimensionalidade`: PCA, t-SNE e K-means.
8. `04-avaliacao-final`: fusão sem vazamento, UF, features criadas, seleção, balanceamento, blocos, solução final, curva de aprendizado e teste (cerca de 52 minutos). Opcional: notebook 05-diagnostico-notas-outras-areas (dataset 6, cerca de 5 minutos; fora da solução).

Saídas. `resultados/experimentos.csv` (uma linha por experimento: hipótese, features, preparação, modelo, parâmetros, conjunto avaliado, métricas por dobra, média, desvio, tempo e conclusão; as linhas `T_*` são do teste); `resultados/previsoes_teste.csv` (identificador, nota observada e previsões do baseline, da regressão linear e da solução final); `resultados/tabelas/` e `resultados/figuras/` (10 figuras do notebook 04); `models/*.joblib` (fora do git).

Mapa para o artigo e o pitch. O enunciado pede estas figuras e tabela no artigo e as mesmas evidências no pitch:

Evidência exigida	Onde está neste documento	Arquivo
Distribuição da nota com os zeros em destaque	Seção 2	`distribuicao_nota_dev.png`
Modelos contra o baseline e os 3 melhores antes/depois da busca	Seções 6 e 7	`comparacao_modelos.png`
Variância explicada do PCA, com o número de componentes e a justificativa	Seção 10	`pca_variancia_e_rmse.png`
Curva de aprendizado do modelo final	Seção 13	`curva_aprendizado.png`
Observada contra prevista no teste e resíduos	Seção 14	`teste_real_previsto_residuos.png`
Erro por faixa de nota e por grupo, com tamanhos	Seção 14	`teste_erros_por_faixa_e_grupo.png`
Tabela de RMSE, MAE, R^2 e tempo: CV (média e desvio) separada do teste	Seções 1 e 14	`tabela_final_cv_e_teste.csv`

O artigo foi escrito no padrão IEEE (duas colunas), com 10 páginas, 10 figuras e 9 tabelas, e inclui a replicação independente (dataset 5, subseção III-F) e o diagnóstico com as notas de outras áreas (dataset 6, subseção III-G, rotulado como fora da solução) e as extensões finais do notebook 06 (subseção III-H, Apêndice G). Os slides do pitch têm 26 slides, um gráfico por slide, com dois deles para esses dois conjuntos. Para o artigo, as seções 2 a 5 viram “Metodologia”, 6 a 14 viram “Resultados”, 15 vira “Discussão” e 1 vira “Resumo” e “Conclusão”. Os detalhes por modelo (seção 6), os espaços de busca (seção 7) e as tabelas completas por UF ficam no repositório.

Equipe. João Igor Vidal de Andrade, Raquel Albuquerque Quirino, Amanda Lira e Sofya Oliveira. Repositório: github.com/Alyra004/ciencia-de-dados-unifor-projeto-2.

Referências. Inep, Microdados do ENEM 2023 e dicionário de variáveis (2024); Pedregosa et al., Scikit-learn: Machine learning in Python, JMLR 12 (2011); Friedman, Greedy function approximation: a gradient boosting machine, Annals of Statistics 29(5) (2001); Breiman, Bagging predictors, Machine Learning 24(2) (1996) e Random forests, Machine Learning 45(1) (2001); Wolpert, Stacked generalization, Neural Networks 5(2) (1992); Bergstra e Bengio, Random search for hyper-parameter optimization, JMLR 13 (2012); Hoerl e Kennard, Ridge regression, Technometrics 12(1) (1970); Jolliffe, Principal Component Analysis, 2ª ed. (Springer, 2002); Ke et al., LightGBM, NIPS (2017); van der Maaten e Hinton, Visualizing data using t-SNE, JMLR 9 (2008); Spearman, The proof and measurement of association between two things, American Journal of Psychology 15(1) (1904).

17. Apêndice A: figuras complementares

Todas as figuras dos notebooks que não aparecem no corpo do documento (as do corpo vão de 1 a 38). Elas estão numeradas de A1 a A45 e agrupadas pelo notebook de origem: 01 (exploração e Spearman), 02 (modelos em configuração inicial), 02 otimizado (modelos depois da busca) e 03 (PCA). Os gráficos de importância mostram quanto cada coluna pesa; os de "real × previsto" mostram 20 mil pessoas da validação (a reta verde é a previsão perfeita e as notas zero formam a coluna da esquerda).

A.1 Notebook 01: exploração, Spearman e datasets 2 e 3

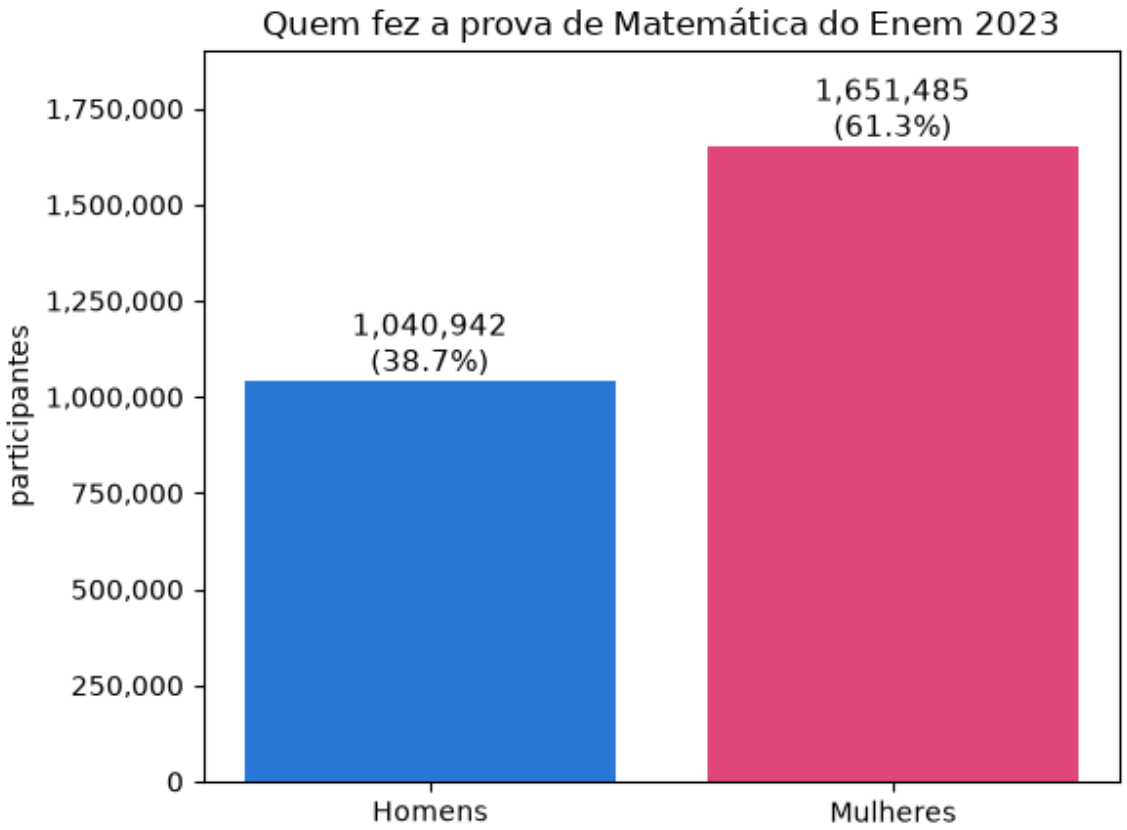


Figura A1. Participantes por sexo (com nota de Matemática). Fonte: Inep, ENEM 2023.

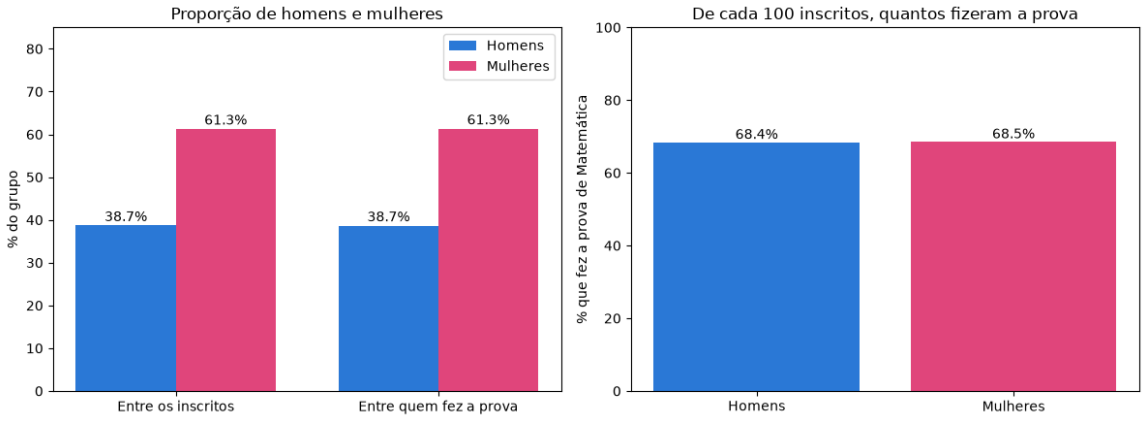


Figura A2. Participantes por sexo entre todos os inscritos, inclusive quem não tem nota. Fonte: Inep, ENEM 2023.

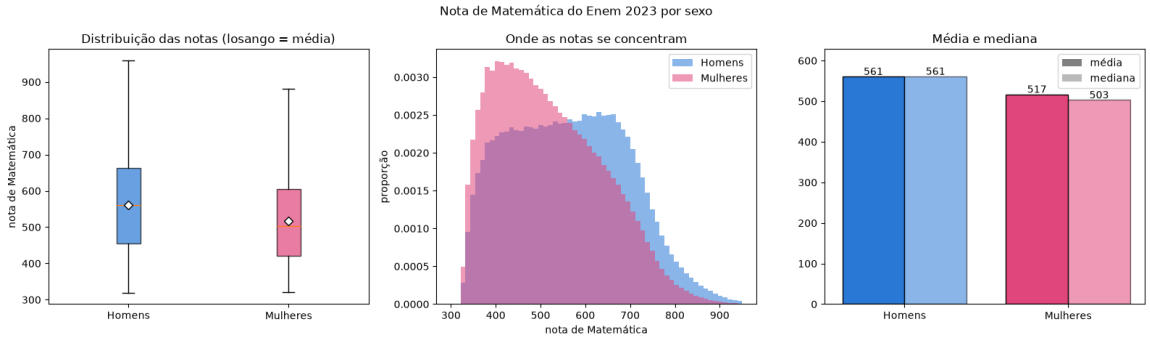


Figura A3. Nota de Matemática por sexo. Fonte: Inep, ENEM 2023.

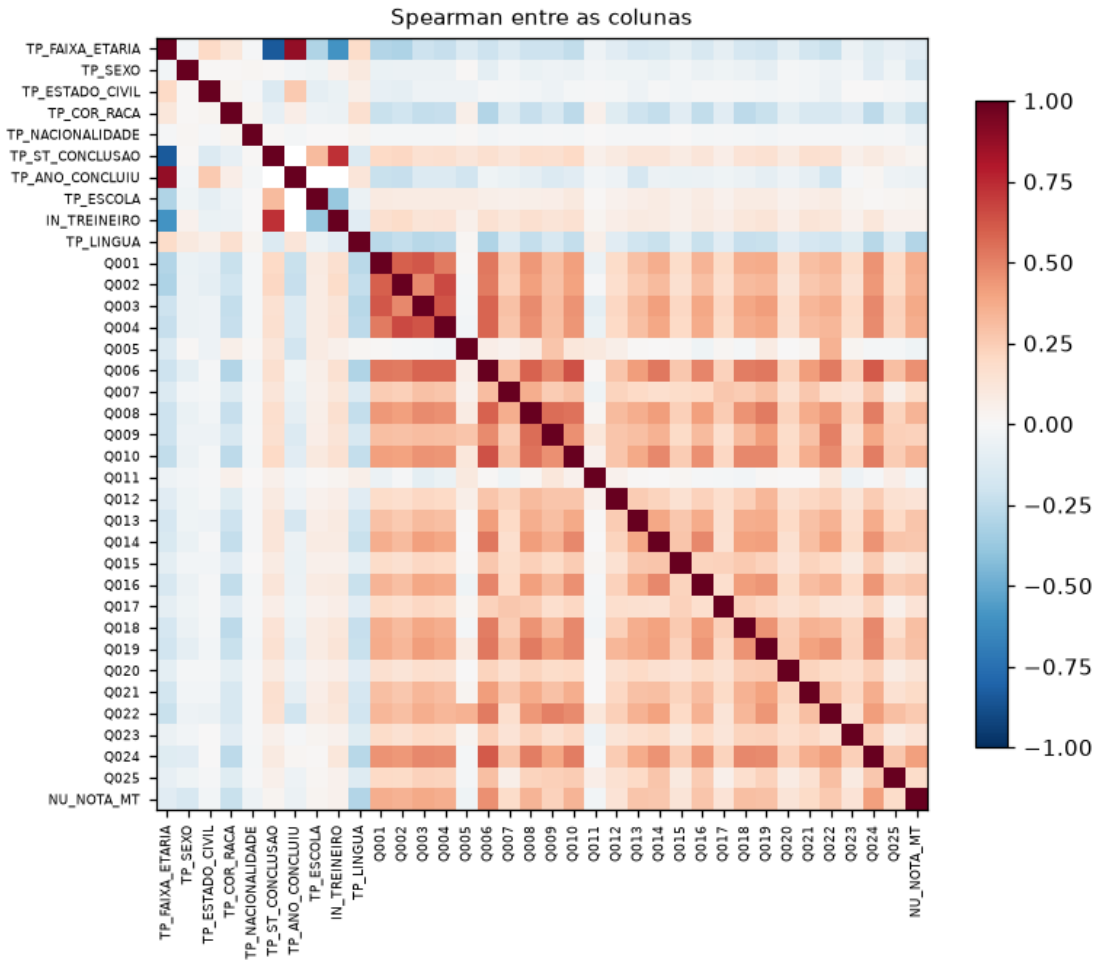


Figura A4. Matriz de Spearman entre as colunas, antes da fusão. Fonte: Inep, ENEM 2023.

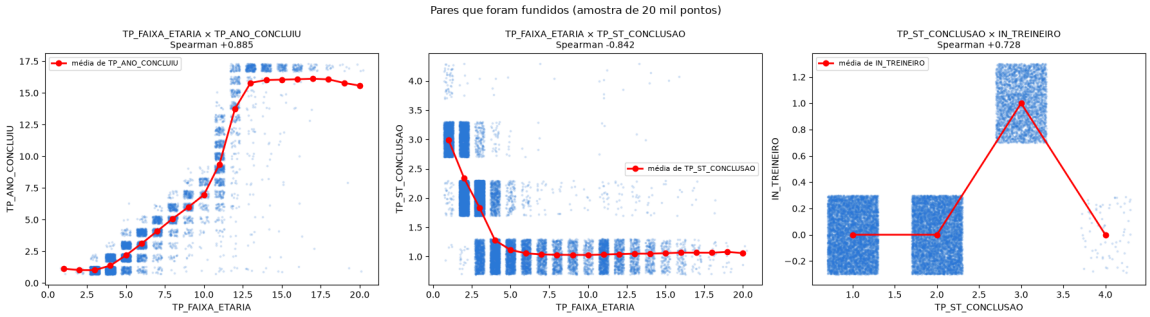


Figura A5. Exemplos de pares de colunas com Spearman alto (candidatos à fusão). Fonte: Inep, ENEM 2023.

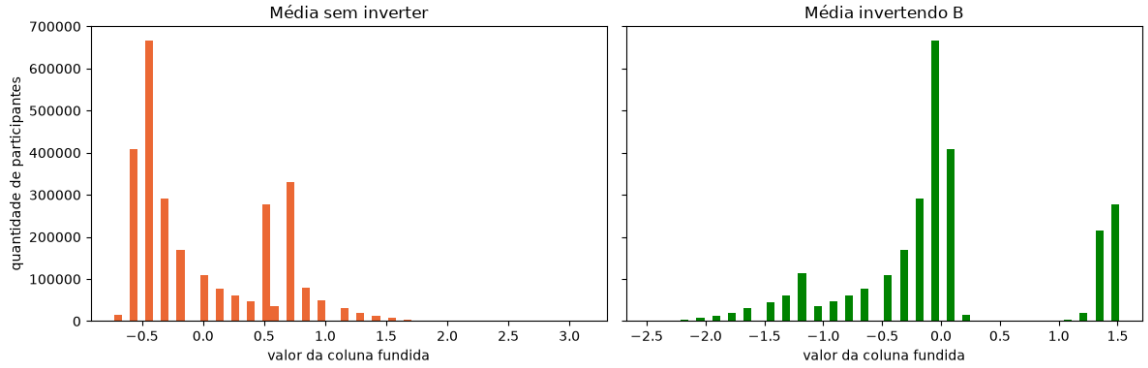


Figura A6. Fusão de IN_TREINEIRO e TP_FAIXA_ETARIA: média sem inverter o sinal contra média invertendo uma das colunas. Fonte: Inep, ENEM 2023.

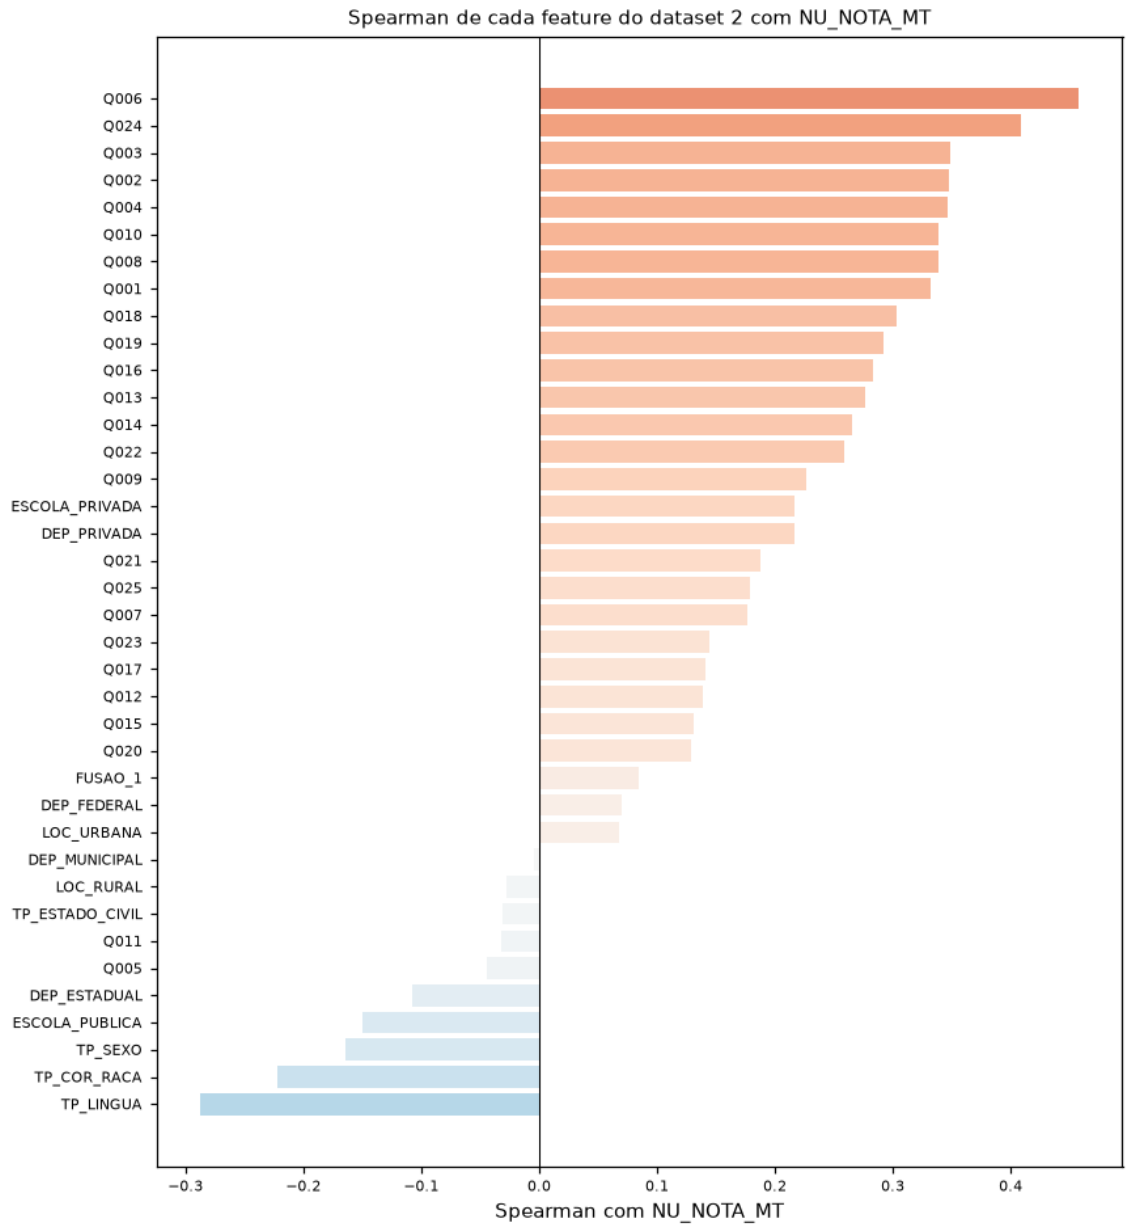


Figura A7. Dataset 2 antes da retirada das quatro colunas DEP: Spearman de cada feature com a nota. Fonte: Inep, ENEM 2023.

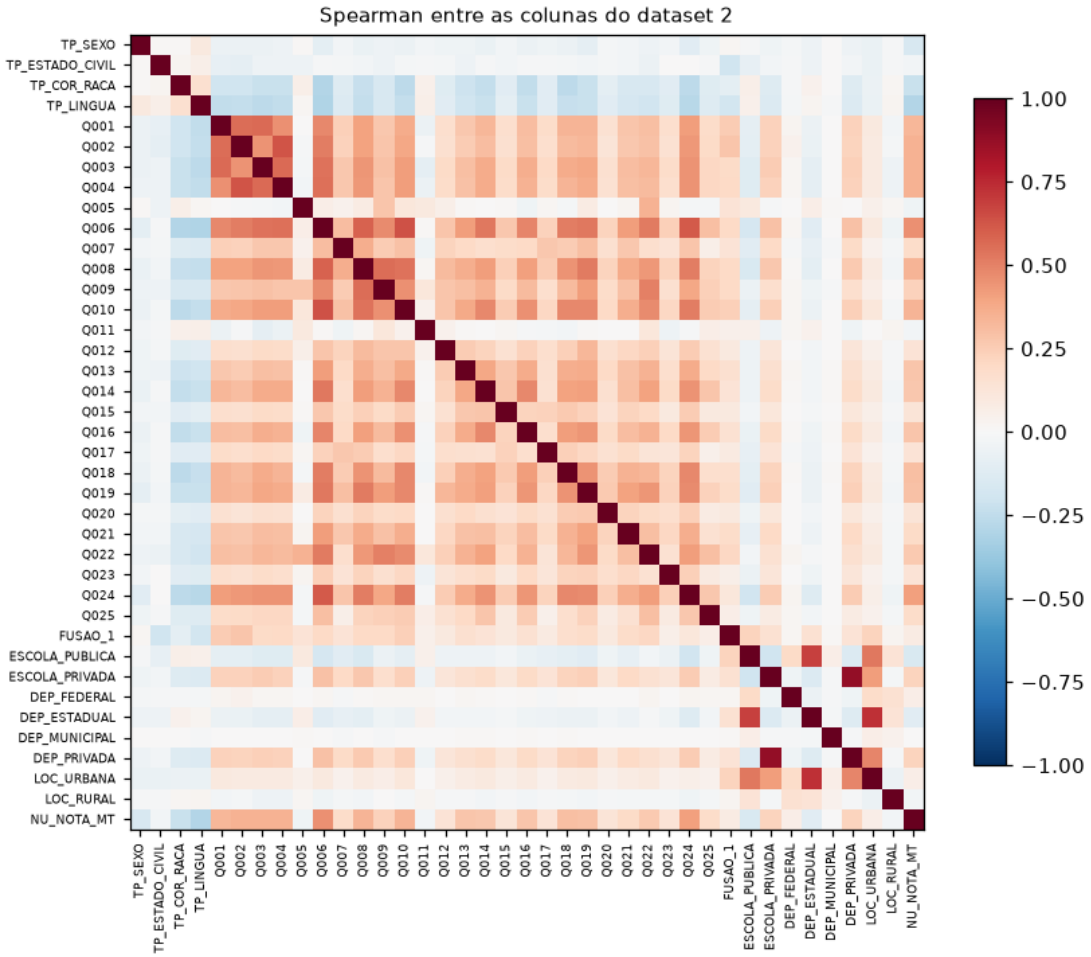


Figura A8. Dataset 2 antes da retirada das quatro colunas DEP: matriz de Spearman. Fonte: Inep, ENEM 2023.

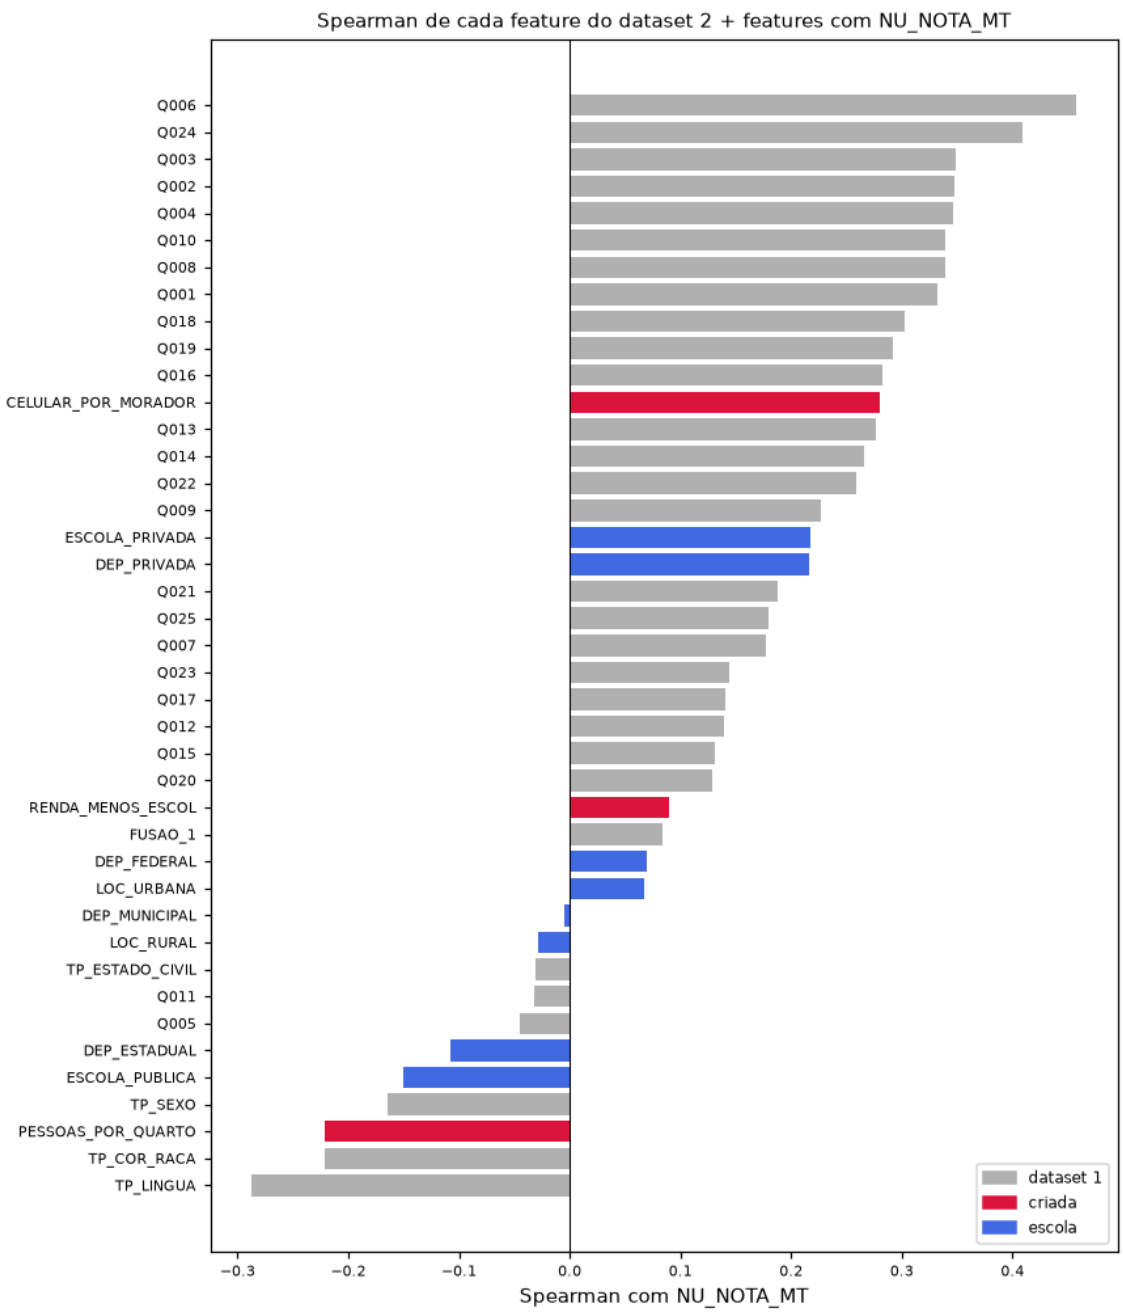


Figura A9. Dataset 2 + features antes da retirada das quatro colunas DEP: Spearman com a nota. Fonte: Inep, ENEM 2023.

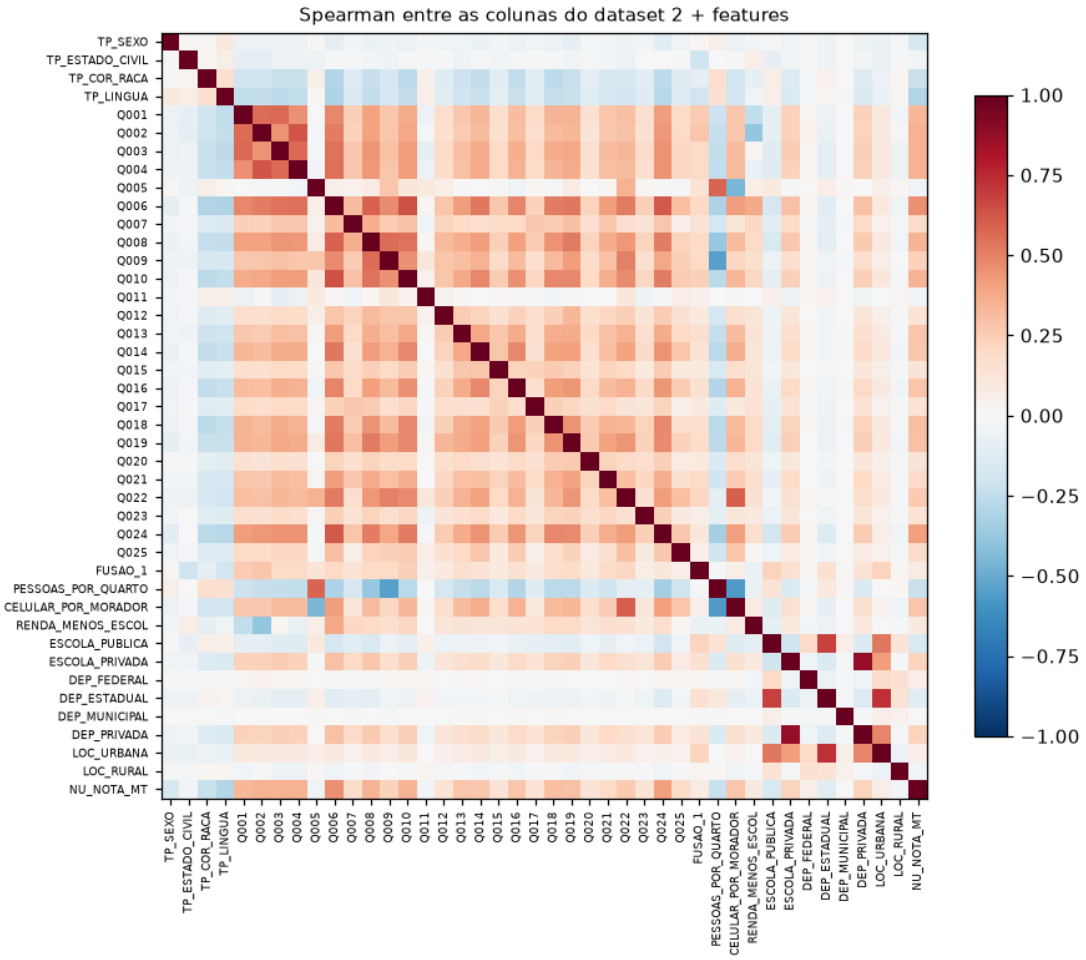


Figura A10. Dataset 2 + features antes da retirada das quatro colunas DEP: matriz de Spearman. Fonte: Inep, ENEM 2023.

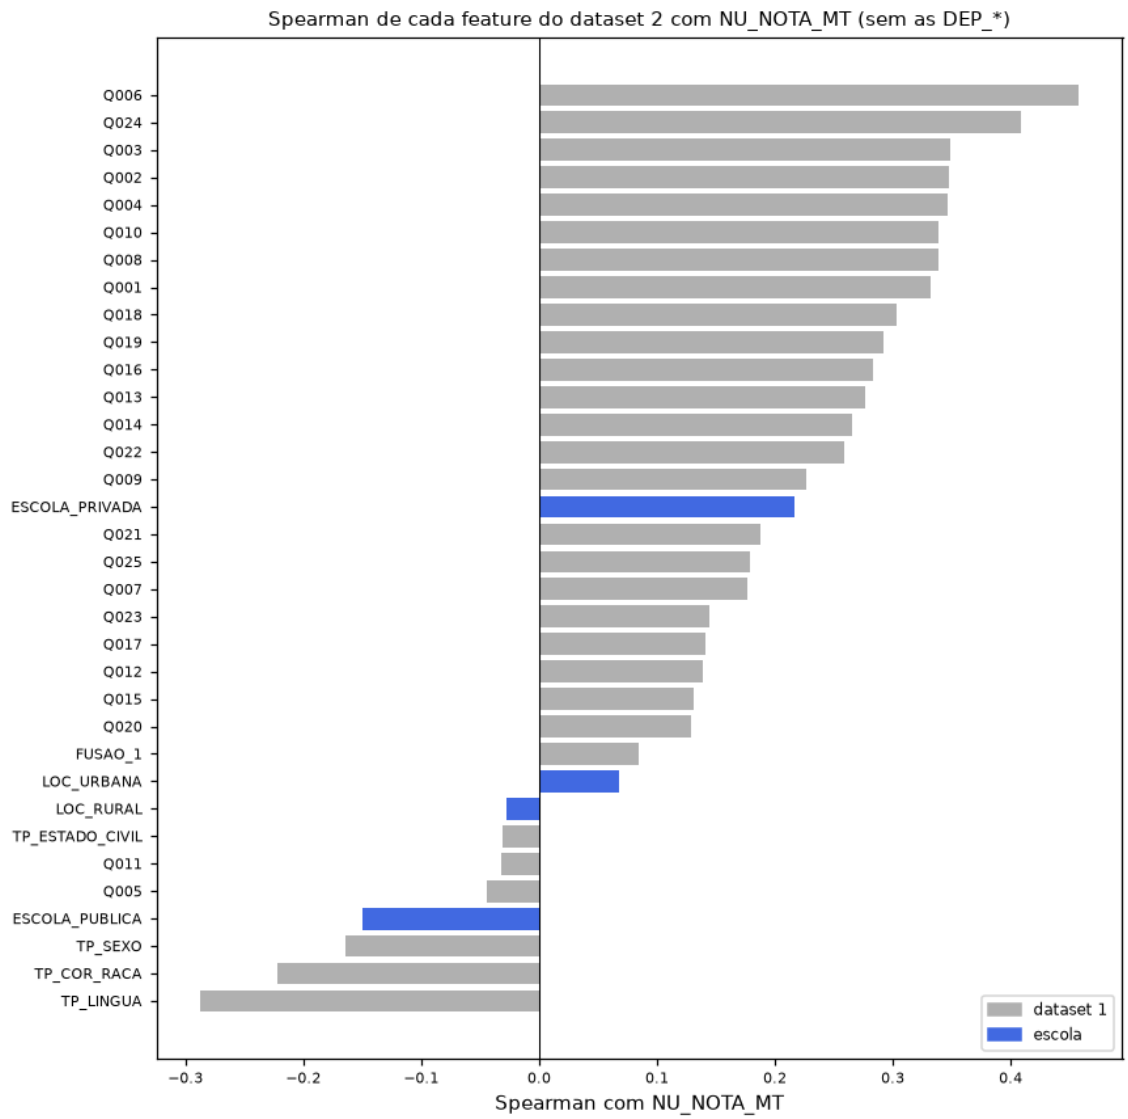


Figura A11. Dataset 2 final (sem as colunas DEP): Spearman de cada feature com a nota. Fonte: Inep, ENEM 2023.

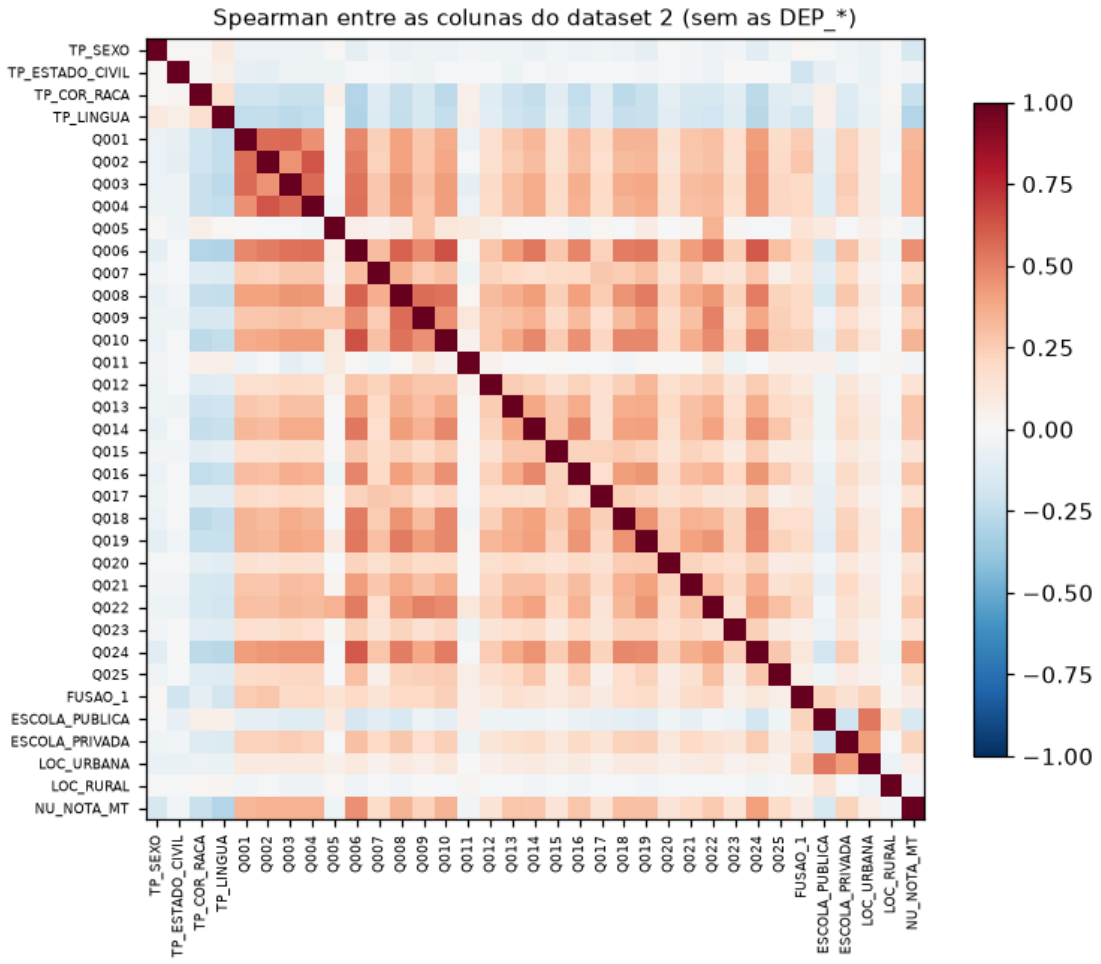


Figura A12. Dataset 2 final: matriz de Spearman. Fonte: Inep, ENEM 2023.

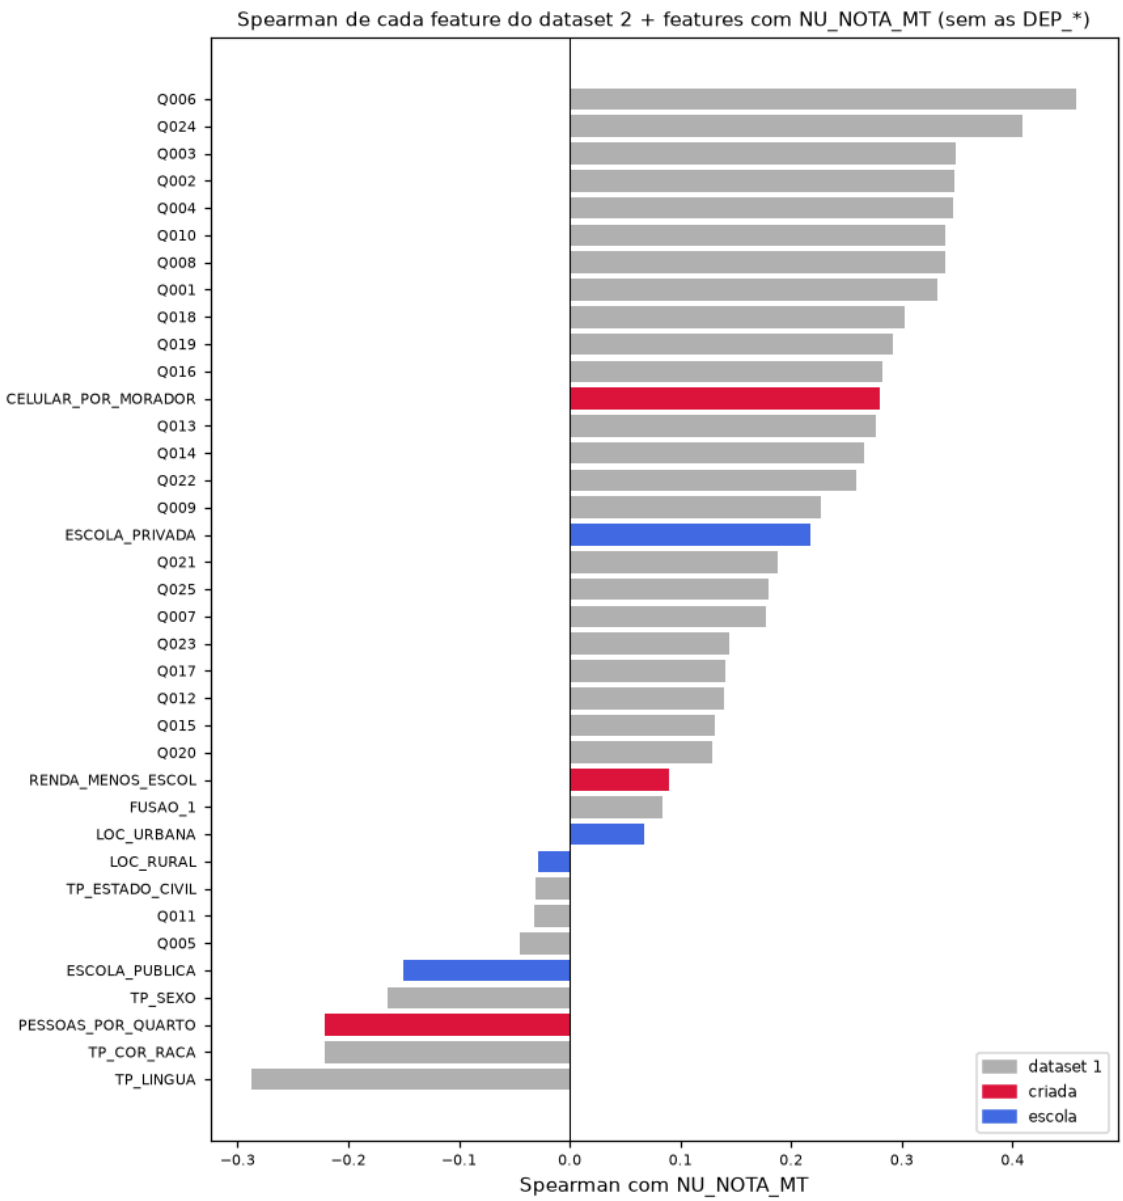


Figura A13. Dataset 2 + features final: Spearman de cada feature com a nota. Fonte: Inep, ENEM 2023.

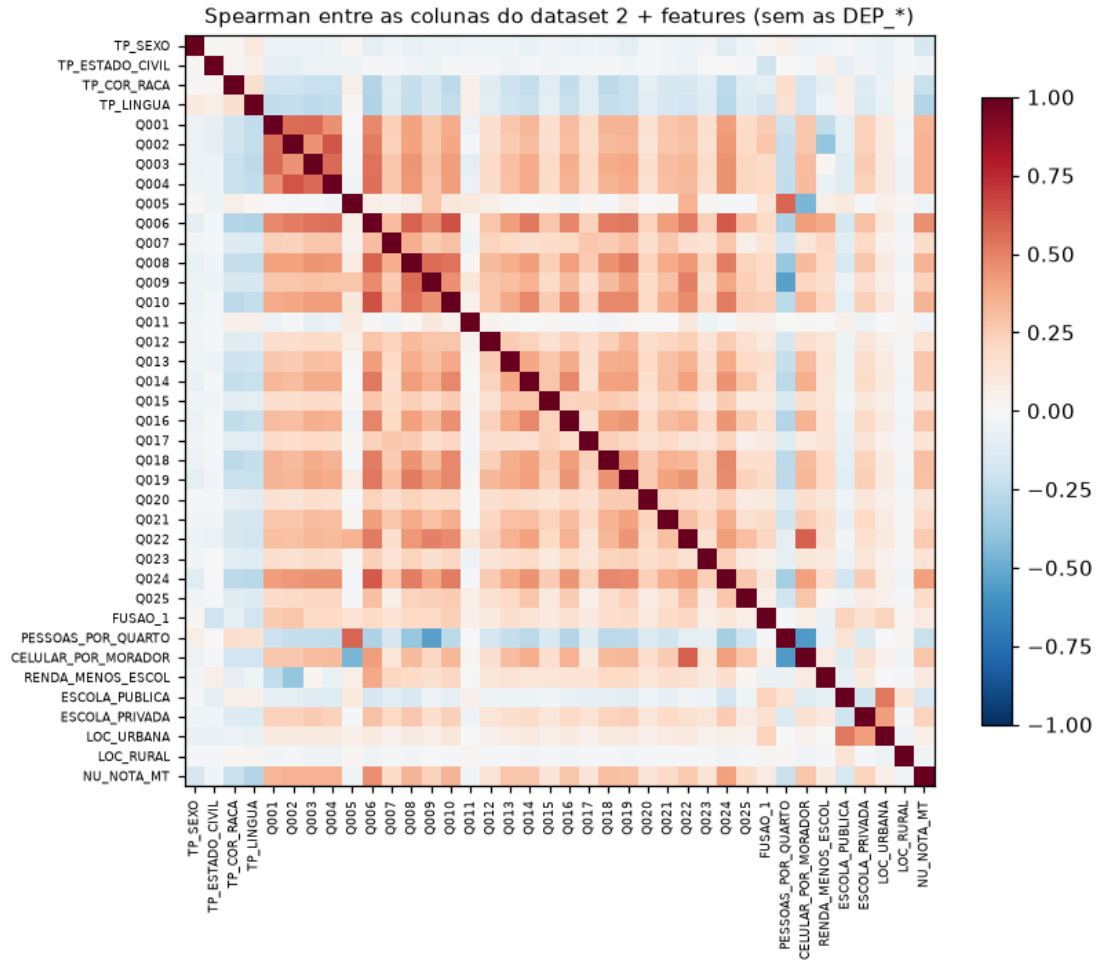


Figura A14. Dataset 2 + features final: matriz de Spearman. Fonte: Inep, ENEM 2023.

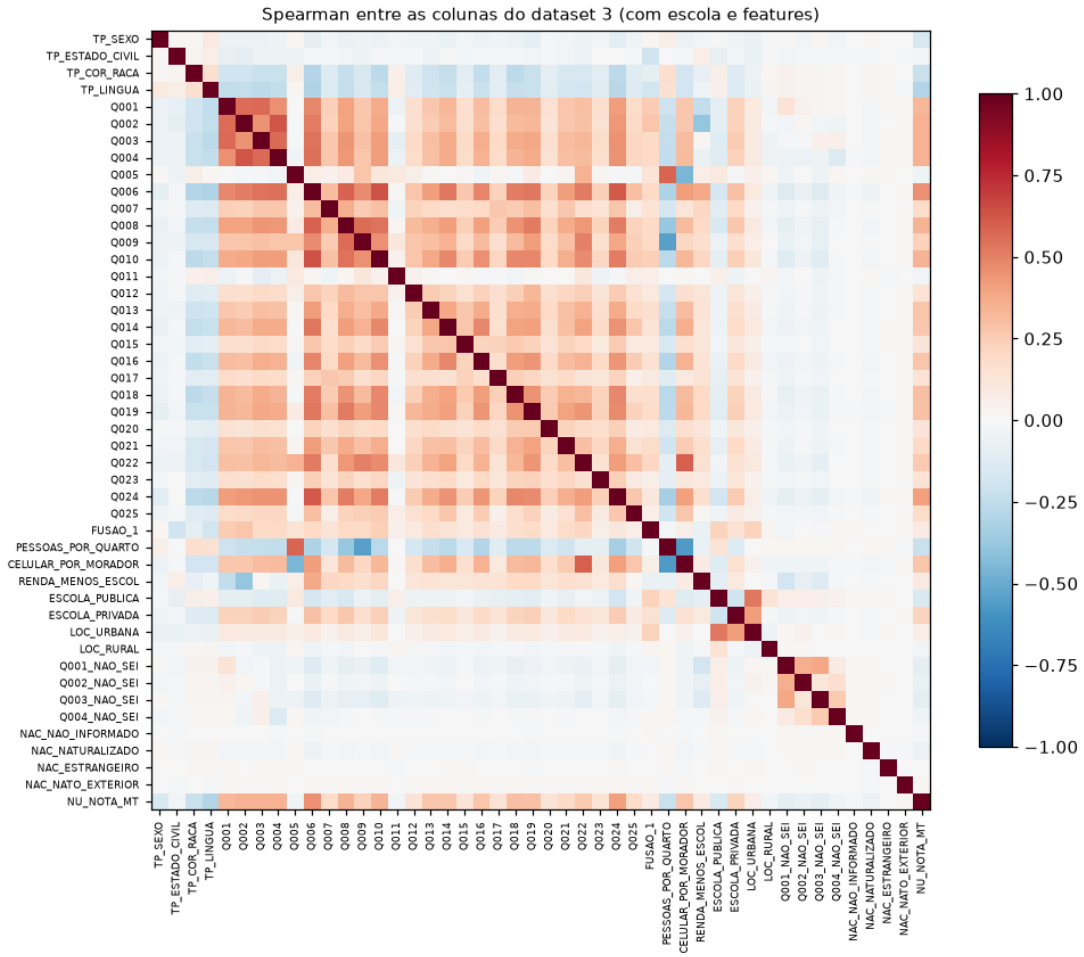


Figura A15. Dataset 3 (maior tabela): matriz de Spearman. Fonte: Inep, ENEM 2023.

A.2 Notebook 02: modelos em configuração inicial (gráficos que não estão no corpo)

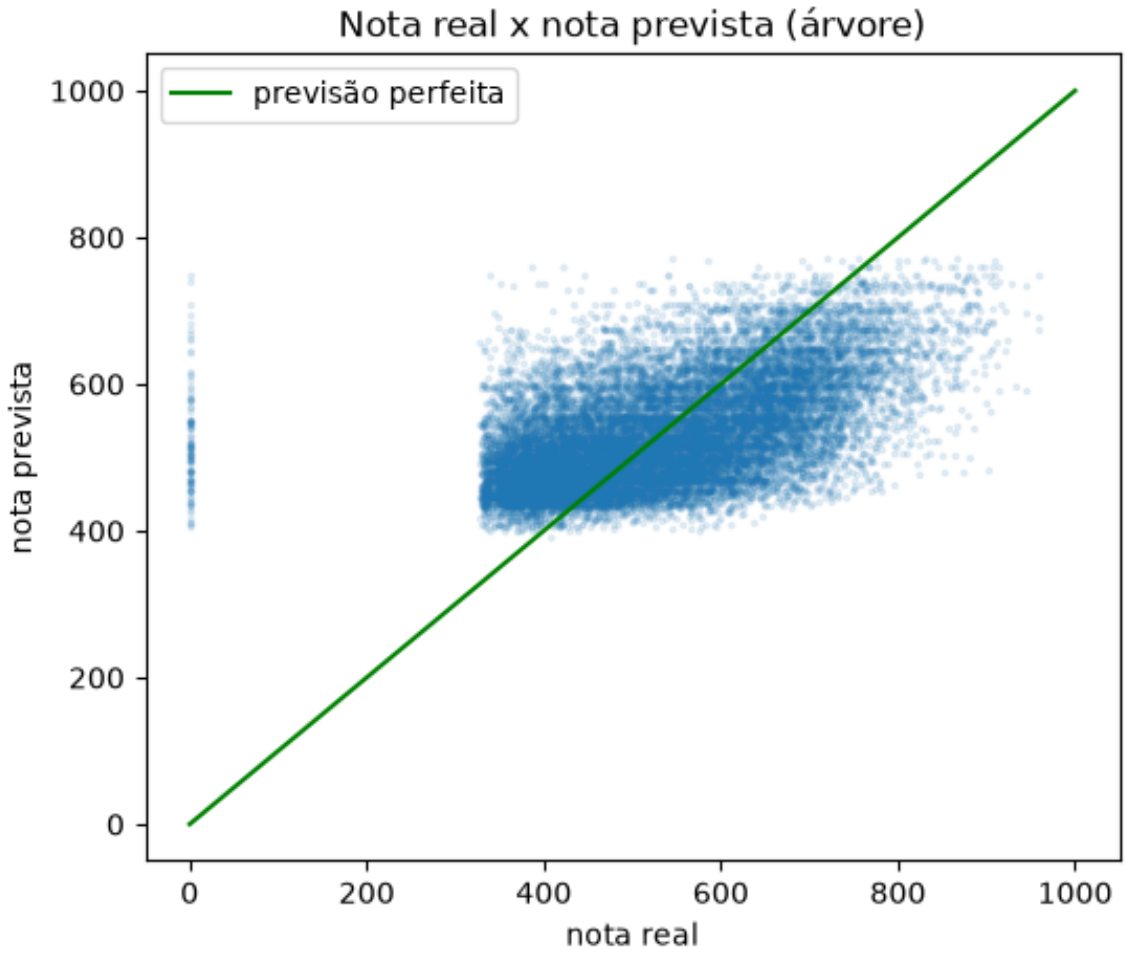


Figura A16. Árvore de decisão: nota real × nota prevista (faixas horizontais, uma por folha). Fonte: Inep, ENEM 2023.

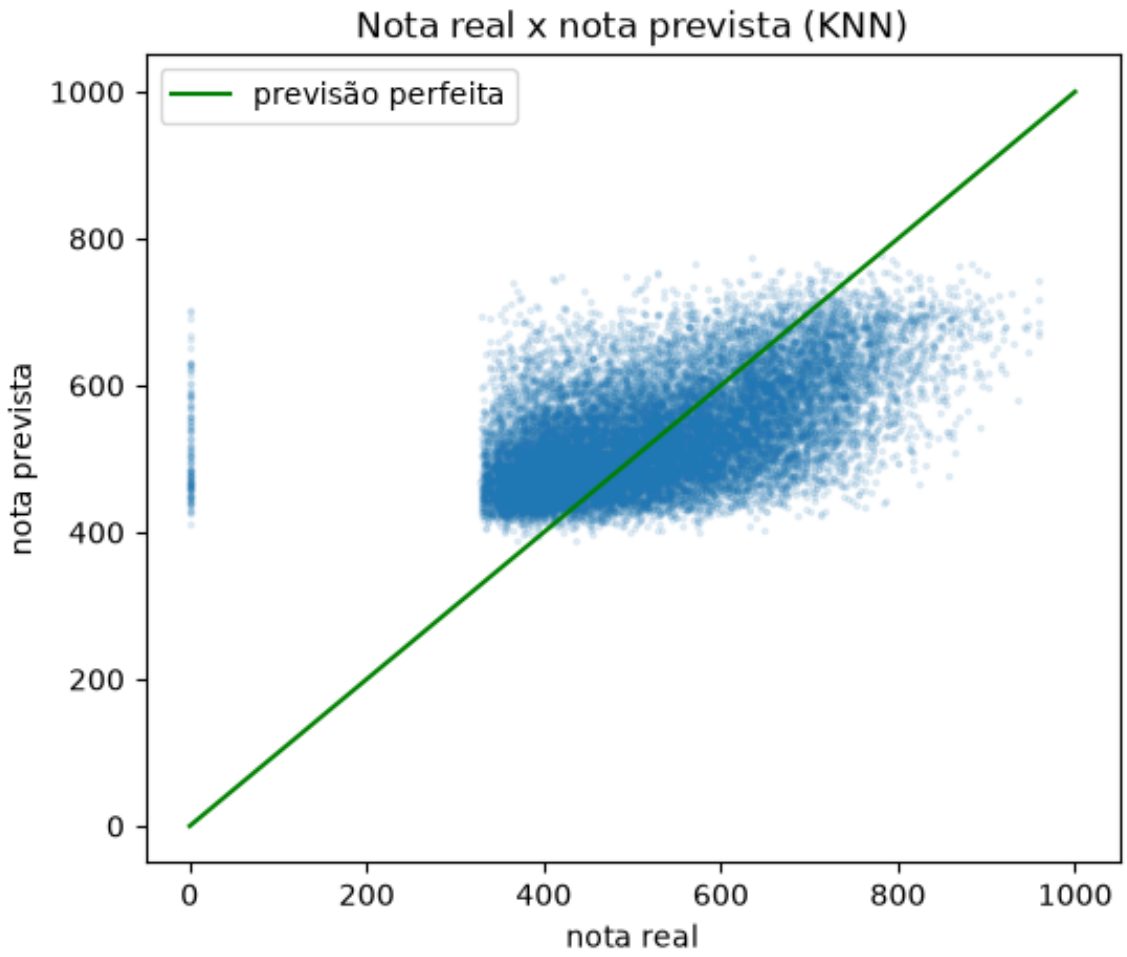


Figura A17. KNN: nota real × nota prevista. Fonte: Inep, ENEM 2023.

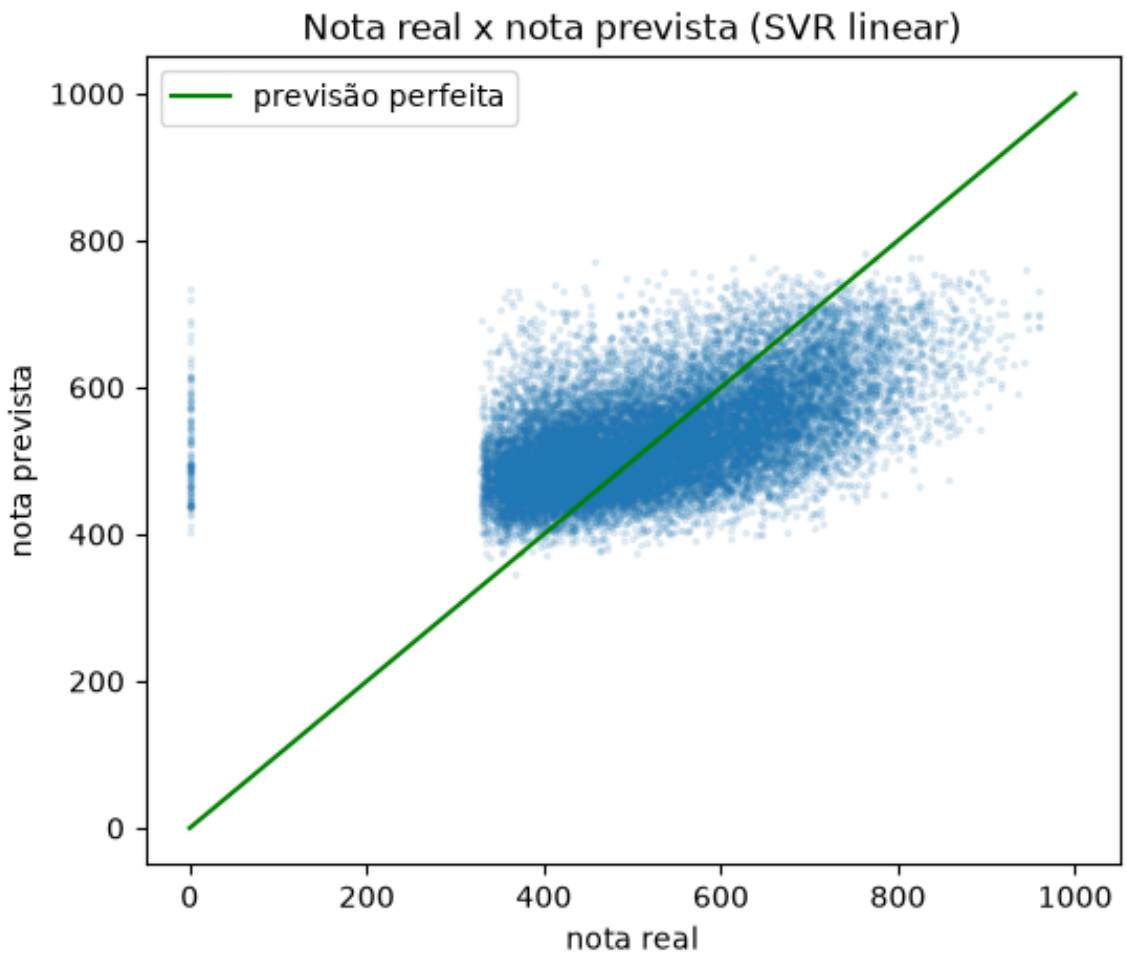


Figura A18. SVR linear: nota real × nota prevista. Fonte: Inep, ENEM 2023.

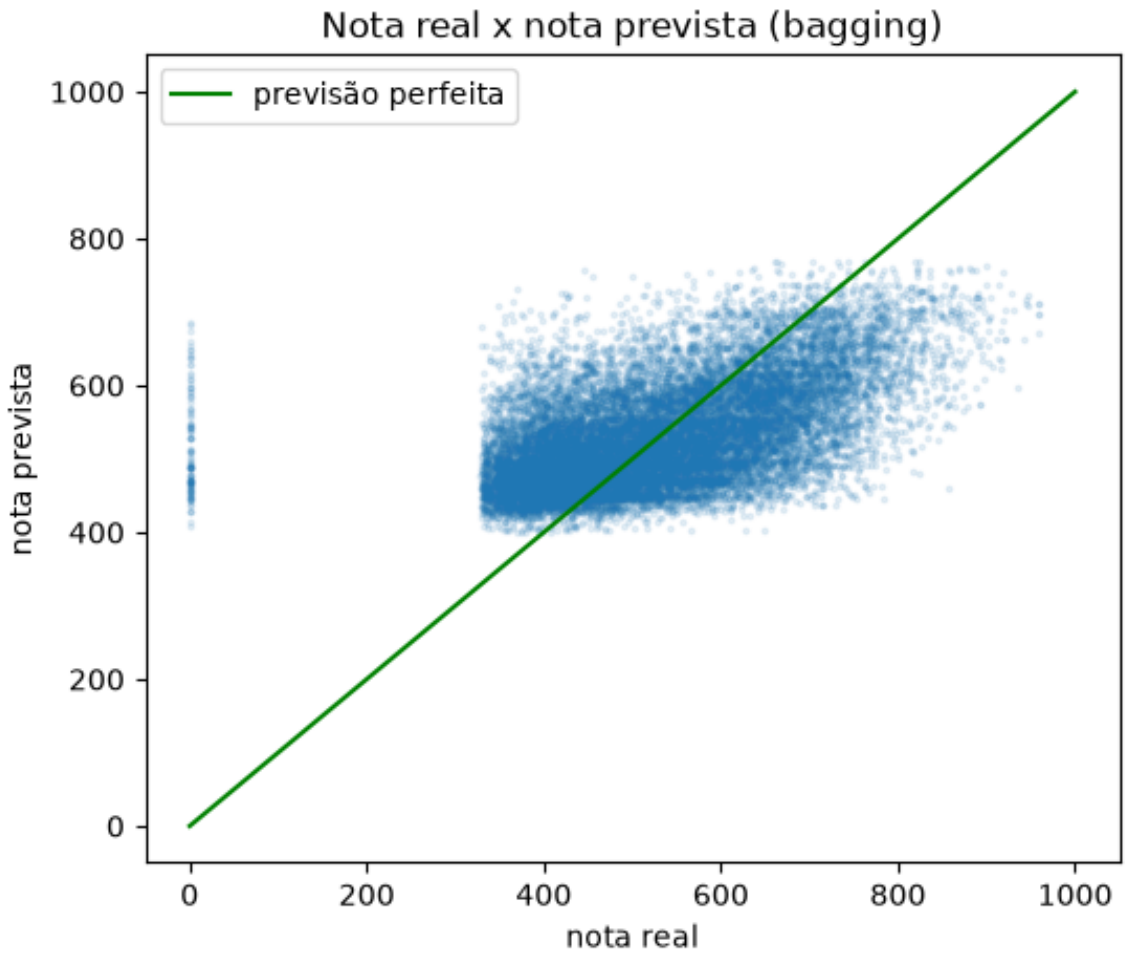


Figura A19. Bagging: nota real × nota prevista. Fonte: Inep, ENEM 2023.

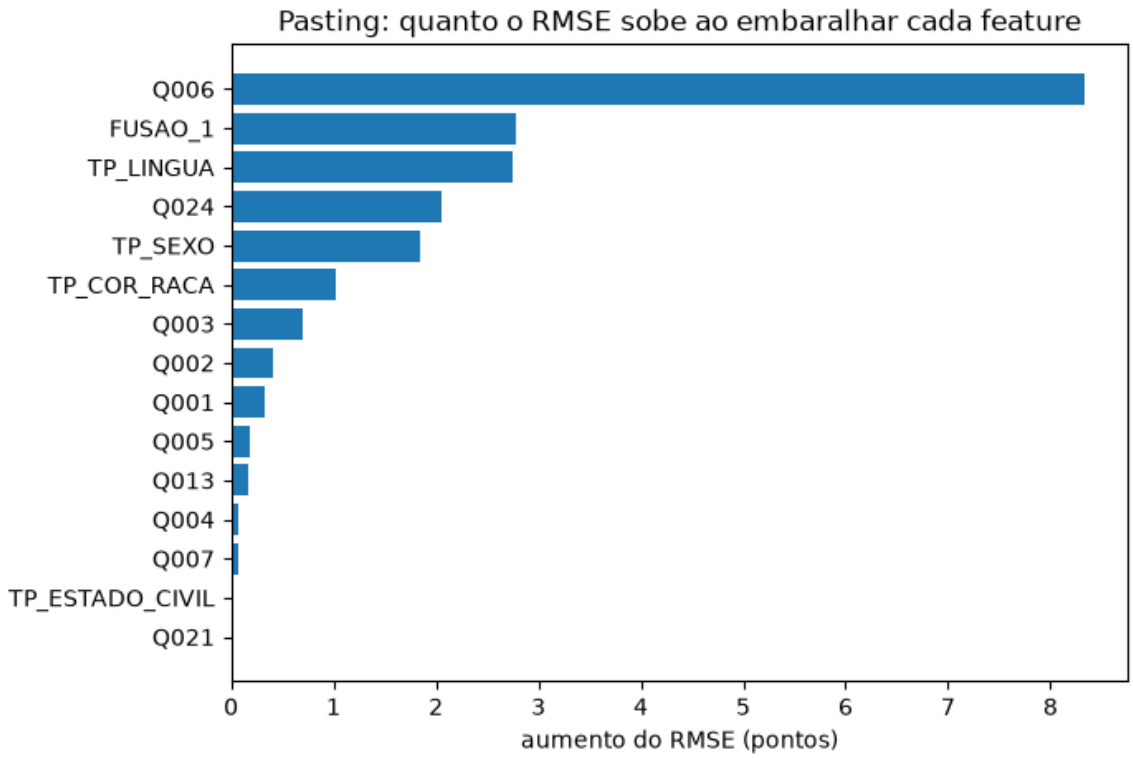


Figura A20. Pasting: importância por permutação. Fonte: Inep, ENEM 2023.

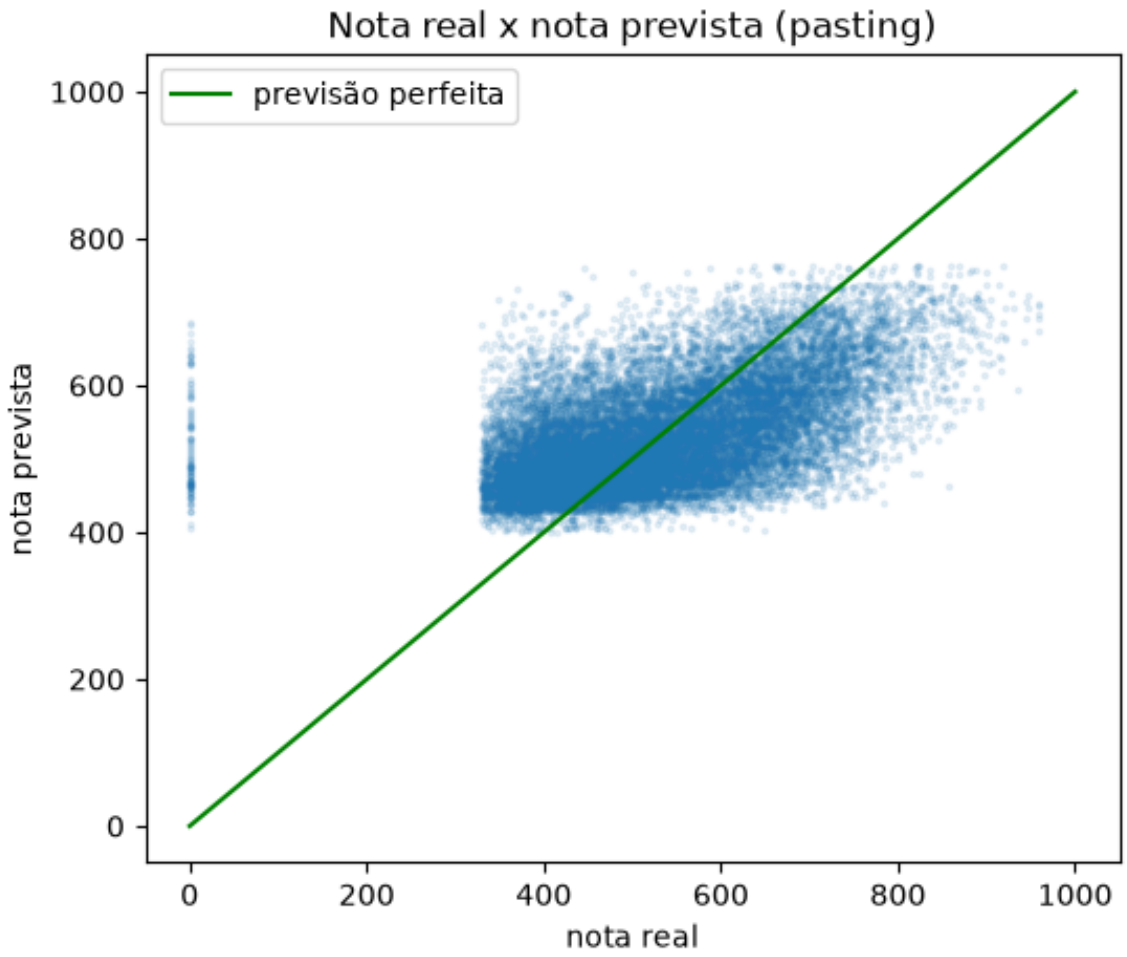


Figura A21. Pasting: nota real × nota prevista. Fonte: Inep, ENEM 2023.

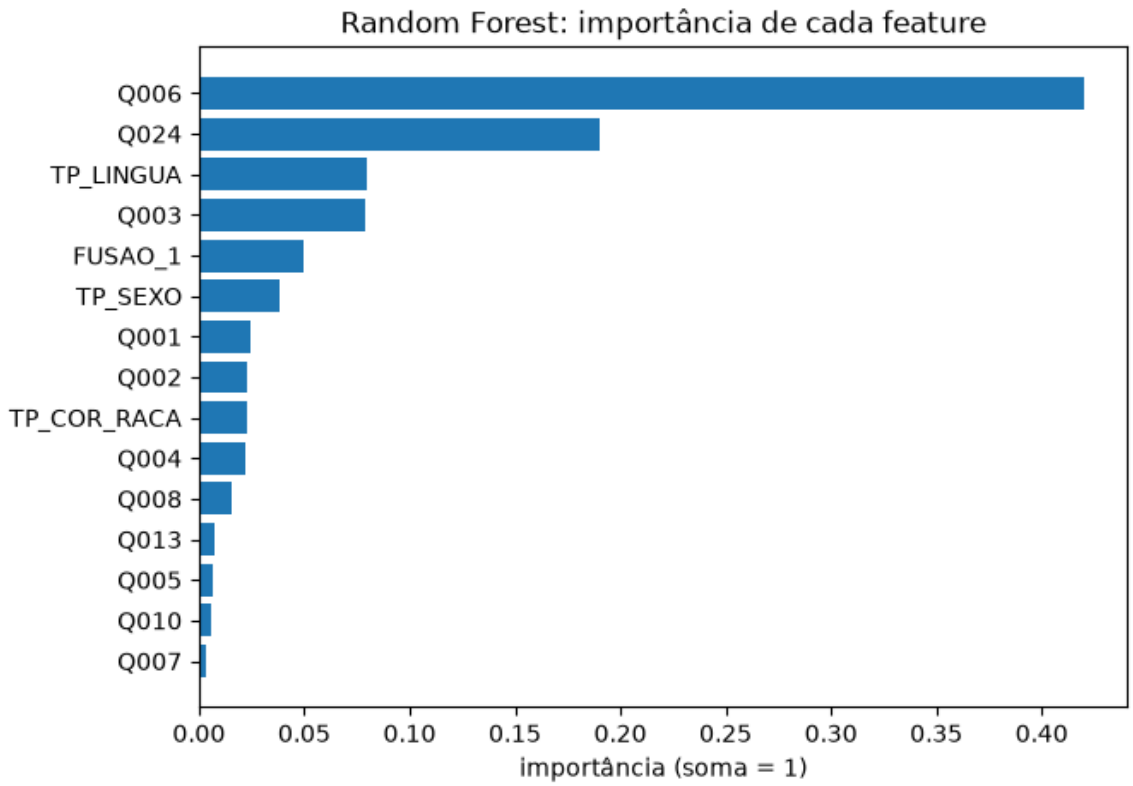


Figura A22. Random Forest: importância nativa (soma = 1). Fonte: Inep, ENEM 2023.

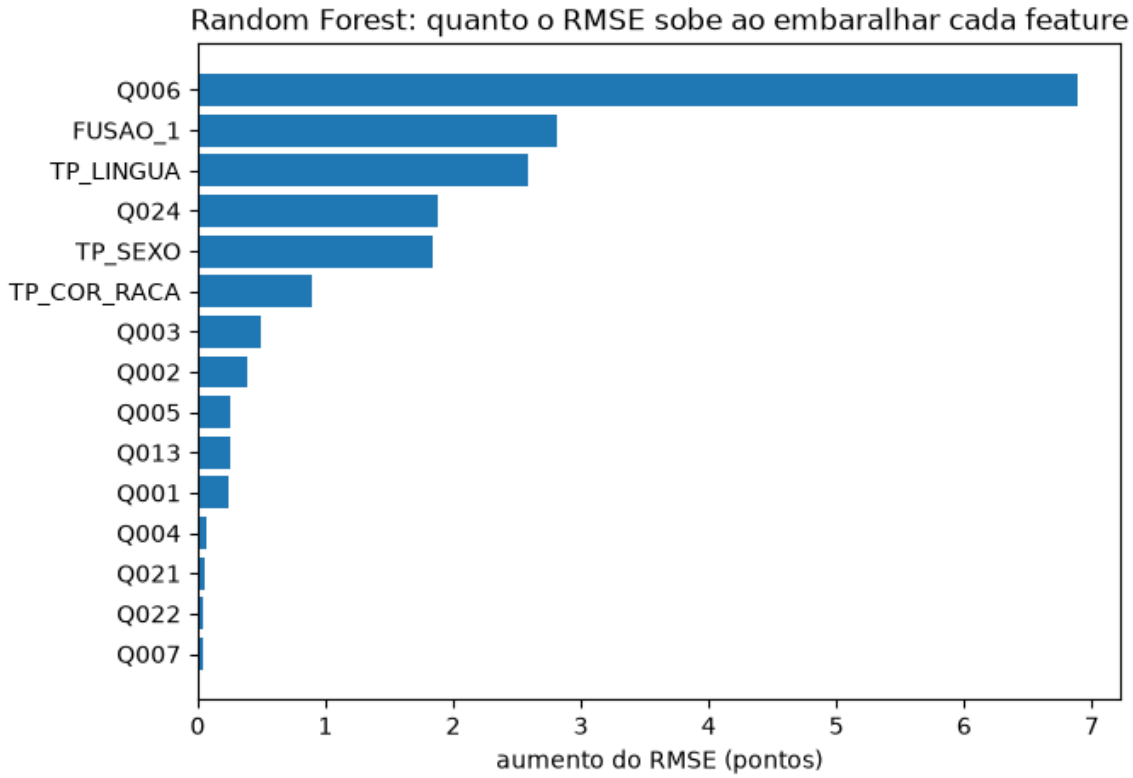


Figura A23. Random Forest: importância por permutação. Fonte: Inep, ENEM 2023.

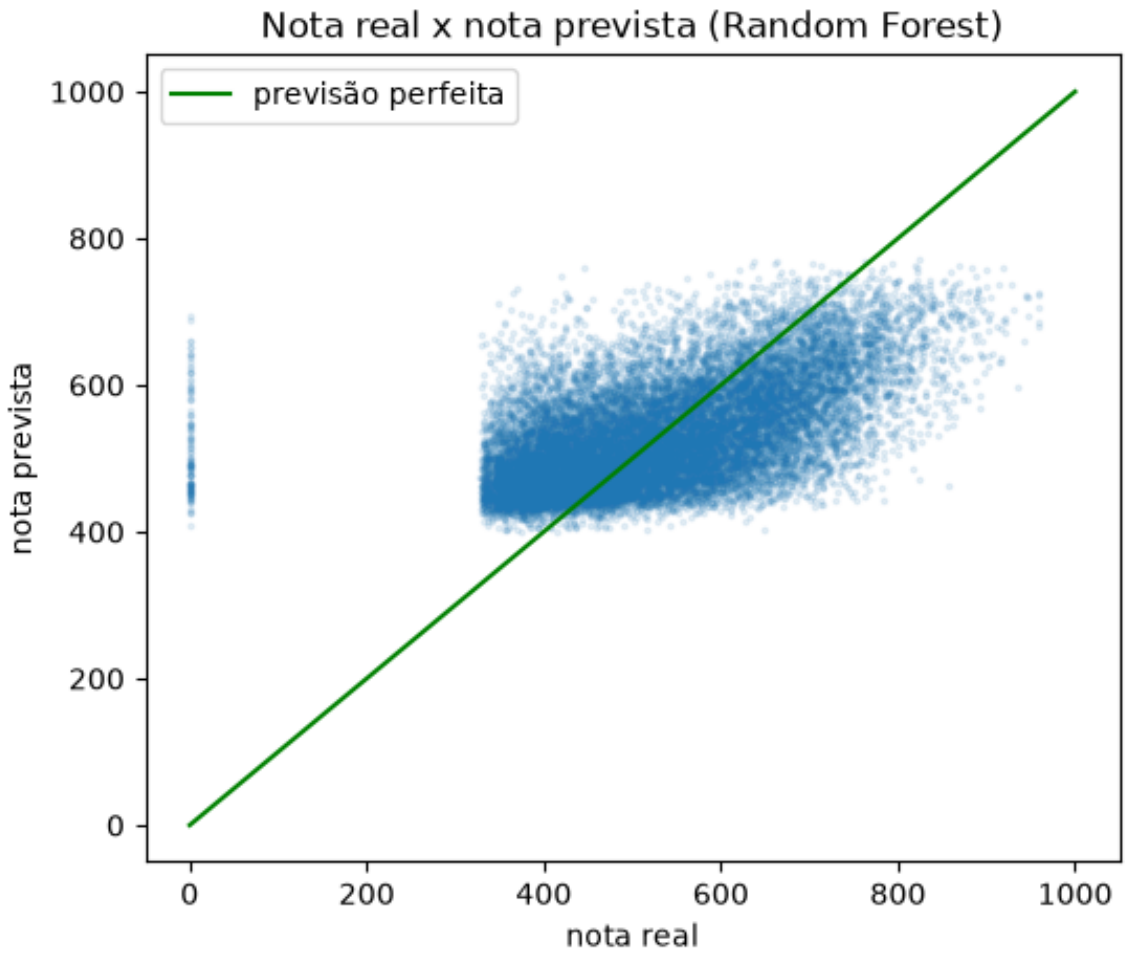


Figura A24. Random Forest: nota real × nota prevista. Fonte: Inep, ENEM 2023.

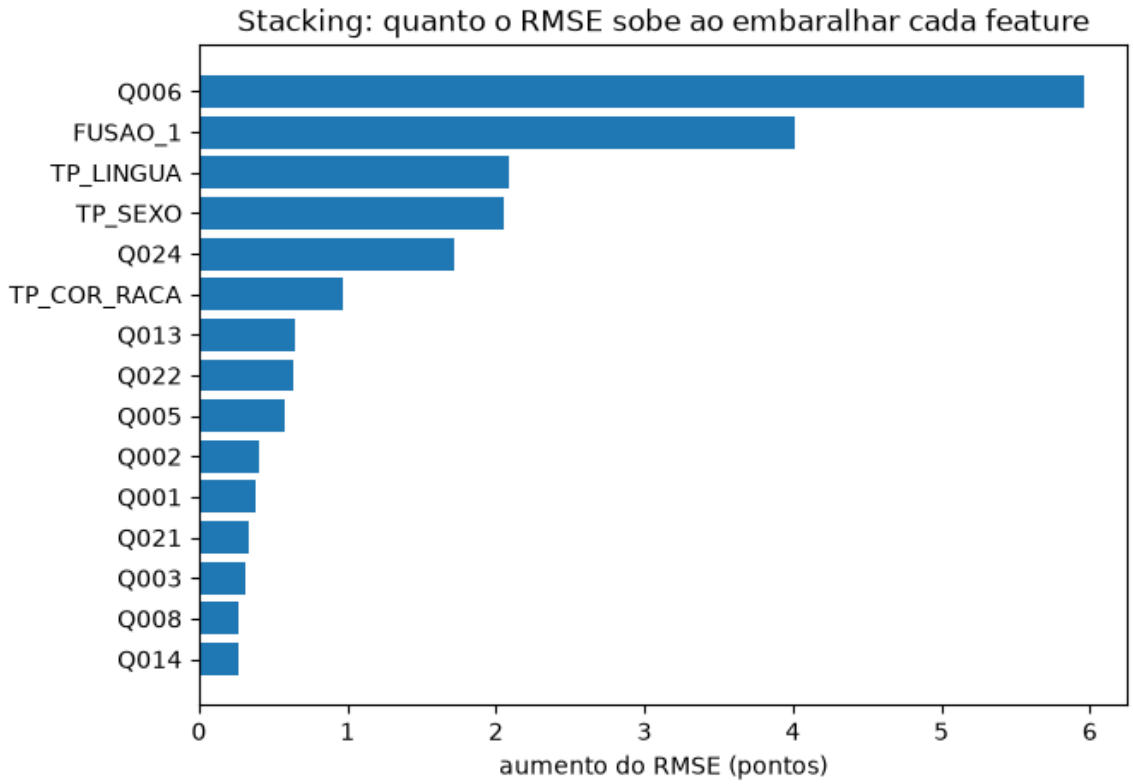


Figura A25. Stacking: importância por permutação. Fonte: Inep, ENEM 2023.

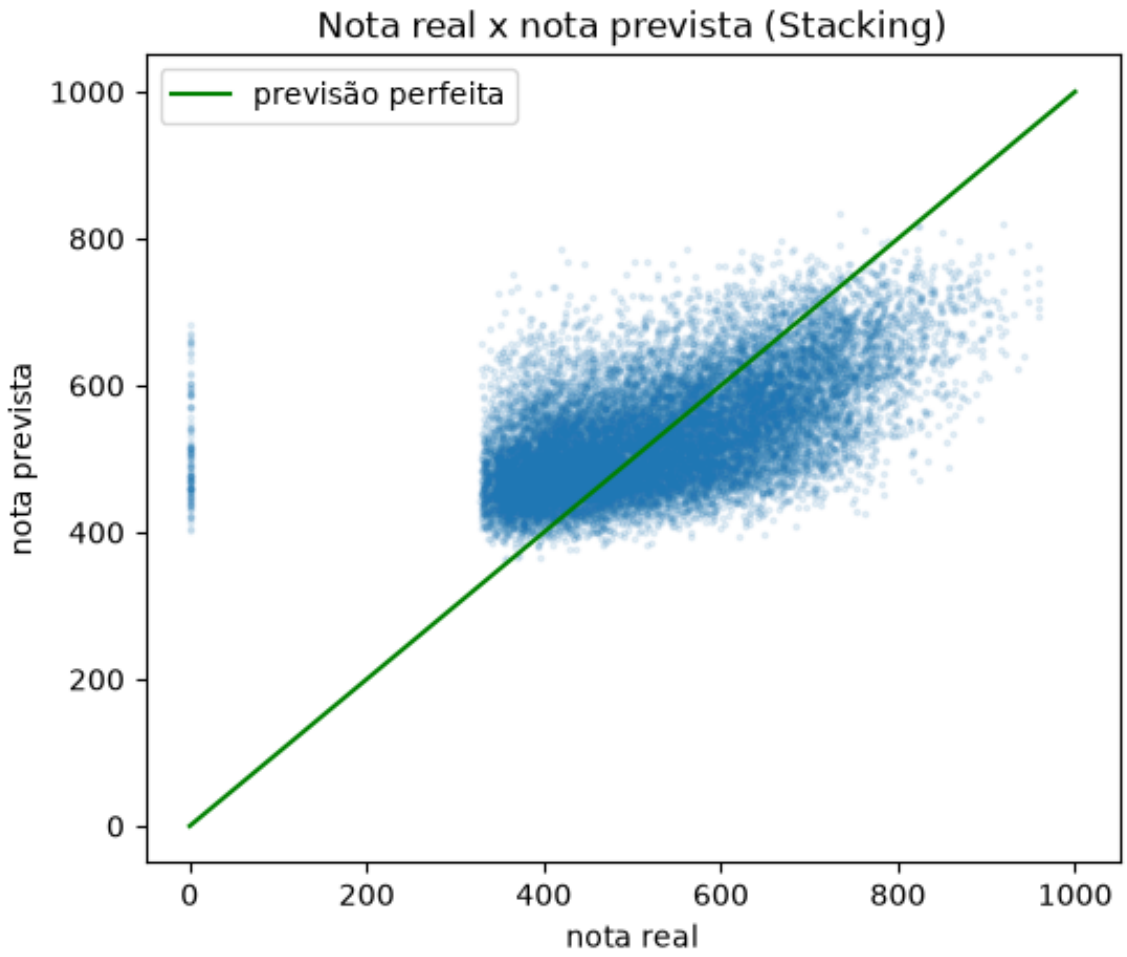


Figura A26. Stacking: nota real × nota prevista. Fonte: Inep, ENEM 2023.

A.3 Notebook 02 otimizado: modelos depois da busca de hiperparâmetros

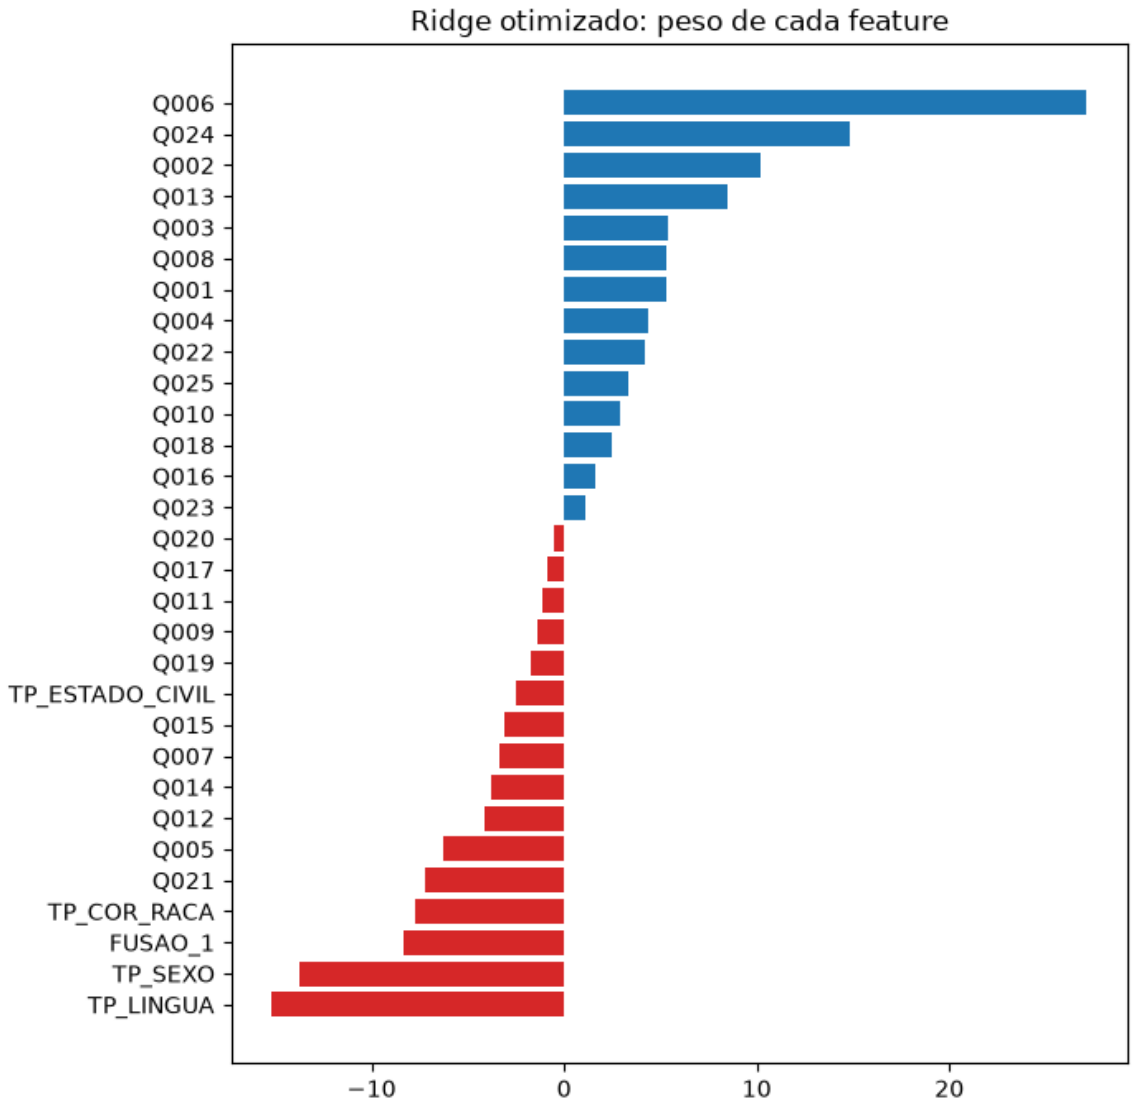


Figura A27. Ridge otimizado: peso de cada feature. Fonte: Inep, ENEM 2023.

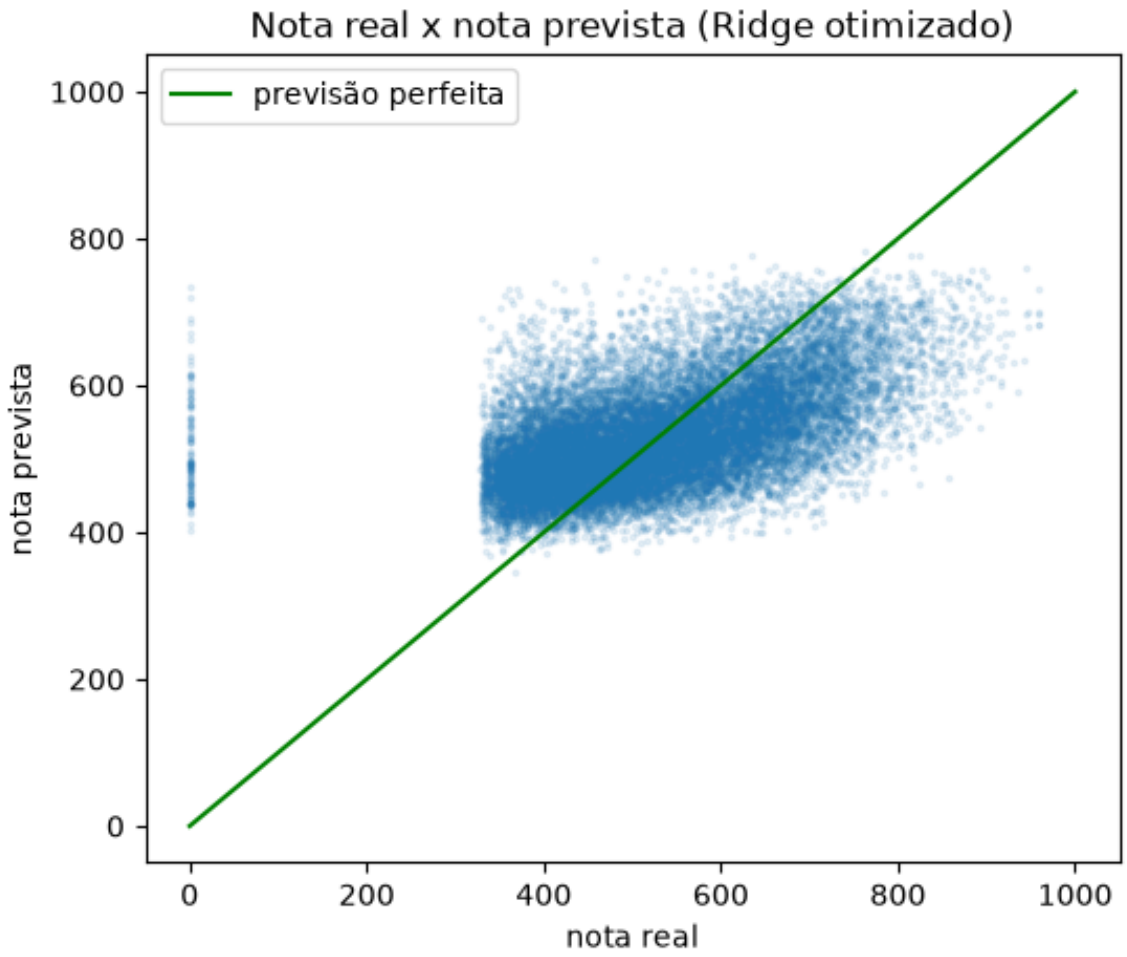


Figura A28. Ridge otimizado: nota real × nota prevista. Fonte: Inep, ENEM 2023.

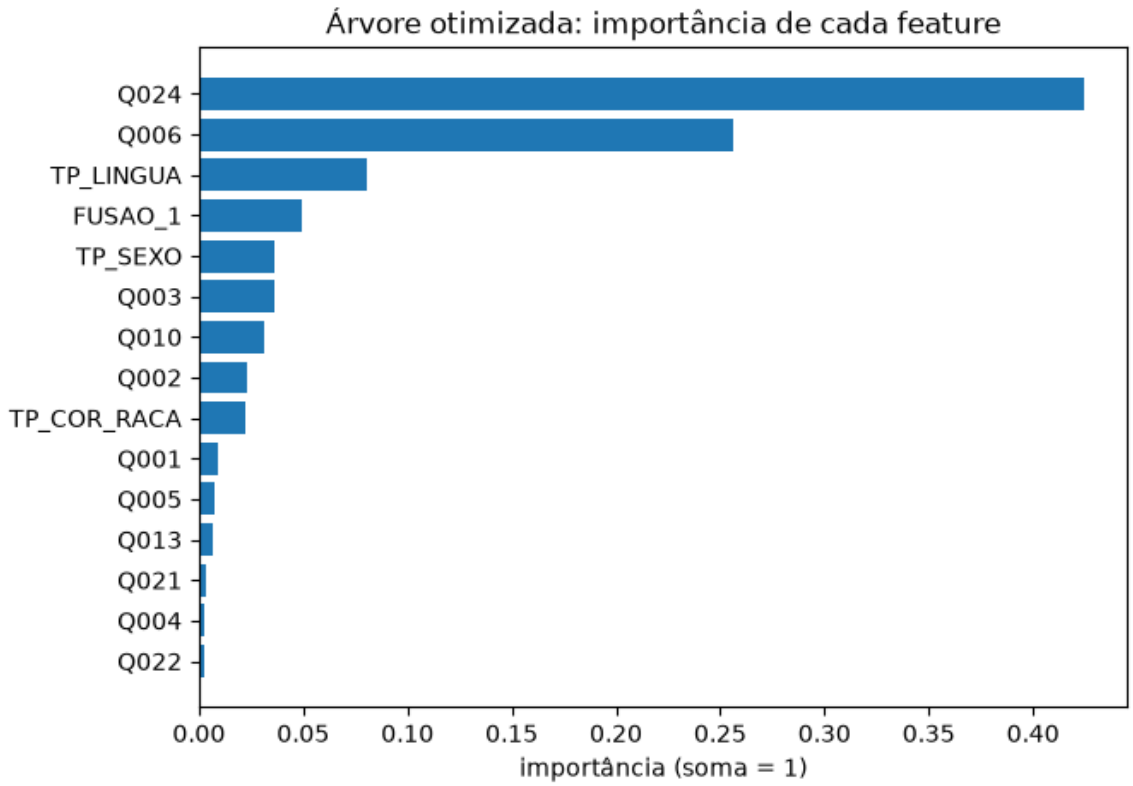


Figura A29. Árvore de decisão otimizada: importância de cada feature. Fonte: Inep, ENEM 2023.

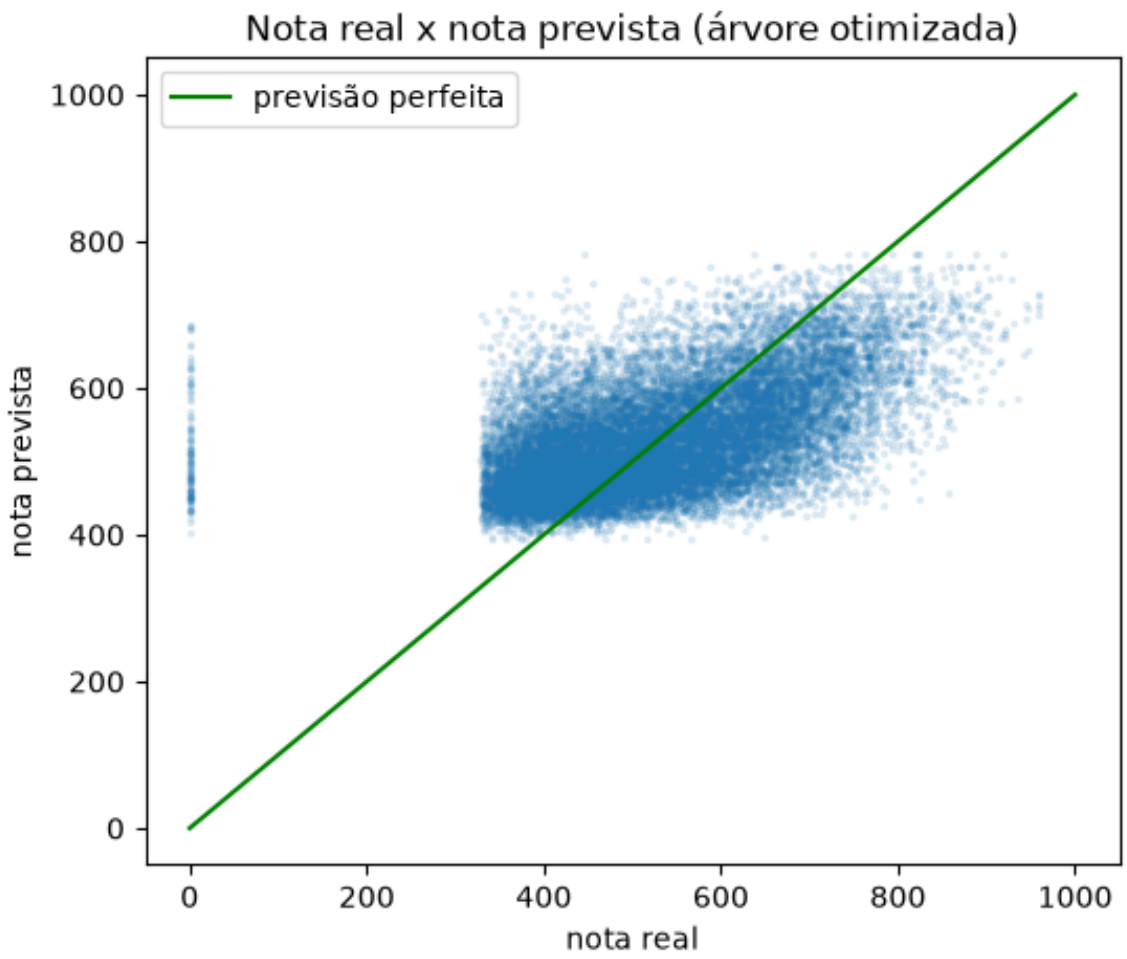


Figura A30. Árvore de decisão otimizada: nota real × nota prevista. Fonte: Inep, ENEM 2023.

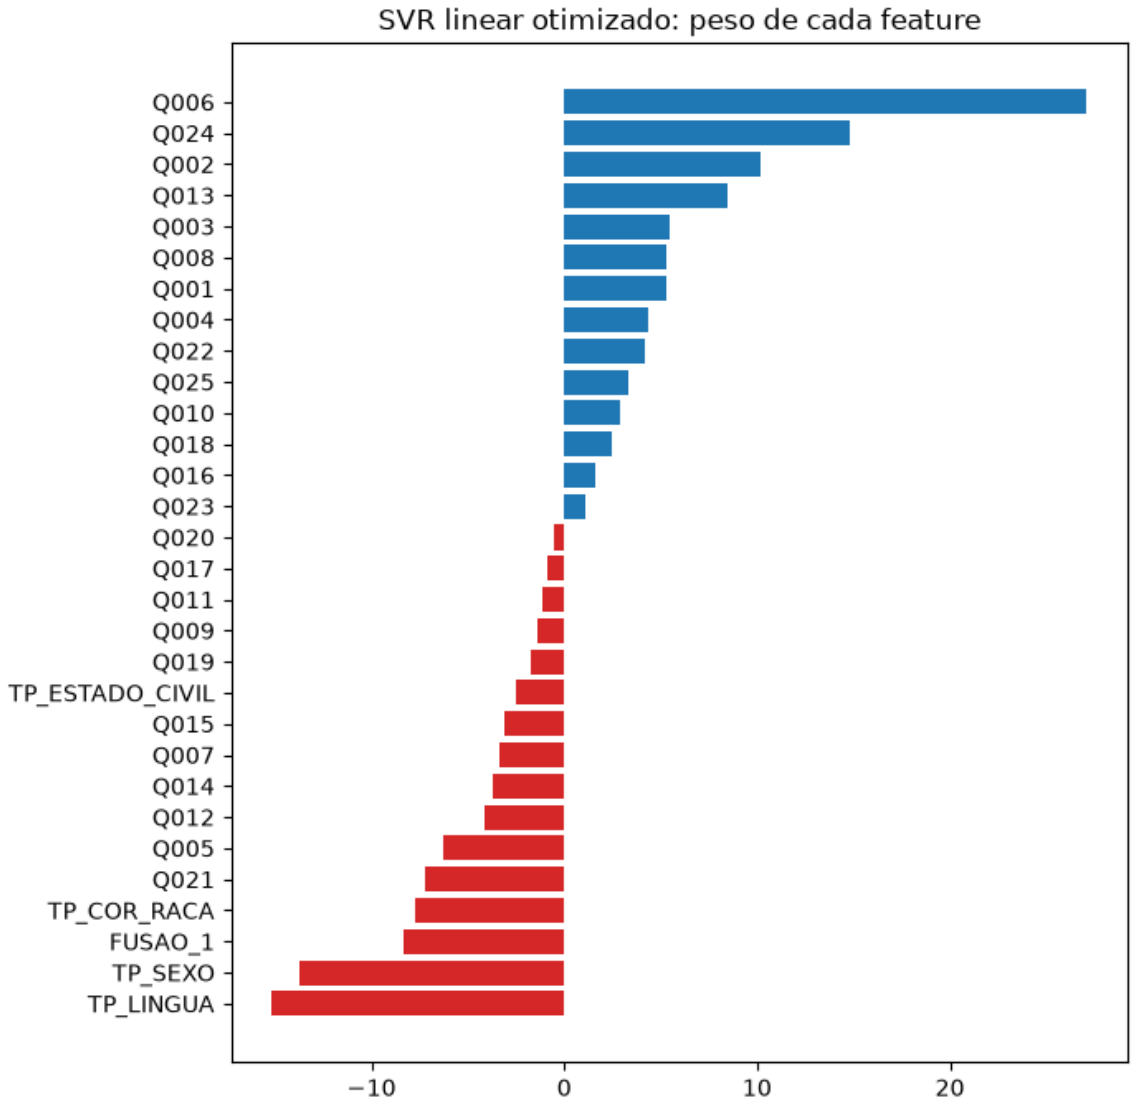


Figura A31. SVR linear otimizado: peso de cada feature. Fonte: Inep, ENEM 2023.

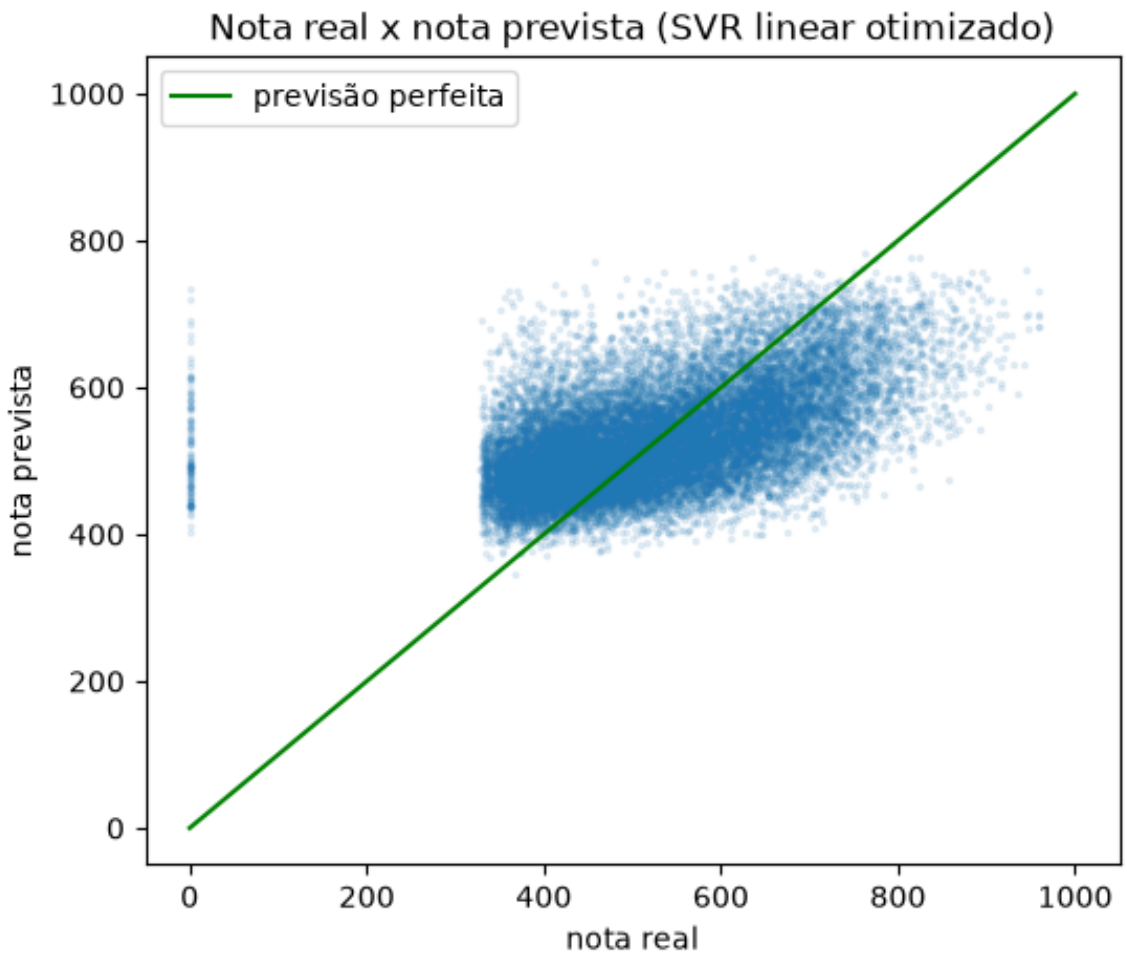


Figura A32. SVR linear otimizado: nota real × nota prevista. Fonte: Inep, ENEM 2023.

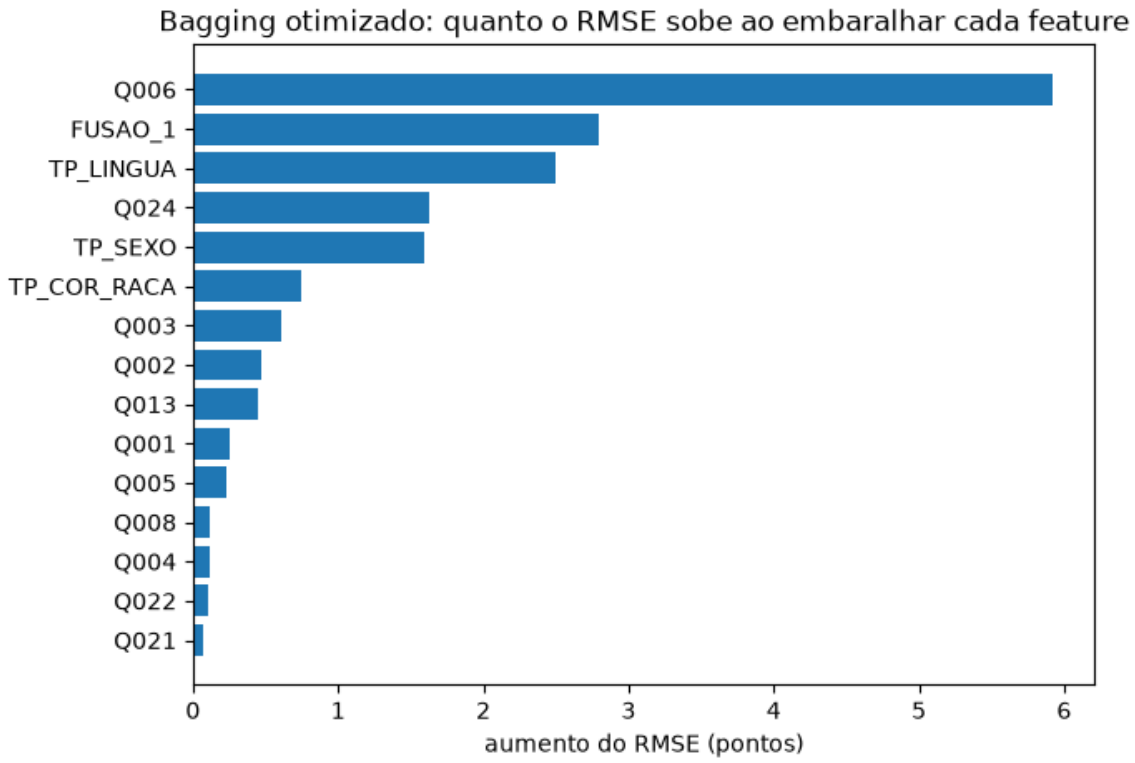


Figura A33. Bagging otimizado: importância por permutação. Fonte: Inep, ENEM 2023.

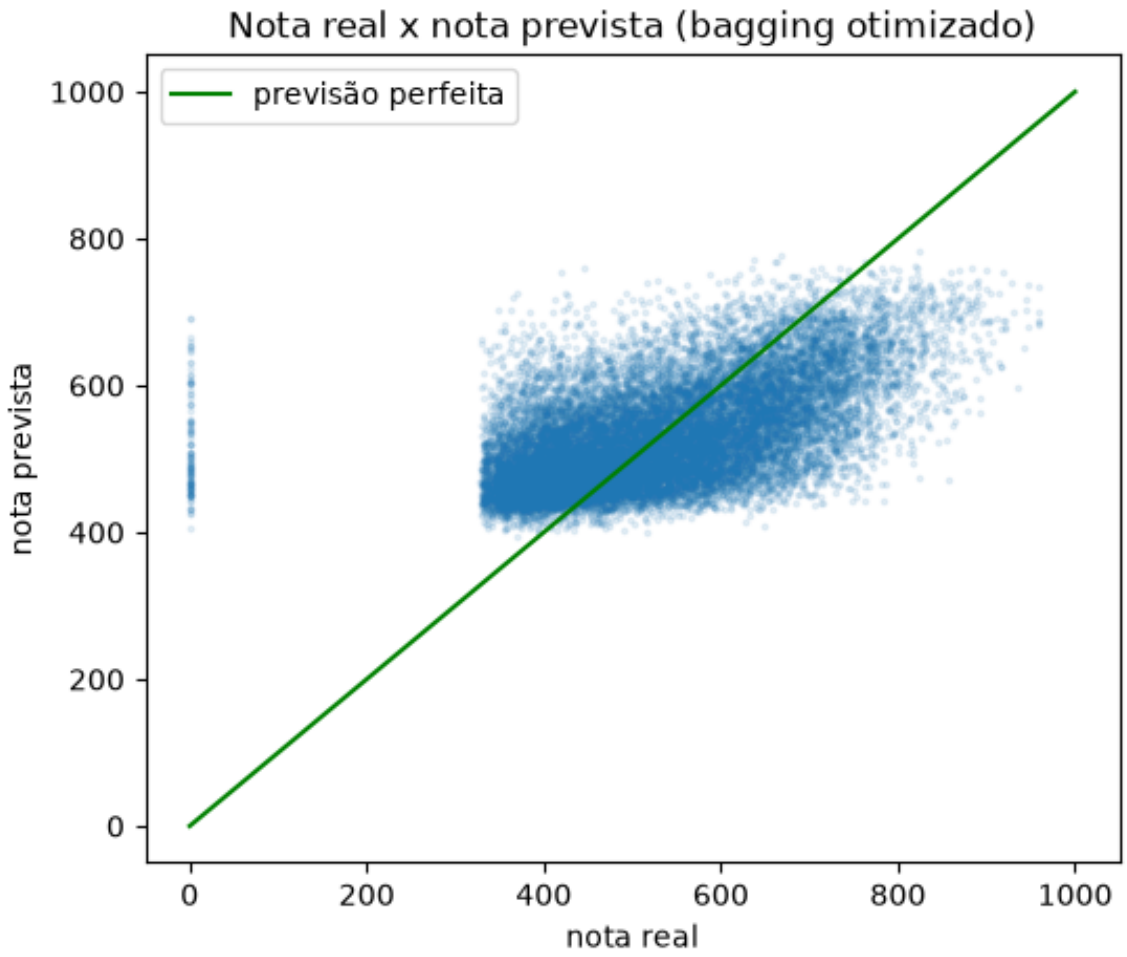


Figura A34. Bagging otimizado: nota real × nota prevista. Fonte: Inep, ENEM 2023.

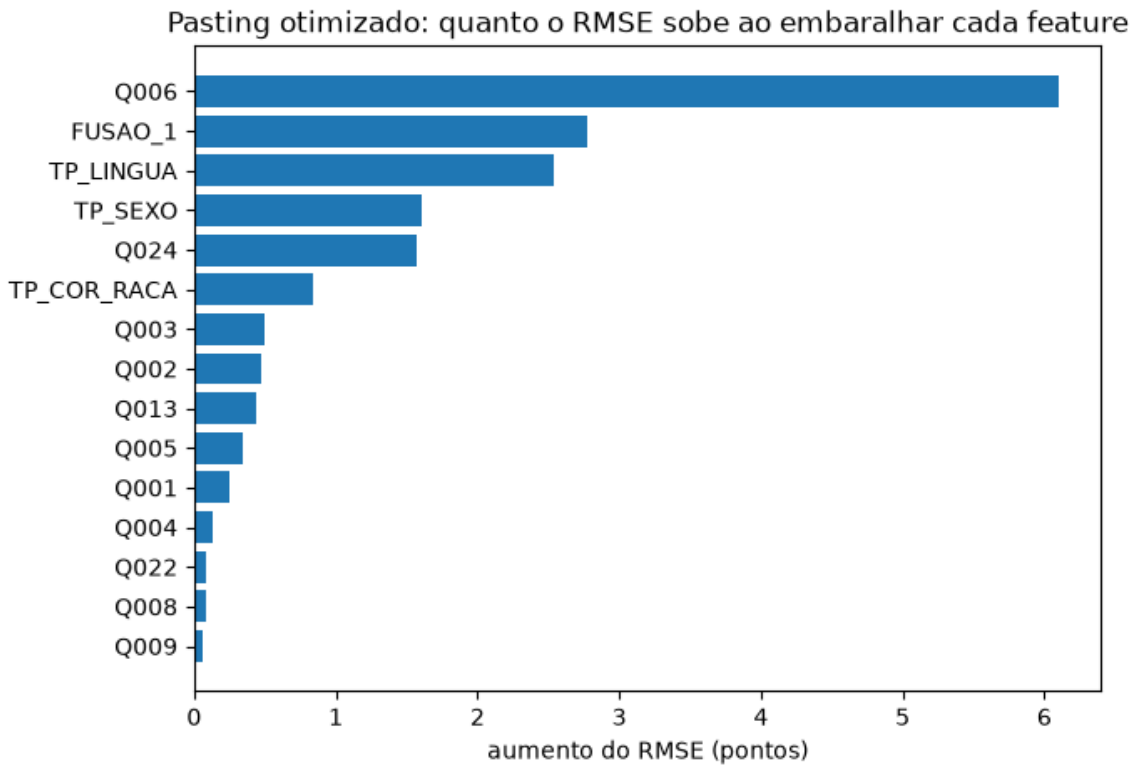


Figura A35. Pasting otimizado: importância por permutação. Fonte: Inep, ENEM 2023.

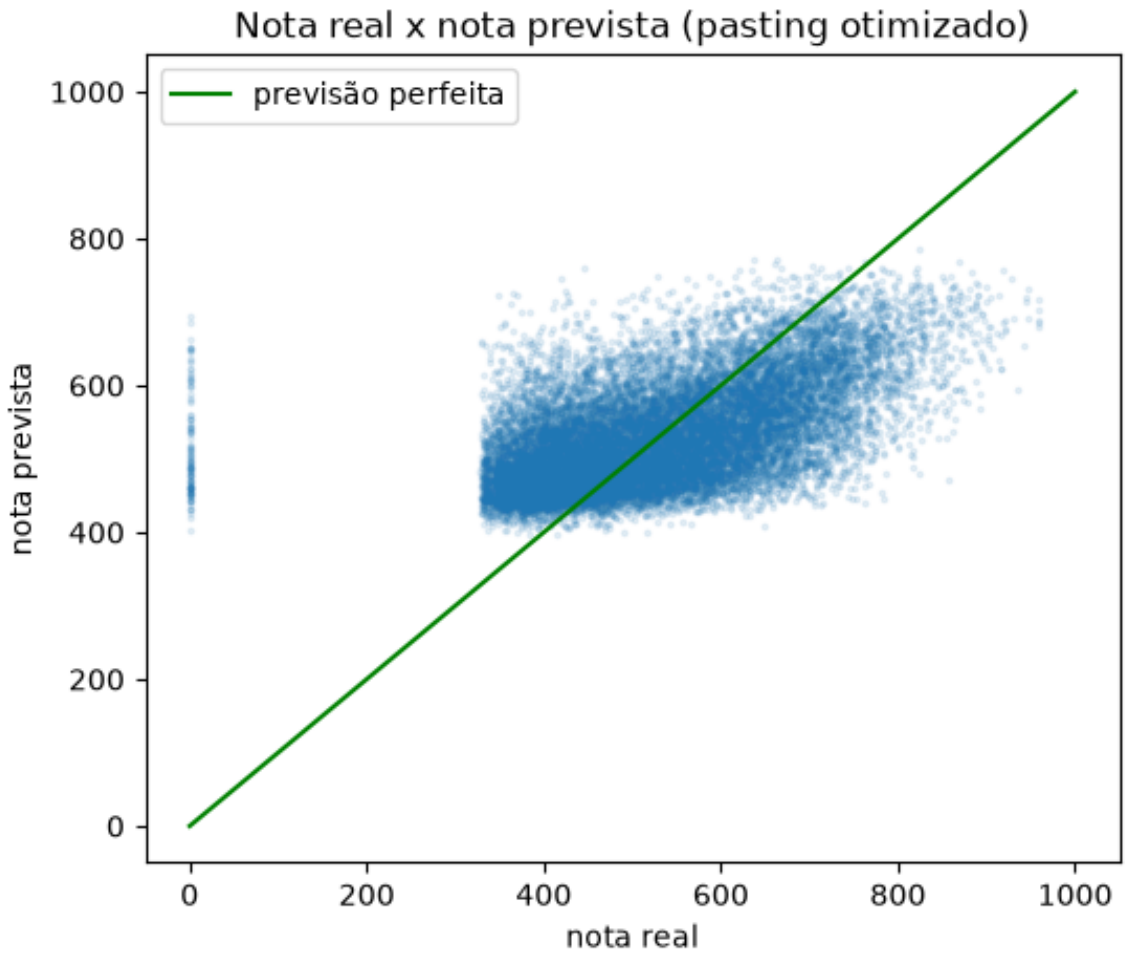


Figura A36. Pasting otimizado: nota real × nota prevista. Fonte: Inep, ENEM 2023.

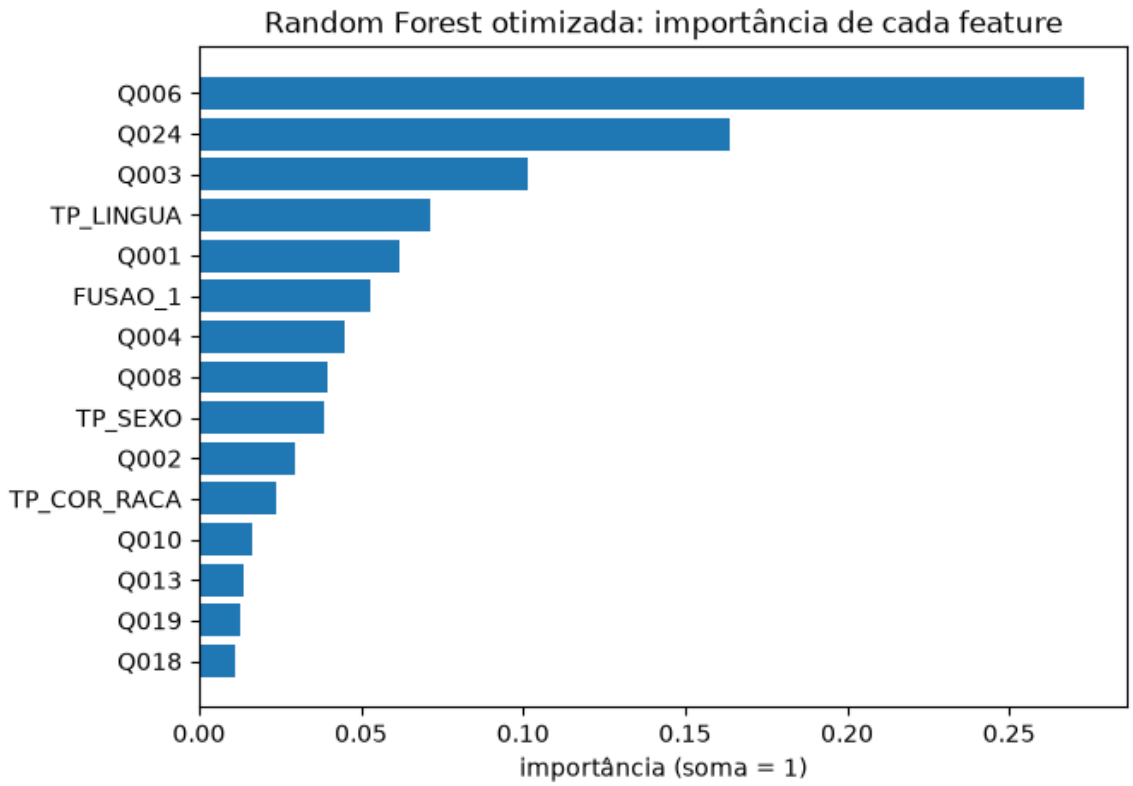


Figura A37. Random Forest otimizada: importância nativa. Fonte: Inep, ENEM 2023.

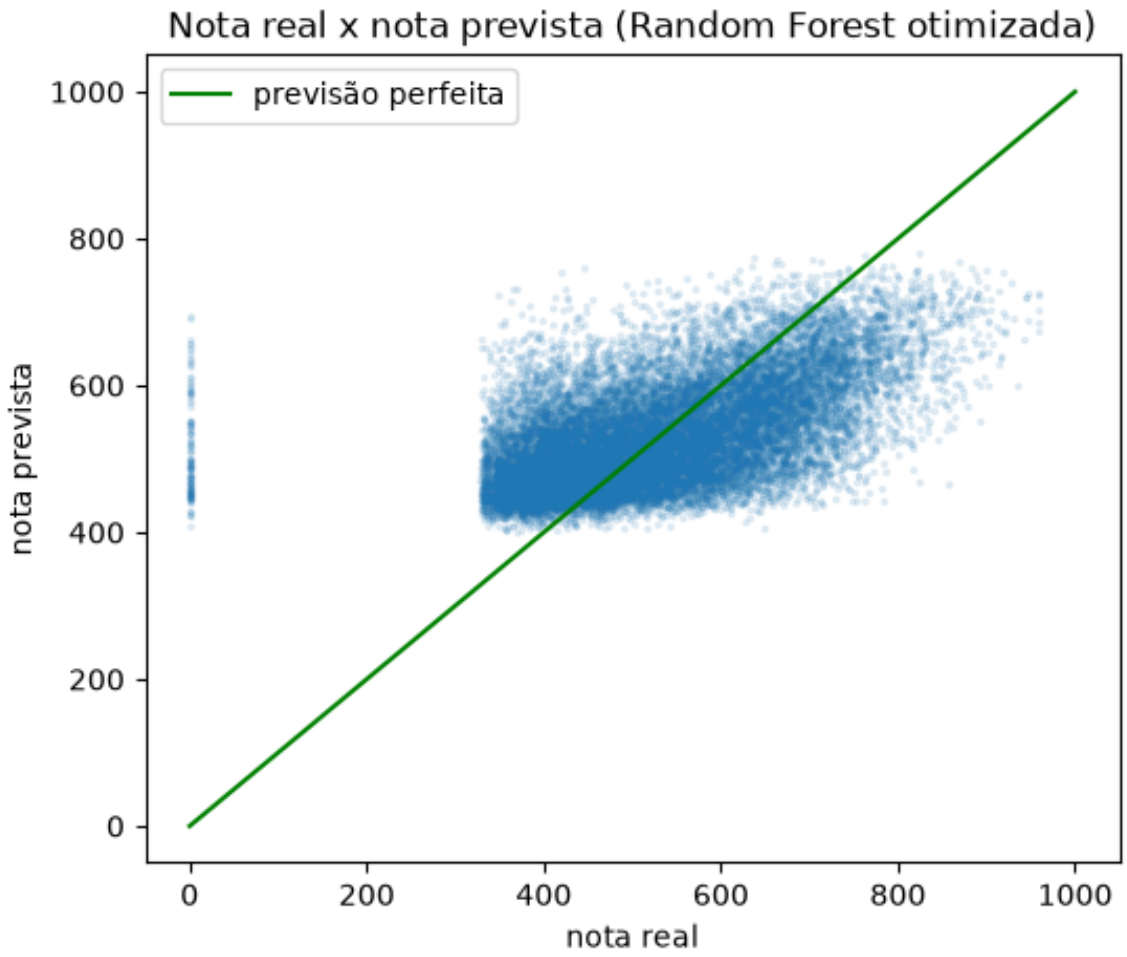


Figura A38. Random Forest otimizada: nota real × nota prevista. Fonte: Inep, ENEM 2023.

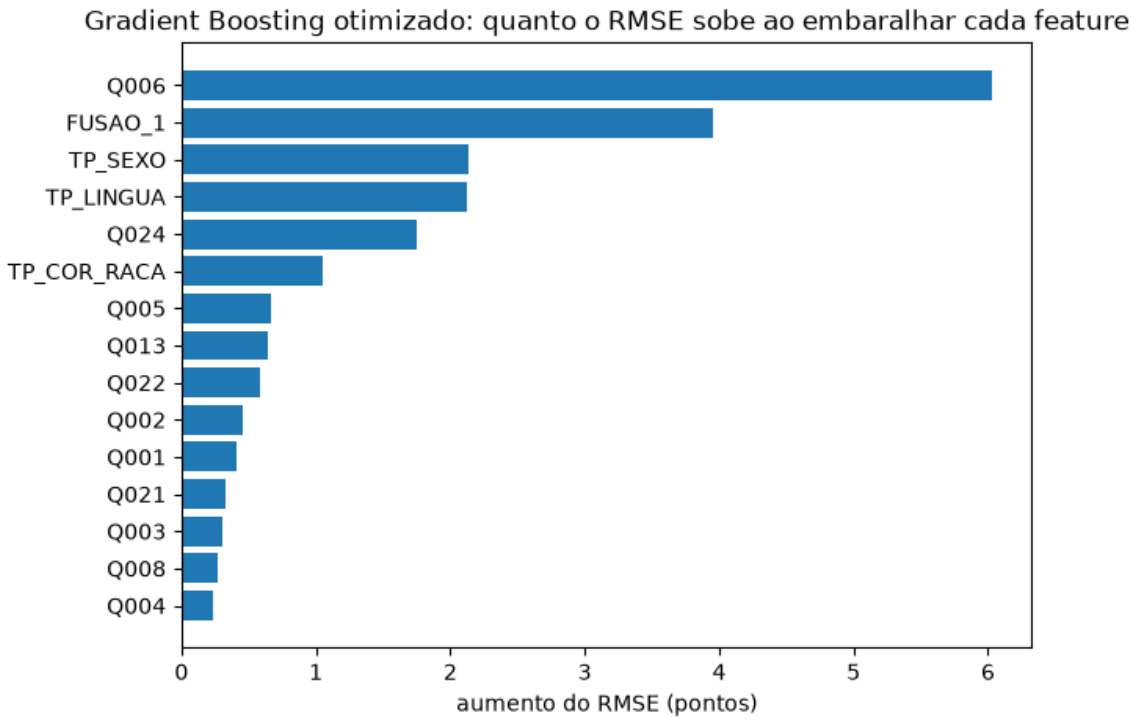


Figura A39. Gradient Boosting otimizado: importância por permutação. Fonte: Inep, ENEM 2023.

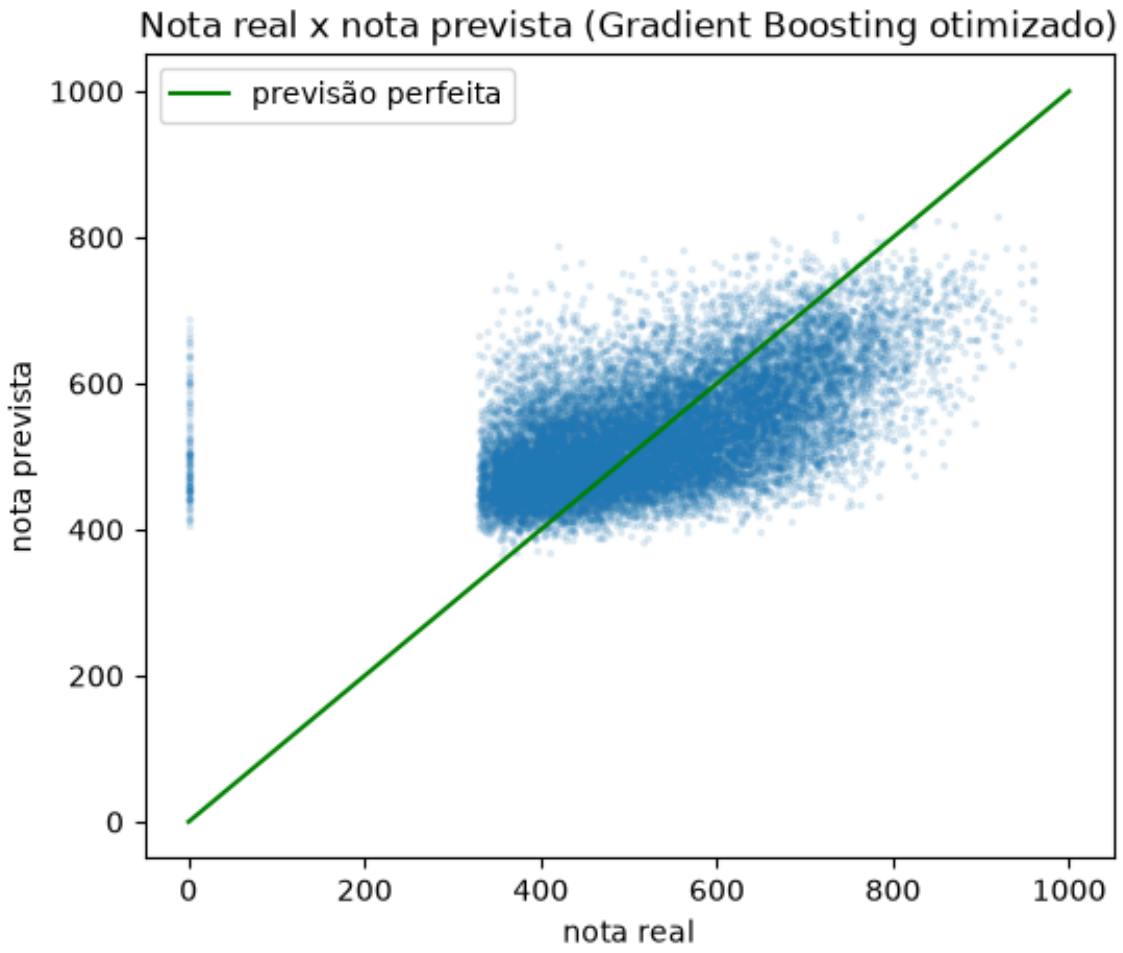


Figura A40. Gradient Boosting otimizado: nota real × nota prevista. Fonte: Inep, ENEM 2023.

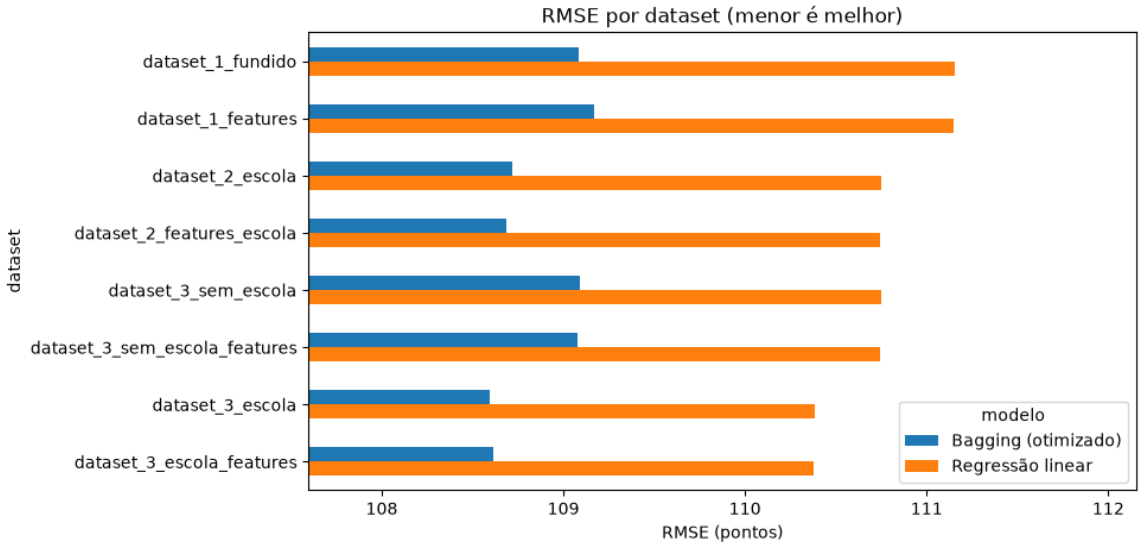


Figura A41. RMSE por dataset: regressão linear e bagging otimizado (menor é melhor). Fonte: Inep, ENEM 2023.

A.4 Notebook 03: PCA

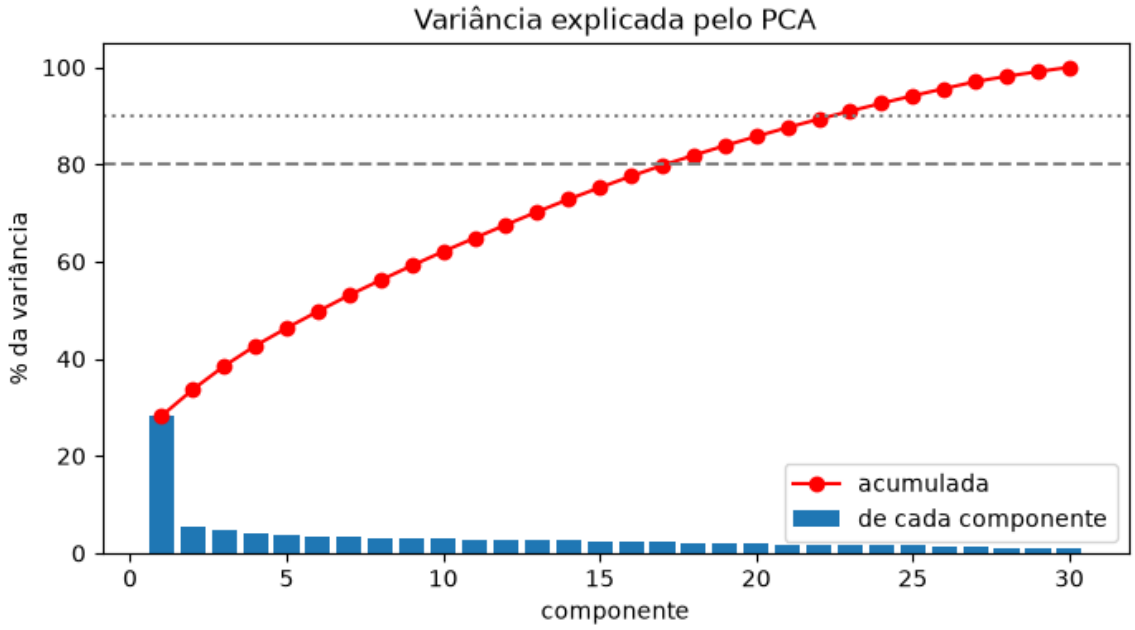


Figura A42. PCA: variância explicada por cada componente e variância acumulada. Fonte: Inep, ENEM 2023.

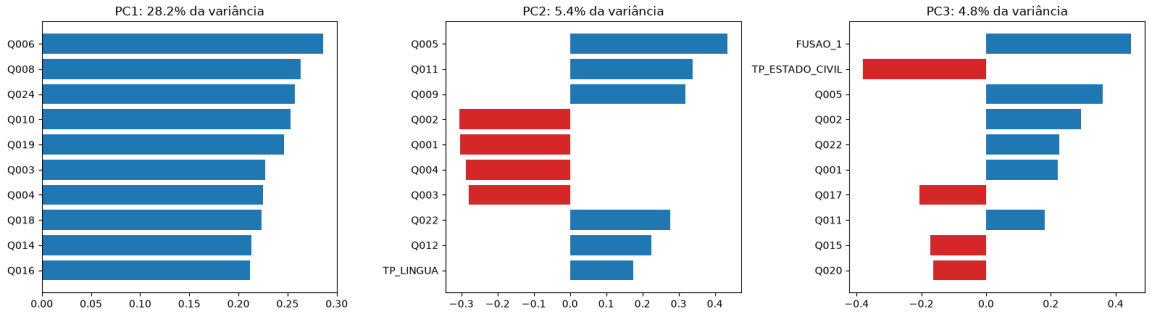


Figura A43. PCA: cargas das 10 maiores features nos 3 primeiros componentes. Fonte: Inep, ENEM 2023.

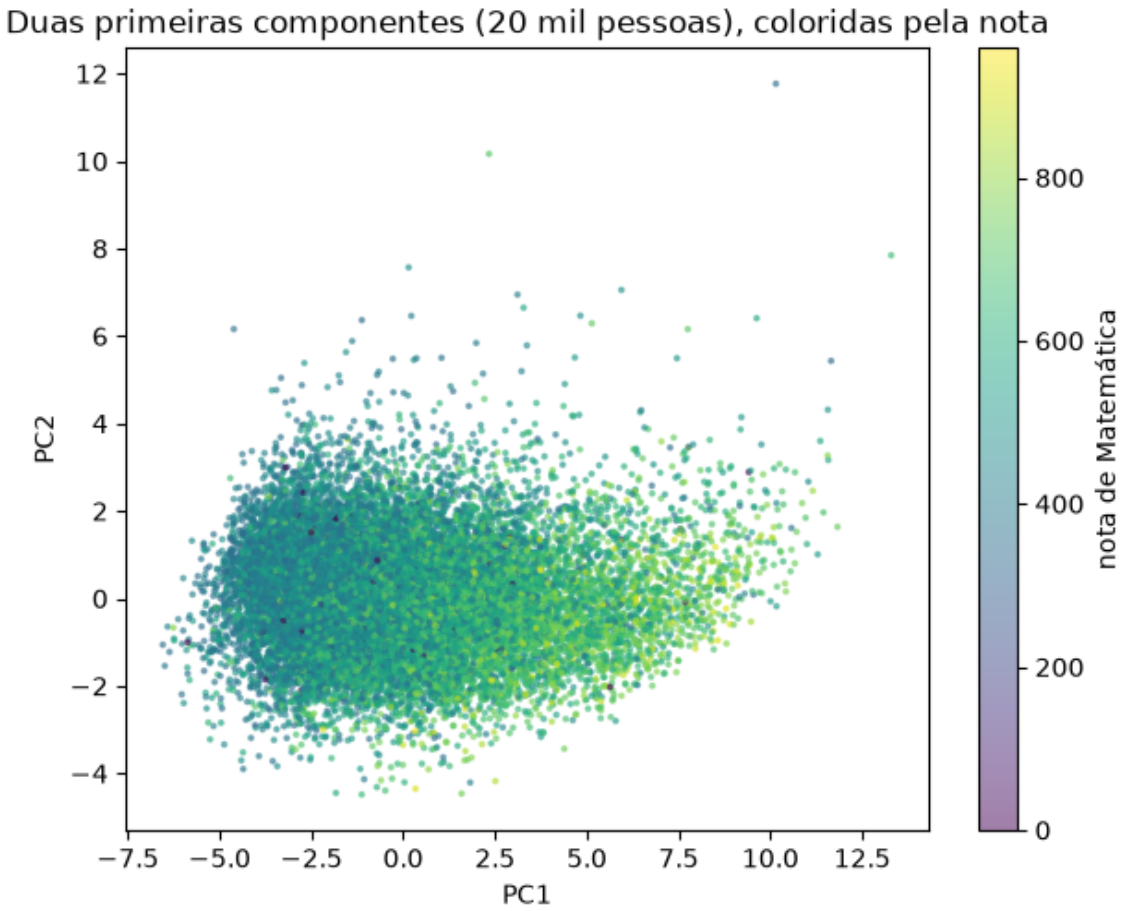


Figura A44. PCA: as duas primeiras componentes (20 mil pessoas), coloridas pela nota. Fonte: Inep, ENEM 2023.

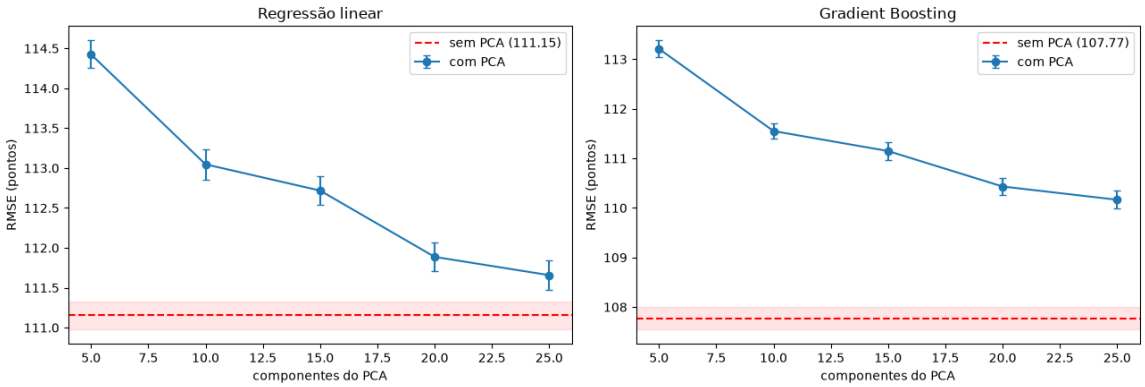


Figura A45. PCA: RMSE em função do número de componentes, regressão linear e Gradient Boosting (linha vermelha: sem PCA, com a faixa de 1 desvio). Fonte: Inep, ENEM 2023.

18. Apêndice B: todos os experimentos registrados

Uma linha por experimento do arquivo `resultados/experimentos.csv` (82 linhas). Os que começam com `H_` (39 linhas) vêm dos notebooks 02 e 03; como esses notebooks só guardaram média e desvio, o **notebook 07 refez cada um com a mesma configuração** e gravou as três dobras (a média refeita difere da antiga em no máximo 0,0005 ponto de RMSE). `S1` a `S6` e `F_` são do notebook 04 com as três dobras; `E1` a `E6` (18 linhas) são das extensões finais do notebook 06 (Apêndice G); `T_` são do **teste final**, separados da validação cruzada e colocados por último. RMSE por dobra em pontos (dobra 1 / 2 / 3); MAE e R^2 são médias; tempo em segundos por dobra (nos testes, tempo de ajuste). Nas linhas `H_`, o tempo é o dos notebooks originais quando eles o registraram; o refazimento do notebook 07 rodou com a máquina menos carregada e foi mais rápido (por exemplo, o stacking levou 63 s por dobra, contra 630 s), e esse tempo fica na coluna de conclusão do CSV (onde o original não registrou o tempo, a tabela mostra o do notebook 07). O prefixo `H_dataset_` é fixo, então os ids de comparação de datasets repetem a palavra (`H_dataset_dataset_1_fundido_GB`). O arquivo CSV tem também hipótese, features, preparação, modelo, parâmetros e conclusão de cada linha.

Experimento	Avaliado	RMSE (média ± desvio)	RMSE por dobra	MAE	R^2	Tempo (s)
H_inicial_Baseline	validação cruzada	131,634 ± 0,158	131,52 / 131,57 / 131,81	107,58	-0,000	0
H_inicial_Regressão linear	validação cruzada	111,153 ± 0,178	111,05 / 111,05 / 111,36	86,96	0,287	1
H_inicial_Ridge	validação cruzada	111,153 ± 0,178	111,05 / 111,05 / 111,36	86,96	0,287	0
H_inicial_Árvore de decisão	validação cruzada	110,551 ± 0,190	110,45 / 110,44 / 110,77	86,38	0,295	3
H_inicial_KNN	validação cruzada	111,575 ± 0,184	111,47 / 111,47 / 111,79	87,18	0,282	476
H_inicial_SVR linear	validação cruzada	111,153 ± 0,178	111,05 / 111,05 / 111,36	86,96	0,287	2
H_inicial_Bagging	validação cruzada	110,014 ± 0,207	109,92 / 109,87 / 110,25	85,99	0,302	24
H_inicial_Pasting	validação cruzada	110,012 ± 0,208	109,92 / 109,87 / 110,25	86,00	0,302	20
H_inicial_Random Forest	validação cruzada	109,422 ± 0,195	109,32 / 109,30 / 109,65	85,49	0,309	103
H_inicial_Gradient Boosting	validação cruzada	107,770 ± 0,226	107,71 / 107,58 / 108,02	83,82	0,330	133
H_inicial_Stacking	validação cruzada	107,763 ± 0,226	107,71 / 107,57 / 108,01	83,80	0,330	630

Experimento	Avaliado	RMSE (média ± desvio)	RMSE por dobra	MAE	R^2	Tempo (s)
H_busca_Gradient Boosting	validação cruzada	107,680 ± 0,218	107,65 / 107,48 / 107,91	83,71	0,331	224
H_busca_Bagging	validação cruzada	109,083 ± 0,189	108,98 / 108,97 / 109,30	85,27	0,313	24
H_busca_Random Forest	validação cruzada	109,138 ± 0,194	109,03 / 109,02 / 109,36	85,24	0,313	19
H_dataset_dataset_1_fundido_GB	validação cruzada	107,770 ± 0,226	107,71 / 107,58 / 108,02	83,82	0,330	18
H_dataset_dataset_1_features_GB	validação cruzada	107,759 ± 0,239	107,71 / 107,55 / 108,02	83,81	0,330	19
H_dataset_dataset_2_escola_GB	validação cruzada	107,261 ± 0,202	107,21 / 107,09 / 107,48	83,36	0,336	20
H_dataset_dataset_2_features_escola_GB	validação cruzada	107,255 ± 0,194	107,21 / 107,09 / 107,47	83,36	0,336	21
H_dataset_dataset_3_sem_escola_GB	validação cruzada	107,551 ± 0,211	107,49 / 107,38 / 107,79	83,61	0,332	20
H_dataset_dataset_3_sem_escola_features_GB	validação cruzada	107,540 ± 0,223	107,48 / 107,35 / 107,79	83,60	0,333	22
H_dataset_dataset_3_escola_GB	validação cruzada	107,056 ± 0,187	107,00 / 106,91 / 107,27	83,16	0,339	21
H_dataset_dataset_3_escola_features_GB	validação cruzada	107,048 ± 0,196	106,99 / 106,89 / 107,27	83,16	0,339	26
H_semzeros_Regressão linear	validação cruzada	111,202 ± 0,187	111,09 / 111,09 / 111,42	87,05	0,286	1
H_semzeros_Ridge	validação cruzada	111,202 ± 0,187	111,09 / 111,09 / 111,42	87,05	0,286	0
H_semzeros_Árvore de decisão	validação cruzada	110,331 ± 0,210	110,21 / 110,21 / 110,57	86,16	0,297	3
H_semzeros_Gradient Boosting	validação cruzada	107,737 ± 0,204	107,63 / 107,61 / 107,97	83,81	0,330	30

Experimento	Avaliado	RMSE (média ± desvio)	RMSE por dobra	MAE	R^2	Tempo (s)
H_pca_Regressão linear_sem PCA	validação cruzada	111,153 ± 0,178	111,05 / 111,05 / 111,36	86,96	0,287	1
H_pca_Regressão linear_5	validação cruzada	114,425 ± 0,174	114,30 / 114,36 / 114,62	90,05	0,244	0
H_pca_Regressão linear_10	validação cruzada	113,047 ± 0,190	112,90 / 112,98 / 113,26	88,66	0,262	0
H_pca_Regressão linear_15	validação cruzada	112,718 ± 0,184	112,60 / 112,63 / 112,93	88,40	0,267	0
H_pca_Regressão linear_20	validação cruzada	111,887 ± 0,177	111,78 / 111,79 / 112,09	87,67	0,278	1
H_pca_Regressão linear_25	validação cruzada	111,658 ± 0,181	111,54 / 111,56 / 111,87	87,47	0,280	1
H_pca_Gradient Boosting_sem PCA	validação cruzada	107,770 ± 0,226	107,71 / 107,58 / 108,02	83,82	0,330	17
H_pca_Gradient Boosting_5	validação cruzada	113,210 ± 0,168	113,11 / 113,11 / 113,40	88,93	0,260	3
H_pca_Gradient Boosting_10	validação cruzada	111,551 ± 0,152	111,46 / 111,46 / 111,73	87,33	0,282	6
H_pca_Gradient Boosting_15	validação cruzada	111,148 ± 0,181	111,03 / 111,06 / 111,36	86,98	0,287	9
H_pca_Gradient Boosting_20	validação cruzada	110,432 ± 0,172	110,36 / 110,30 / 110,63	86,32	0,296	9
H_pca_Gradient Boosting_25	validação cruzada	110,165 ± 0,183	110,05 / 110,07 / 110,38	86,06	0,300	10
H_kmeans_Gradient Boosting	validação cruzada	107,789 ± 0,232	107,74 / 107,58 / 108,04	83,84	0,329	73
S1a_fusao_no_treino	validação cruzada	107,051 ± 0,192	106,99 / 106,90 / 107,27	83,16	0,339	25
S1b_colunas_separadas	validação cruzada	106,726 ± 0,189	106,64 / 106,60 / 106,94	82,84	0,343	27
S2_com_uf	validação cruzada	106,025 ± 0,188	105,95 / 105,89 / 106,24	82,20	0,351	40
S3_sem_features_criadas	validação cruzada	106,038 ± 0,167	105,95 / 105,94 / 106,23	82,21	0,351	38

Experimento	Avaliado	RMSE (média ± desvio)	RMSE por dobra	MAE	R^2	Tempo (s)
S4_gb_k22	validação cruzada	110,607 ± 0,191	110,49 / 110,51 / 110,83	86,36	0,294	14
S4_gb_k37	validação cruzada	107,436 ± 0,208	107,30 / 107,34 / 107,68	83,45	0,334	24
S4_gb_k51	validação cruzada	107,069 ± 0,199	106,95 / 106,96 / 107,30	83,11	0,338	30
S4_linear_todas	validação cruzada	108,868 ± 0,162	108,78 / 108,77 / 109,06	84,86	0,316	2
S4_linear_k22	validação cruzada	112,251 ± 0,165	112,14 / 112,17 / 112,44	88,01	0,273	1
S4_linear_k37	validação cruzada	110,526 ± 0,198	110,38 / 110,45 / 110,75	86,26	0,295	1
S4_linear_k51	validação cruzada	110,198 ± 0,196	110,06 / 110,12 / 110,42	85,95	0,299	1
S5_peso_alfa_0.5	validação cruzada	108,140 ± 0,188	108,07 / 108,00 / 108,35	82,82	0,325	40
S5_peso_alfa_1.0	validação cruzada	123,459 ± 0,149	123,43 / 123,33 / 123,62	94,83	0,120	24
S6_sem_renda	validação cruzada	106,893 ± 0,194	106,79 / 106,77 / 107,12	83,03	0,341	44
S6_sem_escolaridade	validação cruzada	106,559 ± 0,168	106,50 / 106,43 / 106,75	82,71	0,345	46
S6_sem_bens	validação cruzada	107,356 ± 0,174	107,29 / 107,22 / 107,55	83,39	0,335	33
S6_sem_escola	validação cruzada	106,439 ± 0,185	106,37 / 106,30 / 106,65	82,56	0,346	47
S6_sem_localização	validação cruzada	106,726 ± 0,189	106,64 / 106,60 / 106,94	82,84	0,343	33
S6_sem_perfil	validação cruzada	110,445 ± 0,189	110,35 / 110,32 / 110,66	86,24	0,296	35
F_baseline_cv	validação cruzada	131,634 ± 0,158	131,52 / 131,57 / 131,81	107,58	-0,000	0
F_regressao_linear_cv	validação cruzada	108,868 ± 0,162	108,78 / 108,77 / 109,06	84,86	0,316	3
F_final_cv	validação cruzada	105,864 ± 0,169	105,80 / 105,74 / 106,06	82,02	0,353	91

Experimento	Avaliado	RMSE (média ± desvio)	RMSE por dobra	MAE	R^2	Tempo (s)
E1_linear_A_numeros	validação cruzada	108,868 ± 0,162	108,78 / 108,77 / 109,06	84,86	0,316	1
E1_ridge_A_numeros	validação cruzada	108,868 ± 0,162	108,78 / 108,77 / 109,06	84,86	0,316	1
E1_linear_B_onehot_nominais	validação cruzada	108,629 ± 0,163	108,54 / 108,53 / 108,82	84,66	0,319	2
E1_ridge_B_onehot_nominais	validação cruzada	108,630 ± 0,163	108,54 / 108,53 / 108,82	84,66	0,319	1
E1_linear_C_onehot_todas	validação cruzada	107,888 ± 0,178	107,79 / 107,78 / 108,09	83,95	0,328	5
E1_ridge_C_onehot_todas	validação cruzada	107,891 ± 0,179	107,79 / 107,78 / 108,10	83,96	0,328	6
E3_com_municipio_TE	validação cruzada	105,730 ± 0,171	105,65 / 105,61 / 105,93	81,92	0,355	25
E3_sem_municipio	validação cruzada	106,025 ± 0,188	105,95 / 105,89 / 106,24	82,20	0,351	27
E4_semente_0	validação cruzada	105,862 ± 0,182	105,80 / 105,72 / 106,07	82,02	0,353	60
E4_semente_1	validação cruzada	105,871 ± 0,192	105,78 / 105,74 / 106,09	82,03	0,353	55
E4_semente_2	validação cruzada	105,868 ± 0,184	105,79 / 105,74 / 106,08	82,03	0,353	61
E5_gb_busca	validação cruzada	105,859 ± 0,181	105,79 / 105,72 / 106,06	82,02	0,353	66
E5_bagging_busca	validação cruzada	107,878 ± 0,172	107,80 / 107,76 / 108,08	84,22	0,328	41
E5_rf_busca	validação cruzada	107,919 ± 0,192	107,83 / 107,79 / 108,14	84,18	0,328	39
E6_dataset5_regressao_linear	validação cruzada	111,287 ± 2,393	113,65 / 111,35 / 108,87	84,20	0,285	39
E6_dataset5_ridge	validação cruzada	107,508 ± 0,197	107,41 / 107,38 / 107,73	83,60	0,333	15
E6_dataset5_svr_linear	validação cruzada	107,903 ± 0,206	107,80 / 107,77 / 108,14	83,30	0,328	18
E6_dataset5_gradient_boosting	validação cruzada	107,992 ± 0,210	107,91 / 107,84 / 108,23	84,35	0,327	7

Experimento	Avaliado	RMSE (média ± desvio)	RMSE por dobra	MAE	R^2	Tempo (s)
T_baseline	teste	131,703	—	107,64	-0,000	0
T_regressao_linear	teste	108,863	—	84,89	0,317	4
T_final	teste	105,815	—	82,00	0,354	165

Os experimentos do dataset 6 (diagnóstico com as notas de outras áreas) ficam em arquivos separados, de propósito, para não se misturarem com os da solução: `resultados/tabelas/diagnostico_dataset6_notas_outras_areas.csv`, `diagnostico_dataset6_sem_zeros.csv` e os dois arquivos de Spearman.

19. Apêndice C: colunas usadas, criadas e removidas

A solução final tem **74 colunas**: as 44 do `dataset_3_escola_features` sem a `FUSAO_1`, as 4 colunas de situação escolar separadas e 26 de UF da prova.

Coluna(s)	Situação	Justificativa
`NU_NOTA_MT`	Alvo (y)	Nota de Matemática; só participantes com nota observada
`TP_SEXO`, `TP_ESTADO_CIVIL`, `TP_COR_RACA`, `TP_LINGUA`	Usadas	Perfil demográfico; as nominais entram como número em escada (limitação para modelos lineares)
`Q001` a `Q025`	Usadas	Questionário socioeconômico; “não sei” de `Q001` a `Q004` preenchido com a mediana
`IN_TREINEIRO`, `TP_ANO_CONCLUIU`, `TP_FAIXA_ETARIA`, `TP_ST_CONCLUSAO`	Fundidas na `FUSAO_1` nos datasets 1 a 3; **separadas** na solução final	Spearman acima de 0,7 entre si (redundantes), mas desdobrar melhora o erro (−0,33); a fusão refeita só com o treino foi comparada no notebook 04
`PESSOAS_POR_QUARTO`, `CELULAR_POR_MORADOR`, `RENDA_MENOS_ESCOL`	Criadas	Hipóteses na seção 5.1; sem efeito mensurável no erro
`ESCOLA_PUBLICA`, `ESCOLA_PRIVADA`, `LOC_URBANA`, `LOC_RURAL`	Datasets 2 em diante e solução	`TP_ESCOLA` e `TP_LOCALIZACAO_ESC` em 0/1; vazio = “sem informação” (referência)

Coluna(s)	Situação	Justificativa
`Q001_NAO_SEI` a `Q004_NAO_SEI`, `NAC_NAO_INFORMADO`, `NAC_NATURALIZADO`, `NAC_ESTRANGEIRO`, `NAC_NATO_EXTERIOR`	Dataset 3 e solução	Desproporcionais, mas com sinal (`NAO_SEI`: −40 a −50 pontos)
`SG_UF_PROVA` (26 colunas `UF_*`, referência SP)	Solução final (notebook 04)	Melhora o erro (−0,70); UF da prova, não residência; fora dos datasets 1 a 3
`FUSAO_1`	Datasets 1 a 3 (não está na solução final)	Média de z-scores das 4 colunas de trajetória; média e desvio com todas as linhas nos datasets salvos; refeita só com o treino no notebook 04
`DEP_FEDERAL`, `DEP_ESTADUAL`, `DEP_MUNICIPAL`, `DEP_PRIVADA`	Removidas	Redundantes com `ESCOLA_*` e `LOC_*` (0,88 e 0,73); `DEP_MUNICIPAL` tem 0,2% das linhas
`CO_MUNICIPIO_ESC`, `NO_MUNICIPIO_ESC`, `CO_UF_ESC`, `SG_UF_ESC`, `TP_SIT_FUNC_ESC`, `TP_ENSINO`	Removidas (usadas só no dataset 5)	66% a 76% de ausentes, alta cardinalidade ou categorias muito raras
`CO_MUNICIPIO_PROVA`, `NO_MUNICIPIO_PROVA`, `CO_UF_PROVA`	Removidas (por ora)	O município (cerca de 1.750 categorias) só entraria com codificação supervisionada dentro do Pipeline
`NU_NOTA_CN`, `NU_NOTA_CH`, `NU_NOTA_LC`, `NU_NOTA_REDACAO`	**Proibidas** na solução; usadas só no dataset 6 (diagnóstico)	Vazamento: descrevem a própria prova
`NU_NOTA_COMP1` a `NU_NOTA_COMP5`, `TP_PRESENCA_*`, `CO_PROVA_*`, `TX_RESPOSTAS_*`, `TX_GABARITO_*`, `TP_STATUS_REDACAO`, `NU_ANO`	**Proibidas**	Vazamento: resultados ou informações da própria prova
`NU_INSCRICAO`	Identificador	Guardado à parte em `ids_elegiveis.csv`; não é entrada do modelo

20. Apêndice D: tabelas completas do teste e da curva de aprendizado

D.1 Curva de aprendizado por dobra (`resultados/tabelas/curva_aprendizado.csv`). Subconjuntos progressivos do treino de cada dobra, semente 42, pipeline reajustado a cada tamanho.

Dobra	% do treino	Linhas de treino	RMSE de treino	RMSE de validação	Tempo (s)
1	10%	143.596	102,91	106,59	14
1	25%	358.990	103,59	106,18	31
1	50%	717.980	104,05	105,93	75
1	75%	1.076.970	104,83	105,88	83
1	100%	1.435.960	104,72	105,78	140
2	10%	143.596	102,13	106,56	18
2	25%	358.990	103,56	106,10	36
2	50%	717.980	104,21	105,89	73
2	75%	1.076.971	104,57	105,79	108
2	100%	1.435.961	104,70	105,71	143
3	10%	143.596	102,80	106,88	14
3	25%	358.990	103,95	106,46	29
3	50%	717.980	104,32	106,23	62
3	75%	1.076.971	104,42	106,13	95
3	100%	1.435.961	104,88	106,10	102

D.2 Erro no teste por UF da prova (ordenado pelo RMSE; `resultados/tabelas/teste_erros_por_grupo.csv`). O viés é nota real menos prevista; por UF ele chega a −2,5 pontos (MT) e +2,1 (ES), maior que nos outros grupos.

UF	Participantes	Nota média	RMSE	MAE	Viés
AP	3.642	481,0	95,3	73,5	-1,9
AM	9.946	483,4	96,5	73,4	-1,4
AC	2.992	490,5	97,4	74,8	0,7
PA	30.824	483,9	97,8	74,7	-0,5
MA	22.560	483,4	98,1	75,8	0,2
TO	4.368	504,3	99,2	78,4	-1,6
RR	1.225	520,7	99,7	78,3	1,6
BA	44.474	505,8	100,6	78,4	-0,3
RO	4.606	504,1	101,7	79,8	0,9
RN	14.581	525,0	103,1	80,5	0,2
SE	9.520	511,2	103,5	80,4	1,6
PI	14.196	502,9	103,7	81,4	-0,3
AL	11.100	506,3	104,0	80,8	-0,9

UF	Participantes	Nota média	RMSE	MAE	Viés
MS	6.356	528,5	104,1	81,8	-0,3
PB	17.300	512,7	105,2	81,3	-1,6
PE	30.562	527,8	105,7	83,5	1,8
GO	19.133	532,2	106,3	83,0	-0,1
SP	82.185	572,1	106,4	83,5	0,6
RS	22.179	558,8	106,8	82,4	0,4
CE	35.046	521,9	107,7	84,6	-0,5
DF	10.051	555,7	107,7	82,2	-0,6
MT	8.460	513,7	109,9	83,9	-2,5
ES	10.064	557,4	109,9	85,0	2,1
RJ	36.876	553,4	110,5	84,7	1,9
MG	50.192	566,7	111,0	85,9	-0,6
PR	23.253	553,4	112,1	85,9	-0,1
SC	12.795	561,4	116,2	85,6	-1,0

21. Apêndice E: o que está feito e o que falta

Feito e rodado: protocolo e partição; exploração e 8 datasets; todos os regressores obrigatórios em configuração inicial; busca de hiperparâmetros em 7 modelos; PCA em dois regressores, t-SNE e K-means; treino sem zeros; as 13 variações do notebook 04 (fusão sem vazamento, UF, features criadas, seleção, balanceamento, blocos); solução final; curva de aprendizado; teste final aberto uma vez; dataset 5 (métricas de teste da solução independente); dataset 6 (diagnóstico); as extensões finais do notebook 06 (one-hot, V de Cramér, município com target encoding, três sementes, busca na representação final e dataset 5 por validação cruzada, Apêndice G); as métricas por dobra das 39 linhas históricas (notebook 07, Apêndice B); as correções dos notebooks 02 (KNN no fim, seção 12 robusta e busca do notebook sem zeros com nome próprio); artigo, pitch, README e este documento; commits na branch `do-zero`.

Pendente ou em aberto (nada disto bloqueia a entrega):

1. **Município com target encoding:** melhorou 0,30 ponto na validação cruzada (0,13 sobre a solução final), mas **não foi adotado** porque o teste já foi aberto. Fica como próximo passo; adotá-lo agora exigiria reabrir o teste, o que desfaz o protocolo.
2. **Stacking e KNN** nunca passaram por busca de hiperparâmetros (custo); nenhum dos dois ganhou do Gradient Boosting na configuração inicial.
3. **Corte de 400 s nos notebooks 02:** o pedido era 120 s; não foi aplicado de propósito, porque mudaria o modelo escolhido (Gradient Boosting) e os resultados documentados.
4. **Entrega:** push para o GitHub, abrir este documento no Word para checar o layout, ensaiar o pitch (todos precisam dominar as decisões) e conferir o nome da universidade e da equipe no artigo.

22. Apêndice F: o artigo e o pitch

Artigo (`docs/artigo.pdf`): padrão IEEE em duas colunas, 10 páginas (limite de 10), 10 figuras e 9 tabelas, 12 referências, com os e-mails e a instituição (UNIFOR) na primeira página; a mesma versão em LaTeX está em docs/artigo.tex. Estrutura: resumo e abstract; I Introdução; II Metodologia (A dados e protocolo, B features e preparação, C modelos, PCA, seleção, balanceamento e busca, D curva de aprendizado e métodos novos, E conjuntos de entrada e verificações adicionais); III Resultados (A distribuição da nota e comparação inicial, B PCA, C hipóteses, D solução final e curva, E teste final, F dataset 5, G dataset 6); IV Discussão; V Conclusão; Referências. O dataset 6 aparece sempre rotulado como diagnóstico fora da solução.

Pitch (`docs/pitch.pdf`): 26 slides, para 10 a 15 minutos, com visual limpo, a mensagem principal logo abaixo do título e diagramas que mostram o caminho dos dados: o funil das linhas (do Inep às dobras), o protocolo das dobras, o funil das colunas (de 76 a 74), a árvore dos 8 datasets com o RMSE de cada um, a matriz das 21 combinações e a cascata do que reduziu o erro.

Slide	Conteúdo	Quem apresenta
1	Capa	Raquel
2	A pergunta	Raquel
3	Do Inep às dobras de validação (funil das linhas)	Raquel
4	Validação cruzada sem vazamento (diagrama das dobras e do Pipeline)	Amanda
5	A nota de Matemática	Amanda
6	Como escolhemos as colunas (funil de 76 a 74)	Amanda
7	Decisões de preparação	Amanda
8	Três features criadas, cada uma com uma hipótese	Sofya
9	Os 8 datasets e a representação final (árvore)	Amanda
10	As 21 combinações testadas (matriz)	Sofya
11	Dez regressores na configuração inicial	João Igor
12	Busca de hiperparâmetros	João Igor
13	PCA	Sofya
14	O que reduziu o erro, passo a passo (cascata)	Sofya
15	Quanto vale cada bloco de informação	Sofya
16	Balanceamento por pesos	João Igor
17	A solução final	João Igor
18	Curva de aprendizado	João Igor
19	Teste: observada contra prevista	Raquel
20	Onde o modelo erra mais	Raquel
21	Erros por região, renda e escola	Raquel

Slide	Conteúdo	Quem apresenta
22	Replicação independente (dataset 5)	João Igor
23	Diagnóstico com as notas de outras áreas (dataset 6)	Sofya
24	Extensões depois do teste	Amanda
25	As perguntas que fizemos e as respostas	Sofya
26	O que aprendemos	Raquel

Raquel apresenta 7 slides (com a capa), Sofya 7 e Amanda e João Igor 6 cada. Os gráficos são gerados por `src/figuras_pitch_graficos.py`; os diagramas são desenhados no próprio script dos slides.

23. Apêndice G: extensões finais (notebook 06)

Este apêndice fecha as pendências do Apêndice E. Tudo foi rodado **só com validação cruzada no desenvolvimento** (as mesmas 3 dobras, semente 42). O teste já tinha sido aberto uma vez no notebook 04, então **nada daqui altera a solução final**: são hipóteses extras, medidas e registradas no `experimentos.csv` (linhas `E1_*` a `E6_*`). As notas das outras áreas (dataset 6) não entram em nenhum destes experimentos.

G.1 One-hot nas categóricas, em modelos lineares (E1)

Hipótese: nas colunas sem ordem (cor/raça, estado civil), tratar o código como número obriga o modelo linear a supor uma ordem que não existe; o one-hot deve ajudar, com efeito esperado de cerca de 1 ponto, como sugeria a solução independente (dataset 5). Três versões das mesmas 74 colunas, com regressão linear e Ridge (alfa 10); `OneHotEncoder(min_frequency=50)` dentro do Pipeline.

Versão	Regressão linear (RMSE médio ± desvio)	Ridge	R^2	Ganho sobre A
A. Tudo como número	108,868 ± 0,162	108,868	0,316	—
B. One-hot só em cor/raça e estado civil	108,629 ± 0,163	108,630	0,319	−0,24
C. One-hot em todas as categóricas (faixa etária, situação, ano de conclusão, Q001 a Q025 e as nominais)	107,888 ± 0,178	107,891	0,328	−0,98

Resultado: a hipótese se confirma. O ganho das duas nominais sozinhas é pequeno (0,24, dentro de 1,5 desvio entre dobras); o ganho de cerca de 1 ponto vem de abrir **todas** as categóricas (C). Ridge e regressão linear dão o mesmo resultado, pois com mais de 1 milhão de linhas de treino a regularização quase não pesa. Mesmo no melhor caso, o modelo linear (107,89) fica a 2 pontos do Gradient Boosting final (105,86): a não linearidade explica o resto.

G.2 V de Cramér entre colunas sem ordem (E2)

O V de Cramér mede a associação entre duas colunas categóricas (0 = nenhuma, 1 = uma determina a outra). Foi calculado para os pares entre as 9 colunas sem ordem (sexo, estado civil, cor/raça, língua,

situação de conclusão, tipo e localização da escola, nacionalidade e UF da prova), numa amostra de 400 mil pessoas do desenvolvimento. O limite de redundância é o mesmo dos outros datasets (0,7).

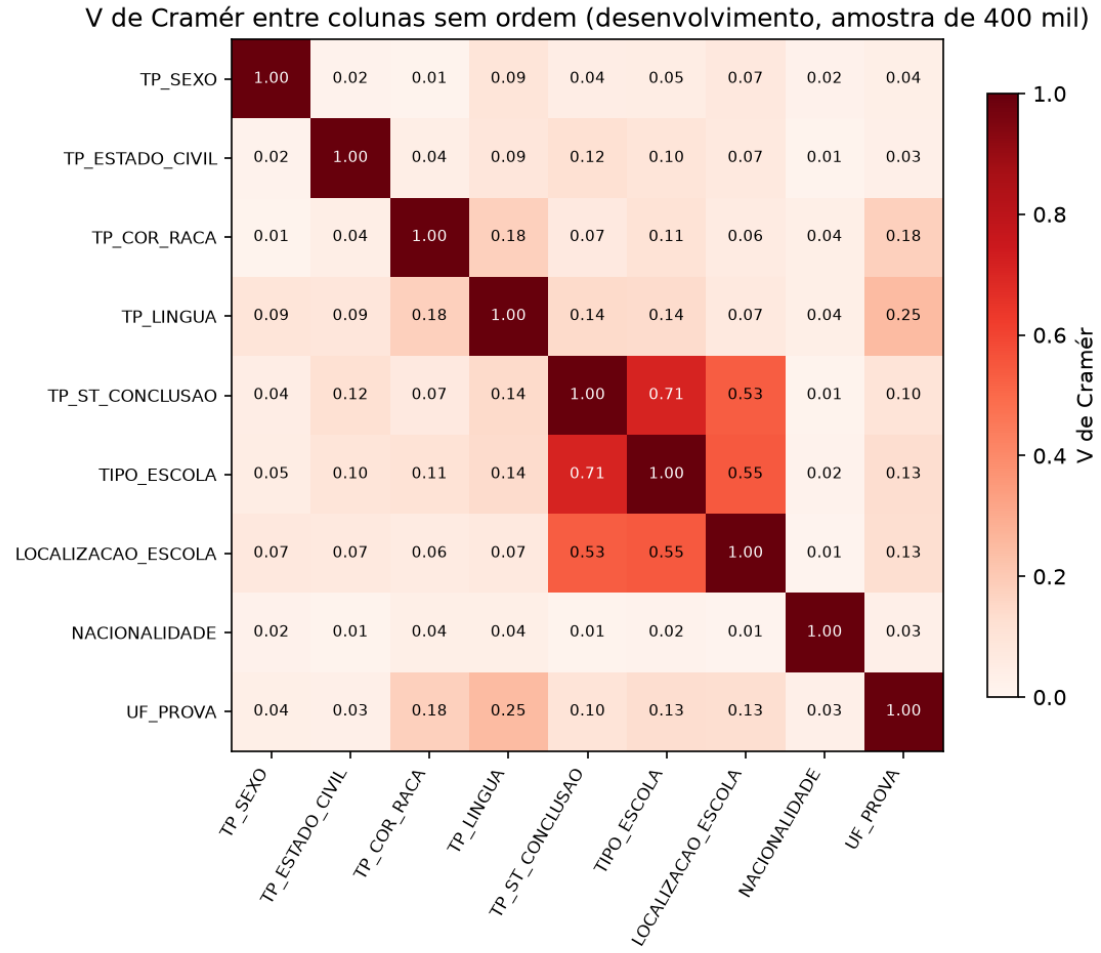


Figura G1. V de Cramér entre as colunas categóricas. Fonte: Inep, ENEM 2023.

Par	V de Cramér
Situação de conclusão × tipo de escola	0,707
Tipo de escola × localização da escola	0,546
Situação de conclusão × localização da escola	0,534
Língua estrangeira × UF da prova	0,249
Cor/raça × língua estrangeira	0,178

Resultado: a redundância se concentra no trio **situação de conclusão, tipo e localização da escola**; só o par situação × tipo de escola passa do limite de 0,7 (0,707). É o mesmo grupo que a fusão `FUSAO_1` do notebook 04 já tratava. Todos os demais pares ficam abaixo de 0,25, então não há outro grupo de colunas nominais para fundir. Tabelas completas: `resultados/tabelas/e2_cramer_v_matriz.csv` e `e2_cramer_v_pares.csv`.

G.3 Município com target encoding (E3)

Hipótese: o município da prova é o maior sinal ainda não usado; codificá-lo pela nota média (aprendida só no treino de cada dobra, com `TargetEncoder(cv=KFold(5))` dentro do Pipeline) deve reduzir o erro. Comparação com o mesmo modelo sem o município (`S2_com_uf`, 74 colunas).

Experimento	Colunas	RMSE por dobra	RMSE médio ± desvio	MAE	R^2
Sem município (`E3_sem_municipio`)	74	105,949 / 105,887 / 106,239	106,025 ± 0,188	82,196	0,351
Com município (`E3_com_municipio_TE`)	75	105,651 / 105,612 / 105,926	105,730 ± 0,171	81,916	0,355

Resultado: ganho de **0,295 ponto de RMSE**, em todas as 3 dobras, e maior que o desvio entre dobras (0,19): o município ajuda de forma pequena mas consistente. Contra a solução final (105,864, com hiperparâmetros buscados), o ganho cai para 0,13, dentro do desvio. **Não foi adotado**: o teste já foi aberto, e trocar a solução depois de olhar o teste desfaria o protocolo. Fica como o melhor próximo passo.

G.4 Mais de uma semente (E4)

A solução final (semente 42) foi treinada de novo com as sementes 0, 1 e 2.

Semente	RMSE médio ± desvio	R^2
42 (`F_final_cv`)	105,864 ± 0,169	0,353
0	105,862 ± 0,182	0,353
1	105,871 ± 0,192	0,353
2	105,868 ± 0,184	0,353

Resultado: as quatro sementes diferem em **0,009 ponto** (de 105,862 a 105,871), cerca de 20 vezes menos que o desvio entre dobras (0,17). A semente não explica nenhuma diferença que tenhamos medido neste trabalho.

G.5 Busca de hiperparâmetros na representação final (E5)

A busca original foi feita no dataset de 30 colunas. Aqui, `RandomizedSearchCV` (10 sorteios, `refit=False`, mesmas dobras) nas 74 colunas finais, para os 3 melhores modelos. Não substitui a solução final.

Modelo	RMSE médio ± desvio	MAE	R^2
Gradient Boosting (`E5_gb_busca`)	105,859 ± 0,181	82,018	0,353
Bagging (`E5_bagging_busca`)	107,878 ± 0,172	84,217	0,328
Random Forest (`E5_rf_busca`)	107,919 ± 0,192	84,175	0,328

Resultado: o Gradient Boosting reencontra o mesmo patamar (105,859 contra 105,864 da solução final: diferença de 0,005, praticamente zero), e os dois modelos de árvores independentes ficam 2 pontos atrás. Ou seja, a busca feita antes, em 30 colunas, **já estava no limite do que o modelo entrega**; a representação nova não pedia outros hiperparâmetros. Stacking e KNN continuam sem busca por custo (cerca de 10 e 8 minutos por dobra).

G.6 Dataset 5 por validação cruzada (E6)

A preparação da solução independente (colunas categóricas originais mais 4 derivadas, one-hot de tudo, 45 colunas de entrada) foi reproduzida com o script arquivado em `resultados/dataset5_replicacao_independente/` e avaliada nas **nossas** 3 dobras do desenvolvimento, para comparar com o resto em pé de igualdade. Antes, o dataset 5 só tinha métrica de teste da outra solução.

Modelo no dataset 5	RMSE por dobra	RMSE médio ± desvio	MAE	R^2
Regressão linear	113,650 / 111,345 / 108,865	111,287 ± 2,393	84,203	0,285
Ridge	107,412 / 107,378 / 107,734	107,508 ± 0,197	83,599	0,333
SVR linear	107,796 / 107,771 / 108,141	107,903 ± 0,206	83,298	0,328
Gradient Boosting leve (50 árvores)	107,909 / 107,837 / 108,231	107,992 ± 0,210	84,353	0,327
Solução final (74 colunas, para comparar)	*105,800 / 105,737 / 106,055*	*105,864 ± 0,169*	*82,025*	*0,353*

Resultado: o melhor do dataset 5 (Ridge, 107,51) bate com a métrica de teste que a outra solução tinha achado (107,5): a validação cruzada confirma o número. Nossa solução final fica **1,6 ponto melhor** (RMSE) e sobe o R^2 de 0,333 para 0,353. A regressão linear simples é instável nesse conjunto (desvio de 2,4 entre dobras, com a dobra 1 em 113,65): com one-hot de todas as colunas, o modelo sem regularização fica sensível a categorias raras e a dobra 1 sofre mais; o Ridge, que regulariza, fica estável (desvio de 0,2). Não investigamos mais a fundo a causa.

G.7 Conclusão do apêndice

Seis hipóteses extras, **nenhuma muda a conclusão**: o erro fica em cerca de 106 pontos ($R^2 \approx 0{,}35$). O que ainda tem ganho mensurável é pequeno (município, 0,3; one-hot em modelos lineares, 1,0 sobre modelos que já perdem por 2) e nada chega perto de fechar a distância para o limite de informação já medido (curva de aprendizado e diagnóstico do dataset 6).

G.8 Tabelas completas do E5 e do E2

E5: as 10 configurações sorteadas em cada busca (74 colunas finais, 3 dobras; ordenadas pelo RMSE médio; a primeira linha de cada modelo é a de menor erro). O desvio desta tabela é o do `RandomizedSearchCV` (divide por 3), por isso é menor que o das outras tabelas (divide por 2). Repare que a segunda linha do Gradient Boosting (105,864) tem exatamente os hiperparâmetros da solução final: com a mesma semente, a busca sorteou as mesmas configurações de antes, e na representação de 74 colunas outra configuração ficou apenas 0,005 à frente.

Gradient Boosting

Posição	RMSE médio ± desvio	l2_regularization	learning_rate	max_iter	max_leaf_nodes	min_samples_leaf
1	105,859 ± 0,148	0,0292	0,0688	500	76	100
2	105,864 ± 0,138	0,2440	0,0669	500	89	137
3	105,937 ± 0,147	0,0534	0,0440	500	56	237
4	105,961 ± 0,144	7,2867	0,1786	200	67	435
5	105,998 ± 0,151	9,3078	0,1065	300	36	302
6	106,071 ± 0,143	0,0315	0,2625	500	86	238
7	106,086 ± 0,149	7,5795	0,1906	300	16	241
8	106,147 ± 0,142	0,0339	0,2867	200	17	356
9	106,182 ± 0,143	0,0216	0,0294	500	36	358
10	106,344 ± 0,150	0,5263	0,0677	300	18	138

Bagging

Posição	RMSE médio ± desvio	estimator__max_depth	estimator__min_samples_leaf	max_features	max_samples	n_estimators
1	107,878 ± 0,140	15	34	0,8	0,7	24
2	108,137 ± 0,148	14	68	1	1	40
3	108,216 ± 0,149	13	40	1	0,7	28
4	108,498 ± 0,154	13	171	1	0,7	30
5	108,564 ± 0,137	12	94	1	0,5	13
6	108,816 ± 0,144	12	199	0,6	1	20
7	108,845 ± 0,160	10	180	0,8	0,7	38
8	109,048 ± 0,156	10	70	1	0,5	18
9	110,045 ± 0,142	8	127	1	0,5	12
10	110,152 ± 0,193	7	107	0,8	0,7	11

Random Forest

Posição	RMSE médio ± desvio	max_depth	max_features	min_samples_leaf	n_estimators
1	107,919 ± 0,157	15	0,3	30	50
2	108,033 ± 0,155	14	0,3	24	50
3	108,207 ± 0,151	15	0,3	109	100
4	108,216 ± 0,155	15	0,7	159	50
5	108,368 ± 0,147	15	0,3	170	100
6	108,766 ± 0,160	11	0,7	199	100
7	109,021 ± 0,164	10	0,7	179	100
8	109,300 ± 0,167	9	0,5	47	100
9	109,320 ± 0,170	9	0,5	98	50
10	109,369 ± 0,165	9	0,7	84	50

E2: matriz completa do V de Cramér (amostra de 400 mil pessoas do desenvolvimento).

	TP_SEXO	TP_ESTADO_CIVIL	TP_COR_RACA	TP_LINGUA	TP_ST_CONCLUSAO	TIPO_ESCOLA	LOCALIZACAO_ESCOLA	NACIONALIDADE	UF_PROVA
TP_SEXO	1,000	0,016	0,014	0,095	0,044	0,049	0,074	0,023	0,036
TP_ESTADO_CIVIL	0,016	1,000	0,040	0,088	0,121	0,096	0,074	0,012	0,034
TP_COR_RACA	0,014	0,040	1,000	0,178	0,067	0,109	0,055	0,038	0,176
TP_LINGUA	0,095	0,088	0,178	1,000	0,143	0,138	0,073	0,037	0,249
TP_ST_CONCLUSAO	0,044	0,121	0,067	0,143	1,000	0,707	0,534	0,014	0,099
TIPO_ESCOLA	0,049	0,096	0,109	0,138	0,707	1,000	0,546	0,019	0,132
LOCALIZACAO_ESCOLA	0,074	0,074	0,055	0,073	0,534	0,546	1,000	0,011	0,126
NACIONALIDADE	0,023	0,012	0,038	0,037	0,014	0,019	0,011	1,000	0,033

	TP_SEXO	TP_ESTADO_CIVIL	TP_COR_RACA	TP_LINGUA	TP_ST_CONCLUSAO	TIPO_ESCOLA	LOCALIZACAO_ESCOLA	NACIONALIDADE	UF_PROVA
UF_PROVA	0,036	0,034	0,176	0,249	0,099	0,132	0,126	0,033	1,000

24. Apêndice H: valores de Spearman (tabelas das figuras)

As figuras de Spearman mostram os gráficos, mas não dão para ler o valor de cada coluna. Este apêndice traz os números. O Spearman de uma coluna com a nota não depende das outras colunas do conjunto, então a tabela da Figura 10 (45 colunas do dataset 3) vale para todos os datasets que contenham a coluna. ρ positivo: quanto mais da coluna, maior a nota. Os valores do notebook 01 foram calculados nos 2.692.427 participantes com nota (antes da partição 80/20); os do dataset 6 (notebook 05) só no desenvolvimento. As matrizes completas ficam nas figuras; aqui estão os pares com $|\rho| \geq 0{,}50$ (limite de redundância: 0,70).

H.1 Dataset 2 antes de retirar as colunas DEP (Figura A7)

38 colunas, incluindo as quatro de dependência administrativa da escola (`DEP_*`), retiradas depois.

Coluna	O que é	ρ com a nota
`Q006`	renda familiar mensal	+0,457
`Q024`	computadores	+0,409
`Q003`	ocupação do pai ou responsável	+0,349
`Q002`	escolaridade da mãe ou responsável	+0,347
`Q004`	ocupação da mãe ou responsável	+0,346
`Q010`	carros	+0,339
`Q008`	banheiros	+0,339
`Q001`	escolaridade do pai ou responsável	+0,332
`Q018`	aspirador de pó	+0,303
`Q019`	televisores	+0,292
`Q016`	micro-ondas	+0,283
`Q013`	freezers	+0,276
`Q014`	máquina de lavar roupa	+0,266
`Q022`	celulares	+0,259
`Q009`	quartos para dormir	+0,227
`ESCOLA_PRIVADA`	escola privada (0/1)	+0,217
`DEP_PRIVADA`	escola privada, pela dependência (0/1)	+0,217

Coluna	O que é	ρ com a nota
Q021	TV por assinatura	+0,188
Q025	acesso à internet	+0,179
Q007	empregado doméstico	+0,177
Q023	telefone fixo	+0,144
Q017	máquina de lavar louça	+0,141
Q012	geladeiras	+0,139
Q015	máquina de secar roupa	+0,131
Q020	aparelho de DVD	+0,128
FUSAO_1	fusão das 4 colunas de situação escolar	+0,084
DEP_FEDERAL	escola federal (0/1)	+0,070
LOC_URBANA	escola em zona urbana (0/1)	+0,068
DEP_MUNICIPAL	escola municipal (0/1)	−0,005
LOC_RURAL	escola em zona rural (0/1)	−0,028
TP_ESTADO_CIVIL	estado civil	−0,031
Q011	motocicletas	−0,033
Q005	pessoas na residência	−0,045
DEP_ESTADUAL	escola estadual (0/1)	−0,107
ESCOLA_PUBLICA	escola pública (0/1)	−0,150
TP_SEXO	sexo	−0,165
TP_COR_RACA	cor/raça	−0,222
TP_LINGUA	língua estrangeira (inglês ou espanhol)	−0,287

H.2 Pares de colunas com |ρ| ≥ 0,50, por matriz

Antes da fusão (Figura A4; 26 pares, 2 casas como na matriz). Os três primeiros pares (acima de 0,70) levaram à fusão das quatro colunas de situação escolar.

Coluna 1	Coluna 2	ρ
TP_FAIXA_ETARIA	TP_ANO_CONCLUIU	+0,88
TP_FAIXA_ETARIA	TP_ST_CONCLUSAO	−0,84
TP_ST_CONCLUSAO	IN_TREINEIRO	+0,73
Q002	Q004	+0,66
Q006	Q010	+0,64

Coluna 1	Coluna 2	ρ
Q003	Q004	+0,63
Q001	Q003	+0,62
Q006	Q024	+0,61
Q001	Q002	+0,60
TP_FAIXA_ETARIA	IN_TREINEIRO	−0,60
Q006	Q008	+0,59
Q003	Q006	+0,58
Q004	Q006	+0,58
Q008	Q009	+0,56
Q008	Q010	+0,54
Q001	Q006	+0,53
Q006	Q014	+0,53
Q006	Q019	+0,53
Q001	Q004	+0,52
Q002	Q006	+0,52
Q006	Q022	+0,52
Q008	Q019	+0,52
Q006	Q018	+0,51
Q008	Q024	+0,51
Q010	Q024	+0,51
Q009	Q022	+0,50

Dataset 2 antes de retirar as `DEP_*` (Figura A8; 24 pares).

Coluna 1	Coluna 2	ρ
ESCOLA_PRIVADA	DEP_PRIVADA	+0,88
DEP_ESTADUAL	LOC_URBANA	+0,73
ESCOLA_PUBLICA	DEP_ESTADUAL	+0,68
Q006	Q010	+0,64
Q002	Q004	+0,63
Q006	Q024	+0,61
Q006	Q008	+0,59

Coluna 1	Coluna 2	ρ
Q001	Q003	+0,57
Q003	Q004	+0,57
Q001	Q002	+0,56
Q008	Q009	+0,56
Q004	Q006	+0,55
Q003	Q006	+0,54
Q008	Q010	+0,54
ESCOLA_PUBLICA	LOC_URBANA	+0,53
Q006	Q014	+0,53
Q006	Q019	+0,53
Q006	Q022	+0,52
Q008	Q019	+0,52
Q002	Q006	+0,51
Q006	Q018	+0,51
Q008	Q024	+0,51
Q010	Q024	+0,51
Q009	Q022	+0,50

Dataset 2 mais features antes de retirar as `DEP_*` (Figura A10; 28 pares).

Coluna 1	Coluna 2	ρ
ESCOLA_PRIVADA	DEP_PRIVADA	+0,88
DEP_ESTADUAL	LOC_URBANA	+0,73
ESCOLA_PUBLICA	DEP_ESTADUAL	+0,68
Q006	Q010	+0,64
Q002	Q004	+0,63
Q006	Q024	+0,61
Q022	CELULAR_POR_MORADOR	+0,60
Q006	Q008	+0,59
Q005	PESSOAS_POR_QUARTO	+0,58
PESSOAS_POR_QUARTO	CELULAR_POR_MORADOR	−0,57
Q001	Q003	+0,57

Coluna 1	Coluna 2	ρ
Q003	Q004	+0,57
Q001	Q002	+0,56
Q008	Q009	+0,56
Q004	Q006	+0,55
Q003	Q006	+0,54
Q008	Q010	+0,54
Q009	PESSOAS_POR_QUARTO	−0,54
ESCOLA_PUBLICA	LOC_URBANA	+0,53
Q006	Q014	+0,53
Q006	Q019	+0,53
Q006	Q022	+0,52
Q008	Q019	+0,52
Q002	Q006	+0,51
Q006	Q018	+0,51
Q008	Q024	+0,51
Q010	Q024	+0,51
Q009	Q022	+0,50

Dataset 2 final, sem as `DEP_*` (Figura A12; 21 pares, 3 casas).

Coluna 1	Coluna 2	ρ
Q006	Q010	+0,640
Q002	Q004	+0,628
Q006	Q024	+0,615
Q006	Q008	+0,589
Q003	Q004	+0,571
Q001	Q003	+0,570
Q008	Q009	+0,565
Q001	Q002	+0,562
Q004	Q006	+0,554
Q008	Q010	+0,544
Q003	Q006	+0,538

Coluna 1	Coluna 2	ρ
Q006	Q019	+0,531
ESCOLA_PUBLICA	LOC_URBANA	+0,531
Q006	Q014	+0,529
Q008	Q019	+0,519
Q006	Q022	+0,516
Q006	Q018	+0,514
Q008	Q024	+0,512
Q010	Q024	+0,511
Q002	Q006	+0,508
Q009	Q022	+0,501

Dataset 2 mais features final (Figura A14) e dataset 3 (Figura A15; 25 pares, 3 casas; os dois dão a mesma lista, porque as colunas extras do dataset 3 não chegam a 0,50 com ninguém).

Coluna 1	Coluna 2	ρ
Q006	Q010	+0,640
Q002	Q004	+0,628
Q006	Q024	+0,615
Q022	CELULAR_POR_MORADOR	+0,595
Q006	Q008	+0,589
Q005	PESSOAS_POR_QUARTO	+0,581
Q003	Q004	+0,571
Q001	Q003	+0,570
PESSOAS_POR_QUARTO	CELULAR_POR_MORADOR	−0,567
Q008	Q009	+0,565
Q001	Q002	+0,562
Q004	Q006	+0,554
Q009	PESSOAS_POR_QUARTO	−0,545
Q008	Q010	+0,544
Q003	Q006	+0,538
Q006	Q019	+0,531
ESCOLA_PUBLICA	LOC_URBANA	+0,531

Coluna 1	Coluna 2	ρ
Q006	Q014	+0,529
Q008	Q019	+0,519
Q006	Q022	+0,516
Q006	Q018	+0,514
Q008	Q024	+0,512
Q010	Q024	+0,511
Q002	Q006	+0,508
Q009	Q022	+0,501

H.3 Dataset 6, com as notas de outras áreas (diagnóstico, fora da solução)

Spearman de cada coluna com a nota de Matemática no desenvolvimento (notebook 05; 52 colunas). As quatro notas são as colunas mais associadas, e as três colunas `AUSENTE_*` do primeiro dia são idênticas (ρ = 1). A coluna `AUSENTE_CN` é constante e foi retirada.

Coluna	O que é	ρ com a nota
NU_NOTA_CH	nota de Ciências Humanas	+0,656
NU_NOTA_LC	nota de Linguagens e Códigos	+0,643
NU_NOTA_CN	nota de Ciências da Natureza	+0,643
NU_NOTA_REDACAO	nota de Redação	+0,527
Q006	renda familiar mensal	+0,457
Q024	computadores	+0,409
Q003	ocupação do pai ou responsável	+0,349
Q002	escolaridade da mãe ou responsável	+0,347
Q004	ocupação da mãe ou responsável	+0,346
Q010	carros	+0,339
Q008	banheiros	+0,339
Q001	escolaridade do pai ou responsável	+0,332
Q018	aspirador de pó	+0,303
Q019	televisores	+0,292
Q016	micro-ondas	+0,283
CELULAR_POR_MORADOR	criada: celulares por morador (Q022 / Q005)	+0,280
Q013	freezers	+0,276

Coluna	O que é	ρ com a nota
Q014	máquina de lavar roupa	+0,266
Q022	celulares	+0,259
Q009	quartos para dormir	+0,227
ESCOLA_PRIVADA	escola privada (0/1)	+0,217
Q021	TV por assinatura	+0,188
Q025	acesso à internet	+0,179
Q007	empregado doméstico	+0,177
Q023	telefone fixo	+0,144
Q017	máquina de lavar louça	+0,141
Q012	geladeiras	+0,139
Q015	máquina de secar roupa	+0,131
Q020	aparelho de DVD	+0,129
RENDA_MENOS_ESCOL	criada: renda menos escolaridade	+0,090
FUSAO_1	fusão das 4 colunas de situação escolar	+0,084
LOC_URBANA	escola em zona urbana (0/1)	+0,068
NAC_NATO_EXTERIOR	brasileiro nato no exterior (0/1)	+0,015
NAC_ESTRANGEIRO	estrangeiro (0/1)	−0,002
NAC_NAO_INFORMADO	nacionalidade não informada (0/1)	−0,010
AUSENTE_LC	ausente no 1º dia (Linguagens)	−0,019
AUSENTE_CH	ausente no 1º dia (Humanas)	−0,019
AUSENTE_REDACAO	ausente no 1º dia (Redação)	−0,019
LOC_RURAL	escola em zona rural (0/1)	−0,028
TP_ESTADO_CIVIL	estado civil	−0,031
Q011	motocicletas	−0,032
Q004_NAO_SEI	indicador: não sabe a ocupação da mãe	−0,043
Q005	pessoas na residência	−0,044
NAC_NATURALIZADO	brasileiro naturalizado (0/1)	−0,059
Q002_NAO_SEI	indicador: não sabe a escolaridade da mãe	−0,069
Q003_NAO_SEI	indicador: não sabe a ocupação do pai	−0,089
Q001_NAO_SEI	indicador: não sabe a escolaridade do pai	−0,091

Coluna	O que é	ρ com a nota
ESCOLA_PUBLICA	escola pública (0/1)	−0,150
TP_SEXO	sexo	−0,165
PESSOAS_POR_QUARTO	criada: pessoas por quarto (Q005 / Q009)	−0,221
TP_COR_RACA	cor/raça	−0,222
TP_LINGUA	língua estrangeira (inglês ou espanhol)	−0,287

Pares com |ρ| ≥ 0,50 no dataset 6 (inclui os pares com a nota de Matemática, NU_NOTA_MT).

Coluna 1	Coluna 2	ρ
AUSENTE_CH	AUSENTE_LC	+1,000
AUSENTE_CH	AUSENTE_REDACAO	+1,000
AUSENTE_LC	AUSENTE_REDACAO	+1,000
NU_NOTA_CH	NU_NOTA_LC	+0,788
NU_NOTA_CN	NU_NOTA_CH	+0,657
NU_NOTA_CH	NU_NOTA_MT	+0,656
NU_NOTA_LC	NU_NOTA_MT	+0,643
NU_NOTA_CN	NU_NOTA_MT	+0,643
Q006	Q010	+0,640
NU_NOTA_CN	NU_NOTA_LC	+0,636
Q002	Q004	+0,628
Q006	Q024	+0,615
Q022	CELULAR_POR_MORADOR	+0,595
Q006	Q008	+0,589
Q005	PESSOAS_POR_QUARTO	+0,581
Q003	Q004	+0,571
Q001	Q003	+0,570
PESSOAS_POR_QUARTO	CELULAR_POR_MORADOR	−0,567
Q008	Q009	+0,565
Q001	Q002	+0,562
Q004	Q006	+0,554
Q009	PESSOAS_POR_QUARTO	−0,545
Q008	Q010	+0,544

Coluna 1	Coluna 2	ρ
Q003	Q006	+0,538
Q006	Q019	+0,531
ESCOLA_PUBLICA	LOC_URBANA	+0,530
Q006	Q014	+0,529
NU_NOTA_REDACAO	NU_NOTA_MT	+0,527
Q008	Q019	+0,519
Q006	Q022	+0,517
NU_NOTA_CH	NU_NOTA_REDACAO	+0,516
Q006	Q018	+0,515
NU_NOTA_LC	NU_NOTA_REDACAO	+0,513
Q008	Q024	+0,512
Q010	Q024	+0,511
Q002	Q006	+0,508
Q009	Q022	+0,502

25. Apêndice I: perguntas prováveis da banca e respostas curtas

Para ensaiar o pitch. Todos os integrantes precisam saber responder pelas decisões. Os números são os medidos neste relatório.

#	Pergunta	Resposta e número que sustenta
1	Por que RMSE como métrica principal?	Está na mesma unidade da nota e pune mais os erros grandes. MAE e R^2 entram como complemento.
2	Por que 3 dobras e não 5 ou 10?	São 2,15 milhões de linhas e alguns modelos levam minutos por dobra. O desvio entre dobras já é pequeno (cerca de 0,2).
3	Como evitaram vazamento?	Tudo que se aprende dos dados (fusão, padronização, seleção, PCA, pesos) fica num Pipeline e é refeito só no treino de cada dobra. Notas de outras provas, gabarito e presença ficam fora.
4	Teve algum vazamento?	Sim, um pequeno: a fusão da situação escolar usava média e desvio de todas as linhas. Medimos 0,003 de RMSE e corrigimos dentro do Pipeline.
5	Por que o teste foi aberto uma vez só?	Para a estimativa não ficar otimista. Deu 105,81, contra 105,86 na validação.

#	Pergunta	Resposta e número que sustenta
6	Por que manter as notas zero?	É resultado observado e válido (0,62%). Tirar do treino não mudou o erro.
7	Por que não imputar a nota ausente?	Quem não tem nota (1.241.528) faltou ou foi eliminado. Não é zero, e sem alvo não há como treinar.
8	Por que o Gradient Boosting venceu?	Capta não linearidade e interação: 107,77 contra 111,15 da linear. O stacking empata e custa 5 vezes mais.
9	Por que o R^2 é só 0,35?	O perfil não mede esforço nem qualidade do ensino. Modelos muito diferentes param no mesmo patamar, e com as notas de outras áreas o R^2 sobe a 0,68.
10	É subajuste ou sobreajuste?	Sobreajuste não: treino 104,8 e validação 105,9. Subajuste não é conclusão segura: de 75% a 100% do treino, o ganho é 0,07. Aponta falta de informação.
11	Por que o PCA não ajudou?	Precisa de 18 de 30 componentes para 80% da variância, e o erro piora em todos os cortes.
12	Por que fundir as colunas e depois separar?	Quatro colunas tinham $\|\rho\|$ de até 0,885. Testamos fundidas e separadas, e as separadas ganharam 0,33.
13	Por que “não sei” virou ausente com indicador?	Não é um nível da escala. Quem não sabe tira de 40 a 50 pontos a menos, e a mediana apagaria isso.
14	Como escolheram os hiperparâmetros?	`RandomizedSearchCV`, 10 configurações, mesmas dobras, só no desenvolvimento. No boosting o ganho foi 0,09, dentro do desvio.
15	Por que não usaram Optuna?	Não está instalado, e o enunciado cita `RandomizedSearchCV`.
16	Por que os pesos por faixa não foram adotados?	Acima de 800 o RMSE cai de 185 para 155, mas o erro geral sobe 2,1.
17	Por que o modelo erra mais nas pontas?	Regressão à média: as previsões ficam entre 350 e 850. O viés é −510 nos zeros e +171 acima de 800.
18	O modelo serve para decidir sobre uma pessoa?	Não. O erro médio é de cerca de 82 pontos, e associação não é causa.
19	O modelo trata os grupos de forma parecida?	O viés médio é menor que 1 ponto por região, renda, escola e sexo (por UF, até 2,5). O RMSE varia de 97 a 113.
20	Vale a pena trocar a linear pelo boosting?	Ganha 3 pontos de RMSE, mas custa cerca de 30 vezes mais tempo (91 s contra 3 s por dobra).

#	Pergunta	Resposta e número que sustenta
21	A outra IA fez melhor?	Não: 107,53 no teste e 107,51 na validação cruzada, contra 105,81 e 105,86. O ganho dela vem do one-hot nos modelos lineares.
22	Por que usar o dataset 6 se é proibido?	Só como diagnóstico, para medir o vazamento. Fica fora da solução e o teste não foi aberto com ele.
23	A semente muda o resultado?	Quatro sementes variaram 0,009, bem menos que o desvio entre dobras.
24	Por que não usaram município?	Testamos depois de abrir o teste: −0,30 na validação cruzada. Não adotamos para não desfazer o protocolo.
25	Vale para outros anos ou escolas novas?	Não sabemos: só avaliamos o ENEM 2023 e participantes da mesma edição.
26	Como reproduzir?	Semente 42, partição e dobras em `dados/splits`, `requirements.txt`, notebooks 01 a 07 na ordem do README.
27	Quem fez o quê?	A tabela de contribuições está no README. Todos precisam saber responder pelas decisões.

26. Apêndice J: hipóteses candidatas para novos testes

Hipóteses além das 10 perguntas já respondidas, para a equipe escolher quais rodar. ★ marca as perguntas do enunciado que ficaram sem teste. Como o teste já foi aberto, qualquer uma só pode ser avaliada por validação cruzada no desenvolvimento e não altera a solução final. Custo: baixo (menos de 30 minutos), médio (1 a 3 horas), alto (mais que isso). Custo e ganho esperado são estimativas, não medidas.

#	Hipótese	Custo	Ganho esperado (palpite)
1 ★	Um modelo por região contra o nacional, nos mesmos participantes	baixo	pequeno
2 ★	Transformar o alvo (raiz, log ou ranking da nota)	baixo	pequeno, talvez ajude nas pontas
3 ★	Função de perda diferente (Huber, erro absoluto)	baixo	pequeno
4 ★	Dados externos por município (renda, IDH, população)	alto	médio, é o maior sinal que falta
5	Classificar “zero ou não” e depois regredir (dois estágios)	médio	ataca o erro de 515 nos zeros
6	Calibrar a previsão para reduzir a regressão à média	baixo	melhora o viés nas pontas

#	Hipótese	Custo	Ganho esperado (palpite)
7	Categóricas nativas do boosting no lugar de números	baixo	pequeno
8	Agrupar as 26 UFs em regiões	baixo	testa se as 26 colunas valem a pena
9	Interação renda × tipo de escola	baixo	pequeno
10	Interação renda × UF	baixo	pequeno
11	Remover treineiros	baixo	explica se o grupo atrapalha
12	Treinar com 25% das linhas	baixo	mostra que dá para ter a mesma solução com menos custo (106,25 na curva)
13	Retirar as colunas menos importantes pela permutação	baixo	solução mais simples sem perder erro
14	Oversampling das notas altas no lugar de pesos	baixo	compara com o balanceamento atual
15	Intervalos de previsão (regressão quantílica)	baixo	mede a incerteza por pessoa
16	Um modelo por sexo	baixo	testa se o padrão difere
17	Comparar com XGBoost ou LightGBM	médio	pequeno
18	Rede neural pequena (MLP)	médio	provavelmente igual ou pior
19	Busca no stacking	alto	pequeno, ele só empatou
20	Busca no KNN	alto	pequeno, o KNN ficou 3,8 atrás
21	Interpretação por SHAP em vez de permutação	médio	mais explicação, sem ganho de erro
22	Intervalo de confiança do teste por bootstrap	baixo	mede a incerteza da nota final
23	Erros por UF com modelo e sem a UF	baixo	confirma onde a UF ajuda