Previsão da nota de Matemática do ENEM 2023 a partir do perfil dos participantes

Relatório técnico detalhado do andamento

Projeto 2 · Ciência de Dados · Unidade II (Aprendizado de Máquina) · Unifor

Fonte: microdados do ENEM 2023 (Inep). Tarefa: regressão do alvo NU_NOTA_MT.

Data de elaboração: 10/11/2026

Equipe (conforme o README do repositório): João Igor Vidal de Andrade, Raquel Albuquerque Quirino, Amanda Lira e Sofya Oliveira.

Este documento reúne o que foi feito até agora: dados e protocolo, preparação, os quatro grupos de datasets, os modelos treinados, a busca de hiperparâmetros, o treino sem notas zero, a redução de dimensionalidade e a clusterização, com todos os gráficos gerados nos notebooks. O conjunto de teste continua reservado e não foi usado para escolher features, técnicas ou hiperparâmetros. Todos os números de desempenho são de validação cruzada de 3 dobras no desenvolvimento (80% dos participantes com nota).

Sumário

1. Resumo executivo 3
2. Dados e protocolo de avaliação 4
3. Exploração e preparação dos dados 5
4. Os datasets construídos 12
5. Modelos treinados (configuração inicial) 25
6. Busca de hiperparâmetros 41
7. Comparação entre os datasets 50
8. Treino sem as notas zero 52
9. Redução de dimensionalidade e clusterização 54
10. Discussão 58
11. Limitações, riscos e pendências 59
Apêndice A. Colunas usadas, criadas e removidas 60
Apêndice B. Espaços de busca 60
Apêndice C. Arquivos gerados 61

1. Resumo executivo

Objetivo: investigar quanto o perfil socioeconômico, escolar e demográfico dos participantes permite estimar a nota de Matemática do ENEM 2023 (regressão), comparando escolhas de preparação e de modelagem e explicando os resultados e os limites das previsões.

Principais resultados

- Base: 3.933.955 participantes; 2.692.427 com nota de Matemática observada (usados). Desenvolvimento: 2.153.941 (80%). Teste reservado: 538.486 (20%). Validação cruzada de 3 dobras (KFold, semente 42) só no desenvolvimento.
- Baseline (prever sempre a média): RMSE 131,634, R^2 0,000. Regressão linear: RMSE 111,153, R^2 0,287.
- Melhor modelo com configuração inicial: Gradient Boosting, RMSE 107,770 ± 0,226 e R^2 0,330 (18,1% menos erro que o baseline). O stacking (107,763) empata com ele e custa cerca de 5 vezes mais tempo.
- Modelos de árvores ganham da regressão linear (interações entre variáveis), mas o ganho é moderado: R^2 de 0,287 para 0,330. O KNN (111,575) ficou pior que a regressão linear e foi o mais lento (476 s por dobra).
- A busca de hiperparâmetros (RandomizedSearchCV, 10 configurações por modelo) deu ganhos pequenos: de 0,93 ponto de RMSE no bagging a 0,09 no Gradient Boosting (dentro do desvio). Ridge e SVR linear não mudaram.
- Mais colunas ajudam pouco: da regressão linear no dataset 1 (111,153) ao melhor dataset (110,378) são 0,8 ponto. Num teste à parte com Gradient Boosting leve, a UF da prova trouxe 0,64 ponto e o desdobramento da FUSAO_1 trouxe 0,47; juntos, 1,15.
- Tirar as notas zero (13.300 pessoas, 0,62%) só do treino de cada dobra não mudou o RMSE de forma mensurável nos quatro modelos testados (diferenças de −0,06 a +0,01, menores que o desvio de 0,18 a 0,22), embora os zeros respondam por 13,7% do erro ao quadrado da regressão linear.
- PCA piora o desempenho (Gradient Boosting: 107,77 sem PCA contra 110,17 com 25 componentes). K-means (2 grupos) não ajuda (107,79 contra 107,77). O t-SNE mostra pouca estrutura além de um gradiente renda × nota.

Conclusão central

Com o perfil dos participantes é possível estimar a nota de Matemática apenas de forma aproximada: o melhor modelo erra, em média, cerca de 107 pontos e explica cerca de um terço da variação da nota (R^2 de 0,33 a 0,34). O limite vem das informações disponíveis, não do algoritmo: o perfil indica a tendência do grupo, mas não o esforço de estudo, a qualidade do ensino recebido nem as circunstâncias do dia da prova. O PDF do projeto não exige R^2 mínimo e pede explicitamente discussão de ganhos pequenos e de limites.

2. Dados e protocolo de avaliação

Indicador	Quantidade
Registros na base bruta (76 colunas)	3.933.955
Sem nota de Matemática (fora da regressão, 31,56%)	1.241.528
Com nota de Matemática observada (usados, 68,44%)	2.692.427
Desenvolvimento (80%)	2.153.941
Teste reservado (20%)	538.486
Dobras da validação cruzada (3)	717.981 / 717.980 / 717.980
Notas zero no desenvolvimento	13.300 (0,62%)
Nota de Matemática no desenvolvimento: média e desvio padrão	533,83 e 131,63

Protocolo (conforme o PDF do projeto)

- Participantes com nota: divisão aleatória em 80% desenvolvimento e 20% teste, random_state=42, com os identificadores salvos em dados/splits/ (desenvolvimento_ids.csv, teste_ids.csv). Não há conjunto de validação separado.
- Validação cruzada apenas no desenvolvimento: KFold(n_splits=3, shuffle=True, random_state=42), com as dobras salvas em dobras_cv.csv e as mesmas dobras em todas as comparações.
- Baseline: DummyRegressor(strategy='mean'), com a média recalculada no treino de cada dobra.
- Métricas: RMSE (principal), MAE, R^2 e MSE, sempre na escala original da nota, com média e desvio padrão entre as dobras, mais o tempo.
- Nota ausente não é imputada nem vira zero. Treineiros e todas as faixas etárias foram mantidos. Nenhuma amostra por conveniência foi usada na comparação principal: os gráficos de dispersão e o t-SNE usam amostras apenas para desenhar.
- Ficam fora de X todas as notas de outras áreas e da redação, a presença, as respostas, o gabarito, os códigos da prova, o status da redação e o identificador (vazamento).

Observação sobre o teste: ele não foi usado para escolher features, técnicas ou hiperparâmetros. Na criação do split foi conferida apenas a distribuição da nota (média 533,84 e desvio 131,70 no teste, contra 533,83 e 131,63 no desenvolvimento).

3. Exploração e preparação dos dados

3.1 Triagem de valores ausentes

As colunas da escola têm 75,6% de valores ausentes na base completa (73,1% entre quem tem nota): o vazio corresponde a quem já concluiu o ensino médio, então tem significado. TP_ENSINO tem 66,0% de ausentes. As colunas de nota e de prova têm 31,6% ou 28,2% de ausentes porque a pessoa faltou ou foi eliminada. Candidatas com mais de 50% de ausentes foram removidas na primeira versão (7 colunas da escola e TP_ENSINO).

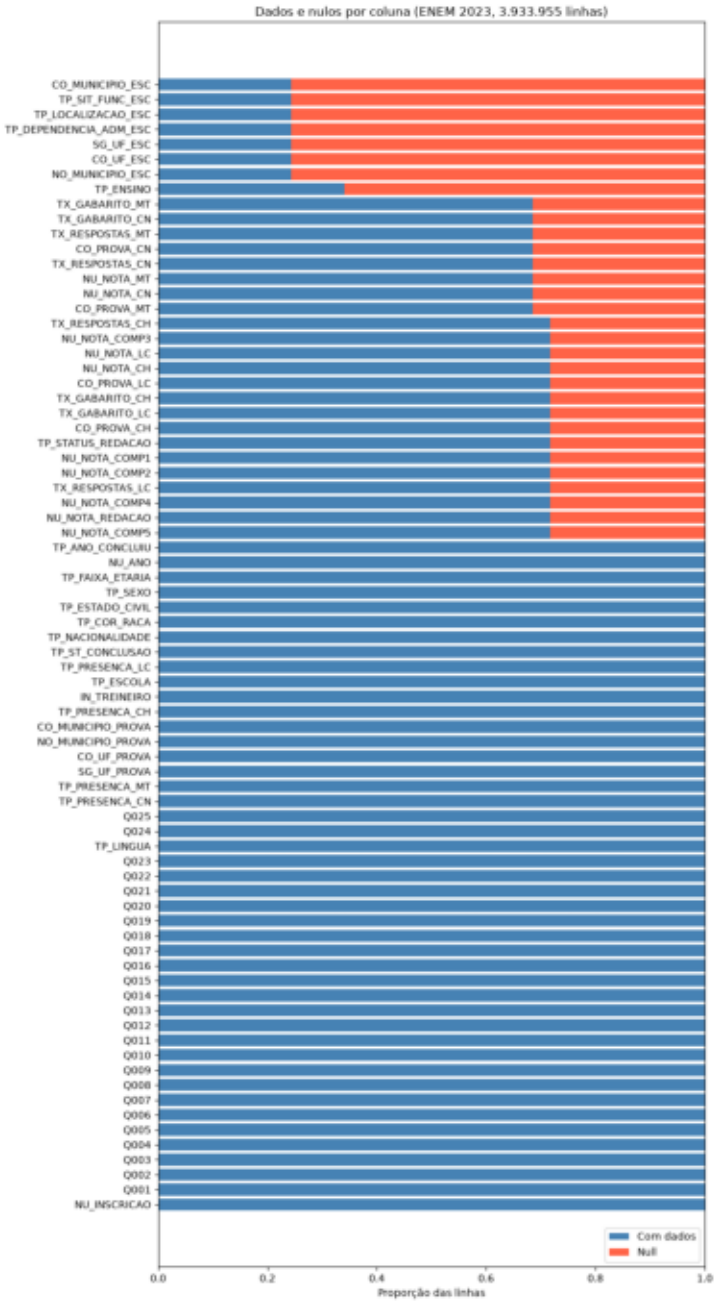


Figura 1. Proporção de dados e de valores ausentes em cada coluna da base bruta.

3.2 Exploração por sexo e língua estrangeira

Antes de qualquer tratamento, foi descrito quem faz mais o Enem e quem tira notas maiores. Os números usam as 2.692.427 linhas, ainda sem a divisão 80/20 (descrição apenas, nenhuma decisão do modelo sai daqui). Nas notas por língua, quem escolheu inglês tem média 74,5 pontos maior que quem escolheu espanhol (tamanho de efeito de 0,60 desvio padrão).

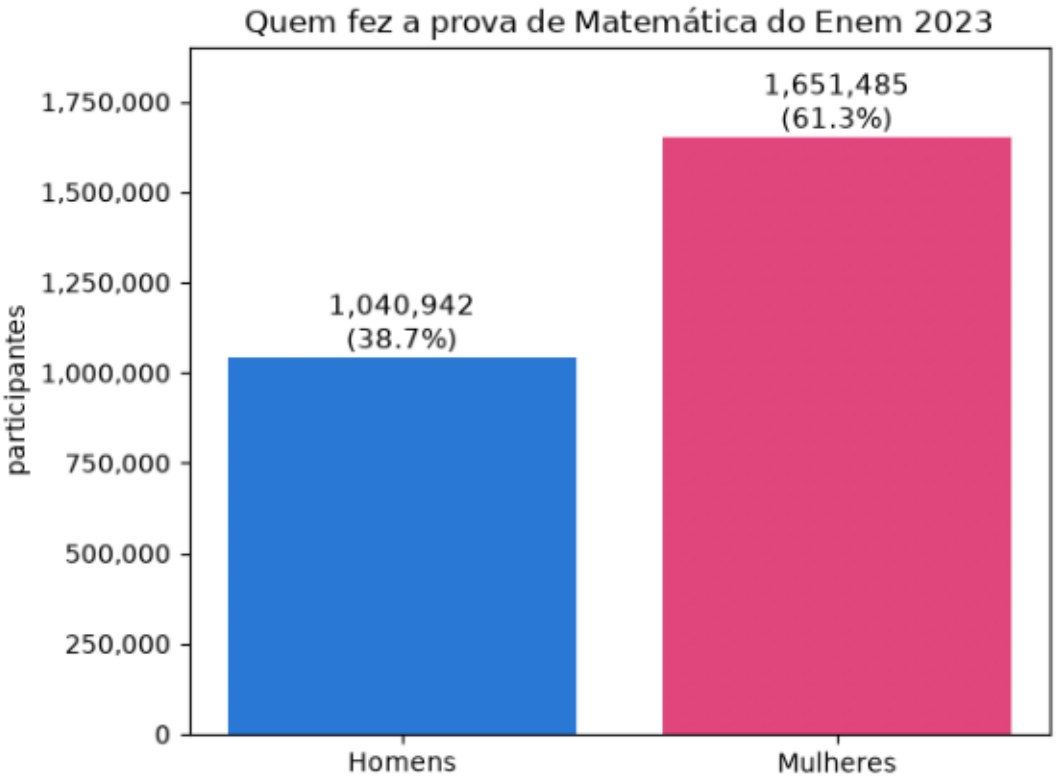


Figura 2. Participantes por sexo (com nota de Matemática).

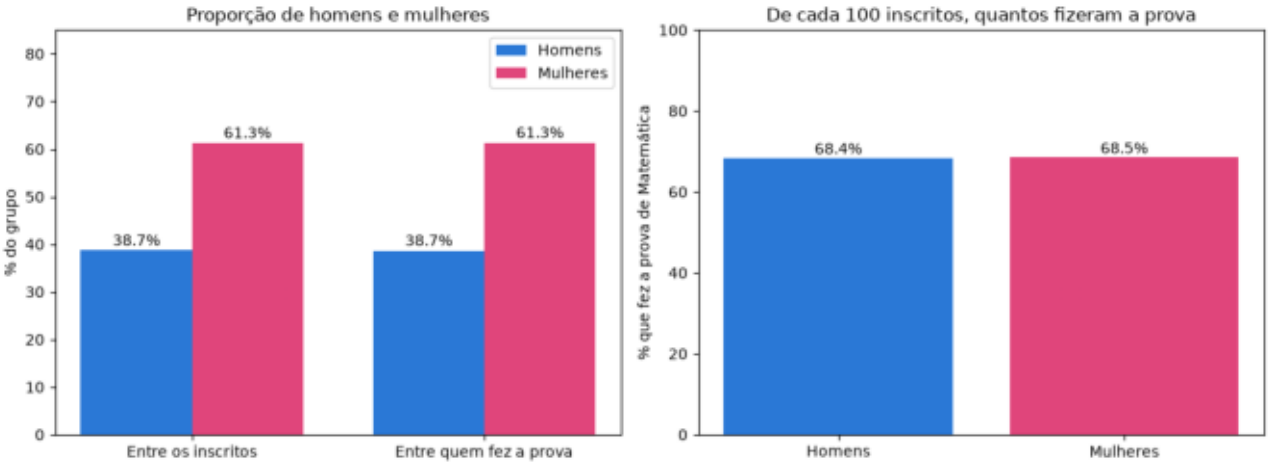


Figura 3. Participantes por sexo entre todos os inscritos, inclusive quem não tem nota.



Figura 4. Nota de Matemática por sexo.

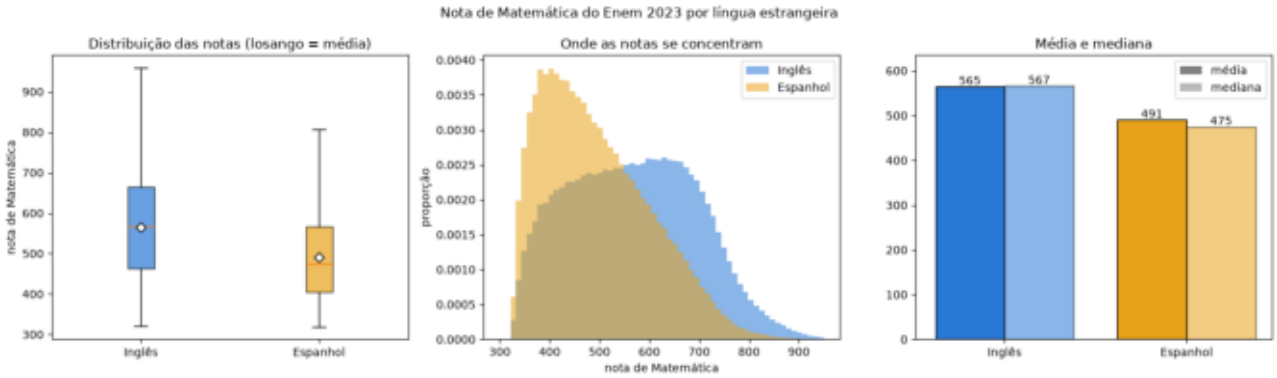


Figura 5. Nota de Matemática por língua estrangeira (inglês × espanhol).

3.3 Correlação de Spearman e fusão de colunas redundantes

A correlação de Spearman (correlação de ranking) foi usada para ver a relação de cada coluna com a nota e quais colunas se repetem. O limite de redundância adotado foi |Spearman| > 0,7. Colunas nominais (cor/raça, estado civil, nacionalidade, escola) não entram na fusão, porque o código numérico não tem ordem. Quatro colunas da situação escolar (IN_TREINEIRO, TP_ANO_CONCLUIU, TP_FAIXA_ETARIA, TP_ST_CONCLUSAO) ficaram redundantes entre si e foram trocadas por uma coluna só, a FUSAO_1: média dos z-scores, com inversão de sinal quando a correlação é negativa.

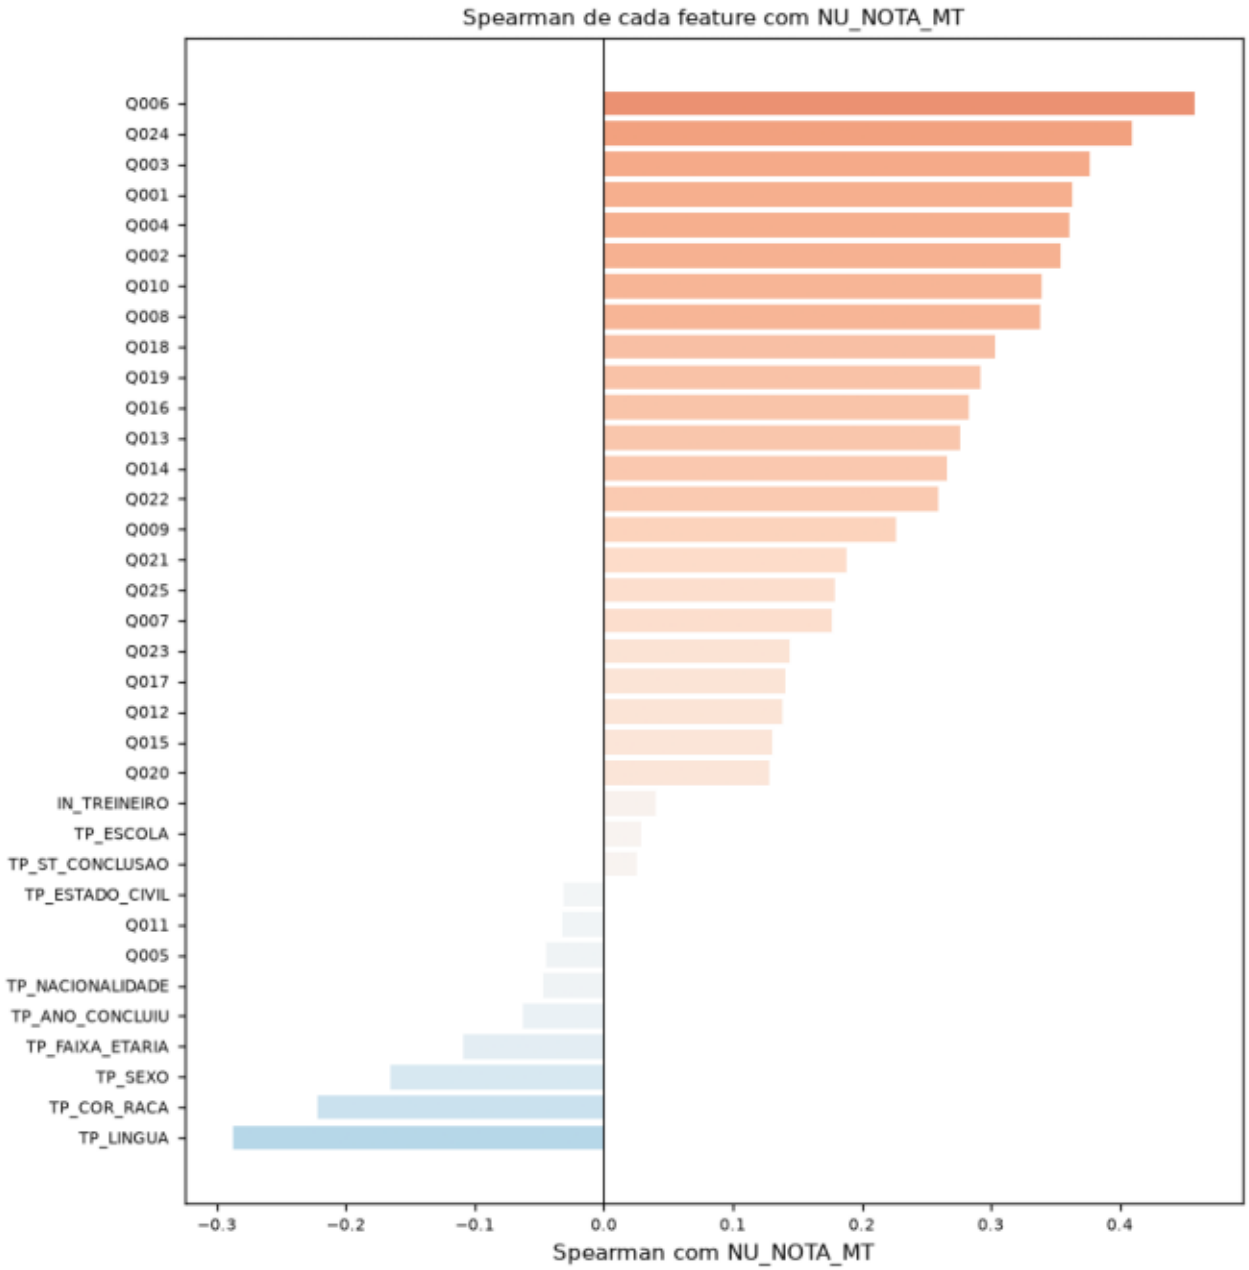


Figura 6. Spearman de cada feature com a nota, antes da fusão.

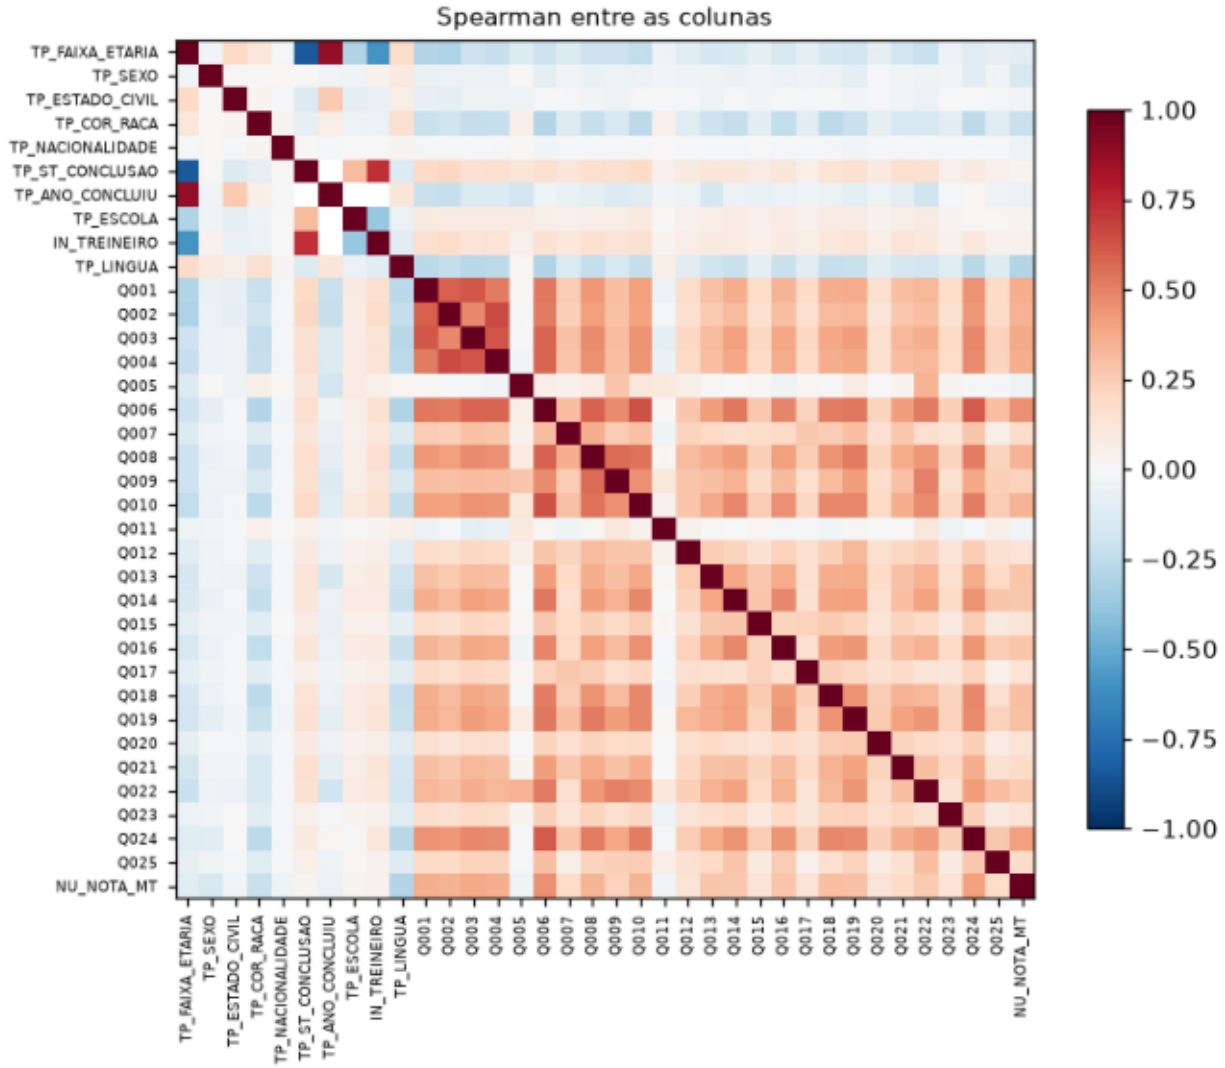


Figura 7. Matriz de Spearman entre as colunas, antes da fusão.

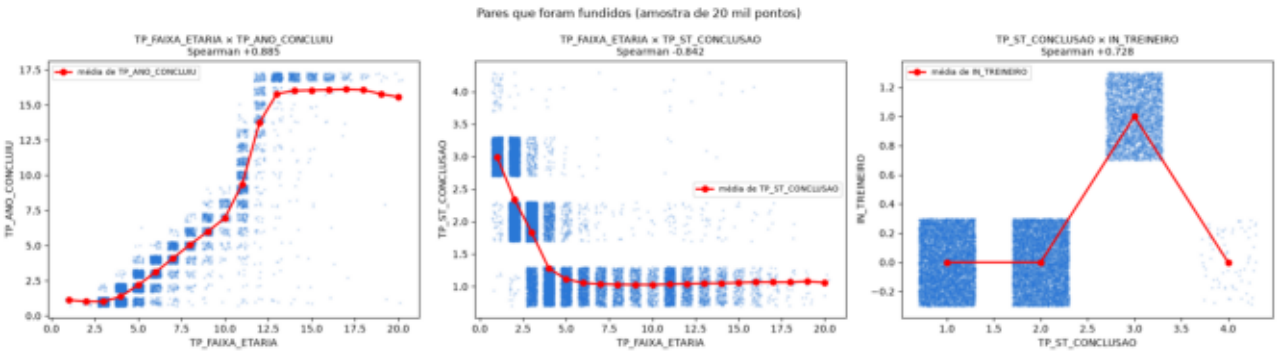


Figura 8. Exemplos de pares de colunas com Spearman alto (candidatos à fusão).

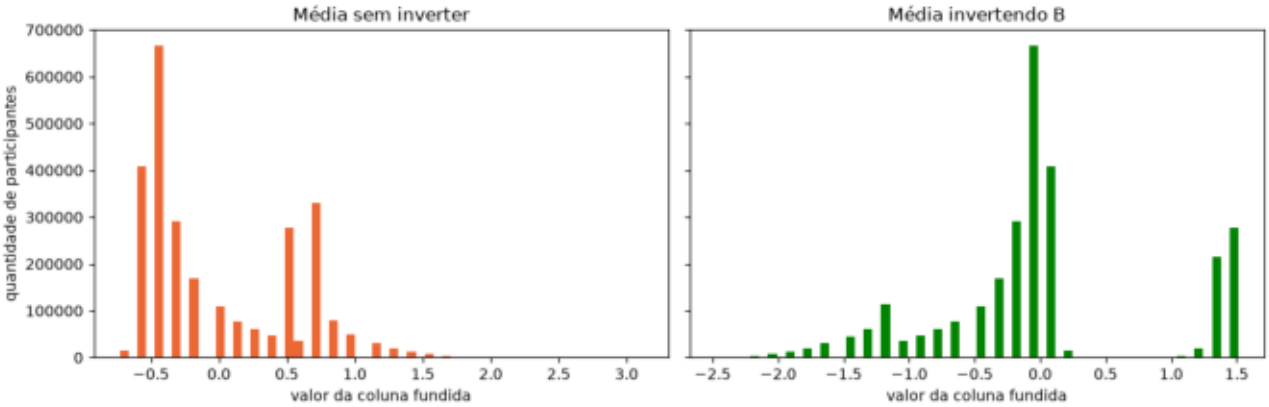


Figura 9. Fusão de IN_TREINEIRO e TP_FAIXA_ETARIA: média sem inverter o sinal contra média invertendo uma das colunas.

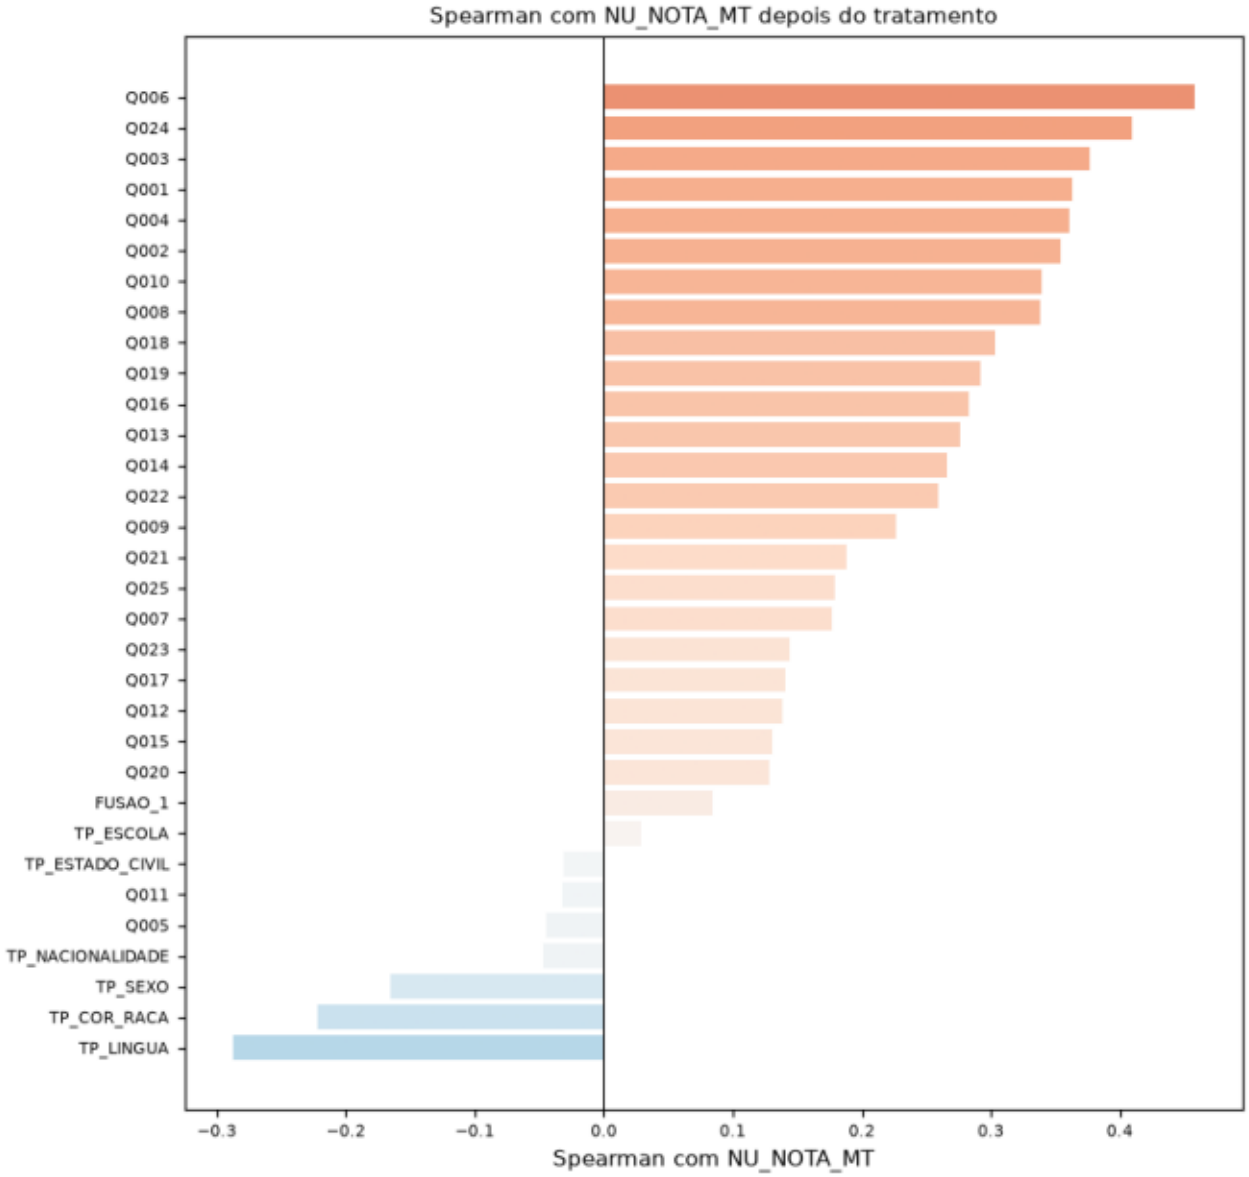


Figura 10. Spearman com a nota depois da fusão (dataset 1).

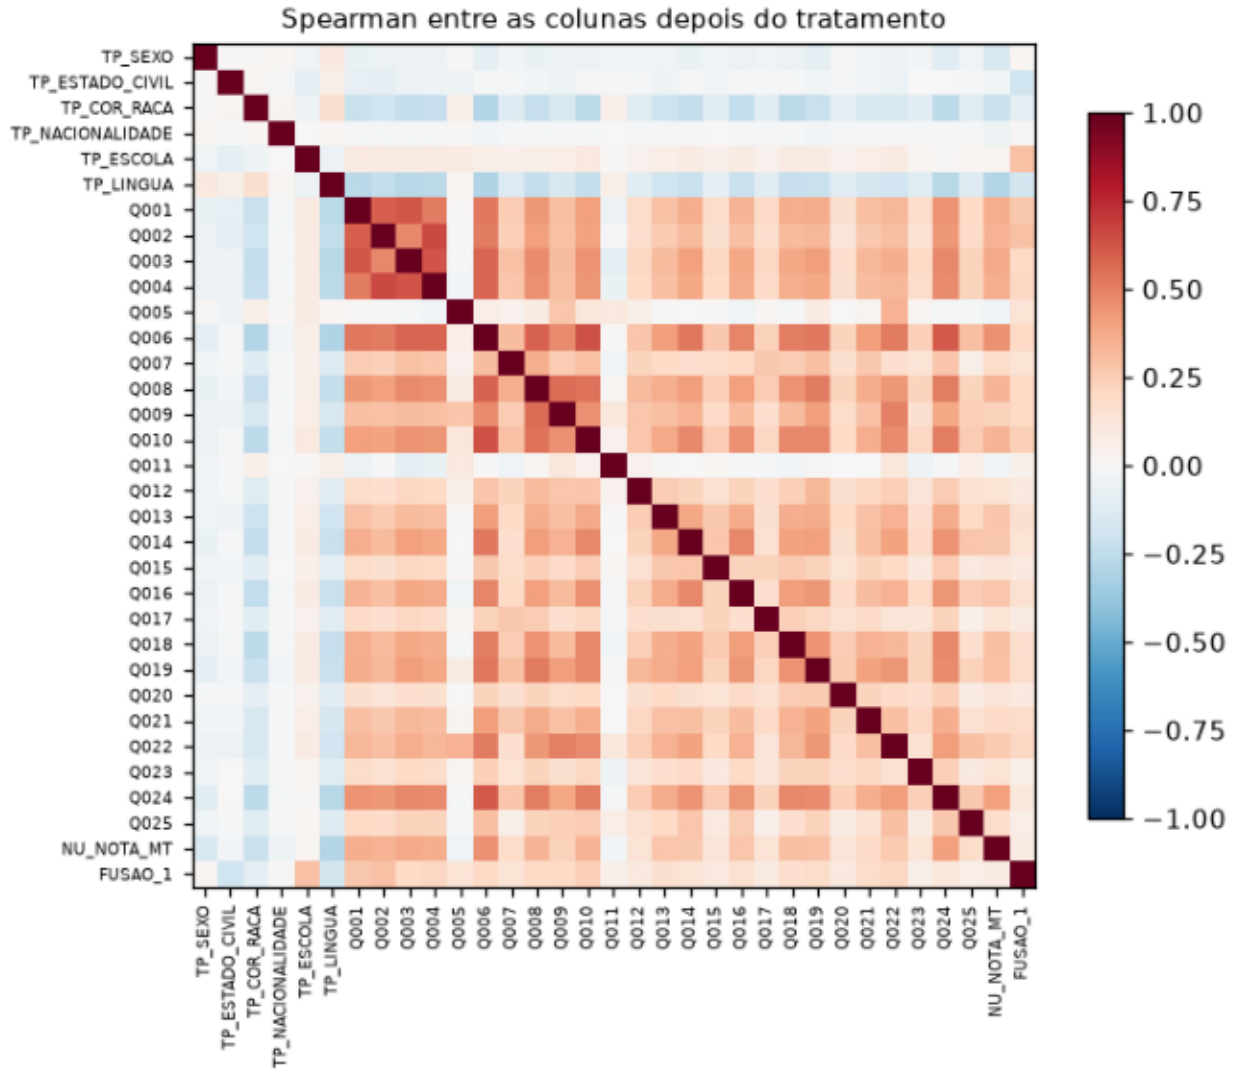


Figura 11. Matriz de Spearman depois da fusão (dataset 1).

3.4 Tratamento dos valores 'não sei' e revisão do dataset 1

As respostas 'não sei' de Q001 a Q004 (escolaridade e ocupação do pai e da mãe) viraram ausentes e foram preenchidas com a mediana de quem respondeu. Na revisão do dataset 1, saíram TP_NACIONALIDADE (97,8% são brasileiros), TP_ESCOLA (61% 'não respondeu') e as colunas indicadoras Q00X_NAO_SEI, por serem desproporcionais. O dataset 1 ficou com 30 features, sem nenhum valor ausente. Atenção: a média e o desvio da FUSAO_1 e as medianas do preenchimento foram calculados com todas as linhas (inclusive as do teste). É um vazamento pequeno que precisa ser refeito dentro do Pipeline antes do modelo final.

4. Os datasets construídos

Foram montados oito datasets, todos com as mesmas 2.692.427 linhas, na mesma ordem de ids_elegiveis.csv, sem valores ausentes e com o alvo NU_NOTA_MT na última coluna.

Dataset (arquivo)	Features	Composição
dataset_1_fundido	30	Perfil (sexo, estado civil, cor/raça, língua), Q001 a Q025 e FUSAO_1
dataset_1_features	33	Dataset 1 + 3 features criadas
dataset_2_escola	34	Dataset 1 + 4 colunas de escola (0/1): ESCOLA_PUBLICA, ESCOLA_PRIVADA, LOC_URBANA, LOC_RURAL
dataset_2_features_escola	37	Dataset 2 + 3 features criadas
dataset_3_sem_escola	38	Dataset 1 + 4 colunas NAO_SEI + 4 colunas de nacionalidade
dataset_3_sem_escola_features	41	Dataset 3 sem escola + 3 features criadas
dataset_3_escola	42	Dataset 2 + NAO_SEI + nacionalidade
dataset_3_escola_features	45	Dataset 2 + features + NAO_SEI + nacionalidade (o maior)

4.1 Features criadas (dataset 1 + features)

O PDF exige criar ao menos 3 features, cada uma com hipótese. A primeira versão (renda per capita, escolaridade máxima dos responsáveis e acesso digital) teve Spearman de 0,89 a 0,94 com as colunas de origem, ou seja, repetia informação, e foi descartada. Entre 29 candidatas testadas, ficaram as que passam de |Spearman| < 0,7 com todas as colunas e entre si.

Feature	Hipótese	Spearman com a nota
PESSOAS_POR_QUARTO (pessoas ÷ quartos, mínimo 1 quarto)	Casa mais lotada, menos espaço para estudar	−0,221
CELULAR_POR_MORADOR (celulares ÷ pessoas)	Mais celulares por pessoa, mais acesso próprio a conteúdo e aulas online	+0,280
RENDA_MENOS_ESCOL (renda 0 a 1 − escolaridade máxima 0 a 1)	Renda alta (ou baixa) para o nível de estudo da família carrega informação extra	+0,090

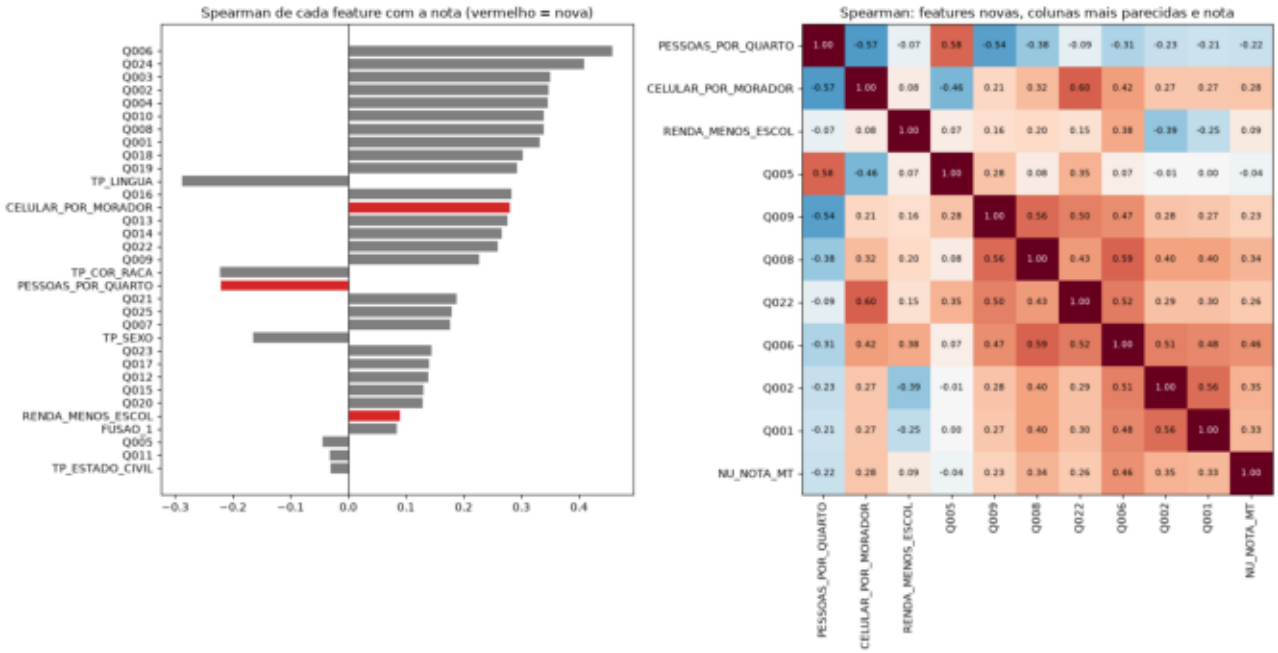


Figura 12. Spearman das três features criadas: com a nota, com as colunas mais parecidas e a matriz resumida.

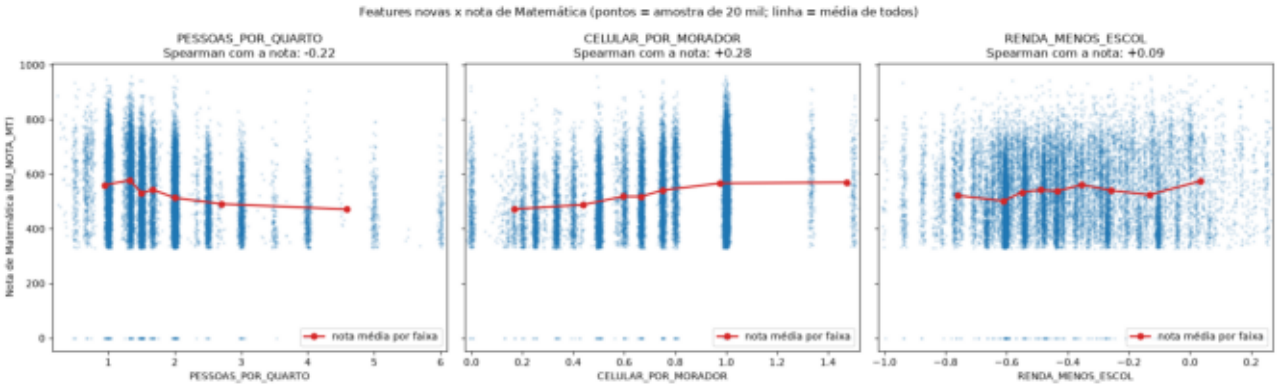


Figura 13. Dispersão das features criadas contra a nota de Matemática (pontos: amostra de 20 mil; linha vermelha: nota média por faixa, com todas as linhas).

4.2 Dataset 2: tipo de escola

As colunas da escola voltam como colunas 0/1 (one-hot), com a primeira categoria como referência. O vazio nas colunas da escola (73%, quem já concluiu o ensino médio) é a categoria 'sem informação', com todas as colunas da escola em 0: o vazio carrega informação, por isso não foi preenchido com mediana nem as linhas foram removidas (remover deixaria só 724.385 participantes e contraria o PDF). O Spearman mostrou pares redundantes entre as colunas de escola (ESCOLA_PRIVADA × DEP_PRIVADA, 0,88; DEP_ESTADUAL × LOC_URBANA, 0,73), e por isso as quatro colunas DEP_* foram retiradas. Ficaram ESCOLA_PUBLICA (−0,150 com a nota), ESCOLA_PRIVADA (+0,217), LOC_URBANA (+0,068) e LOC_RURAL (−0,028). Nenhum par passa de 0,7.

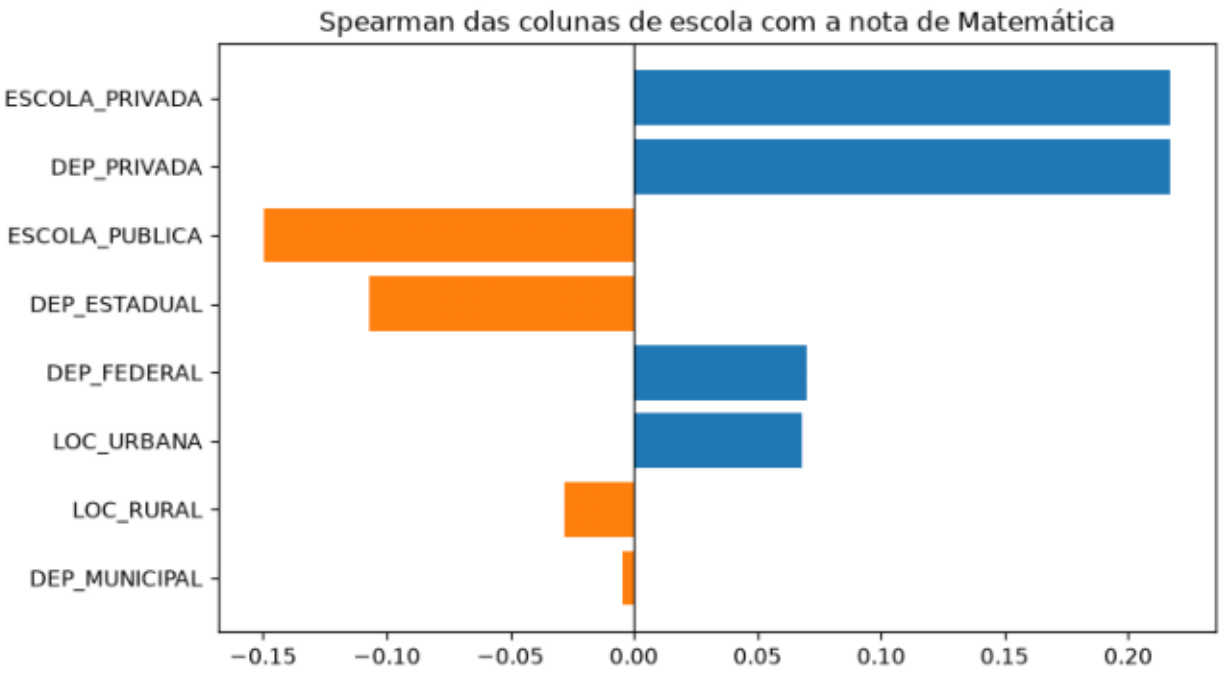


Figura 14. Spearman das oito colunas de escola com a nota (antes da retirada das DEP_*).

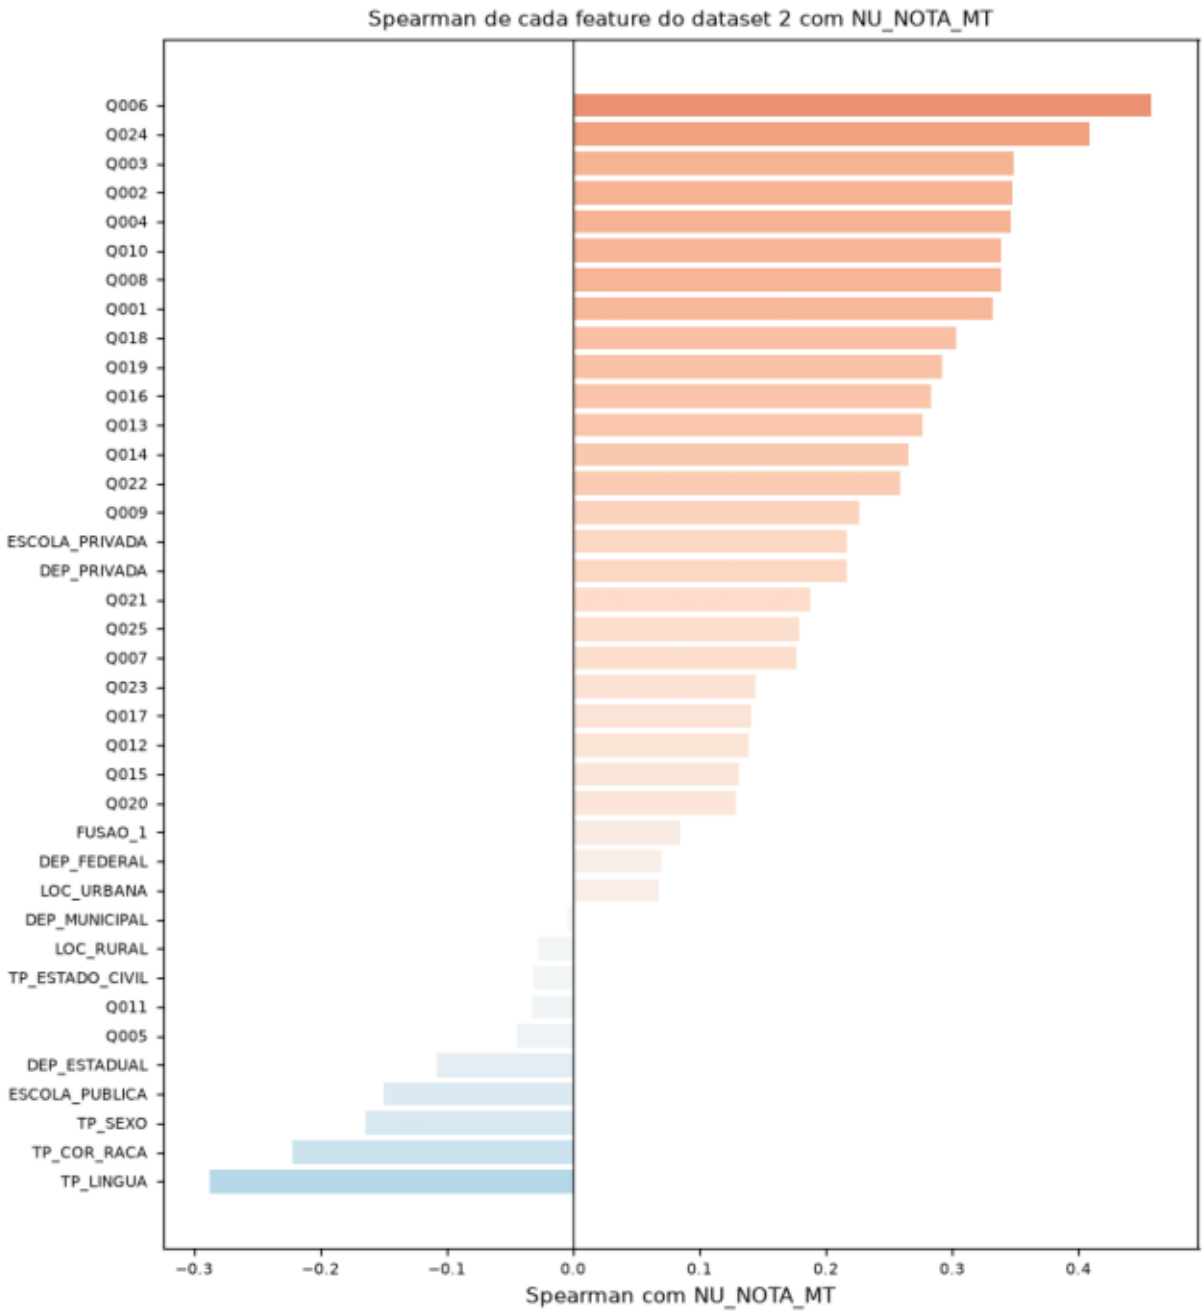


Figura 15. Dataset 2 antes da retirada das DEP_*: Spearman de cada feature com a nota.

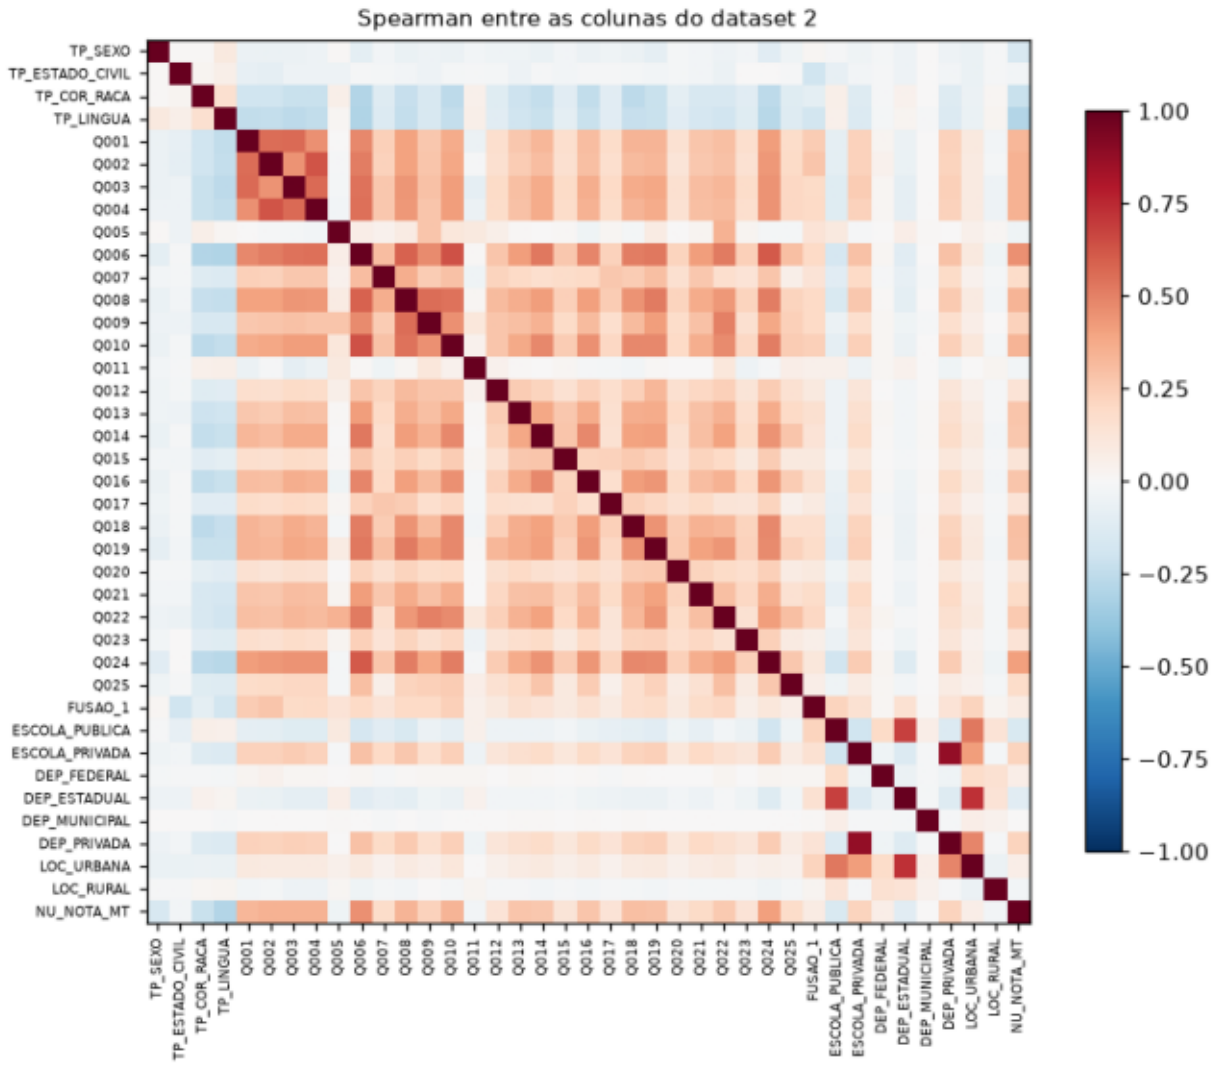


Figura 16. Dataset 2 antes da retirada das DEP_*: matriz de Spearman.

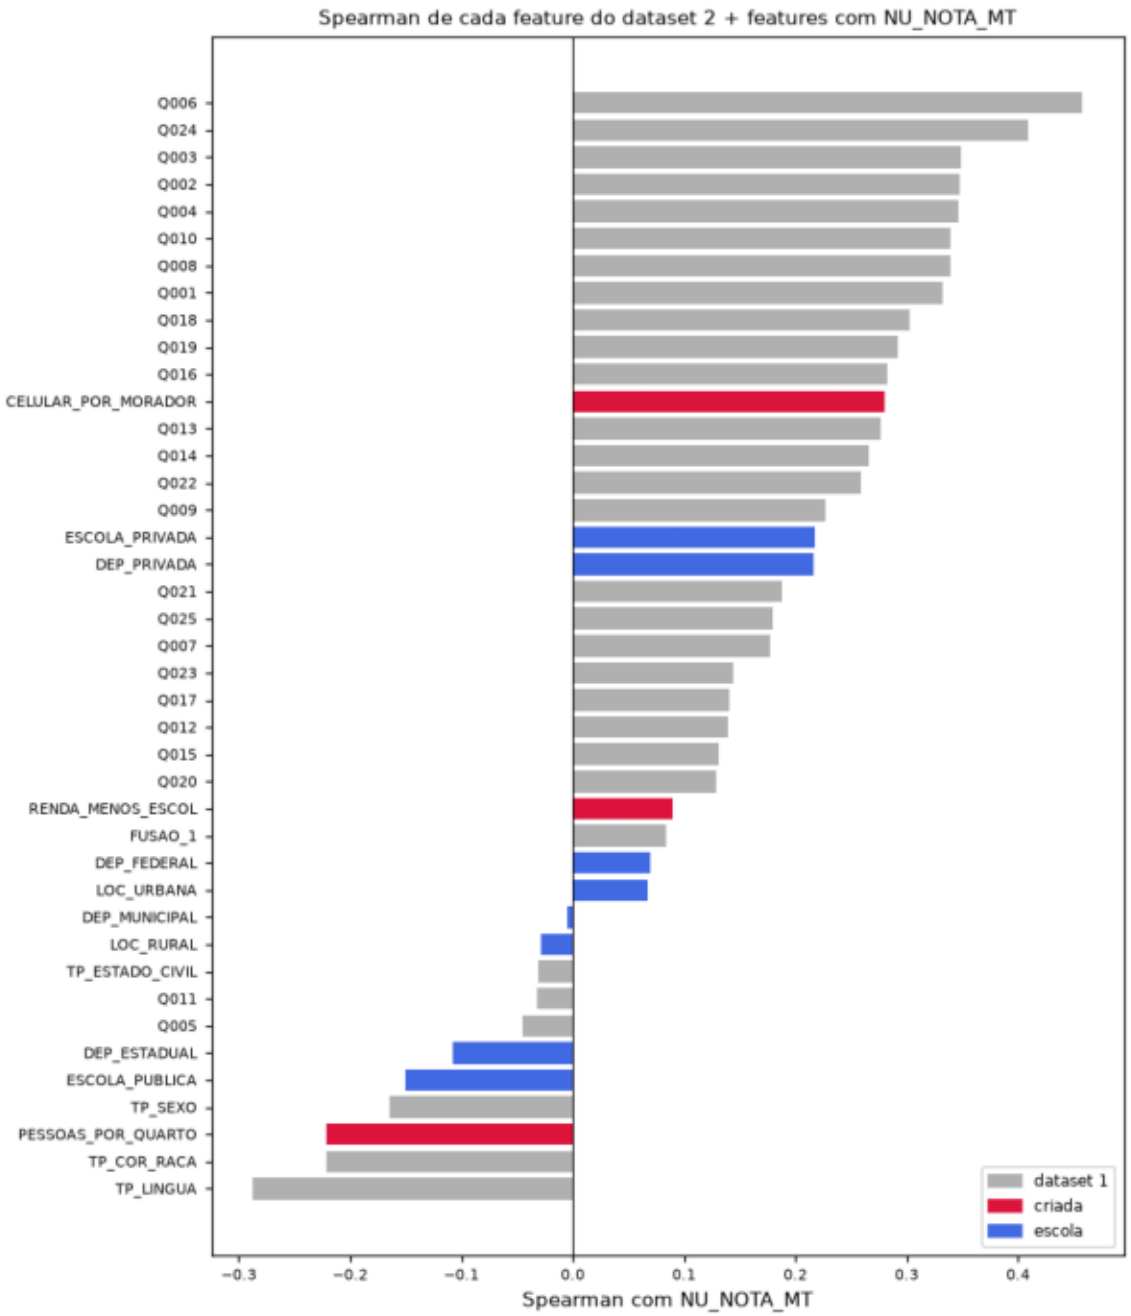


Figura 17. Dataset 2 + features antes da retirada: Spearman com a nota.

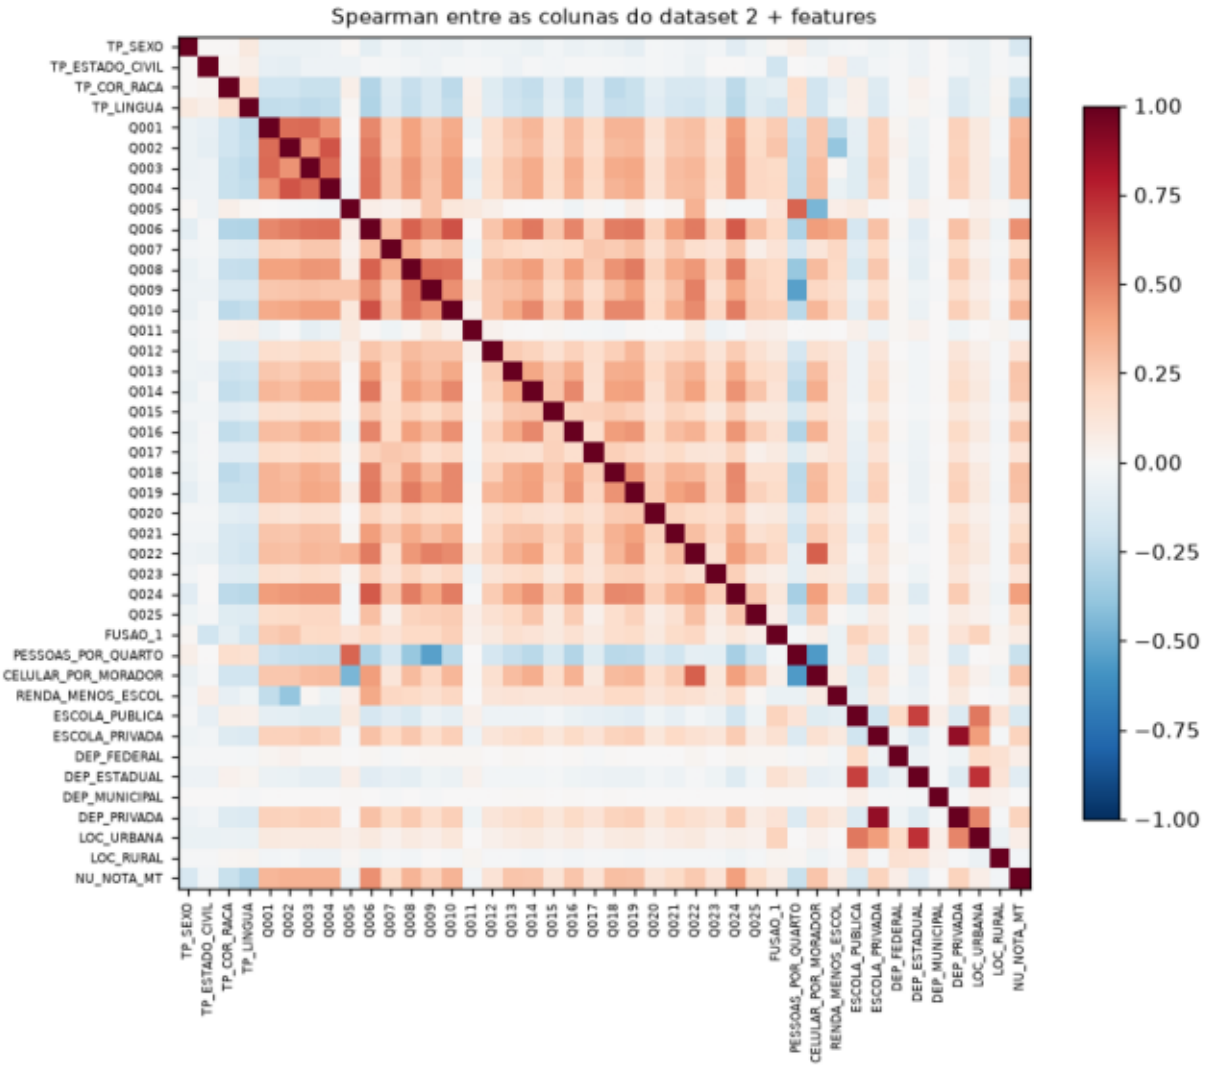


Figura 18. Dataset 2 + features antes da retirada: matriz de Spearman.

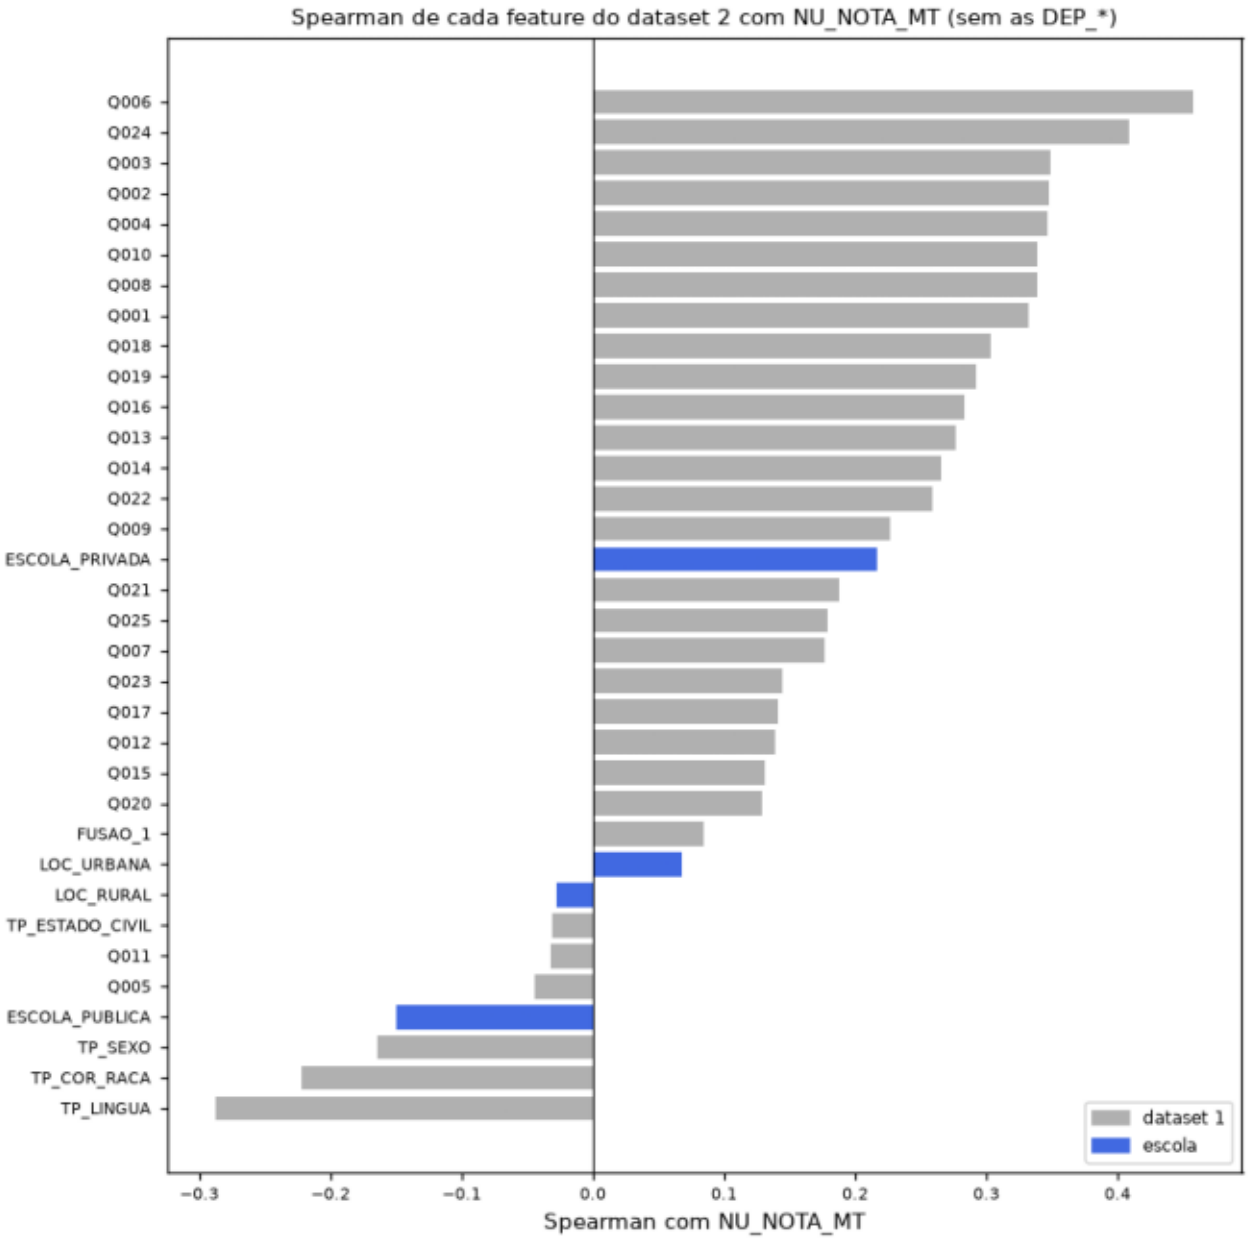


Figura 19. Dataset 2 final (sem as DEP_*): Spearman de cada feature com a nota.

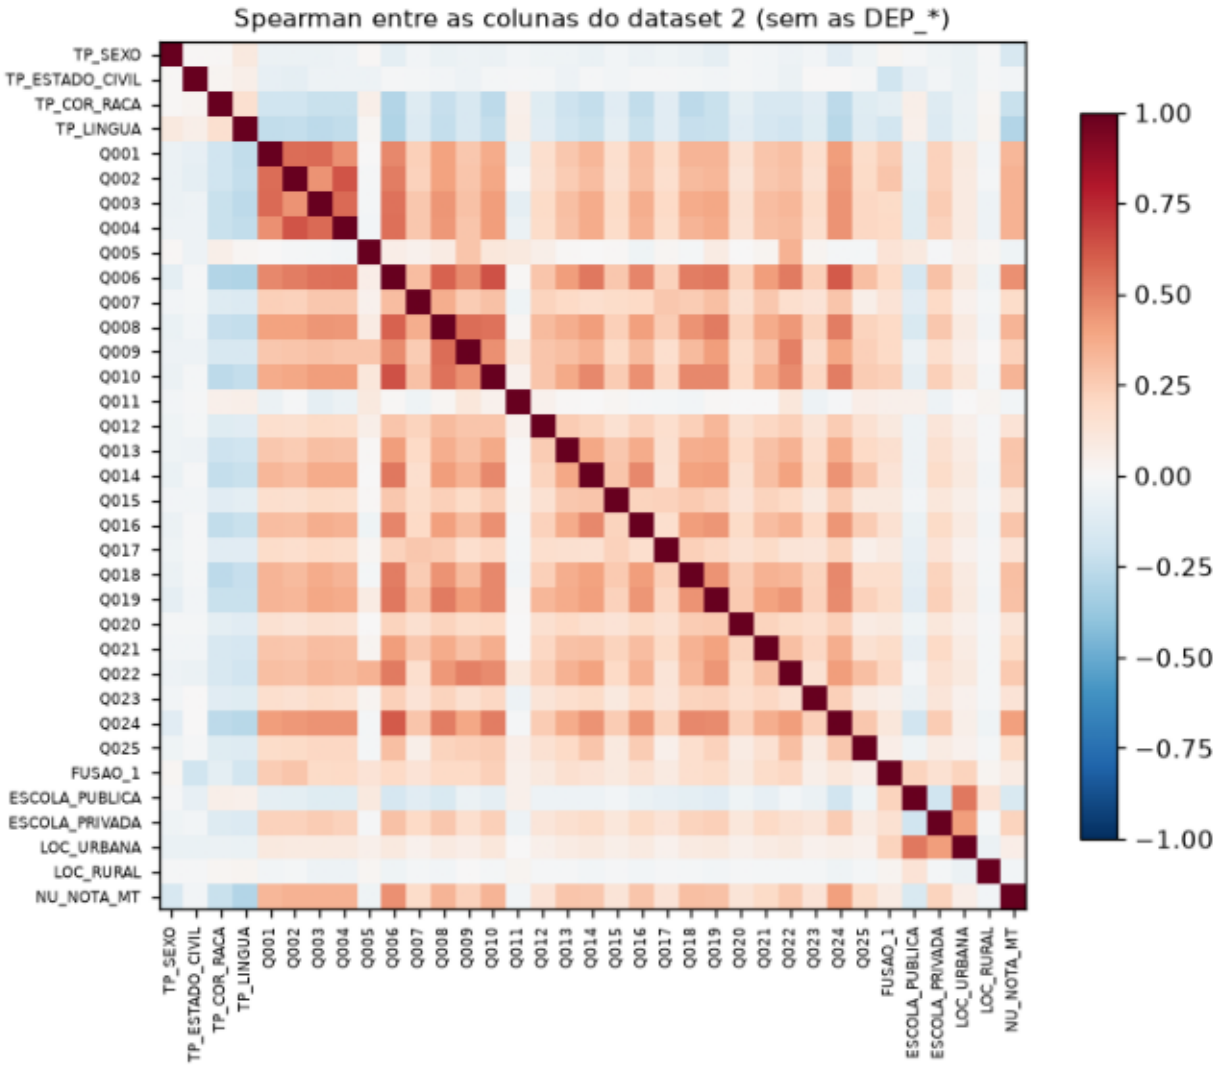


Figura 20. Dataset 2 final: matriz de Spearman.

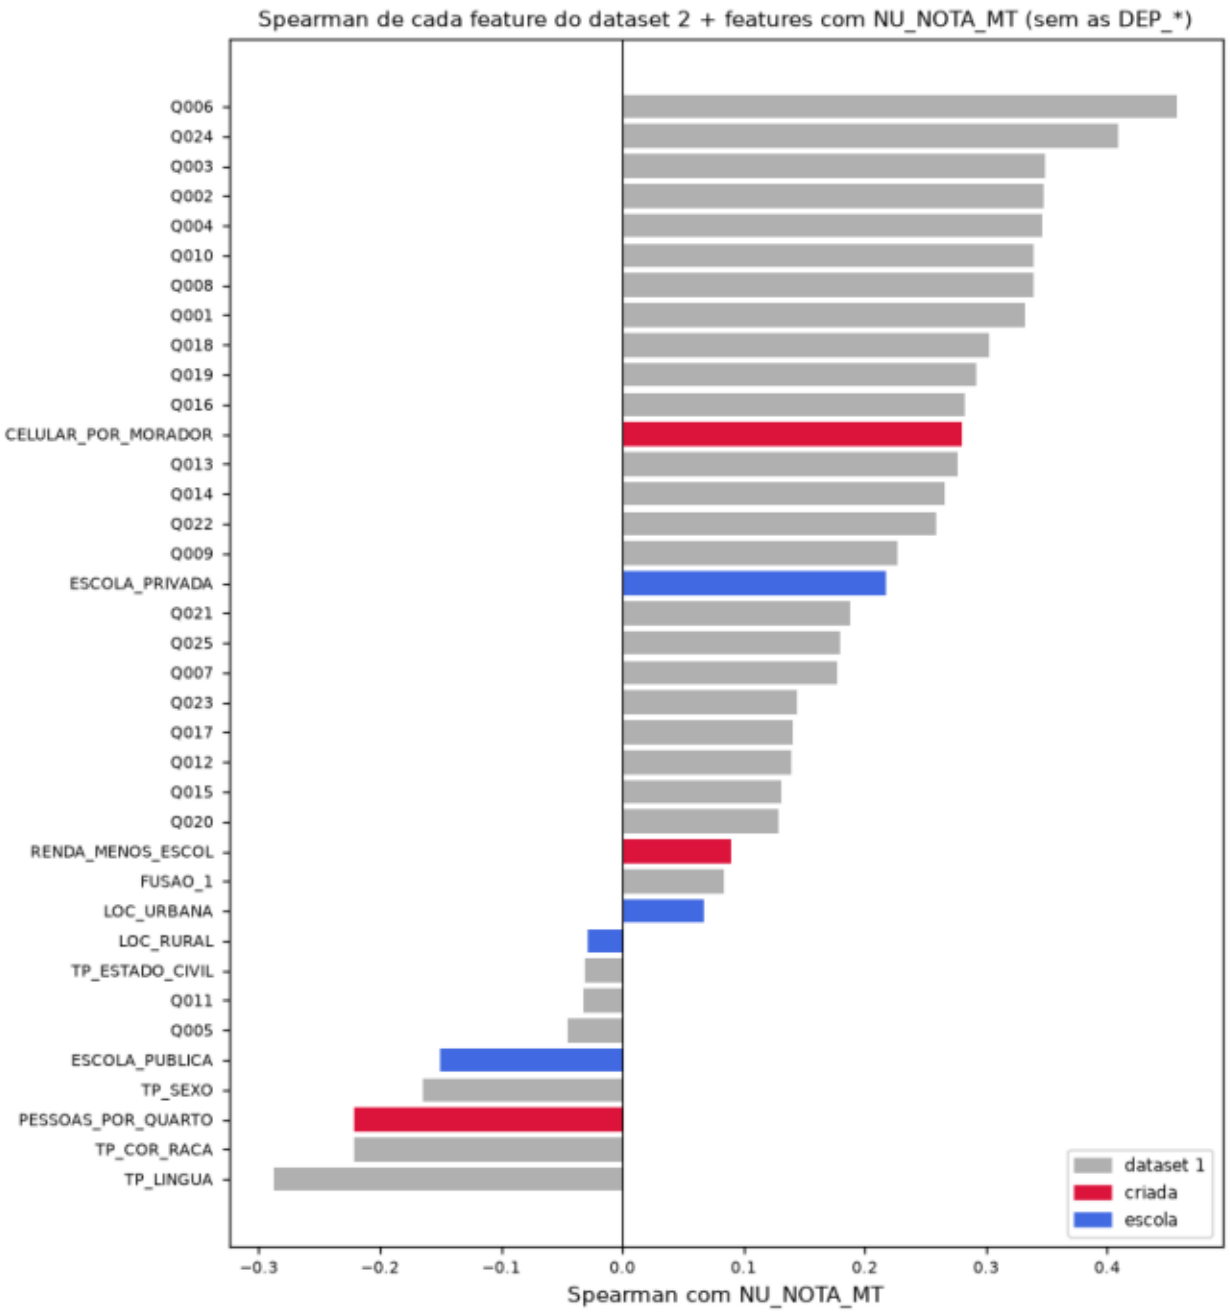


Figura 21. Dataset 2 + features final: Spearman de cada feature com a nota.

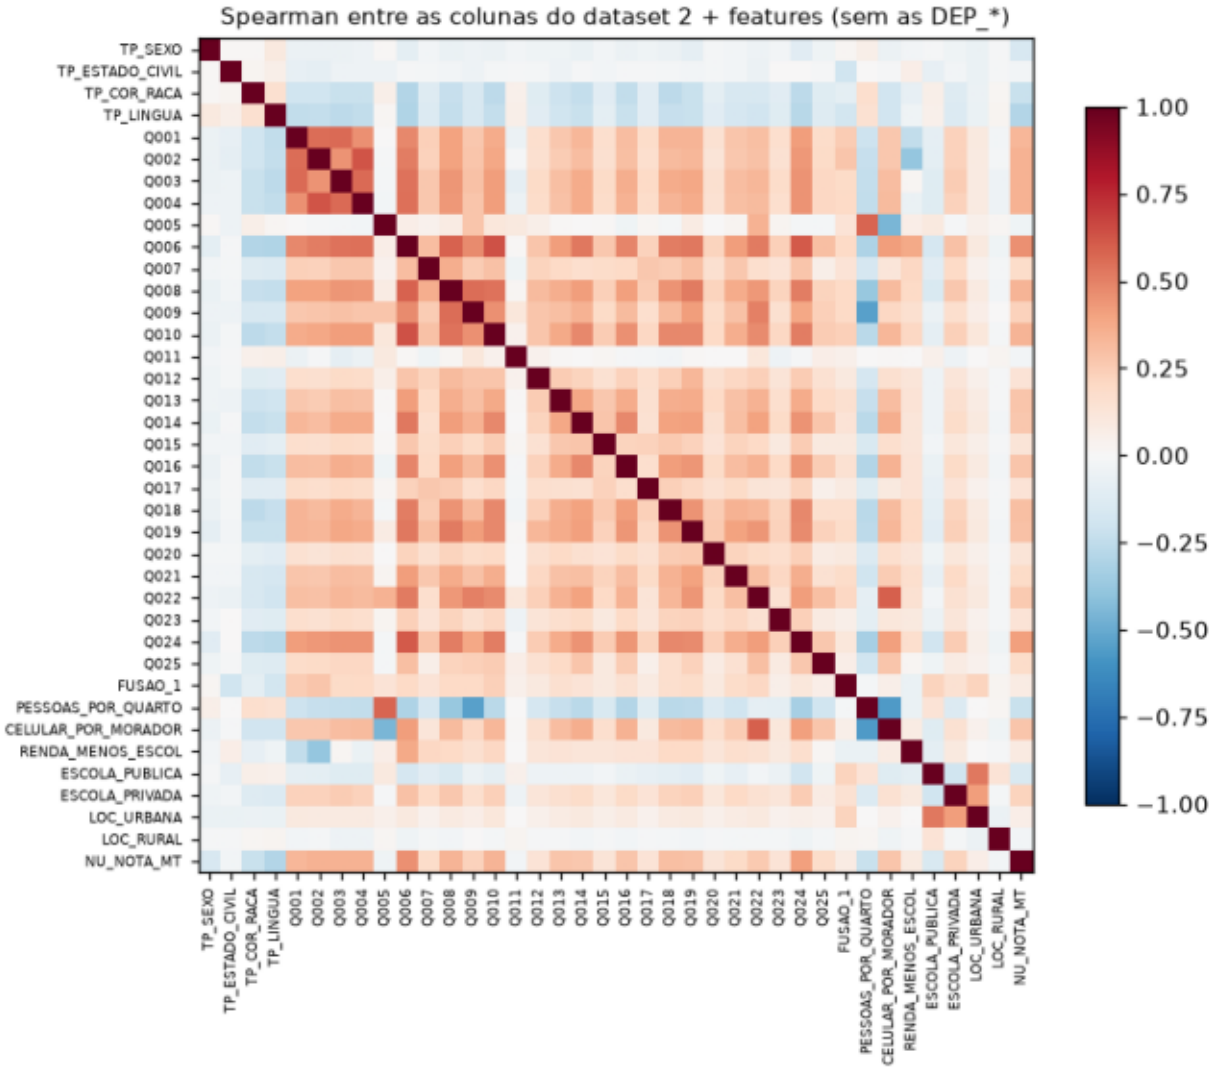


Figura 22. Dataset 2 + features final: matriz de Spearman.

4.3 Dataset 3: colunas 'desproporcionais' de volta

O dataset 3 traz de volta as colunas retiradas por desproporção, que ainda não estavam em nenhum dataset. As colunas NAO_SEI mostram que quem não sabe a escolaridade ou a ocupação dos pais tem nota média 40 a 50 pontos menor, informação que o preenchimento por mediana apagava. O dataset 3 sai em 4 tabelas (com e sem escola, com e sem features). Nenhum par passa de 0,7 de Spearman.

Coluna	O que é	Pessoas	Nota média (quem marcou)	Nota média (quem respondeu)
Q001_NAO_SEI	não sabe a escolaridade do pai	9,3%	497	538
Q002_NAO_SEI	não sabe a escolaridade da mãe	2,9%	483	535
Q003_NAO_SEI	não sabe a ocupação do pai	11,9%	502	538
Q004_NAO_SEI	não sabe a ocupação da mãe	8,7%	516	536

NAC_* (4 colunas)	TP_NACIONALIDADE em 0/1 (referência: brasileiro, 97,8%)	0,05% a 1,8%	478 a 575	535 (brasileiros)

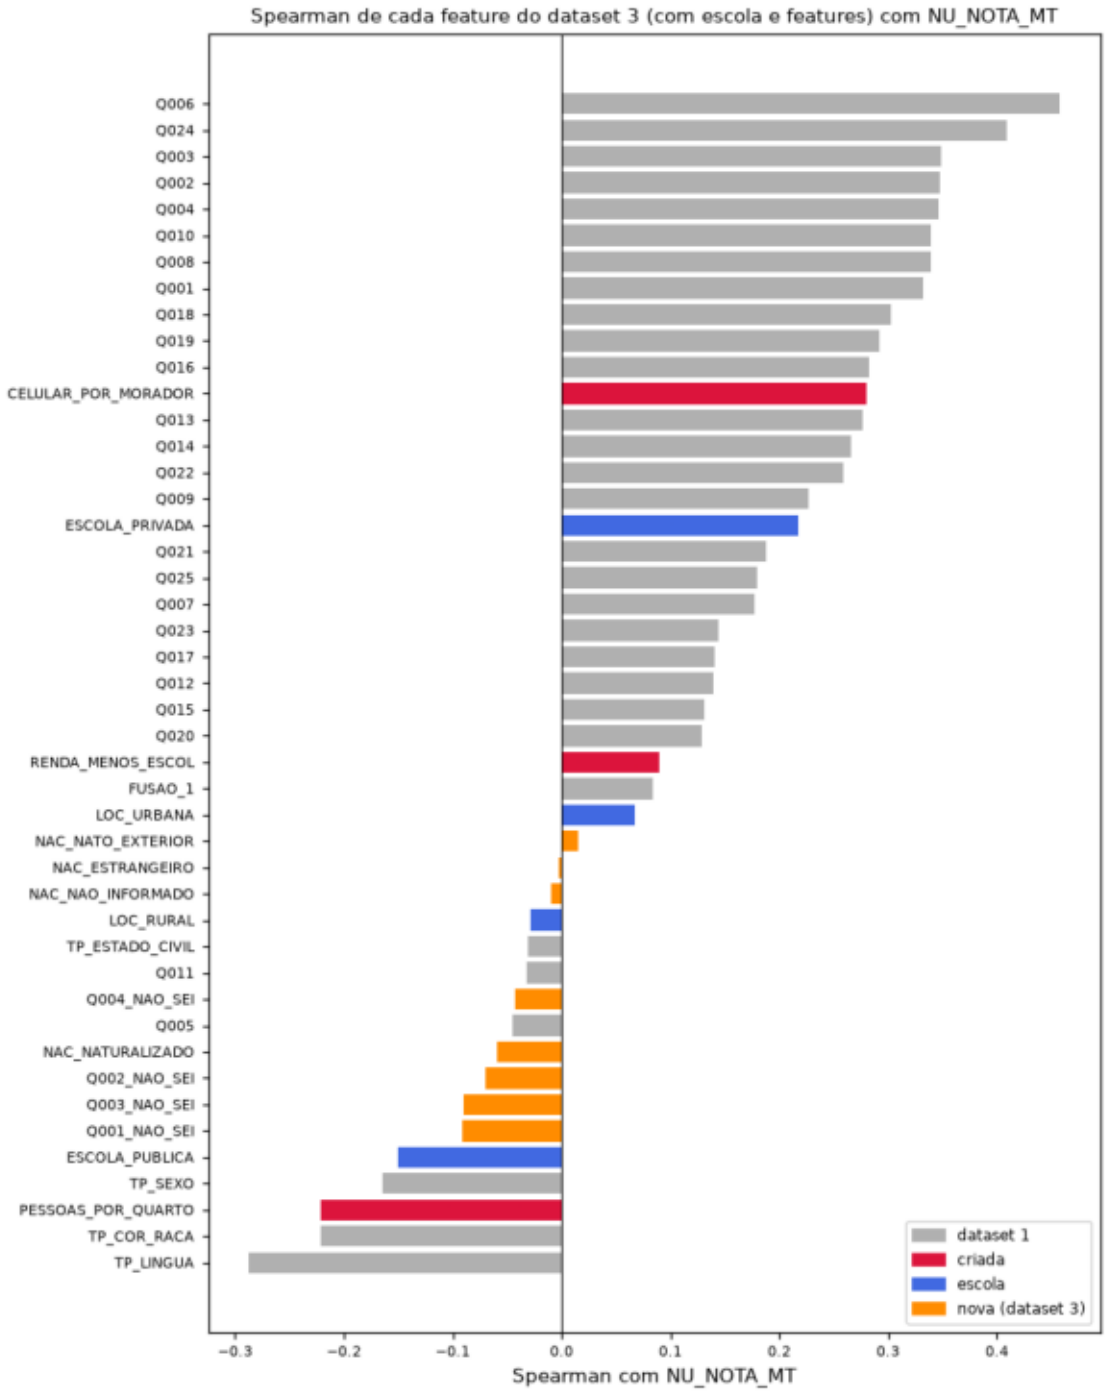


Figura 23. Dataset 3 (maior tabela): Spearman de cada feature com a nota.

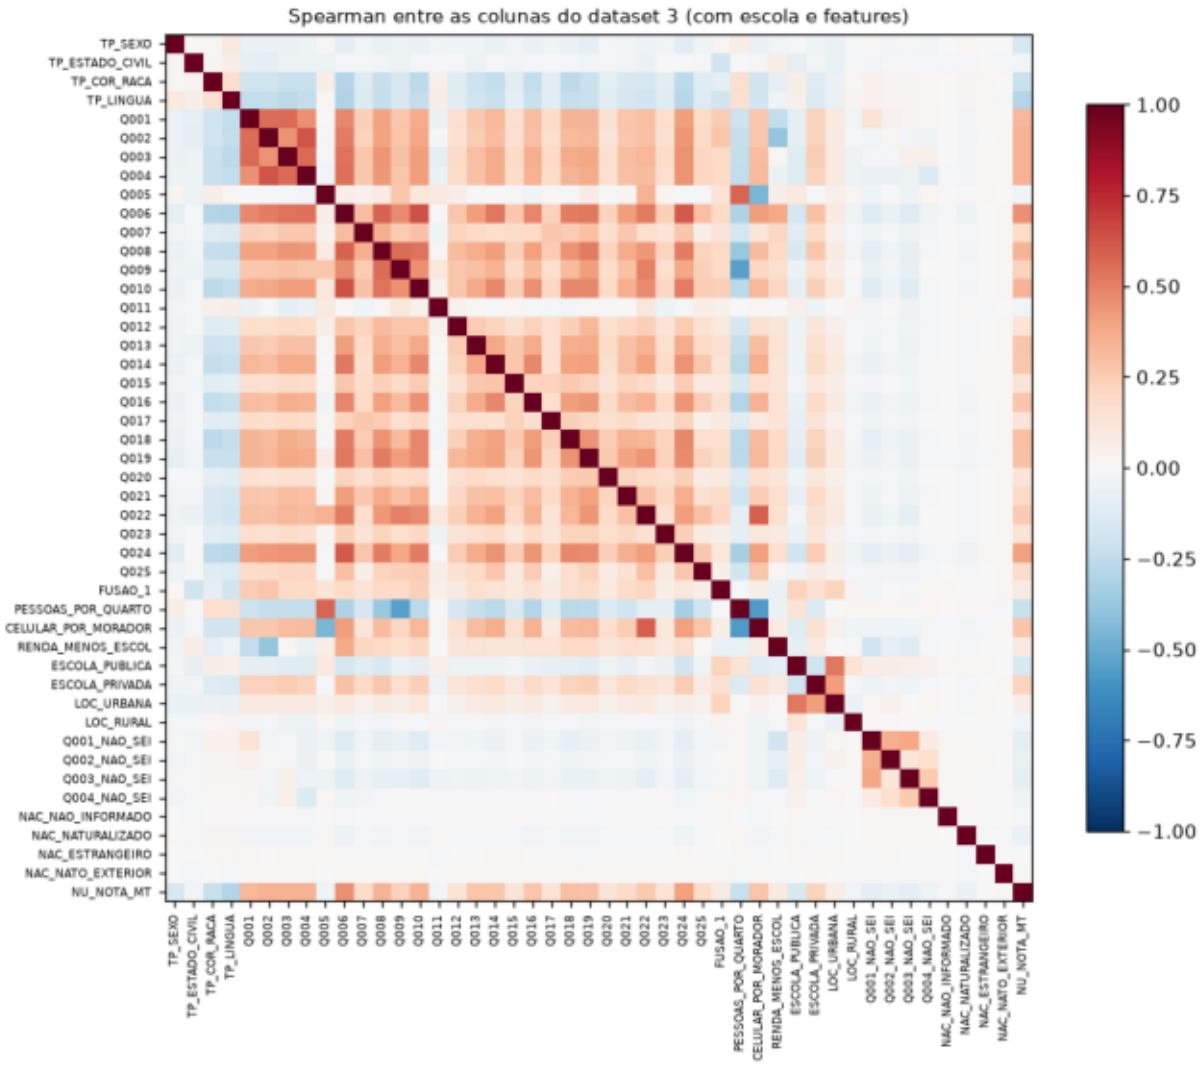


Figura 24. Dataset 3: matriz de Spearman.

5. Modelos treinados (configuração inicial)

Todos os modelos foram medidos no dataset_1_fundido (30 features), nas mesmas 3 dobras, com a configuração inicial registrada antes de qualquer busca. Quando o modelo usa distância ou pesos (regressão linear, KNN, SVR), há um StandardScaler dentro do Pipeline, ajustado só no treino de cada dobra.

Tabela 1. Validação cruzada de 3 dobras no desenvolvimento, dataset_1_fundido.

Modelo	RMSE (média ± desvio)	MAE	R^2	Tempo por dobra (s)	Menos erro que o baseline
Stacking	107,763 ± 0,226	83,804	0,330	630	18,1%
Gradient Boosting	107,770 ± 0,226	83,825	0,330	133	18,1%
Random Forest	109,422 ± 0,195	85,494	0,309	103	16,9%
Pasting	110,012 ± 0,208	85,996	0,302	20	16,4%
Bagging	110,014 ± 0,207	85,991	0,302	24	16,4%
Árvore de decisão	110,551 ± 0,190	86,381	0,295	3,0	16,0%
Ridge (alpha = 1)	111,153 ± 0,178	86,960	0,287	0,3	15,6%
Regressão linear	111,153 ± 0,178	86,960	0,287	0,7	15,6%
SVR linear (LinearSVR)	111,153 ± 0,178	86,961	0,287	1,9	15,6%
KNN (50 vizinhos)	111,575 ± 0,184	87,180	0,282	476	15,2%
Baseline (média)	131,634 ± 0,158	107,582	0,000	0,06	0,0%

- Configurações iniciais: árvore com max_depth=10 e min_samples_leaf=50; KNN com 50 vizinhos e algorithm='brute'; LinearSVR com C=1 e epsilon=0 (o SVR com kernel RBF custa o quadrado do tamanho da base e foi descartado, o que foi medido em amostras pequenas); bagging com 20 árvores e bootstrap=True; pasting com 20 árvores, bootstrap=False e max_samples=0,5; Random Forest com 100 árvores, max_depth=12, min_samples_leaf=50 e max_features=0,5; Gradient Boosting (HistGradientBoostingRegressor) com learning_rate=0,1, até 300 árvores de 31 folhas e parada antecipada com 10% do treino da dobra; stacking com Ridge, árvore e Gradient Boosting como base e Ridge como modelo final.
- Ridge e regressão linear dão o mesmo resultado: com 2 milhões de linhas e colunas pouco redundantes, a regularização quase não pesa. O SVR linear também chega ao mesmo ponto.
- A diferença entre os modelos não lineares e a regressão linear (3,4 pontos de RMSE no melhor caso) indica alguma interação entre variáveis, mas o ganho é moderado: o limite está na informação dos dados.
- O stacking empata com o Gradient Boosting (diferença de 0,007 ponto, muito menor que o desvio de 0,226) e custa cerca de 5 vezes mais, então não se justifica.

5.1 Baseline

Prever sempre a média (533,8) erra, em média, o próprio desvio padrão da nota (RMSE = 131,634 = desvio padrão) e tem R^2 igual a zero. É a régua: qualquer modelo útil precisa ter RMSE menor e R^2 maior que zero. Na dispersão de nota real contra nota prevista, o baseline é uma reta horizontal.

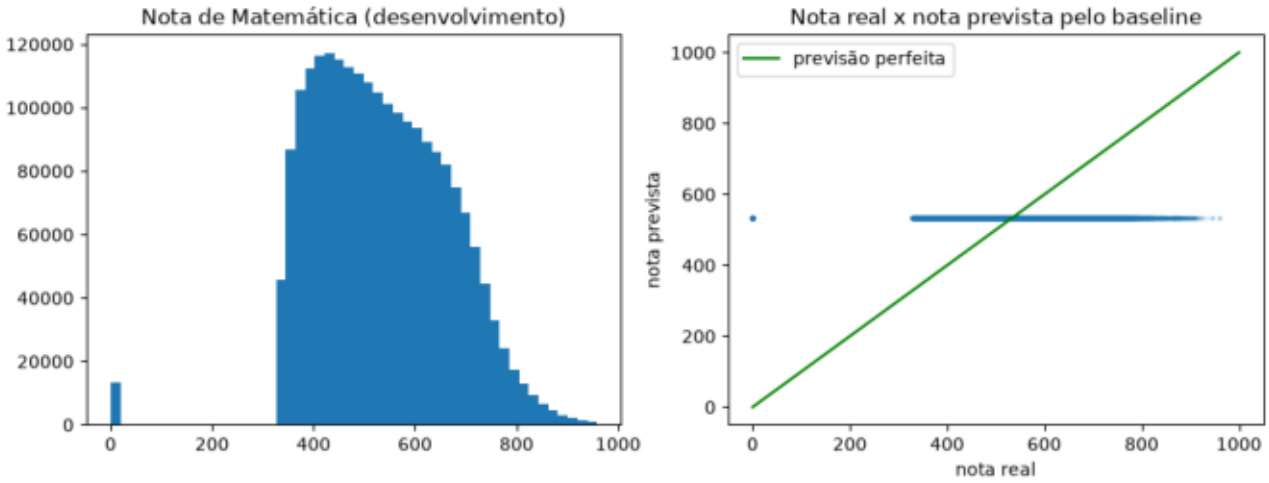


Figura 25. Baseline: distribuição da nota no desenvolvimento e nota real × nota prevista.

5.2 Regressão linear

A nota é uma soma ponderada das features. Os pesos mostram o efeito de cada feature em pontos de nota por desvio padrão: renda (Q006) +27,2, computadores (Q024) +14,8 e escolaridade da mãe (Q002) +10,2 são os maiores positivos; língua (espanhol), sexo (feminino) e FUSAO_1 são os maiores negativos. É associação nos dados, não causa. A reta do modelo na dispersão é inclinada, com inclinação de cerca de 0,29: o modelo puxa as previsões para a média, subestimando notas altas e superestimando notas baixas. Os zeros são previstos em cerca de 519 pontos.

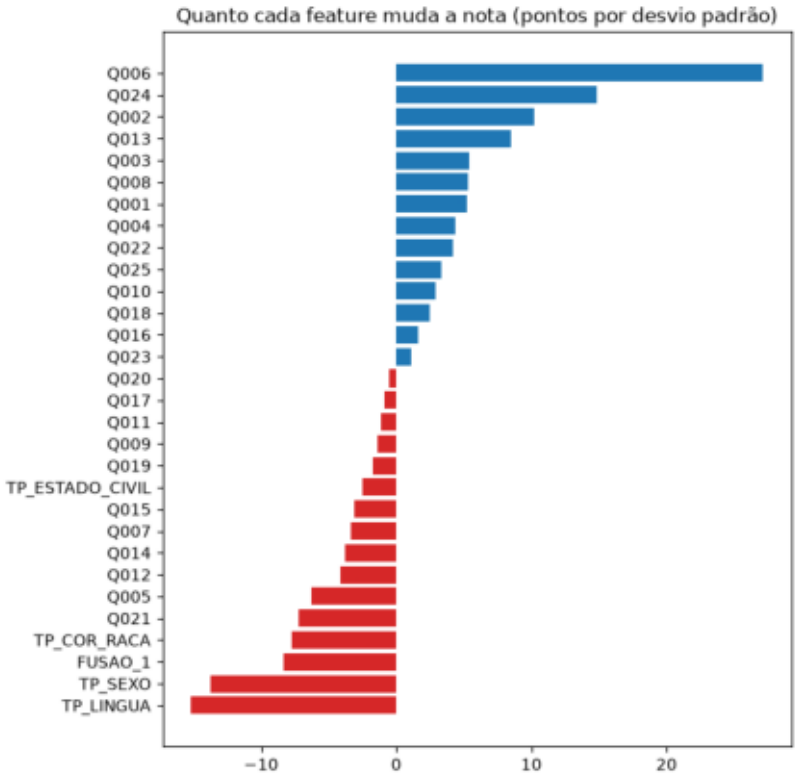


Figura 26. Regressão linear: peso de cada feature (pontos de nota por desvio padrão).

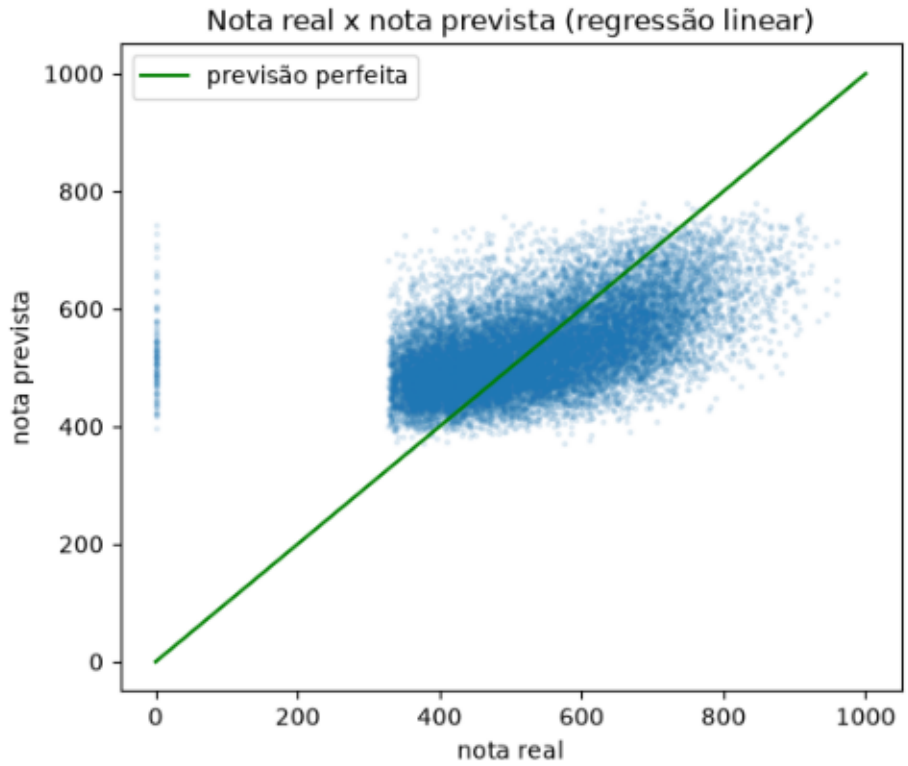


Figura 27. Regressão linear: nota real × nota prevista (previsões fora da dobra).

5.3 Árvore de decisão

A árvore agrupa as pessoas por perguntas sobre as features; a previsão de cada grupo é a nota média. A primeira pergunta (Q006 ≤ 4) separa 1,49 milhão de pessoas (nota média 499) de 662 mil (612). Em profundidade 10 o treino e a validação têm R^2 parecidos (0,301 e 0,295); a partir de 15 níveis o treino continua subindo (0,328 e 0,345) e a validação cai (0,291 e 0,280): é o início do overfitting. Com profundidade 2 a árvore usa 2 features; com 6, 11; com 10, as 30. Q006 concentra 62% da importância, seguida de Q024 (11,8%), TP_LINGUA (7,8%), FUSAO_1 (4,8%) e TP_SEXO (3,7%).

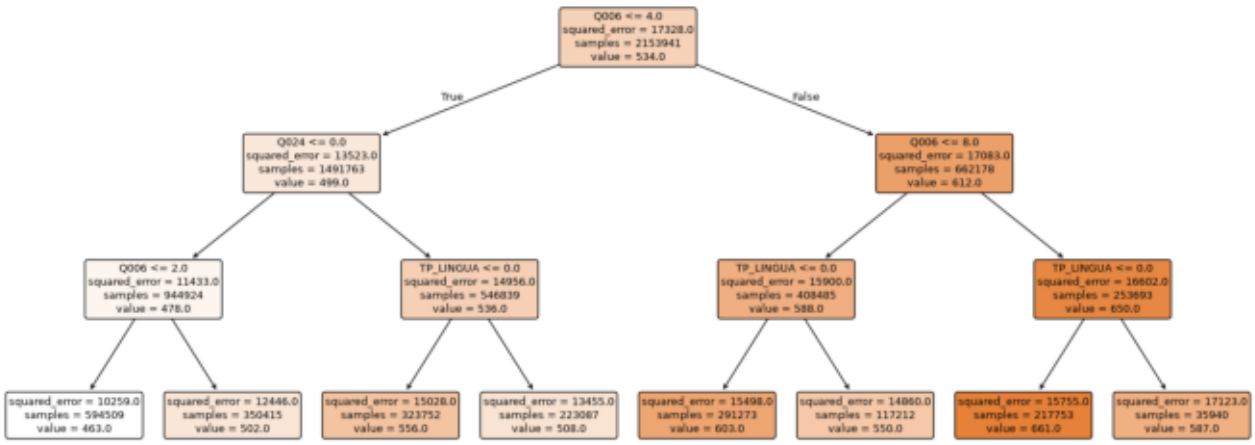


Figura 28. Árvore de decisão pequena (3 níveis) para ilustrar como o modelo divide as pessoas.

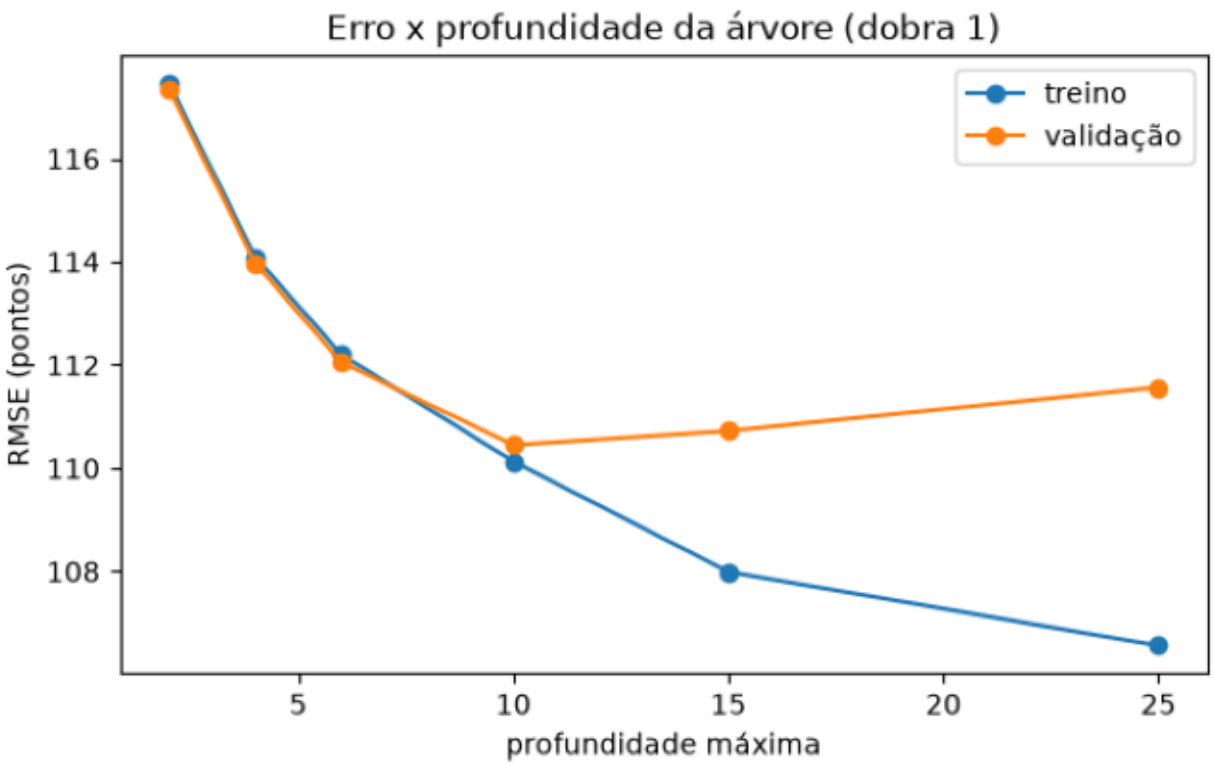


Figura 29. Erro × profundidade da árvore (dobra 1): treino e validação.

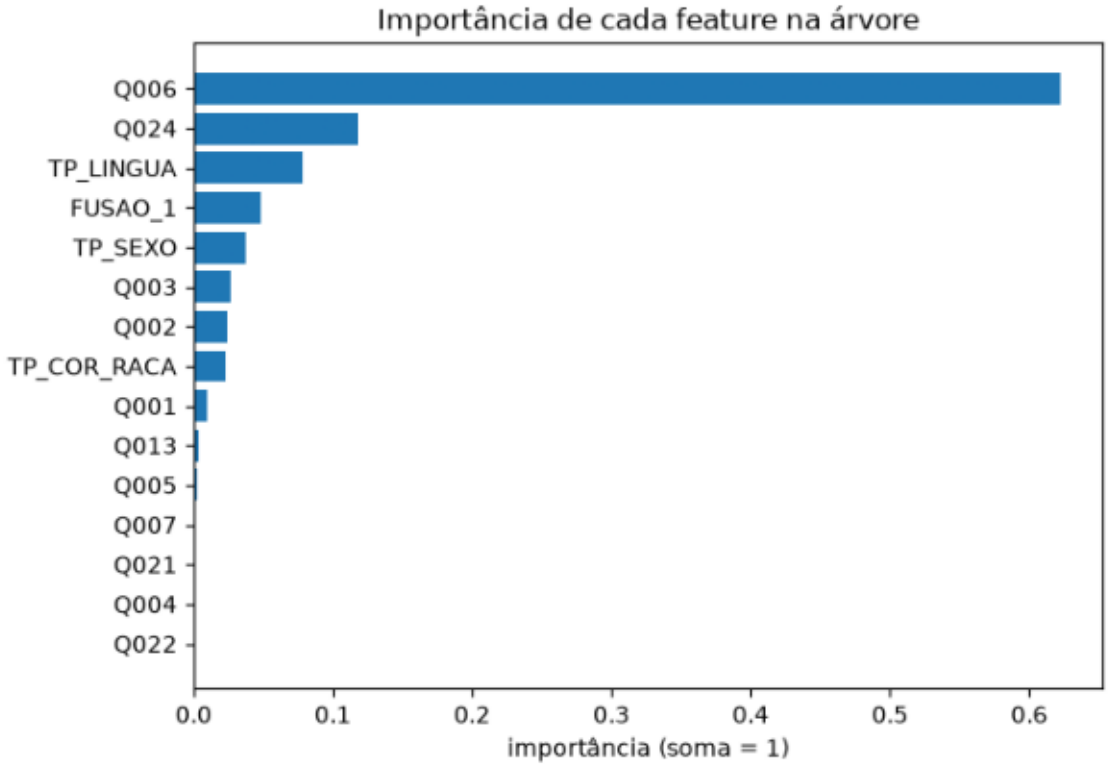


Figura 30. Importância de cada feature na árvore (soma = 1).

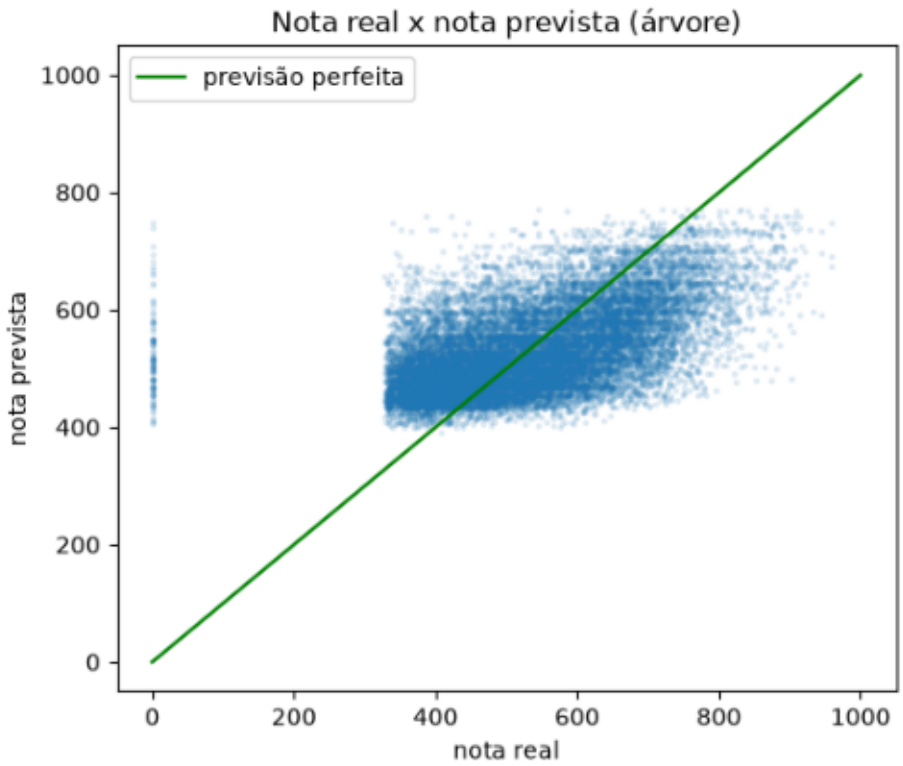


Figura 31. Árvore: nota real × nota prevista (faixas horizontais, uma por folha).

5.4 KNN

Para cada pessoa, o KNN acha as 50 mais parecidas no treino e prevê a média da nota delas. É o mais lento: cerca de 476 s por dobra, porque cada previsão compara com cerca de 1,4 milhão de pessoas. Ficou pior que a regressão linear. Como o KNN não tem pesos próprios, a importância é por permutação (quanto o RMSE sobe ao embaralhar uma feature), numa amostra de 3.000 pessoas da validação da dobra 1.

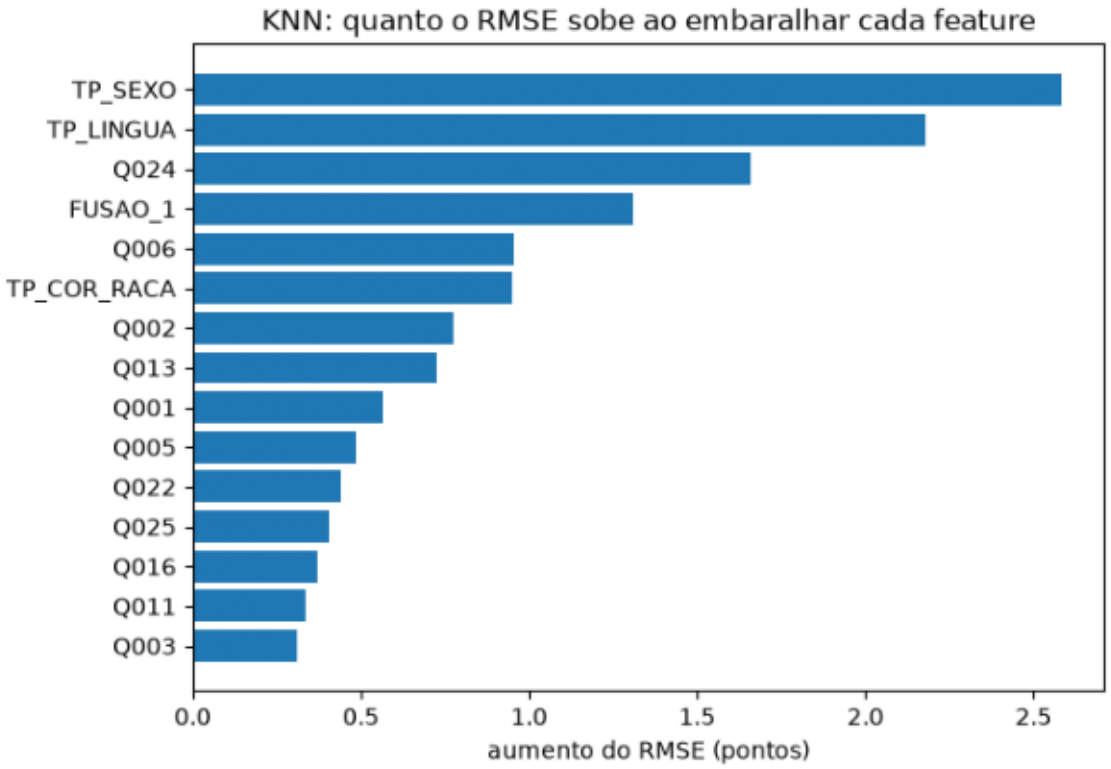


Figura 32. KNN: importância por permutação.

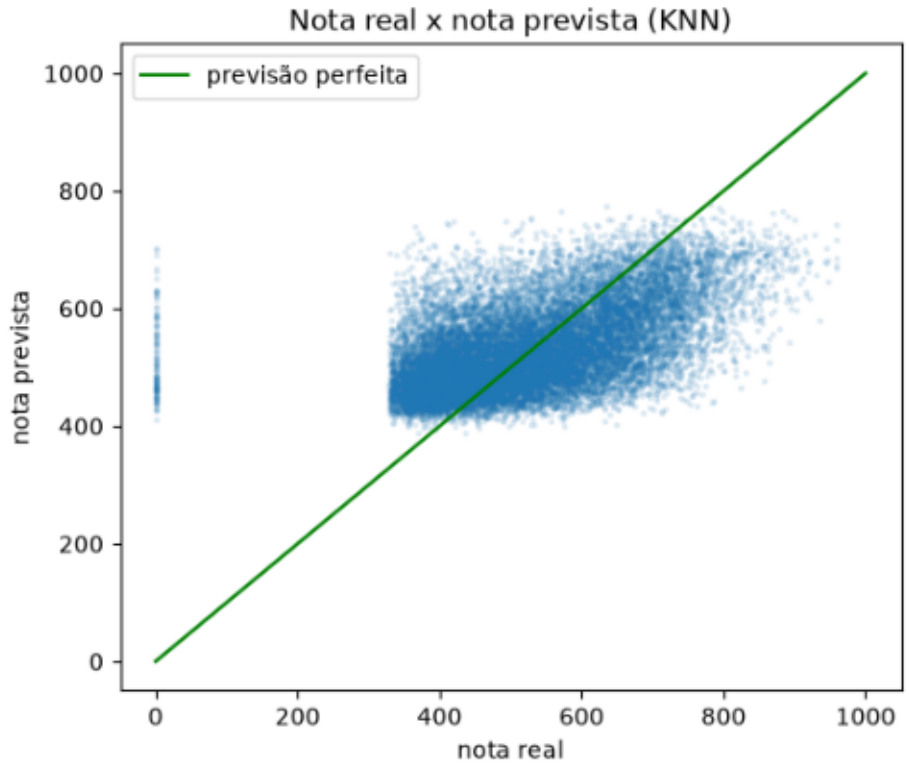


Figura 33. KNN: nota real × nota prevista.

5.5 SVR (linear)

O SVR com kernel compara todos os pares de pessoas, e o tempo cresce com o quadrado do tamanho da base: foi medido em amostras de 2.000 a 8.000 pessoas e extrapolado, o que é inviável para 1,4 milhão. Foi usado o LinearSVR (permitido pelo PDF). Ele chega ao mesmo resultado da regressão linear.

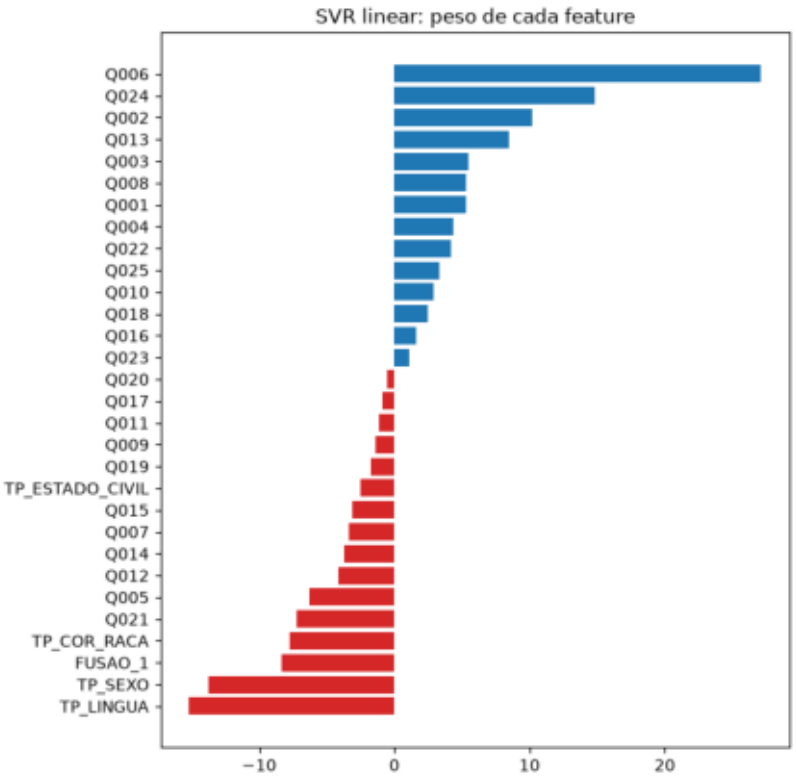


Figura 34. SVR linear: peso de cada feature.

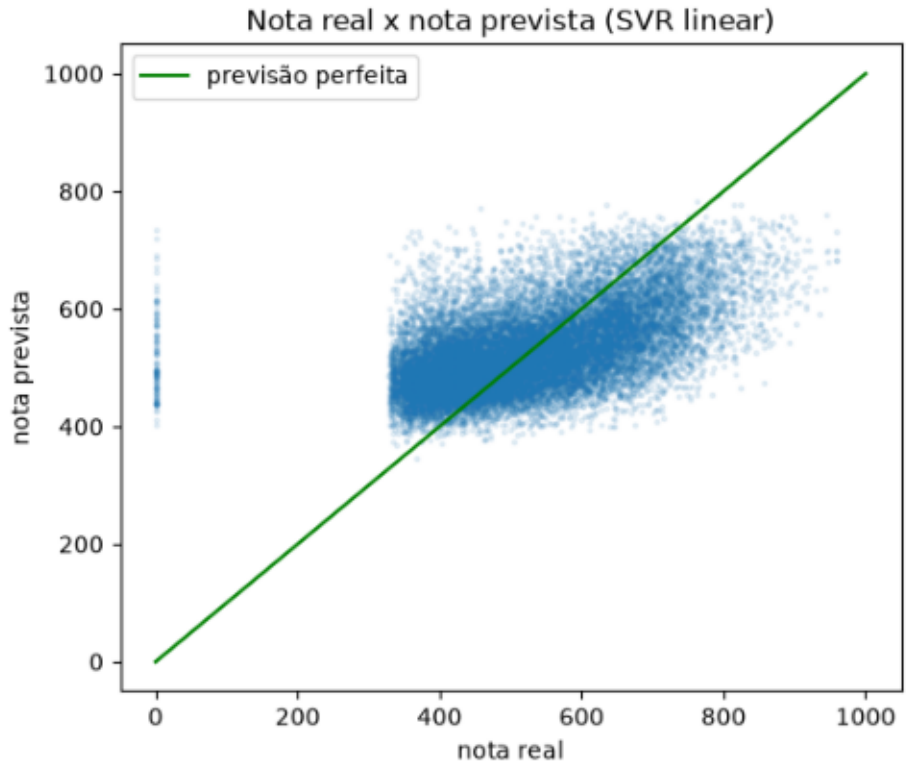


Figura 35. SVR linear: nota real × nota prevista.

5.6 Bagging e pasting

O bagging treina 20 árvores, cada uma numa amostra sorteada com reposição, e prevê a média; o pasting faz o mesmo sem reposição, com metade do treino em cada árvore. Ficaram praticamente iguais (110,014 e 110,012). Importância por permutação na dobra 1.

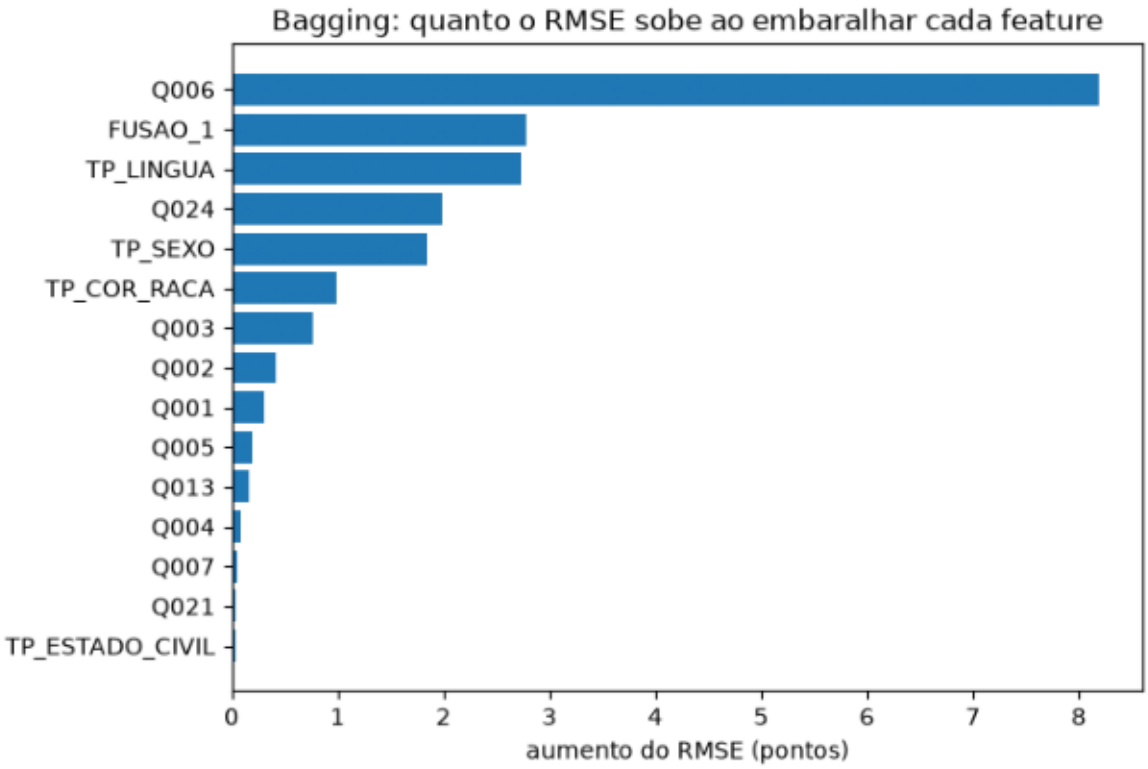


Figura 36. Bagging: importância por permutação.

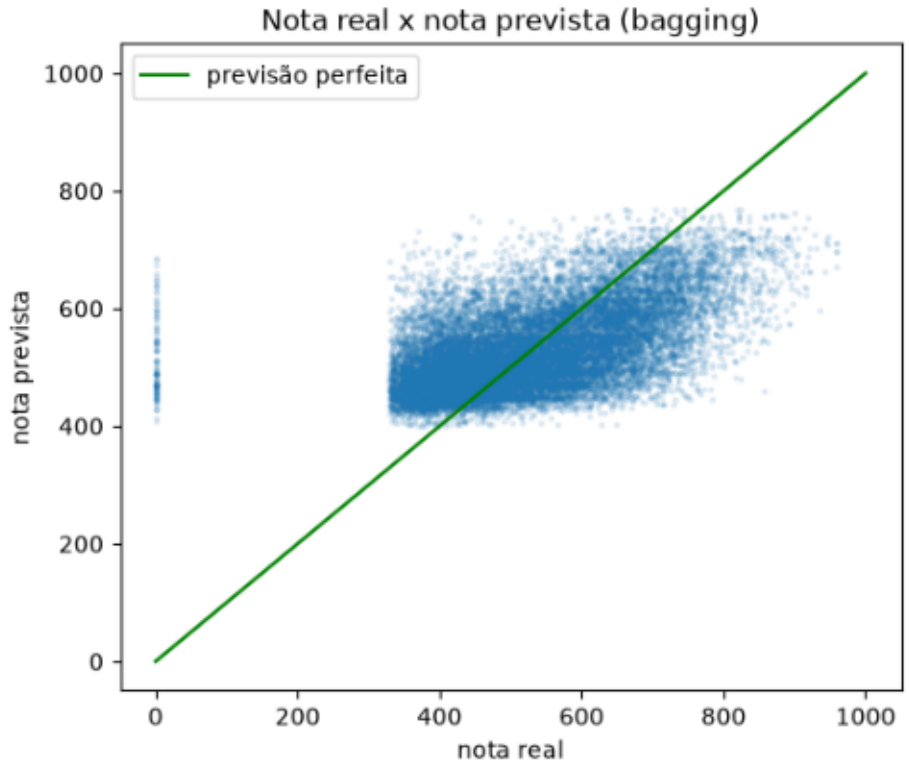


Figura 37. Bagging: nota real × nota prevista.

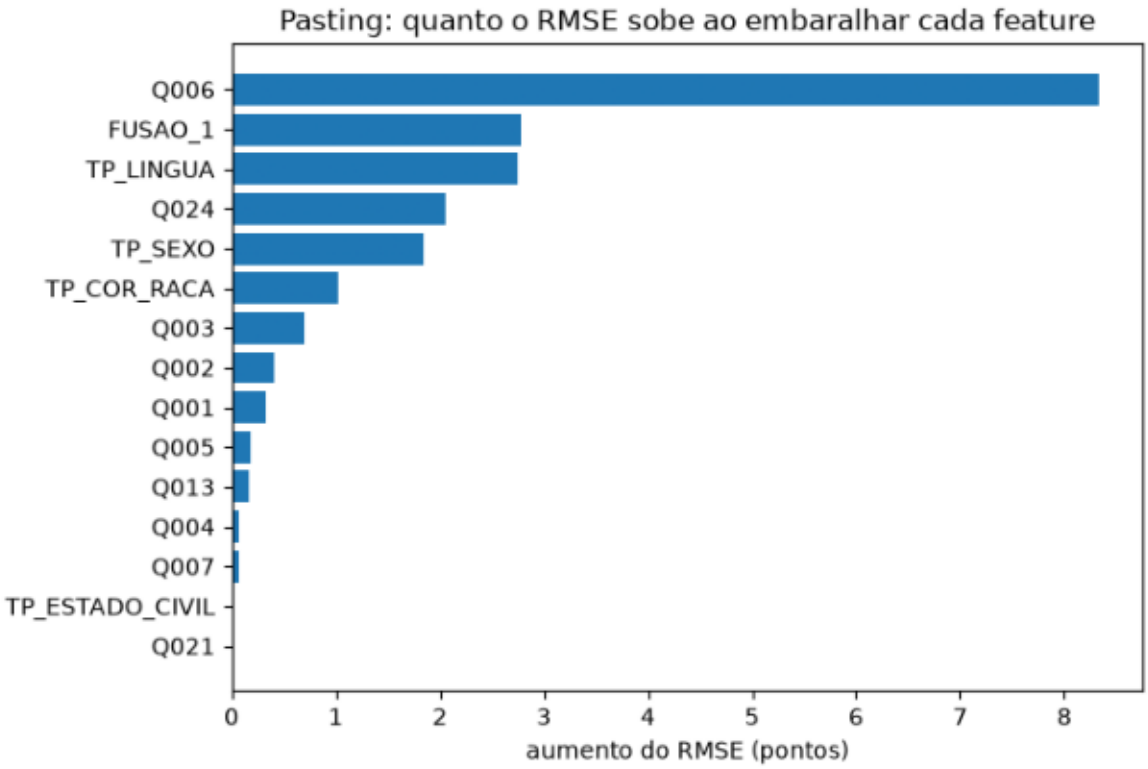


Figura 38. Pasting: importância por permutação.

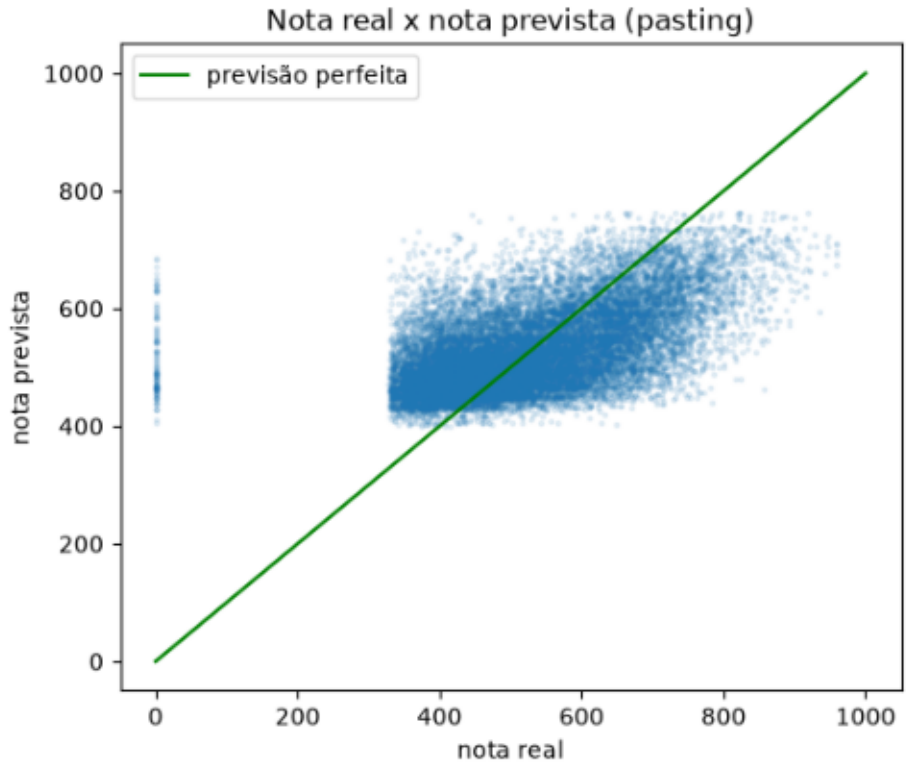


Figura 39. Pasting: nota real × nota prevista.

5.7 Random Forest

A Random Forest é um bagging de árvores em que cada divisão só considera uma parte sorteada das features. Teve RMSE 109,422. A importância nativa (média das árvores) e a por permutação mostram as mesmas features no topo.

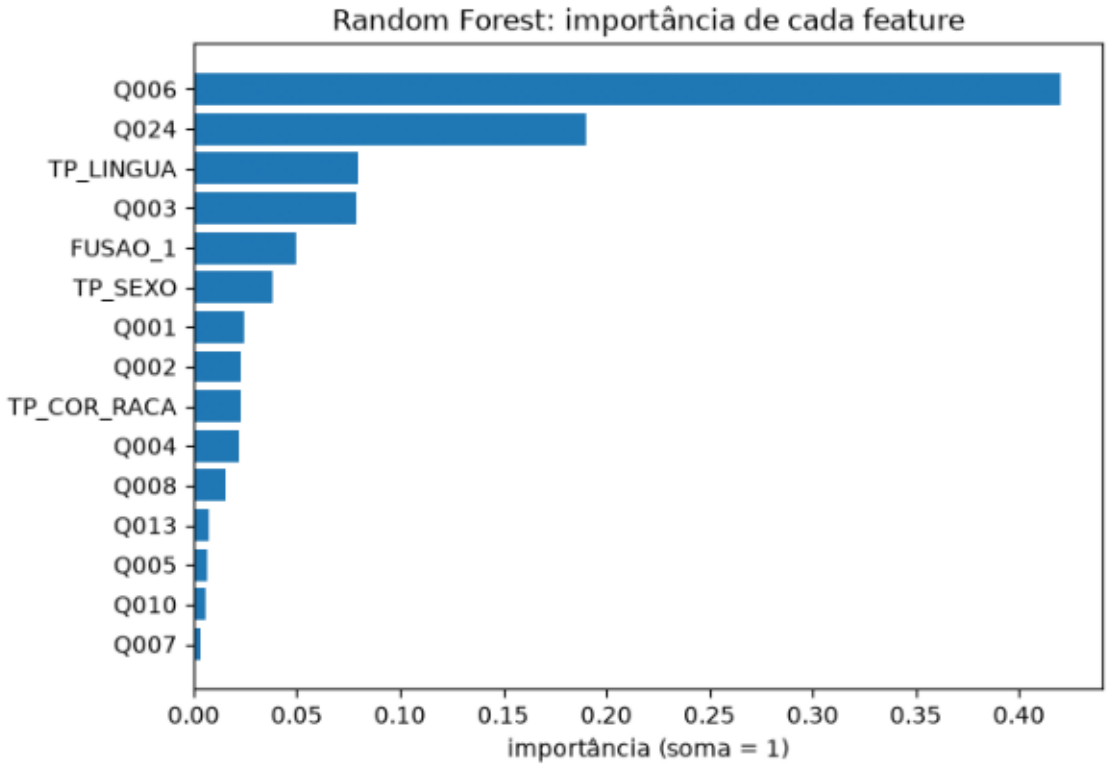


Figura 40. Random Forest: importância nativa (soma = 1).

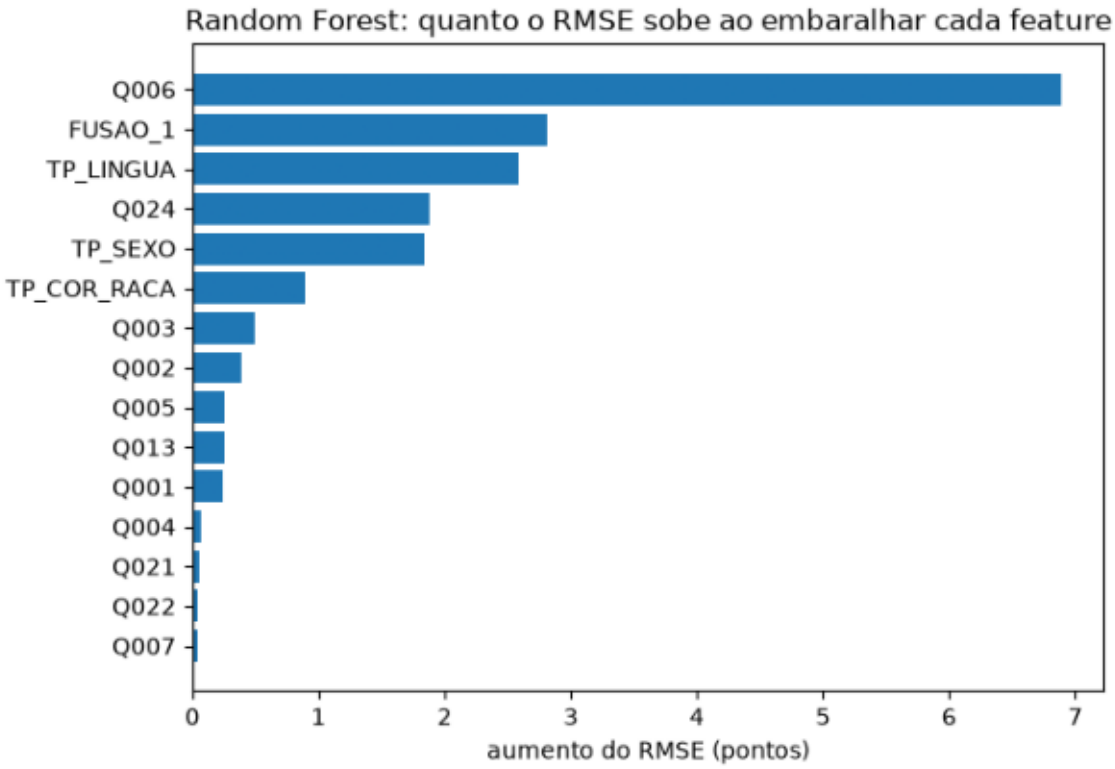


Figura 41. Random Forest: importância por permutação.

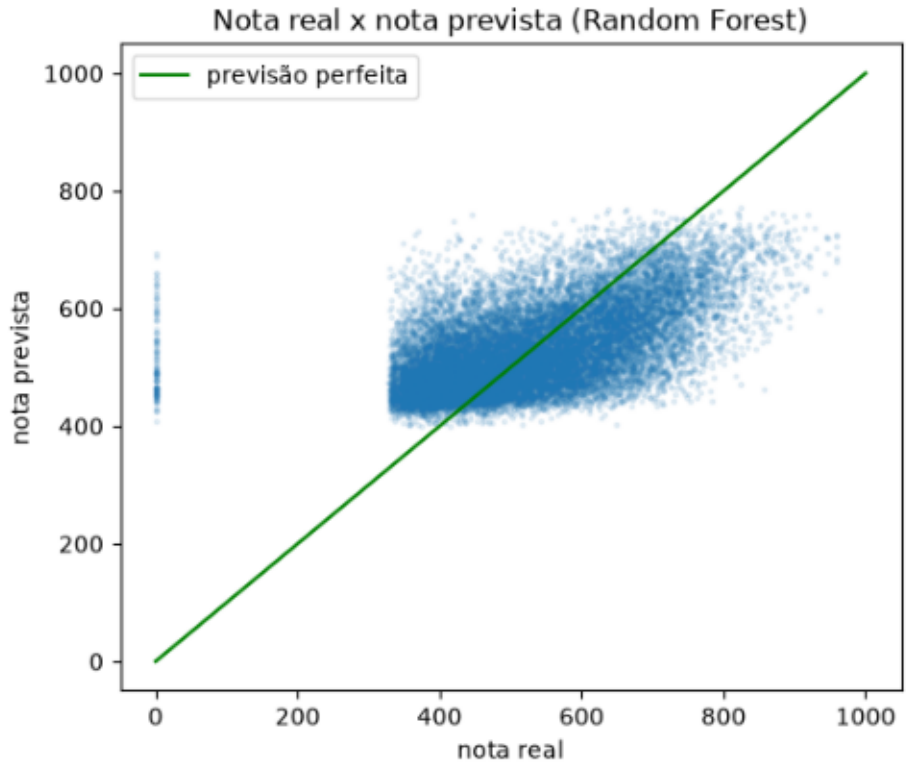


Figura 42. Random Forest: nota real × nota prevista.

5.8 Gradient Boosting

No boosting as árvores são treinadas em sequência, cada uma corrigindo o erro das anteriores. Foi usado o HistGradientBoostingRegressor, mais rápido em bases grandes, com parada antecipada usando 10% do treino de cada dobra (o teste nunca entra). É o melhor modelo: RMSE 107,770 e R^2 0,330.

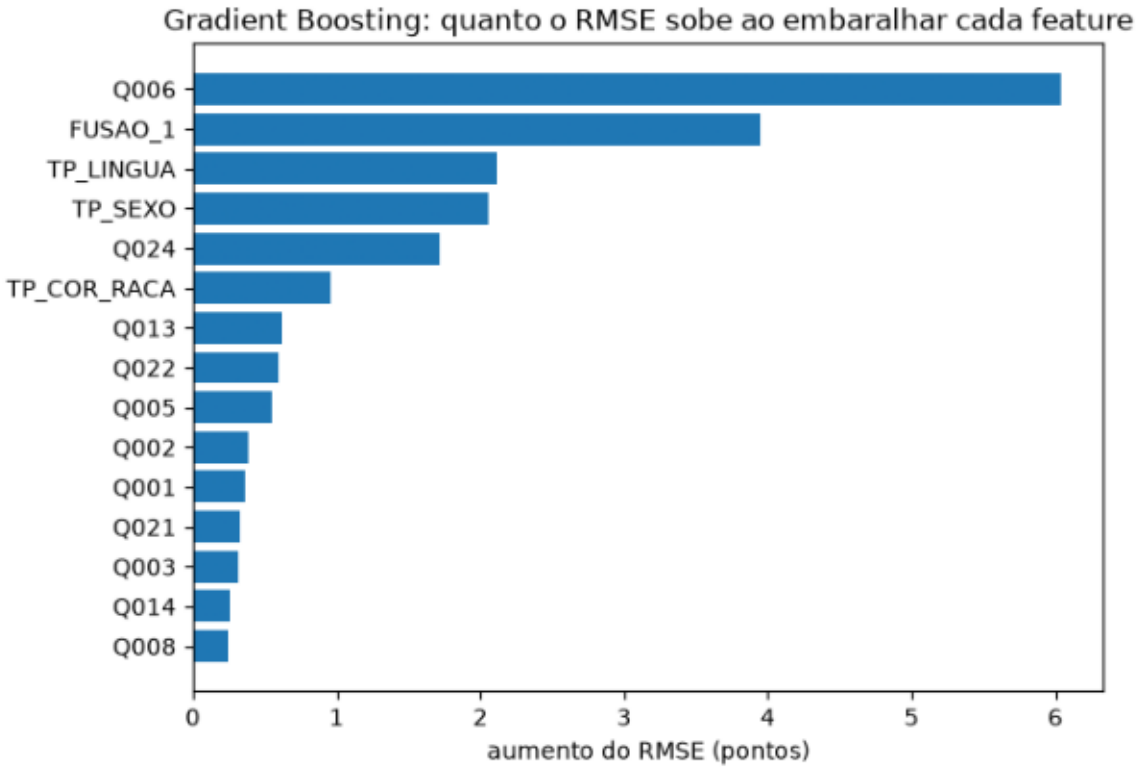


Figura 43. Gradient Boosting: importância por permutação.

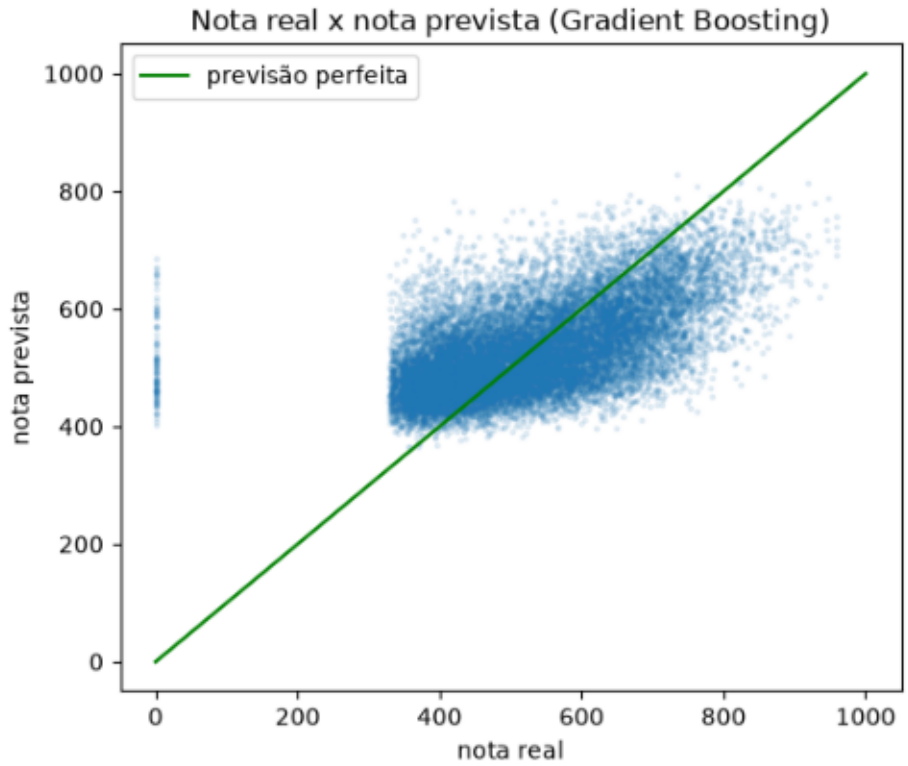


Figura 44. Gradient Boosting: nota real × nota prevista.

5.9 Stacking

O stacking junta as previsões de vários modelos e um Ridge final aprende a combiná-las; as previsões usadas pelo modelo final vêm de uma validação cruzada interna. Empata com o Gradient Boosting (107,763) com custo cerca de 5 vezes maior.

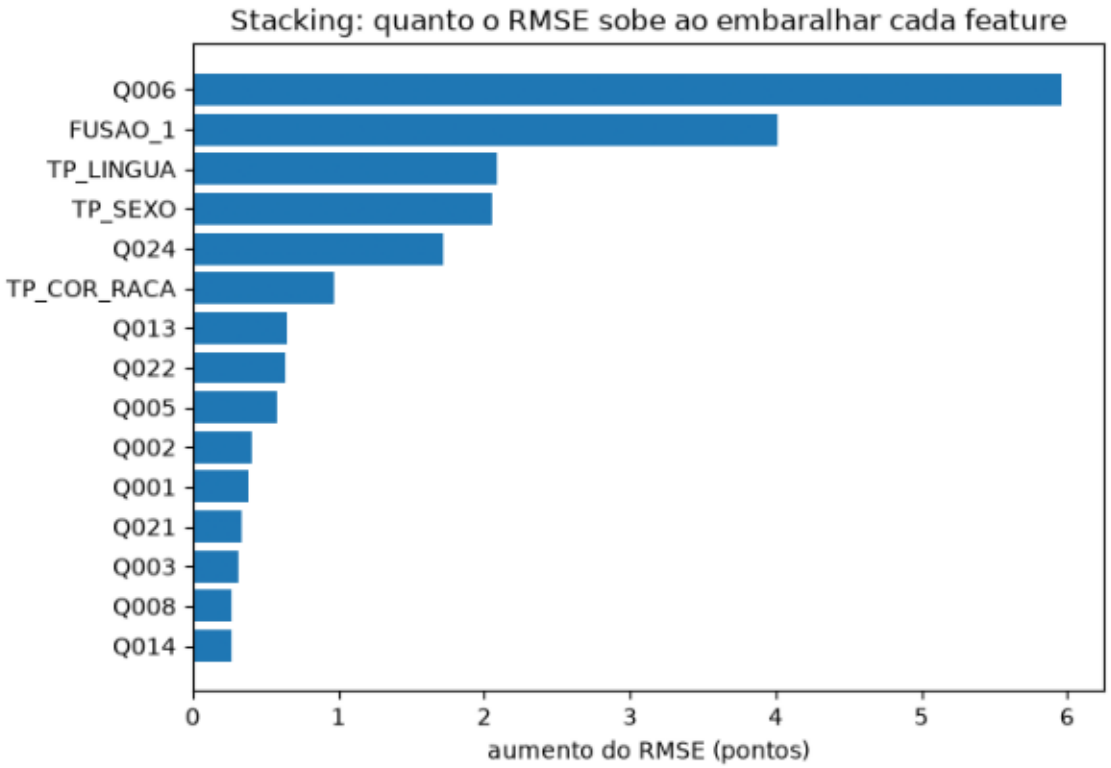


Figura 45. Stacking: importância por permutação.

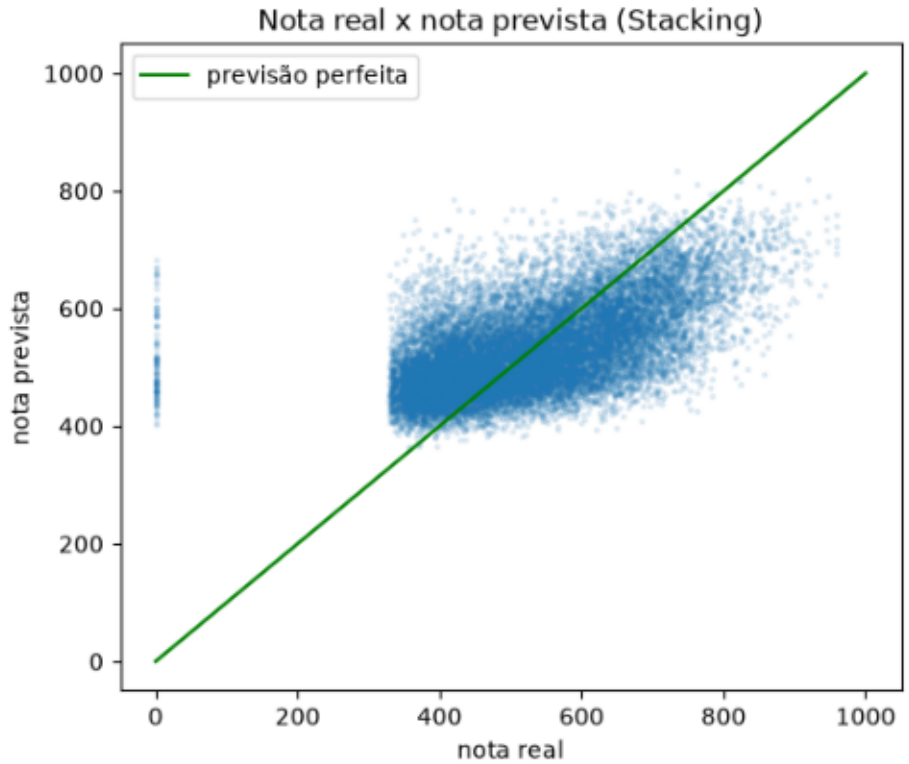


Figura 46. Stacking: nota real × nota prevista.

5.10 Comparação geral

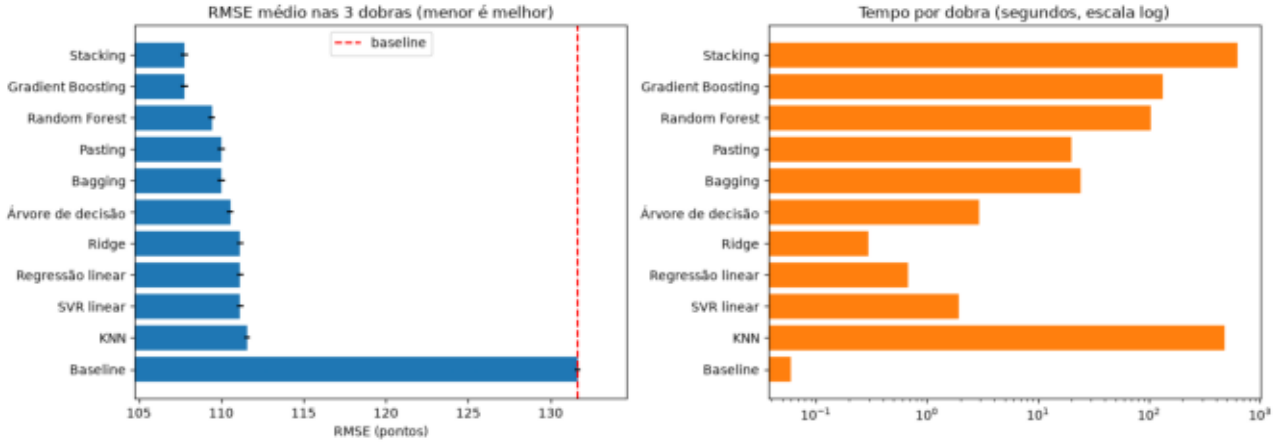


Figura 47. RMSE médio de cada modelo com o desvio entre as dobras (esquerda) e tempo por dobra em escala logarítmica (direita).

Os 3 melhores regressores distintos, pelo RMSE médio (sem contar o baseline): Stacking (107,763), Gradient Boosting (107,770) e Random Forest (109,422). Para a busca de hiperparâmetros, o stacking é o mais caro e não traz ganho, então a prioridade fica com o Gradient Boosting e a Random Forest.

6. Busca de hiperparâmetros

Otimizador: RandomizedSearchCV do scikit-learn (um dos dois que o PDF cita). Para cada modelo sorteia 10 configurações dentro de faixas definidas pela equipe (o PDF pede no mínimo 10), mede cada uma nas mesmas 3 dobras pelo RMSE médio, escolhe a de menor RMSE e a reajusta nos 80% do desenvolvimento. Semente 42. O teste não entra. KNN e stacking ficaram sem busca pelo custo (mais de 3 e mais de 2 horas, respectivamente). O Optuna não foi usado: não está instalado no ambiente.

Tabela 2. Antes e depois da busca (dataset_1_fundido). O RMSE depois da busca é um pouco otimista: foi escolhido o melhor entre 10 sorteados.

Modelo	RMSE inicial	RMSE depois da busca	Ganho	R² depois	Tempo da busca
Bagging	110,014	109,083 ± 0,154	0,931	0,313	17,8 min
Pasting	110,012	109,146 ± 0,158	0,866	0,312	12,0 min
Random Forest	109,422	109,138 ± 0,159	0,284	0,313	19,7 min
Árvore de decisão	110,551	110,337 ± 0,148	0,214	0,297	4,7 min
Gradient Boosting	107,770	107,680 ± 0,178	0,090	0,331	54,2 min
Ridge	111,153	111,153 ± 0,145	0,000	0,287	0,6 min
SVR linear	111,153	111,153 ± 0,145	0,000	0,287	2,0 min

- O maior ganho foi no bagging e no pasting (cerca de 0,9 ponto, acima do desvio de 0,15). A Random Forest e a árvore ganharam 0,2 a 0,3. No Gradient Boosting o ganho (0,09) fica dentro do desvio (0,178), então a busca praticamente não melhorou o melhor modelo.
- Ridge e SVR linear não mudam: todas as configurações sorteadas dão o mesmo resultado, porque a regressão linear já está no limite do que consegue.
- Melhores hiperparâmetros: Ridge alpha=461,9; árvore max_depth=25, max_features=0,8, min_samples_leaf=298; SVR linear C=0,029, epsilon=0,78; bagging 24 árvores, max_samples=0,7, max_features=0,8, árvore base com max_depth=15 e min_samples_leaf=34; pasting 24 árvores, max_samples=0,3 (mesmos demais valores); Random Forest 50 árvores, max_depth=15, max_features=0,3, min_samples_leaf=30; Gradient Boosting learning_rate=0,067, até 500 árvores, 89 folhas, min_samples_leaf=137 e l2_regularization=0,244.

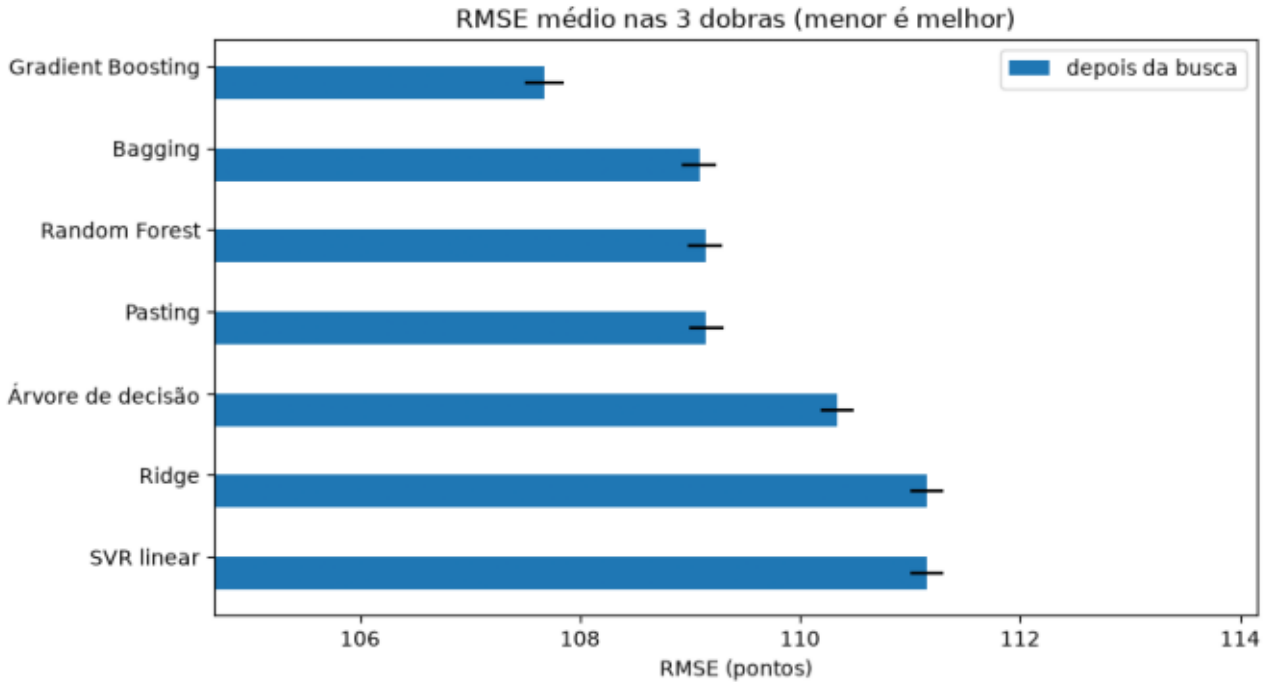


Figura 48. RMSE de cada modelo depois da busca de hiperparâmetros.

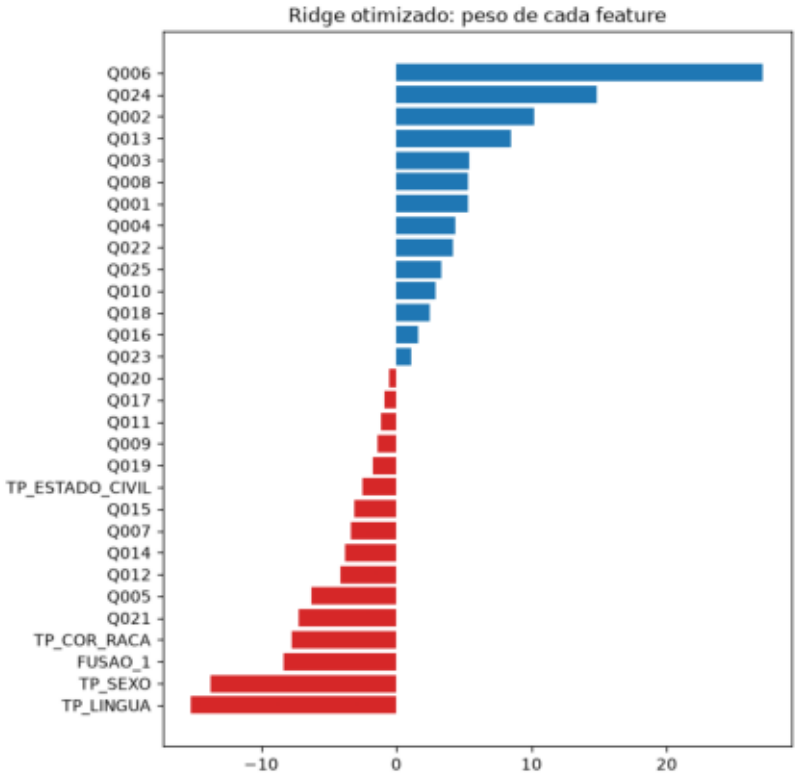


Figura 49. Ridge otimizado: importância ou pesos das features.

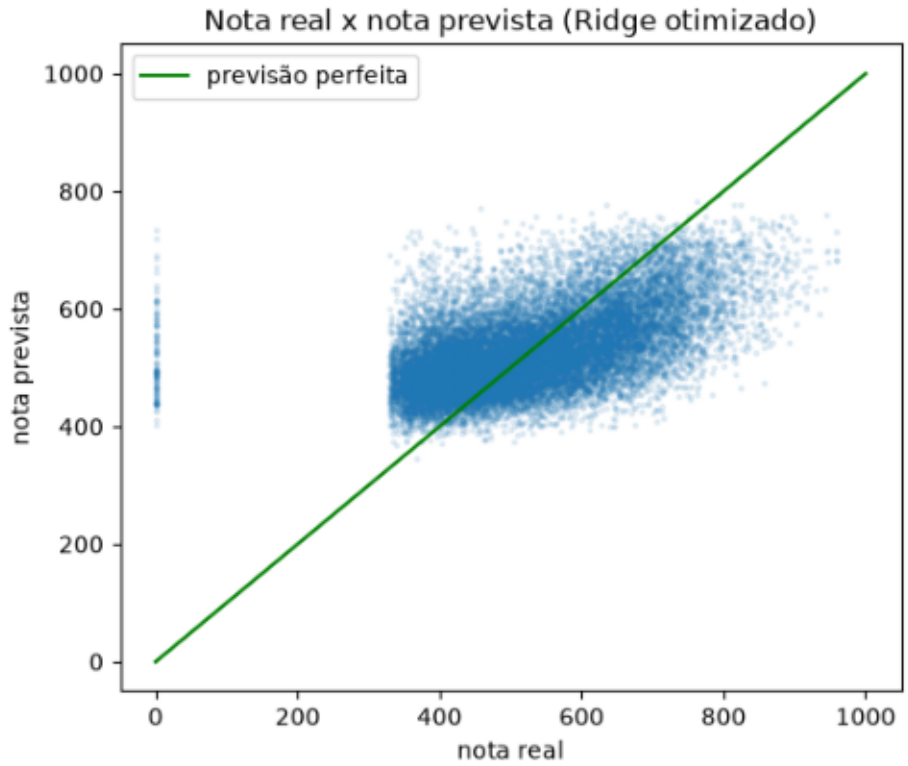


Figura 50. Ridge otimizado: nota real × nota prevista.

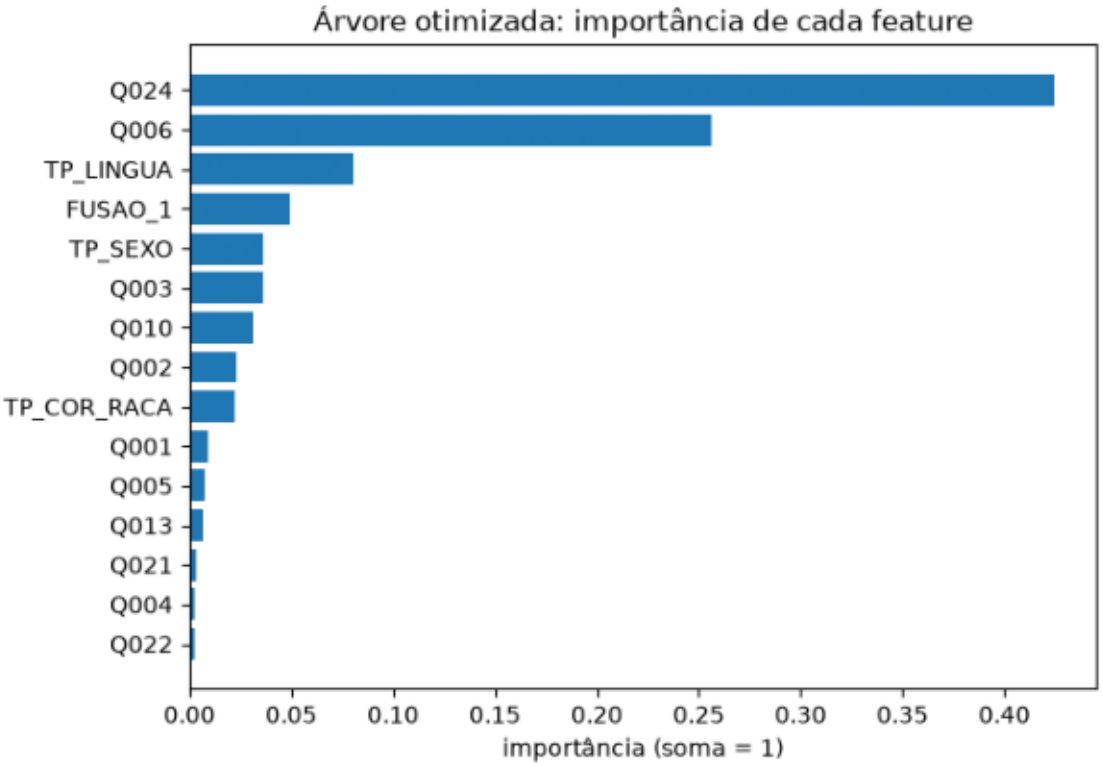


Figura 51. Árvore de decisão otimizado: importância ou pesos das features.

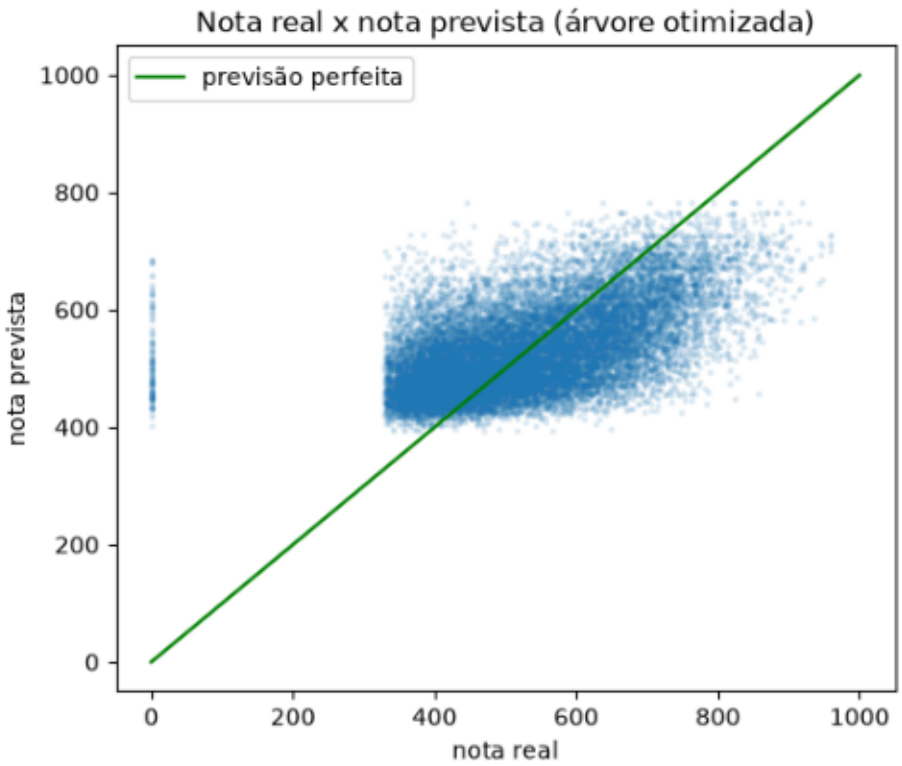


Figura 52. Árvore de decisão otimizado: nota real × nota prevista.

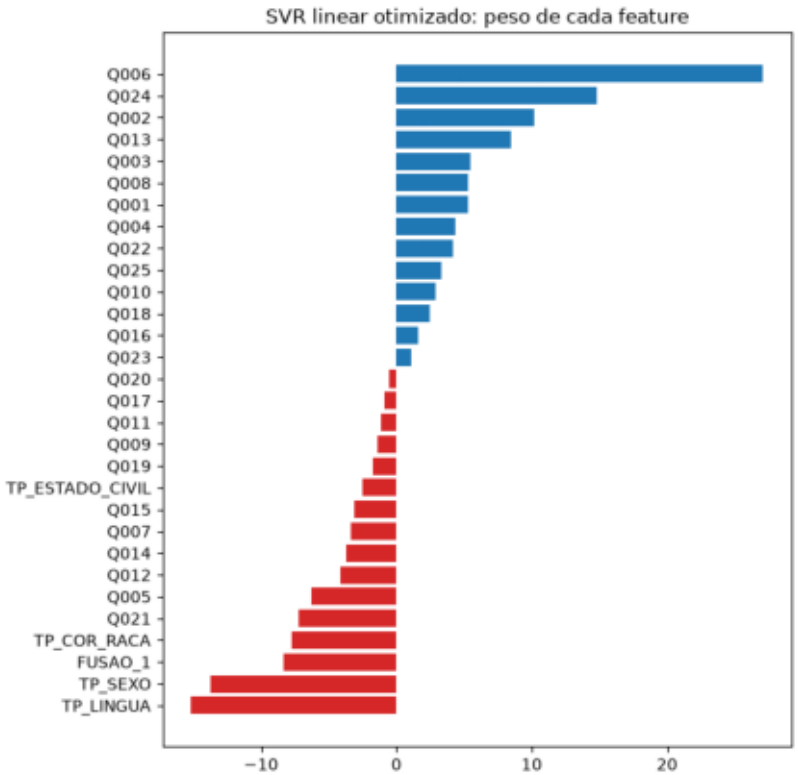


Figura 53. Svr linear otimizado: importância ou pesos das features.

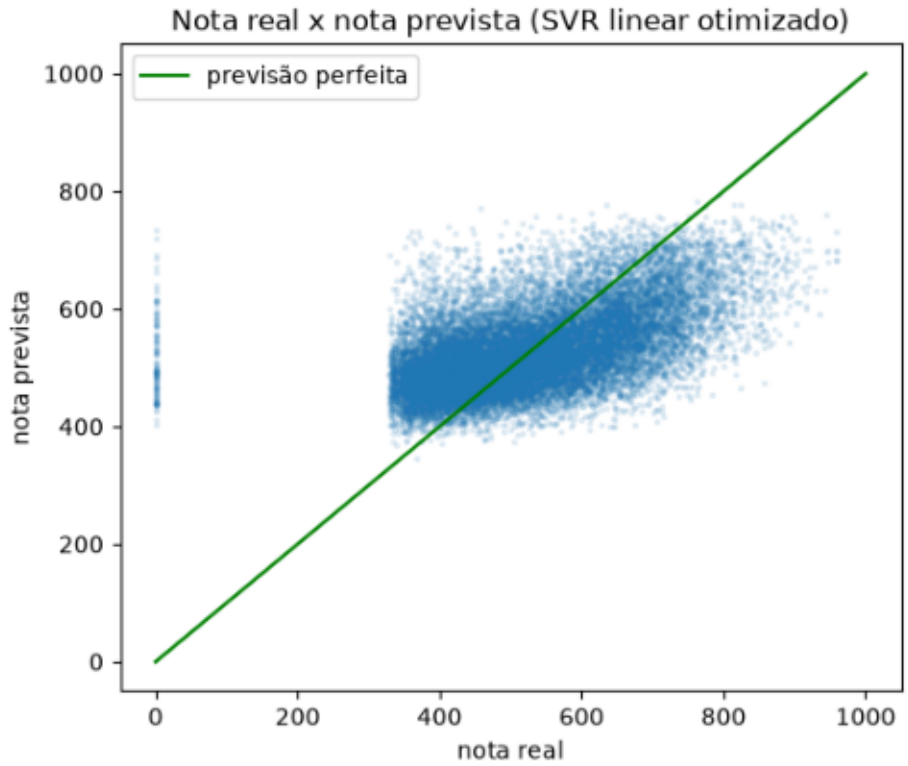


Figura 54. Svr linear otimizado: nota real × nota prevista.

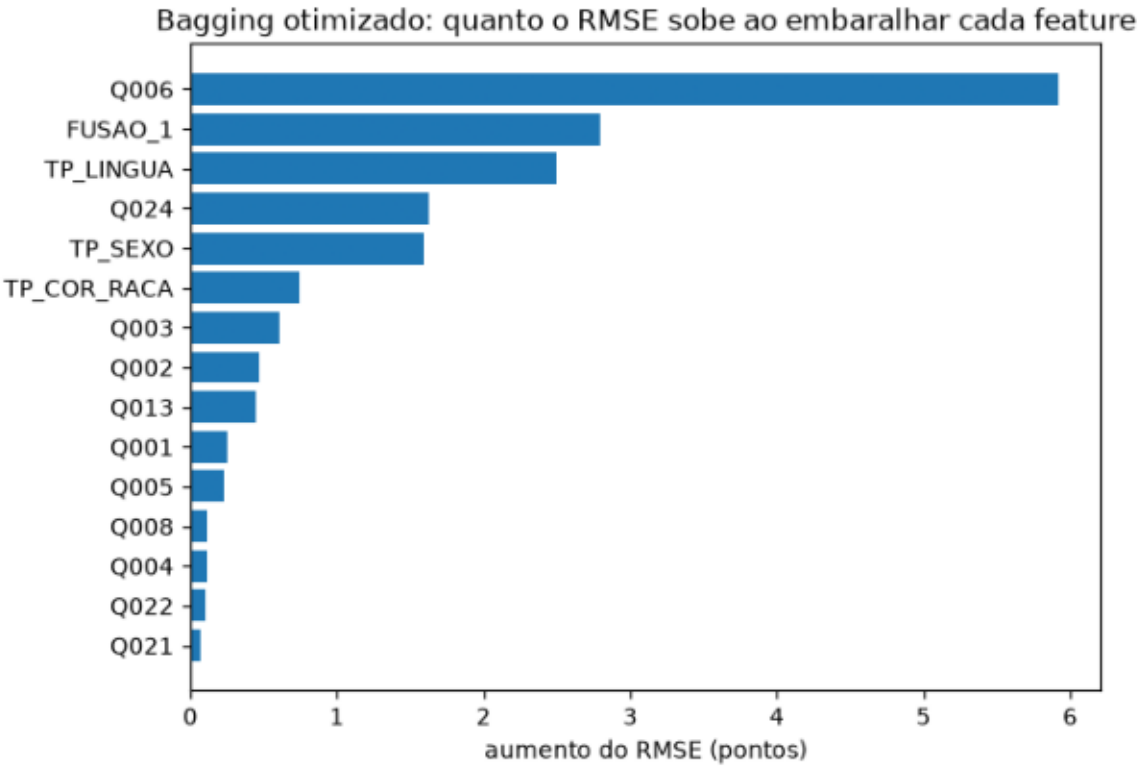


Figura 55. Bagging otimizado: importância ou pesos das features.

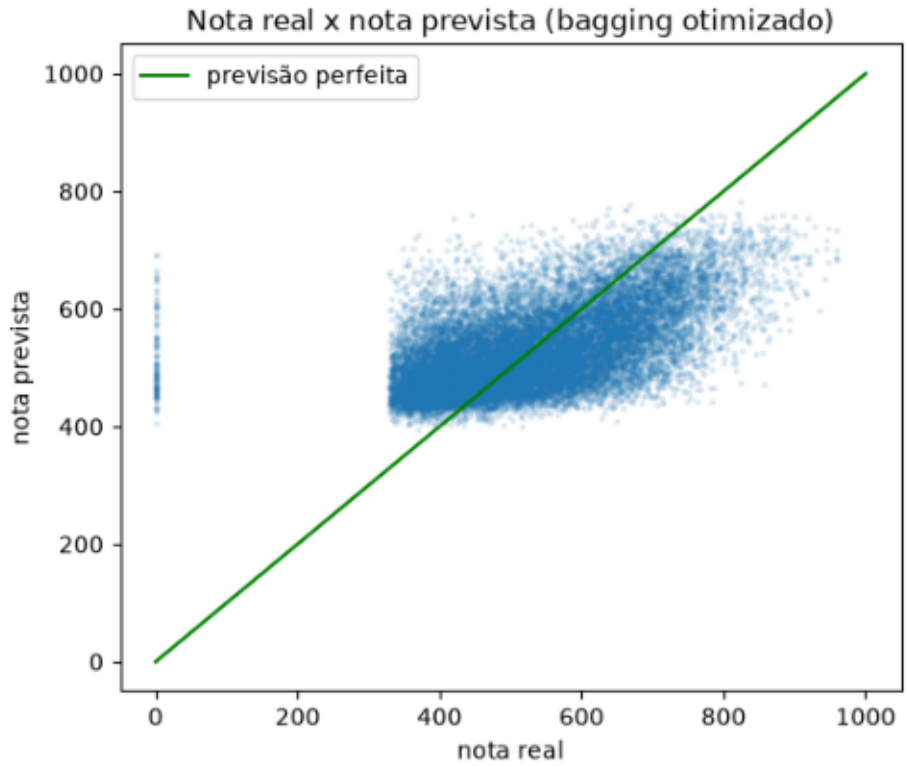


Figura 56. Bagging otimizado: nota real × nota prevista.

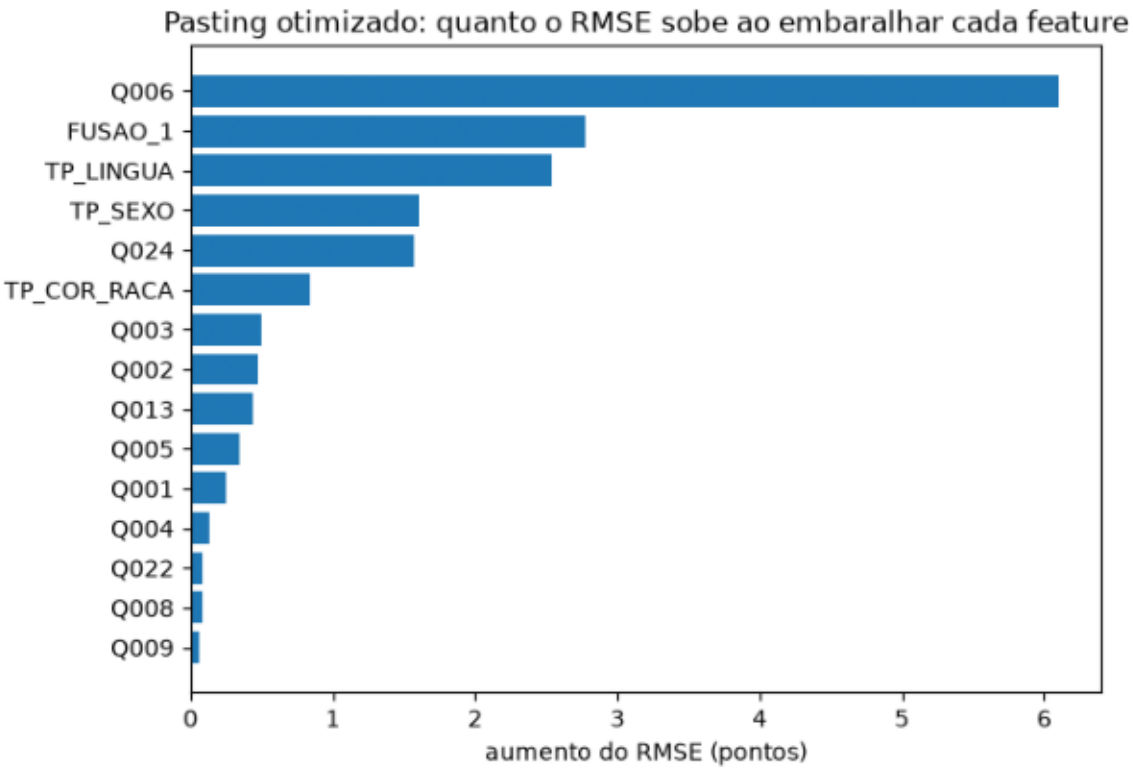


Figura 57. Pasting otimizado: importância ou pesos das features.

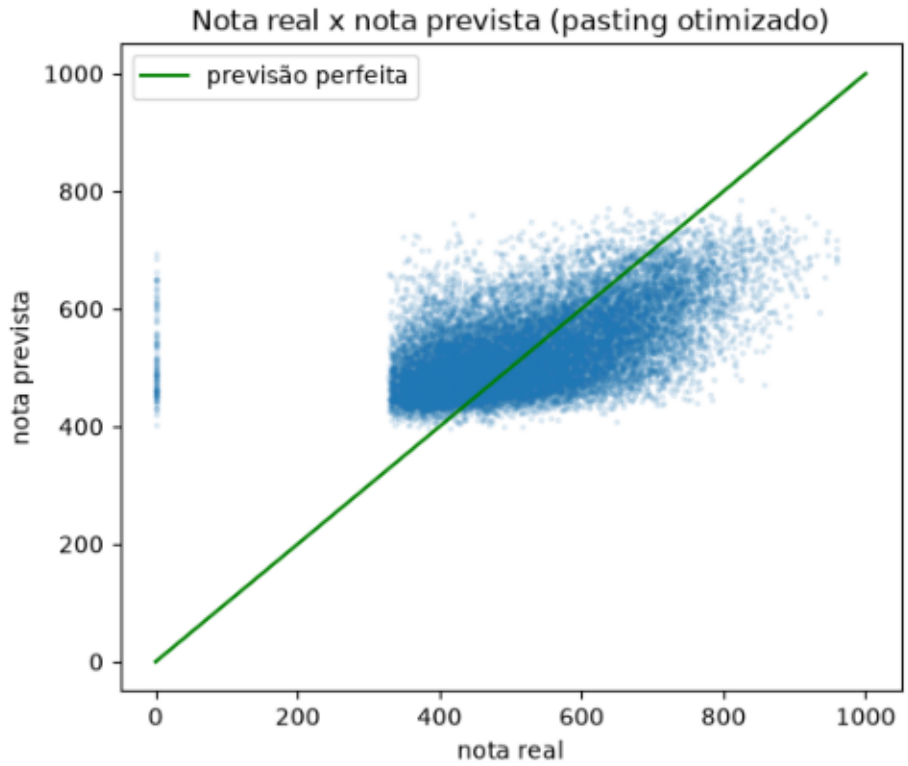


Figura 58. Pasting otimizado: nota real × nota prevista.

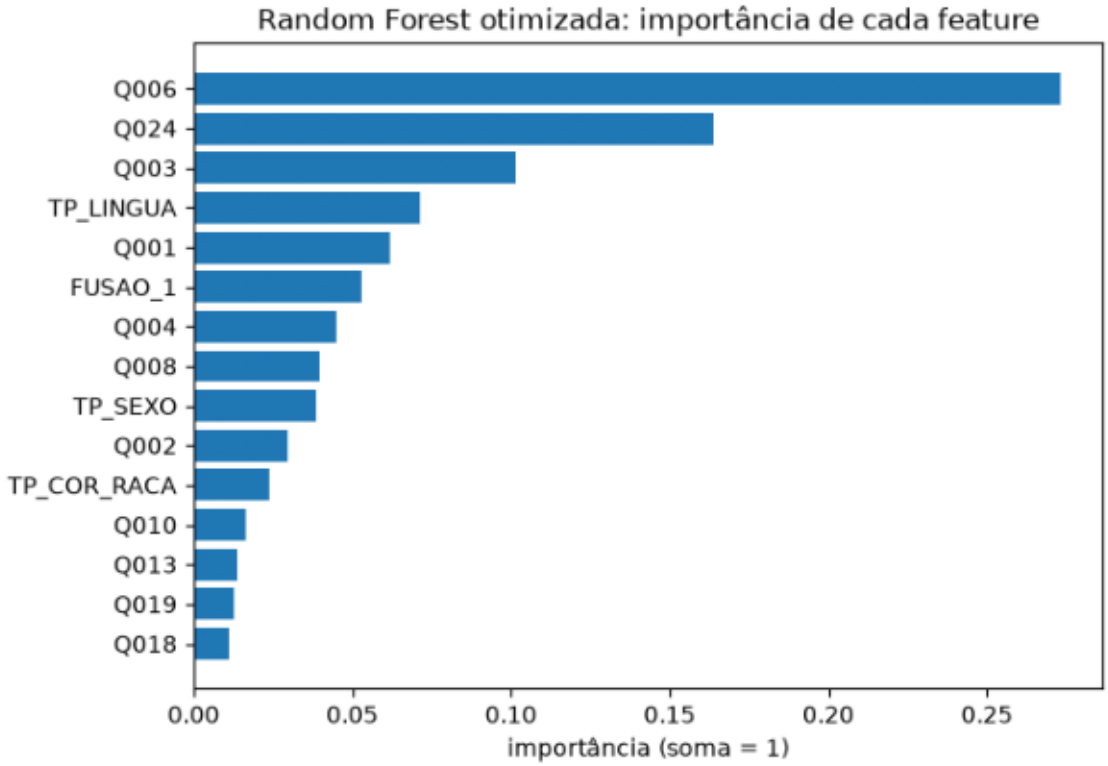


Figura 59. Random forest otimizado: importância ou pesos das features.

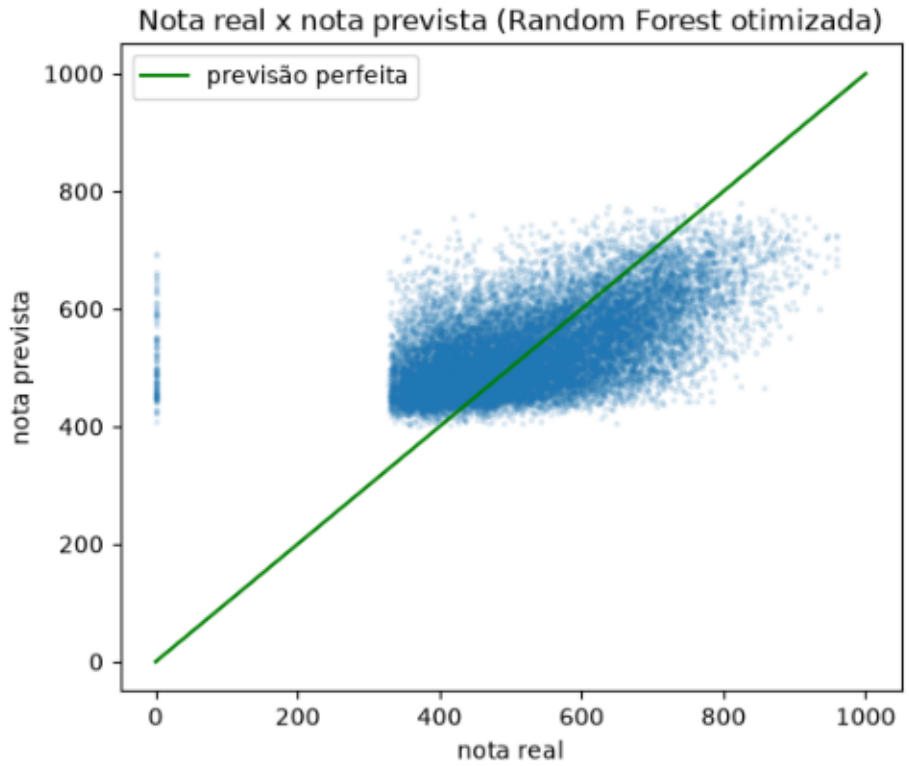


Figura 60. Random forest otimizado: nota real × nota prevista.

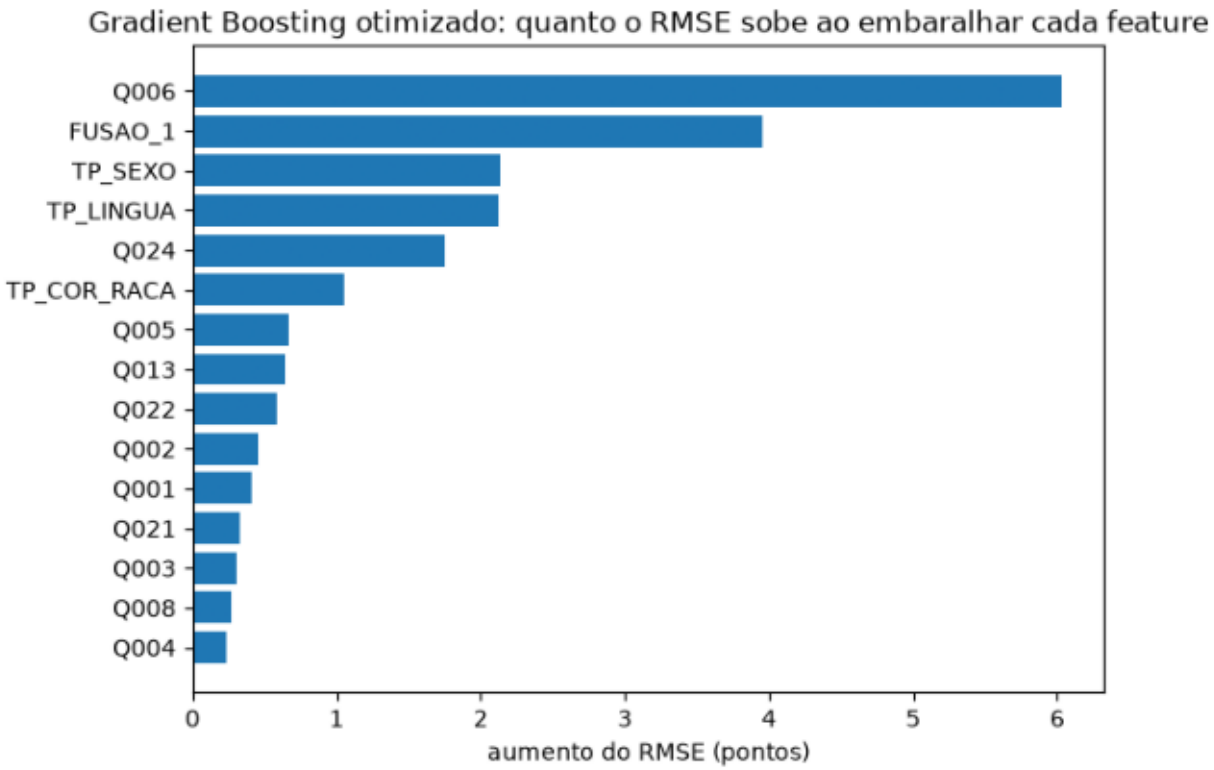


Figura 61. Gradient boosting otimizado: importância ou pesos das features.

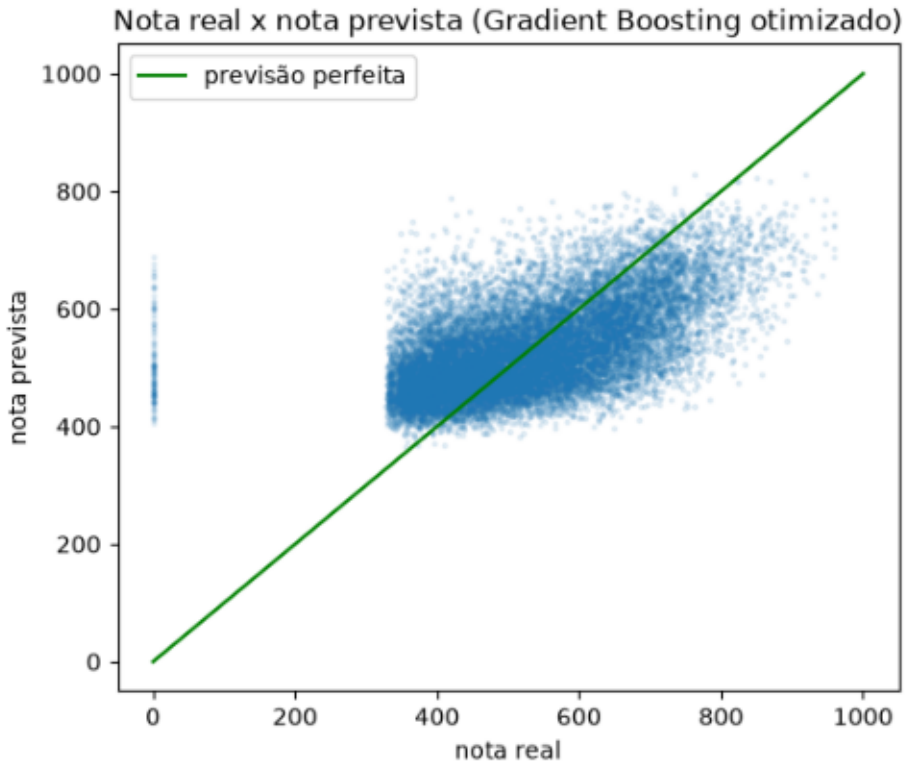


Figura 62. Gradient boosting otimizado: nota real × nota prevista.

7. Comparação entre os datasets

Para ver quanto cada conjunto de features ajuda, a regressão linear e um modelo de árvores foram medidos nos oito datasets, nas mesmas dobras.

Tabela 3. RMSE médio nas 3 dobras (menor é melhor).

Dataset	Features	Regressão linear	Gradient Boosting (inicial)	Bagging otimizado
dataset_1_fundido	30	111,153	107,770	109,083
dataset_1_features	33	111,146	107,759	109,170
dataset_2_escola	34	110,747	107,261	108,720
dataset_2_features_escola	37	110,742	107,255	108,684
dataset_3_sem_escola	38	110,752	107,551	109,089
dataset_3_sem_escola_features	41	110,744	107,540	109,081
dataset_3_escola	42	110,384	107,056	108,597
dataset_3_escola_features	45	110,378	107,048	108,615

- O melhor dataset é o dataset_3_escola_features (45 features): Gradient Boosting 107,048, 0,72 ponto melhor que o dataset 1. A escola dá o ganho mais consistente (cerca de 0,5 ponto no Gradient Boosting e 0,4 na regressão linear), seguida de NAO_SEI e nacionalidade (0,2 a 0,4).
- As 3 features criadas quase não mudam o resultado (cerca de 0,01 ponto), como era de se esperar de colunas calculadas a partir das que já existem.
- Os ganhos de adicionar colunas são pequenos: do dataset 1 ao melhor dataset são 0,8 ponto na regressão linear e 0,7 no Gradient Boosting.

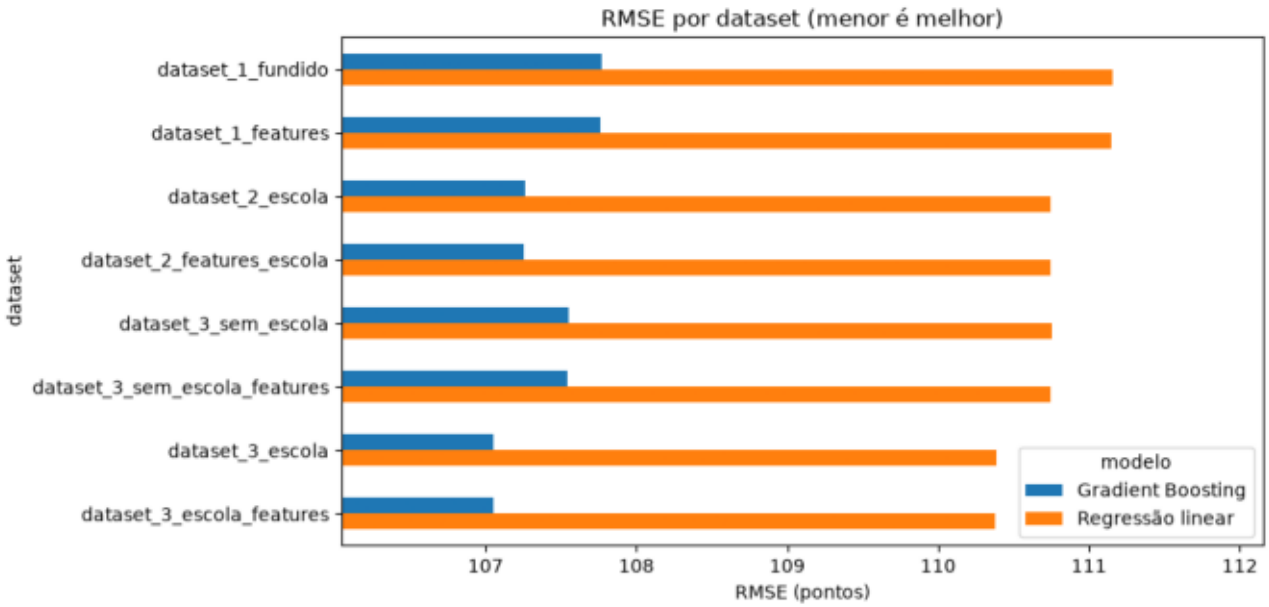


Figura 63. RMSE por dataset: regressão linear e Gradient Boosting.

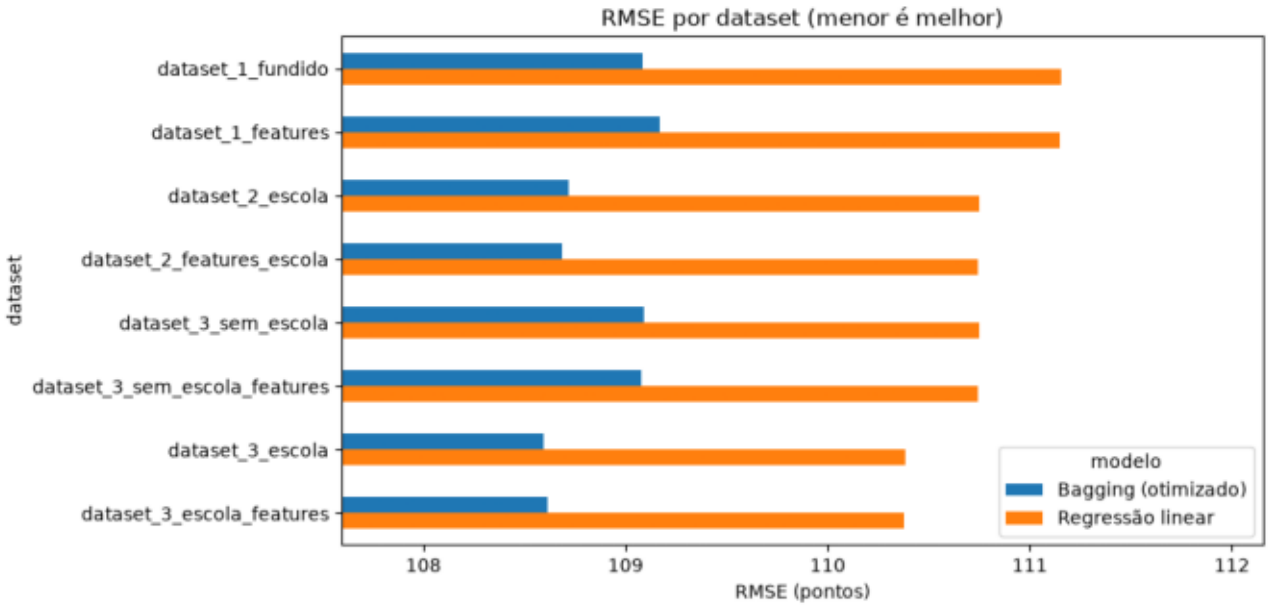


Figura 64. RMSE por dataset: regressão linear e bagging otimizado.

7.1 O que ainda não estava nos datasets: teste à parte

Para verificar se alguma informação importante ficou de fora, foi feito um teste à parte (Gradient Boosting leve, 150 árvores, mesmas 3 dobras, dataset 1 como base). A UF da prova (27 colunas 0/1) e as colunas de idade, situação do ensino médio, ano de conclusão e treineiro, que a FUSAO_1 havia juntado, ajudam um pouco, e os dois efeitos se somam.

Tabela 4. Teste à parte: colunas que ainda não estavam nos datasets (diagnóstico, não faz parte dos notebooks).

Conjunto	Colunas	RMSE (± desvio)	R^2	Ganho
A. Dataset 1	30	107,977 ± 0,185	0,327	
B. A + UF da prova (one-hot)	57	107,334 ± 0,169	0,335	0,64
C. A + idade, situação, ano e treineiro separados	34	107,505 ± 0,152	0,333	0,47
D. A + B + C	61	106,830 ± 0,139	0,341	1,15

Implicações: a FUSAO_1 custou 0,47 ponto de RMSE, e manter as quatro colunas separadas também resolve o vazamento da fusão; a UF entra em one-hot (sem vazamento); o município (1.750 categorias) é o próximo candidato e só entra com target encoding dentro do Pipeline.

8. Treino sem as notas zero

Nota zero é um resultado observado. O PDF permite testar o treino sem os zeros, mas só dentro do treino de cada dobra, e com a validação e o teste mantendo todos os participantes, inclusive os zeros: uma avaliação só entre as notas positivas descreve outra população e não comprova melhoria. Por isso não foi criado um dataset sem zeros: a classe SemZerosNoTreino descarta as pessoas com nota 0 só nas duas dobras de treino e o modelo prevê para todos. Foram buscados hiperparâmetros treinando sem zeros, e a melhor configuração foi medida dos dois jeitos (com e sem zeros no treino), nas mesmas dobras.

Tabela 5. Efeito de tirar os zeros do treino (validação com todos os participantes).

Modelo	RMSE com zeros	RMSE sem zeros	Diferença (com − sem)	Desvio entre dobras	Veredito
Regressão linear	111,153	111,202	−0,049	0,178	sem diferença clara
Ridge	111,153	111,202	−0,049	0,178	sem diferença clara
Árvore de decisão	110,337	110,331	+0,006	0,181	sem diferença clara
Gradient Boosting	107,680	107,737	−0,057	0,218	sem diferença clara

- Em nenhum dos modelos a diferença passa do desvio entre as dobras: tirar os zeros do treino não melhora nem piora de forma mensurável o RMSE geral.
- Por faixa de nota (regressão linear): o erro dos zeros e das notas baixas sobe um pouco sem eles (de 522,6 para 526,0 nos zeros; de 131,1 para 134,1 em 1 a 400), e o erro das notas altas cai um pouco (de 210,4 para 207,7 acima de 800). Os zeros são previstos em cerca de 519 pontos nos dois casos.
- O viés é grande nas pontas: nos zeros, o modelo prevê cerca de 520 pontos a mais; acima de 800, prevê cerca de 200 a menos. É o efeito de regressão à média.
- Os zeros são 0,62% das pessoas e geram 13,7% do erro ao quadrado da regressão linear: o RMSE entre quem não zerou é 103,6 (descritivo; descreve outra população e não comprova melhoria).
- Busca sem zeros: Ridge (alpha=0,003; 1,4 min), árvore (max_depth=25, max_features=0,8, min_samples_leaf=298; 7,2 min) e Gradient Boosting (75,4 min). A Random Forest ficou desligada.

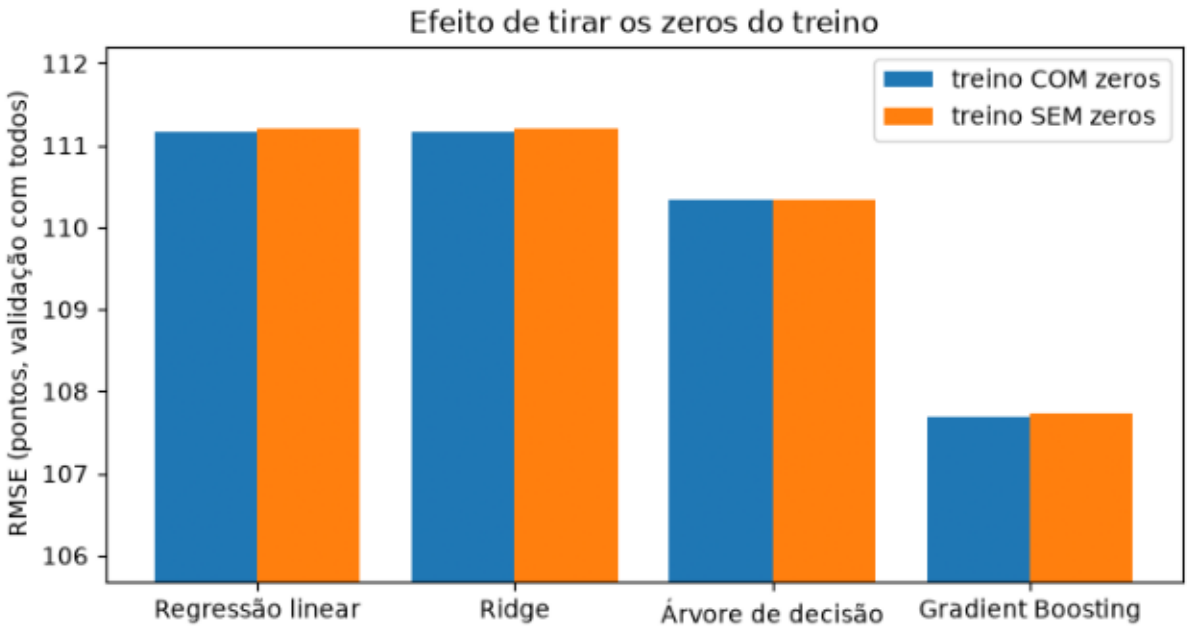


Figura 65. RMSE de cada modelo treinando com e sem zeros.

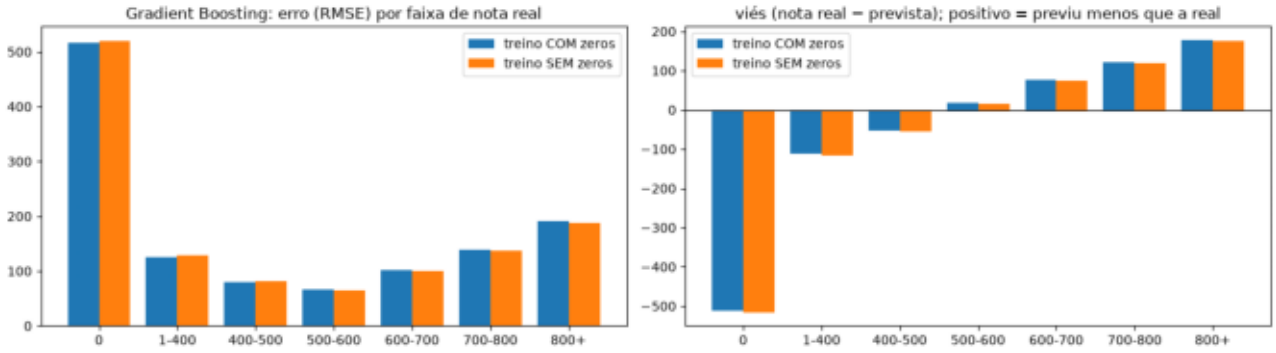


Figura 66. Gradient Boosting: erro (RMSE) e viés por faixa de nota real, com e sem zeros no treino.

9. Redução de dimensionalidade e clusterização

O PDF exige testar o PCA em pelo menos dois regressores e justificar o número de componentes. O t-SNE é opcional (só em amostra, como diagnóstico). O K-means não é exigido; se usado, tem de ficar dentro do Pipeline.

9.1 PCA exploratório

Com as colunas padronizadas (o PCA é sensível à escala) e todo o desenvolvimento, são necessários 7 componentes para 50% da variância, 18 para 80%, 23 para 90% e 26 para 95% (de 30). Ou seja, os dados quase não se comprimem: as colunas carregam informações independentes, o que combina com o fato de nenhum par passar de 0,7 de Spearman. O primeiro componente (renda e bens da casa) tem correlação de 0,463 com a nota; o segundo, −0,152.

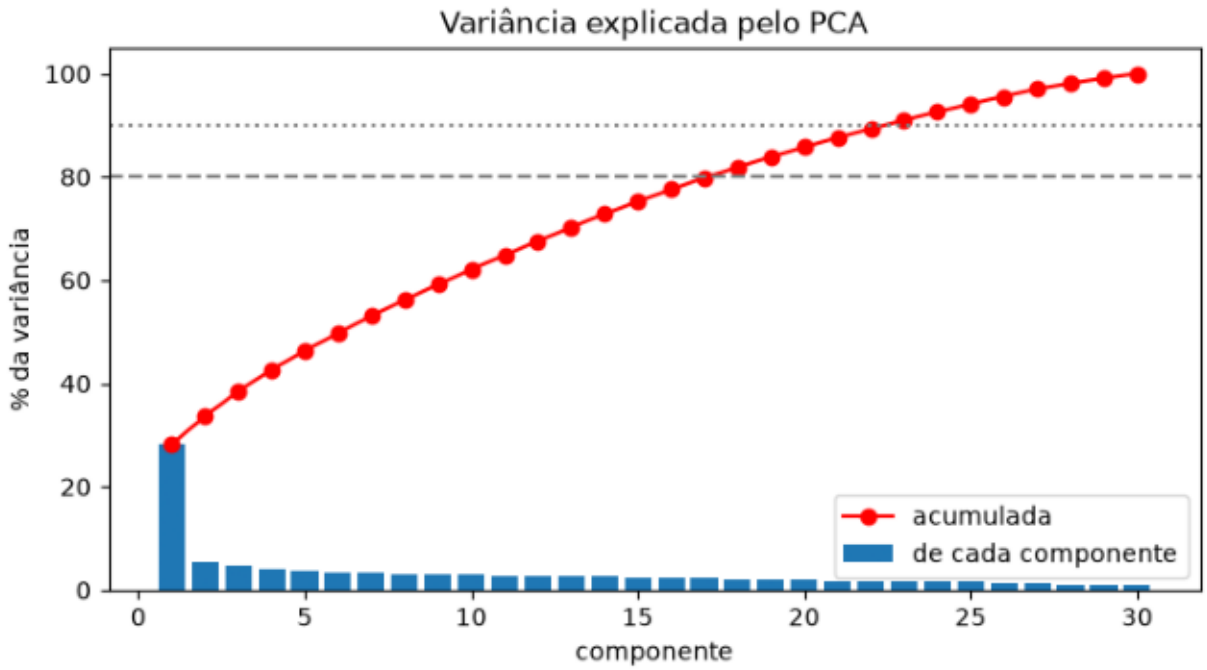


Figura 67. Variância explicada por cada componente do PCA e variância acumulada.

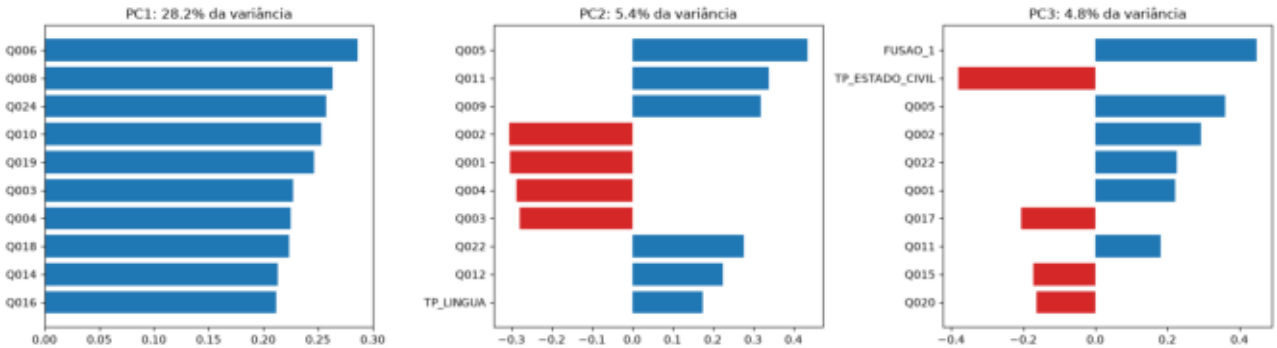


Figura 68. Cargas das 10 maiores features nos 3 primeiros componentes.

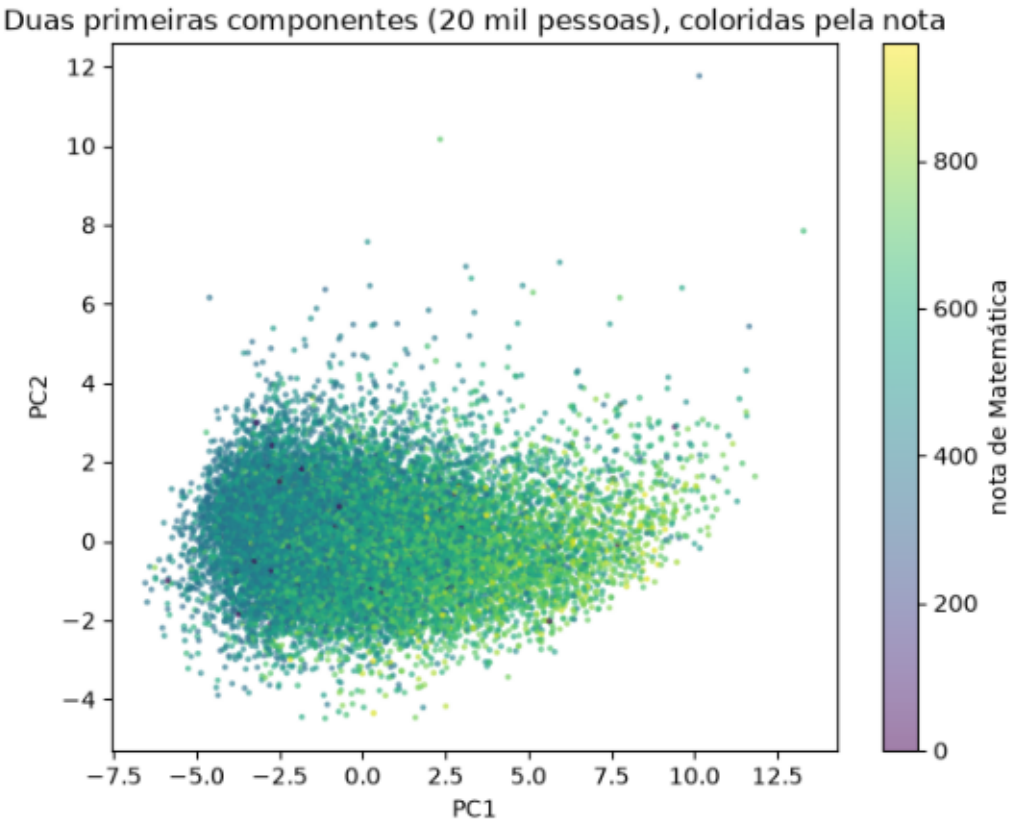


Figura 69. As duas primeiras componentes (20 mil pessoas), coloridas pela nota.

9.2 PCA dentro do Pipeline (exigência do PDF)

Pipeline StandardScaler → PCA(k componentes) → regressor, com a padronização e o PCA reajustados só no treino de cada dobra. Testados dois regressores, com k = 5, 10, 15, 20 e 25 (de 30) e o modelo sem PCA, nas mesmas dobras.

Tabela 6. RMSE e R² com e sem PCA (dataset_1_fundido).

Componentes	Regressão linear: RMSE	Regressão linear: R²	Gradient Boosting: RMSE	Gradient Boosting: R²
sem PCA	111,153	0,287	107,770	0,330
25	111,658	0,280	110,165	0,300
20	111,887	0,278	110,432	0,296
15	112,718	0,267	111,148	0,287
10	113,047	0,262	111,551	0,282
5	114,425	0,244	113,210	0,260

Resultado: o PCA piora os dois regressores, e o RMSE cresce à medida que se cortam componentes. Nenhum k testado fica dentro de 1 desvio do modelo sem PCA (desvio de 0,18 a 0,23). A regressão linear só se aproximaria do resultado sem PCA com todos os componentes (o PCA completo é só uma rotação). O Gradient Boosting perde mais, porque o PCA mistura as colunas e dificulta as divisões das árvores. Justificativa do número de componentes: para 80% da variância seriam 18 (seção 9.1), mas nenhum corte melhora o erro; a melhor escolha para os modelos finais é não usar PCA, o que é um resultado legítimo para o artigo.

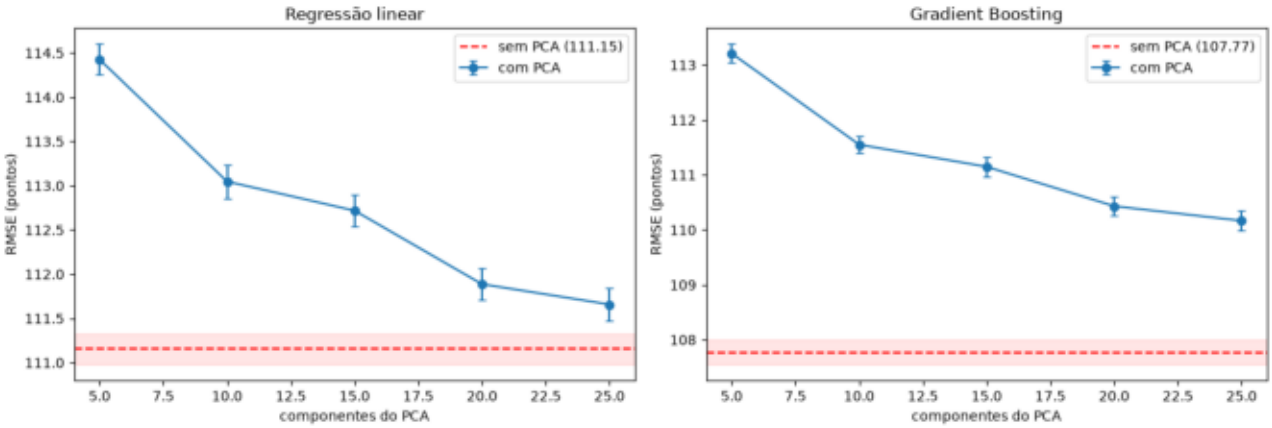


Figura 70. RMSE em função do número de componentes do PCA, para a regressão linear e o Gradient Boosting (linha vermelha: sem PCA, com a faixa de 1 desvio).

9.3 t-SNE (diagnóstico)

O t-SNE desenha as pessoas em 2 dimensões mantendo perto as que são parecidas, e não entra em nenhum modelo (não sabe transformar pessoas novas). Usou-se uma amostra de 15 mil pessoas do desenvolvimento, o que o PDF aceita por ser diagnóstico. Distâncias grandes entre grupos não devem ser interpretadas ao pé da letra: o t-SNE preserva vizinhanças, não distâncias.

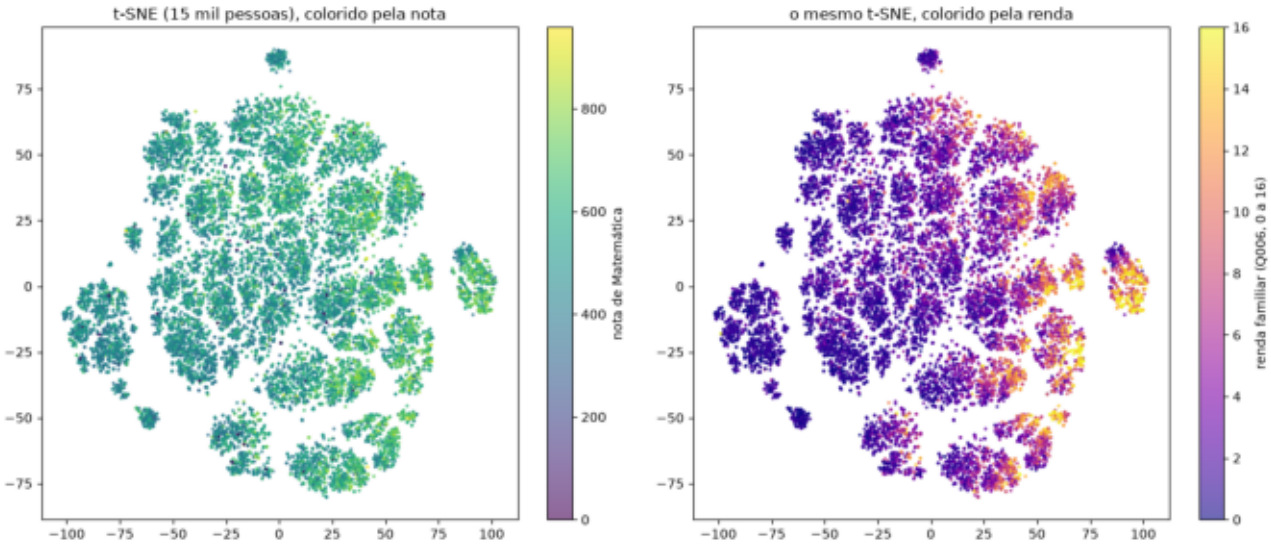


Figura 71. t-SNE de 15 mil pessoas, colorido pela nota (esquerda) e pela renda familiar Q006 (direita).

9.4 K-means

O MiniBatchKMeans foi rodado para k de 2 a 10 nos 2,15 milhões de pessoas padronizadas. A silhueta é maior com k = 2 (0,207) e cai para menos de 0,11 de k = 3 em diante: as pessoas formam um contínuo, não ilhas. Os dois grupos separam o perfil de maior renda e escolaridade (705.499 pessoas, nota média 607,5, Q006 médio de 7,6) do de menor (1.448.442 pessoas, nota média 497,9, Q006 médio de 2,0), mas a nota varia muito dentro de cada grupo (desvios de 116 e 131).

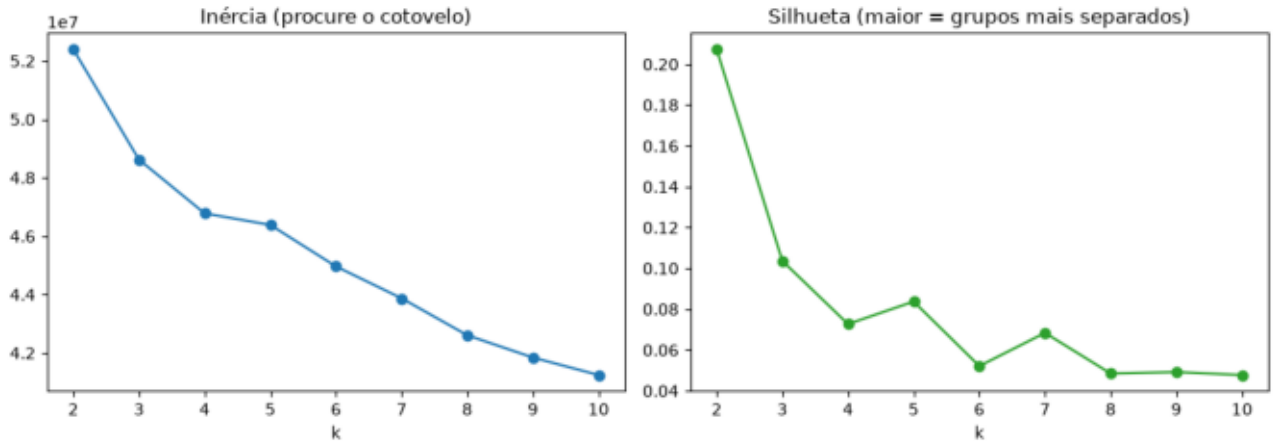


Figura 72. Inércia e silhueta do K-means para k de 2 a 10.

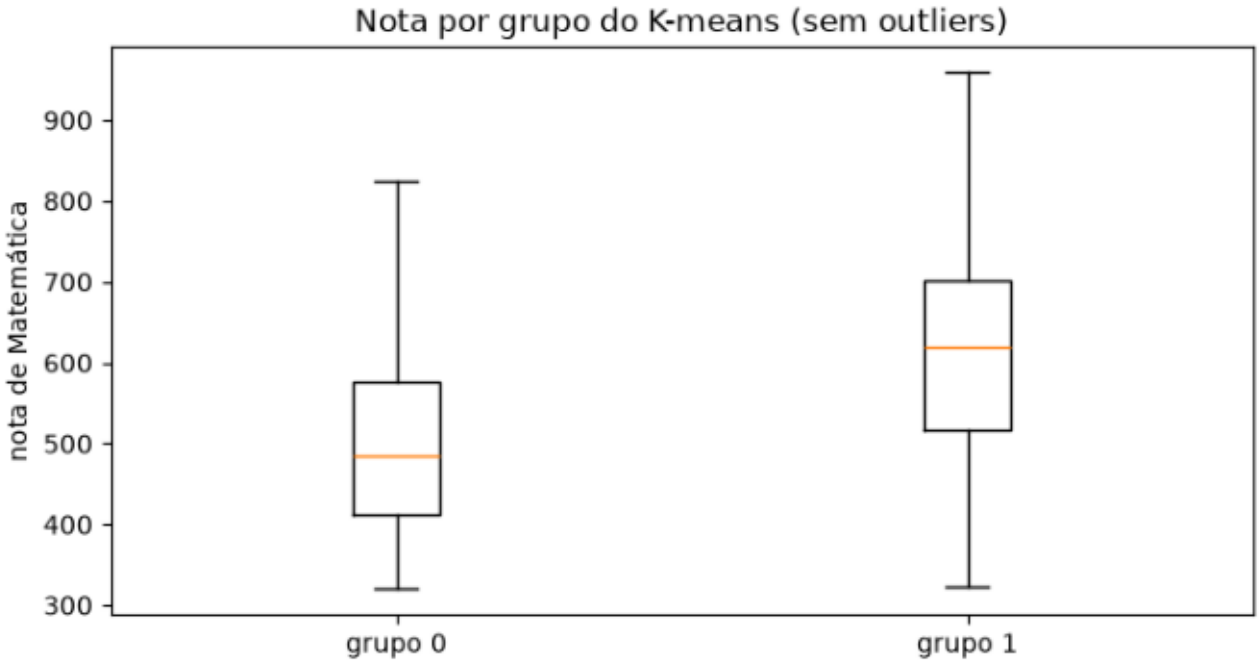


Figura 73. Nota por grupo do K-means (k = 2), sem outliers.

Dar o grupo ao modelo (distâncias aos centros, com o K-means reajustado só no treino de cada dobra) não ajuda: Gradient Boosting 107,770 sem e 107,789 com as distâncias aos 2 grupos (diferença de −0,019, bem menor que o desvio de 0,226). O Gradient Boosting já encontra essas interações sozinho.

10. Discussão

10.1 Por que o R² fica em torno de 0,33

- As features descrevem o perfil (renda, escolaridade dos pais, bens, tipo de escola). O que mais pesa na nota de Matemática (horas de estudo, base escolar, qualidade do ensino, circunstâncias do dia da prova) não está nos dados. Pessoas com o mesmo perfil tiram notas muito diferentes.
- Famílias de modelos muito diferentes (linear, árvore, KNN) caem no mesmo patamar de 110 a 112 de RMSE, e árvores só ganham 3 a 4 pontos: o limite vem das features, não do algoritmo. Se o problema fosse fortemente não linear, os modelos flexíveis ganhariam muito mais.
- A base de 2023 não traz o código da escola (só município e UF), então não é possível usar a nota média da escola, que seria um dos melhores preditores. As colunas da escola só existem para cerca de 27% dos participantes.
- Usar notas de outras áreas, presença ou respostas elevaria o R² acima de 0,7, mas isso é vazamento e o PDF proíbe. Prever pelo perfil é o objetivo do trabalho.

10.2 O que funcionou e o que não funcionou

Alavanca	Efeito no RMSE	Avaliação
Modelos de árvores (Gradient Boosting, Random Forest)	−3,4 e −1,7 contra a regressão linear	Funcionou, é o maior ganho
Informação de escola	cerca de −0,4 a −0,5	Funcionou, pequeno
UF da prova e desdobrar a FUSAO_1	−0,64 e −0,47 (−1,15 juntas)	Funcionou, pequeno
Busca de hiperparâmetros	de −0,9 (bagging) a −0,09 (Gradient Boosting)	Funcionou só nos modelos de bagging
NAO_SEI e nacionalidade	cerca de −0,2 a −0,4	Pequeno
3 features criadas	cerca de −0,01	Sem efeito prático
Stacking	−0,007 contra o Gradient Boosting	Não vale o custo
Treino sem zeros	−0,06 a +0,01 (dentro do desvio)	Sem efeito geral mensurável
PCA	+0,5 a +5,4 (piora)	Prejudica
K-means como feature	+0,02 (dentro do desvio)	Sem efeito
KNN e SVR	KNN +0,4 contra a regressão linear	Lentos e sem ganho

11. Limitações, riscos e pendências

Limitações e riscos conhecidos

- Vazamento pequeno na preparação: a média e o desvio da FUSAO_1 e as medianas de Q001 a Q004 foram calculados com todas as linhas, inclusive o teste. Deve ser refeito dentro do Pipeline (por exemplo com SimpleImputer e mantendo as quatro colunas separadas), aprendido só no treino de cada dobra, antes do modelo final.
- As colunas de escola cobrem só cerca de 27% da base; para o resto, a escola não ajuda a prever nada.
- Colunas nominais (cor/raça, estado civil) entram como número em escada nos datasets atuais, o que prejudica principalmente os modelos lineares; falta o one-hot.
- A correlação de Spearman não verifica redundância entre colunas nominais; falta o V de Cramér para esses pares e um método de seleção de atributos dentro do Pipeline (o PDF exige testar um).
- O RMSE de uma busca de hiperparâmetros é otimista (foi escolhido o melhor entre 10). As diferenças menores que o desvio entre as dobras não provam melhora.
- A divisão avalia novos participantes da mesma edição; não demonstra generalização para escolas ou municípios inéditos.
- Os arquivos resultados/tabelas/busca_<modelo>.csv são gravados com o mesmo nome pelo notebook otimizado e pelo notebook sem zeros: o que foi rodado por último sobrescreve o anterior (Ridge, árvore e Gradient Boosting). Vale usar nomes diferentes.

Pendências pelo PDF do projeto

- Município da escola e da prova com target encoding dentro do Pipeline (o maior sinal ainda não usado).
- Balanceamento por faixa de nota (ponderação por faixa de 10 pontos, suavizada, só no treino de cada dobra): exigência do PDF ainda não cumprida.
- Busca de hiperparâmetros nos 3 melhores regressores com o dataset final, depois da correção do vazamento.
- Curva de aprendizado do modelo final, análise de erros por faixa de nota e por grupo, e avaliação no teste (uma única vez, depois de fixar a solução): baseline, regressão linear sem regularização e a solução final.
- Registro dos experimentos em resultados/experimentos.csv (hipótese, features, preparação, modelo, parâmetros, métricas por dobra, média, desvio, tempo e conclusão) e resultados/previsoes_teste.csv.
- Hipóteses de aprofundamento (por exemplo comparar one-hot com números discretos, UF e município, Optuna contra RandomizedSearchCV).
- Artigo (10 páginas, ABNT), pitch presencial, README com a ordem de execução e o ambiente.

Apêndice A. Colunas usadas, criadas e removidas

Coluna(s)	Situação	Justificativa
NU_NOTA_MT	Alvo (y)	Nota de Matemática; só participantes com nota observada
TP_SEXO, TP_ESTADO_CIVIL, TP_COR_RACA, TP_LINGUA	Usadas	Perfil demográfico (nominais entram como número em escada nos datasets atuais)
Q001 a Q025	Usadas	Questionário socioeconômico; 'não sei' de Q001 a Q004 preenchido com a mediana
IN_TREINEIRO, TP_ANO_CONCLUIU, TP_FAIXA_ETARIA, TP_ST_CONCLUSAO	Fundidas em FUSAO_1	|Spearman| > 0,7 entre si; desdobradas pode ajudar (−0,47)
PESSOAS_POR_QUARTO, CELULAR_POR_MORADOR, RENDA_MENOS_ESCOL	Criadas	Hipóteses na seção 4.1; |Spearman| < 0,7 com todas as colunas
ESCOLA_PUBLICA, ESCOLA_PRIVADA, LOC_URBANA, LOC_RURAL	Dataset 2 em diante	TP_ESCOLA e TP_LOCALIZACAO_ESC em one-hot; vazio = 'sem informação'
DEP_FEDERAL, DEP_ESTADUAL, DEP_MUNICIPAL, DEP_PRIVADA	Removidas	Redundantes com ESCOLA_* e LOC_* (0,88 e 0,73); DEP_MUNICIPAL tem 0,2% das linhas
Q001_NAO_SEI a Q004_NAO_SEI, NAC_* (4)	Dataset 3	Desproporcionais, mas com sinal (NAO_SEI: −40 a −50 pontos)
CO_/NO_MUNICIPIO_ESC, CO_/SG_UF_ESC, TP_SIT_FUNC_ESC, TP_ENSINO	Removidas	73% de ausentes, alta cardinalidade, categorias muito raras
SG_UF_PROVA, CO_UF_PROVA, CO_/NO_MUNICIPIO_PROVA	Removidas (por ora)	UF ajuda (−0,64) e o município é o próximo candidato (target encoding)
NU_NOTA_CN/CH/LC, NU_NOTA_COMP1 a 5, NU_NOTA_REDACAO, TP_PRESENCA_*, CO_PROVA_*, TX_RESPOSTAS_*, TX_GABARITO_*, TP_STATUS_REDACAO, NU_ANO	Proibidas	Vazamento: resultados ou informações da própria prova
NU_INSCRICAO	Identificador	Guardado à parte em ids_elegiveis.csv; não é entrada do modelo

Apêndice B. Espaços de busca

RandomizedSearchCV, 10 configurações por modelo, validação cruzada nas mesmas 3 dobras, semente 42.

Modelo	Hiperparâmetros e faixas
Ridge	alpha: loguniform de 1e-3 a 1e5
Árvore de decisão	max_depth: inteiro de 5 a 30; min_samples_leaf: inteiro de 5 a 299; max_features: None, 0,8 ou 0,5
SVR linear	C: loguniform de 1e-2 a 10; epsilon: uniforme de 0 a 5
Bagging	n_estimators: 10 a 40; max_samples: 0,5, 0,7 ou 1,0; max_features: 0,6, 0,8 ou 1,0; árvore base: max_depth 6 a 15 e min_samples_leaf 20 a 199
Pasting	igual ao bagging, com max_samples: 0,2, 0,3, 0,5 ou 0,7 (sem reposição)

Random Forest	n_estimators: 50 ou 100; max_depth: 8 a 15; min_samples_leaf: 10 a 199; max_features: 0,3, 0,5 ou 0,7
Gradient Boosting	learning_rate: loguniform de 0,02 a 0,3; max_iter: 200, 300 ou 500; max_leaf_nodes: 15 a 99; min_samples_leaf: 50 a 499; l2_regularization: loguniform de 1e-3 a 10

Apêndice C. Arquivos gerados

- Notebooks (pasta notebooks/): 01-exploracao-filtro (dados, Spearman, fusão, datasets 1 a 3); 02-treino-modelos (todos os modelos, configuração inicial); 02-treino-modelos-optimized (busca de hiperparâmetros); 02-treino-modelos-sem-zeros-optimized (treino sem zeros); 03-reducao-dimensionalidade (PCA, t-SNE e K-means).
- Dados preparados (dados/processed/, não vão ao GitHub): dataset_1_fundido, dataset_1_features, dataset_2_escola, dataset_2_features_escola, dataset_3_sem_escola, dataset_3_sem_escola_features, dataset_3_escola, dataset_3_escola_features e ids_elegiveis.
- Partições (dados/splits/): desenvolvimento_ids.csv, teste_ids.csv e dobras_cv.csv.
- Modelos treinados nos 80% do desenvolvimento (models/*.joblib, não vão ao GitHub): baseline, regressão linear, Ridge, árvore, KNN, SVR linear, bagging, pasting, Random Forest, Gradient Boosting e stacking, nas versões inicial, otimizada e sem zeros. O KNN guarda todo o treino (cerca de meio gigabyte).
- Tabelas das buscas: resultados/tabelas/busca_<modelo>.csv.